

Gilsiley Henrique Darú

Orientador: Prof. Dr. Gustavo Valentim Loch  
Programa de Pós-Graduação em Métodos Numéricos em Engenharia  
Universidade Federal do Paraná

Defesa de Doutorado — 2026



[0:30] Cumprimente a banca. Bom dia. Vou apresentar o FALCO, um framework de aprendizado ativo com oráculos LLM para classificação de texto curto em português. Respire; não leia o slide.

- 1 Contexto e problema
- 2 Fundamentação
- 3 Método
- 4 Resultados
- 5 Entregas e conclusão

[0:30] O percurso: o problema e a hipótese; a fundamentação; o método; os resultados por pilar; e as entregas. Não detalhe — é um mapa.

- Descrições de produtos como saem do cupom fiscal:  
CERV BRAHMA LT 350ML, SAB OMO 1KG
- 4–50 caracteres, caixa alta, abreviação agressiva, sem contexto
- **621 categorias** com cauda longa severa (razão de desbalanceamento  $> 1000:1$ )
- Aplicações: automação fiscal, *pricing*, cesta de mercado, estatística de consumo

### Por que é difícil

Pouca informação por instância + centenas de classes raras  $\Rightarrow$  o Macro F1 é implacável e a partida a frio é crítica.

[2:00] Ancore no exemplo concreto: leia CERV BRAHMA LT 350ML em voz alta. Ponto-chave: 621 classes, cauda longa, texto sem contexto. Feche com por isso o Macro F1 é implacável e a partida a frio é crítica— planta as duas ideias que voltam.

- Classificadores modernos são bons; **obter rótulos** é o custo dominante
- **Aprendizado ativo (AA)**: o modelo escolhe o que vale a pena rotular
- Mas o laço clássico tem **duas fraturas**:
  - ① *Partida a frio*: as estratégias dependem de um modelo que ainda não existe
  - ② *Oráculo perfeito*: assume-se anotador correto e de custo unitário
- **LLMs** mudam o jogo nas duas frentes — podem *selecionar* e podem *rotular* — mas trazem ruído estruturado e um novo modelo de custo (por token)

É nessas duas fraturas que o FALCO atua.

[2:00] A frase que a banca precisa reter: o gargalo não é o modelo, é o rótulo. Explique as duas fraturas devagar (cold start e oráculo perfeito). Feche dizendo que LLMs mexem nas duas — transição natural para a hipótese.



## Pergunta

Como reduzir o custo de rotulagem em classificação de texto curto em português, usando LLMs nas fases em que o AA tradicional é mais frágil?

## Hipótese — critério quantitativo fixado *antes* dos experimentos

Atingir  $\geq 95\%$  do Macro F1 da supervisão completa com  $\leq 30\%$  dos rótulos (via oráculo LLM), superando amostragem aleatória e incerteza pura com significância estatística.

Definido de antemão o que conta como **refutação**; *gate* pré-registrado de qualidade do oráculo. Postura: **nenhum número sem artefato rastreável**.

[2:30] Este é o slide mais importante do início. Enfatize PRÉ-REGISTRO: o critério (95%/30%) e a definição de refutação foram fixados ANTES. Diga a frase-assinatura: ñnenhum número sem artefato rastreável: A banca vai gostar disso.

## Objetivo geral

Propor e avaliar um framework de AA com oráculos LLM progressivos para texto curto em português.

## Objetivos específicos

- Medir a sensibilidade do conjunto inicial (P1)
- Propor cold start sem rótulos (P2 — DRI-SL)
- Avaliar LLMs como oráculo, com custo (P3)
- Integrar e testar o framework (P4)

## Contribuições

- Framework FALCO + DRI-SL (e variante DRI-SL-C)
- Avaliação instrumentada de oráculos (621 classes, PT)
- Métrica LCE; achados de instrumento (enum, serving)
- Base pública auditada (DOI); biblioteca aberta (pip) + interface


[1:30] Leia rápido — é o mapa dos 4 pilares. Diga que cada pilar tem pergunta e critério próprios, e que os resultados virão nessa ordem.

- **Aprendizado ativo:** seleção por incerteza, comitê, densidade; limitações do laço (cold start, oráculo imperfeito, viés de amostragem)
- **LLM como oráculo:** Gilardi (2023) — supera *crowd*; estudos de produto param em dezenas a  $\approx 370$  classes
- **Texto curto:** esparsidade, cauda longa, português de varejo
- **Instrumentação estatística:** Wilson, McNemar, Wilcoxon, bootstrap

## Lacuna

Ninguém combina cold start informado + oráculo LLM progressivo + texto curto em português + custo instrumentado. É a célula vazia da tabela de lacunas.

[2:00] Não faça revisão de literatura falada; destaque só a LACUNA (a célula vazia: cold start informado + oráculo LLM + PT + custo instrumentado). Mencione que a instrumentação estatística está toda declarada — Wilson, McNemar, Wilcoxon.



- Diferencial: não é uma estratégia nova — é **disciplina de medição**. Cada decisão vem de critério pré-registrado e artefato rastreável.

[2:30] Caminhe pelo diagrama da esquerda para a direita: pool, Fase 1 (DRI-SL), Fase 2 (incerteza+leve), parada, classificador forte 1x no fim. Aponte o gate embaixo alimentando os oráculos. Frase central: o diferencial não é uma estratégia nova, é disciplina de medição:



## Base (DOI Kaggle, pública desde 2022)

- $\approx 250$  mil descrições, 621 categorias
- Auditoria do gabarito: censo de conflitos, multi-gold; teto  $\approx 99,3\%$
- Deduplicação *antes* do particionamento (evita vazamento)

## Rigor

- Partições imutáveis, sementes fixas
- Pareamento (McNemar) e Wilcoxon (8 sementes)
- IC de Wilson em toda proporção
- Tudo versionado; execuções retomáveis

Quatro pilares P1–P4, cada um com pergunta e critério declarados.

[2:00] Destaque a AUDITORIA do gabarito (censo de conflitos, teto 99,3%) — mostra rigor. É a deduplicação antes do particionamento (evita vazamento). Rigor estatístico: partições imutáveis, 8 sementes, Wilson.

## Começar bem

P1–P2

DRI-SL (cold start)

## Perguntar bem

E1 / E6

seleção por incerteza

## Pagar bem

P3 / E0

oráculo LLM barato

## Integrar e testar

E4 / E5 / E3'

o framework à prova

→ cada frente responde uma pergunta e alimenta a próxima →

- A tese não é uma coleção de experimentos — é *um* argumento em quatro passos.

[1:00] Este slide é a bússola dos próximos 20 minutos. Diga a frase: a tese não é uma coleção de experimentos, é um argumento em quatro passos: começar bem, perguntar bem, pagar bem, e integrar tudo para testar. Volte a esta ideia ao terminar cada pilar — é o fio que costura os resultados.

- 47 tamanhos  $\times$  30 repetições
- Em  $|L_0| = 100$ : acurácia varia **6,4 p.p.** só pelo sorteio
- A cobertura de classes é o mecanismo (Macro F1 segue a cobertura)
- Reexecução independente (protocolo com dedup): divergência  $\leq 0,7$  p.p.

### Consequência

Se a composição importa tanto no regime pequeno — o do cold start —, então *construir*  $L_0$  deliberadamente é a alavanca disponível antes de existir qualquer rótulo.

[2:30] O número que impressiona: 6,4 p.p. de variação SÓ pelo sorteio em  $L0=100$ . Explique o mecanismo (cobertura de classes). Feche: se a composição importa tanto, construir o  $L0$  é a alavanca antes de existir rótulo— prepara o P2.

| $ L_0 $ | DRI-SL      |             | AG (melhor indivíduo) |          |
|---------|-------------|-------------|-----------------------|----------|
|         | Acc         | Macro F1    | Acc                   | Macro F1 |
| 100     | <b>41,2</b> | <b>6,9</b>  | 38,8                  | 6,5      |
| 1.000   | <b>67,4</b> | <b>25,8</b> | 62,2                  | 24,7     |
| 5.000   | <b>76,9</b> | <b>44,1</b> | 74,1                  | 40,1     |

- Heurística determinística (densidade semântica + variedade lexical), **sem rótulos**
- Supera o *melhor indivíduo* de um algoritmo genético supervisionado até  $|L_0| = 5.000$
- Auditoria de circularidade: envelope do AG estava inflado em 6,3 p.p. — a comparação é **conservadora**

[3:00] Slide forte. DRI-SL não usa NENHUM rótulo e supera o MELHOR indivíduo de um AG supervisionado. Deixe isso pousar. Depois a honestidade que impressiona banca: a auditoria de circularidade mostrou que o AG estava inflado 6,3 p.p. — então a comparação é conservadora, o DRI-SL vence por mais.



| Oráculo                   | Acurácia | Macro F1 | US\$/1k      |
|---------------------------|----------|----------|--------------|
| deepseek-v4-pro           | 82,1%    | 0,785    | 0,410        |
| gpt-4o                    | 80,9%    | 0,788    | 0,923        |
| deepseek-v4-flash         | 78,3%    | 0,750    | <b>0,035</b> |
| nemotron-3-ultra (grátis) | 77,9%    | 0,752    | <b>0,000</b> |
| gpt-4o-mini               | 61,3%    | 0,518    | 0,051        |

- Platô 77–83% em 621 classes; Macro F1 zero-shot **supera** o supervisionado leve
- Spread de custo de **26×** dentro de empate estatístico
- $\approx 48\%$  do erro é *convenção de catálogo*, não ignorância do produto

[3:00] Três mensagens: (1) platô 77-83% em 621 classes; (2) spread de custo 26x dentro de empate estatístico — escolher oráculo é decisão de engenharia; (3) o Macro F1 zero-shot supera o supervisionado leve porque o LLM é bom nas classes raras. Aponte o nemotron grátis.

- **Contrato de saída importa:** sem restrição ao espaço de classes, **6,8%** das respostas viram falsos erros de fraseado
- **O provedor de *serving* importa:** o mesmo modelo gratuito diverge *de si mesmo* entre dois serviços ( $p < 0,001$ )
- **E0-P (prompt):** regras de fronteira ajudam na distribuição de produção (+4,6 p.p.,  $p = 0,012$ ) mas *degradam* as classes raras (−10,8 p.p.) — faca de dois gumes

## Lição

Cada medição de oráculo é uma fotografia da tripla (modelo, provedor, data) — e o instrumento move resultados por margens maiores que várias diferenças entre modelos.

[2:30] O achado metodológico. A medição é parte do método. Os 6,8% de falsos erros pelo contrato de saída e a divergência entre provedores (mesmo modelo diverge de si) — isso costuma render pergunta da banca, esteja pronto. E0-P: a faca de dois gumes.

- O ruído do oráculo vira *ruído de rótulo* para o classificador
- E4: injeta ruído uniforme  $\varepsilon \in \{0; 0,1; 0,2; 0,4\}$
- Retenção do Macro F1 final: **87% / 74% / 54%** em  $\varepsilon = 0,1/0,2/0,4$
- Desenho *pessimista*: ruído real do oráculo é **estruturado** (categorias-irmãs), menos danoso que uniforme de mesma taxa

O resultado positivo do E4 é um limite inferior do desempenho esperável com os oráculos reais.

[2:00] Robustez a ruído: retenção 87/74/54%. O ponto esperto: o desenho é PESSIMISTA (ruído uniforme), enquanto o ruído real é estruturado e menos danoso — então o resultado é um limite inferior. Isso fortalece qualquer número positivo.

### Protocolo pool / população reservada

- Pool 50k rotulável; população 181k *já* tocada
- Mede-se no teste interno (o que o praticante vê) e na população (real)
- Braço aleatório de controle:  $\Delta \approx 0$  (valida o instrumento)

Consequência de projeto: conjunto reservado é obrigatório para decidir liberação.

### Achado (8 sementes)

- Acurácia interna **subestima**:  $-17,1 \pm 1,0$  p.p.
- Macro F1 interno **superestima**
- Direções opostas conforme a métrica

[2:30] Explique o protocolo pool/população e o braço de controle aleatório que VALIDA o instrumento (delta zero). Depois o achado: acurácia interna subestima 17 p.p., Macro F1 superestima — direções opostas. Conclusão de projeto: conjunto reservado é obrigatório.



- Entropia satura com  **$9,1k \pm 0,6k$**  rótulos; aleatório precisa de  $15,5k \pm 1,1k$
- Vence o aleatório em teto **8/8 sementes** (Wilcoxon  $p = 0,0078$ )
- **Menos é mais**: treinar com a amostra ativa *supera* treinar com o pool completo (a amostra ativa é mais balanceada)
- Ablação: o ganho da DRI-SL-C vem do *agrupamento por predição*, não da novidade lexical (que é contraproducente no regime contínuo)

Um aviso operacional: **rotular mais pode piorar** a métrica macro.

[2:30] Entropia satura com 9k vs 15k do aleatório, vence 8/8 sementes ( $p=0,0078$ ). E o contraintuitivo: MENOS É MAIS — treinar com a amostra ativa supera o pool completo. Este é o achado mais memorável; dê ênfase e uma pausa.

| Braço     | Rótulos | Acc.         | Macro F1     | Critério |
|-----------|---------|--------------|--------------|----------|
| E (30%)   | 15.000  | 83,1%        | 0,380        | ✗ ✗      |
| E20 (40%) | 20.000  | 85,9%        | 0,418        | ✓ ✗      |
| E25 (50%) | 25.000  | 87,3%        | 0,434        | ✓ ✓      |
| E35 (70%) | 35.000  | <b>88,6%</b> | <b>0,463</b> | ✓ ✓      |
| D (100%)  | 50.000  | 88,3%        | 0,451        | —        |

- BERTimbau treinado *fora do laço*, 1× no fim, avaliado na população reservada
- Hipótese **refutada em 30%**, mas **sustentada a partir de 50%**
- Gargalo é a **parada** — não o oráculo nem a seleção
- Com 70%, o modelo forte **supera a supervisão completa** do pool

[3:00] O clímax. BERTimbau treinado fora do laço julga a hipótese. Leia a tabela: refutada em 30%, sustentada a partir de 50%. Aponte E35 (70%) SUPERANDO a régua completa — menos é mais de novo, agora no transformer. Frase: ö gargalo era a parada, não o oráculo:

- **Ruído do oráculo** (A vs. B, mesmos itens): custa 4,4 p.p. de acurácia, mas em Macro F1 *ajuda* — erro estruturado regulariza caudas
- **Seleção** (B vs. C): compra cobertura (620 vs. 493 classes), não acurácia bruta
- **Orçamento**: é o fator dominante — a parada por estagnação do classificador leve encerra o laço cedo demais para o objetivo macro do forte

## Correção medida

Parar por *proxy* do modelo forte, ou piso de  $\approx 50\%$  do pool. A hipótese não é infirmada: ela requer o orçamento e a parada corretos.

[2:30] Aqui você antecipa a pergunta "você não mudou a trave?". Explique a decomposição: ruído (ajuda o macro!), seleção (compra cobertura), orçamento (o culpado). O critério pré-registrado permanece; a varredura MEDE onde ele passa a valer. Piso de 50%.

## Científico

- Framework FALCO + DRI-SL / DRI-SL-C
- Oráculos instrumentados (621 classes, PT)
- Métrica LCE; base auditada com DOI
- 5 artigos derivados em preparação

Reprodutibilidade *clicável*: cada número tem um artefato por trás.

## Software (aberto)

- Biblioteca `activelearning` (pip, DDD, 80 testes)
- FlowBuilder: catálogo executável — *reproduzir e reprisar* cada número da tese
- Ciclo real rodado a **custo zero** de oráculo

[2:00] Mostre que a pesquisa virou uso: biblioteca pip, 80 testes, e a interface que REPRODUZ e REPRISA cada número. Frase: "reprodutibilidade clicável". Mencione o ciclo real a custo zero de oráculo.



## Limitações

- Um único conjunto de dados (autor)
- E3'/E6 com semente única em parte dos braços (declarado)
- Custos de API datados (razões mais estáveis que valores)

## Futuros

- Parada ancorada no modelo forte (já medida)
- Composição/roteamento de oráculos (*bandit*)
- *Prompt* otimizável a partir da matriz de confusão
- Réplica em benchmark público (AlleNoise)

[1:30] Seja honesto e curto — listar limitações com naturalidade transmite maturidade. Um dataset, semente única em parte dos braços (declarado), custos datados. Futuros saem dos dados.

## A resposta

O custo de rotulagem em texto curto em português pode ser atacado nas três frentes que o FALCO integra: **começar bem** (DRI-SL), **perguntar bem** (incerteza) e **pagar bem** (oráculos LLM por centavos).

- A hipótese central se sustenta com  $\approx 50\%$  dos rótulos e parada ancorada no modelo forte — refutação em 30% e piso corrigido, ambos medidos
- Três achados são sobre **instrumentos**, não modelos (enum, serving, circularidade)
- Postura: **nenhum número sem artefato rastreável**

Obrigado. Perguntas?

[2:00] Recapitule as três frentes: começar bem, perguntar bem, pagar bem. Reafirme: hipótese sustentada com 50% e parada correta, ambos medidos. Feche com a postura metodológica. Agradeça e abra para perguntas com calma.

- **Régua = pool de 50k**: o AA só enxerga o pool; comparar com a base inteira confundiria seleção com volume de dados
- Classificador forte **fora do laço**,  $1\times$  no fim — como o FALCO opera em produção
- Braços pareados A/B isolam ruído; C isola seleção;  $E_k$  varrem orçamento
- Proveniência: P1/P2 originais no repo `activetextclassification`; P3/P4 e reexecuções na `activelearning` — portes verificados (igualdade de escores, reexecução, conferência de artefato)

[reserva] Use se perguntarem sobre o desenho do E3' ou a régua de 50k, ou a proveniência dupla (legado x biblioteca nova).

- Nenhum oráculo atinge o gate de 85%  $\Rightarrow$  E4 (ruído) torna-se central
- **LLM Inicial** = deepseek-v4-flash (78–82% a US\$0,035/1k)
- **LLM Avançado** = deepseek-v4-pro (superioridade significativa,  $p < 0,001$ )
- Alternativa custo zero: nemotron-3-ultra (empata com o flash,  $p = 0,76$ )
- Restrição operacional: vazão do provedor define o tempo de parede tanto quanto o preço

[reserva] Use se perguntarem por que deepseek-v4-flash/pro, ou sobre o gate de 85% e a alternativa gratuita.



| Situação                          | Instrumento                               |
|-----------------------------------|-------------------------------------------|
| Precisão de uma acurácia          | IC de Wilson 95%                          |
| Dois oráculos, mesmas instâncias  | McNemar (exato se poucos discordantes)    |
| Duas estratégias, mesmas sementes | Wilcoxon (mín. 8 sementes $p/ p < 0,05$ ) |
| Funcional sem distribuição        | IC <i>bootstrap</i> percentil             |

Cada uso mapeado na tese à situação, ao teste e à referência original + aplicada.

[reserva] Use se perguntarem sobre escolha dos testes estatísticos — situação -> instrumento.

- 1 Codifica o pool em *embeddings* de texto
- 2 Agrupa por *k*-means (agrupamentos semânticos)
- 3 Aloca o orçamento proporcional à massa de cada grupo
- 4 Preenche cada cota gulosamente, preferindo instâncias que adicionam *tokens* lexicais inéditos (variedade)

Determinístico, custo linear após o agrupamento, **sem usar rótulos**. Variante **DRI-SL-C**: após o cold start, os grupos passam a ser as classes previstas pelo classificador (para a seleção contínua).

[reserva] Use se perguntarem como o DRI-SL funciona por dentro, ou a variante DRI-SL-C.