

Gilsiley Henrique Darú

Orientador: Prof. Dr. Gustavo Valentim Loch
Programa de Pós-Graduação em Métodos Numéricos em Engenharia
Universidade Federal do Paraná

Defesa de Doutorado — 2026



- 1 Contexto e problema
- 2 Fundamentação
- 3 Método
- 4 Resultados
- 5 Entregas e conclusão

- Descrições de produtos como saem do cupom fiscal:
CERV BRAHMA LT 350ML, SAB OMO 1KG
- 4–50 caracteres, caixa alta, abreviação agressiva, sem contexto
- **621 categorias** com cauda longa severa (razão de desbalanceamento $> 1000:1$)
- Aplicações: automação fiscal, *pricing*, cesta de mercado, estatística de consumo

Por que é difícil

Pouca informação por instância + centenas de classes raras $\Rightarrow$ o Macro F1 é implacável e a partida a frio é crítica.

- Classificadores modernos são bons; *obter rótulos* é o custo dominante
- *Aprendizado ativo (AA)*: o modelo escolhe o que vale a pena rotular
- Mas o laço clássico tem **duas fraturas**:
 - ① *Partida a frio*: as estratégias dependem de um modelo que ainda não existe
 - ② *Oráculo perfeito*: assume-se anotador correto e de custo unitário
- As *LLMs* mudam o jogo nas duas frentes — podem *selecionar* e podem *rotular* — mas trazem ruído estruturado e um novo modelo de custo (por token)

É nessas duas fraturas que o FALCO atua.

Pergunta

Como reduzir o custo de rotulagem em classificação de texto curto em português, usando LLMs nas fases em que o AA tradicional é mais frágil?

Hipótese — critério quantitativo fixado *antes* dos experimentos

Atingir $\geq 95\%$ do Macro F1 da supervisão completa com $\leq 30\%$ dos rótulos (via oráculo LLM), superando amostragem aleatória e incerteza pura com significância estatística.

Definido de antemão o que conta como *refutação*; *gate* pré-registrado de qualidade do oráculo. Postura: *nenhum número sem artefato rastreável*.

Objetivo geral

Propor e avaliar um framework de AA com oráculos LLM progressivos para texto curto em português.

Objetivos específicos

- Medir a sensibilidade do conjunto inicial (P1)
- Propor cold start sem rótulos (P2 — DRI-SL)
- Avaliar LLMs como oráculo, com custo (P3)
- Integrar e testar o framework (P4)


Contribuições

- Framework FALCO + DRI-SL (e variante DRI-SL-C)
- Avaliação instrumentada de oráculos (621 classes, PT)
- Métrica LCE; achados de instrumento (enum, serving)
- Base pública auditada (DOI); biblioteca aberta (pip) + interface

- *Aprendizado ativo*: seleção por incerteza, comitê, densidade; limitações do laço (cold start, oráculo imperfeito, viés de amostragem)
- *LLM como oráculo*: Gilardi (2023) — supera *crowd*; estudos de produto param em dezenas a ≈ 370 classes
- *Texto curto*: esparsidade, cauda longa, português de varejo
- *Instrumentação estatística*: Wilson, McNemar, Wilcoxon, bootstrap

Lacuna

Ninguém combina cold start informado + oráculo LLM progressivo + texto curto em português + custo instrumentado. É a célula vazia da tabela de lacunas.



- Diferencial: não é uma estratégia nova — é **disciplina de medição**. Cada decisão vem de critério pré-registrado e artefato rastreável.

Base (DOI Kaggle, pública desde 2022)

- ≈ 250 mil descrições, 621 categorias
- Auditoria do gabarito: censo de conflitos, multi-gold; teto $\approx 99,3\%$
- Deduplicação *antes* do particionamento (evita vazamento)

Rigor

- Partições imutáveis, sementes fixas
- Pareamento (McNemar) e Wilcoxon (8 sementes)
- IC de Wilson em toda proporção
- Tudo versionado; execuções retomáveis

Quatro pilares P1–P4, cada um com pergunta e critério declarados.

Começar bem

P1–P2

DRI-SL (cold start)

Perguntar bem

E1 / E6

seleção por incerteza

Pagar bem

P3 / E0

oráculo LLM barato

Integrar e testar

E4 / E5 / E3'

o framework à prova

→ cada frente responde uma pergunta e alimenta a próxima →

- A tese não é uma coleção de experimentos — é *um* argumento em quatro passos.

- 47 tamanhos $\times$ 30 repetições
- Em $|L_0| = 100$: acurácia varia **6,4 p.p.** só pelo sorteio
- A cobertura de classes é o mecanismo (Macro F1 segue a cobertura)
- Reexecução independente (protocolo com dedup): divergência $\leq 0,7$ p.p.

Consequência

Se a composição importa tanto no regime pequeno — o do cold start —, então *construir* L_0 deliberadamente é a alavanca disponível antes de existir qualquer rótulo.

$ L_0 $	DRI-SL		AG (melhor indivíduo)	
	Acc	Macro F1	Acc	Macro F1
100	41,2	6,9	38,8	6,5
1.000	67,4	25,8	62,2	24,7
5.000	76,9	44,1	74,1	40,1

- Heurística determinística (densidade semântica + variedade lexical), **sem rótulos**
- Supera o *melhor indivíduo* de um algoritmo genético supervisionado até $|L_0| = 5.000$
- Auditoria de circularidade: envelope do AG estava inflado em 6,3 p.p. — a comparação é *conservadora*

Oráculo	Acurácia	Macro F1	US\$/1k
deepseek-v4-pro	82,1%	0,785	0,410
gpt-4o	80,9%	0,788	0,923
deepseek-v4-flash	78,3%	0,750	0,035
nemotron-3-ultra (grátis)	77,9%	0,752	0,000
gpt-4o-mini	61,3%	0,518	0,051

- Platô 77–83% em 621 classes; Macro F1 zero-shot *supera* o supervisionado leve
- Spread de custo de **26×** dentro de empate estatístico
- $\approx 48\%$ do erro é *convenção de catálogo*, não ignorância do produto

- *Contrato de saída importa*: sem restrição ao espaço de classes, **6,8%** das respostas viram falsos erros de fraseado
- *O provedor de serving importa*: o mesmo modelo gratuito diverge *de si mesmo* entre dois serviços ($p < 0,001$)
- *E0-P (prompt)*: regras de fronteira ajudam na distribuição de produção (+4,6 p.p., $p = 0,012$) mas *degradam* as classes raras (−10,8 p.p.) — faca de dois gumes

Lição

Cada medição de oráculo é uma fotografia da tripla (modelo, provedor, data) — e o instrumento move resultados por margens maiores que várias diferenças entre modelos.

- O ruído do oráculo vira *ruído de rótulo* para o classificador
- E4: injeta ruído uniforme $\varepsilon \in \{0; 0,1; 0,2; 0,4\}$
- Retenção do Macro F1 final: **87% / 74% / 54%** em $\varepsilon = 0,1/0,2/0,4$
- Desenho *pessimista*: ruído real do oráculo é *estruturado* (categorias-irmãs), menos danoso que uniforme de mesma taxa

O resultado positivo do E4 é um limite inferior do desempenho esperável com os oráculos reais.

Protocolo pool / população reservada

- Pool 50k rotulável; população 181k *já* tocada
- Mede-se no teste interno (o que o praticante vê) e na população (real)
- Braço aleatório de controle: $\Delta \approx 0$ (valida o instrumento)

Consequência de projeto: conjunto reservado é obrigatório para decidir liberação.

Achado (8 sementes)

- Acurácia interna **subestima**: $-17,1 \pm 1,0$ p.p.
- Macro F1 interno **superestima**
- Direções opostas conforme a métrica

- Entropia satura com $9,1k \pm 0,6k$ rótulos; aleatório precisa de $15,5k \pm 1,1k$
- Vence o aleatório em teto $8/8$ sementes (Wilcoxon $p = 0,0078$)
- **Menos é mais:** treinar com a amostra ativa *supera* treinar com o pool completo (a amostra ativa é mais balanceada)
- Ablação: o ganho da DRI-SL-C vem do *agrupamento por predição*, não da novidade lexical (que é contraproducente no regime contínuo)

Um aviso operacional: **rotular mais pode piorar** a métrica macro.

Braço	Rótulos	Acc.	Macro F1	Critério
E (30%)	15.000	83,1%	0,380	✗ ✗
E20 (40%)	20.000	85,9%	0,418	✓ ✗
E25 (50%)	25.000	87,3%	0,434	✓ ✓
E35 (70%)	35.000	88,6%	0,463	✓ ✓
D (100%)	50.000	88,3%	0,451	—

- BERTimbau treinado *fora do laço*, 1× no fim, avaliado na população reservada
- Hipótese **refutada em 30%, mas sustentada a partir de 50%**
- Gargalo é a *parada* — não o oráculo nem a seleção
- Com 70%, o modelo forte *supera a supervisão completa* do pool

- *Ruído do oráculo* (A vs. B, mesmos itens): custa 4,4 p.p. de acurácia, mas em Macro F1 *ajuda* — erro estruturado regulariza caudas
- *Seleção* (B vs. C): compra cobertura (620 vs. 493 classes), não acurácia bruta
- **Orçamento**: é o fator dominante — a parada por estagnação do classificador leve encerra o laço cedo demais para o objetivo macro do forte

Correção medida

Parar por *proxy* do modelo forte, ou piso de $\approx 50\%$ do pool. A hipótese não é infirmada: ela requer o orçamento e a parada corretos.

Científico

- Framework FALCO + DRI-SL / DRI-SL-C
- Oráculos instrumentados (621 classes, PT)
- Métrica LCE; base auditada com DOI
- 5 artigos derivados em preparação

Reprodutibilidade *clicável*: cada número tem um artefato por trás.

Software (aberto)

- Biblioteca `activelearning` (pip, DDD, 80 testes)
- FlowBuilder: catálogo executável — *reproduzir e reprisar* cada número da tese
- Ciclo real rodado a **custo zero** de oráculo

Limitações

- Um único conjunto de dados (autor)
- E3'/E6 com semente única em parte dos braços (declarado)
- Custos de API datados (razões mais estáveis que valores)

Futuros

- Parada ancorada no modelo forte (já medida)
- Composição/roteamento de oráculos (*bandit*)
- *Prompt* otimizável a partir da matriz de confusão
- Réplica em benchmark público (AlleNoise)

A resposta

O custo de rotulagem em texto curto em português pode ser atacado nas três frentes que o FALCO integra: **começar bem** (DRI-SL), **perguntar bem** (incerteza) e **pagar bem** (oráculos LLM por centavos).

- A hipótese central se sustenta com $\approx 50\%$ dos rótulos e parada ancorada no modelo forte — refutação em 30% e piso corrigido, ambos medidos
- Três achados são sobre *instrumentos*, não modelos (enum, serving, circularidade)
- Postura: **nenhum número sem artefato rastreável**

Obrigado. Perguntas?

- **Régua = pool de 50k**: o AA só enxerga o pool; comparar com a base inteira confundiria seleção com volume de dados
- Classificador forte *fora do laço*, $1\times$ no fim — como o FALCO opera em produção
- Braços pareados A/B isolam ruído; C isola seleção; E_k varrem orçamento
- Proveniência: P1/P2 originais no repo `activetextclassification`; P3/P4 e reexecuções na `activelearning` — portes verificados (igualdade de escores, reexecução, conferência de artefato)

- Nenhum oráculo atinge o gate de 85% $\Rightarrow$ E4 (ruído) torna-se central
- **LLM Inicial** = deepseek-v4-flash (78–82% a US\$0,035/1k)
- **LLM Avançado** = deepseek-v4-pro (superioridade significativa, $p < 0,001$)
- Alternativa custo zero: nemotron-3-ultra (empata com o flash, $p = 0,76$)
- Restrição operacional: vazão do provedor define o tempo de parede tanto quanto o preço

Situação	Instrumento
Precisão de uma acurácia	IC de Wilson 95%
Dois oráculos, mesmas instâncias	McNemar (exato se poucos discordantes)
Duas estratégias, mesmas sementes	Wilcoxon (mín. 8 sementes $p/ p < 0,05$)
Funcional sem distribuição	IC <i>bootstrap</i> percentil

Cada uso mapeado na tese à situação, ao teste e à referência original + aplicada.

- 1 Codifica o pool em *embeddings* de texto
- 2 Agrupa por *k*-means (agrupamentos semânticos)
- 3 Aloca o orçamento proporcional à massa de cada grupo
- 4 Preenche cada cota gulosamente, preferindo instâncias que adicionam *tokens* lexicais inéditos (variedade)

Determinístico, custo linear após o agrupamento, **sem usar rótulos**. Variante **DRI-SL-C**: após o cold start, os grupos passam a ser as classes previstas pelo classificador (para a seleção contínua).