

FALCO: Aprendizado Ativo com Oráculos LLM para Classificação de Texto Curto

Reduzindo o custo de rotulagem em português com 621 categorias

Gilsiley Henrique Darú

Orientador: Prof. Dr. Gustavo Valentim Loch
PPGMNE — Universidade Federal do Paraná

Defesa de Doutorado — 2026

- 1 O problema
- 2 O framework
- 3 Achados
- 4 Entregas

O gargalo: rotular custa caro

- Classificar **descrições curtas de produtos** (cupom fiscal): CERV BRAHMA LT 350ML
- **621 categorias**, cauda longa, texto ruidoso e abreviado
- O custo dominante não é o modelo — é **obter rótulos**
- Aprendizado ativo reduz *contagem* de rótulos, mas assume *oráculo perfeito* e *modelo inicial* — as duas fraturas

Pergunta de pesquisa

Como reduzir o custo de rotulagem em texto curto em português, usando LLMs nas fases em que o AL tradicional é mais frágil?


Hipótese central (pré-registrada)

Critério quantitativo, fixado *antes* dos experimentos

O FALCO deve atingir $\geq 95\%$ do Macro F1 da supervisão completa com $\leq 30\%$ dos rótulos (via oráculo LLM), superando amostragem aleatória e incerteza pura com significância.

- Definido de antemão o que conta como **refutação**
- *Gate* pré-registrado de qualidade mínima do oráculo
- Princípio metodológico: **nenhum número sem artefato rastreável**

FALCO: quatro componentes sob disciplina de medição



- O diferencial não é uma estratégia nova — é a **disciplina**: cada decisão (qual oráculo, qual fase, quando parar) vem de medição pré-registrada e rastreável.

A composição do L_0 importa

- Amplitude de **6,4 p.p.** de acurácia só pelo sorteio ($|L_0| = 100$)
- Reexecução independente: divergência $\leq 0,7$ p.p.

DRI-SL captura isso sem rótulos

- Heurística determinística (densidade semântica + variedade lexical)
- **Supera o melhor indivíduo** de um AG supervisionado até $|L_0| = 5.000$
- Auditoria de circularidade: envelope do AG inflado em 6,3 p.p. — comparação conservadora

P3 — LLMs como oráculo: viáveis, baratos, erram com estrutura

Oráculo	Acurácia	Macro F1	US\$/1k
deepseek-v4-pro	82,1%	0,785	0,410
gpt-4o	80,9%	0,788	0,923
deepseek-v4-flash	78,3%	0,750	0,035
nemotron-3-ultra (grátis)	77,9%	0,752	0,000

- Platô 77–83% em 621 classes; Macro F1 zero-shot **supera** o supervisionado leve — LLM é melhor nas classes raras
- Spread de custo de **26×** dentro de empate estatístico
- Quase metade do erro é *convenção de catálogo* (não ignorância)
- RQ4: o instrumento importa — sem restrição de saída, 6,8% viram falsos erros; o *provedor* de serving também ($p < 0,001$)

Viés bidirecional (8 sementes)

- Medir no próprio conjunto coletado é enviesado
- Acurácia interna **subestima** ($-17,1 \pm 1,0$ p.p.)
- Macro F1 interno **superestima**
- $\Rightarrow$ conjunto reservado é obrigatório

Entropia domina, robustamente

- Satura com $9,1k \pm 0,6k$ rótulos (vs. 15,5k do aleatório)
- Vence o aleatório em **8/8 sementes** (Wilcoxon $p = 0,008$)
- “Menos é mais”: treinar com a amostra ativa $>$ pool completo

E3' — O classificador forte julga a hipótese

Braço	Rótulos	Acc.	Macro F1	Critério
E (pipeline, 30%)	15.000	83,1%	0,380	✗ ✗
E20 (40%)	20.000	85,9%	0,418	✓ ✗
E25 (50%)	25.000	87,3%	0,434	✓ ✓
E35 (70%)	35.000	88,6%	0,463	✓ ✓
D (régua, 100%)	50.000	88,3%	0,451	—

- Hipótese **refutada em 30%**, mas **sustentada a partir de 50%**
- Gargalo é a **parada** — não o oráculo (que ajuda as caudas) nem a seleção
- Com 70%, o modelo forte **supera a supervisão completa** do pool

O que fica: da pesquisa ao uso

Científico

- Framework FALCO + DRI-SL (e variante DRI-SL-C)
- Avaliação instrumentada de oráculos (621 classes, PT)
- Métrica LCE; base pública auditada (DOI Kaggle)
- 5 artigos derivados em preparação

Software

- Biblioteca `activelearning` (pip, DDD/hexagonal, 80 testes)
- FlowBuilder: interface com catálogo executável de experimentos — *reproduzir* e *reprisar* cada número da tese
- Ciclo real rodado a **custo zero** de oráculo

A resposta

O custo de rotulagem em texto curto PT pode ser atacado nas três frentes que o FALCO integra: **começar bem** (DRI-SL), **perguntar bem** (incerteza) e **pagar bem** (oráculos LLM por centavos).

- A hipótese central se sustenta com $\approx 50\%$ dos rótulos e parada ancorada no modelo forte — refutação em 30% e piso corrigido, ambos medidos
- Postura central: **nenhum número sem artefato rastreável** — e agora rastreabilidade *clicável*

Obrigado. Perguntas?

- **Régua = pool de 50k** (o AL só enxerga o pool; comparar com a base inteira confundiria seleção com volume de dados)
- Classificador forte **fora do laço**: treinado 1× no fim — é como o FALCO opera em produção
- Braços pareados A/B isolam ruído do oráculo (−4,4 p.p. acc, mas +Macro F1: erro estruturado regulariza caudas)
- Proveniência dupla: P1/P2 originais no repo `activetextclassification`; P3/P4 e reexecuções na `activelearning` — portes verificados

- Nenhum oráculo atinge o gate de 85% $\Rightarrow$ E4 (ruído) torna-se central
- **LLM Inicial** = deepseek-v4-flash (78–82% a US\$0,035/1k)
- **LLM Avançado** = deepseek-v4-pro (superioridade significativa, $p < 0,001$)
- Alternativa custo zero: nemotron-3-ultra (empata com o flash, $p = 0,76$)
- E4: retenção de 87/74/54% do Macro F1 sob ruído $\varepsilon = 0,1/0,2/0,4$