

Aprendizado Ativo

Reduzindo o Saneamento de Dados no Aprendizado Supervisionado.



TDC  **INNOVATION** FLORIANOPOLIS EXPERIENCE

01 JUN
11:40

**TRILHA I.A. E
MACHINE
LEARNING**


**Aprendizado Ativo -
Reduzindo o Saneamento de
Dados no Aprendizado
Supervisionado.**



Gilsley Henrique Darú


thedeconf.com

Inteligência Artificial



Fonte: igti.com curso de engenheiro de machine learning

Aprendizado de Máquina




Fonte: alura.com.br – formação em Machine Learning

APRENDIZADO DE MÁQUINA



Fonte: alura.com.br – formação em Machine Learning

Aprendizado de Máquina



Fonte: O autor

EXEMPLO: CATEGORIA BISCOITO

- PROCURAR BISCOITO
 - BISCOITO DUX SALGADO 648G
 - BISCOITO CRACKERS DUX 216G
- MAS ...
 - BISC LEITE MABEL 400G
 - BISC CRACKER MANT MARILAN 400G
- OU
 - BISC.PARATI MARIA PE 370GR
 - BOLACHAO MEL ANA JULIA 700G CHOCOLATE
 - BOLACHA PAPAGUARA MOTOR 400g

EXEMPLO: CATEGORIA BISCOITO

- E TEM OUTRAS PALAVRAS CHAVES
 - COOKIE INT BAUDUCCO AVEIA PASSAS 40G
 - COOKIES GRAN CASTANH PARA KOBBER 150G
- E BISCOITO QUE NÃO É BISCOITO
 - BISC PET CRACKER FORTAL 400G
 - BISC PET DOG CROCK 500G
 - BISC LACTA BIS FLOWP 126G, LAKA BCO
 - CESTA SUPREME BISCOITO LIMAO 100G



Digite o nome do Palestrante

- Enquete

<https://www.mentimeter.com/app/presentation/53bbc1d16bd0c07a92de88759bc911de/7da2ed9932b4>



Digite o nome da cidade solicitada

- Enquete

<https://www.mentimeter.com/app/presentation/f72bbfd8af4438d9eee2f0416f9ed9eb/2d3d4aab7f00>

Caso prático

- Cadastre o item:
- Enquete

<https://www.mentimeter.com/app/presentation/53f0747dbd98ede8632d5785a328c82b/253157cc16f1>








Qual o problema?

- QUALIDADE DE DADOS
- ESFORÇO PARA CATEGORIZAÇÃO




Quanto de Esforço? BASE NOVA



SANEAMENTO DE DADOS


- FAKENEWSBR – 3 Meses de trabalho. 7200 Notícias.
- Case Particular – 6 Meses de trabalho +130k

A SOLUÇÃO: Aprendizado Ativo




Fonte: Adaptado de Settles, B. (2009). Active learning literature survey.

A SOLUÇÃO: Aprendizado Ativo




Fonte: Adaptado de Settles, B. (2009). Active learning literature survey.

A SOLUÇÃO: Aprendizado Ativo




Fonte: Adaptado de Settles, B. (2009). Active learning literature survey.

A SOLUÇÃO: Aprendizado Ativo




Fonte: Adaptado de Settles, B. (2009). Active learning literature survey.

A SOLUÇÃO: Aprendizado Ativo




Fonte: Adaptado de Settles, B. (2009). Active learning literature survey.

A SOLUÇÃO: Aprendizado Ativo




Fonte: Adaptado de Settles, B. (2009). Active learning literature survey.

A SOLUÇÃO: Aprendizado Ativo




Fonte: Adaptado de Settles, B. (2009). Active learning literature survey.

A SOLUÇÃO: Aprendizado Ativo



Fonte: Adaptado de Settles, B. (2009). Active learning literature survey.

A SOLUÇÃO: Aprendizado Ativo



Fonte: Adaptado de Settles, B. (2009). Active learning literature survey.


Mas como selecionar as instâncias?

- Estratégia do menos confidente (Probabilidade de Certeza)
- Estratégia do Comitê
- Estratégia da alteração de modelo
- Estratégia da Redução do Erro
- Estratégia da Variância

E quantas amostras selecionar?

- Quantidade Variável
- Quantidade por Lote

Algoritmos



Caso Prático – FakeNewsBR.com

 FAKENEWSBR

[Detector](#)

[Equipe](#)

[Mídia](#)

[+FakeNews](#)

←

MECAI-ICMC-USP


Detector de FAKENEWS Versão 1.03

Texto para Verificação

Verificar

Estatísticas

Probabilidade Fake News por Modelo



Modelo	fake	true
CBOWLIGHT	90.0%	10.0%
SKIPPGRAMLIGHT	90.0%	10.0%
TFIDFLIGHT	90.0%	10.0%
LIGHTGBMOLD	90.0%	10.0%
Média Geral	90.0%	10.0%

Atenção

Este é um trabalho experimental. Não assumimos nenhuma responsabilidade pelas consequências do uso das informações aqui contidas.

Toda e qualquer informação deve ser usada por sua própria conta e risco. Lembre-se de que informações ficam desatualizadas. Sempre verifique na fonte oficial a informação mais atualizada. UTILIZE TEXTOS COMPLETOS. Títulos e pequenas perguntas são consideradas FAKENEWS.

Copyright © FakeNewsBR 2022 - 5183 acessos desde 25/01/2022 Notícia número Em geração

Algoritmos:

Davi Keglevich Neiva, Gilsley Henrique Danú, Luiz Guilherme Giordani, Rhenan Queiroz, Vitor Buzinaro


Interface, Infraestrutura e Integração dos Algoritmos

Gilsley Henrique Danú

A técnica


- Sklearn.svm.SVC

7200 Notícias



Resultados

Região a ser
saneada
740 Amostras



Exemplos de Rótulos do Vetor Base

- Morre aos 73 anos o médico psiquiatra, psicoterapeuta e escritor Flávio Gikovate. Ao longo da carreira ele publicou mais de 200 livros. Gikovate morreu por causa de um câncer. Médico psiquiatra, psicoterapeuta, conferencista e escritor, Flávio Gikovate morreu depois de uma batalha contra um câncer de pâncreas que foi descoberto em abril. Nos últimos trinta anos, escreveu 25 livros sobre vida social, afetiva e sexual e seus reflexos na sociedade. Flávio estava internado desde a semana passada.
- BASE → FAKE
- Modelo selecionou para revisão.
- Resultado: TRUE



Conclusões

- Não desperdice o tempo da equipe, aplique técnicas de aprendizado ativo como o algoritmo SVC.
- Utilize os scores mais próximos do vetor de suporte entre -1 a 1.
- Utilize tamanho de lotes pequenos (até 100 como sugestão)
- Pode-se utilizar para uma base já saneada, como auditoria.
- Pode ser incorporado em um “PIPELINE” de dados para encaminhamento para o “Oráculo”

Obrigado!!!

- Meus sites:
- www.fakenewsbr.com
- www.datascienceuniversity.net
- Email: ghdaru@gmail.com



Gilsiley Henrique Darú
Especialista II na Neogrid

