

UNIVERSIDADE FEDERAL DO PARANÁ

GILSILEY HENRIQUE DARÚ

APRENDIZADO ATIVO COM MODELOS DE LINGUAGEM
PARA TEXTOS CURTOS EM PORTUGUÊS

CURITIBA PR

2026

GILSILEY HENRIQUE DARÚ

APRENDIZADO ATIVO COM MODELOS DE LINGUAGEM
PARA TEXTOS CURTOS EM PORTUGUÊS

(versão pré-defesa, compilada em 20 de julho de 2026)

Tese apresentada como requisito parcial à obtenção do grau de Doutor em Métodos Numéricos em Engenharia no Programa de Pós-Graduação em Métodos Numéricos em Engenharia, Setores de Ciências Exatas e de Tecnologia, da Universidade Federal do Paraná.

Área de concentração: *Programação Matemática*.

Orientador: Prof. Dr. Gustavo Valentim Loch.

CURITIBA PR

2026

RESUMO

A classificação de textos curtos em português — como descrições de produtos de notas fiscais, com vocabulário abreviado, ruidoso e centenas de categorias — depende de grandes volumes de rótulos cuja obtenção é o principal custo desses sistemas. Esta tese propõe e avalia o FALCO (*Framework de Aprendizado Ativo com LLM para texto CurtO*), que integra três frentes de redução de custo: composição informada do conjunto inicial de treinamento, seleção ativa de instâncias por incerteza e substituição parcial do anotador humano por oráculos baseados em grandes modelos de linguagem (LLMs), organizados em fases de custo crescente. A investigação usa um conjunto público auditado de 250.365 descrições de produtos em 621 categorias e segue protocolo pré-registrado com partições imutáveis, análise pareada (McNemar, Wilcoxon) e artefatos rastreáveis para todos os números reportados. Quatro resultados principais: (i) a sensibilidade à composição do conjunto inicial é máxima no regime de poucos rótulos (amplitude de 6,4 pontos percentuais de acurácia com $|L_0| = 100$) e a heurística determinística proposta, DRI-SL — densidade semântica com diversidade lexical, sem usar nenhum rótulo —, supera o melhor indivíduo de um algoritmo genético supervisionado em todos os tamanhos de 100 a 5.000, comparação conservadora após a correção de circularidade que reduziu o envelope evolutivo em até 6,3 pontos percentuais; (ii) oráculos LLM zero-shot atingem 77–83% de acurácia no espaço fechado de 621 categorias a custos de US\$ 0,035 a US\$ 0,92 por mil rótulos, com Macro F1 superior ao de um classificador supervisionado leve treinado com 250 mil rótulos, e quase metade dos seus erros concentra-se em convenções de catálogo (categorias-irmãs e classes guarda-chuva); (iii) o instrumento de medição importa: sem restrição de saída ao espaço de classes, 6,8% das respostas viram falsos erros; regras de fronteira no *prompt* melhoram o modelo fraco na distribuição de produção (+4,6 p.p., $p = 0,012$) ao custo de degradação severa nas classes raras ($p < 0,001$); e até o provedor de *serving* é parte do instrumento — o mesmo modelo gratuito diverge significativamente de si mesmo entre dois serviços ($p < 0,001$), embora, servido adequadamente, empate com oráculos pagos na amostra de produção; (iv) as estratégias de incerteza superam a seleção aleatória com significância máxima em 8 sementes ($p = 0,0078$), recuperando 78% do Macro F1 do teto supervisionado com 15% dos rótulos, e essa vantagem sobrevive intacta a ruído uniforme de oráculo até $\varepsilon = 0,4$ — cobrindo a faixa de erro observada nos LLMs reais. Como o melhor oráculo ficou abaixo do critério pré-registrado de 85% de acurácia, o gate metodológico definiu a configuração final (oráculo econômico na fase inicial e oráculo de maior acurácia na fase avançada) e tornou central o cenário de aprendizado com rótulos ruidosos. Por fim, (v) o framework foi executado ponta a ponta com oráculo LLM gratuito, a custo monetário zero, parando por estagnação com 32–40% do orçamento, e a validação com o classificador forte (BERTimbau) treinado fora do laço respondeu à hipótese central pré-registrada — $\geq 95\%$ do Macro F1 da supervisão completa do *pool* com $\leq 30\%$ dos rótulos —, que foi

refutada na configuração executada: a decomposição pareada inocenta o ruído do oráculo (que, estruturado, até beneficia as classes raras) e a seleção, e atribui a perda ao critério de parada herdado do classificador leve; com 30% dos rótulos a acurácia alcança 94,1% da supervisão completa, a 0,75 ponto percentual do critério. Os experimentos em escala populacional mostram ainda que a autoavaliação em dados coletados ativamente é enviesada em direção dependente da métrica — a acurácia interna subestima e o Macro F1 interno superestima o desempenho real —, fundamentando o conjunto reservado e o critério de liberação que o framework adota. A tese entrega ainda a métrica LCE para comparação de curvas de aprendizado, a biblioteca aberta `activelearning` e a ferramenta FlowBuilder, com ingestão saneada de dados, execução parametrizada e curvas de aprendizado, que tornam o protocolo reutilizável em outros domínios.

Palavras-chave: Aprendizado Ativo. Classificação de Textos Curtos. Modelos de Linguagem de Grande Porte. FALCO. Rotulagem.

ABSTRACT

Short-text classification in Portuguese — such as product descriptions from electronic invoices, with abbreviated, noisy vocabulary and hundreds of categories — depends on large volumes of labels whose acquisition is the dominant cost of these systems. This thesis proposes and evaluates FALCO (Active Learning Framework with LLMs for Short Text), which integrates three cost-reduction fronts: informed composition of the initial training set, uncertainty-based active selection of instances, and partial replacement of the human annotator by oracles based on large language models (LLMs), organized in phases of increasing cost. The investigation uses an audited public dataset of 250,365 product descriptions across 621 categories and follows a pre-registered protocol with immutable partitions, paired analysis (McNemar, Wilcoxon), and traceable artifacts for every reported number. Four main results: (i) sensitivity to the composition of the initial set is highest in the low-label regime (a 6.4 percentage-point accuracy range at $|L_0| = 100$), and the proposed deterministic heuristic, DRI-SL — semantic density with lexical diversity, using no labels at all — outperforms the best individual found by a supervised genetic algorithm at every size from 100 to 5,000, a conservative comparison after the circularity correction that reduced the evolutionary envelope by up to 6.3 percentage points; (ii) zero-shot LLM oracles reach 77–83% accuracy in the closed space of 621 categories at costs of US\$ 0.035 to US\$ 0.92 per thousand labels, with Macro F1 above that of a light supervised classifier trained on 250 thousand labels, and nearly half of their errors concentrate on catalog conventions (sibling categories and umbrella classes); (iii) the measurement instrument matters: without output restriction to the class space, 6.8% of responses become spurious errors; boundary rules in the prompt improve the weak model on the production distribution (+4.6 p.p., $p = 0.012$) at the cost of severe degradation on rare classes ($p < 0.001$); and even the serving provider is part of the instrument — the same free model diverges significantly from itself across two services ($p < 0.001$), although, properly served, it ties with paid oracles on the production sample; (iv) uncertainty strategies outperform random selection at the maximum significance achievable with 8 seeds ($p = 0.0078$), recovering 78% of the supervised ceiling’s Macro F1 with 15% of the labels, and this advantage survives intact under uniform oracle noise up to $\varepsilon = 0.4$ — covering the error range observed in the real LLMs. Since the best oracle fell short of the pre-registered 85% accuracy criterion, the methodological gate defined the final configuration (an economical oracle in the initial phase and the most accurate oracle in the advanced phase) and made learning with noisy labels the central scenario. Finally, (v) the framework was executed end to end with a free LLM oracle at zero monetary cost, stopping by stagnation at 32–40% of budget, and validation with the strong classifier (BERTimbau) trained outside the loop answered the pre-registered central hypothesis — $\geq 95\%$ of full-pool-supervision Macro F1 with $\leq 30\%$ of the labels —, which was **refuted in the executed configuration**: the paired

decomposition exonerates oracle noise (which, being structured, even benefits rare classes) and selection, attributing the loss to the stopping criterion inherited from the light classifier; with 30% of the labels, accuracy reaches 94.1% of full supervision, 0.75 percentage points short of the criterion. Population-scale experiments further show that self-evaluation on actively collected data is biased in a metric-dependent direction — internal accuracy underestimates and internal Macro F1 overestimates real performance —, grounding the reserved evaluation set and release criterion the framework adopts. The thesis also delivers the LCE metric for learning-curve comparison, the open-source `activelearning` library, and the FlowBuilder tool, with sanitized data ingestion, parameterized execution, and learning curves, which make the protocol reusable in other domains.

Keywords: Active Learning. Short Text Classification. Large Language Models. FALCO. Labeling.

LISTA DE FIGURAS

2.1	Arquitetura conceitual do ActiveLLM: o LLM atua como <i>seletor</i> de instâncias informativas — mitigando o <i>cold start</i> — enquanto a rotulagem permanece com um oráculo e o aprendizado com um modelo sucessor. Adaptado de Bayer e Reuter (2026).	28
4.1	Tendência da performance média (Acurácia e Macro F1) e intervalo mín–máx por tamanho de L_0 no teste T , escala logarítmica. Classificador PVBIn.	45

LISTA DE TABELAS

2.1	Instrumentos de inferência estatística e seu emprego nesta tese.	22
2.2	Componentes do arcabouço de aprendizado ativo	23
2.3	Comparação de alto nível das famílias de estratégias de seleção.	26
2.4	Cobertura das dimensões da lacuna pelos trabalhos mais próximos (2020–2026). ✓ = tratado; ✗ = ausente; ~ = parcial.	33
3.1	Programa experimental da tese.. . . .	35
4.1	Evolução do AG (1 ^a vs. 100 ^a geração) — cenários de Acurácia. Envelope entre minimização e maximização.	46
4.2	<i>Cold start</i> : DRI-SL vs. envelope do AG (última geração), até $ L_0 = 5.000$. Classificador PVBIn.	47
4.3	Estudo de sensibilidade: original (30 rep.) vs. reexecução independente (10 rep., protocolo com deduplicação). Acurácia média.	47
5.1	E0 — desempenho dos oráculos LLM. Modo enum para OpenAI; json-prompt para MaaS, agregador e NVIDIA NIM (sem suporte a saída estruturada). IC = intervalo de Wilson 95%.	49
5.2	E0 — custo por mil rótulos (US\$) e taxa de acerto de <i>cache</i> de prefixo (S-rand; preços vigentes na execução, jul/2026)..	50
5.3	E0-P — ablação de <i>prompt</i> no gpt-4o-mini (enum, $b = 10$, $n = 500$ pareado por amostra). p : McNemar exato contra o $v3$	52
5.4	E1 — estratégias com oráculo perfeito (média $\pm$ dp sobre 8 sementes; orçamento 3.000, lote 100). p : Wilcoxon pareado por semente contra a aleatória; com $n = 8$, o menor p atingível é 0,0078.. . . .	53
5.5	E4 — robustez ao ruído uniforme do oráculo (média $\pm$ dp, 8 sementes). Retenção: fração do Macro F1 final da mesma estratégia em $\varepsilon = 0$. p : Wilcoxon pareado entropia vs. aleatória no mesmo ε	54
5.6	E6 — Macro F1 na população por seletor e classificador. Saturação: menor $ L $ que atinge 95% do teto do próprio braço.. . . .	55
5.7	E3' — BERTimbau treinado por braço e avaliado na população reservada. IC = Wilson 95%.. . . .	57
5.8	E3' — varredura de orçamento. Critério $0,95 \times$ régua (D): acurácia $\geq 83,9\%$, Macro F1 $\geq 0,428$. ✓ atende.. . . .	58

F.1	Estatísticas Descritivas da Performance em Função do Tamanho de L0 (Classificador: PVBIn (1,2)-gram). 30 repetições por tamanho.	81
-----	--	----

LISTA DE ACRÔNIMOS

AG	Algoritmo Genético
AL	<i>Active Learning</i> (Aprendizado Ativo)
ALC	<i>Area under the Learning Curve</i>
API	<i>Application Programming Interface</i>
AUC	<i>Area Under the Curve</i>
BERT	<i>Bidirectional Encoder Representations from Transformers</i>
DRI-SL	Densidade e Representatividade Informada — Semântica e Lexical
FALCO	<i>Framework de Aprendizado Ativo com LLM para texto CurtO</i>
IC	Intervalo de Confiança
LCE	<i>Learning Curve Efficiency</i> (Eficiência da Curva de Aprendizado)
LLM	<i>Large Language Model</i> (Modelo de Linguagem de Grande Porte)
NF-e	Nota Fiscal Eletrônica
PPGMNE	Programa de Pós-Graduação em Métodos Numéricos em Engenharia
PVBin	<i>Prototype Vector — Binary</i> (classificador por protótipos binários)
RQ	<i>Research Question</i> (Questão de Pesquisa)
SBERT	<i>Sentence-BERT</i>
SVD	<i>Singular Value Decomposition</i>
TF-IDF	<i>Term Frequency — Inverse Document Frequency</i>
UFPR	Universidade Federal do Paraná

LISTA DE SÍMBOLOS

L_0	conjunto inicial de instâncias rotuladas (<i>cold start</i>)
U	<i>pool</i> de instâncias não rotuladas
b	tamanho do lote (de seleção ou de rotulagem)
ε	taxa de ruído injetada no oráculo simulado
$\varepsilon_{\max}$	limiar de estagnação da transição de fases do FALCO
p	paciência (rodadas sem melhora) na transição de fases
n_1, n_K	orçamentos inicial e final da curva de aprendizado

SUMÁRIO

1	INTRODUÇÃO	15
1.1	PROBLEMA DE PESQUISA	15
1.2	LACUNA DE PESQUISA	16
1.3	QUESTÃO DE PESQUISA E HIPÓTESE	16
1.4	OBJETIVOS	17
1.5	DELIMITAÇÃO DA CONTRIBUIÇÃO	17
1.6	ORGANIZAÇÃO DO TRABALHO	18
2	FUNDAMENTAÇÃO TEÓRICA E REVISÃO DA LITERATURA	19
2.1	APRENDIZADO SUPERVISIONADO: CONCEITOS, MÉTRICAS E VALIDAÇÃO	19
2.1.1	Regimes de supervisão e a tarefa de classificação multiclasse	19
2.1.2	Métricas para classes desbalanceadas.	20
2.1.3	Validação e particionamento	21
2.1.4	Inferência estatística para comparação de classificadores e oráculos.	21
2.2	APRENDIZADO ATIVO.	22
2.2.1	Formalização e cenários	23
2.2.2	Estratégias de seleção de instâncias.	24
2.2.3	Limitações do laço clássico	26
2.3	MODELOS DE LINGUAGEM COMO ORÁCULOS DE ROTULAGEM	27
2.3.1	Capacidades e evidência empírica	27
2.3.2	Arquiteturas de integração no laço	28
2.3.3	Rótulos ruidosos e seu efeito no treinamento.	29
2.3.4	Custo, instrumentação e reprodutibilidade da medição.	29
2.4	CLASSIFICAÇÃO DE TEXTO CURTO.	30
2.4.1	Definições e desafios	30
2.4.2	Representação e classificadores.	30
2.4.3	Implicações para o aprendizado ativo no domínio	31
2.5	ESTADO DA ARTE NA INTERSEÇÃO E LACUNA DE PESQUISA	32
2.5.1	Escopo e método da revisão	32
2.5.2	Síntese por frente	32
2.5.3	Lacuna de pesquisa	33
2.5.4	Conclusão do capítulo	34
3	METODOLOGIA	35
3.1	DESENHO DA PESQUISA	35

3.2	CONJUNTO DE DADOS	36
3.2.1	Fonte e características.	36
3.2.2	Auditoria de qualidade dos rótulos	36
3.2.3	Pré-processamento e espaço de rótulos	37
3.2.4	Particionamento.	37
3.3	CLASSIFICADORES DA TAREFA	37
3.4	MÉTRICAS DE AVALIAÇÃO E ANÁLISE ESTATÍSTICA	38
3.5	PILAR P1: COMPOSIÇÃO DO CONJUNTO INICIAL L_0	39
3.5.1	Sensibilidade à amostragem aleatória.	39
3.5.2	Otimização por algoritmo genético	39
3.6	PILAR P2: <i>COLD START</i> SEM RÓTULOS — ALGORITMO DRI-SL	39
3.7	PILAR P3: LLMS COMO ORÁCULO DE ROTULAGEM (EXPERIMENTO E0)	40
3.7.1	Instrumentação da medição	40
3.7.2	Desenho fatorial do E0	41
3.7.3	Critério de decisão para o FALCO	41
3.8	PILAR P4: O FRAMEWORK FALCO E SUA AVALIAÇÃO (EXPERIMENTOS E1–E4)	41
3.8.1	Componentes e fases	42
3.8.2	Métodos de referência e desenho do E3	42
3.9	AMEAÇAS À VALIDADE	43
3.10	REPRODUTIBILIDADE E AMBIENTE	44
4	RESULTADOS: COMPOSIÇÃO E CONSTRUÇÃO DO CONJUNTO INICIAL	45
4.1	SENSIBILIDADE À COMPOSIÇÃO E AO TAMANHO DE L_0	45
4.2	LIMITES POR OTIMIZAÇÃO EVOLUTIVA	46
4.3	DRI-SL <i>VERSUS</i> ALEATÓRIO E ENVELOPE DO AG	46
4.4	REEXECUÇÃO INDEPENDENTE E EFEITO DA CIRCULARIDADE	47
4.5	SÍNTESE DO CAPÍTULO	48
5	RESULTADOS: ORÁCULOS LLM E O FRAMEWORK FALCO	49
5.1	E0: AVALIAÇÃO FATORIAL DE ORÁCULOS LLM	49
5.1.1	RQ1 — assertividade	49
5.1.2	RQ2 — custo e o efeito do <i>cache</i>	50
5.1.3	RQ3 — perfil de erro	51
5.1.4	RQ4 — efeito do instrumento de medição	51
5.1.5	Sensibilidade ao ruído do gabarito e calibração do lote	51
5.2	E0-P: O PROMPT COMO VARIÁVEL DO INSTRUMENTO	52
5.3	E1: ESTRATÉGIAS DE SELEÇÃO COM ORÁCULO PERFEITO	52
5.4	E4: ROBUSTEZ DO APRENDIZADO AO RUÍDO DO ORÁCULO.	53

5.5	E6: SELETORES EM ESCALA POPULACIONAL E O VIÉS DA AUTOAVALIAÇÃO.	54
5.6	E3': O CLASSIFICADOR FORTE JULGA O PIPELINE E A HIPÓTESE CENTRAL	56
5.6.1	Varredura de orçamento: o piso que sustenta a hipótese	57
5.7	DECISÃO DO GATE E CONFIGURAÇÃO DO FALCO	58
6	DISCUSSÃO E CONCLUSÃO	59
6.1	SÍNTESE DOS ACHADOS	59
6.2	DISCUSSÃO	60
6.3	CONTRIBUIÇÕES	61
6.4	LIMITAÇÕES	61
6.5	TRABALHOS FUTUROS	61
6.6	CONCLUSÃO	62
	REFERÊNCIAS	63
	APÊNDICE A – MÉTRICA LEARNING CURVE EFFICIENCY (LCE)	75
A.1	DEFINIÇÃO	75
A.2	PROPRIEDADES.	75
A.3	RELAÇÃO COM A ALC.	75
	APÊNDICE B – ALGORITMO GENÉTICO PARA OTIMIZAÇÃO DE L0	76
B.1	FORMULAÇÃO	76
B.2	OPERADORES E PARÂMETROS	76
B.3	PSEUDOCÓDIGO	76
	APÊNDICE C – ALGORITMO DRI-SL	77
C.1	OBJETIVO E ENTRADAS.	77
C.2	ETAPAS.	77
C.3	INTUIÇÃO	77
	APÊNDICE D – A BIBLIOTECA ACTIVELEARNING.	78
D.1	ARQUITETURA	78
D.2	REPRODUÇÃO DOS EXPERIMENTOS	78
D.3	FLOWBUILDER	78
	APÊNDICE E – PROMPTS E ESQUEMAS DO ORÁCULO LLM.	79
E.1	PROMPT V3 (PRODUÇÃO).	79
E.2	MODOS DE INSTRUMENTAÇÃO	79
E.3	VARIANTES DO E0-P.	79
	APÊNDICE F – TABELAS COMPLETAS	81
	APÊNDICE G – CRITÉRIO DE PARADA, LIBERAÇÃO DO MODELO E MONITORAMENTO DE DERIVA	85
G.1	PARADA DO LAÇO DE APRENDIZADO ATIVO	85
G.2	CRITÉRIO DE LIBERAÇÃO DO MODELO	85

G.3	MONITORAMENTO DE DERIVA E POLÍTICA DE RETREINAMENTO . . .	86
-----	---	----

1 INTRODUÇÃO

A classificação de textos curtos é uma tarefa relevante em Processamento de Linguagem Natural (PLN), especialmente em contextos nos quais grandes volumes de registros textuais precisam ser organizados, filtrados ou categorizados automaticamente. Esse cenário aparece em aplicações como consultas, comentários, atendimento e descrições de produtos. A literatura mostra que textos curtos apresentam dificuldades específicas, como baixo contexto por instância, alta esparsidade, ruído e informalidade, o que torna sua classificação mais desafiadora do que a de documentos mais extensos (Alsmadi e Gan, 2019a; Song et al., 2014a).

No contexto da língua portuguesa, essas dificuldades se intensificam. Em aplicações como comércio eletrônico e cadastros operacionais, descrições curtas costumam apresentar abreviações, variações morfológicas, ruídos ortográficos e grande heterogeneidade lexical. Em trabalho anterior, voltado à classificação de descrições curtas de produtos em português, observou-se que métodos clássicos de recuperação da informação, como *bag-of-words*, TF e TF-IDF, podem alcançar desempenho relevante quando combinados com pré-processamento e parametrização adequados (Darú, 2024). Esse resultado confirma a relevância empírica do problema e fornece uma base concreta para investigações posteriores.

Ao mesmo tempo, o avanço dos modelos de linguagem pré-treinados alterou significativamente o estado da arte em PLN. O BERT mostrou que representações bidirecionais profundas, obtidas por pré-treinamento em texto não rotulado e posterior ajuste fino em tarefas específicas, podem produzir resultados de ponta em diversas tarefas (Devlin et al., 2019a). Para o português, o BERTimbau evidenciou que modelos monolíngues pré-treinados são particularmente relevantes em cenários com poucos dados anotados, superando o BERT multilíngue em tarefas importantes da língua (Souza et al., 2020). Por essa razão, esta tese adota um classificador baseado em BERTimbau na validação principal do framework proposto, reservando modelos mais leves para análises exploratórias específicas.

Apesar desses avanços, a limitação central permanece: dados não rotulados são abundantes, mas a obtenção de rótulos confiáveis continua custosa. Nesse contexto, o aprendizado ativo surge como alternativa promissora, ao selecionar iterativamente exemplos potencialmente mais informativos para anotação. No entanto, revisões recentes mostram que sua aplicação prática envolve dificuldades adicionais, como custo de anotação, critérios de parada, viabilidade computacional e reaproveitamento dos exemplos obtidos (Zhang et al., 2022a).

1.1 PROBLEMA DE PESQUISA

Embora o aprendizado ativo seja conceitualmente adequado para cenários com alto custo de rotulagem, sua aplicação em modelos modernos de PLN enfrenta limitações importantes. A principal delas é o problema de *cold start*: nas etapas iniciais, quando ainda há poucos exemplos

anotados, o sistema não dispõe de informação suficiente para selecionar instâncias realmente informativas. Além disso, o treinamento iterativo do modelo ao longo do ciclo de seleção pode ser caro e pouco prático. Assim, o problema central desta tese não é apenas classificar textos curtos em português com boa acurácia, mas **como reduzir o custo de rotulagem nesse contexto sem comprometer o desempenho final**, superando as limitações do aprendizado ativo tradicional nas fases iniciais do processo (Zhang et al., 2022a).

1.2 LACUNA DE PESQUISA

A literatura já consolidou os desafios da classificação de textos curtos e a força de modelos pré-treinados em cenários com poucos dados anotados (Alsmadi e Gan, 2019a; Song et al., 2014a; Devlin et al., 2019a; Souza et al., 2020). Trabalhos recentes, como o ActiveLLM, indicaram que modelos de linguagem de grande porte podem apoiar a seleção de instâncias em cenários com poucos exemplos, mitigando o *cold start* (Bayer e Reuter, 2026), e que LLMs podem atuar como rotuladores de baixo custo em ciclos de aprendizado ativo (Zhang e Takada, 2025a). Ainda assim, permanece uma lacuna específica: **falta uma formulação metodológica voltada ao português e ao problema de textos curtos que articule, de forma explícita e com validação empírica em cada componente, aprendizado ativo, classificação em baixo regime de supervisão e uso de modelos de linguagem para apoiar a fase inicial de seleção e rotulagem**. É nesse espaço que esta tese se posiciona.

1.3 QUESTÃO DE PESQUISA E HIPÓTESE

Diante dessa lacuna, esta tese é guiada pela seguinte questão de pesquisa:

Como estruturar um framework de aprendizado ativo para classificação de textos curtos em português que reduza o esforço de rotulagem, sem perda relevante de desempenho, utilizando modelos de linguagem para apoiar as fases iniciais do processo?

A hipótese central é que **um framework de aprendizado ativo apoiado por modelos de linguagem nas etapas iniciais pode reduzir a necessidade de rótulos sem perda relevante de desempenho final**. Para torná-la falseável, adota-se o seguinte critério quantitativo de aceitação: o framework proposto deve atingir, com no máximo 30% dos rótulos do *pool* (fornecidos por oráculo LLM), pelo menos 95% do Macro F1-Score obtido com supervisão completa, superando com significância estatística as estratégias de referência de amostragem aleatória e de incerteza pura sob o mesmo orçamento (Capítulo 3). A hipótese é condicional à qualidade do oráculo disponível: o protocolo prevê um *gate* pré-registrado de acurácia mínima do oráculo (Seção 3.7.3) e define de antemão o que conta como refutação — se nem o melhor oráculo aprovado sustentar o critério, a hipótese é considerada refutada *para o cardápio de oráculos avaliado*, e a tese reporta

o resultado com a decomposição que separa custo do ruído de rotulagem e custo da parcimônia de rótulos (braços pareados do $E3'$, Seção 3.8.2).

1.4 OBJETIVOS

O objetivo geral é propor e avaliar o **FALCO**, um framework de aprendizado ativo para classificação de textos curtos em português, com uso de modelos de linguagem como oráculo de rotulagem e apoio à fase inicial de seleção, visando reduzir o custo de anotação e manter desempenho competitivo. A investigação é organizada em quatro pilares empíricos, que estruturam também os capítulos de resultados:

1. **P1 — composição do conjunto inicial:** quantificar o impacto da composição e do tamanho do conjunto inicial de rotulagem (L_0) na generalização do classificador, incluindo a estimativa de limites por otimização evolutiva;
2. **P2 — *cold start* sem rótulos:** propor e avaliar o algoritmo DRI-SL, que constrói um L_0 informativo sem acesso a rótulos, combinando densidade semântica e variedade lexical;
3. **P3 — LLM como oráculo:** medir, com instrumentação validada, a assertividade, o custo e o perfil de erro de LLMs como rotuladores para o domínio, derivando a configuração de oráculos do framework;
4. **P4 — o framework integrado:** avaliar o FALCO contra métodos de referência sob o mesmo orçamento, com testes de significância, verificando a hipótese central.

Transversalmente, propõe-se a métrica *Learning Curve Efficiency* (LCE) para sumarizar a eficiência de curvas de aprendizado, e disponibiliza-se a biblioteca `activelearning`, que implementa todo o instrumental com reprodutibilidade rastreável.

1.5 DELIMITAÇÃO DA CONTRIBUIÇÃO

Esta tese não propõe um novo modelo fundacional para o português nem um novo classificador de texto: sua contribuição está delimitada à **eficiência do processo de rotulagem**. Dois níveis de modelagem são usados de forma complementar — um classificador leve, derivado da linha investigada na dissertação de mestrado do autor (Darú, 2024), em análises exploratórias massivas, e um classificador baseado em BERTimbau na validação principal. Essa distinção isola a contribuição metodológica: a originalidade reside no processo de seleção e rotulagem, não no modelo de classificação. A tese também se distingue do trabalho anterior do autor, que investigou como classificar bem com dados já anotados; aqui a pergunta é **como obter, de forma eficiente, o conjunto anotado necessário**.

1.6 ORGANIZAÇÃO DO TRABALHO

Além desta introdução, o trabalho está organizado da seguinte forma. O Capítulo 2 apresenta os fundamentos de classificação de textos curtos, aprendizado ativo e modelos de linguagem, e a revisão sistemática da literatura recente. O Capítulo 3 descreve a metodologia: dados e sua auditoria, os quatro pilares, o programa experimental E0–E4 e o instrumental de reprodutibilidade. O Capítulo 4 apresenta os resultados sobre a composição e a construção do conjunto inicial (P1 e P2). O Capítulo 5 apresenta a avaliação dos oráculos LLM e do framework FALCO (P3 e P4). O Capítulo 6 discute os achados, limitações e trabalhos futuros. Os apêndices formalizam a métrica LCE, o algoritmo genético, o DRI-SL, a biblioteca `activelearning` e os *prompts* utilizados.

2 FUNDAMENTAÇÃO TEÓRICA E REVISÃO DA LITERATURA

Este capítulo estabelece a base teórica sobre a qual o framework FALCO, proposto no Capítulo 3, é construído, e o faz na ordem em que os conceitos se encadeiam no argumento da tese. A Seção 2.1 apresenta o instrumental de aprendizado supervisionado do qual todos os capítulos seguintes dependem — a tarefa multiclasse, as métricas sob desbalanceamento, as estratégias de validação e os testes estatísticos usados nas comparações. A Seção 2.2 formaliza o aprendizado ativo, o laço que compra rótulos seletivamente, e identifica as duas limitações do laço clássico que o FALCO ataca: a partida a frio e a suposição de oráculo perfeito. A Seção 2.3 examina o que muda quando o oráculo é um modelo de linguagem de grande porte — capacidades, arquiteturas de integração, ruído de rótulo e a estrutura de custo e medição que passa a existir. A Seção 2.4 caracteriza o domínio de aplicação, a classificação de texto curto em português, e mostra por que ele tensiona simultaneamente as métricas, o *cold start* e o oráculo. A Seção 2.5 fecha o capítulo com a revisão sistemática da interseção dessas frentes e a lacuna de pesquisa que o Capítulo 3 ocupa.

2.1 APRENDIZADO SUPERVISIONADO: CONCEITOS, MÉTRICAS E VALIDAÇÃO

O aprendizado de máquina desenvolve algoritmos que melhoram seu desempenho em uma tarefa T , segundo uma métrica P , por meio da experiência E adquirida dos dados (Mitchell, 1997). Esta seção limita-se ao que os capítulos seguintes usam diretamente: a tarefa de classificação multiclasse, as métricas adotadas, as estratégias de validação e a inferência estatística das comparações. Um panorama geral de algoritmos e representações para classificação de texto pode ser encontrado em Kowsari et al. (2019).

2.1.1 Regimes de supervisão e a tarefa de classificação multiclasse

No **aprendizado supervisionado**, o algoritmo recebe exemplos de entrada com os rótulos desejados e induz uma função que generalize para dados não vistos (Russell e Norvig, 2010; Mitchell, 1997). No **não supervisionado**, não há rótulos: o algoritmo identifica estruturas latentes, como agrupamentos ou direções de maior variância (Murphy, 2012). O **semi-supervisionado** combina uma pequena parcela rotulada com muitos exemplos não rotulados, explorando a estrutura destes para melhorar a generalização (Chapelle et al., 2006). O **aprendizado ativo** — objeto desta tese, formalizado na Seção 2.2 — ataca o mesmo gargalo do semi-supervisionado (o custo do rótulo) por via oposta: o próprio algoritmo escolhe, de forma interativa, quais instâncias submeter a um oráculo, priorizando as de maior benefício esperado (Settles, 2009). A distinção importa porque o desempenho passa a depender de duas políticas acopladas — a de seleção de instâncias e a de obtenção de rótulos — exatamente os dois eixos que o FALCO instrumenta.

A tarefa-alvo é a **classificação**: aprender $f : X \rightarrow Y$ com Y discreto (Duda et al., 2001) — aqui, atribuir a cada descrição de produto uma dentre centenas de categorias. Com $K > 2$ classes, classificadores binários podem ser combinados (um-contra-todos, um-contra-um) (Rifkin e Klautau, 2004), mas os modelos usados nesta tese são multiclasse diretos: produzem um vetor de escores $(z_1, \dots, z_K)$ convertido em distribuição de probabilidade pela função *softmax*,

$$p_i = \frac{\exp(z_i)}{\sum_{j=1}^K \exp(z_j)}, \quad i = 1, \dots, K, \quad (2.1)$$

treinados com perda de entropia cruzada (Bishop, 2006; Murphy, 2012). Essa distribuição p é duplamente essencial no aprendizado ativo: além de fornecer a predição ($\arg \max_i p_i$), é dela que as estratégias de seleção por incerteza (Seção 2.2.2) derivam seus escores. Os dois classificadores empregados nos experimentos — um modelo probabilístico vetorial leve e o BERTimbau ajustado com uma camada de classificação (Souza et al., 2020) — são detalhados no Capítulo 3.

2.1.2 Métricas para classes desbalanceadas

A **acurácia** é a proporção de predições corretas,

$$A = \frac{n_{\text{corretas}}}{N}, \quad (2.2)$$

mas é inadequada como métrica única sob desbalanceamento: um classificador que prediz sempre a classe majoritária obtém acurácia alta ignorando as minoritárias (Sokolova e Lapalme, 2009; Grandini et al., 2020; Barros et al., 2014). Por isso usam-se métricas por classe. Para uma classe tomada como positiva, com TP , FP e FN denotando verdadeiros positivos, falsos positivos e falsos negativos,

$$\text{Precisão} = \frac{TP}{TP + FP}, \quad \text{Revocação} = \frac{TP}{TP + FN}, \quad (2.3)$$

e o **F1-Score** é sua média harmônica,

$$F_1 = 2 \cdot \frac{\text{Precisão} \cdot \text{Revocação}}{\text{Precisão} + \text{Revocação}}. \quad (2.4)$$

No cenário multiclasse, a agregação **macro** calcula a métrica por classe e tira a média aritmética, dando peso igual a todas as classes; a agregação **micro** soma TP , FP e FN globais antes de aplicar a fórmula, refletindo sobretudo as classes majoritárias (Sokolova e Lapalme, 2009). Em bases com forte desbalanceamento — caso do conjunto de dados desta tese — o **Macro F1-Score** é a métrica principal, por expor o desempenho nas classes raras. Alternativas com propósito semelhante — acurácia balanceada, coeficiente de correlação de Matthews e Kappa de Cohen — são discutidas por Grandini et al. (2020) e Riyanto et al. (2023); esta tese as dispensa porque o par Macro F1 + acurácia global já separa os dois fenômenos de interesse (desempenho nas caudas *versus* desempenho agregado). A **matriz de confusão** $K \times K$, cuja

entrada $[i, j]$ conta exemplos da classe real i preditos como j , complementa as métricas agregadas ao revelar confusões sistemáticas entre pares de classes (Han et al., 2012) — instrumento usado no Capítulo 3 para caracterizar o perfil de erro dos oráculos LLM.

2.1.3 Validação e particionamento

Avaliar um modelo nos mesmos dados de treino superestima seu desempenho (*overfitting*); a validação exige dados independentes (Kohavi, 1995). As práticas empregadas nesta tese são: (i) **hold-out**, separação treino/teste, adequada a bases grandes como a desta tese; (ii) **validação cruzada k -fold estratificada**, que particiona os dados em k dobras preservando as proporções de classe — essencial sob desbalanceamento (Kohavi, 1995; Forman e Scholz, 2010; James et al., 2013; Widodo et al., 2022) — com k tipicamente 5 ou 10, equilíbrio entre viés, variância e custo (Nti et al., 2021; Reusens et al., 2024); (iii) um conjunto de **validação** separado do teste para ajuste de hiperparâmetros, mantendo o teste intocado até a avaliação final (Bishop, 2006); e (iv) para modelos de aprendizado profundo, a **parada antecipada** (*early stopping*), que interrompe o treinamento quando o desempenho em validação cessa de melhorar (Prechelt, 2012; Goodfellow et al., 2016). Uma exigência adicional específica desta tese, motivada pela auditoria da base (Capítulo 3): como descrições de produto se repetem, o particionamento deduplica por texto normalizado *antes* do sorteio, prevenindo vazamento treino→teste por duplicatas exatas.

2.1.4 Inferência estatística para comparação de classificadores e oráculos

Medir não basta: as comparações desta tese — entre oráculos, entre estratégias de seleção, entre configurações — exigem afirmar se uma diferença observada excede a flutuação amostral. Quatro instrumentos cobrem as situações que aparecem nos Capítulos 4 e 5, cada qual com a referência original e a referência aplicada ao aprendizado de máquina.

Intervalo de confiança para proporções (Wilson). Toda acurácia é uma proporção estimada em n instâncias. O intervalo usual de Wald ($\hat{p} \pm z\sqrt{\hat{p}(1 - \hat{p})/n}$) tem cobertura errática — oscila severamente abaixo do nível nominal mesmo com n grande e p moderado —, enquanto o intervalo de Wilson (1927), que resolve a desigualdade no parâmetro em vez de na estimativa, mantém cobertura próxima da nominal em toda a faixa de p ; a análise sistemática de Brown et al. (2001) recomenda-o como escolha padrão. Por isso toda acurácia de oráculo do E0 é reportada com IC de Wilson a 95%.

Comparação pareada na mesma amostra (McNemar). Quando dois oráculos rotulam *as mesmas* instâncias, os erros são dependentes e o teste correto opera sobre os pares discordantes: o teste de McNemar (1947) examina a assimetria entre os b casos em que só o primeiro acerta e os c em que só o segundo acerta; quando $b + c < 25$, usa-se a versão binomial exata. Dietterich (1998), avaliando empiricamente cinco testes para comparar classificadores, recomenda o McNemar precisamente no regime desta tese — modelos avaliados uma única vez sobre um conjunto comum — por controlar o erro tipo I onde os testes t re-amostrados falham.

Comparação pareada por semente (Wilcoxon). Quando duas estratégias são executadas com as mesmas sementes, cada semente gera um par de resultados. O teste de postos sinalizados de Wilcoxon (1945) compara os pares sem supor normalidade — suposição indefensável para métricas limitadas como o Macro F1 —, e é a recomendação canônica de Demšar (2006) para comparar dois algoritmos sobre múltiplas condições. Sua limitação estrutural importa ao desenho: com n pares, o menor p -valor bicaudal atingível é $2/2^n$ — com menos de seis sementes a significância a 5% é inalcançável por construção, o que fundamenta o mínimo de oito sementes adotado no Capítulo 3.

Intervalos por reamostragem (*bootstrap*). Para funcionais sem distribuição amostral conhecida — como a diferença de LCE entre estratégias —, o *bootstrap* (Efron e Tibshirani, 1993) estima o intervalo de confiança reamostrando os pares observados com reposição (método do percentil), permanecendo informativo mesmo com poucas repetições.

A Tabela 2.1 resume o mapeamento situação–teste–uso.

Tabela 2.1: Instrumentos de inferência estatística e seu emprego nesta tese.

Situação	Instrumento	Uso na tese
Precisão de uma proporção estimada	IC de Wilson 95% (Wilson, 1927; Brown et al., 2001)	toda acurácia de oráculo (E0)
Dois oráculos, mesmas instâncias	McNemar; binomial exato se $b+c < 25$ (McNemar, 1947; Dietterich, 1998)	pareamentos do E0/E0-P
Duas estratégias, mesmas sementes	Wilcoxon de postos sinalizados (Wilcoxon, 1945; Demšar, 2006)	E1/E4 (8 sementes)
Funcional sem distribuição conhecida	IC <i>bootstrap</i> percentil (Efron e Tibshirani, 1993)	diferença de LCE (E3)

Com o instrumental de medição estabelecido, a próxima seção formaliza o processo cuja eficiência ele mede: o laço de aprendizado ativo.

2.2 APRENDIZADO ATIVO

O aprendizado ativo (AA) maximiza a eficiência de rotulagem ao permitir que o sistema selecione, de forma interativa, as amostras mais informativas para anotação (Settles, 2012), explorando o fato de que instâncias não rotuladas costumam estar disponíveis em abundância e a baixo custo (Zhu e Goldberg, 2009). Suas origens remontam aos trabalhos de Angluin (1988), sobre aprendizado via consultas, e de Cohn et al. (1994), sobre redução de incerteza; a consolidação teórica e a taxonomia de cenários e estratégias devem-se a Settles (2012). O paradigma é a resposta natural aos domínios em que a anotação é o gargalo — de imagens médicas que exigem radiologistas a transcrições cuja anotação custa dez vezes a duração do

áudio (Settles, 2012) —, e ganhou novas camadas com o aprendizado profundo (Ren et al., 2021) e, mais recentemente, com os LLMs no papel de oráculo ou de seletor (Bayer e Reuter, 2024). Esta seção formaliza o laço, apresenta o catálogo de estratégias de seleção e encerra nas duas limitações estruturais que motivam o desenho do FALCO.

2.2.1 Formalização e cenários

No aprendizado supervisionado tradicional parte-se de um conjunto fixo de pares rotulados $L = \{(x_i, y_i)\}_{i=1}^n$. O aprendizado ativo acrescenta um componente interativo: além de L , dispõe-se de um conjunto não rotulado $U = \{x_j\}_{j=1}^m$ com $L \cap U = \emptyset$, e a cada iteração uma **regra de seleção** $S : (U_t, \theta_t, L_t) \mapsto Q_t \subseteq U_t$ escolhe um lote Q_t a ser consultado; o oráculo rotula Q_t , os pares entram em L_t , e o processo segue até esgotar o orçamento B ou satisfazer um critério de parada. Entre as formulações existentes (Settles, 2012; Roy e McCallum, 2001; Goudjil et al., 2018), adapta-se aqui o arcabouço de Cohn, Ghahramani e Jordan, ampliado por Hanneke (Cohn et al., 1996; Hanneke, 2015).

Definição 2.1 (Aprendizado Ativo) *Aprendizado ativo é representado, neste trabalho, pela sêxtupla*

$$\mathcal{A} = \langle L, U, \theta, S, O, B \rangle,$$

em que L é um conjunto de exemplos rotulados, U um conjunto de exemplos não rotulados, θ denota o estado do modelo supervisionado atualizado a partir de L , S é uma regra de seleção que indica os exemplos de U a serem consultados, O é o oráculo que fornece o rótulo correto para cada instância, e B corresponde ao orçamento, eventualmente infinito, de consultas possíveis ao oráculo.

A Tabela 2.2 resume os componentes; o Algoritmo 1 apresenta o laço (Settles, 2012; Goudjil et al., 2018). Essa notação — L_0 para o conjunto inicial, U para o *pool*, S para a estratégia, O para o oráculo, B para o orçamento — é a mesma usada em todo o Capítulo 3.

Tabela 2.2: Componentes do arcabouço de aprendizado ativo

Símbolo	Definição formal	Descrição
L	$L = \{(x_i, y_i)\}_{i=1}^n \subseteq \mathcal{X} \times \mathcal{Y}$	Conjunto de exemplos rotulados
U	$U = \{x_j\}_{j=1}^m \subseteq \mathcal{X}$	Instâncias não rotuladas disponíveis
θ	$\theta \in \Theta$	Modelo treinado em L
S	$S : (U_t, \theta_t, L_t) \mapsto Q_t \subseteq U_t$	Regra que determina o lote Q_t a enviar ao oráculo
O	$O : \mathcal{X} \rightarrow \mathcal{Y}$	Oráculo que devolve o rótulo verdadeiro $y = O(x)$
B	$B \in \mathbb{N}$	Orçamento de consultas restantes

Algoritmo 1 Esquema geral de aprendizado ativo

- 1: **1. Inicialização:** definir os conjuntos iniciais e orçamento.
 - 2: $L_0 \leftarrow$ conjunto de exemplos rotulados iniciais
 - 3: $U_0 \leftarrow$ conjunto de exemplos não rotulados
 - 4: $B_0 \leftarrow$ orçamento inicial de consultas
 - 5: **2. Laço principal:** enquanto houver orçamento e instâncias não rotuladas, repetir:
 - 6: $\theta_t \leftarrow \text{Learn}(L_t)$
 - 7: $Q_t \leftarrow S(U_t, \theta_t, L_t)$
 - 8: $\forall x \in Q_t, y \leftarrow O(x)$
 - 9: $L_{t+1} \leftarrow L_t \cup \{(x, y) : x \in Q_t\}; U_{t+1} \leftarrow U_t \setminus Q_t; B_{t+1} \leftarrow B_t - |Q_t|$
 - 10: $t \leftarrow t + 1$
 - 11: **3. Finalização:** retornar θ_{final} treinado em L_T .
-

O laço admite três cenários clássicos, que diferem em como as instâncias chegam ao seletor (Settles, 2012): na **síntese de consultas**, o algoritmo gera instâncias artificiais — poderoso em espaços bem definidos, mas sujeito a produzir exemplos ininteligíveis para anotadores (Baum e Lang, 1992); na **amostragem seletiva em fluxo**, instâncias chegam uma a uma de uma distribuição natural e o algoritmo decide, por um limiar de utilidade, se consulta cada uma (Dagan e Engelson, 1995); e no **aprendizado ativo com acervo fixo** (*pool-based*), o cenário desta tese e o mais comum na prática, um conjunto finito U está disponível desde o início e o algoritmo seleciona dele as instâncias de maior utilidade (Lewis e Gale, 1994). Três extensões do cenário básico são relevantes aqui: o modo em **lote** (*batch-mode*), que seleciona múltiplas instâncias por iteração — inevitável quando o re-treinamento é caro, mas exigindo diversidade dentro do lote (Hoi et al., 2006); o aprendizado ativo **federado**, que executa a seleção localmente em múltiplos clientes preservando privacidade (Deng et al., 2023); e o cenário com **múltiplos oráculos** de custos e competências distintos (Yan et al., 2011) — historicamente motivado por *crowdsourcing* e hoje reencarnado no cardápio de LLMs com preços e acurácias diferentes, que é precisamente o cenário do FALCO.

2.2.2 Estratégias de seleção de instâncias

A estratégia de seleção é o componente que define um algoritmo de aprendizado ativo: ela determina quais instâncias valem o custo do oráculo, buscando maximizar a informação obtida por consulta (Settles, 2012) — no espírito de Shannon (1948), buscar ativamente a informação que mais reduz a incerteza. As famílias de estratégias diferem no princípio heurístico e no custo computacional; as que esta tese emprega diretamente recebem tratamento completo, e as demais, uma síntese com as referências de aprofundamento.

Amostragem por incerteza (*uncertainty sampling*). A família mais usada na prática (Lewis e Catlett, 1994; Settles, 2012): seleciona as instâncias sobre as quais o modelo corrente está

mais incerto, requerendo apenas as probabilidades preditas — custo baixo, aplicabilidade geral, e relação teórica com a bissecção do espaço de versão em classificadores de margem (Tong e Koller, 2000); permanece linha de base forte em *deep learning* (Gal et al., 2017). Suas três medidas canônicas são usadas nos experimentos desta tese:

$$x_{LC}^* = \arg \max_x [1 - P_\theta(\hat{y}|x)] \quad (2.5)$$

seleciona pela **menor confiança** na classe mais provável;

$$x_M^* = \arg \min_x [P_\theta(\hat{y}_1|x) - P_\theta(\hat{y}_2|x)] \quad (2.6)$$

seleciona pela **menor margem** entre as duas classes mais prováveis; e

$$x_H^* = \arg \max_x \left[- \sum_y P_\theta(y|x) \log P_\theta(y|x) \right] \quad (2.7)$$

seleciona pela **entropia** da distribuição completa. As limitações da família são conhecidas: é míope (confia num modelo possivelmente ruim, em especial no início), suscetível a *outliers*, e pode negligenciar classes raras ao concentrar-se na fronteira das majoritárias (Settles, 2012; Attenberg e Provost, 2010).

Comitês e espaço de versão. A segunda família seleciona pela divergência entre hipóteses plausíveis: o espaço de versão é o subconjunto de hipóteses consistentes com L (Mitchell, 1982), e consultas que maximizam o desacordo entre seus membros eliminam hipóteses mais rapidamente — com garantias teóricas de melhoria exponencial em certos regimes (Cohn et al., 1994; Hanneke, 2015). A implementação prática é a **consulta por comitê** (QBC): um *ensemble* construído por amostragem bayesiana, *bagging*, *boosting* ou múltiplas visões (Seung et al., 1992; Freund et al., 1997; McCallum e Nigam, 1998; Abe e Mamitsuka, 1998; Muslea et al., 2000; Blum e Mitchell, 1998) vota, e as instâncias de maior desacordo (medido por entropia de votos ou divergência de Kullback–Leibler) são consultadas; a diversidade do comitê é determinante (Melville e Mooney, 2004). O custo de manter múltiplos modelos torna a família menos atraente quando o classificador é re-treinado a cada lote.

Redução de erro ou variância esperados. A terceira família adota a perspectiva de teoria da decisão: escolher a consulta que, em expectativa, mais reduz o erro de generalização ou a variância preditiva do modelo resultante (Roy e McCallum, 2001; MacKay, 1992; Cohn et al., 1996), com tratamento natural de lotes via otimização submodular (Guestrin et al., 2005; Golovin e Krause, 2011; Krause e Golovin, 2014). É a única família que otimiza diretamente o objetivo final — e a de custo computacional proibitivo no nosso regime: re-treinamento por par candidato-rótulo ou álgebra matricial que escala mal com a dimensionalidade.

Exploração da estrutura dos dados. A quarta família incorpora a distribuição $P(X)$ das próprias instâncias: seleciona pontos que sejam, além de informativos, **representativos** — em regiões densas ou centrais a agrupamentos — mitigando a seleção de *outliers*. A ponderação por densidade multiplica a utilidade-base por um termo de representatividade,

$$x_{ID}^* = \arg \max_x \phi_A(x) \times (\text{Representatividade}(x))^\beta, \quad (2.8)$$

com β controlando o peso da densidade (Settles e Craven, 2008); as variantes por agrupamento consultam centróides ou amostram hierarquicamente com garantias de robustez (Nguyen e Smeulders, 2004; Dasgupta e Hsu, 2008). Esta família é a base conceitual do DRI-SL (Capítulo 3): densidade semântica e variedade lexical como critérios de representatividade computáveis sem nenhum rótulo. Sua hipótese de trabalho — estrutura dos dados correlacionada com a distribuição dos rótulos — nem sempre vale, e o custo de computar a estrutura não é desprezível.

A Tabela 2.3 resume o quadro comparativo.

Tabela 2.3: Comparação de alto nível das famílias de estratégias de seleção.

Estratégia	Vantagens principais	Desvantagens principais
Amostragem por incerteza	Simples, rápida, aplicabilidade geral.	Míope, suscetível a <i>outliers</i> , pode falhar com desbalanceamento.
Comitês / espaço de versão	Menos míope, garantias teóricas.	Custo do comitê; depende da sua qualidade e diversidade.
Redução de erro / variância	Otimiza o objetivo final; base teórica sólida.	Custo computacional proibitivo em escala.
Exploração da estrutura	Mitiga <i>outliers</i> ; funciona sem rótulos.	Depende da correlação estrutura-rótulo; custo de computar a estrutura.

2.2.3 Limitações do laço clássico

Duas suposições sustentam o laço da Seção 2.2.1 — e ambas falham exatamente nos regimes que interessam a esta tese.

A primeira é a existência de um modelo inicial capaz de guiar a seleção. As estratégias de incerteza e desacordo pressupõem θ_0 treinado em algum L_0 ; com L_0 minúsculo ou inexistente — a **partida a frio** (*cold start*) — o modelo não sustenta seleções melhores que o acaso (Bayer e Reuter, 2024), e o problema se agrava em texto curto, onde cada instância carrega pouca informação, e com classificadores profundos, cujo re-treinamento frequente é caro (Fromme et al., 2022). As respostas da literatura passam pela exploração da estrutura dos dados antes de existir modelo — a família da Eq. (2.8) — e, mais recentemente, por seletores externos com conhecimento pré-treinado (Seção 2.3).

A segunda é a suposição de **oráculo perfeito**: O devolve sempre o rótulo verdadeiro, a custo unitário constante. Anotadores reais erram, variam entre si e cansam; a resposta clássica inclui rotulagem repetida, modelagem da qualidade do anotador e roteamento entre anotadores

de custos distintos (Sheng et al., 2008; Snow et al., 2008; Donmez et al., 2009; Yan et al., 2011). Quando o oráculo passa a ser um LLM, essa fratura muda de natureza — o erro torna-se sistemático e estruturado, e o custo, uma função de tokens — e é tratada em profundidade na Seção 2.3.

Duas consequências operacionais do laço merecem registro porque reaparecem nos experimentos. Primeiro, o **critério de parada**: o ganho marginal por lote decresce ao longo da curva de aprendizado, e critérios baseados na estagnação do desempenho em um conjunto de validação — como o adotado pelo FALCO e formalizado no Apêndice G — ou em razões de custo-benefício (Rouzegar e Makrehchi, 2024) evitam pagar rótulos que só comprem ruído. Segundo, o **viés de amostragem ativa**: o conjunto rotulado resultante não é uma amostra i.i.d. da população — a seleção por incerteza sobre-representa casos difíceis e classes raras (Santos, 2016; Settles, 2012) —, o que afeta tanto o treinamento (às vezes a favor: o conjunto fica mais balanceado que a distribuição natural) quanto, criticamente, a *avaliação*: métricas calculadas sobre os próprios dados coletados não estimam o desempenho populacional, exigindo conjuntos reservados — fenômeno quantificado no experimento E6 desta tese (Capítulo 5).

2.3 MODELOS DE LINGUAGEM COMO ORÁCULOS DE ROTULAGEM

O surgimento dos *Large Language Models* (LLMs) altera os dois lados do laço de aprendizado ativo: eles podem selecionar instâncias e podem rotulá-las. Esta seção examina a evidência empírica dessas capacidades, as arquiteturas de integração propostas na literatura, o regime de treinamento com rótulos ruidosos que o oráculo LLM inaugura e — dimensão raramente tratada de forma sistemática — a estrutura de custo e de medição que passa a existir quando o oráculo é um serviço pago por token.

2.3.1 Capacidades e evidência empírica

A anotação humana é cara, lenta e sujeita a inconsistências (Settles, 2012); LLMs surgem como pseudo-oráculos capazes de rotular em escala (Zhang et al., 2022b). A evidência seminal é o estudo de Gilardi et al. (2023): o ChatGPT em modo *zero-shot* superou anotadores de *crowdsourcing* em cerca de 25 pontos percentuais de acurácia média, com maior concordância intercodificador e custo por anotação aproximadamente 30 vezes menor. As vantagens estruturais — escalabilidade sem fadiga, consistência entre anotações, velocidade — convivem com limitações conhecidas: qualidade inferior à de especialistas em domínios de nuance, vieses herdados do pré-treinamento, alucinação e conhecimento datado. Cabe a ressalva central para esta tese: os resultados positivos concentram-se em tarefas com poucas classes; os estudos recentes de classificação de produtos operam com dezenas a algumas centenas de categorias — 248 no comparativo zero-shot de Roumeliotis et al. (2025), 370 folhas nos testes de robustez de Gholamian et al. (2024), que também mostram LLMs mais resilientes que modelos supervisionados sob abreviação e truncamento de títulos. A transferência desse desempenho para espaços fechados

com centenas de categorias em português não é automática e constitui uma das perguntas experimentais do Capítulo 3.

2.3.2 Arquiteturas de integração no laço

A literatura organiza-se em torno de papéis e composições distintas para o LLM no laço.

Como **anotador**, o LLM substitui o oráculo humano: Zhang e Takada (2025b) rotulam com GPT as instâncias selecionadas por estratégias clássicas de incerteza e diversidade, treinando um modelo compacto *cross-task* a custo muito inferior ao de classificar todo o conjunto com o LLM; Rouzegar e Makrehchi (2024) introduzem roteamento por limiar de confiança — o LLM anota quando confia, casos difíceis vão ao humano — aproximando o F1 da anotação inteiramente humana a custo reduzido. Em línguas de baixo recurso, Kholodna et al. (2024) acrescentam duas práticas operacionais que esta tese incorpora: a *seleção prévia do anotador* entre LLMs candidatos e a *anotação em lote*, que amortiza o prefixo do *prompt* entre várias instâncias, com economia estimada superior a 42 vezes frente à anotação humana.

Como **seletor**, o LLM ataca a partida a frio: o ActiveLLM (Bayer e Reuter, 2024) usa o conhecimento pré-treinado de modelos como o GPT-4 para escolher instâncias informativas em regime *few-shot*, sem depender de um classificador inicial, superando estratégias tradicionais e técnicas específicas de poucos exemplos; a arquitetura conceitual está na Figura 2.1. O desempenho do seletor depende da engenharia do *prompt* — instruções claras de papel, encadeamento de pensamento (Wei et al., 2022), controle do tamanho do lote e recapitulação das seleções anteriores (Bayer e Reuter, 2024) —, e a própria escolha de *prompts* pode ser ativa (Diao et al., 2023; Schick et al., 2023).




Figura 2.1: Arquitetura conceitual do ActiveLLM: o LLM atua como *seletor* de instâncias informativas — mitigando o *cold start* — enquanto a rotulagem permanece com um oráculo e o aprendizado com um modelo sucessor. Adaptado de Bayer e Reuter (2026).

Como **componente de sistemas compostos**, quatro desenhos recentes importam ao posicionamento desta tese: a *destilação ativa de conhecimento*, em que o LLM-professor rotula para um estudante compacto (Su et al., 2023), com a variante de *rótulos candidatos* de Xia et al. (2025a) — quando incerto, o LLM emite um conjunto de hipóteses que o estudante destila, convertendo incerteza em informação; os *sistemas híbridos humano-LLM*, que roteiam casos difíceis ao humano (Margatina et al., 2023); a *mistura de LLMs* de Qi et al. (2026), que substitui o anotador único por um comitê de modelos leves locais com mecanismos de discrepância e aprendizado negativo; e o paradigma *dual-expert* para taxonomias amplas de produtos (Cheng

et al., 2024), em que um especialista de domínio contrai o espaço a K candidatos e o LLM generalista decide entre eles.

2.3.3 Rótulos ruidosos e seu efeito no treinamento

Quando o LLM assume o papel de oráculo, o classificador da tarefa passa a ser treinado com *rótulos ruidosos* — regime com literatura própria e madura: o survey clássico de Frénay e Verleysen (2014) organiza taxonomias de ruído (aleatório, dependente de classe, dependente de instância) e seus efeitos; Natarajan et al. (2013) estabelecem garantias de aprendizado sob ruído com funções de perda corrigidas; e Song et al. (2023) revisam o estado da arte com redes profundas. Dois resultados importam diretamente: redes profundas toleram ruído moderado quando há dados suficientes, mas degradam de forma acentuada sob ruído estruturado (dependente de classe) — exatamente o perfil de erro observado em oráculos LLM, cujas confusões se concentram em pares de classes vizinhas. A evidência mais recente acrescenta uma cautela metodológica: ruído *real* de anotação é substancialmente mais nocivo que as corrupções sintéticas usadas em avaliação — demonstrado em reconhecimento de entidades pelo NoiseBench (Merdjanovska et al., 2024), que inclui um braço explícito de ruído gerado por LLM, e em classificação de produtos em larga escala pelo AlleNoise (Rączkowska et al., 2024), meio milhão de títulos em 5.692 categorias com 15% de ruído real de *marketplace*. Estratégias que combinam filtragem por modelos pequenos com consulta seletiva ao LLM apenas nos casos suspeitos (Yuan et al., 2025) apontam o caminho de integração. O experimento E4 desta tese (Capítulo 3) quantifica a degradação sob ruído controlado no domínio de interesse.

2.3.4 Custo, instrumentação e reprodutibilidade da medição

O oráculo LLM introduz uma economia e uma metrologia próprias, raramente instrumentadas na literatura. O **custo** deixa de ser por item e passa a ser por *token*, com três alavancas operacionais: o tamanho do lote de anotação, que amortiza o prefixo comum do *prompt* entre instâncias (Kholodna et al., 2024); o *cache* de prefixo oferecido por provedores, que reduz o preço da porção repetida; e os limites de vazão (requisições por minuto, cotas diárias), que definem o tempo de parede independentemente do preço. A **medição** também muda: parte do erro aparente de um LLM anotador é erro de *formato* — resposta fora do espaço de classes ou inconsumível automaticamente — e não de semântica (Kholodna et al., 2024), o que torna a restrição da saída ao espaço fechado de rótulos parte do instrumento; a confiança auto-reportada dos LLMs tende ao excesso, exigindo calibração (Tian et al., 2023); as janelas de contexto limitam o lote (Bayer e Reuter, 2024); e a resposta do mesmo modelo pode variar entre versões e provedores de *serving*, fazendo de cada medição uma fotografia da tripla (modelo, provedor, data). A seleção ativa em múltiplos níveis — de instâncias, de *prompts* e do próprio oráculo (Wu et al., 2022) — é a generalização natural desse cenário. O Capítulo 3 instrumenta cada um desses componentes; os experimentos E0 e E0-P os quantificam.

Em síntese: com um oráculo LLM, qualidade, custo e instrumento de medição tornam-se três dimensões *escolhíveis* de projeto — e é nesse espaço de decisão que o FALCO opera.

2.4 CLASSIFICAÇÃO DE TEXTO CURTO

O domínio de aplicação desta tese — descrições de produtos de varejo em português — pertence à classificação de texto curto (*short text classification*, STC), subcampo com desafios próprios que tensionam tanto as métricas da Seção 2.1 quanto o laço da Seção 2.2. Textos curtos abundam em plataformas digitais — consultas de busca, mensagens, títulos — e sua classificação sustenta aplicações de análise de sentimento a categorização de catálogos (Ahmed et al., 2022; Song et al., 2014b).

2.4.1 Definições e desafios

A classificação de texto aprende $f : D \rightarrow C$ de documentos para um conjunto pré-definido de classes a partir de exemplos rotulados (Aggarwal e Zhai, 2012; Kowsari et al., 2019); o texto *curto* especializa a tarefa para sequências de comprimento limitado — tipicamente até 200 caracteres (Song et al., 2014b; Alsmadi e Gan, 2019b) —, como *tweets*, títulos de notícias, consultas e descrições de produtos (Darú, 2024). Quatro características tornam o regime difícil (Ahmed et al., 2022, 2023; Song et al., 2014b): a **escassez de contexto**, que limita a desambiguação; a **esparsidade lexical** em alta dimensionalidade, que enfraquece métricas de similaridade e agrava a maldição da dimensionalidade; o **ruído e a informalidade** — erros, abreviações, gírias — que exigem normalização (Aliero et al., 2023); e a **ambiguidade** semântica acentuada pela falta de contexto. O pré-processamento usual (tokenização, minúsculas, remoção de pontuação e *stopwords*, lematização ou *stemming*, tratamento de ruído específico) mitiga parte do problema, e sua escolha e ordem afetam o desempenho final (Naseem et al., 2021b; Aliero et al., 2023); nesta tese ele é deliberadamente mínimo (Capítulo 3), delegando a variação lexical ao classificador. No domínio específico — cupons fiscais de varejo — os textos têm 4 a 50 caracteres, caixa alta e abreviações agressivas (CERV BRAHMA LT 350ML), combinando todos os quatro desafios de uma vez.

2.4.2 Representação e classificadores

As **representações esparsas** — *one-hot*, *bag-of-words* nas variantes binária, por frequência e TF-IDF (Salton e Buckley, 1988), estendidas por *n*-gramas — projetam cada texto num vetor de dimensão igual ao vocabulário; a similaridade do cosseno é a métrica de comparação usual nesse regime (Baeza-Yates e Ribeiro-Neto, 2013). Suas propriedades em descrições curtas de produtos em português foram investigadas em profundidade na dissertação de mestrado do autor (Darú, 2024), que este trabalho toma como ponto de partida: em texto curto a frequência de termos satura (quase todo termo ocorre uma única vez por descrição), o que explica a vantagem empírica da variante binária sobre TF e TF-IDF — e a configuração vencedora lá identificada

(binária, uni e bigramas, sem normalização) é a adotada pelo classificador leve PVBin desta tese; para o panorama de ponderação e representação, ver Salton e Buckley (1988) e Naseem et al. (2021a). As **representações densas** mapeiam palavras ou textos para espaços contínuos de baixa dimensão: os *embeddings* estáticos — Word2Vec (Mikolov et al., 2013), GloVe (Pennington et al., 2014), FastText (Bojanowski et al., 2017) — atribuem um vetor por palavra, sem tratar polissemia (Selva e Titus, 2021; Goldberg, 2017); os **contextuais** condicionam a representação de cada token à sequência inteira — ELMo (Peters et al., 2018), a família GPT (Radford et al., 2018, 2019) e o BERT (Devlin et al., 2019b) —, resolvendo a polissemia e sustentando o estado da arte em texto curto (Ahmed et al., 2022; Li et al., 2020; Karl e Scherp, 2023). É dessa família o SBERT usado pelo DRI-SL e o BERTimbau (Souza et al., 2020) usado como classificador forte.

Quanto aos **classificadores**, os algoritmos clássicos — SVM (Cortes e Vapnik, 1995), Naive Bayes e regressão logística (Murphy, 2012), KNN (Cover e Hart, 1967), árvores e *ensembles* (Quinlan, 1993; Breiman, 2001; Dietterich, 2000) — seguem relevantes como linhas de base eficientes sobre representações esparsas (Kowsari et al., 2019; Aliero et al., 2023); arquiteturas profundas convolucionais e recorrentes capturam padrões locais e sequenciais (Goodfellow et al., 2016; Xu et al., 2017), com benefício limitado em textos muito curtos; e os **Transformers ajustados** (BERT e variantes) representam o estado da arte da tarefa (Devlin et al., 2019b; Li et al., 2020; Karl e Scherp, 2023), ao custo de treinamento e inferência substancialmente maiores. Essa gradação de custo-capacidade é a razão de esta tese operar com um par de classificadores: um leve, barato o suficiente para re-treinos a cada lote, e um forte, para a validação final.

2.4.3 Implicações para o aprendizado ativo no domínio

Três consequências do regime de texto curto estruturam os experimentos desta tese. Primeiro, a cauda longa de classes torna o Macro F1 implacável: com centenas de categorias e poucas instâncias nas raras, cada classe descoberta tarde custa caro na métrica — e é por isso que a cobertura de classes do conjunto inicial domina o desempenho no regime pequeno (Capítulo 4). Segundo, a partida a frio é mais severa: com pouca informação por instância, o modelo inicial precisa de mais exemplos para sustentar seleções informadas, elevando o valor de heurísticas de representatividade que operam sem rótulos. Terceiro, o desbalanceamento interage com a seleção por incerteza — que tende a concentrar-se nas fronteiras das classes majoritárias (Attenberg e Provost, 2010) — e com a própria avaliação, como discutido na Seção 2.2.3. O domínio de descrições de varejo em português (Darú et al., 2022) reúne essas três condições em escala, o que o torna o laboratório adequado para o framework proposto.

2.5 ESTADO DA ARTE NA INTERSEÇÃO E LACUNA DE PESQUISA

As três seções anteriores revisaram as frentes isoladamente; esta seção examina sua interseção — aprendizado ativo com oráculos LLM para classificação de texto curto — na literatura de 2020 ao primeiro semestre de 2026, e delimita a lacuna que o restante da tese ocupa.

2.5.1 Escopo e método da revisão

Esta revisão concentrou-se em publicações revisadas por pares e pré-prints significativos (ACL Anthology, arXiv e periódicos da área) do período de 2020 até o primeiro semestre de 2026, com uma atualização dedicada cobrindo o último ano (meados de 2025 a meados de 2026). A busca utilizou combinações de termos como *active learning*, *text classification*, *short text*, *LLM*, *large language model*, *cold start*, *few-shot learning* e *oracle*, priorizando trabalhos que conectassem explicitamente essas áreas. A análise focou em identificar tendências na aplicação de LLMs em AA, abordagens para a partida a frio e as lacunas remanescentes. Registre-se o estatuto metodológico: trata-se de uma *revisão narrativa focada* na interseção das frentes, e não de uma revisão sistemática completa com protocolo registrado e fluxo de seleção documentado (Kitchenham, 2004) — escolha adequada ao papel do capítulo (fundamentar a lacuna, não inventariar um campo), cuja contrapartida é a tabela de lacunas (Tabela 2.4) explicitar os critérios pelos quais os trabalhos mais próximos foram confrontados.

2.5.2 Síntese por frente

Partida a frio informada. A linha que antecede os LLMs usa representações pré-treinadas para selecionar o conjunto inicial — ALPS (Yuan et al., 2020) explora a "surpresa" do modelo de linguagem; Ein-Dor et al. (Ein-Dor et al., 2020) e Griesshaber et al. (Grießhaber et al., 2020) adaptam AA ao BERT — e culmina no DEUCE (Guo et al., 2025), que combina diversidade textual e de classe prevista num grafo duplo-vizinho para evitar o efeito de cluster perdido. O DEUCE converge conceitualmente com a Fase 1 do FALCO, mas não incorpora oráculo LLM nem é avaliado em português ou texto de e-commerce.

LLM no laço. A transição do BERT ajustado para o LLM generativo redefiniu os papéis: seleção informada pelo conhecimento pré-treinado (ActiveLLM (Bayer e Reuter, 2024)), rotulagem das instâncias selecionadas (Zhang e Takada, 2025b), roteamento híbrido humano-LLM (Rouzegar e Makrehchi, 2024), rótulos candidatos com destilação (Xia et al., 2025a) e misturas de LLMs leves (Qi et al., 2026); a survey de Xia et al. (2025b) organiza o campo na progressão "da seleção para a geração". Os desafios transversais são a calibração da confiança, o custo por consulta e a propagação de vieses (Bayer e Reuter, 2024; Zhang e Takada, 2025b). A pesquisa de comunidade de Romberg et al. (2025) acrescenta o alerta prático: complexidade de implantação, incerteza sobre a redução real de custo e ferramental inadequado seguem sendo as barreiras à adoção — a viabilidade operacional, não a acurácia, é o obstáculo apontado.

Robustez a ruído e produto/e-commerce. As duas frentes restantes foram detalhadas nas Seções 2.3.3 e 2.3.2; na interseção com o domínio, o estudo de Machado e Veloso (2026) — classificação de ≈ 100 mil títulos de supermercados portugueses nas categorias ECOICOP para estatística oficial — corrobora a escolha do BERTimbau como classificador forte (97,0% de acurácia, 94,0% de Macro F1 após ajuste), mas depende de um fluxo de rotulagem humano ad-hoc iniciado com 12 mil rótulos manuais, sem estratégia formal de aprendizado ativo nem oráculo automatizado — exatamente o processo que o FALCO formaliza.

2.5.3 Lacuna de pesquisa

A análise revela que as peças existem separadas, mas sua integração sistemática não: falta um framework que (i) utilize o conhecimento pré-treinado de LLMs para informar a seleção inicial ou fornecer rótulos na partida a frio; (ii) adapte as estratégias de seleção para considerar, além do classificador em treinamento, a confiança e o custo do oráculo LLM; (iii) seja otimizado para as características do texto curto; e (iv) balanceie explicitamente o custo financeiro das consultas com o ganho de informação — com avaliação rigorosa desse *trade-off*, ainda rara mesmo nos trabalhos que tocam o custo (Zhang e Takada, 2025b; Ein-Dor et al., 2020). A Tabela 2.4 cruza os trabalhos mais próximos com as cinco dimensões cuja combinação define a lacuna.

Tabela 2.4: Cobertura das dimensões da lacuna pelos trabalhos mais próximos (2020–2026). ✓ = tratado; ✗ = ausente; ~ = parcial.

Trabalho	<i>Cold start</i> informado	Oráculo LLM	Custo instrum.	Texto curto em PT	AA formal
DEUCE (Guo et al., 2025)	✓	✗	✗	~	✓
ActiveLLM (Bayer e Reuter, 2024)	✓	✗	✗	✗	✓
Zhang e Takada (2025b)	✗	✓	~	✗	✓
Rouzegar e Makrehchi (2024)	✗	✓	~	✗	✓
Kholodna et al. (2024)	✗	✓	✓	✗	✓
CanDist (Xia et al., 2025a)	✗	✓	✗	~	~
MoLLIA (Qi et al., 2026)	✗	✓	~	✗	✓
Dual-expert (Cheng et al., 2024)	✗	✓	✗	~	✗
Machado e Veloso (2026)	✗	✗	✗	✓	✗
FALCO (esta tese)	✓	✓	✓	✓	✓

A leitura da tabela confirma que a lacuna permanece após a atualização 2025–2026: DEUCE cobre a partida a frio sem oráculo LLM; a mistura de LLMs cobre a robustez do anotador sem progressão de custo; os estudos de produto cobrem o domínio sem aprendizado ativo. A ausência combinada — partida a frio informada + oráculo LLM progressivo + texto curto em português + custo instrumentado — é a lacuna que o Capítulo 3 ataca.

2.5.4 Conclusão do capítulo

O capítulo percorreu uma cadeia: as *métricas* sob desbalanceamento e a inferência que as compara (Seção 2.1); o *laço* que compra informação e suas duas fraturas — partida a frio e oráculo imperfeito (Seção 2.2); o *oráculo LLM* que transforma qualidade, custo e instrumento em variáveis de projeto (Seção 2.3); o *domínio* de texto curto que tensiona tudo simultaneamente (Seção 2.4); e o *estado da arte* que resolve cada fratura isoladamente, mas não as três em conjunto (Seção 2.5). O Capítulo 3 apresenta o framework que ocupa essa interseção — e o programa experimental que o submete à prova.

3 METODOLOGIA

Este capítulo descreve a metodologia empregada para desenvolver e avaliar o **FALCO** (*Framework de Aprendizado Ativo com LLM para texto CurtO*). A investigação está organizada em quatro pilares empíricos, cada qual associado a um experimento identificado e reproduzível: (P1) o impacto da composição do conjunto inicial de rotulagem L_0 ; (P2) a construção de um L_0 informativo sem acesso a rótulos, via o algoritmo DRI-SL; (P3) a viabilidade, o custo e o perfil de erro de modelos de linguagem de grande porte (LLMs) como oráculos de rotulagem; e (P4) a avaliação integrada do FALCO contra métodos de referência sob o mesmo orçamento de rotulagem. Uma métrica transversal, a *Learning Curve Efficiency* (LCE), sumariza a eficiência das curvas de aprendizado em todos os pilares.

Todos os experimentos são implementados na biblioteca `activelearning` (Apêndice D), desenvolvida nesta pesquisa sob arquitetura hexagonal com domínio isolado, e cada número reportado nos capítulos de resultados é rastreável a um artefato de execução versionado (configuração, sementes, revisão do código e registros por iteração), conforme a Seção 3.10.

3.1 DESENHO DA PESQUISA

A pesquisa adota um desenho experimental quantitativo, no modo *pool-based* de aprendizado ativo (Lewis e Gale, 1994; Settles, 2012): há um acervo finito de instâncias não rotuladas U , um classificador da tarefa θ , uma estratégia de seleção S que escolhe lotes de consulta $Q_t \subset U_t$, um oráculo O que fornece rótulos e um orçamento B de consultas. Como os rótulos verdadeiros de todo o conjunto de dados estão disponíveis, o processo é simulado com fidelidade: o oráculo LLM pode ser avaliado contra o padrão-ouro, e um modelo treinado com supervisão completa fornece o limite superior de desempenho.

A Tabela 3.1 resume o programa experimental. Os experimentos E0 a E3 respondem, respectivamente, aos pilares P3, P1/P2 (reanálise) e P4; E4 é condicional ao resultado de E0, conforme o critério de decisão da Seção 3.7.3.

Tabela 3.1: Programa experimental da tese.

Id	Objetivo	Pilar	Recursos
E0	Avaliação fatorial de LLMs como oráculo	P3	APIs de LLM
E1	Estratégias de seleção $\times$ tamanho de lote (oráculo simulado)	apoio a P4	CPU
E2	Épocas de ajuste fino do BERTimbau por iteração	apoio a P4	GPU
E3	FALCO <i>versus</i> RS e US sob mesmo orçamento	P4	GPU + APIs
E4	Robustez do aprendizado a ruído controlado do oráculo	P4 (condicional)	GPU

P1 (sensibilidade de L_0) e P2 (DRI-SL) reutilizam execuções já realizadas e auditadas.

3.2 CONJUNTO DE DADOS

Esta seção documenta o material empírico da tese em quatro decisões encadeadas: de onde vêm os dados e o que os caracteriza, quanto se pode confiar nos rótulos de referência, como textos e espaço de classes foram normalizados e como o conjunto foi particionado para os experimentos.

3.2.1 Fonte e características

O conjunto de dados é o *Retail Product Description-Ptbr* (Darú et al., 2022; Darú, 2024), publicado pelo autor no Kaggle com identificador persistente (DOI 10.34740/kaggle/dsv/4265348; Darú, 2022), com $N = 250.365$ descrições de produtos de varejo na versão original — 250.221 na versão corrigida utilizada (Seção 3.2.2) — em português brasileiro, coletadas de 18 grandes varejistas, cada qual associada a uma categoria de produto. As descrições são curtas (4 a 50 caracteres; mediana de 32), tipicamente em caixa alta e com abreviações características de cupons fiscais (*e.g.*, CERV BRAHMA LT 350ML), configurando os desafios de esparsidade lexical e baixo contexto discutidos no Capítulo 2. A distribuição de classes é fortemente desbalanceada: a classe mais frequente (*biscoito*) concentra 14.292 instâncias (5,7%), enquanto centenas de classes têm poucas dezenas de exemplos.

3.2.2 Auditoria de qualidade dos rótulos

Antes dos experimentos, o conjunto foi auditado quanto à qualidade do padrão-ouro — etapa relevante porque os rótulos servem simultaneamente de gabarito para o oráculo LLM (P3) e de supervisão para o classificador (P4). Três achados condicionam o desenho experimental e a interpretação dos resultados:

1. **Conflitos de rótulo:** 719 descrições distintas (1.807 linhas; 0,7% do total) aparecem associadas a duas ou mais categorias diferentes (*e.g.*, MILHARINA QUAKER 500G ocorre com os rótulos *farinha de milho*, *floco de milho*, *fubá* e *polenta*). Esse ruído impõe um teto de aproximadamente 99,3% à acurácia mensurável de qualquer classificador ou oráculo na distribuição de produção. As instâncias foram mantidas por representarem o ruído real do domínio; o teto é considerado na interpretação (Capítulo 5). Uma análise de sensibilidade quantifica o efeito dessa decisão: reavaliando as anotações dos oráculos do E0 (i) com as instâncias conflitantes excluídas e (ii) sob pontuação *multi-gold* (acerto quando o rótulo predito coincide com *qualquer* dos rótulos observados para a mesma descrição na base), a acurácia de todos os oráculos varia no máximo +0,7 ponto percentual, sem alteração de nenhum ordenamento ou decisão. O ruído de gabarito, portanto, limita a medição, mas não a contamina de forma relevante — o que justifica manter as instâncias.

2. **Rótulo operacional:** a categoria `inativo` (144 linhas) registra um status de cadastro, não um tipo de produto (*e.g.*, UVA PASSA ESCURA 150G $\rightarrow$ `inativo`). As linhas foram removidas na versão corrigida da base (250.221 instâncias); a versão original e o registro exato das linhas removidas são preservados no repositório de código, garantindo a rastreabilidade da correção.
3. **Duplicatas exatas:** 19.356 linhas (7,7%) repetem o par (descrição, rótulo). Isso é inócuo para a avaliação do oráculo, mas exige **deduplicação por descrição normalizada antes do particionamento** nos experimentos com treinamento (E2/E3), sob pena de vazamento entre treino e teste.

3.2.3 Pré-processamento e espaço de rótulos

O pré-processamento textual é mínimo — conversão para minúsculas e remoção de acentos — delegando ao tokenizador de subpalavras do classificador o tratamento de variações lexicais. Rótulos passam pela mesma normalização. Classes com menos de cinco instâncias são agrupadas na categoria sentinela `_rare_` (0,13% das linhas), resultando em um espaço fechado de **621 categorias** (620 classes frequentes + `_rare_`). Esse espaço fechado, denominado *CategorySchema*, é um objeto de primeira classe na implementação: é a fonte única da restrição de saída imposta aos oráculos LLM (Seção 3.7.1).

3.2.4 Particionamento

Para os experimentos com treinamento do classificador (E2/E3), o conjunto — após deduplicação — é particionado de forma estratificada em: conjunto de teste T (20%), reservado exclusivamente à avaliação final; conjunto de validação V (10%), para monitoramento do ajuste fino; e o *pool* de aprendizado ativo U_0 (70%). Para o E3, um subconjunto estratificado de aproximadamente 50 mil instâncias do *pool* é utilizado — amostragem estratificada por classe com semente fixa e registrada, preservando as proporções de U_0 —, dimensionado para viabilizar múltiplas repetições do ciclo completo com BERTimbau no hardware disponível; o orçamento de rotulagem é fixado em $B = 30\%$ de $|U_0|$. A generalização das conclusões do subconjunto para o *pool* completo é discutida nas limitações (Seção 3.9).

3.3 CLASSIFICADORES DA TAREFA

Dois classificadores θ são empregados, com papéis distintos e explícitos:

- **BERTimbau Base** (`neuralmind/bert-base-portuguese-cased`) (Souza et al., 2020): classificador principal, usado na validação do FALCO e dos métodos de referência (E2/E3). O ajuste fino usa a biblioteca `transformers` (Wolf et al., 2020) com otimizador AdamW (Loshchilov e Hutter, 2019), taxa de aprendizado 3×10^{-5} ,

lote de treinamento 32 e decaimento de peso 0,01. O número de épocas por iteração do ciclo ativo é determinado empiricamente no E2 (curvas de perda em validação para $|L| \in \{10^3, 10^4, 5 \times 10^4\}$), em vez de fixado por convenção.

- **Classificador vetorial binário (PVBin):** representação *bag-of-words* binária com uni e bigramas, protótipos de classe por concatenação de documentos e predição por similaridade de cosseno com *softmax* sobre os escores (Darú, 2024). Por seu custo de treinamento desprezível, viabiliza os estudos que exigem milhares de reexecuções: a sensibilidade de L_0 , a otimização por algoritmo genético (P1) e a varredura de estratégias do E1.

Essa separação isola a contribuição metodológica: o FALCO é validado com o classificador forte, enquanto as análises exploratórias massivas usam o classificador leve.

3.4 MÉTRICAS DE AVALIAÇÃO E ANÁLISE ESTATÍSTICA

Desempenho do classificador. A métrica primária é o **Macro F1-Score** — média aritmética dos F1 por classe, que pondera igualmente classes majoritárias e minoritárias, adequada ao forte desbalanceamento do conjunto (Sokolova e Lapalme, 2009). A **acurácia global** é reportada como métrica secundária. Ambas são calculadas no conjunto de teste T ao longo das iterações, compondo curvas de aprendizado (métrica *versus* $|L_t|$).

Eficiência da curva de aprendizado (LCE). Para comparar estratégias de aprendizado ativo por um único escalar, emprega-se a métrica LCE, proposta nesta tese e formalizada no Apêndice A:

$$\text{LCE} = \frac{\text{AUC}_{\text{real}}}{\text{AUC}_{\text{ideal}}}, \quad \text{AUC}_{\text{ideal}} = \text{Perf}_{\text{baseline}} \times (L_{\text{final}} - L_{\text{ideal},0}), \quad (3.1)$$

em que AUC_{real} é a área sob a curva de aprendizado medida, integrada numericamente pela regra de Simpson sobre os pontos observados, $\text{Perf}_{\text{baseline}}$ é o desempenho do classificador com supervisão completa e $L_{\text{ideal},0}$ é a abscissa inicial da curva ideal (o menor tamanho de conjunto rotulado observado, de modo que curvas reais e ideal integrem o mesmo intervalo). Valores próximos de 1 indicam que a estratégia se aproxima rapidamente do desempenho de referência com poucos rótulos. A LCE tem precedente direto na **ALC** (*Area under the Learning Curve*) do *Active Learning Challenge* (Guyon et al., 2011); difere dela em dois pontos: a normalização usa o desempenho de supervisão completa do próprio par (classificador, conjunto) — e não o máximo teórico da métrica — tornando o valor comparável entre classificadores de tetos distintos; e a integração usa Simpson sobre a grade observada, em vez de interpolação em escala logarítmica.

Análise estatística. Três testes acompanham as comparações, conforme a natureza dos dados: (i) toda acurácia de oráculo é reportada com **intervalo de confiança de Wilson** a 95% (Wilson, 1927), apropriado para proporções em qualquer faixa; (ii) comparações entre oráculos

que rotularam *as mesmas instâncias* usam o **teste de McNemar** (McNemar, 1947) sobre os pares discordantes (com teste binomial exato quando as discordâncias somam menos de 25); e (iii) comparações entre estratégias de aprendizado ativo executadas com múltiplas sementes usam o **teste de postos sinalizados de Wilcoxon** (Wilcoxon, 1945) sobre as métricas finais e a LCE.

3.5 PILAR P1: COMPOSIÇÃO DO CONJUNTO INICIAL L_0

O primeiro pilar responde a duas perguntas em sequência: quanto a composição do conjunto inicial importa (medição de sensibilidade) e qual o teto de desempenho que uma composição otimizada alcança (busca evolutiva). A segunda só faz sentido se a primeira acusar efeito relevante.

3.5.1 Sensibilidade à amostragem aleatória

Para quantificar o impacto da composição de L_0 , o classificador PVBin foi treinado com conjuntos iniciais amostrados aleatoriamente em **47 tamanhos** entre 10 e 200.000 instâncias, com **30 repetições independentes** por tamanho (sementes distintas), avaliando Acurácia e Macro F1 no conjunto de teste. As estatísticas descritivas completas constam do Apêndice F.

3.5.2 Otimização por algoritmo genético

Para estimar os *limites* de desempenho alcançáveis pela escolha da composição de L_0 — inatingíveis por busca exaustiva no espaço combinatório — empregou-se um algoritmo genético (Holland, 1975; Goldberg, 1989) sobre indivíduos que representam conjuntos de I índices únicos do *pool*. A configuração, idêntica em todas as execuções, foi: população $N_{pop} = 50$; 100 gerações; seleção por torneio de tamanho $k_t = 3$; cruzamento de um ponto com probabilidade $p_c = 0,8$ e reparo de unicidade; mutação com probabilidade $p_m = 0,1$ substituindo $m_s = \max(1, \lceil 0,01 \cdot I \rceil)$ genes; elitismo de 10% ($N_{elite} = 5$). Quatro cenários foram otimizados (maximização e minimização de Acurácia e de Macro F1) para dez tamanhos de L_0 entre 10 e 30.000. A função de aptidão é avaliada em uma **partição de aferição disjunta do conjunto de teste**: otimizar e reportar na mesma partição superajustaria o envelope ao conjunto de avaliação (circularidade); por isso, os indivíduos finais de cada cenário são *reavaliados* no conjunto de teste intocado, e é esse valor — tipicamente inferior ao de aptidão — que os capítulos de resultados reportam como envelope. O fluxo completo e os operadores são formalizados no Apêndice B.

3.6 PILAR P2: COLD START SEM RÓTULOS — ALGORITMO DRI-SL

O DRI-SL (*Diversidade Representativa Inicial via densidade Semântica e variedade Lexical*) constrói um L_0 de tamanho alvo I a partir de U_0 sem acesso a rótulos, combinando dois espaços de representação: (i) **densidade semântica** — as instâncias são projetadas por um codificador de sentenças (Reimers e Gurevych, 2019) e agrupadas por k -médias em N_c grupos,

com alocação de amostras proporcional ao tamanho de cada grupo; e (ii) **variedade lexical intragrupo** — dentro de cada grupo, as amostras são escolhidas iterativamente maximizando a introdução de termos relevantes ainda não cobertos (escore de novidade ponderado pelo perfil TF-IDF do grupo). A formalização, o pseudocódigo e as decisões de implementação constam do Apêndice C. O DRI-SL é a estratégia da Fase 1 do FALCO e é avaliado (P2) contra a amostragem aleatória e contra o envelope de desempenho estimado pelo algoritmo genético (P1), que atua como limite empírico de referência.

3.7 PILAR P3: LLMS COMO ORÁCULO DE ROTULAGEM (EXPERIMENTO E0)

A avaliação de oráculos exige, antes de qualquer comparação, um instrumento de medição confiável. Por isso esta seção define primeiro a instrumentação (contrato de saída, custo e proveniência), depois o desenho fatorial do E0 e, por fim, o critério pré-registrado que converte as medições em decisão de arquitetura para o FALCO.

3.7.1 Instrumentação da medição

Medir a acurácia de um LLM como rotulador exige restringir a saída ao espaço de rótulos: em experimento preliminar da própria pesquisa, um esquema de saída sem restrição produziu variações de fraseado (*e.g.*, “ovos de páscoa” quando o padrão-ouro registra “ovo de páscoa”) contabilizadas como erro, deflacionando a acurácia medida. Três modos de instrumentação são definidos — e o modo utilizado fica registrado em cada anotação:

- **enum** (modo de produção): saída estruturada com o rótulo restrito, na decodificação, ao *CategorySchema* de 621 valores, com validação estrita imposta pelo provedor (*structured outputs*);
- **json-prompt**: para provedores sem suporte a saída estruturada, a lista de categorias e o formato JSON são instruídos no *prompt*, com validação posterior exata e contabilização explícita de rótulos inválidos;
- **free**: saída estruturada *sem* restrição de rótulo — réplica controlada do instrumento defeituoso, usada exclusivamente para quantificar o efeito do instrumento (RQ4 abaixo).

O *prompt* (Apêndice E) contextualiza o domínio (cupons fiscais, abreviações), instrui a classificação do *tipo* de produto ignorando marca e embalagem, e desestimula o uso indevido da categoria sentinela `_rare_`. A parte estática do *prompt* e o esquema precedem o item variável, explorando o *cache* de prefixo dos provedores que o oferecem — com efeito direto no custo por rótulo. A rotulagem é feita **em lote** (itens numerados em uma única chamada; resposta como vetor indexado), com o tamanho do lote calibrado em etapa prévia (lotes de 1, 10 e 25 itens, pareados nas mesmas instâncias) e adotando-se o maior lote que não degrade a acurácia (teste de McNemar) — decisão registrada junto aos resultados.

3.7.2 Desenho fatorial do E0

O E0 responde a quatro perguntas: (RQ1) a acurácia e o Macro F1 de cada LLM candidato, com intervalos de confiança e comparações pareadas; (RQ2) o custo por mil rótulos e a latência; (RQ3) o perfil de erro por classe (matriz de confusão, taxa de rótulos inválidos); e (RQ4) o efeito do instrumento de medição (enum *versus* free, mesmas instâncias). Os modelos candidatos abrangem três regimes de custo: APIs comerciais (gpt-4o-mini e gpt-4o), modelos servidos por plataforma *MaaS* (DeepSeek-V4-Flash, DeepSeek-V4-Pro e GLM-5.2) e o regime de custo zero via agregador (representado pela variante *free* do Nemotron-3-Ultra; a redução de escopo deste braço, imposta pela vazão do plano gratuito, é registrada na decisão D-005 e discutida nos resultados).

Duas amostras pareadas — todos os modelos rotulam *as mesmas* instâncias — são usadas: **S-rand** ($n = 1.000$, amostragem aleatória simples), que preserva a distribuição de produção e serve a RQ1/RQ2/RQ4 — o tamanho é dimensionado pela precisão exigida da medição: com $n = 1.000$, a meia-largura do IC de Wilson é de no máximo ≈ 3 p.p. (pior caso $p = 0,5$; $\approx 2,5$ p.p. no platô observado), suficiente para separar os oráculos do limiar de 85% do gate e entre regimes de custo, com custo pareado de anotação linear no número de modelos; e **S-strat** (3 por classe, $n \approx 1.863$), que dá suporte por classe ao Macro F1 e à matriz de confusão (RQ3) — necessária porque, com 621 classes, a amostra aleatória deixa a maioria das classes sem representação; três instâncias por classe é o mínimo que distingue erro sistemático de classe (0/3, 3/3) de erro esporádico (1/3, 2/3), e valores maiores dobrariam ou triplicariam o custo pareado de *todos* os oráculos sem alterar as decisões (a sensibilidade do gabarito, Seção 3.2.2, limita o ganho de precisão adicional). A temperatura é fixada em 0 em todos os modelos.

3.7.3 Critério de decisão para o FALCO

Do E0 deriva a configuração de oráculos do FALCO: o **LLM Inicial** é o de melhor razão acurácia/custo sujeito a acurácia mínima de 85% na S-rand; o **LLM Avançado** é o de maior acurácia, *desde que* significativamente superior ao Inicial (McNemar, $\alpha = 0,05$) — caso contrário, a Fase 3 do framework é eliminada e o FALCO opera com oráculo único. Se nenhum modelo atingir o limiar, o E4 (robustez a ruído) torna-se obrigatório e a discussão da tese passa a tratar o aprendizado com oráculo ruidoso como cenário central.

3.8 PILAR P4: O FRAMEWORK FALCO E SUA AVALIAÇÃO (EXPERIMENTOS E1–E4)

O quarto pilar integra os anteriores no framework proposto. A seção descreve primeiro os componentes e a máquina de fases do FALCO — o objeto em avaliação — e, em seguida, os métodos de referência e o desenho experimental que o colocam à prova (E1–E4).

3.8.1 Componentes e fases

O FALCO opera em três fases, adaptando estratégia de seleção e oráculo ao amadurecimento do classificador:

1. **Fase 1 — *cold start* informado:** o lote inicial ($b_0 = \lceil 0,01 \cdot B \rceil$) é selecionado pelo DRI-SL (Seção 3.6) e rotulado pelo LLM Inicial, formando L_0 ;
2. **Fase 2 — seleção por incerteza com LLM Inicial:** a cada iteração, as b instâncias de maior entropia preditiva de θ (Settles, 2012) são consultadas ao LLM Inicial; a transição ocorre quando o Macro F1 no conjunto de *validação* V estagna por $p = 5$ iterações consecutivas (tolerância $\epsilon = 10^{-3}$). O conjunto de teste T jamais participa de decisões do processo — usá-lo aqui contaminaria a avaliação final (vazamento de teste);
3. **Fase 3 — refinamento com LLM Avançado:** mantida a seleção por incerteza, o oráculo passa ao LLM Avançado, concentrando o custo do modelo mais capaz nas instâncias mais difíceis. A fase existe apenas se o critério da Seção 3.7.3 a justificar.

O processo encerra ao exaurir B ou U . As constantes de projeto têm o seguinte racional, registrado como decisão de engenharia (não de otimização): $b_0 = \lceil 0,01 \cdot B \rceil$ dá à Fase 1 um custo máximo de 1% do orçamento — suficiente para o DRI-SL cobrir os agrupamentos semânticos sem comprometer o orçamento das fases guiadas; a janela de estagnação $p = 5$ com tolerância $\epsilon = 10^{-3}$ corresponde a cinco iterações sem ganho acima do ruído típico de reamostragem observado nas curvas do E1, evitando transições por flutuação; e o limiar de 85% do gate de oráculo (Seção 3.7.3) fica um desvio acima do melhor baseline supervisionado leve conhecido do conjunto de dados (acurácia de 89,56% com *todos* os rótulos (Darú, 2024)), exigindo do oráculo zero-shot qualidade próxima à do teto supervisionado antes de dispensar tratamento de ruído; a sensibilidade a essas escolhas é discutida com os resultados. O tamanho de lote b e a estratégia de incerteza da Fase 2 são fixados com base no E1, que varre as estratégias de entropia, menor confiança, menor margem, híbrida e aleatória sob oráculo simulado perfeito com o classificador PVBin — barato o suficiente para varredura ampla — e justifica a escolha por LCE.

3.8.2 Métodos de referência e desenho do E3

A validação com o classificador forte segue o próprio desenho do FALCO: quem executa o laço é o classificador leve, re-treinado a cada lote; o BERTimbau é treinado *uma única vez por braço*, sobre o conjunto que o processo coletou. Essa decisão — o classificador forte *fora do laço* — reduz o custo computacional em ordens de grandeza sem alterar o objeto medido, pois é exatamente assim que o framework opera em produção. Duas escolhas de régua completam o desenho, ambas registradas como decisão metodológica: (a) a “supervisão completa” de referência é o *pool* de 50.000 instâncias (o mesmo do E6 e do ciclo real, com semente e embaralhamento idênticos), e não a base inteira — o aprendizado ativo só enxerga o

pool, e compará-lo com um braço treinado em $5\times$ mais dados confundiria o valor da *seleção* com o valor de *ter mais dados*; **(b)** a avaliação de todos os braços ocorre na **população reservada** (≈ 177 mil instâncias fora do pool e fora dos conjuntos de validação/teste usados pelo ciclo real nas decisões de parada), com amostra estratificada fixa entre braços, acurácia com IC de Wilson e Macro F1, e predições persistidas por braço para os pareamentos de McNemar.

O experimento executado (denotado E3') compara cinco braços, cada qual um ajuste fino do BERTimbau: **(A)** os itens selecionados e anotados pelo *pipeline real* — os ciclos ponta a ponta com oráculo LLM gratuito (Apêndice G.1), cujo cache de anotações define o conjunto — com os rótulos *do oráculo*; **(B)** os mesmos itens de (A) com rótulos do gabarito — a diferença $A-B$ isola o custo do *ruído do oráculo* no modelo forte; **(C)** igual cardinalidade de itens sorteados uniformemente do pool, com gabarito — a diferença $B-C$ isola o valor da *seleção*; **(D)** o pool inteiro com gabarito — a régua; e **(E)** o prefixo de 15 mil da trajetória de entropia do E6 — mede se orçamento adicional ajudaria. O critério de aceitação da hipótese central torna-se direto: $F1(A) \geq 0,95 \cdot F1(D)$, com $|A|/|D| \approx 18\%$ dos rótulos. Os braços pareados A/B cumprem o papel do braço *oráculo-total* do desenho original — separar ruído de parcimônia — a custo de anotação zero, pois reutilizam as anotações reais já pagas. O desenho completo original (FALCO, RS e US com re-treino do BERTimbau no laço, ablações de L_0 e de progressão de oráculo, 8 sementes com Wilcoxon pareado e *bootstrap* sobre LCE) permanece pré-registrado como extensão para hardware dedicado; o E3' executa-se com semente única e estatuto descritivo, como o E6. O E4 — executado se o critério do oráculo indicar ruído relevante — repete o desenho de comparação com oráculo simulado de ruído paramétrico $\varepsilon \in \{0; 0,1; 0,2; 0,4\}$, quantificando a degradação do aprendizado em função da qualidade do oráculo.

3.9 AMEAÇAS À VALIDADE

Validade externa. Todo o programa empírico usa um único conjunto de dados, construído pelo próprio autor (Darú et al., 2022). Isso maximiza o realismo (dados de produção de 18 varejistas) e a comparabilidade com o trabalho anterior, mas limita a generalização: as conclusões valem, a rigor, para descrições curtas de produtos de varejo em português. Três mitigações são adotadas: as decisões do framework não usam nenhuma propriedade específica do conjunto além das características públicas do gênero (texto curto, desbalanceamento, abreviações); os achados de instrumentação (P3) são mecanismos do par LLM-API, não do dado; e o protocolo completo é reproduzível em qualquer conjunto rotulado com a mesma estrutura, ficando a réplica em benchmark público (*e.g.*, STOPS (Karl e Scherp, 2023)) registrada como trabalho futuro.

Validade interna. O conjunto de teste é isolado de todas as decisões do processo (particionamento com deduplicação prévia; transição de fase por V ; envelope do AG reavaliado em partição intocada). O viés distribucional que a amostragem ativa induz no conjunto rotulado (Santos, 2016) não afeta a medição, feita sempre em T fixo e aleatório.

Validade de constructo. A acurácia do oráculo é medida contra um padrão-ouro com ruído conhecido (teto $\approx 99,3\%$; análise de sensibilidade na Seção 3.2.2), e o efeito do instrumento de medição é ele próprio quantificado (RQ4). O custo por rótulo depende de preços de API vigentes na execução — os valores absolutos datam; as razões entre modelos são mais estáveis. Mais amplamente, **toda medição de oráculo LLM nesta tese é uma fotografia da tripla (modelo, provedor, data)**: temperatura zero não garante determinismo entre versões de modelo nem entre serviços de *serving* — o próprio E0 demonstra o mesmo modelo divergindo significativamente de si mesmo entre dois provedores (Seção 5.1.2) — e por isso cada anotação é arquivada com proveniência completa, permitindo re-medição futura contra a mesma referência.

3.10 REPRODUTIBILIDADE E AMBIENTE

Toda a instrumentação é implementada na biblioteca `activelearning` (Apêndice D), sob arquitetura hexagonal: o núcleo de domínio (instâncias, esquema de categorias, estratégias, métricas, políticas de fase) é puro e testado isoladamente; LLMs, classificadores e armazenamento são adaptadores intercambiáveis. Cada experimento tem um ponto de entrada único parametrizado por arquivo de configuração versionado; execuções registram sementes, revisão do código e anotações linha a linha (JSONL), e são retomáveis após interrupção. Chamadas a oráculos registram tokens, tokens em *cache*, latência e custo estimado — insumos da análise de custo do Capítulo 5. O ambiente de treinamento é uma estação com GPU NVIDIA RTX 3090 (24 GB), 64 GB de RAM e Linux; as versões das dependências são fixadas pelo gerenciador de pacotes do repositório.

Proveniência dupla dos resultados. Por razões históricas, o programa experimental distribui-se em dois repositórios versionados, e a distinção é mantida explícita em toda a tese. Os resultados *originais* dos pilares P1 e P2 (estudo de sensibilidade de L_0 , envelope do algoritmo genético e DRI-SL no *cold start*) foram produzidos no repositório `activetextclassification`; os pilares P3 e P4 (E0, E0-P, E1, E4, E5, E6 e E3') e as *reexecuções* de verificação de P1/P2 foram produzidos na biblioteca `activelearning`, reescrita sob a arquitetura acima. Onde a tese reporta um número originado no repositório legado, o porte para a biblioteca nova foi verificado — por igualdade de matrizes de escore (PVBIn), por reexecução independente com protocolo mais rigoroso (sensibilidade de L_0 , divergência $\leq 0,7$ p.p.) ou por conferência direta contra o artefato de origem (DRI-SL); o registro dessa auditoria acompanha o código.

4 RESULTADOS: COMPOSIÇÃO E CONSTRUÇÃO DO CONJUNTO INICIAL

Este capítulo apresenta os resultados dos pilares P1 e P2: a sensibilidade da generalização à composição do conjunto inicial L_0 (Seção 4.1), os limites estimados por otimização evolutiva (Seção 4.2) e a avaliação do DRI-SL como estratégia de *cold start* (Seção 4.3). Todos os experimentos usam o classificador leve PVBin (Capítulo 3); os resultados originais foram obtidos no programa experimental da pesquisa e, como verificação de robustez, o estudo de sensibilidade e o mecanismo do AG foram **reexecutados de forma independente** na biblioteca *activelearning*, com protocolo mais rigoroso (deduplicação antes do particionamento e reavaliação em teste intocado); as duas séries são apresentadas lado a lado (Seção 4.4).

4.1 SENSIBILIDADE À COMPOSIÇÃO E AO TAMANHO DE L_0

O experimento avaliou 47 tamanhos de L_0 (10 a 200.000), com 30 repetições aleatórias por tamanho, medindo Acurácia Global e Macro F1 no conjunto de teste T . As estatísticas completas constam do Apêndice F; a Figura 4.1 resume a tendência.




Figura 4.1: Tendência da performance média (Acurácia e Macro F1) e intervalo mín-máx por tamanho de L_0 no teste T , escala logarítmica. Classificador PVBin.

Três padrões estruturam a leitura:

1. **Crescimento com saturação:** a acurácia média sobe de 6,7% ($I = 10$) para 24,7% ($I = 100$), 55,9% ($I = 1.000$), 76,9% ($I = 10.000$) e satura em torno de 89,1% ($I = 200.000$); o Macro F1 acompanha com atraso (0,4% $\rightarrow$ 3,4% $\rightarrow$ 17,8% $\rightarrow$ 43,3% $\rightarrow$ 70,4%), refletindo o custo de cobrir classes minoritárias.

2. **Variabilidade decrescente:** o desvio-padrão da acurácia cai de 0,024 ($I = 10$) para menos de 0,001 ($I = 200.000$); para $I = 100$, a acurácia entre repetições variou de 21,7% a 28,1% — uma amplitude de 6,4 pontos percentuais causada exclusivamente pela composição do sorteio. É a evidência direta da hipótese de variabilidade: *existem* L_0 bons e ruins de mesmo tamanho.
3. **Cobertura de classes como mecanismo:** em $I = 10$ o L_0 típico cobre 9 das 621 classes; em $I = 1.000$, cerca de 255; a curva de Macro F1 segue de perto a curva de cobertura, indicando que, no regime pequeno, o fator dominante é *quais classes* entram no sorteio.

Esses resultados fundamentam o P2: se a composição importa tanto no regime pequeno — exatamente o regime do *cold start* do aprendizado ativo —, então construir L_0 deliberadamente (em vez de sorteá-lo) é a alavanca disponível antes de existir qualquer rótulo.

4.2 LIMITES POR OTIMIZAÇÃO EVOLUTIVA

Para estimar o quanto a composição pode render além do sorteio, um algoritmo genético (Seção 3.5.2) otimizou a composição de L_0 em quatro cenários (maximização e minimização de Acurácia e Macro F1) para dez tamanhos. A Tabela 4.1 resume a evolução do melhor (pior) indivíduo entre a 1ª e a 100ª geração nos cenários de acurácia.

Tabela 4.1: Evolução do AG (1ª vs. 100ª geração) — cenários de Acurácia. Envelope entre minimização e maximização.

$ L_0 $	Maximização			Minimização		
	1ª	100ª	Δ	1ª	100ª	Δ
10	13,06%	18,82%	+5,76	—	—	—
50	22,12%	33,83%	+11,71	16,17%	7,13%	−9,04
100	26,65%	36,71%	+10,06	22,17%	10,86%	−11,31
500	48,55%	56,00%	+7,46	45,23%	36,17%	−9,06
1.000	57,76%	62,20%	+4,44	55,76%	49,33%	−6,43
5.000	73,48%	74,13%	+0,64	72,00%	70,82%	−1,18
20.000	82,10%	83,23%	+1,13	81,58%	79,55%	−2,03
30.000	85,07%	85,88%	+0,81	84,39%	83,03%	−1,36

Duas leituras: o envelope é **largo no regime pequeno** (em $I = 100$, a distância entre pior e melhor indivíduo da última geração chega a 25,9 pontos percentuais de acurácia) e **estreita com o tamanho** — coerente com a Seção 4.1: quanto maior o L_0 , menos a composição importa. O ganho evolutivo sobre a 1ª geração (coluna Δ) confirma que o AG explora estrutura real, não flutuação.

4.3 DRI-SL VERSUS ALEATÓRIO E ENVELOPE DO AG

A Tabela 4.2 compara o DRI-SL (heurística determinística sem rótulos, Seção 3.6) com o envelope do AG.

Tabela 4.2: *Cold start*: DRI-SL vs. envelope do AG (última geração), até $|L_0| = 5.000$. Classificador PVBin.

$ L_0 $	DRI-SL		AG (melhor)		AG (pior)	
	Acc	Macro F1	Acc	Macro F1	Acc	Macro F1
100	41,23%	6,85%	38,76%	6,51%	5,75%	1,81%
500	59,22%	18,45%	56,00%	18,01%	36,17%	6,52%
1.000	67,39%	25,83%	62,20%	24,69%	49,33%	12,60%
2.500	73,36%	36,53%	69,28%	32,58%	63,92%	24,11%
5.000	76,87%	44,09%	74,13%	40,07%	70,82%	31,87%

O resultado central do P2: **o DRI-SL supera não só a amostragem aleatória média, mas o próprio melhor indivíduo encontrado pelo AG** em todos os tamanhos de 100 a 5.000 (ex.: $I = 1.000$: 67,4% vs. 62,2% de acurácia). Uma heurística construtiva de custo linear e sem acesso a rótulos supera um otimizador evolutivo com 5.000 avaliações supervisionadas — forte indício de que densidade semântica + variedade lexical capturam exatamente a estrutura que torna um L_0 informativo. Há uma ressalva metodológica: os valores do AG aqui reportados herdam o protocolo original (aptidão e relato na mesma partição), inflacionado por construção — a quantificação está na seção seguinte, e reforça a conclusão.

4.4 REEXECUÇÃO INDEPENDENTE E EFEITO DA CIRCULARIDADE

A reexecução na biblioteca *activelearning* usa grade reduzida de 15 tamanhos $\times$ 10 repetições (artefatos em `experiments/pl/results/`): os 15 tamanhos são log-espaçados cobrindo todo o intervalo original (10 a 2×10^5) — a forma da curva, e não a sua densidade, é o objeto da validação — e 10 repetições estimam a média com erro-padrão inferior à divergência que se pretende detectar (a amplitude entre repetições do original), a um nono do custo computacional das 47×30 células originais. A reexecução reproduz a estrutura completa do estudo original com protocolo mais rigoroso — deduplicação por texto normalizado *antes* do particionamento e teste fixo de 20.000 instâncias.

Tabela 4.3: Estudo de sensibilidade: original (30 rep.) vs. reexecução independente (10 rep., protocolo com deduplicação). Acurácia média.

$ L_0 $	Original	Reexecução	Diferença
10	6,7%	6,6%	-0,1
100	24,7%	24,0%	-0,7
1.000	55,9%	55,5%	-0,4
10.000	76,9%	76,4%	-0,5
100.000	87,1%	86,7%	-0,4
200.000	89,1%	88,8%	-0,3

A concordância (diferença $\leq 0,7$ p.p. em todos os tamanhos, sempre no sentido esperado — o protocolo com deduplicação é ligeiramente mais difícil) valida de forma independente

tanto o estudo original quanto o porte do classificador para a biblioteca nova, cuja fidelidade foi adicionalmente verificada por igualdade exata das matrizes de escore entre implementações.

A reexecução do AG usou 2 tamanhos $\times$ 2 cenários com $N_{pop} = 30$ e 40 gerações — a menor configuração que reproduz o *mecanismo* (a aptidão estabiliza bem antes da 40ª geração em todas as células), pois o objetivo aqui é validar o fenômeno e quantificar a circularidade, não re-estimar o envelope completo, que permanece o do estudo original — e aplicou o protocolo anticircularidade da Seção 3.5.2: aptidão medida em partição de aferição, indivíduo final *reavaliado* no teste intocado. O mecanismo se reproduz (melhor indivíduo evolui +5,2 p.p. de acurácia em $I = 50$; envelope acima da média aleatória em todos os casos), mas a reavaliação honesta revela a inflação da circularidade: para maximização de Macro F1 com $I = 500$, a aptidão final é 19,4%, mas o mesmo indivíduo mede 13,1% no teste intocado — 6,3 pontos percentuais de superajuste ao conjunto de aferição. Para acurácia a inflação é menor (≈ 1 p.p.). Conclusão metodológica incorporada à tese: **envelopes evolutivos devem ser reportados exclusivamente em partição não usada como aptidão**; os valores de AG das Tabelas 4.1 e 4.2 devem ser lidos como limites otimistas, e a superioridade do DRI-SL sobre eles é, portanto, conservadora.

4.5 SÍNTESE DO CAPÍTULO

(i) A composição de L_0 tem efeito grande e mensurável no regime pequeno (amplitude de 6,4 p.p. em $I = 100$ só por sorteio), decaindo com o tamanho; (ii) o envelope evolutivo confirma espaço explorável de dezenas de pontos percentuais entre composições boas e ruins; (iii) o DRI-SL captura esse espaço sem usar rótulos, superando o melhor indivíduo do AG até $I = 5.000$ — e é por isso a estratégia da Fase 1 do FALCO; (iv) a reexecução independente reproduz os três achados e quantifica o viés de circularidade do protocolo original de AG, corrigido nesta tese.

5 RESULTADOS: ORÁCULOS LLM E O FRAMEWORK FALCO

Este capítulo apresenta os resultados do pilar P3 — a avaliação instrumentada de LLMs como oráculos de rotulagem (E0, Seção 5.1), a ablação de prompt no modelo de menor custo (E0-P, Seção 5.2) — e o pilar P4: a varredura de estratégias com oráculo simulado (E1, Seção 5.3), a robustez do aprendizado a ruído controlado de oráculo (E4, Seção 5.4), os seletores em escala populacional (E6, Seção 5.5) e a validação com o classificador forte fora do laço (E3', Seção 5.6), que responde a hipótese central. Todos os números reportados são rastreáveis a artefatos versionados no repositório `activelearning` (`experiments/e0`, `e0p`, `e1e4`, `e6population`, `e2e3`).

5.1 E0: AVALIAÇÃO FATORIAL DE ORÁCULOS LLM

5.1.1 RQ1 — assertividade

A Tabela 5.1 apresenta acurácia (com IC de Wilson a 95%), Macro F1 e taxa de rótulos inválidos dos oráculos avaliados nas duas amostras pareadas oficiais (S-rand $n = 1.000$; S-strat $n = 1.863$), com temperatura 0 e rotulagem em lote calibrada.

Tabela 5.1: E0 — desempenho dos oráculos LLM. Modo enum para OpenAI; json-prompt para MaaS, agregador e NVIDIA NIM (sem suporte a saída estruturada). IC = intervalo de Wilson 95%.

Oráculo	Amostra	Acurácia	IC 95%	Macro F1	Inválidos
deepseek-v4-pro	S-rand	82,1%	[79,6; 84,4]	0,785	0,1%
gpt-4o	S-rand	80,9%	[78,4; 83,2]	0,788	0,0%
deepseek-v4-flash	S-rand	78,3%	[75,6; 80,8]	0,750	0,7%
nemotron-3-ultra (grátis)	S-rand	77,9%	[75,2; 80,4]	0,752	1,2%
glm-5.2	S-rand	77,3%	[74,6; 79,8]	0,742	0,0%
gpt-4o-mini	S-rand	61,3%	[58,2; 64,3]	0,518	0,0%
deepseek-v4-pro	S-strat	82,6%	[80,8; 84,2]	0,793	0,0%
gpt-4o	S-strat	82,1%	[80,3; 83,8]	0,797	0,0%
deepseek-v4-flash	S-strat	81,6%	[79,7; 83,3]	0,781	0,9%
glm-5.2	S-strat	80,9%	[79,1; 82,6]	0,782	0,0%
nemotron-3-ultra (grátis)	S-strat	79,6%	[77,7; 81,4]	0,770	2,6%
gpt-4o-mini	S-strat	45,7%	[43,4; 48,0]	0,427	0,0%

Quatro leituras principais. **(i)** Os quatro melhores oráculos formam um platô entre 77% e 83% nas duas amostras — as diferenças internas ao platô são pequenas; o teste pareado (RQ1, McNemar) na S-strat mostra deepseek-v4-pro significativamente superior ao v4-flash ($b = 43$, $c = 16$, $p < 0,001$) e estatisticamente empatado com o gpt-4o ($p = 0,061$). **(ii)** O gpt-4o-mini colapsa na amostra estratificada (45,7%): o modelo pequeno erra sistematicamente nas classes raras, que a S-strat expõe por construção. **(iii)** Nenhum oráculo atinge o limiar de 85% do gate (Seção 3.7.3) na S-rand — o melhor zero-shot fica a ≈ 7 p.p. do teto supervisionado

com 250 mil rótulos (89,6%, Darú, 2024). A consequência de desenho está na Seção 5.7. **(iv)** Em compensação, o Macro F1 zero-shot dos oráculos do platô ($\approx 0,78$ – $0,80$ na S-strat) *supera* o Macro F1 do PVBin treinado com supervisão completa (0,70): o conhecimento de mundo do LLM compensa exatamente onde o supervisionado leve sofre — classes com pouquíssimos exemplos.

5.1.2 RQ2 — custo e o efeito do *cache*

Tabela 5.2: E0 — custo por mil rótulos (US\$) e taxa de acerto de *cache* de prefixo (S-rand; preços vigentes na execução, jul/2026).

Oráculo	US\$/1k rótulos	Cache	Acurácia
nemotron-3-ultra (grátis)	0,000	—	77,9%
deepseek-v4-flash	0,035	—	78,3%
gpt-4o-mini	0,051	91%	61,3%
glm-5.2	0,249	—	77,3%
deepseek-v4-pro	0,410	—	82,1%
gpt-4o	0,923	88%	80,9%

O intervalo de custo entre oráculos do mesmo platô de acurácia é de mais de uma ordem de grandeza: o deepseek-v4-flash entrega 78–82% por US\$ 0,035/1k — **26 vezes mais barato** que o gpt-4o (80–82%). O *cache* de prefixo (prefixo estático do *prompt* + schema precedendo o item variável, Seção 3.7.1) atinge 88–95% de acerto nos provedores que o suportam, reduzindo pela metade o custo efetivo do tokens de entrada. Para referência externa, o custo fica duas a três ordens de grandeza abaixo do custo típico de anotação humana por item relatado na literatura (Gilardi et al., 2023). Custo, porém, não é a única restrição operacional: os limites de vazão dos provedores (3 requisições/min no MaaS, 18/min no plano gratuito do OpenRouter, nos artefatos de latência do E0) moldaram o próprio desenho experimental e, em produção, definem o tempo de parede de um ciclo de rotulagem tanto quanto o preço — um oráculo barato e lento pode ser dominado por um caro e paralelo quando o gargalo é o prazo.

O **regime de custo monetário zero** confirmou-se competitivo: o nemotron-3-ultra servido pela API de avaliação da NVIDIA empata estatisticamente com o deepseek-v4-flash na S-rand (McNemar, $p = 0,76$) e com o glm-5.2 na S-strat ($p = 0,078$), ficando abaixo apenas do v4-pro ($p < 0,001$). Duas ressalvas operacionais, ambas achados: (i) grátis não é custo operacional zero — a primeira tentativa, via agregador com cota de 50 requisições/dia, projetava seis dias de execução (decisões D-005/D-006); e (ii) *o provedor de serving é parte do instrumento*: o MESMO modelo servido pelo agregador diverge significativamente de si mesmo servido pela NVIDIA nas mesmas instâncias ($p < 0,001$ no subconjunto pareado de 850 itens) — medições de oráculo LLM devem registrar não só o modelo, mas quem o serve e como.

5.1.3 RQ3 — perfil de erro

A anatomia dos 324 erros do melhor oráculo (v4-pro, S-strat) revela estrutura, não ruído difuso: **31%** são confusões entre *categorias-irmãs* que compartilham palavra (*antiséptico bucal* → *enxaguante bucal*; *ervilha* → *ervilha em conserva*); **17%** têm como gabarito uma classe guarda-chuva *outro* . . . (o modelo escolhe a específica; o catálogo arquiva na agregadora) e 7% o inverso; $\approx 2\%$ envolvem `_rare_` ou rótulo inválido; o restante são erros semânticos genuínos. Ou seja: quase metade do erro do oráculo não é ignorância sobre o produto, e sim desconhecimento das *convenções deste catálogo* — fronteiras entre classes vizinhas e política de agregação que só se aprendem com exemplos rotulados. Esse diagnóstico tem duas consequências: motiva a ablação de prompt do E0-P (regras de fronteira explícitas) e prevê que o ruído do oráculo é *estruturado* (concentrado em pares vizinhos), cenário menos danoso ao classificador treinado que ruído uniforme (Frénay e Verleysen, 2014; Song et al., 2023) — hipótese testada no E4.

5.1.4 RQ4 — efeito do instrumento de medição

Com o mesmo modelo (gpt-4o-mini), as mesmas 1.000 instâncias da S-rand e o mesmo *prompt*, a troca do instrumento — saída estruturada com `enum` *versus* saída livre (réplica do instrumento do legado) — produz: acurácia 61,3% (`enum`) contra 60,5% (`free`), mas taxa de rótulos inválidos de **0,0% contra 6,8%**. O efeito do instrumento aparece menos na acurácia pontual e mais na *contabilidade do erro*: sem restrição de saída, quase 7% das respostas são variações de fraseado fora do espaço de rótulos, que um protocolo ingênuo computa como erro do modelo — deflacionando a medição e contaminando qualquer comparação entre modelos com propensões diferentes a parafrasear. A restrição por `enum` com validação estrita elimina essa classe de artefato por construção, e é por isso o modo de produção do FALCO (Princípio III da constituição do projeto).

5.1.5 Sensibilidade ao ruído do gabarito e calibração do lote

Duas verificações de instrumentação completam o E0. **Gabarito**: reavaliando todos os oráculos (a) sem as instâncias de rótulo conflitante e (b) sob pontuação *multi-gold*, a acurácia varia no máximo +0,7 p.p., sem alterar nenhum ordenamento — o ruído conhecido do gabarito limita o teto de medição ($\approx 99,3\%$), mas não contamina as comparações (Seção 3.2.2). **Lote**: na calibração pareada (lotes de 1, 10 e 25 itens nas mesmas instâncias), o McNemar não detecta degradação ($b = 1$ vs. $b = 10$: $p = 0,58$), e o lote reduz o custo por rótulo em até 10 vezes ao amortizar o prefixo — adotou-se $b = 10$ (OpenAI) e $b = 25$ (MaaS), registrado por anotação. O ganho é consistente com o precedente de anotação em lote em laços de AL com LLM (Kholodna et al., 2024), que reporta o mesmo mecanismo de amortização de *prompt* como componente central da economia frente à anotação humana.

5.2 E0-P: O PROMPT COMO VARIÁVEL DO INSTRUMENTO

A anatomia de erros (RQ3) indica que $\approx 48\%$ dos erros do oráculo são de convenção de catálogo — atacáveis por *prompt*. O E0-P mede esse potencial no modelo de MENOR custo com cache (gpt-4o-mini): variantes **v4a** (dez regras de fronteira explícitas derivadas do perfil de erro da S-strat) e **v4b** (v4a + dez exemplos *inventados* de fronteiras difíceis — nunca instâncias das amostras, desenho anti-vazamento D-004), pareadas com o v3 oficial nos mesmos 500 primeiros itens de cada amostra — subconjunto-prefixo (aleatório por construção, pois as amostras já são embaralhadas) dimensionado para detectar, via McNemar, deslocamentos da ordem de 4–5 p.p. com o volume de discordâncias esperado (≈ 60 –80 pares), a um quinto do custo da amostra completa por variante. A Tabela 5.3 resume o resultado (artefato: `experiments/e0p/results/analysis.json`).

Tabela 5.3: E0-P — ablação de *prompt* no gpt-4o-mini (enum, $b = 10$, $n = 500$ pareado por amostra). p : McNemar exato contra o v3.

Amostra	Variante	Acurácia	Discordantes (+/–)	p vs. v3
S-rand	v3 (base)	60,4%	—	—
S-rand	v4a (regras)	64,2%	50/31	0,045
S-rand	v4b (regras+ex.)	65,0%	50/27	0,012
S-strat	v3 (base)	51,8%	—	—
S-strat	v4a (regras)	44,8%	20/55	$< 0,001$
S-strat	v4b (regras+ex.)	41,0%	14/68	$< 0,001$

O resultado é uma faca de dois gumes — e por isso mesmo informativo. Na S-rand, que espelha a distribuição de produção, as regras de fronteira recuperam parte do erro de convenção: +3,8 p.p. com v4a ($p = 0,045$) e +4,6 p.p. com v4b ($p = 0,012$), confirmando que uma fração do déficit do modelo fraco é atacável por *prompt* sem nenhum rótulo adicional. Na S-strat, porém, as mesmas regras *destroem* desempenho: $-7,0$ e $-10,8$ p.p. ($p < 0,001$), com os exemplos inventados piorando significativamente sobre as regras puras ($p = 0,0013$). A leitura é direta: regras derivadas do perfil de erro agregado empurram o modelo para as convenções das classes *frequentes*, exatamente o comportamento que penaliza a amostra estratificada, dominada por classes raras. Duas implicações para o FALCO: (i) otimização de *prompt* deve ser validada nas *duas* distribuições antes de adoção, pois um ganho medido só na amostra natural pode mascarar regressão severa nas caudas; e (ii) o ganho barato na distribuição de produção existe e justifica a direção de trabalho futuro de gerar regras automaticamente a partir da matriz de confusão (Seção 6.5) — desde que com salvaguarda estratificada.

5.3 E1: ESTRATÉGIAS DE SELEÇÃO COM ORÁCULO PERFEITO

O E1 varre as cinco estratégias de seleção (entropia, menor confiança, menor margem, híbrida, aleatória) com o PVBin e oráculo simulado sem ruído, em pool deduplicado de 20.000

instâncias, orçamento de 3.000 rótulos, lote 100 e 8 sementes por célula; a ablação de lote repete a entropia — a estratégia pré-registrada da Fase 2 do FALCO e do E4 — com $b \in \{50, 200\}$. O dimensionamento é deliberado: 20.000 é o maior pool que mantém as 104 células (5 estratégias + ablações + E4, $\times 8$ sementes) computáveis em CPU preservando representação de todas as classes; o orçamento de 3.000 (15% do pool) cobre exatamente o regime de poucos rótulos em que as estratégias diferem — para além dele as curvas convergem e a comparação perde poder; o lote 100 é o valor operacional do FALCO, e a própria ablação testa sua vizinhança; e 8 sementes é o mínimo que permite $p < 0,05$ no Wilcoxon pareado (Seção 3.8.2). O teto supervisionado do *pool* completo (20.000 rótulos) é Macro F1 = 0,540. A Tabela 5.4 apresenta as células (artefato: `experiments/ele4/results/analysis.json`).

Tabela 5.4: E1 — estratégias com oráculo perfeito (média $\pm$ dp sobre 8 sementes; orçamento 3.000, lote 100). p : Wilcoxon pareado por semente contra a aleatória; com $n = 8$, o menor p atingível é 0,0078.

Estratégia	LCE	Macro F1 final	p vs. aleatória
Menor margem	0,528 $\pm$ 0,013	0,418 $\pm$ 0,013	0,0078
Menor confiança	0,518 $\pm$ 0,010	0,421 $\pm$ 0,009	0,0078
Entropia	0,493 $\pm$ 0,006	0,398 $\pm$ 0,008	0,0078
Híbrida	0,476 $\pm$ 0,014	0,379 $\pm$ 0,008	0,0078
Aleatória	0,444 $\pm$ 0,011	0,339 $\pm$ 0,006	—

Três leituras. **(i) Toda estratégia de incerteza supera a aleatória**, e o faz no máximo de significância que 8 sementes permitem ($p = 0,0078$ em LCE e em F1 final, todas as comparações): com 15% do orçamento de rótulos, a melhor célula recupera 78% do Macro F1 do teto supervisionado. **(ii) As margens vencem a entropia** no regime de 621 classes: menor margem lidera em LCE (0,528) e menor confiança em F1 final (0,421), enquanto a entropia — diluída pela cauda longa de probabilidades em espaços de classe muito grandes — fica $\approx 2\text{--}3$ p.p. atrás; a híbrida herda o pior dos dois mundos. **(iii) O lote é barato até certo ponto**: na ablação com entropia, $b = 50$ (LCE 0,492 $\pm$ 0,009) e $b = 100$ (0,493 $\pm$ 0,006) são indistinguíveis, mas $b = 200$ degrada para 0,481 $\pm$ 0,012 — com lotes grandes a seleção repete redundância dentro do próprio lote antes de o modelo se atualizar. Para o FALCO, isso fixa o lote operacional em $b \leq 100$ e recomenda menor margem/menor confiança como estratégias da Fase 2 — com a ressalva explícita de que o ordenamento foi medido com o classificador leve e deve ser revalidado com BERTimbau no E3: probabilidades mais calibradas do *transformer* podem reordenar entropia e margens.

5.4 E4: ROBUSTEZ DO APRENDIZADO AO RUÍDO DO ORÁCULO

O E4 injeta ruído uniforme $\varepsilon \in \{0,1; 0,2; 0,4\}$ no oráculo simulado e repete o desenho do E1 para entropia e aleatória — a pergunta é quanto do valor do aprendizado ativo sobrevive quando o oráculo erra na taxa observada nos LLMs reais ($\varepsilon \approx 0,17\text{--}0,23$ no platô do E0). Os três níveis são escolhidos para *cercar* essa faixa: 0,1 abaixo dela (oráculo melhor que os disponíveis),

0,2 dentro dela (cenário central) e 0,4 como teste de estresse — o dobro do erro real, região do gpt-4o-mini na S-strat. A Tabela 5.5 apresenta o resultado (mesmo artefato do E1).

Tabela 5.5: E4 — robustez ao ruído uniforme do oráculo (média $\pm$ dp, 8 sementes). Retenção: fração do Macro F1 final da mesma estratégia em $\varepsilon = 0$. p : Wilcoxon pareado entropia vs. aleatória no mesmo ε .

ε	Estratégia	Macro F1 final	Retenção	p
0,1	Entropia	0,347 $\pm$ 0,008	87,2%	0,0078
	Aleatória	0,294 $\pm$ 0,006	86,7%	
0,2	Entropia	0,294 $\pm$ 0,006	74,0%	0,0078
	Aleatória	0,252 $\pm$ 0,006	74,4%	
0,4	Entropia	0,215 $\pm$ 0,010	54,1%	0,0078
	Aleatória	0,186 $\pm$ 0,006	54,8%	

Dois achados. **Primeiro, o ruído custa caro, mas não destrói o aprendizado ativo:** a vantagem da entropia sobre a aleatória sobrevive *intacta e no teto de significância* em todos os níveis de ruído ($p = 0,0078$ em LCE e F1 final para todo ε), e a retenção relativa das duas estratégias é praticamente idêntica (87%, 74% e 54% em $\varepsilon = 0,1, 0,2$ e $0,4$) — ou seja, o ruído uniforme deprime a curva inteira sem corroer o *valor da seleção*. Não há, neste regime, o colapso descrito na literatura em que a incerteza persegue os rótulos errados. **Segundo, a taxa de erro dos oráculos reais está na faixa tolerável:** os LLMs do E0 erram $\varepsilon \approx 0,17\text{--}0,23$ no espaço fechado, região em que o E4 mede retenção de $\approx 74\text{--}87\%$ do F1 final. E o E4 é deliberadamente pessimista: injeta ruído *uniforme*, enquanto a anatomia do RQ3 mostrou que quase metade do erro real dos oráculos é estruturado (categorias-irmãs e guarda-chuva semanticamente próximas), cujo dano esperado ao classificador é menor que o do erro aleatório de mesma taxa (Frénay e Verleysen, 2014; Song et al., 2023). Registre-se a nuance: essa leitura não é unânime — em reconhecimento de entidades, ruído *real* de anotação mostrou-se mais nocivo que corrupção artificial de mesma taxa (Merdjanovska et al., 2024); a extrapolação aqui é condicionada à anatomia específica medida no RQ3 (confusões semanticamente adjacentes e parcialmente defensáveis), não a uma superioridade geral do ruído estruturado. Sob essa condição, o resultado positivo do E4 é um limite inferior do desempenho esperável com os oráculos reais do E0; e a extensão natural do desenho é a correção colaborativa de rótulos ruidosos com apoio de LLM (Yuan et al., 2025).

5.5 E6: SELETORES EM ESCALA POPULACIONAL E O VIÉS DA AUTOAVALIAÇÃO

O E6 estende a comparação de seletores para a escala completa da base e introduz um instrumento novo, proposto durante a pesquisa: a distinção entre avaliação *interna* e *externa*. A base deduplicada é dividida em um *pool* rotulável de 50.000 instâncias (oráculo perfeito, isto é, o próprio gabarito) e uma **população reservada** com todo o restante (≈ 140 mil instâncias), jamais tocada pela seleção. A cada lote de 500, o conjunto rotulado acumulado sofre uma divisão

convencional 80/20 e o modelo treinado é medido em dois lugares: no *teste interno* (os 20% do que o processo rotulou — o que um praticante sem conjunto reservado conseguiria medir) e na *população* (o desempenho real de implantação). Cinco seletores são comparados com PVBin e SGD logístico: entropia, aleatório, DRI-SL como política contínua, a variante **DRI-SL-C** — em que, após o *cold start*, os grupos do DRI-SL deixam de vir de *k*-means e passam a ser as *classes previstas pelo próprio classificador*, mantidas a alocação proporcional e a novidade lexical intra-grupo — e um braço de **ablação** da própria DRI-SL-C, que remove o termo de novidade lexical e equivale, portanto, a *amostragem estratificada pelas classes previstas*. A ablação isola a origem do ganho da variante: agrupamento por predição ou seleção lexical dentro dos grupos. Execução com semente única e orçamento até o *pool* completo (artefatos em `experiments/e6population`); por ser braço único por célula, os números da Tabela 5.6 são descritivos. Os dois braços centrais (entropia e aleatório, ambos classificadores) foram, contudo, reexecutados em **oito sementes** que variam o sorteio inicial, os desempates e a divisão interna mantendo o *pool* fixo, permitindo inferência sobre a comparação principal (artefato `analysis_multiseed.json`). A robustez confirma o quadro: a saturação da entropia no SGD é $9,1k \pm 0,6k$ rótulos (faixa 8,5–10k) contra $15,5k \pm 1,1k$ do aleatório, e o teto da entropia supera o do aleatório em **8 das 8 sementes** (Wilcoxon pareado, $p = 0,0078$ — a significância máxima alcançável com oito pares); no PVBin a vantagem de teto é pequena e não significativa (6/8), mas a saturação ($19,3k \pm 0,7k$) permanece menos da metade da do aleatório ($40,6k \pm 1,4k$). O viés de autoavaliação da acurácia é igualmente estável: em $|L| = 10k$ o teste interno subestima a população em $17,1 \pm 1,0$ p.p. entre as sementes. O valor de saturação de 8.000 reportado na Tabela 5.6 (semente original) situa-se na borda otimista da faixa multi-semente, sem alterar nenhuma conclusão.

Tabela 5.6: E6 — Macro F1 na população por seletor e classificador. Saturação: menor $|L|$ que atinge 95% do teto do próprio braço.

Classif.	Seletor	Teto F1	Saturação	F1@10k	F1@20k
SGD	Entropia	0,591	8.000	0,565	0,574
SGD	Estratif. por predição	0,555	10.000	0,533	0,543
SGD	DRI-SL-C	0,491	15.500	0,412	0,486
SGD	Aleatório	0,459	16.500	0,391	0,449
SGD	DRI-SL	0,441	41.500	0,310	0,365
PVBin	Entropia	0,529	19.000	0,438	0,509
PVBin	Estratif. por predição	0,528	18.000	0,444	0,498
PVBin	DRI-SL-C	0,525	39.500	0,349	0,453
PVBin	Aleatório	0,530	40.000	0,348	0,423
PVBin	DRI-SL	0,527	45.500	0,284	0,356

Cinco achados (Tabela 5.6). (i) **A entropia domina em escala**: satura a 95% do teto com 8.000 rótulos no SGD (19.000 no PVBin), metade ou um quarto do que a seleção aleatória exige — confirmando o E1 fora do regime de orçamento pequeno. (ii) **Rotular tudo pode piorar**: no SGD, o Macro F1 populacional atinge 0,59 com ≈ 15 mil rótulos selecionados por

entropia e *cai* para 0,44 quando o *pool* inteiro é rotulado — a amostra ativa é mais balanceada por classe que a distribuição natural, que domina o treino do modelo de perda logística quando tudo entra; o PVBIn, que constrói um protótipo por classe, é imune. Para o custo de rotulagem, a implicação é forte: além do desperdício, o rótulo adicional pode ser *nocivo* à métrica macro.

(iii) O DRI-SL contínuo se corrige quando guiado pelo classificador: a variante DRI-SL-C eleva o teto do SGD de 0,441 para 0,491, adianta a saturação em $2,7\times$ (de 41.500 para 15.500) e supera o aleatório em toda a região útil — enquanto o DRI-SL clássico, cego ao classificador, fica abaixo do aleatório como política contínua.

(iv) A ablação atribui o ganho ao agrupamento, não à novidade lexical: o braço estratificado por predição — DRI-SL-C *sem* o termo de novidade — supera a DRI-SL-C completa nos dois classificadores (SGD: teto 0,555 e saturação em 10.000 contra 0,491 e 15.500; PVBIn: saturação em 18.000 contra 39.500, empatando com a entropia) e em toda a região média da curva. A seleção lexical intra-grupo, valiosa na partida a frio sem nenhum rótulo (P2), é *contraproducente* no regime contínuo: privilegia exemplares lexicalmente atípicos quando o que a métrica macro paga é cobertura balanceada de classes. A leitura consolidada da tese passa a ser: DRI-SL para o *cold start* (Fase 1, onde venceu o envelope evolutivo); na Fase 2, entropia como padrão, tendo a estratificação pelas classes previstas — política trivial de implementar — como alternativa representativa que captura quase todo o ganho.

(v) A autoavaliação em dados coletados ativamente é enviesada — com sinal dependente da métrica: no braço aleatório (controle), acurácia interna e externa coincidem ($\Delta \approx 0$), validando o instrumento; na entropia, a acurácia interna *subestima* a real em até 14 p.p. (o teste interno herda os casos difíceis); e o Macro F1 interno *superestima* o populacional em todos os seletores (até +34 p.p. no DRI-SL no início da curva), porque a amostra ativa sobre-representa classes raras. Nenhuma das duas direções é utilizável como estimativa de implantação — a justificativa empírica direta para o conjunto de validação reservado que o FALCO exige e para o critério de liberação do Apêndice G.2.

5.6 E3': O CLASSIFICADOR FORTE JULGA O PIPELINE E A HIPÓTESE CENTRAL

O E3' (desenho na Seção 3.8.2) treina o BERTimbau uma vez por braço, sobre conjuntos já coletados, e avalia todos os braços na população reservada ($n = 20.092$, amostra estratificada fixa, excluídos *pool* e os conjuntos de decisão do ciclo real). Configuração uniforme entre braços: 3 épocas, lote 16, comprimento máximo de 32 *tokens*, semente única — números descritivos, comparações amparadas pelos IC de Wilson e pelo pareamento na mesma amostra de avaliação. A Tabela 5.7 consolida.

O veredito da hipótese central é negativo na configuração executada: $F1(A) = 0,242 < 0,95 \cdot F1(D) = 0,428$, com 17,9% dos rótulos do *pool*. O valor do resultado está na decomposição, que o desenho pareado permite:

(i) O ruído do oráculo não é o gargalo. Nos mesmos 8.937 itens, os rótulos do oráculo custam 4,4 p.p. de acurácia frente ao gabarito (A vs. B, ICs disjuntos) — coerente com a

Tabela 5.7: E3' — BERTimbau treinado por braço e avaliado na população reservada. IC = Wilson 95%.

Braço	Conjunto de treino	<i>n</i>	Acurácia [IC]	Macro F1
A	pipeline real, rótulos do oráculo	8.937	65,9% [65,2; 66,5]	0,242
B	mesmos itens, gabarito	8.937	70,2% [69,6; 70,9]	0,209
C	aleatório, gabarito	8.937	73,2% [72,6; 73,8]	0,189
E	15k por entropia (E6), gabarito	15.000	83,1% [82,6; 83,7]	0,380
D	<i>pool</i> inteiro, gabarito (régua)	50.000	88,3% [87,9; 88,8]	0,451

concordância oráculo–gabarito de 71,6% nesses itens, selecionados por incerteza e portanto mais difíceis que a média. Em Macro F1, porém, A *supera* B (0,242 vs. 0,209): o erro estruturado do oráculo espalha rótulos por mais classes (635 vs. 620) e atua como regularizador involuntário das caudas — corroborando, agora no classificador forte, a previsão do E4 de que ruído estruturado é o regime benigno.

(ii) **A seleção ativa compra cobertura, não acurácia.** Com o mesmo orçamento e gabarito, o braço aleatório vence em acurácia (C vs. B: +3,0 p.p.) mas perde em Macro F1 (0,189 vs. 0,209) e em cobertura (493 vs. 620 classes presentes no treino) — o mesmo padrão do E6, reproduzido no transformer.

(iii) **O fator dominante é orçamento, e o critério de parada do laço leve subserve o modelo forte.** O braço E — 15 mil rótulos perfeitos selecionados por entropia, o dobro do ponto em que o ciclo real parou — salta para 83,1% de acurácia (94,1% da régua, a 0,75 p.p. do critério de 95%) e 0,380 de Macro F1 (84,3% da régua). A estagnação da validação do classificador *leve* (que encerrou o ciclo real em 4,7–6 mil rótulos) é, portanto, um *proxy* inadequado para o ponto de parada do classificador *forte* em métrica macro: o BERTimbau segue convertendo rótulos em cobertura de cauda muito além do ponto em que o PVBIn/SGD saturam. Como o braço B usa gabarito (oráculo perfeito), essa conclusão independe da qualidade do oráculo — nenhum oráculo sustentaria o critério sob a política de parada executada.

Em síntese: a hipótese, como pré-registrada, é **refutada para a configuração executada** (oráculo gratuito + parada por estagnação do classificador leve + 3 épocas), *quase* se sustenta em acurácia com orçamento de 30% (94,1% da régua) e não se sustenta em Macro F1 — com o diagnóstico apontando a correção de desenho (parar pelo *proxy* do modelo forte, ou por piso de orçamento) como a extensão prioritária. O resultado negativo é o que o pré-registro existe para proteger: o critério foi fixado antes, o instrumento decompõe a perda em suas fontes, e a resposta é acionável.

5.6.1 Varredura de orçamento: o piso que sustenta a hipótese

Para localizar o orçamento em que a hipótese passa a valer, o BERTimbau foi treinado sobre prefixos crescentes da mesma trajetória de entropia (20, 25, 30 e 35 mil rótulos com gabarito), avaliados na população reservada (Tabela 5.8).

Tabela 5.8: E3' — varredura de orçamento. Critério 0,95× régua (D): acurácia $\geq 83,9\%$, Macro F1 $\geq 0,428$. ✓ atende.

Braço	Rótulos	% <i>pool</i>	Acurácia	Macro F1	Critério
A (pipeline real)	8.937	18%	65,9%	0,242	acc ✗ F1 ✗
E	15.000	30%	83,1%	0,380	acc ✗ F1 ✗
E20	20.000	40%	85,9%	0,418	acc ✓ F1 ✗
E25	25.000	50%	87,3%	0,434	acc ✓ F1 ✓
E30	30.000	60%	87,7%	0,456	acc ✓ F1 ✓
E35	35.000	70%	88,6%	0,463	acc ✓ F1 ✓
D (régua)	50.000	100%	88,3%	0,451	—

Três leituras fecham o pilar. **(i) A hipótese é alcançável.** O critério em *acurácia* passa a valer em 20 mil rótulos (40% do *pool*) e o critério em *Macro F1* — a métrica da hipótese — em 25 mil (50%); o orçamento pré-registrado de $\leq 30\%$ era, portanto, apertado demais para o objetivo macro do classificador forte, mas o piso correto é modesto e conhecido. **(ii) Confirma-se o diagnóstico:** o gargalo era a política de parada, não o oráculo nem a seleção — bastou gastar mais da mesma seleção por entropia (com gabarito) para cruzar o critério, e a distância era pequena. **(iii) Menos é mais, também no transformer:** o braço E35 (35 mil rótulos ativamente selecionados) *supera a régua de supervisão completa do pool* tanto em acurácia (88,6% vs. 88,3%) quanto em Macro F1 (0,463 vs. 0,451) — os 15 mil rótulos finais, sorteados da distribuição natural, não só são dispensáveis como *degradam* o modelo forte, reproduzindo no BERTimbau o efeito medido no E6 com os classificadores leves. A conclusão consolidada: com uma política de parada ancorada no modelo forte (ou um piso de orçamento de $\approx 50\%$ do *pool*), o FALCO sustenta a hipótese central; a versão executada apenas parou cedo demais.

5.7 DECISÃO DO GATE E CONFIGURAÇÃO DO FALCO

Aplicando o critério pré-registrado da Seção 3.7.3 aos resultados do E0: nenhum oráculo atinge acurácia $\geq 85\%$ na S-rand; portanto, (i) o **E4 torna-se obrigatório** — executado nesta tese com o classificador leve (Seção 5.4) e pronto para reexecução com BERTimbau —, e (ii) a discussão passa a tratar o aprendizado com oráculo ruidoso como cenário central, não excepcional. Para a configuração de oráculos do FALCO derivada do E0: **LLM Inicial** = deepseek-v4-flash (melhor razão acurácia/custo: 78–82% a US\$ 0,035/1k); **LLM Avançado** = deepseek-v4-pro (maior acurácia; significativamente superior ao flash na S-strat, $p < 0,001$ — o critério de superioridade significativa é atendido e a Fase 3 do FALCO se justifica). O gpt-4o não se qualifica em nenhum papel: empata com o v4-pro em acurácia e custa o dobro; o gpt-4o-mini é eliminado ($p \approx 0$ contra todos na S-strat). O nemotron-3-ultra gratuito é a *alternativa de custo zero* para o papel de LLM Inicial — empata com o flash na S-rand ($p = 0,76$) — condicionada a um provedor de *serving* com vazão e termos de produção; o flash permanece a escolha padrão pela confiabilidade operacional.

6 DISCUSSÃO E CONCLUSÃO

6.1 SÍNTESE DOS ACHADOS

Esta tese perguntou como reduzir o custo de rotulagem na classificação de textos curtos em português sem perda relevante de desempenho, usando modelos de linguagem nas fases em que o aprendizado ativo tradicional é mais frágil. Os quatro pilares produziram um quadro coerente:

P1 — a composição do conjunto inicial importa, e importa mais quanto menor o orçamento. A sensibilidade medida (47 tamanhos $\times$ 30 repetições, reproduzida de forma independente com divergência $\leq 0,7$ p.p.) mostra amplitude de 6,4 p.p. de acurácia em $|L_0| = 100$ causada só pelo sorteio, decaindo até a irrelevância em $|L_0| \geq 10^5$. O envelope evolutivo confirma dezenas de pontos percentuais entre composições boas e ruins no regime pequeno — o regime do *cold start*.

P2 — é possível capturar esse espaço sem nenhum rótulo. O DRI-SL, heurística determinística de densidade semântica + variedade lexical, superou o *melhor indivíduo* encontrado pelo algoritmo genético supervisionado em todos os tamanhos de 100 a 5.000 — e a reexecução com protocolo anticircularidade mostrou que essa comparação é conservadora, pois o envelope do AG estava inflacionado em até 6,3 p.p. pela avaliação na própria partição de aptidão.

P3 — oráculos LLM são viáveis, baratos e erram de forma estruturada. No espaço fechado de 621 categorias, os melhores oráculos zero-shot atingem 77–83% de acurácia (v4-pro: 82,6% na S-strat) — a ≈ 7 p.p. do teto supervisionado com 250 mil rótulos — a custos entre US\$ 0,035 e US\$ 0,92 por mil rótulos, ordens de grandeza abaixo da anotação humana (Gilardi et al., 2023). O Macro F1 zero-shot ($\approx 0,79$) supera o do baseline supervisionado leve (0,70): o LLM é *melhor nas classes raras* e pior nas convenções do catálogo — quase metade dos seus erros são fronteiras entre categorias-irmãs e política de classes guarda-chuva, aprendíveis apenas com exemplos. O efeito do instrumento de medição (RQ4) confirmou-se: sem restrição de saída, 6,8% das respostas viram falsos erros de fraseado.

P4 — respondido, com veredito negativo e diagnóstico. O gate pré-registrado decidiu: sem oráculo $\geq 85\%$, o aprendizado com oráculo ruidoso é o cenário central (E4), e a configuração derivada do FALCO é deepseek-v4-flash (Inicial) + deepseek-v4-pro (Avançado, superioridade significativa comprovada). A validação com o classificador forte fora do laço (E3') julgou o pipeline completo: a hipótese central *não* se sustenta na configuração executada ($F1 = 0,242$ contra critério de 0,428 com 17,9% dos rótulos), e a decomposição pareada atribui a perda ao *orçamento* — não ao ruído do oráculo (que em Macro F1 até ajuda as caudas) nem à seleção (que compra cobertura): a parada por estagnação do classificador leve encerra o laço muito antes do ponto em que o BERTimbau para de converter rótulos em cobertura de cauda. A varredura de orçamento confirma-o e quantifica a correção: a hipótese **passa a valer** com 20 mil rótulos

(40% do *pool*) em acurácia e 25 mil (50%) em Macro F1, e com 35 mil rótulos selecionados por entropia o modelo forte *supera* a supervisão completa do *pool* em ambas as métricas — o mesmo “menos é mais” do E6, agora no transformer. A hipótese central, portanto, não é infirmada: ela requer um orçamento de $\approx 50\%$ do *pool* e uma política de parada ancorada no modelo forte, ambos identificados e medidos.

6.2 DISCUSSÃO

O que muda quando o oráculo é um LLM. A literatura clássica de AL minimiza *contagem de rótulos* assumindo oráculo correto (Settles, 2012; Olsson, 2009); a com custos reais mostra que contagem não é custo (Settles et al., 2008). Com oráculo LLM, a moeda muda duas vezes: o custo vira função de tokens (e do *cache*, e do lote — a instrumentação desta tese mede os três) e a qualidade vira parâmetro escolhível num cardápio com uma ordem de grandeza de variação de preço. A decisão “qual oráculo em qual fase” — o coração do FALCO — só faz sentido nesse regime novo, e os dados do E0 mostram que ela não é trivial: o modelo mais caro (gpt-4o) não é o mais acurado, e o segundo mais barato entrega 96% da acurácia do melhor por 8,5% do custo.

Erro estruturado é menos grave que erro uniforme — e é o que temos. O perfil de erro do RQ3 (confusões concentradas em pares vizinhos e classes guarda-chuva) é o cenário benigno da literatura de rótulos ruidosos (Frénay e Verleysen, 2014; Natarajan et al., 2013; Song et al., 2023): parte do “erro” do oráculo é inclusive defensável semanticamente (a análise multi-gold mostrou que o gabarito também erra). Isso sugere que o E4 com ruído *uniforme* — o desenho adotado — é um teste *mais duro* que a realidade, o que fortalece qualquer resultado positivo obtido nele.

Mais rótulo não é sempre melhor — e a autoavaliação engana. O E6 acrescenta dois avisos operacionais ao quadro: treinar com o subconjunto ativamente selecionado pode superar o treino com *todos* os rótulos em métrica macro (a amostra ativa é mais balanceada que a distribuição natural), e a avaliação feita sobre os próprios dados coletados é enviesada em direções opostas conforme a métrica — subestima a acurácia, superestima o Macro F1. Ambos reforçam o mesmo princípio de desenho do FALCO: parar cedo pelo critério de estagnação e medir sempre em conjunto reservado.

A medição é parte do método. Três achados desta tese são sobre instrumentos, não sobre modelos: o efeito do enum (RQ4), a inflação de circularidade no envelope evolutivo (−6,3 p.p. ao reavaliar em teste intocado) e o teto imposto pelo ruído do gabarito (limitado a +0,7 p.p. nas comparações). Em conjunto, eles justificam a posição metodológica central do trabalho: nenhum número sem artefato rastreável, e nenhum instrumento sem quantificação do seu próprio erro.

6.3 CONTRIBUIÇÕES

(i) O framework FALCO — fases com oráculo LLM progressivo e *cold start* informado — com implementação aberta, testada e reproduzível; (ii) o algoritmo DRI-SL — e a evidência de que supera o envelope evolutivo supervisionado no regime de interesse — acompanhado da análise honesta do seu limite: no regime contínuo, a ablação da variante guiada pelo classificador (DRI-SL-C) mostrou que o ganho vem do agrupamento pelas classes previstas, não da novidade lexical, apontando a estratificação por predição como política representativa de referência; (iii) a avaliação instrumentada de oráculos LLM para português com 621 classes — granularidade muito acima da usual na literatura de LLM-como-anotador, cujos estudos zero-shot recentes de classificação de produtos operam com dezenas a ≈ 250 categorias (Roumeliotis et al., 2025), chegando a 370 folhas nos testes de robustez com catálogos públicos (Gholamian et al., 2024) — incluindo custo real com *cache* e lote; (iv) a métrica LCE (com posicionamento explícito frente à ALC); (v) o conjunto de dados público auditado, com censo de conflitos e análise de sensibilidade; e (vi) a biblioteca *activelearning* e o FlowBuilder (ingestão com saneamento, execução parametrizada e curvas), que tornam o protocolo reutilizável fora desta tese.

6.4 LIMITAÇÕES

As ameaças à validade estão detalhadas na Seção 3.9; as principais: um único conjunto de dados, criado pelo autor (mitigado por protocolo replicável e achados de mecanismo); o E3' executado em configuração uniforme mas econômica (3 épocas, contexto de 32 *tokens*, semente única, CPU) — a régua absoluta do BERTimbau pode subir com mais épocas e contexto, o que tornaria o critério *mais* exigente, não menos, preservando o sentido do veredito; custos de API datados (as *razões* entre modelos são mais estáveis que os valores); e regras de fronteira do E0-P derivadas do perfil de erro do próprio domínio — generalizam o método, não as regras.

6.5 TRABALHOS FUTUROS

A extensão prioritária, já parcialmente executada na varredura de orçamento (Seção 5.6.1), é consolidar a política de parada ancorada no modelo forte: substituir a estagnação do classificador leve por ajustes finos periódicos do BERTimbau em pontos de verificação da trajetória, ou por um piso de orçamento de $\approx 50\%$ do *pool* (o ponto medido em que o Macro F1 cruza o critério), e formalizar a regra de liberação daí decorrente. Demais direções: (i) composição de oráculos — comparar a progressão sequencial do FALCO com *mixture-of-LLMs* paralelo (Qi et al., 2026) e com roteamento por confiança (Rouzegar e Makrehchi, 2024), idealmente formulando a escolha de oráculo por fase como problema de *bandit* com custo (Blum e Mansour, 2007; Baykal et al., 2021); (ii) *prompt* como componente otimizável — o E0-P abre a porta; as extensões naturais são gerar regras de fronteira automaticamente a partir da matriz de confusão de uma rodada anterior e permitir que o oráculo emita *rótulos*

candidatos quando incerto, destilados pelo classificador leve (Xia et al., 2025a) — o que também endereça os 2–4% de respostas inválidas observadas; a contração prévia do espaço de classes por top- K do classificador de domínio (Cheng et al., 2024) é o desenho complementar para as 621 categorias; **(iii)** usar os racionais do oráculo (*expanded_description*) como atributo auxiliar do classificador (Sharma et al., 2015); **(iv)** réplica em benchmark público de produtos (STOPS, Karl e Scherp, 2023; e **AlleNoise**, 500 mil títulos em 5.692 categorias com ruído *real* de marketplace, Rączkowska et al., 2024 — o teste externo ideal para o E4) e extensão a taxonomias hierárquicas (Sun et al., 2003; Tan et al., 2020); e **(v)** o ciclo de vida pós-treinamento — o critério de parada do laço (estagnação em validação) já está implementado e formalizado, mas a decisão de *liberação* do modelo e o monitoramento de *drift* em produção merecem tratamento próprio: o oráculo LLM barato da Fase Inicial vira instrumento de auditoria contínua (verificação amostral periódica a custo desprezível), e sinais sem rótulo (taxa de vocabulário novo, deriva da confiança predita) antecipam o gatilho de retreino — desenho detalhado na documentação operacional da biblioteca.

6.6 CONCLUSÃO

No estado atual da evidência: o custo de rotulagem em classificação de textos curtos em português pode ser atacado nas três frentes que o FALCO integra — começar bem (DRI-SL supera até o envelope evolutivo), perguntar bem (estratégias de incerteza sobre classificador barato) e pagar bem (oráculos LLM com 78–83% de acurácia por centavos de dólar o milhar, com erro majoritariamente estruturado). A hipótese quantitativa central — $\geq 95\%$ do Macro F1 de supervisão completa com $\leq 30\%$ dos rótulos via oráculo LLM — foi submetida ao teste pré-registrado (E3’): **refutada no orçamento de 30% originalmente fixado, mas sustentada a partir de 50% do *pool***, com o diagnóstico identificando a causa — não o ruído do oráculo nem a seleção, e sim o critério de parada herdado do classificador leve, que subestima o apetite do classificador forte por cobertura de cauda. A varredura de orçamento mediu os pisos (40% dos rótulos para a acurácia, 50% para o Macro F1) e revelou que 70% dos rótulos ativamente selecionados *superam* a supervisão completa do *pool* — rotular tudo é contraproducente. Uma tese que termina com um número honesto, uma causa identificada e o piso corrigido medido vale mais que uma que termina com uma promessa: os resultados dos experimentos executados (E0, E0-P, E1, E4, E5, E6, E3’ e os replays de P1/P2) delimitam com precisão as condições em que a hipótese se sustenta.

REFERÊNCIAS

- Abe, N. e Mamitsuka, H. (1998). Query learning strategies using boosting and bagging. Em Shavlik, J. W., editor, *Proceedings of the Fifteenth International Conference on Machine Learning (ICML '98)*, páginas 1–9. Morgan Kaufmann.
- Aggarwal, C. C. e Zhai, C. (2012). A survey of text classification algorithms. Em Aggarwal, C. C. e Zhai, C., editores, *Mining Text Data*, páginas 163–222. Springer.
- Ahmed, M. H., Tiun, S. e Omar, N. (2023). Topic modelling for short texts: A survey. *Information*, 14(4):215.
- Ahmed, M. H., Tiun, S., Omar, N. e Sani, N. S. (2022). Short text clustering algorithms, application and challenges: A survey. *Applied Sciences*, 13(1):342.
- Aliero, A. A., Adebayo, B. S., Aliyu, H. O., Tafida, A. G., Kangiwa, B. U. e Dankolo, N. M. (2023). Systematic review on text normalization techniques and its approach to non-standard words. *International Journal of Computer Applications*, 185(33):1–10.
- Alsmadi, I. e Gan, K. H. (2019a). Review of short-text classification. *International Journal of Web Information Systems*, 15(2):155–182.
- Alsmadi, I. e Gan, K. H. (2019b). Review of short-text classification. *International Journal of Web Information Systems*, 15(2):155–182.
- Angluin, D. (1988). Queries and concept learning. Em *Machine Learning*, volume 2, páginas 319–342.
- Attenberg, J. e Provost, F. (2010). Why label when you can search?: Alternatives to active learning for applying human resources to build classification models under extreme class imbalance. *Proceedings of the 16th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, páginas 423–432.
- Baeza-Yates, R. e Ribeiro-Neto, B. (2013). *Recuperação de Informação: conceitos e tecnologia das máquinas de busca*. Bookman Editora, Porto Alegre, 2 edition.
- Barros, R. C., Garcia, L. e Cavalcanti, G. (2014). Aprendizado supervisionado com conjuntos de dados desbalanceados. *Revista de Sistemas de Informação da FSMA*, 13:4–19.
- Baum, E. B. e Lang, K. (1992). Query learning can work poorly when a human oracle is used. Em *Proceedings of the IEEE International Joint Conference on Neural Networks*, páginas 1386–1391.

- Bayer, M. e Reuter, C. (2024). Activellm: Large language model-based active learning for textual few-shot scenarios. arXiv preprint arXiv:2405.10808.
- Bayer, M. e Reuter, C. (2026). ActiveLLM: large language model-based active learning for textual few-shot scenarios. *Transactions of the Association for Computational Linguistics*.
- Baykal, C., Liebenwein, L., Gal, O., Feldman, D. e Rus, D. (2021). Low-regret active learning.
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer, New York, NY.
- Blum, A. e Mansour, Y. (2007). Learning, regret minimization, and equilibria. Em Nisan, N., Roughgarden, T., Tardos, É. e Vazirani, V. V., editores, *Algorithmic Game Theory*. Cambridge University Press.
- Blum, A. e Mitchell, T. (1998). Combining labeled and unlabeled data with co-training. Em *Proceedings of the Eleventh Annual Conference on Computational Learning Theory (COLT '98)*, páginas 92–100. ACM.
- Bojanowski, P., Grave, E., Joulin, A. e Mikolov, T. (2017). Enriching word vectors with subword information. Em *Transactions of the Association for Computational Linguistics*, volume 5, páginas 135–146.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.
- Brown, L. D., Cai, T. T. e DasGupta, A. (2001). Interval estimation for a binomial proportion. *Statistical Science*, 16(2):101–133.
- Chapelle, O., Schölkopf, B. e Zien, A., editores (2006). *Semi-Supervised Learning*. The MIT Press, Cambridge, MA.
- Cheng, Z., Zhang, W., Chou, C.-C., Jau, Y.-Y., Pathak, A., Gao, P. e Batur, U. (2024). E-commerce product categorization with LLM-based dual-expert classification paradigm. Em *Proceedings of the 1st Workshop on Customizable NLP (CustomNLP4U), EMNLP 2024*.
- Cohn, D., Atlas, L. e Ladner, R. (1994). Improving generalization with active learning. *Machine learning*, 15(2):201–221.
- Cohn, D. A., Ghahramani, Z. e Jordan, M. I. (1996). Active learning with statistical models. *Journal of Artificial Intelligence Research*, 4:129–145.
- Cortes, C. e Vapnik, V. N. (1995). Support-vector networks. *Machine Learning*, 20(3):273–297.
- Cover, T. e Hart, P. (1967). Nearest neighbor pattern classification. *IEEE transactions on information theory*, 13(1):21–27.

- Dagan, I. e Engelson, S. (1995). Committee-based sampling for training probabilistic classifiers. Em *12th International Conference on Machine Learning*, páginas 150–157.
- Darú, G. H. (2022). Classificação produtos varejo CPG PTBR. Conjunto de dados. Disponível em: <https://www.kaggle.com/datasets/gilsileydaru/classificacao-produtos-varejo-cpg-prbr>.
- Darú, G. H. (2024). Categorização de produtos em e-commerce: avaliação do método argmax para classificação de descrições curtas em português. Dissertação de Mestrado, Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos.
- Darú, G. H., Motta, F. D. d., Castelo, A. e Loch, G. V. (2022). Short text classification applied to item description: Some methods evaluation. *Semina: Ciências Exatas e Tecnológicas*, 43(2):189–198.
- Dasgupta, S. e Hsu, D. (2008). Hierarchical sampling for active learning. Em *Proceedings of the 25th International Conference on Machine Learning (ICML '08)*, páginas 208–215. ACM.
- Demšar, J. (2006). Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, 7:1–30.
- Deng, Z., Yang, Y. e Suzuki, K. (2023). Federated active learning framework for efficient annotation strategy in skin-lesion classification. *arXiv preprint arXiv:2303.09753*.
- Devlin, J., Chang, M.-W., Lee, K. e Toutanova, K. (2019a). Bert: Pre-training of deep bidirectional transformers for language understanding. Em *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, volume 1, páginas 4171–4186.
- Devlin, J., Chang, M.-W., Lee, K. e Toutanova, K. (2019b). Bert: Pre-training of deep bidirectional transformers for language understanding. Em *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, volume 1, páginas 4171–4186.
- Diao, S., Wang, P., Lin, Y. e Zhang, Y. (2023). Active prompting with chain-of-thought for large language models. *arXiv preprint arXiv:2302.12246*.
- Dietterich, T. G. (1998). Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation*, 10(7):1895–1923.
- Dietterich, T. G. (2000). Ensemble methods in machine learning. *Multiple Classifier Systems*, 1857:1–15.

- Donmez, P., Carbonell, J. G. e Schneider, J. (2009). Efficiently learning the accuracy of labeling sources for selective sampling. Em *Proceedings of the 15th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, páginas 259–268. ACM.
- Duda, R. O., Hart, P. E. e Stork, D. G. (2001). *Pattern Classification*. Wiley-Interscience, New York, NY, 2nd edition.
- Efron, B. e Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall/CRC.
- Ein-Dor, L., Halfon, A., Gera, A., Shnarch, E., Dankin, L. E., Choshen, L., Danilevsky, M., Aharonov, R., Katz, Y. e Slonim, N. (2020). Active learning for bert: An empirical study. Em *EMNLP 2020*, páginas 7949–7962.
- Forman, G. e Scholz, M. (2010). Apples-to-apples in cross-validation studies: pitfalls in classifier performance measurement. *ACM SIGKDD explorations newsletter*, 12(1):49–57.
- Frénay, B. e Verleysen, M. (2014). Classification in the presence of label noise: A survey. *IEEE Transactions on Neural Networks and Learning Systems*, 25(5):845–869.
- Freund, Y., Seung, H. S., Shamir, E. e Tishby, N. (1997). Selective sampling using the query by committee algorithm. *Machine Learning*, 28(2-3):133–168.
- Fromme, L., Mirylenka, K., Kuhn, J. e Bogojeska, J. (2022). Investigating active learning sampling strategies for extreme multi label text classification. Em *Proceedings of the 13th Conference on Language Resources and Evaluation (LREC 2022)*, páginas 4597–4605, Marseille, France. European Language Resources Association.
- Gal, Y., Islam, R. e Ghahramani, Z. (2017). Deep bayesian active learning with image data. Em Precup, D. e Teh, Y. W., editores, *Proceedings of the 34th International Conference on Machine Learning (ICML)*, volume 70 de *Proceedings of Machine Learning Research*, páginas 1183–1192. PMLR.
- Gholamian, S., Romani, G., Rudnikowicz, B. e Skylaki, S. (2024). LLM-based robust product classification in commerce and compliance. Em *Proceedings of the 1st Workshop on Customizable NLP (CustomNLP4U), EMNLP 2024*.
- Gilardi, F., Alizadeh, M. e Kubli, M. (2023). Chatgpt outperforms crowd workers for text-annotation tasks. *Proceedings of the National Academy of Sciences*, 120(30):e2305016120.
- Goldberg, D. E. (1989). *Genetic Algorithms in Search, Optimization, and Machine Learning*. Addison-Wesley.
- Goldberg, Y. (2017). Neural network methods for natural language processing. *Synthesis Lectures on Human Language Technologies*, 10(1):1–309.

- Golovin, D. e Krause, A. (2011). Adaptive submodularity: Theory and applications in active learning and stochastic optimization. *Journal of Artificial Intelligence Research*, 42:427–486.
- Goodfellow, I., Bengio, Y. e Courville, A. (2016). *Deep Learning*. The MIT Press, Cambridge, MA.
- Goudjil, M., Koudil, M., Bedda, M. e Ghoggali, N. (2018). A novel active learning method using SVM for text classification. *International Journal of Automation and Computing*, 15(3):290–298.
- Grandini, M., Bagli, E. e Visani, G. (2020). Metrics for multi-class classification: an overview. *arXiv preprint arXiv:2008.05756*.
- Grießhaber, D., Maucher, J. e Vu, N. T. (2020). Fine-tuning bert for low-resource natural language understanding via active learning. Em *COLING 2020*, páginas 1158–1171.
- Guestrin, C., Krause, A. e Singh, A. P. (2005). Near-optimal sensor placements in gaussian processes. Em *Proceedings of the 22nd International Conference on Machine Learning (ICML '05)*, páginas 265–272. ACM.
- Guo, J., Chen, C. L. P., Li, S. e Zhang, T. (2025). DEUCE: Dual-diversity enhancement and uncertainty-awareness for cold-start active learning. *Transactions of the Association for Computational Linguistics*, 12:1736–1754.
- Guyon, I., Cawley, G., Dror, G. e Lemaire, V. (2011). Results of the active learning challenge. Em *JMLR Workshop and Conference Proceedings (AISTATS 2011 Workshop)*, volume 16, páginas 19–45.
- Han, J., Kamber, M. e Pei, J. (2012). *Data Mining: Concepts and Techniques*. Morgan Kaufmann Publishers Inc., San Francisco, CA, USA, 3rd edition.
- Hanneke, S. (2015). Theory of disagreement-based active learning. *Foundations and Trends in Machine Learning*, 7(2–3):131–309.
- Hoi, S. C. H., Jin, R. e Lyu, M. R. (2006). Large-scale text categorization by batch mode active learning. Em *15th International Conference on World Wide Web*, páginas 633–642.
- Holland, J. H. (1975). *Adaptation in Natural and Artificial Systems*. University of Michigan Press.
- James, G., Witten, D., Hastie, T. e Tibshirani, R. (2013). *An introduction to statistical learning*, volume 112. Springer.
- Karl, F. e Scherp, A. (2023). Transformers are short-text classifiers: A study of inductive short text classifiers on benchmarks and real-world datasets. *Lecture Notes in Computer Science*, 14065:103–122.

- Kholodna, N., Julka, S., Khodadadi, M., Gumus, M. N. e Granitzer, M. (2024). LLMs in the loop: Leveraging large language model annotations for active learning in low-resource languages.
- Kitchenham, B. (2004). Procedures for performing systematic reviews. Relatório Técnico TR/SE-0401, Keele University and NICTA, Keele, UK.
- Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI)*, 2:1137–1143.
- Kowsari, K., Jafari Meimandi, K., Heidarysafa, M., Mendu, S., Barnes, L. e Brown, D. (2019). Text classification algorithms: A survey. *Information*, 10(4):150.
- Krause, A. e Golovin, D. (2014). Submodular function maximization. Em Nowozin, S., Poupart, P., Kohli, P. e Tu, Z., editores, *Tracts in Machine Learning*, volume 5. Cambridge University Press. Chapter in "Modern Convex Optimization and Its Applications".
- Lewis, D. D. e Catlett, J. (1994). Heterogeneous uncertainty sampling for supervised learning. Em Cohen, W. W. e Hirsh, H., editores, *Machine Learning: Proceedings of the Eleventh International Conference (ICML 1994)*, páginas 148–156. Morgan Kaufmann.
- Lewis, D. D. e Gale, W. A. (1994). A sequential algorithm for training text classifiers. *Proceedings of the 17th ACM SIGIR Conference*, páginas 3–12.
- Li, Q., Peng, H., Li, J., Xia, C., Yang, R., Sun, L., Yu, P. S. e He, L. (2020). A survey on text classification: From shallow to deep learning. *arXiv preprint arXiv:2008.00364*.
- Loshchilov, I. e Hutter, F. (2019). Decoupled weight decay regularization. Em *International Conference on Learning Representations (ICLR)*.
- Machado, J. d. F. U. e Veloso, B. (2026). Turning web data into official statistics: Classifying Portuguese retail products with NLP models. *Statistical Journal of the IAOS*, 42(1).
- MacKay, D. J. C. (1992). Information-based objective functions for active data selection. *Neural Computation*, 4(4):590–604.
- Margatina, K., Vernikos, G., Mou, L. e Gunel, B. (2023). Active learning strategies for large language models: A survey. *arXiv preprint arXiv:2303.13561*.
- McCallum, A. K. e Nigam, K. (1998). Employing em in pool-based active learning for text classification. Em Shavlik, J. W., editor, *Proceedings of the Fifteenth International Conference on Machine Learning (ICML '98)*, páginas 350–358. Morgan Kaufmann.
- McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2):153–157.

- Melville, P. e Mooney, R. J. (2004). Diverse ensembles for active learning. Em *Proceedings of the 21st International Conference on Machine learning (ICML '04)*, página 74. ACM.
- Merdjanovska, E., Aynedinov, A. e Akbik, A. (2024). NoiseBench: Benchmarking the impact of real label noise on named entity recognition. Em *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing (EMNLP)*.
- Mikolov, T., Chen, K., Corrado, G. e Dean, J. (2013). Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781*.
- Mitchell, T. M. (1982). Generalization as search. *Artificial Intelligence*, 18(2):203–226.
- Mitchell, T. M. (1997). *Machine Learning*. McGraw Hill, Burr Ridge, IL.
- Murphy, K. P. (2012). *Machine Learning: A Probabilistic Perspective*. The MIT Press, Cambridge, MA.
- Muslea, I., Minton, S. e Knoblock, C. A. (2000). Selective sampling with redundant views. Em *Proceedings of the Seventeenth National Conference on Artificial Intelligence (AAAI'00)*, páginas 621–626.
- Naseem, U., Razzak, I., Khan, S. K. e Prasad, M. (2021a). A comprehensive survey on word representation models: From classical to state-of-the-art word representation language models. *ACM Transactions on Asian and Low-Resource Language Information Processing*, 20(5):1–35.
- Naseem, U., Razzak, I., Khushi, M., Eklund, P. W. e Kim, J. (2021b). A survey on text preprocessing techniques and their impact on text classification. *ACM Computing Surveys (CSUR)*, 54(8):1–39.
- Natarajan, N., Dhillon, I. S., Ravikumar, P. e Tewari, A. (2013). Learning with noisy labels. Em *Advances in Neural Information Processing Systems 26 (NIPS)*, páginas 1196–1204.
- Nguyen, H. T. e Smeulders, A. W. M. (2004). Active learning using pre-clustering. Em *Proceedings of the 21st International Conference on Machine learning (ICML '04)*, página 79. ACM.
- Nti, I. K., Nyarko-Boateng, O. e Aning, J. (2021). Performance of Machine Learning Algorithms with Different K Values in K-fold Cross-Validation. *International Journal of Information Technology and Computer Science*, 13(6):61–71.
- Olsson, F. (2009). A literature survey of active machine learning in the context of natural language processing. Relatório Técnico T2009:06, Swedish Institute of Computer Science, Kista.
- Pennington, J., Socher, R. e Manning, C. D. (2014). Glove: Global vectors for word representation. *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing*, 14:1532–1543.

- Peters, M. E., Neumann, M., Iyyer, M., Gardner, M., Clark, C., Lee, K. e Zettlemoyer, L. (2018). Deep contextualized word representations. Em *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, páginas 2227–2237.
- Prechelt, L. (2012). Early stopping – but when? Em Montavon, G., Orr, G. B. e Müller, K.-R., editores, *Neural Networks: Tricks of the Trade*, volume 7700 de *Lecture Notes in Computer Science*, páginas 53–67. Springer, second edition.
- Qi, Y., Yang, X., Lu, J., Guo, G., Enticott, J., Liu, G. e Du, L. (2026). Next generation active learning: Mixture of LLMs in the loop.
- Quinlan, J. R. (1993). *C4.5: Programs for Machine Learning*. Morgan Kaufmann Publishers Inc., San Francisco, CA, USA.
- Rączkowska, A., Osowska-Kurczab, A., Szczerbiński, J., Jasinska-Kobus, K. e Nazarko, K. (2024). AlleNoise: large-scale text classification benchmark dataset with real-world label noise.
- Radford, A., Narasimhan, K., Salimans, T. e Sutskever, I. (2018). Improving language understanding by generative pre-training. Relatório técnico, OpenAI.
- Radford, A., Wu, J., Child, R., Luan, D., Amodei, D. e Sutskever, I. (2019). Language models are unsupervised multitask learners. *OpenAI blog*, 1(8):9.
- Reimers, N. e Gurevych, I. (2019). Sentence-BERT: sentence embeddings using Siamese BERT-networks. Em *Proceedings of EMNLP-IJCNLP*, páginas 3982–3992.
- Ren, P., Xiao, Y., Chang, X., Huang, P., Li, Z., Chen, X. e Wang, X. (2021). A survey of deep active learning. *ACM Computing Surveys*, 54(9):1–40.
- Reusens, M., Stevens, A., Tonglet, J. e De Smedt, J. (2024). Evaluating text classification: A benchmark study. *Expert Systems with Applications*, 252:124168.
- Rifkin, R. e Klautau, A. (2004). In defense of one-vs-all classification. *Journal of Machine Learning Research*, 5:101–141.
- Riyanto, S., Sitanggang, I. S., Djatna, T. e Atikah, T. D. (2023). Comparative Analysis using Various Performance Metrics in Imbalanced Data for Multi-class Text Classification. (*IJACSA*) *International Journal of Advanced Computer Science and Applications*, 14(6):1082–1090.
- Romberg, J., Schröder, C., Gonsior, J., Tomanek, K. e Olsson, F. (2025). Reassessing active learning adoption in contemporary NLP: A community survey.

- Roumeliotis, K. I., Tselikas, N. D. e Nasiopoulos, D. K. (2025). LLMs for product classification in e-commerce: A zero-shot comparative study of GPT and Claude models. *Natural Language Processing Journal*, 11:100142.
- Rouzegar, H. e Makrehchi, M. (2024). Enhancing text classification through llm-driven active learning and human annotation.
- Roy, N. e McCallum, A. (2001). Toward optimal active learning through sampling estimation of error reduction. Em *Proceedings of the 18th International Conference on Machine Learning*, páginas 441–448.
- Russell, S. J. e Norvig, P. (2010). *Artificial Intelligence: A Modern Approach*. Prentice Hall, Upper Saddle River, NJ, 3rd edition.
- Salton, G. e Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information processing & management*, 24(5):513–523.
- Santos, D. P. d. (2016). *Seleção e controle do viés de aprendizado ativo*. Tese de doutorado, Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos.
- Schick, T., Dwivedi-Yu, J., Dessì, R., Raileanu, R., Lomeli, M., Zettlemoyer, L., Cancedda, N. e Scialom, T. (2023). Toolformer: Language models can teach themselves to use tools. arXiv preprint arXiv:2302.04761.
- Schröder, C., Müller, L., Niekler, A. e Potthast, M. (2021). Small-text: Active learning for text classification in python.
- Selva, J. P. e Titus, T. S. (2021). Review on word embedding techniques and its applications. *International Journal of Engineering Research & Technology (IJERT)*, 10(01).
- Settles, B. (2009). Active learning literature survey. Computer Sciences Technical Report 1648, University of Wisconsin-Madison.
- Settles, B. (2012). *Active Learning*. Synthesis Lectures on Artificial Intelligence and Machine Learning. Morgan & Claypool.
- Settles, B. e Craven, M. (2008). An analysis of active learning strategies for sequence labeling tasks. Em *Proceedings of the 2008 Conference on Empirical Methods in Natural Language Processing (EMNLP '08)*, páginas 1070–1079. Association for Computational Linguistics.
- Settles, B., Craven, M. e Friedland, L. (2008). Active learning with real annotation costs. Em *Proceedings of the NIPS Workshop on Cost-Sensitive Learning*.
- Seung, H. S., Oppor, M. e Sompolinsky, H. (1992). Query by committee. Em *Proceedings of the Fifth Annual Workshop on Computational Learning Theory (COLT '92)*, páginas 287–294. ACM.

- Shannon, C. E. (1948). A mathematical theory of communication. *The Bell System Technical Journal*, 27(3):379–423.
- Sharma, M., Zhuang, D. e Bilgic, M. (2015). Active learning with rationales for text classification. Em *Proceedings of NAACL-HLT 2015*, páginas 441–451.
- Sheng, V. S., Provost, F. e Ipeirotis, P. G. (2008). Get another label? Improving data quality and data mining using multiple, noisy labelers. Em *Proceedings of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, páginas 614–622. ACM.
- Snow, R., O’Connor, B., Jurafsky, D. e Ng, A. Y. (2008). Cheap and fast – but is it good? Evaluating non-expert annotations for natural language tasks. Em *Proceedings of the 2008 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, páginas 254–263, Honolulu, Hawaii. Association for Computational Linguistics.
- Sokolova, M. e Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4):427–437.
- Song, G., Ye, Y., Du, X., Huang, X. e Bie, R. (2014a). Short text classification: A survey. *Journal of Multimedia*, 9(5):635–643.
- Song, G., Ye, Y., Du, X., Huang, X. e Bie, S. (2014b). Short text classification: A survey. *Journal of Multimedia*, 9(5):635–643.
- Song, H., Kim, M., Park, D., Shin, Y. e Lee, J.-G. (2023). Learning from noisy labels with deep neural networks: A survey. *IEEE Transactions on Neural Networks and Learning Systems*, 34(11):8135–8153.
- Souza, F., Nogueira, R. e Lotufo, R. (2020). BERTimbau: pretrained BERT models for Brazilian Portuguese. Em *Brazilian Conference on Intelligent Systems (BRACIS)*, páginas 403–417. Springer.
- Su, B., Guo, J., Liu, Q. e Zhang, Y. (2023). Freeal: Towards human-free active learning in the era of large language models. Em *EMNLP 2023*, páginas 7982–7995.
- Sun, A., Lim, E.-P. e Ng, W.-K. (2003). Performance measurement framework for hierarchical text classification. *Journal of the American Society for Information Science and Technology*, 54(11):1014–1028.
- Tan, L., Li, M. Y. e Kok, S. (2020). E-commerce product categorization via machine translation. *ACM Transactions on Management Information Systems*, 11(3):1–14.
- Tian, Y., Lee, J., Fu, B., Das, R., Khashabi, C. e Ma, J. (2023). Artprompt: Ascii art-based jailbreak attacks against aligned llms. arXiv preprint arXiv:2402.11753.

- Tong, S. e Koller, D. (2000). Support vector machine active learning with applications to text classification. Em Langley, P., editor, *Proceedings of the Seventeenth International Conference on Machine Learning (ICML 2000)*, páginas 999–1006. Morgan Kaufmann.
- Wei, J., Wang, X., Schuurmans, D., Bosma, M., Chi, E. H., Le, Q. V. e Zhou, D. (2022). Chain-of-thought prompting elicits reasoning in large language models. Em *Advances in Neural Information Processing Systems*.
- Widodo, S., Brawijaya, H. e Samudi (2022). Stratified K-fold cross validation optimization on machine learning for prediction. *Sinkron : Jurnal dan Penelitian Teknik Informatika*, 7(4):2407–2413.
- Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83.
- Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158):209–212.
- Wolf, T. et al. (2020). Transformers: state-of-the-art natural language processing. Em *Proceedings of EMNLP: System Demonstrations*, páginas 38–45.
- Wu, L., Lei, T. e Pineau, J. (2022). Active learning for natural language processing: A survey. arXiv preprint arXiv:2212.06445.
- Xia, M., Wang, H., Li, Y., Yu, Z., Wang, J., Zhao, J. e Wu, R. (2025a). Prompt candidates, then distill: A teacher-student framework for LLM-driven data annotation. Em *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (ACL)*, páginas 2750–2770.
- Xia, Y., Mukherjee, S., Xie, Z. L., Wu, J., Li, X. e Aponte, R. (2025b). From selection to generation: A survey of LLM-based active learning. Year set to 2025 as per the citation, corresponds to arXiv submission date.
- Xu, J., Xu, B., Wang, P., Zheng, S., Tian, G. e Zhao, J. (2017). Self-taught convolutional neural networks for short text clustering. *Neural Networks*, 88:22–31.
- Yan, Y., Rosales, R., Fung, G. e Dy, J. (2011). Active learning from crowds. Em *28th International Conference on Machine Learning*, páginas 1161–1168.
- Yuan, B., Chen, Y., Zhang, Y. e Jiang, W. (2025). Hide and seek in noise labels: Noise-robust collaborative active learning with LLM-powered assistance. arXiv:2504.02901.
- Yuan, M., Lin, H.-T. e Boyd-Graber, J. (2020). Cold-start active learning through self-supervised language modeling. Em *Proceedings of the 2020 Conference on Empirical Methods in Natural*

Language Processing (EMNLP), páginas 7935–7948, Online. Association for Computational Linguistics.

- Zhang, Y. e Takada, S. (2025a). Applying LLMs to active learning: towards cost-efficient cross-task text classification without manually labeled data. arXiv:2502.16892.
- Zhang, Y. e Takada, S. (2025b). Applying LLMs to active learning: Towards cost-efficient cross-task text classification without manually labeled data. Year set to 2025 as per the citation, corresponds to arXiv submission date.
- Zhang, Z., Strubell, E. e Hovy, E. (2022a). A survey of active learning for natural language processing. Em *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, páginas 6166–6190, Abu Dhabi, United Arab Emirates. Association for Computational Linguistics.
- Zhang, Z., Strubell, E. e Hovy, E. (2022b). A survey of active learning for natural language processing. Em Goldberg, Y., Kozareva, Z. e Zhang, Y., editores, *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, páginas 6166–6190, Abu Dhabi, United Arab Emirates. Association for Computational Linguistics.
- Zhu, X. e Goldberg, A. B. (2009). Introduction to semi-supervised learning. *Synthesis Lectures on Artificial Intelligence and Machine Learning*, 3(1):1–130.

APÊNDICE A – MÉTRICA LEARNING CURVE EFFICIENCY (LCE)

A.1 DEFINIÇÃO

Seja uma execução de aprendizado ativo que produz a curva $\{(n_k, m_k)\}_{k=1}^K$, em que n_k é o número de instâncias rotuladas na iteração k (estritamente crescente) e m_k a métrica de interesse (nesta tese, Macro F1 no conjunto de teste fixo T). Define-se:

$$\text{LCE} = \frac{\int_{n_1}^{n_K} m(n) dn}{\text{Perf}_{\text{baseline}} \cdot (n_K - n_1)}, \quad (\text{A.1})$$

em que a integral do numerador (AUC_{real}) é calculada numericamente pela regra composta de Simpson sobre os pontos observados (com recuo para a regra do trapézio quando $K = 2$) e $\text{Perf}_{\text{baseline}}$ é o desempenho do MESMO classificador treinado com supervisão completa do pool. O denominador é a área da curva ideal: desempenho de referência atingido instantaneamente no início do processo ($L_{\text{ideal},0} = n_1$).

A.2 PROPRIEDADES

(i) $\text{LCE} \in (0, 1]$ quando $m_k \leq \text{Perf}_{\text{baseline}}$ para todo k ; valores maiores indicam aproximação mais rápida do teto. (ii) É invariante a transformações afins do eixo n (mudança de unidade de orçamento). (iii) Ao normalizar pelo teto do próprio par (classificador, conjunto) — e não pelo máximo teórico da métrica — permite comparar estratégias entre classificadores de tetos distintos: um classificador fraco bem servido pela estratégia pode ter LCE maior que um classificador forte mal servido. (iv) Depende do intervalo $[n_1, n_K]$: comparações exigem execuções com o mesmo orçamento e o mesmo L_0 — condição imposta em todos os desenhos desta tese.

A.3 RELAÇÃO COM A ALC

A *Area under the Learning Curve* do *Active Learning Challenge* (Guyon et al., 2011) também sumariza a curva por área normalizada. As diferenças da LCE: normalização pelo baseline de supervisão completa do próprio par (a ALC normaliza pelo máximo global da métrica) e integração de Simpson na grade observada (a ALC interpola em escala logarítmica de consultas). A implementação de referência está em `src/activelearning/domain/metrics.py` (função `lce`), com testes unitários de propriedades.

APÊNDICE B – ALGORITMO GENÉTICO PARA OTIMIZAÇÃO DE L0

B.1 FORMULAÇÃO

Indivíduo: conjunto de I índices únicos do pool (L_0 candidato). Aptidão: desempenho (Acurácia ou Macro F1) do classificador PVBin treinado no indivíduo e avaliado em partição de **aferição** disjunta do conjunto de teste (protocolo anticircularidade; ver Seção 4.4 para a quantificação do viés do protocolo ingênuo). Quatro cenários: maximização e minimização de cada métrica — o par (max, min) delimita o envelope empírico de desempenho alcançável pela composição.

B.2 OPERADORES E PARÂMETROS

- **População** $N_{pop} = 50$; **gerações** 100 (reexecução reduzida: 30×40 ; decisão D-002 do registro de decisões);
- **seleção**: torneio de tamanho $k_t = 3$;
- **cruzamento**: um ponto sobre a lista de índices, com probabilidade $p_c = 0,8$, seguido de *reparo de unicidade* (índices repetidos são substituídos por sorteio até restaurar $|L_0| = I$);
- **mutação**: com probabilidade $p_m = 0,1$, substituição de $m_s = \max(1, \lceil 0,01 \cdot I \rceil)$ genes por índices inéditos;
- **elitismo**: 10% ($N_{elite} = 5$ na configuração original).

B.3 PSEUDOCÓDIGO

1. Inicializar N_{pop} indivíduos por amostragem uniforme sem reposição.
2. Avaliar aptidão de todos na partição de aferição.
3. Por geração: copiar elite; completar a população por torneio $\rightarrow$ cruzamento $\rightarrow$ reparo $\rightarrow$ mutação; reavaliar.
4. Ao final, **reavaliar o melhor indivíduo no conjunto de teste intocado** — o valor reportado como envelope é este, não a aptidão.

Implementação de referência da reexecução: `experiments/p1/replay_ga.py`; resultados em `experiments/p1/results/replay_ga.jsonl`.

APÊNDICE C – ALGORITMO DRI-SL

C.1 OBJETIVO E ENTRADAS

Construir L_0 de tamanho alvo I a partir do pool não rotulado U , sem acesso a rótulos. Entradas: textos de U ; codificador de sentenças ϕ (SBERT multilíngue (Reimers e Gurevych, 2019) na configuração da tese); número de grupos N_c (padrão $\max(2, \lfloor \sqrt{I} \rfloor)$); semente.

C.2 ETAPAS

1. **Densidade semântica:** projetar U por ϕ ; agrupar por k -médias em N_c grupos; alocar a cota q_c de cada grupo proporcionalmente ao seu tamanho (cota mínima de 1 para grupo não vazio; ajuste do resto pelas maiores frações).
2. **Variedade lexical intragrupo:** para cada grupo c , computar o perfil TF-IDF médio; selecionar iterativamente, entre os membros ainda não escolhidos, o texto que maximiza o *escore de novidade* — a soma dos pesos, no perfil do grupo, dos termos que o texto introduz e que ainda não estão cobertos pelos já selecionados; atualizar o conjunto de termos cobertos; repetir até preencher q_c .

A seleção é determinística dada a semente (inicialização do k -médias). O custo é dominado pela codificação ($O(|U|)$ passagens do codificador) e pelo k -médias; a etapa lexical é $O(q_c \cdot |c|)$ por grupo, com operações esparsas.

C.3 INTUIÇÃO

A etapa 1 garante *representatividade*: cada região semântica do pool contribui proporcionalmente — nenhum agrupamento relevante fica de fora do L_0 . A etapa 2 garante *não redundância*: dentro da região, evita quase-duplicatas (frequentes no domínio: 7,7% de duplicatas exatas) e força cobertura de vocabulário — que, para um classificador por protótipo como o PVBin, é exatamente o recurso que constrói fronteiras. A combinação explica o resultado do Capítulo 4: cobertura semântica dá o esqueleto de classes; cobertura lexical dá o poder discriminativo por classe.

Implementação de referência: `src/activelearning/adapters/strategies/drisl.py` (com codificador alternativo TF-IDF+SVD para ambientes leves), testes em `tests/unit/test_drisl.py`.

APÊNDICE D – A BIBLIOTECA ACTIVELEARNING

D.1 ARQUITETURA

A biblioteca segue arquitetura hexagonal com domínio isolado: o núcleo (`domain/`) contém instâncias, o espaço fechado de categorias (*CategorySchema*), anotações com contabilidade de uso (*OracleUsage*: tokens, tokens em cache, custo, latência), estratégias de incerteza e métricas (LCE, Wilson, McNemar) — puro, sem dependência de rede ou framework. Os **adapters** implementam as portas: oráculos (OpenAI, OpenAI-compatível/MaaS, OpenRouter, Gemini, Ollama, Simulado com ruído ε), classificadores (PVBIn; BERTimbau via `transformers`), estratégias com infraestrutura (DRI-SL com SBERT), dados (CSV do domínio) e persistência (SQLite/PostgreSQL). Os **casos de uso** (`application/`) orquestram: avaliação de oráculo (E0, retomável), laço de aprendizado ativo (E1/E4), runner do FALCO (fases com transição por validação) e saneamento de dados.

O diferencial frente a bibliotecas existentes de AL para texto — notadamente *small-text* (Schröder et al., 2021), que padroniza classificador $\times$ estratégia $\times$ critério de parada — é elevar o **oráculo** a porta de primeira classe: custo por consulta, modos de instrumentação (`enum/json-prompt/free`), variantes de prompt, lote por chamada e cache são medidos e registrados em cada anotação.

D.2 REPRODUÇÃO DOS EXPERIMENTOS

Cada experimento tem ponto de entrada único parametrizado por configuração versionada; execuções gravam sementes e registros por item/iteração (JSONL) e são retomáveis. Mapa: E0 $\rightarrow$ `experiments/e0/run_e0.py` (+ `analyze_e0.py`, `analyze_noise_impact.py`); E0-P $\rightarrow$ `experiments/e0p/`; P1/AG $\rightarrow$ `experiments/p1/`; E1/E4 $\rightarrow$ `experiments/e1e4/`; E2/E3 (GPU) $\rightarrow$ runner do FALCO em `application/run_falco.py` com os cinco braços do desenho. A suíte de testes unitários cobre domínio, adapters e casos de uso sem rede.

D.3 FLOWBUILDER

Interface web (FastAPI + React) sobre a biblioteca: envio de CSV com saneamento automático (remoção de rótulos operacionais; censo de conflitos e duplicatas; download da base saneada), execução parametrizada de fluxos (semente, orçamento, lote, L_0 , estratégia, oráculo — incluindo modelos de custo zero) e acompanhamento de curvas de aprendizado. O banco guarda o índice das execuções; os artefatos brutos permanecem em disco, versionáveis.

APÊNDICE E – PROMPTS E ESQUEMAS DO ORÁCULO LLM

E.1 PROMPT V3 (PRODUÇÃO)

Contexto de tarefa comum a todos os modos (o texto integral e versionado está em `src/activelearning/adapters/oracles/prompt.py`):

“Você é um especialista em catalogação de produtos do varejo brasileiro. As descrições vêm de cupons fiscais e cadastros de e-commerce: são curtas, geralmente em caixa alta e cheias de abreviações (ex.: CERV=cerveja, REFR=refrigerante, BISC=biscoito, CHOC=chocolate, RECH=recheado, PCT=pacote, LT=lata, CX=caixa, UN=unidade). Expanda mentalmente as abreviações e classifique o TIPO do produto, ignorando marca, tamanho e embalagem. Escolha sempre a categoria mais específica aplicável; na dúvida entre uma categoria plausível e ‘_rare_’, prefira a categoria plausível — use ‘_rare_’ SOMENTE se nenhuma categoria da lista descrever o tipo do produto. Exemplos: ‘CERV BRAHMA LT 350ML’ → cerveja; ‘BISC RECH CHOC 130G’ → biscoito; ‘REQUEIJAO LIGHT CP 200G’ → requeijao.”

O prefixo estático (contexto + esquema) precede o item variável, habilitando o *cache* de prefixo dos provedores (88–95% de acerto medido no E0).

E.2 MODOS DE INSTRUMENTAÇÃO

enum: saída estruturada com `strict:true`; o campo `predicted_category` é restrito por `enum` às 621 categorias do *CategorySchema*; campos `expanded_description` e `rationale` completam o objeto (todos obrigatórios — exigência do modo estrito). **json-prompt** (provedores sem saída estruturada): a lista de categorias e o formato JSON são instruídos no texto; a resposta passa por extração tolerante e validação exata contra o esquema, com rótulos fora do espaço contabilizados como inválidos. **free** (somente RQ4): saída estruturada sem `enum` — réplica controlada do instrumento defeituoso do trabalho anterior. Na rotulagem em lote, os itens são numerados e a resposta é um vetor indexado; o esquema do lote não fixa `minItems/maxItems` para preservar a cacheabilidade do prefixo; o uso (tokens/custo) é rateado igualmente entre os itens da chamada.

E.3 VARIANTES DO E0-P

v4a acrescenta dez regras de fronteira do catálogo derivadas da anatomia de erros (ex.: medicamentos → *outro farma*; produto bucal líquido → *antiséptico bucal*; pó para suco → *preparo para suco*; fones com fio → *acessorio de audio*); **v4b** soma dez exemplos *inventados* de

fronteiras difíceis (nunca instâncias das amostras de avaliação — decisão D-004). Texto integral das variantes no mesmo módulo versionado.

APÊNDICE F – TABELAS COMPLETAS

A Tabela F.1 apresenta as estatísticas descritivas completas do estudo de sensibilidade de L_0 (Seção 4.1): Acurácia Global e Macro F1 no teste T por tamanho I , com média, mediana, desvio-padrão, extremos, quartis e coeficiente de variação da mediana — 47 tamanhos, 30 repetições cada, classificador PVBin. A tabela reproduz o artefato original do programa experimental; a reexecução independente (15 tamanhos $\times$ 10 repetições) está em `experiments/p1/results/replay_l0.jsonl` no repositório de código.

Tabela F.1: Estatísticas Descritivas da Performance em Função do Tamanho de L_0 (Classificador: PVBin (1,2)-gram). 30 repetições por tamanho.

Métrica Base	Tam. L_0 (I)	Média	Mediana	DP	Mínimo	P25	P75	Máximo	IQR	CV (Med.)
Acurácia	10	0.067	0.069	0.024	0.026	0.046	0.088	0.102	0.042	0.345
Acurácia	20	0.105	0.110	0.023	0.049	0.089	0.122	0.138	0.033	0.211
Acurácia	30	0.140	0.139	0.023	0.095	0.125	0.155	0.181	0.030	0.165
Acurácia	40	0.160	0.159	0.023	0.100	0.145	0.178	0.191	0.034	0.141
Acurácia	50	0.178	0.180	0.022	0.124	0.164	0.199	0.208	0.034	0.121
Acurácia	60	0.193	0.194	0.019	0.145	0.179	0.207	0.230	0.027	0.100
Acurácia	70	0.207	0.207	0.014	0.177	0.196	0.219	0.229	0.023	0.067
Acurácia	80	0.224	0.224	0.015	0.203	0.212	0.235	0.252	0.023	0.066
Acurácia	90	0.235	0.234	0.019	0.205	0.221	0.250	0.278	0.029	0.082
Acurácia	100	0.247	0.247	0.016	0.217	0.237	0.257	0.281	0.020	0.064
Acurácia	200	0.333	0.333	0.016	0.306	0.321	0.345	0.370	0.024	0.048
Acurácia	300	0.391	0.392	0.010	0.365	0.388	0.397	0.409	0.010	0.027
Acurácia	400	0.435	0.434	0.010	0.417	0.429	0.439	0.465	0.009	0.023
Acurácia	500	0.468	0.467	0.008	0.452	0.463	0.475	0.483	0.012	0.018
Acurácia	600	0.491	0.492	0.008	0.471	0.486	0.496	0.509	0.010	0.016
Acurácia	700	0.513	0.513	0.007	0.497	0.508	0.516	0.530	0.008	0.014
Acurácia	800	0.529	0.532	0.009	0.508	0.524	0.537	0.544	0.013	0.018
Acurácia	900	0.546	0.547	0.005	0.534	0.544	0.550	0.557	0.006	0.010
Acurácia	1000	0.559	0.559	0.007	0.542	0.555	0.564	0.568	0.009	0.012
Acurácia	2000	0.640	0.641	0.004	0.633	0.637	0.643	0.648	0.006	0.006
Acurácia	3000	0.679	0.678	0.004	0.671	0.675	0.682	0.687	0.006	0.006
Acurácia	4000	0.705	0.705	0.003	0.698	0.703	0.707	0.714	0.003	0.004

Continua na próxima página

Tabela F.1 – continuação da página anterior

Métrica Base	Tam. L0 (I)	Média	Mediana	DP	Mínimo	P25	P75	Máximo	IQR	CV (Med.)
Acurácia	5000	0.721	0.721	0.003	0.713	0.719	0.723	0.726	0.005	0.004
Acurácia	6000	0.736	0.736	0.004	0.727	0.732	0.738	0.746	0.006	0.005
Acurácia	7000	0.747	0.747	0.003	0.741	0.744	0.748	0.751	0.004	0.003
Acurácia	8000	0.755	0.755	0.003	0.748	0.753	0.757	0.760	0.005	0.004
Acurácia	9000	0.763	0.762	0.003	0.758	0.761	0.765	0.769	0.004	0.004
Acurácia	10000	0.769	0.769	0.003	0.765	0.767	0.771	0.774	0.004	0.003
Acurácia	20000	0.806	0.807	0.002	0.802	0.805	0.808	0.812	0.003	0.003
Acurácia	30000	0.826	0.826	0.001	0.824	0.825	0.827	0.829	0.002	0.002
Acurácia	40000	0.838	0.838	0.001	0.835	0.837	0.839	0.842	0.002	0.002
Acurácia	50000	0.847	0.847	0.002	0.843	0.846	0.848	0.852	0.002	0.002
Acurácia	60000	0.853	0.854	0.001	0.851	0.853	0.854	0.856	0.001	0.001
Acurácia	70000	0.859	0.859	0.001	0.856	0.858	0.859	0.861	0.002	0.001
Acurácia	80000	0.864	0.863	0.001	0.861	0.863	0.864	0.867	0.002	0.001
Acurácia	90000	0.867	0.867	0.001	0.865	0.866	0.868	0.870	0.001	0.001
Acurácia	100000	0.871	0.871	0.001	0.869	0.870	0.872	0.873	0.001	0.001
Acurácia	110000	0.874	0.874	0.001	0.872	0.873	0.875	0.876	0.002	0.001
Acurácia	120000	0.876	0.877	0.001	0.875	0.876	0.877	0.878	0.001	0.001
Acurácia	130000	0.879	0.879	0.001	0.877	0.878	0.879	0.880	0.001	0.001
Acurácia	140000	0.881	0.881	0.001	0.880	0.881	0.882	0.883	0.001	0.001
Acurácia	150000	0.883	0.883	0.001	0.882	0.883	0.884	0.884	0.001	0.001
Acurácia	160000	0.885	0.885	0.001	0.884	0.885	0.885	0.886	0.001	0.001
Acurácia	170000	0.886	0.887	0.000	0.885	0.886	0.887	0.888	0.001	0.001
Acurácia	180000	0.888	0.888	0.000	0.887	0.888	0.888	0.889	0.000	0.000
Acurácia	190000	0.889	0.890	0.000	0.889	0.889	0.890	0.890	0.000	0.000
Acurácia	200000	0.891	0.891	0.000	0.891	0.891	0.891	0.891	0.000	0.000
F1-Macro	10	0.004	0.003	0.001	0.002	0.003	0.004	0.007	0.001	0.309
F1-Macro	20	0.008	0.008	0.001	0.005	0.007	0.009	0.010	0.002	0.175
F1-Macro	30	0.012	0.012	0.002	0.009	0.010	0.013	0.015	0.003	0.148
F1-Macro	40	0.015	0.015	0.002	0.011	0.014	0.016	0.018	0.002	0.099
F1-Macro	50	0.018	0.018	0.002	0.014	0.017	0.020	0.023	0.003	0.126
F1-Macro	60	0.021	0.022	0.002	0.017	0.020	0.023	0.026	0.003	0.105
F1-Macro	70	0.024	0.024	0.002	0.021	0.023	0.025	0.029	0.002	0.081
F1-Macro	80	0.028	0.027	0.003	0.023	0.026	0.029	0.036	0.003	0.097
F1-Macro	90	0.031	0.031	0.003	0.027	0.029	0.033	0.038	0.004	0.084

Continua na próxima página

Tabela F.1 – continuação da página anterior

Métrica Base	Tam. L0 (I)	Média	Mediana	DP	Mínimo	P25	P75	Máximo	IQR	CV (Med.)
F1-Macro	100	0.034	0.035	0.003	0.030	0.033	0.035	0.041	0.003	0.075
F1-Macro	200	0.062	0.063	0.004	0.054	0.058	0.064	0.068	0.006	0.064
F1-Macro	300	0.084	0.085	0.004	0.078	0.081	0.086	0.090	0.006	0.043
F1-Macro	400	0.103	0.104	0.005	0.095	0.098	0.108	0.113	0.010	0.053
F1-Macro	500	0.119	0.120	0.004	0.109	0.116	0.122	0.127	0.006	0.037
F1-Macro	600	0.135	0.134	0.004	0.128	0.131	0.138	0.141	0.007	0.029
F1-Macro	700	0.147	0.148	0.006	0.134	0.144	0.152	0.162	0.008	0.040
F1-Macro	800	0.158	0.158	0.006	0.149	0.154	0.162	0.169	0.008	0.036
F1-Macro	900	0.168	0.168	0.006	0.158	0.165	0.173	0.179	0.008	0.033
F1-Macro	1000	0.178	0.176	0.008	0.163	0.172	0.185	0.191	0.013	0.045
F1-Macro	2000	0.251	0.252	0.006	0.239	0.248	0.255	0.267	0.007	0.025
F1-Macro	3000	0.295	0.295	0.005	0.287	0.292	0.298	0.306	0.006	0.017
F1-Macro	4000	0.328	0.327	0.005	0.316	0.324	0.331	0.340	0.007	0.016
F1-Macro	5000	0.350	0.348	0.006	0.341	0.345	0.354	0.363	0.009	0.017
F1-Macro	6000	0.373	0.374	0.008	0.358	0.369	0.379	0.390	0.010	0.022
F1-Macro	7000	0.393	0.393	0.007	0.379	0.390	0.397	0.406	0.007	0.017
F1-Macro	8000	0.406	0.406	0.007	0.390	0.402	0.411	0.421	0.009	0.017
F1-Macro	9000	0.420	0.420	0.007	0.406	0.415	0.426	0.429	0.011	0.016
F1-Macro	10000	0.433	0.432	0.006	0.418	0.429	0.438	0.446	0.009	0.015
F1-Macro	20000	0.503	0.503	0.007	0.488	0.500	0.508	0.517	0.008	0.014
F1-Macro	30000	0.549	0.548	0.008	0.536	0.542	0.554	0.565	0.012	0.014
F1-Macro	40000	0.574	0.575	0.007	0.558	0.569	0.579	0.584	0.010	0.011
F1-Macro	50000	0.595	0.594	0.007	0.584	0.590	0.598	0.613	0.008	0.012
F1-Macro	60000	0.612	0.613	0.006	0.601	0.607	0.616	0.624	0.009	0.010
F1-Macro	70000	0.625	0.624	0.006	0.612	0.622	0.627	0.642	0.005	0.010
F1-Macro	80000	0.635	0.634	0.006	0.627	0.631	0.641	0.651	0.009	0.009
F1-Macro	90000	0.645	0.646	0.005	0.637	0.641	0.649	0.655	0.008	0.008
F1-Macro	100000	0.654	0.653	0.006	0.640	0.652	0.657	0.666	0.006	0.009
F1-Macro	110000	0.661	0.661	0.006	0.648	0.657	0.666	0.674	0.009	0.009
F1-Macro	120000	0.670	0.669	0.004	0.662	0.667	0.672	0.677	0.005	0.006
F1-Macro	130000	0.675	0.676	0.004	0.668	0.672	0.679	0.685	0.006	0.007
F1-Macro	140000	0.679	0.679	0.004	0.671	0.677	0.683	0.686	0.007	0.006
F1-Macro	150000	0.685	0.685	0.003	0.677	0.682	0.688	0.690	0.005	0.005
F1-Macro	160000	0.689	0.688	0.004	0.682	0.687	0.691	0.700	0.004	0.005

Continua na próxima página

Tabela F.1 – continuação da página anterior

Métrica	Tam. L0	Média	Mediana	DP	Mínimo	P25	P75	Máximo	IQR	CV (Med.)
Base	(I)									
F1-Macro	170000	0.693	0.693	0.003	0.688	0.690	0.695	0.699	0.005	0.004
F1-Macro	180000	0.698	0.699	0.003	0.692	0.696	0.700	0.704	0.004	0.004
F1-Macro	190000	0.701	0.701	0.002	0.695	0.700	0.702	0.706	0.002	0.003
F1-Macro	200000	0.704	0.704	0.000	0.704	0.704	0.704	0.705	0.000	0.000

APÊNDICE G – CRITÉRIO DE PARADA, LIBERAÇÃO DO MODELO E MONITORAMENTO DE DERIVA

Este apêndice consolida a política operacional do ciclo de vida do classificador treinado pelo FALCO — da decisão de parar de rotular à decisão de retreinar em produção. As duas primeiras seções descrevem mecanismos implementados na biblioteca `activelearning`; a terceira é o desenho recomendado para operação contínua (FlowBuilder), com gatilhos numéricos.

G.1 PARADA DO LAÇO DE APRENDIZADO ATIVO

O laço encerra a aquisição de rótulos pelo primeiro de três gatilhos: **(i) estagnação na validação** — o Macro F1 em V não melhora mais que $\varepsilon_{\max} = 10^{-3}$ por $p = 5$ iterações consecutivas (Capítulo 3 para o racional das constantes); o conjunto de teste jamais participa; **(ii) orçamento** — teto absoluto de rótulos B ; **(iii) exaustão do pool**. O racional do gatilho (i) é estatístico: o ganho marginal por lote decai ao longo da curva de aprendizado, enquanto o custo marginal do rótulo é constante; quando o ganho observável cai abaixo da resolução do próprio conjunto de validação ($\approx 1/\sqrt{n_V}$), rotular mais é pagar para medir ruído. O gatilho foi exercitado em duas execuções ponta a ponta da biblioteca: com oráculo simulado (ruído 0,2), encerrou o ciclo em 910 de 1.000 rótulos orçados; com **oráculo LLM real e gratuito** (nemotron via NIM, acurácia $\approx 78\%$) e orçamento de 15.000, encerrou em **6.009** rótulos (PVBin) e **4.742** (SGD) — 32–40% do orçamento —, com as curvas de validação e teste estagnadas em conjunto. Os artefatos estão no repositório (`experiments/e5cycle`).

G.2 CRITÉRIO DE LIBERAÇÃO DO MODELO

Recomenda-se liberar o modelo para produção quando três condições valem simultaneamente: **(a)** a estagnação foi atingida (o modelo parou de melhorar com o oráculo disponível); **(b)** o desempenho de validação alcança o alvo externo de negócio — na ausência de alvo, o teto empírico do braço *oráculo-total* (treinar com todo o pool rotulado pelo mesmo oráculo, ao custo de inferência apenas) indica o máximo que *este* oráculo permite: estagnar perto dele significa que mais rótulos não ajudam, apenas um oráculo melhor; **(c)** o intervalo de confiança de Wilson do desempenho de validação está inteiro acima do piso aceitável (com $n_V = 1.000$, a meia-largura é de 2–3 pontos percentuais). Só então o modelo é avaliado *uma única vez* no conjunto de teste intocado — e esse é o número reportado.

G.3 MONITORAMENTO DE DERIVA E POLÍTICA DE RETREINAMENTO

Textos curtos de varejo derivam continuamente (novos produtos, marcas e grafias). Três camadas de monitoramento, em ordem de custo:

1. **Deriva de entrada** (sem rótulo, custo zero): fração de tokens fora do vocabulário de treino e divergência da distribuição de representações (PSI sobre projeções). Gatilho sugerido: taxa de vocabulário novo em dobro da taxa do treino, ou $\text{PSI} > 0,2$.
2. **Deriva de confiança** (sem rótulo, custo zero): queda da confiança média (ou aumento da entropia média) das previsões em produção. Gatilho: média móvel de 7 dias abaixo de $\mu - 2\sigma$ do período de referência.
3. **Verificação amostral com oráculo** (custo quase nulo): acurácia numa amostra pequena rotulada pelo LLM Inicial — com os custos medidos no E0, 200 itens semanais custam da ordem de US\$ 0,01. Gatilho: acurácia amostral abaixo do limite inferior do IC de validação da liberação.

Política: camadas 1–2 disparando antecipam a camada 3; a camada 3 confirmando, retreina-se. O retreino reaproveita todos os rótulos históricos e roda um ciclo *incremental* de aprendizado ativo apenas sobre o fluxo recente (o classificador atual seleciona o que não entende; o oráculo LLM rotula; treina-se do zero com $L_{\text{antigo}} \cup L_{\text{novo}}$ — retreinar do zero, e não continuar do modelo anterior, preserva comparabilidade e evita a degradação associada a *warm-starting*). Mesmo sem gatilho, recomenda-se a verificação amostral em cadência mensal: deriva de catálogo pode ser gradual demais para as camadas 1–2.