

GILSILEY HENRIQUE DARÚ

APRENDIZADO ATIVO COM MODELOS DE LINGUAGEM
PARA TEXTOS CURTOS EM PORTUGUÊS

(versão pré-defesa, compilada em 17 de julho de 2026)

Tese apresentada como requisito parcial à obtenção do grau de Doutor em Métodos Numéricos em Engenharia no Programa de Pós-Graduação em Métodos Numéricos em Engenharia, Setores de Ciências Exatas e de Tecnologia, da Universidade Federal do Paraná.

Área de concentração: *Programação Matemática*.

Orientador: Prof. Dr. Gustavo Valentim Loch.

CURITIBA PR

2026

RESUMO

A classificação de textos curtos em português — como descrições de produtos de notas fiscais, com vocabulário abreviado, ruidoso e centenas de categorias — depende de grandes volumes de rótulos cuja obtenção é o principal custo desses sistemas. Esta tese propõe e avalia o FALCO (*Framework de Aprendizado Ativo com LLM para texto CurtO*), que integra três frentes de redução de custo: composição informada do conjunto inicial de treinamento, seleção ativa de instâncias por incerteza e substituição parcial do anotador humano por oráculos baseados em grandes modelos de linguagem (LLMs), organizados em fases de custo crescente. A investigação usa um conjunto público auditado de 250.365 descrições de produtos em 621 categorias e segue protocolo pré-registrado com partições imutáveis, análise pareada (McNemar, Wilcoxon) e artefatos rastreáveis para todos os números reportados. Quatro resultados principais: (i) a sensibilidade à composição do conjunto inicial é máxima no regime de poucos rótulos (amplitude de 6,4 pontos percentuais de acurácia com $|L_0| = 100$) e a heurística determinística proposta, DRI-SL — densidade semântica com diversidade lexical, sem usar nenhum rótulo —, supera o melhor indivíduo de um algoritmo genético supervisionado em todos os tamanhos de 100 a 5.000, comparação conservadora após a correção de circularidade que reduziu o envelope evolutivo em até 6,3 pontos percentuais; (ii) oráculos LLM zero-shot atingem 77–83% de acurácia no espaço fechado de 621 categorias a custos de US\$ 0,035 a US\$ 0,92 por mil rótulos, com Macro F1 superior ao de um classificador supervisionado leve treinado com 250 mil rótulos, e quase metade dos seus erros concentra-se em convenções de catálogo (categorias-irmãs e classes guarda-chuva); (iii) o instrumento de medição importa: sem restrição de saída ao espaço de classes, 6,8% das respostas viram falsos erros, e regras de fronteira no *prompt* melhoram o modelo fraco na distribuição de produção (+4,6 p.p., $p = 0,012$) ao custo de degradação severa nas classes raras ($p < 0,001$); (iv) as estratégias de incerteza superam a seleção aleatória com significância máxima em 8 sementes ($p = 0,0078$), recuperando 78% do Macro F1 do teto supervisionado com 15% dos rótulos, e essa vantagem sobrevive intacta a ruído uniforme de oráculo até $\varepsilon = 0,4$ — cobrindo a faixa de erro observada nos LLMs reais. Como o melhor oráculo ficou abaixo do critério pré-registrado de 85% de acurácia, o gate metodológico definiu a configuração final (oráculo econômico na fase inicial e oráculo de maior acurácia na fase avançada) e tornou central o cenário de aprendizado com rótulos ruidosos. A tese entrega ainda a métrica LCE para comparação de curvas de aprendizado, a biblioteca aberta `activelearning` e a ferramenta FlowBuilder, com ingestão saneada de dados, execução parametrizada e curvas de aprendizado, que tornam o protocolo reutilizável em outros domínios.

Palavras-chave: Aprendizado Ativo. Classificação de Textos Curtos. Modelos de Linguagem de Grande Porte. FALCO. Rotulagem.

ABSTRACT

Short-text classification in Portuguese — such as product descriptions from electronic invoices, with abbreviated, noisy vocabulary and hundreds of categories — depends on large volumes of labels whose acquisition is the dominant cost of these systems. This thesis proposes and evaluates FALCO (Active Learning Framework with LLMs for Short Text), which integrates three cost-reduction fronts: informed composition of the initial training set, uncertainty-based active selection of instances, and partial replacement of the human annotator by oracles based on large language models (LLMs), organized in phases of increasing cost. The investigation uses an audited public dataset of 250,365 product descriptions across 621 categories and follows a pre-registered protocol with immutable partitions, paired analysis (McNemar, Wilcoxon), and traceable artifacts for every reported number. Four main results: (i) sensitivity to the composition of the initial set is highest in the low-label regime (a 6.4 percentage-point accuracy range at $|L_0| = 100$), and the proposed deterministic heuristic, DRI-SL — semantic density with lexical diversity, using no labels at all — outperforms the best individual found by a supervised genetic algorithm at every size from 100 to 5,000, a conservative comparison after the circularity correction that reduced the evolutionary envelope by up to 6.3 percentage points; (ii) zero-shot LLM oracles reach 77–83% accuracy in the closed space of 621 categories at costs of US\$ 0.035 to US\$ 0.92 per thousand labels, with Macro F1 above that of a light supervised classifier trained on 250 thousand labels, and nearly half of their errors concentrate on catalog conventions (sibling categories and umbrella classes); (iii) the measurement instrument matters: without output restriction to the class space, 6.8% of responses become spurious errors, and boundary rules in the prompt improve the weak model on the production distribution (+4.6 p.p., $p = 0.012$) at the cost of severe degradation on rare classes ($p < 0.001$); (iv) uncertainty strategies outperform random selection at the maximum significance achievable with 8 seeds ($p = 0.0078$), recovering 78% of the supervised ceiling’s Macro F1 with 15% of the labels, and this advantage survives intact under uniform oracle noise up to $\varepsilon = 0.4$ — covering the error range observed in the real LLMs. Since the best oracle fell short of the pre-registered 85% accuracy criterion, the methodological gate defined the final configuration (an economical oracle in the initial phase and the most accurate oracle in the advanced phase) and made learning with noisy labels the central scenario. The thesis also delivers the LCE metric for learning-curve comparison, the open-source `activelearning` library, and the FlowBuilder tool, with sanitized data ingestion, parameterized execution, and learning curves, which make the protocol reusable in other domains.

Keywords: Active Learning. Short Text Classification. Large Language Models. FALCO. Labeling.

LISTA DE FIGURAS

2.1	Arquitetura conceitual do ActiveLLM: o LLM atua como <i>seletor</i> de instâncias informativas — mitigando o <i>cold start</i> — enquanto a rotulagem permanece com um oráculo e o aprendizado com um modelo sucessor. Adaptado de Bayer e Reuter (2026).	31
4.1	Tendência da performance média (Acurácia e Macro F1) e intervalo mín–máx por tamanho de L_0 no teste T , escala logarítmica. Classificador PVBIn.	56

LISTA DE TABELAS

2.1	Componentes do arcabouço de aprendizado ativo	19
2.2	Comparação de alto nível das famílias de estratégias de seleção de consultas (Revisada).	27
2.3	Métricas Comuns para Classificação Multiclasse e sua Sensibilidade ao Desbalanceamento (Adaptado de (Grandini et al., 2020)).	40
3.1	Programa experimental da tese.	47
4.1	Evolução do AG (1 ^a vs. 100 ^a geração) — cenários de Acurácia. Envelope entre minimização e maximização.	57
4.2	<i>Cold start</i> : DRI-SL vs. envelope do AG (última geração), até $ L_0 = 5.000$. Classificador PVBIn.	58
4.3	Estudo de sensibilidade: original (30 rep.) vs. reexecução independente (10 rep., protocolo com deduplicação). Acurácia média.	58
5.1	E0 — desempenho dos oráculos LLM. Modo enum para OpenAI; json-prompt para MaaS/agregador (sem suporte a saída estruturada). IC = intervalo de Wilson 95%.	60
5.2	E0 — custo por mil rótulos (US\$) e taxa de acerto de <i>cache</i> de prefixo (S-rand; preços vigentes na execução, jul/2026)..	61
5.3	E0-P — ablação de <i>prompt</i> no gpt-4o-mini (enum, $b = 10$, $n = 500$ pareado por amostra). p : McNemar exato contra o v3.	63
5.4	E1 — estratégias com oráculo perfeito (média $\pm$ dp sobre 8 sementes; orçamento 3.000, lote 100). p : Wilcoxon pareado por semente contra a aleatória; com $n = 8$, o menor p atingível é 0,0078.. . . .	63
5.5	E4 — robustez ao ruído uniforme do oráculo (média $\pm$ dp, 8 sementes). Retenção: fração do Macro F1 final da mesma estratégia em $\varepsilon = 0$. p : Wilcoxon pareado entropia vs. aleatória no mesmo ε	64
F.1	Estatísticas Descritivas da Performance em Função do Tamanho de L0 (Classificador: PVBIn (1,2)-gram). 30 repetições por tamanho.	86

LISTA DE ACRÔNIMOS

AG	Algoritmo Genético
AL	<i>Active Learning</i> (Aprendizado Ativo)
ALC	<i>Area under the Learning Curve</i>
API	<i>Application Programming Interface</i>
AUC	<i>Area Under the Curve</i>
BERT	<i>Bidirectional Encoder Representations from Transformers</i>
DRI-SL	Densidade e Representatividade Informada — Semântica e Lexical
FALCO	<i>Framework de Aprendizado Ativo com LLM para texto CurtO</i>
IC	Intervalo de Confiança
LCE	<i>Learning Curve Efficiency</i> (Eficiência da Curva de Aprendizado)
LLM	<i>Large Language Model</i> (Modelo de Linguagem de Grande Porte)
NF-e	Nota Fiscal Eletrônica
PPGMNE	Programa de Pós-Graduação em Métodos Numéricos em Engenharia
PVBin	<i>Prototype Vector — Binary</i> (classificador por protótipos binários)
RQ	<i>Research Question</i> (Questão de Pesquisa)
SBERT	<i>Sentence-BERT</i>
SVD	<i>Singular Value Decomposition</i>
TF-IDF	<i>Term Frequency — Inverse Document Frequency</i>
UFPR	Universidade Federal do Paraná

LISTA DE SÍMBOLOS

L_0	conjunto inicial de instâncias rotuladas (<i>cold start</i>)
U	<i>pool</i> de instâncias não rotuladas
b	tamanho do lote (de seleção ou de rotulagem)
ε	taxa de ruído injetada no oráculo simulado
$\varepsilon_{\max}$	limiar de estagnação da transição de fases do FALCO
p	paciência (rodadas sem melhora) na transição de fases
n_1, n_K	orçamentos inicial e final da curva de aprendizado

SUMÁRIO

1	INTRODUÇÃO	11
1.1	PROBLEMA DE PESQUISA	11
1.2	LACUNA DE PESQUISA	12
1.3	QUESTÃO DE PESQUISA E HIPÓTESE	12
1.4	OBJETIVOS	13
1.5	DELIMITAÇÃO DA CONTRIBUIÇÃO	13
1.6	ORGANIZAÇÃO DO TRABALHO	14
2	FUNDAMENTAÇÃO TEÓRICA E REVISÃO DA LITERATURA	15
2.1	INTRODUÇÃO	15
2.2	CONCEITOS E DEFINIÇÕES DE APRENDIZADO DE MÁQUINA	15
2.2.1	Regimes de Supervisão	16
2.2.2	Classificação Multiclasse	16
2.2.3	Avaliação de Modelos de Classificação Multiclasse	17
2.2.4	Estratégias de Validação de Modelos	17
2.3	APRENDIZADO ATIVO.	18
2.4	FORMALIZAÇÃO DO APRENDIZADO ATIVO.	18
2.5	CENÁRIOS DE APRENDIZADO ATIVO.	20
2.5.1	Cenários Clássicos	20
2.5.2	Cenários Emergentes	22
2.5.3	Estratégias de Seleção de Consultas	23
2.5.4	Large Language Models como Oráculo no Aprendizado Ativo	27
2.6	CLASSIFICAÇÃO DE TEXTO CURTO.	30
2.6.1	Definições	31
2.6.2	Desafios da Classificação de Texto Curto.	32
2.6.3	Processo de Classificação e Pré-processamento	32
2.6.4	Vetorização e Representação de Texto Curto	34
2.6.5	Algoritmos de Classificação para Texto Curto	37
2.6.6	Avaliação e Validação.	38
2.6.7	Revisão Sistemática: Avanços Recentes em Aprendizado Ativo para Classificação de Texto Curto (2020-2026)	41
3	METODOLOGIA	47
3.1	DESENHO DA PESQUISA	47
3.2	CONJUNTO DE DADOS	48
3.2.1	Fonte e características.	48
3.2.2	Auditoria de qualidade dos rótulos	48

3.2.3	Pré-processamento e espaço de rótulos	49
3.2.4	Particionamento	49
3.3	CLASSIFICADORES DA TAREFA	49
3.4	MÉTRICAS DE AVALIAÇÃO E ANÁLISE ESTATÍSTICA	50
3.5	PILAR P1: COMPOSIÇÃO DO CONJUNTO INICIAL L_0	51
3.5.1	Sensibilidade à amostragem aleatória.	51
3.5.2	Otimização por algoritmo genético	51
3.6	PILAR P2: <i>COLD START</i> SEM RÓTULOS — ALGORITMO DRI-SL	51
3.7	PILAR P3: LLMS COMO ORÁCULO DE ROTULAGEM (EXPERIMENTO E0)	52
3.7.1	Instrumentação da medição	52
3.7.2	Desenho fatorial do E0	52
3.7.3	Critério de decisão para o FALCO	53
3.8	PILAR P4: O FRAMEWORK FALCO E SUA AVALIAÇÃO (EXPERIMENTOS E1–E4)	53
3.8.1	Componentes e fases	53
3.8.2	Métodos de referência e desenho do E3	54
3.9	AMEAÇAS À VALIDADE	54
3.10	REPRODUTIBILIDADE E AMBIENTE	55
4	RESULTADOS: COMPOSIÇÃO E CONSTRUÇÃO DO CONJUNTO INICIAL	56
4.1	SENSIBILIDADE À COMPOSIÇÃO E AO TAMANHO DE L_0	56
4.2	LIMITES POR OTIMIZAÇÃO EVOLUTIVA	57
4.3	DRI-SL <i>VERSUS</i> ALEATÓRIO E ENVELOPE DO AG	57
4.4	REEXECUÇÃO INDEPENDENTE E EFEITO DA CIRCULARIDADE	58
4.5	SÍNTESE DO CAPÍTULO	59
5	RESULTADOS: ORÁCULOS LLM E O FRAMEWORK FALCO	60
5.1	E0: AVALIAÇÃO FATORIAL DE ORÁCULOS LLM	60
5.1.1	RQ1 — assertividade	60
5.1.2	RQ2 — custo e o efeito do <i>cache</i>	61
5.1.3	RQ3 — perfil de erro	61
5.1.4	RQ4 — efeito do instrumento de medição	62
5.1.5	Sensibilidade ao ruído do gabarito e calibração do lote	62
5.2	E0-P: O PROMPT COMO VARIÁVEL DO INSTRUMENTO	62
5.3	E1: ESTRATÉGIAS DE SELEÇÃO COM ORÁCULO PERFEITO	63
5.4	E4: ROBUSTEZ DO APRENDIZADO AO RUÍDO DO ORÁCULO.	64
5.5	DECISÃO DO GATE E CONFIGURAÇÃO DO FALCO	64
6	DISCUSSÃO E CONCLUSÃO	66
6.1	SÍNTESE DOS ACHADOS	66
6.2	DISCUSSÃO	67

6.3	CONTRIBUIÇÕES	67
6.4	LIMITAÇÕES	67
6.5	TRABALHOS FUTUROS	68
6.6	CONCLUSÃO	68
	REFERÊNCIAS	69
	APÊNDICE A – MÉTRICA LEARNING CURVE EFFICIENCY (LCE) .	80
A.1	DEFINIÇÃO	80
A.2	PROPRIEDADES.	80
A.3	RELAÇÃO COM A ALC.	80
	APÊNDICE B – ALGORITMO GENÉTICO PARA OTIMIZAÇÃO DE L0	81
B.1	FORMULAÇÃO	81
B.2	OPERADORES E PARÂMETROS	81
B.3	PSEUDOCÓDIGO	81
	APÊNDICE C – ALGORITMO DRI-SL	82
C.1	OBJETIVO E ENTRADAS.	82
C.2	ETAPAS.	82
C.3	INTUIÇÃO	82
	APÊNDICE D – A BIBLIOTECA ACTIVELEARNING.	83
D.1	ARQUITETURA	83
D.2	REPRODUÇÃO DOS EXPERIMENTOS	83
D.3	FLOWBUILDER	83
	APÊNDICE E – PROMPTS E ESQUEMAS DO ORÁCULO LLM.	84
E.1	PROMPT V3 (PRODUÇÃO).	84
E.2	MODOS DE INSTRUMENTAÇÃO	84
E.3	VARIANTES DO E0-P.	84
	APÊNDICE F – TABELAS COMPLETAS	86

1 INTRODUÇÃO

A classificação de textos curtos é uma tarefa relevante em Processamento de Linguagem Natural (PLN), especialmente em contextos nos quais grandes volumes de registros textuais precisam ser organizados, filtrados ou categorizados automaticamente. Esse cenário aparece em aplicações como consultas, comentários, atendimento e descrições de produtos. A literatura mostra que textos curtos apresentam dificuldades específicas, como baixo contexto por instância, alta esparsidade, ruído e informalidade, o que torna sua classificação mais desafiadora do que a de documentos mais extensos (Alsmadi e Gan, 2019a; Song et al., 2014a).

No contexto da língua portuguesa, essas dificuldades se intensificam. Em aplicações como comércio eletrônico e cadastros operacionais, descrições curtas costumam apresentar abreviações, variações morfológicas, ruídos ortográficos e grande heterogeneidade lexical. Em trabalho anterior, voltado à classificação de descrições curtas de produtos em português, observou-se que métodos clássicos de recuperação da informação, como *bag-of-words*, TF e TF-IDF, podem alcançar desempenho relevante quando combinados com pré-processamento e parametrização adequados (Darú, 2024). Esse resultado confirma a relevância empírica do problema e fornece uma base concreta para investigações posteriores.

Ao mesmo tempo, o avanço dos modelos de linguagem pré-treinados alterou significativamente o estado da arte em PLN. O BERT mostrou que representações bidirecionais profundas, obtidas por pré-treinamento em texto não rotulado e posterior ajuste fino em tarefas específicas, podem produzir resultados de ponta em diversas tarefas (Devlin et al., 2019a). Para o português, o BERTimbau evidenciou que modelos monolíngues pré-treinados são particularmente relevantes em cenários com poucos dados anotados, superando o BERT multilíngue em tarefas importantes da língua (Souza et al., 2020). Por essa razão, esta tese adota um classificador baseado em BERTimbau na validação principal do framework proposto, reservando modelos mais leves para análises exploratórias específicas.

Apesar desses avanços, a limitação central permanece: dados não rotulados são abundantes, mas a obtenção de rótulos confiáveis continua custosa. Nesse contexto, o aprendizado ativo surge como alternativa promissora, ao selecionar iterativamente exemplos potencialmente mais informativos para anotação. No entanto, revisões recentes mostram que sua aplicação prática envolve dificuldades adicionais, como custo de anotação, critérios de parada, viabilidade computacional e reaproveitamento dos exemplos obtidos (Zhang et al., 2022a).

1.1 PROBLEMA DE PESQUISA

Embora o aprendizado ativo seja conceitualmente adequado para cenários com alto custo de rotulagem, sua aplicação em modelos modernos de PLN enfrenta limitações importantes. A principal delas é o problema de *cold start*: nas etapas iniciais, quando ainda há poucos exemplos

anotados, o sistema não dispõe de informação suficiente para selecionar instâncias realmente informativas. Além disso, o treinamento iterativo do modelo ao longo do ciclo de seleção pode ser caro e pouco prático. Assim, o problema central desta tese não é apenas classificar textos curtos em português com boa acurácia, mas **como reduzir o custo de rotulagem nesse contexto sem comprometer o desempenho final**, superando as limitações do aprendizado ativo tradicional nas fases iniciais do processo (Zhang et al., 2022a).

1.2 LACUNA DE PESQUISA

A literatura já consolidou os desafios da classificação de textos curtos e a força de modelos pré-treinados em cenários com poucos dados anotados (Alsmadi e Gan, 2019a; Song et al., 2014a; Devlin et al., 2019a; Souza et al., 2020). Trabalhos recentes, como o ActiveLLM, indicaram que modelos de linguagem de grande porte podem apoiar a seleção de instâncias em cenários com poucos exemplos, mitigando o *cold start* (Bayer e Reuter, 2026), e que LLMs podem atuar como rotuladores de baixo custo em ciclos de aprendizado ativo (Zhang e Takada, 2025a). Ainda assim, permanece uma lacuna específica: **falta uma formulação metodológica voltada ao português e ao problema de textos curtos que articule, de forma explícita e com validação empírica em cada componente, aprendizado ativo, classificação em baixo regime de supervisão e uso de modelos de linguagem para apoiar a fase inicial de seleção e rotulagem**. É nesse espaço que esta tese se posiciona.

1.3 QUESTÃO DE PESQUISA E HIPÓTESE

Diante dessa lacuna, esta tese é guiada pela seguinte questão de pesquisa:

Como estruturar um framework de aprendizado ativo para classificação de textos curtos em português que reduza o esforço de rotulagem, sem perda relevante de desempenho, utilizando modelos de linguagem para apoiar as fases iniciais do processo?

A hipótese central é que **um framework de aprendizado ativo apoiado por modelos de linguagem nas etapas iniciais pode reduzir a necessidade de rótulos sem perda relevante de desempenho final**. Para torná-la falseável, adota-se o seguinte critério quantitativo de aceitação: o framework proposto deve atingir, com no máximo 30% dos rótulos do *pool* (fornecidos por oráculo LLM), pelo menos 95% do Macro F1-Score obtido com supervisão completa, superando com significância estatística as estratégias de referência de amostragem aleatória e de incerteza pura sob o mesmo orçamento (Capítulo 3). A hipótese é condicional à qualidade do oráculo disponível: o protocolo prevê um *gate* pré-registrado de acurácia mínima do oráculo (Seção 3.7.3) e define de antemão o que conta como refutação — se nem o melhor oráculo aprovado sustentar o critério, a hipótese é considerada refutada *para o cardápio de oráculos avaliado*, e a tese reporta

o resultado com a decomposição que separa custo do ruído de rotulagem e custo da parcimônia de rótulos (quinto braço do E3, Seção 3.8.2).

1.4 OBJETIVOS

O objetivo geral é propor e avaliar o **FALCO**, um framework de aprendizado ativo para classificação de textos curtos em português, com uso de modelos de linguagem como oráculo de rotulagem e apoio à fase inicial de seleção, visando reduzir o custo de anotação e manter desempenho competitivo. A investigação é organizada em quatro pilares empíricos, que estruturam também os capítulos de resultados:

1. **P1 — composição do conjunto inicial:** quantificar o impacto da composição e do tamanho do conjunto inicial de rotulagem (L_0) na generalização do classificador, incluindo a estimativa de limites por otimização evolutiva;
2. **P2 — *cold start* sem rótulos:** propor e avaliar o algoritmo DRI-SL, que constrói um L_0 informativo sem acesso a rótulos, combinando densidade semântica e variedade lexical;
3. **P3 — LLM como oráculo:** medir, com instrumentação validada, a assertividade, o custo e o perfil de erro de LLMs como rotuladores para o domínio, derivando a configuração de oráculos do framework;
4. **P4 — o framework integrado:** avaliar o FALCO contra métodos de referência sob o mesmo orçamento, com testes de significância, verificando a hipótese central.

Transversalmente, propõe-se a métrica *Learning Curve Efficiency* (LCE) para sumarizar a eficiência de curvas de aprendizado, e disponibiliza-se a biblioteca *activelearning*, que implementa todo o instrumental com reprodutibilidade rastreável.

1.5 DELIMITAÇÃO DA CONTRIBUIÇÃO

Esta tese não propõe um novo modelo fundacional para o português nem um novo classificador de texto: sua contribuição está delimitada à **eficiência do processo de rotulagem**. Dois níveis de modelagem são usados de forma complementar — um classificador leve, derivado da linha investigada na dissertação de mestrado do autor (Darú, 2024), em análises exploratórias massivas, e um classificador baseado em BERTimbau na validação principal. Essa distinção isola a contribuição metodológica: a originalidade reside no processo de seleção e rotulagem, não no modelo de classificação. A tese também se distingue do trabalho anterior do autor, que investigou como classificar bem com dados já anotados; aqui a pergunta é **como obter, de forma eficiente, o conjunto anotado necessário**.

1.6 ORGANIZAÇÃO DO TRABALHO

Além desta introdução, o trabalho está organizado da seguinte forma. O Capítulo 2 apresenta os fundamentos de classificação de textos curtos, aprendizado ativo e modelos de linguagem, e a revisão sistemática da literatura recente. O Capítulo 3 descreve a metodologia: dados e sua auditoria, os quatro pilares, o programa experimental E0–E4 e o instrumental de reprodutibilidade. O Capítulo 4 apresenta os resultados sobre a composição e a construção do conjunto inicial (P1 e P2). O Capítulo 5 apresenta a avaliação dos oráculos LLM e do framework FALCO (P3 e P4). O Capítulo 6 discute os achados, limitações e trabalhos futuros. Os apêndices formalizam a métrica LCE, o algoritmo genético, o DRI-SL, a biblioteca `activelearning` e os *prompts* utilizados.

2 FUNDAMENTAÇÃO TEÓRICA E REVISÃO DA LITERATURA

2.1 INTRODUÇÃO

Este capítulo estabelece a base teórica sobre a qual o framework FALCO, proposto no Capítulo 3, é construído. Como discutido no Capítulo 1, a proposta articula três eixos que raramente aparecem combinados na literatura: aprendizado de máquina supervisionado em cenários de baixa disponibilidade de rótulos, aprendizado ativo como estratégia para reduzir o custo de rotulagem e classificação de textos curtos em português como domínio de aplicação desafiador. A revisão a seguir percorre esses três eixos na ordem em que se articulam na proposta, para então situar o estado da arte específico que motiva o FALCO.

A Seção 2.2 revisa, de forma deliberadamente enxuta, os conceitos de aprendizado de máquina dos quais esta tese depende — regimes de supervisão, classificação multiclasse, métricas e validação — necessários para interpretar as decisões metodológicas dos capítulos seguintes, em especial a escolha das métricas de avaliação (Acurácia Global e Macro F1-Score) usadas para comparar o FALCO com os métodos de referência. A Seção 2.3 aprofunda o formalismo do aprendizado ativo, os cenários de consulta (*pool-based*, *stream-based* e *query synthesis*), as principais estratégias de seleção de instâncias e, por fim, o papel emergente de modelos de linguagem de grande porte (LLMs) como oráculo e como agente de seleção — tema diretamente relacionado à estratégia adaptativa de oráculo progressivo adotada pelo FALCO. A Seção 2.6 caracteriza os desafios específicos da classificação de textos curtos, incluindo esparsidade lexical, baixo contexto por instância e informalidade, e discute etapas de pré-processamento, vetorização e algoritmos usados nesse domínio, com atenção particular ao português e ao contexto de descrições de produtos de e-commerce que motiva esta tese.

Por fim, a Seção 2.6.7 apresenta uma revisão sistemática focada nos avanços recentes que combinam aprendizado ativo, oráculos baseados em LLM e classificação de texto, delimitando a lacuna de pesquisa (Seção 1.2) que o FALCO busca preencher. A combinação dessas três frentes teóricas — aprendizado de máquina, aprendizado ativo e texto curto — não é meramente enciclopédica: cada uma delas informa diretamente uma decisão de projeto do framework, seja a escolha do classificador da tarefa (θ), a estratégia de seleção adaptativa entre fases, ou o uso de um oráculo LLM progressivo para mitigar o problema de *cold start*.

2.2 CONCEITOS E DEFINIÇÕES DE APRENDIZADO DE MÁQUINA

O aprendizado de máquina desenvolve algoritmos que melhoram seu desempenho em uma tarefa T , segundo uma métrica P , por meio da experiência E adquirida dos dados (Mitchell, 1997). Esta seção limita-se aos conceitos dos quais os capítulos seguintes dependem diretamente: os regimes de supervisão (que situam o aprendizado ativo), a tarefa de classificação multiclasse (a

tarefa-alvo da tese), as métricas de avaliação adotadas e as estratégias de validação. Um panorama abrangente de algoritmos e representações para classificação de texto pode ser encontrado em Kowsari et al. (2019).

2.2.1 Regimes de Supervisão

No **aprendizado supervisionado**, o algoritmo recebe exemplos de entrada com os rótulos desejados e induz uma função que generalize para dados não vistos (Russell e Norvig, 2010; Mitchell, 1997). No **não supervisionado**, não há rótulos: o algoritmo identifica estruturas latentes, como agrupamentos ou direções de maior variância (Murphy, 2012). O **semi-supervisionado** combina uma pequena parcela rotulada com muitos exemplos não rotulados, explorando a estrutura destes para melhorar a generalização (Chapelle et al., 2006).

O **aprendizado ativo** — objeto desta tese e formalizado na Seção 2.4 — ataca o mesmo gargalo do semi-supervisionado (o custo do rótulo) por via oposta: em vez de usar passivamente os dados não rotulados, o próprio algoritmo escolhe, de forma interativa, quais instâncias submeter a um oráculo para rotulagem, priorizando as de maior benefício esperado para o modelo (Settles, 2009). A distinção importa porque o desempenho passa a depender de duas políticas acopladas: a de seleção de instâncias e a de obtenção de rótulos — exatamente os dois eixos que o FALCO instrumenta.

2.2.2 Classificação Multiclasse

A tarefa-alvo desta tese é a **classificação**: aprender $f : X \rightarrow Y$ com Y discreto (Duda et al., 2001) — aqui, atribuir a cada descrição de produto uma dentre centenas de categorias. Com $K > 2$ classes, classificadores binários podem ser combinados (um-contra-todos, um-contra-um) (Rifkin e Klautau, 2004), mas os modelos usados nesta tese são multiclasse diretos: produzem um vetor de escores $(z_1, \dots, z_K)$ convertido em distribuição de probabilidade pela função *softmax*,

$$p_i = \frac{\exp(z_i)}{\sum_{j=1}^K \exp(z_j)}, \quad i = 1, \dots, K, \quad (2.1)$$

treinados com perda de entropia cruzada (Bishop, 2006; Murphy, 2012). Essa distribuição p é duplamente essencial no aprendizado ativo: além de fornecer a predição ($\arg \max_i p_i$), é dela que as estratégias de seleção por incerteza (Seção 2.5.3.1) derivam seus escores. Os dois classificadores empregados nos experimentos — um modelo probabilístico vetorial leve e o BERTimbau ajustado com uma camada de classificação (Souza et al., 2020) — são detalhados no Capítulo 3.

2.2.3 Avaliação de Modelos de Classificação Multiclasse

A **acurácia** é a proporção de predições corretas,

$$A = \frac{n_{\text{corretas}}}{N}, \quad (2.2)$$

mas é inadequada como métrica única sob desbalanceamento de classes: um classificador que prediz sempre a classe majoritária obtém acurácia alta ignorando as minoritárias (Sokolova e Lapalme, 2009). Por isso usam-se métricas por classe. Para uma classe tomada como positiva, com TP , FP e FN denotando verdadeiros positivos, falsos positivos e falsos negativos,

$$\text{Precisão} = \frac{TP}{TP + FP}, \quad \text{Revocação} = \frac{TP}{TP + FN}, \quad (2.3)$$

e o **F1-Score** é sua média harmônica,

$$F_1 = 2 \cdot \frac{\text{Precisão} \cdot \text{Revocação}}{\text{Precisão} + \text{Revocação}}. \quad (2.4)$$

No cenário multiclasse, a agregação **macro** calcula a métrica por classe e tira a média aritmética, dando peso igual a todas as classes independentemente da frequência; a agregação **micro** soma TP , FP e FN globais antes de aplicar a fórmula, refletindo sobretudo as classes majoritárias (Sokolova e Lapalme, 2009). Em bases com forte desbalanceamento — caso do conjunto de dados desta tese — o **Macro F1-Score** é a métrica principal, por expor o desempenho nas classes raras. A **matriz de confusão** $K \times K$, cuja entrada $[i, j]$ conta exemplos da classe real i preditos como j , complementa as métricas agregadas ao revelar confusões sistemáticas entre pares de classes (Han et al., 2012) — instrumento usado no Capítulo 3 para caracterizar o perfil de erro dos oráculos LLM.

2.2.4 Estratégias de Validação de Modelos

Avaliar um modelo nos mesmos dados de treino superestima seu desempenho (*overfitting*); a validação exige dados independentes (Kohavi, 1995). As práticas empregadas nesta tese são: (i) **hold-out**, separação treino/teste, adequada a bases grandes como a nossa; (ii) **validação cruzada k -fold estratificada**, que particiona os dados em k dobras preservando as proporções de classe — essencial sob desbalanceamento — e média o desempenho das k rodadas (Kohavi, 1995); e (iii) um conjunto de **validação** separado do teste para ajuste de hiperparâmetros, mantendo o teste intocado até a avaliação final (Bishop, 2006). Uma exigência adicional específica desta tese, motivada pela auditoria da base (Capítulo 3): como descrições de produto se repetem, o particionamento deduplica por texto normalizado *antes* do sorteio, prevenindo vazamento treino→teste por duplicatas exatas.

2.3 APRENDIZADO ATIVO

O *Aprendizado Ativo* (AA) constitui um paradigma de aprendizado de máquina que maximiza a eficiência de rotulagem ao permitir que o sistema selecione, de forma interativa, as amostras mais informativas para anotação (Settles, 2012). Enquanto métodos supervisionados tradicionais requerem grandes volumes de dados rotulados, o AA explora o fato de que instâncias não rotuladas costumam estar disponíveis em abundância e a baixo custo (Zhu e Goldberg, 2009).

As origens do AA remontam a trabalhos seminais, como o de Angluin (1988) sobre aprendizado via consultas de associação e o de Cohn et al. (1994) acerca da redução de incerteza em aprendizado supervisionado. Contudo, foi o estudo abrangente de Settles (2012) que consolidou os fundamentos teóricos e práticos do campo, estabelecendo uma taxonomia clara para cenários e estratégias de consulta.

Em muitos contextos, a anotação de dados incorre em custos elevados, seja pela necessidade de especialistas ou pelo tempo humanamente dispendioso. Por exemplo, a rotulagem de imagens médicas exige avaliação de radiologistas, e a anotação de transcrições de fala pode demandar até dez vezes a duração da gravação original (Settles, 2012). Nesses casos, o AA emerge como alternativa quando a rotulagem se torna o principal gargalo para o desenvolvimento de modelos robustos.

Com a popularização do *deep learning*, o AA adquiriu novas dimensões, originando a área de *Deep Active Learning* (DAL), investigada intensamente na última década (Ren et al., 2021). Mais recentemente, o surgimento dos *Large Language Models* (LLMs) abriu oportunidades adicionais: esses modelos podem atuar como oráculos de rotulagem ou como agentes na seleção de instâncias (Bayer e Reuter, 2024).

Este capítulo apresenta uma análise abrangente do AA, cobrindo desde seus fundamentos teóricos até aplicações recentes envolvendo *deep learning* e LLMs. Primeiramente, são discutidas as definições formais e os cenários clássicos do paradigma. Em seguida, apresentam-se as principais estratégias de seleção de instâncias e os componentes de um sistema de AA. A integração com *deep learning* e o emprego de LLMs como oráculos são examinados em detalhe. Por fim, uma revisão sistemática da literatura de 2015 até o presente fornece um panorama atualizado do estado da arte.

2.4 FORMALIZAÇÃO DO APRENDIZADO ATIVO

No aprendizado supervisionado tradicional parte-se de um conjunto fixo de pares rotulados $L = \{(x_i, y_i)\}_{i=1}^n$, em que $x_i \in \mathcal{X}$ e $y_i \in \mathcal{Y}$. A meta é ajustar uma função $f : \mathcal{X} \rightarrow \mathcal{Y}$ que minimize o risco esperado sobre novos dados provenientes da mesma distribuição.

O *aprendizado ativo* acrescenta um componente interativo: além do lote inicial rotulado L , dispõe-se de um conjunto de instâncias não rotuladas $U = \{x_j\}_{j=1}^m \subseteq \mathcal{X}$ com $L \cap U = \emptyset$. Em cada iteração aplica-se uma **regra de seleção** $S : (U_t, \theta_t, L_t) \rightarrow Q_t \subseteq U_t$, a qual, a partir do lote corrente, do modelo θ_t e da história de rótulos L_t , escolhe um **lote** Q_t de instâncias a

serem consultadas ($|Q_t| = b_t \geq 1$). O oráculo rotula todas as instâncias de Q_t ; os novos pares são acrescentados a L_t ; o processo prossegue até que o orçamento B se esgote ou algum critério de parada seja satisfeito. Esse esquema unifica tanto o modo *batch* ($b_t > 1$) quanto o modo *stream* ($b_t = 1$; S degenera para uma escolha binária em cada amostra observada).

Entre as muitas formulações existentes — por exemplo, (Settles, 2012), (Roy e McCallum, 2001) e *et al.* (Goudjil et al., 2018) — adapta-se aqui o arcabouço proposto por Cohn, Ghahramani e Jordan, posteriormente ampliado por Hanneke (Cohn et al., 1996; Hanneke, 2015), com o fundamento de (Goudjil et al., 2018) e (Settles, 2012), para incorporar um modelo mais abrangente.

Definição 2.1 (Aprendizado Ativo) *Aprendizado ativo é representado, neste trabalho, pela sêxtupla*

$$\mathcal{A} = \langle L, U, \theta, S, O, B \rangle,$$

em que L é um conjunto de exemplos rotulados, U um conjunto de exemplos não rotulados, θ denota o estado do modelo supervisionado atualizado a partir de L , S é uma regra de seleção que indica os exemplos de U a serem consultados, O é o oráculo que fornece o rótulo correto para cada instância, e B corresponde ao orçamento, eventualmente infinito, de consultas possíveis ao oráculo.

Um resumo de cada componente é fornecido pela Tabela 2.1.

Tabela 2.1: Componentes do arcabouço de aprendizado ativo

Símbolo	Definição formal	Descrição
L	$L = \{(x_i, y_i)\}_{i=1}^n \subseteq \mathcal{X} \times \mathcal{Y}$	Conjunto de exemplos rotulados
U	$U = \{x_j\}_{j=1}^m \subseteq \mathcal{X}$	Instâncias não rotuladas disponíveis
θ	$\theta \in \Theta$	Modelo treinado em L
S	$S : (U_t, \theta_t, L_t) \mapsto Q_t \subseteq U_t$	Regra que determina o lote Q_t enviar para o oráculo
O	$O : \mathcal{X} \rightarrow \mathcal{Y}$	Oráculo que devolve o rótulo verdadeiro $y = O(x)$
B	$B \in \mathbb{N}$	Orçamento de consultas restantes

Os elementos apresentados na Tabela 2.1 interagem de forma estruturada para compor o ciclo do aprendizado ativo, conforme discutido em (Settles, 2012) e (Goudjil et al., 2018) e é apresentado no Algoritmo 1 a seguir.

Algoritmo 1 Esquema geral de aprendizado ativo

- 1: **1. Inicialização:** definir os conjuntos iniciais e orçamento.
 - 2: $L_0 \leftarrow$ conjunto de exemplos rotulados iniciais
 - 3: $U_0 \leftarrow$ conjunto de exemplos não rotulados
 - 4: $B_0 \leftarrow$ orçamento inicial de consultas
 - 5: **2. Laço principal:** enquanto houver orçamento e instâncias não rotuladas, repetir:
 - 6: Atualiza-se o modelo com base no conjunto rotulado atual:
 - 7: $\theta_t \leftarrow \text{Learn}(L_t)$
 - 8: Seleciona-se um lote de exemplos a serem rotulados:
 - 9: $Q_t \leftarrow S(U_t, \theta_t, L_t)$
 - 10: Consulta-se o oráculo para obter os rótulos correspondentes:
 - 11: $\forall x \in Q_t, y \leftarrow O(x)$
 - 12: Atualizam-se os conjuntos e o orçamento:
 - 13: $L_{t+1} \leftarrow L_t \cup \{(x, y) : x \in Q_t\}$
 - 14: $U_{t+1} \leftarrow U_t \setminus Q_t$
 - 15: $B_{t+1} \leftarrow B_t - |Q_t|$
 - 16: Incrementa-se a iteração:
 - 17: $t \leftarrow t + 1$
 - 18: **3. Finalização:** ao fim do laço, retorna-se o modelo final.
 - 19: $\theta_{\text{final}} \leftarrow$ modelo treinado em L_T
-

O desempenho do aprendizado ativo depende principalmente do cenário em que é aplicado e da estratégia de seleção definida pela função de utilidade $\mathcal{U}$. As seções seguintes examinam esses cenários e apresenta as principais famílias de critérios de seleção discutidas na literatura.

2.5 CENÁRIOS DE APRENDIZADO ATIVO

Os cenários de aprendizado ativo referem-se aos diferentes contextos e configurações nos quais o aprendizado ativo pode ser aplicado. Estes cenários diferem principalmente em como as instâncias não rotuladas são obtidas e apresentadas ao modelo, e nas restrições impostas ao processo de consulta. Nesta seção, exploramos os cenários clássicos bem estabelecidos na literatura, bem como cenários emergentes que têm ganhado relevância recentemente.

2.5.1 Cenários Clássicos

Tradicionalmente, três cenários principais têm sido estudados na literatura de aprendizado ativo (Settles, 2012):

Síntese de Consultas (Membership Query Synthesis) No cenário de síntese de consultas, o algoritmo de aprendizado pode gerar instâncias sintéticas para rotulação. Não há restrições quanto ao espaço de instâncias possíveis, permitindo que o algoritmo explore livremente este espaço.

Formalmente, a cada iteração t , o algoritmo sintetiza uma instância x_t^* e solicita seu rótulo y_t^* a um oráculo. Este cenário é particularmente útil em domínios onde a geração de instâncias é viável e significativa, como em ambientes simulados ou domínios com espaços de instâncias bem definidos.

Uma limitação importante deste cenário é que as instâncias sintéticas podem não ter significado prático ou podem ser difíceis de interpretar para anotadores humanos. Por exemplo, em processamento de imagens, o algoritmo pode gerar padrões visuais irreconhecíveis; em processamento de linguagem natural, pode gerar sequências de texto sem sentido semântico (Baum e Lang, 1992).

Amostragem Seletiva em Fluxo (Stream-Based Selective Sampling) : Na amostragem seletiva em fluxo, as instâncias não rotuladas são apresentadas ao algoritmo sequencialmente, uma por vez, advindas de uma distribuição natural. Para cada instância x_t , o algoritmo decide se deve ou não solicitar seu rótulo ao oráculo.

Esta decisão pode ser baseada em alguma medida de “informatividade” da instância, ou na determinação de uma “região de incerteza” no espaço de instâncias. Instâncias que caem dentro desta região são consideradas informativas e são selecionadas para rotulação.

Formalmente, a cada iteração t , dada uma instância x_t advinda de uma distribuição D , o algoritmo decide solicitar seu rótulo se $\mathcal{U}(x_t) > \tau$, onde $\mathcal{U}$ é uma função de utilidade e τ é um limiar predefinido.

Este cenário é particularmente relevante em aplicações onde os dados chegam naturalmente em fluxo, como em sensoriamento contínuo, processamento de fluxos de mídia social, ou sistemas de monitoramento em tempo real (Dagan e Engelson, 1995).

Aprendizado Ativo com Acervo Fixo (Pool-Based Active Learning) No cenário baseado em acervo fixo, assume-se que existe um conjunto finito de instâncias não rotuladas U disponível desde o início. A cada iteração, o algoritmo seleciona a instância mais informativa deste conjunto para rotulação.

Formalmente, a cada iteração t , o algoritmo seleciona $x_t^* = \arg \max_{x \in U_t} \mathcal{U}(x)$, onde U_t é o conjunto de instâncias não rotuladas disponíveis na iteração t .

Este é o cenário mais comum na prática, pois em muitas aplicações reais é possível coletar um grande conjunto de dados não rotulados antes de iniciar o processo de rotulação. Exemplos incluem classificação de textos, reconhecimento de imagens, e muitas outras tarefas de aprendizado supervisionado (Lewis e Gale, 1994).

2.5.2 Cenários Emergentes

Além dos cenários clássicos, novos cenários têm emergido para abordar desafios específicos ou explorar novas capacidades em aprendizado ativo, a lista abaixo, não extensiva, apresenta alguns julgados importantes para este trabalho:

Aprendizado Ativo em Lote (Batch-Mode Active Learning) No aprendizado ativo em lote, o algoritmo seleciona múltiplas instâncias simultaneamente para rotulação a cada iteração (Hoi et al., 2006). Este cenário é particularmente relevante quando há paralelismo disponível no processo de rotulação (por exemplo, múltiplos anotadores) ou quando o retreinamento do modelo após cada única instância rotulada é computacionalmente custoso.

Formalmente, a cada iteração t , o algoritmo seleciona um conjunto de instâncias $B_t = \{x_{t,1}^*, x_{t,2}^*, \dots, x_{t,b}^*\} \subset U_t$ de tamanho b para rotulação. A seleção deve considerar não apenas a informatividade individual de cada instância, mas também a diversidade e complementaridade entre as instâncias selecionadas.

Aprendizado Ativo Federado. O *aprendizado ativo federado* (Federated Active Learning – FAL) é um paradigma que combina os princípios do aprendizado federado com técnicas de aprendizado ativo, permitindo que múltiplos clientes (como dispositivos ou instituições) selecionem, de forma local e autônoma, os exemplos mais informativos a serem rotulados, sem a necessidade de compartilhar dados brutos com um servidor central. Essa abordagem visa preservar a privacidade dos dados distribuídos, reduzir os custos de anotação e melhorar a eficiência do treinamento em cenários com dados não-IID. Enquanto o aprendizado federado tradicional já possibilita o treinamento colaborativo de modelos sem centralização dos dados (Deng et al., 2023), o aprendizado ativo federado estende essa capacidade ao introduzir mecanismos de seleção ativa de amostras nos clientes locais, como demonstrado em (Deng et al., 2023) com a proposta do framework KAFAL .

Aprendizado Ativo com Múltiplos Oráculos Em cenários reais, pode haver múltiplos oráculos (anotadores) disponíveis, com diferentes níveis de expertise, custos e disponibilidade (Yan et al., 2011). O algoritmo deve decidir não apenas quais instâncias rotular, mas também qual oráculo consultar para cada instância.

Este cenário é particularmente relevante em plataformas de *crowdsourcing*, onde múltiplos anotadores com diferentes habilidades estão disponíveis para tarefas de rotulação. E em cenários atuais tem-se diversos grandes modelos de linguagem com capacidades e custos distintos, atendendo a este cenário.

2.5.3 Estratégias de Seleção de Consultas

O componente central que define um algoritmo de aprendizado ativo é a sua **estratégia de seleção de consultas** (*query selection strategy*). Este mecanismo determina qual instância, dentre um conjunto de dados não rotulados, deve ser selecionada para apresentação ao oráculo (tipicamente um especialista humano, um experimento ou um modelo de linguagem) a fim de obter seu rótulo verdadeiro. O objetivo principal é maximizar a utilidade informacional de cada consulta, de forma a otimizar o processo de aprendizado e reduzir significativamente o esforço de rotulagem necessário para atingir um nível de desempenho pré-definido para o modelo preditivo (Settles, 2012). Conforme postulado por Shannon (1948), informação representa a resolução da incerteza, e as diversas estratégias de aprendizado ativo podem ser entendidas como diferentes métodos para buscar ativamente a informação que mais eficientemente reduz a incerteza do modelo ou aprimora sua capacidade de generalização.

As metodologias propostas na literatura podem ser agrupadas em famílias distintas, baseadas nos princípios heurísticos que as norteiam. As principais linhas incluem a amostragem baseada na incerteza do modelo, a exploração da estrutura do espaço de hipóteses através do desacordo entre modelos, a otimização direta da redução do erro esperado ou da variância, e o aproveitamento da estrutura intrínseca da distribuição dos dados. Cada uma dessas vertentes apresenta um conjunto particular de benefícios e limitações, tornando a escolha da estratégia mais adequada uma decisão dependente do contexto, como discutido por Settles (2012).

2.5.3.1 Amostragem por Incerteza (*Uncertainty Sampling*)

Esta família de estratégias é, possivelmente, a mais intuitiva e uma das mais frequentemente empregadas na prática (Lewis e Catlett, 1994; Settles, 2012). O princípio fundamental é que as instâncias não rotuladas sobre as quais o modelo preditivo atual demonstra maior grau de incerteza são as mais prováveis de fornecer informação para o refinamento do modelo. O algoritmo seleciona, a cada iteração, a instância x^* do conjunto não rotulado U que maximiza alguma medida quantitativa de incerteza $\phi_A(x)$. O princípio norteador é, portanto, selecionar a instância que induz a maior ambiguidade ou "confusão" nas predições do modelo corrente.

Esta abordagem oferece como benefícios a simplicidade conceitual e de implementação, juntamente com um baixo custo computacional na maioria dos casos, pois requer apenas a avaliação das saídas (probabilidades ou confianças) do modelo já treinado. Sua aplicabilidade é geral a qualquer modelo capaz de produzir tais saídas, e possui justificativa teórica em conjunto com classificadores de margem máxima, como Máquinas de Vetores de Suporte (SVMs), onde se relaciona com a bissecção do espaço de versão (Tong e Koller, 2000; Settles, 2012). Continua sendo uma linha de base forte e frequentemente utilizada, inclusive em contextos modernos de *deep learning* (Gal et al., 2017).

Contudo, a amostragem por incerteza possui limitações significativas. É uma estratégia inerentemente **míope**, baseando-se exclusivamente na perspectiva de um único modelo, que

pode ser impreciso ou enviesado, especialmente nas fases iniciais do aprendizado. Além disso, apresenta suscetibilidade à seleção de **outliers** ou instâncias ruidosas, que podem exibir alta incerteza por serem atípicas e pouco informativas sobre a distribuição geral dos dados (Settles, 2012). Seu desempenho também pode ser subótimo em cenários com distribuições de classes desbalanceadas, nos quais o foco na fronteira da classe majoritária tende a negligenciar as classes raras (Settles, 2012; Attenberg e Provost, 2010).

As medidas de incerteza mais comuns incluem:

Menor Confiança (*Least Confident* - LC): Seleciona a instância x para a qual a classe predita com maior probabilidade, $\hat{y} = \arg \max_y P_\theta(y|x)$, possui o menor valor de probabilidade $P_\theta(\hat{y}|x)$. Esta medida foca na confiança da "melhor" predição do modelo e pode ser interpretada como a maximização da perda 0/1 esperada, conforme percebida pelo modelo. Sua principal limitação reside em ignorar a informação contida nas probabilidades das classes alternativas.

$$x_{LC}^* = \arg \max_x [1 - P_\theta(\hat{y}|x)] \quad (2.5)$$

Margem (*Margin Sampling* - M): Seleciona a instância x onde a diferença (margem) entre a probabilidade da classe mais provável, $\hat{y}_1$, e a segunda classe mais provável, $\hat{y}_2$, é mínima. Esta abordagem concentra-se na dificuldade do modelo em discriminar entre as duas alternativas mais plausíveis. Contudo, ainda ignora grande parte da distribuição de probabilidade, o que pode ser relevante em problemas com muitas classes.

$$x_M^* = \arg \min_x [P_\theta(\hat{y}_1|x) - P_\theta(\hat{y}_2|x)] \quad (2.6)$$

Entropia (*Entropy Sampling* - H): Utiliza a entropia de Shannon da distribuição de probabilidade preditiva $P_\theta(Y|x)$ como medida de incerteza. Seleciona a instância x que maximiza essa entropia, indicando uma distribuição mais uniforme e, portanto, maior incerteza geral sobre o rótulo. Pode ser interpretada como a maximização do log-loss esperado e é frequentemente considerada a medida mais abrangente, pois considera toda a distribuição de probabilidade.

$$x_H^* = \arg \max_x H_\theta(Y|x) = \arg \max_x \left[- \sum_y P_\theta(y|x) \log P_\theta(y|x) \right] \quad (2.7)$$

2.5.3.2 Busca pelo Espaço de Versão e Baseado em Desacordo

Esta família de estratégias parte da noção de **espaço de versão** (V), definido como o subconjunto de todas as hipóteses possíveis (H) que são consistentes com o conjunto de dados rotulados (L) disponível (Mitchell, 1982). O objetivo é selecionar consultas que reduzam o tamanho ou volume de V o mais eficientemente possível, eliminando hipóteses inconsistentes e convergindo para a hipótese alvo verdadeira (assumindo que ela exista em H e os dados não

sejam ruidosos). O princípio norteador é selecionar a instância que causa o maior **desacordo** (*disagreement*) entre as hipóteses candidatas ainda consideradas plausíveis (membros de V ou de um comitê que o aproxima), de modo que seu rótulo permita eliminar o maior número possível dessas hipóteses.

Esta abordagem oferece a vantagem de abordar explicitamente a ambiguidade no espaço de modelos, sendo potencialmente menos míope que a amostragem por incerteza pura. Possui fundamentação teórica robusta em certos cenários, como o algoritmo *Query by Disagreement*(QBD) que pode oferecer melhorias exponenciais na complexidade de amostragem (Cohn et al., 1994; Hanneke, 2015), e pode ser interpretada em termos de maximização da informação mútua (Settles, 2012).

As principais implementações incluem:

Consulta por Desacordo (*Query by Disagreement* - QBD): O algoritmo canônico (Cohn et al., 1994) propõe manter o espaço de versão V e consultar qualquer instância x para a qual existam pelo menos duas hipóteses $h_1, h_2 \in V$ que discordem em sua predição ($h_1(x) \neq h_2(x)$). Na prática, aproximações são usadas.

Consulta por Comitê (*Query by Committee* - QBC): Esta é a abordagem mais prática e difundida desta família (Seung et al., 1992; Freund et al., 1997). Utiliza-se um **comitê** (ou *ensemble*) C de hipóteses $\{h_1, \dots, h_{|C|}\}$ como uma amostra representativa ou uma aproximação de V . A consulta é direcionada para as instâncias onde os membros do comitê apresentam o maior grau de desacordo. A formação do comitê pode usar técnicas como amostragem Bayesiana (McCallum e Nigam, 1998), *Bagging* (Abe e Mamitsuka, 1998), *Boosting*, ou exploração de múltiplas visões (Muslea et al., 2000; Blum e Mitchell, 1998). A diversidade entre os membros é um fator relevante (Melville e Mooney, 2004). As medidas de desacordo incluem Entropia de Votos (VE, Eq. 2.8), Entropia de Votos Suave (SVE, Eq. 2.9) e Divergência Kullback-Leibler (KL, Eq. 2.10).

$$x_{VE}^* = \arg \max_x \left[- \sum_y \frac{\text{vote}_C(y, x)}{|C|} \log \frac{\text{vote}_C(y, x)}{|C|} \right] \quad (2.8)$$

$$x_{SVE}^* = \arg \max_x \left[- \sum_y P_C(y|x) \log P_C(y|x) \right] \quad (2.9)$$

$$x_{KL}^* = \arg \max_x \frac{1}{|C|} \sum_{h \in C} \text{KL}[P_h(Y|x) || P_C(Y|x)] \quad (2.10)$$

2.5.3.3 Redução do Erro Esperado ou Variância

Esta classe de estratégias adota uma perspectiva explícita de **teoria da decisão** (Roy e McCallum, 2001; Settles, 2012). O objetivo é selecionar a consulta x que, em expectativa

sobre seu rótulo verdadeiro y , levará a um novo modelo θ^+ que minimize o erro de generalização esperado ou a variância de saída sobre as instâncias não rotuladas restantes U . O princípio subjacente é escolher a instância cuja rotulagem esperada proporcione a maior redução no erro ou na variância preditiva do modelo sobre a distribuição de dados futura.

Um benefício chave é a otimização direta do objetivo final do aprendizado (ou uma proxy fortemente relacionada como a variância), o que levou a um forte desempenho empírico em diversas tarefas quando a computação é viável (Roy e McCallum, 2001). A Redução de Variância, em particular, possui fundamentação na teoria estatística de Desenho Ótimo de Experimentos (MacKay, 1992; Cohn et al., 1996) e permite tratamento natural de consultas em lote via otimização submodular (Guestrin et al., 2005; Golovin e Krause, 2011; Krause e Golovin, 2014).

A principal barreira, no entanto, é o **custo computacional extremamente elevado**. A Redução de Erro tipicamente exige re-treinamento do modelo para cada par candidato (x, y) e avaliação em todo o U . A Redução de Variância, embora com forma fechada em alguns casos, envolve cálculos matriciais (como inversão da matriz de informação de Fisher) que escalam pobremente com a dimensionalidade do problema ($O(UK^3)$ ou pior), limitando sua aplicabilidade prática. Sua aplicação também é mais natural para certas classes de modelos.

2.5.3.4 Exploração da Estrutura dos Dados

Reconhecendo que as metodologias anteriores podem ignorar informações importantes contidas na distribuição das próprias instâncias de entrada $P(X)$, esta família de abordagens busca incorporar explicitamente informações sobre a estrutura dos dados não rotulados no processo de seleção de consultas. O princípio é selecionar instâncias que sejam não apenas informativas (do ponto de vista do modelo ou do espaço de hipóteses), mas também **representativas** da distribuição de entrada subjacente, por exemplo, localizando-se em regiões de alta densidade ou sendo centrais a agrupamentos (clusters) de dados.

Esta abordagem pode mitigar o problema de seleção de outliers, buscando um equilíbrio entre explorar regiões incertas e explorar regiões representativas. Algumas variantes, como a ponderação por densidade, podem ter baixo custo computacional adicional, enquanto outras, como a Amostragem Hierárquica, oferecem garantias teóricas e robustez (Dasgupta e Hsu, 2008).

Entretanto, a eficácia destas técnicas depende da hipótese (nem sempre válida) de que a estrutura dos dados está correlacionada com a distribuição dos rótulos. Adicionalmente, o custo computacional para determinar a própria estrutura dos dados (e.g., calcular similaridades, realizar clusterização) pode ser significativo.

As principais abordagens incluem:

Ponderação pela Densidade (*Density Weighting*): Combina uma medida de utilidade base $\phi_A(x)$ (e.g., incerteza) com um termo que quantifica a densidade ou representatividade de x . A estratégia de **Densidade de Informação (ID)** é um exemplo:

$$x_{ID}^* = \arg \max_x \phi_A(x) \times (\text{Representatividade}(x))^\beta \quad (2.11)$$

onde $\text{Representatividade}(x)$ pode ser a similaridade média de x com outras instâncias em U , e β controla o peso da densidade (Settles e Craven, 2008).

Aprendizado Ativo Baseado em Cluster (*Cluster-Based*): Utiliza técnicas de clusterização para agrupar U . As consultas podem ser direcionadas aos centróides dos clusters (Nguyen e Smeulders, 2004), a instâncias representativas de clusters informativos, ou através de métodos como a **Amostragem Hierárquica** (Dasgupta e Hsu, 2008). Esta última mantém uma estrutura hierárquica e seleciona clusters para amostragem com base em tamanho e impureza estimada, consultando instâncias aleatórias dentro deles.

2.5.3.5 Sumário Comparativo e Conclusões

A Tabela 2.2 resume as principais características das famílias de estratégias de seleção discutidas.

Tabela 2.2: Comparação de alto nível das famílias de estratégias de seleção de consultas (Revisada).

Estratégia de Consulta	Vantagens Principais	Desvantagens Principais
Amostragem por Incerteza	Simples, rápida, fácil implementação, aplicabilidade geral.	Míope, suscetível a outliers, pode falhar com desbalanceamento.
Baseado em Desacordo / QBC	Menos míope, explora espaço de hipóteses, garantias teóricas.	Custo do comitê, sensível a ruído (V puro), depende da qualidade do comitê.
Redução de Erro / Variância	Otimiza objetivo final (erro/variância), base teórica sólida.	Muito caro computacionalmente , aplicabilidade restrita (RV).
Exploração Estrutura Dados	Mitiga outliers, equilibra exploração/exploração.	Depende da correlação estrutura-rótulo, custo de calcular estrutura.

2.5.4 Large Language Models como Oráculo no Aprendizado Ativo

O surgimento de *Large Language Models* (LLMs) como GPT-4, Claude, Llama e outros trouxe novas possibilidades para o campo de aprendizado ativo. Estes modelos possuem capacidades impressionantes de compreensão e geração de texto, e têm demonstrado desempenho notável em diversas tarefas de processamento de linguagem natural, mesmo em cenários de poucos exemplos (*few-shot*) ou zero-shot. Nesta seção, exploramos como os LLMs podem ser utilizados como oráculos no processo de aprendizado ativo e as implicações desta abordagem (Bayer e Reuter, 2024).

2.5.4.1 LLMs como Substitutos de Anotadores Humanos

Tradicionalmente, o oráculo no aprendizado ativo é um especialista humano que fornece rótulos para as instâncias selecionadas pelo algoritmo. No entanto, a anotação humana pode ser cara, demorada e sujeita a inconsistências (Settles, 2012). LLMs surgem como uma alternativa promissora, podendo atuar como pseudo-oráculos para fornecer rótulos em determinados contextos (Zhang et al., 2022b). A evidência seminal nessa direção é o estudo de Gilardi et al. (2023), que comparou o ChatGPT em modo *zero-shot* com anotadores da plataforma MTurk e anotadores treinados em 6.183 textos: o LLM superou os *crowd-workers* em cerca de 25 pontos percentuais de acurácia média, com maior concordância intercodificador e custo por anotação aproximadamente 30 vezes menor. Cabe a ressalva, central para esta tese, de que tais resultados foram obtidos em tarefas com poucas classes (relevância, postura, tópicos); a transferência desse desempenho para espaços de rótulos com centenas de categorias — o regime dos experimentos do Capítulo 3 — não é automática e constitui precisamente uma das perguntas experimentais deste trabalho.

Esta abordagem apresenta diversas vantagens potenciais. A **escalabilidade** é um fator chave, pois LLMs podem processar grandes volumes de instâncias sem as limitações de disponibilidade e fadiga inerentes aos anotadores humanos. Adicionalmente, tendem a oferecer maior **consistência** nas anotações, evitando variações entre diferentes indivíduos. Em termos de **custo**, embora o acesso a APIs de LLMs possa ter um valor associado, este pode ser significativamente menor que o custo de contratar especialistas humanos, especialmente para domínios complexos. Finalmente, a **velocidade** de anotação via LLM pode acelerar consideravelmente o ciclo iterativo do aprendizado ativo.

Contudo, a utilização de LLMs como oráculos também enfrenta desafios e limitações importantes. A **qualidade das anotações** pode não atingir o nível de precisão de especialistas humanos, particularmente em domínios altamente especializados ou que exigem nuances contextuais profundas. LLMs são suscetíveis a perpetuar ou amplificar **vieses** presentes em seus dados de treinamento e podem gerar informações factualmente incorretas, fenômeno conhecido como **alucinação**. Seu **conhecimento é limitado** aos dados com os quais foram treinados, podendo estar desatualizados. Além disso, embora modelos multimodais estejam evoluindo, muitos LLMs ainda possuem capacidade limitada para processar informações não textuais, representando uma **dificuldade com tarefas visuais ou multimodais**.

2.5.4.2 LLMs como Seletores de Instâncias

Além de atuarem como fontes de rótulos, LLMs também demonstram potencial como agentes ativos na **seleção de instâncias** informativas dentro do ciclo de aprendizado ativo (Bayer e Reuter, 2024).

ActiveLLM: Bayer e Reuter (2024) propuseram a abordagem "ActiveLLM", que emprega LLMs como GPT-4 para identificar e selecionar instâncias para rotulagem em cenários de aprendizado com poucos exemplos (*few-shot learning*). Esta metodologia visa superar o problema de "partida a frio" (*cold start*), comum em estratégias de AL tradicionais que frequentemente necessitam de um conjunto inicial de dados rotulados para estimar a incerteza ou o desacordo de forma eficaz. A ideia central é alavancar as capacidades intrínsecas de compreensão e raciocínio dos LLMs para discernir quais instâncias não rotuladas seriam mais benéficas para treinar um modelo subsequente (e.g., um modelo baseado em BERT). O processo envolve apresentar um lote de instâncias não rotuladas ao LLM, junto com a descrição da tarefa, solicitar a seleção das mais informativas (considerando critérios como diversidade, representatividade e utilidade), rotular as instâncias selecionadas (por um humano ou outro método) e, finalmente, treinar o modelo alvo com os novos dados. Experimentos indicaram que o ActiveLLM pode superar abordagens tradicionais de AL e técnicas específicas de *few-shot* como SetFit (Bayer e Reuter, 2024).

Prompting Efetivo para Seleção: O desempenho de um LLM como seletor depende da engenharia do *prompt*. Bayer e Reuter (2024) investigaram diferentes estratégias, destacando a importância de *instruções claras* sobre o papel do LLM como componente de AL, o uso de *encadeamento de pensamento* (*Chain-of-Thought*) para solicitar raciocínio explícito, o controle do *tamanho do lote* de instâncias apresentado, e a inclusão de *recapitulação* sobre seleções anteriores para evitar redundância em processos iterativos.

2.5.4.3 Prompting e Engenharia de Contexto

A utilização eficaz de LLMs, seja como oráculos ou seletores, demanda estratégias sofisticadas de *prompting* e engenharia de contexto (Bayer e Reuter, 2024; Schick et al., 2023). O *Few-Shot Prompting*, que inclui alguns exemplos rotulados diretamente no *prompt*, pode melhorar significativamente o desempenho ao fornecer contexto específico da tarefa (Zhang et al., 2022b). Similarmente, o *Chain-of-Thought* (CoT) e o raciocínio passo a passo, elicitados por *prompts* como "pense passo a passo", demonstraram melhorar a qualidade das decisões, permitindo ao LLM considerar múltiplos fatores de forma estruturada (Wei et al., 2022). Uma direção emergente é o *Active Prompting*, que integra AL à engenharia de *prompts*, selecionando iterativamente não apenas instâncias, mas também os formatos de *prompt* mais eficazes para uma tarefa (Diao et al., 2023).

2.5.4.4 Integração com Modelos Menores e Especializados

Um paradigma promissor envolve a utilização de LLMs como componentes em um ciclo de AL maior, cujo objetivo final é treinar modelos menores, mais eficientes e especializados (Bayer e Reuter, 2024). Esta abordagem busca combinar o conhecimento abrangente e as

capacidades de raciocínio dos LLMs com a eficiência computacional e a especialização de modelos menores.

Na **destilação de conhecimento ativa** (*active knowledge distillation*), por exemplo, um LLM atua como "professor", fornecendo rótulos (possivelmente "soft labels" ou representações intermediárias) para instâncias selecionadas ativamente, que são subsequentemente utilizadas para treinar um modelo "estudante" menor (Su et al., 2023). Outra possibilidade reside na criação de **sistemas híbridos humano-LLM**, onde o LLM lida com tarefas rotineiras ou de baixa incerteza, enquanto casos difíceis, ambíguos ou críticos são direcionados para anotadores humanos, otimizando o uso de ambos os recursos (Margatina et al., 2023).

2.5.4.5 Desafios e Direções Futuras

Quando o LLM assume o papel de oráculo, o classificador da tarefa passa a ser treinado com *rótulos ruidosos* — regime com literatura própria e madura: o survey clássico de Frénay e Verleysen (2014) organiza taxonomias de ruído (aleatório, dependente de classe, dependente de instância) e seus efeitos; Natarajan et al. (2013) estabelecem garantias de aprendizado sob ruído de rótulo com funções de perda corrigidas; e Song et al. (2023) revisam o estado da arte com redes profundas. Dois resultados dessa literatura importam diretamente aqui: redes profundas toleram ruído moderado quando há dados suficientes, mas degradam de forma acentuada sob ruído estruturado (dependente de classe) — exatamente o perfil de erro observado em oráculos LLM, cujas confusões se concentram em pares de classes vizinhas. O experimento E4 desta tese (Capítulo 3) quantifica essa degradação no nosso domínio.

A integração de LLMs no ciclo de aprendizado ativo, apesar de promissora, apresenta desafios significativos e abre novas avenidas de pesquisa (Bayer e Reuter, 2024). É crucial desenvolver métodos robustos para **avaliar a incerteza** das predições de LLMs, permitindo identificar quando a intervenção humana é necessária ou quando o LLM pode atuar como um oráculo confiável (Tian et al., 2023). A alta **dependência da qualidade do prompt** requer investigação em técnicas para tornar a interação mais robusta e menos sensível a variações na formulação das instruções. As **limitações de contexto** inerentes às arquiteturas atuais de LLMs representam um obstáculo para o processamento de grandes volumes de dados ou documentos extensos em uma única consulta, necessitando de estratégias de loteamento ou sumarização eficazes. Finalmente, explorar o **aprendizado ativo em múltiplos níveis**, onde a seleção ativa ocorre não apenas para instâncias, mas também para prompts, estratégias de consulta ou até mesmo para a escolha do próprio modelo ou oráculo (humano vs. LLM), configura uma direção futura intrigante (Wu et al., 2022).

2.6 CLASSIFICAÇÃO DE TEXTO CURTO

Esta seção aborda a fundamentação teórica específica para a tarefa de Classificação de Texto Curto (*Short Text Classification* - STC), um subcampo do Processamento de Linguagem




Figura 2.1: Arquitetura conceitual do ActiveLLM: o LLM atua como *seletor* de instâncias informativas — mitigando o *cold start* — enquanto a rotulagem permanece com um oráculo e o aprendizado com um modelo sucessor. Adaptado de Bayer e Reuter (2026).

Natural (PLN) e Aprendizado de Máquina. Dada a crescente geração de dados textuais de tamanho reduzido em plataformas digitais como redes sociais, microblogs, chats e sistemas de busca, a STC possui aplicabilidade em diversas áreas, como análise de sentimentos, categorização de mensagens, classificação de consultas de busca e identificação de intenções (Ahmed et al., 2022; Song et al., 2014b).

2.6.1 Definições

A classificação de texto é uma área estabelecida em PLN. Sua definição formal, conforme apresentada na literatura (Aggarwal e Zhai, 2012; Kowsari et al., 2019), é descrita a seguir.

Definição 2.2 (Classificação de Texto) *Dado um conjunto de documentos $D = \{d_1, d_2, \dots, d_n\}$ e um conjunto pré-definido de classes $C = \{c_1, c_2, \dots, c_m\}$, a classificação de texto consiste em aprender uma função (ou modelo) de classificação $f : D \rightarrow C$ que mapeia cada documento $d_i \in D$ a uma classe $y_i \in C$.*

A função f é geralmente aprendida a partir de um conjunto de treinamento rotulado $T = \{(d_1, y_1), \dots, (d_t, y_t)\}$, com o objetivo de generalizar para novos documentos não vistos.

A tarefa apresenta complexidades adicionais quando aplicada a textos curtos. Textos curtos são frequentemente caracterizados por limites no número de caracteres, por exemplo, até 200 caracteres (Song et al., 2014b; Alsmadi e Gan, 2019b).

Definição 2.3 (Texto Curto (por Comprimento)) *Um texto curto pode ser representado como uma sequência textual $s = (t_1, t_2, \dots, t_l)$ onde t_i representa um caractere e o comprimento total l é limitado (e.g., $l \leq 200$).*

Exemplos típicos incluem tweets, títulos de notícias, consultas de busca e descrições de produtos em e-commerce (Darú, 2024). A Classificação de Texto Curto (STC) especializa, portanto, a tarefa geral de classificação para este tipo de dado, buscando construir uma função $f_{\text{curto}} : S \rightarrow C$, onde S é o conjunto dos textos curtos a serem classificados. O objetivo técnico é desenvolver modelos capazes de extrair informação relevante e classificar precisamente esses textos, considerando as características discutidas na Seção 2.6.2.

2.6.2 Desafios da Classificação de Texto Curto

A classificação de textos curtos apresenta desafios particulares, menos acentuados em documentos longos, devido à sua natureza concisa e, por vezes, informal (Ahmed et al., 2022; Song et al., 2014b).

A **escassez de informação e contexto** é um aspecto central. O número reduzido de palavras restringe o contexto disponível, limitando a capacidade de extrair padrões semânticos e realizar a desambiguação de termos de forma eficaz (Ahmed et al., 2022; Song et al., 2014b). A coocorrência de palavras, um sinal importante para muitos modelos tradicionais de PLN, ocorre com pouca frequência, resultando em uma representação textual limitada para cada documento (Ahmed et al., 2023).

A **esparsidade lexical e a alta dimensionalidade** representam outro desafio significativo. Embora cada texto curto individualmente contenha poucos termos, o vocabulário agregado de um corpus pode ser amplo. Quando representados por métodos como Bag-of-Words, os textos resultam em vetores de características que são simultaneamente de alta dimensionalidade e altamente esparsos (com a maioria das entradas sendo zero). Esta característica limita a aplicabilidade de certas métricas de similaridade, eleva a complexidade computacional dos algoritmos e contribui para o fenômeno conhecido como “maldição da dimensionalidade” (Ahmed et al., 2022).

O **ruído e a informalidade** são também comuns, especialmente em textos provenientes de mídias sociais e conteúdo gerado por usuários (UGC). É frequente a ocorrência de erros ortográficos, abreviações, gírias, emojis, URLs, hashtags e outras variações linguísticas não padronizadas, o que demanda etapas eficazes de pré-processamento e normalização (Ahmed et al., 2022; Song et al., 2014b; Aliero et al., 2023). A linguagem utilizada tende a ser direta, com uso de acrônimos e formas não gramaticais (Ahmed et al., 2023).

Por fim, a **ambiguidade** semântica é acentuada pela falta de contexto. Essa característica inerente aos textos curtos compromete a correta interpretação e, conseqüentemente, a classificação (Song et al., 2014b). Superar esses desafios é um ponto central na pesquisa e desenvolvimento de métodos eficazes para STC.

2.6.3 Processo de Classificação e Pré-processamento

O fluxo de trabalho (*pipeline*) para classificação de texto curto geralmente segue etapas sequenciais que incluem coleta de dados, pré-processamento, extração de características (vetorização), treinamento do modelo, avaliação e implantação (Kowsari et al., 2019). Neste contexto, um *pipeline* refere-se a uma sequência definida de etapas de processamento de dados e modelagem. A etapa de pré-processamento, em particular, assume importância elevada devido aos desafios inerentes aos textos curtos discutidos na Seção 2.6.2.

O pré-processamento visa limpar, normalizar e transformar o texto bruto em um formato mais adequado para análise computacional, buscando reduzir a complexidade e a variabilidade

dos dados (Alierio et al., 2023; Naseem et al., 2021b). Um conjunto bem definido de etapas de pré-processamento é aplicado para mitigar os efeitos da esparsidade e do ruído (Ahmed et al., 2022). A seguir, são descritas algumas das técnicas de normalização textuais frequentemente empregadas. A escolha e a ordem de aplicação destas técnicas devem ser consideradas cuidadosamente, pois podem impactar o desempenho do modelo e dependem das características do domínio e do corpus (Naseem et al., 2021b; Alierio et al., 2023).

Tokenização é frequentemente a primeira etapa, consistindo no processo de segmentação de uma sequência de texto em unidades léxicas individuais, denominadas tokens (Ahmed et al., 2023). Por exemplo, a frase “O produto é bom!” seria tokenizada em [‘O’, ‘produto’, ‘é’, ‘bom’, ‘!’].

Conversão para Minúsculas (*Lowercasing*) é a transformação de todos os caracteres de um texto para suas formas minúsculas correspondentes (Ahmed et al., 2022; Alierio et al., 2023). Aplicada ao token “Produto”, resultaria em “produto”. Esta etapa padroniza o texto, garantindo que variações de capitalização sejam tratadas como o mesmo token.

Remoção de Pontuação e Caracteres Especiais envolve a eliminação de símbolos de pontuação e caracteres não alfanuméricos do texto (Ahmed et al., 2022; Alierio et al., 2023). Por exemplo, de “bom!”, o ponto de exclamação seria removido, resultando em “bom”. Similarmente, de “#promoção”, o caractere “#” seria removido. A remoção de números também pode ser realizada (e.g., “item_10” → “item_”), mas sua pertinência depende do contexto da aplicação.

Remoção de *Stopwords* refere-se à eliminação de palavras comuns e de alta frequência que possuem pouco valor semântico discriminativo para a tarefa (e.g., artigos, preposições, conjunções) (Ahmed et al., 2022; Alierio et al., 2023). Aplicando a remoção de *stopwords* (como ‘o’, ‘é’) à sequência de tokens [‘o’, ‘produto’, ‘é’, ‘bom’] resultaria em [‘produto’, ‘bom’]. O objetivo é reduzir a dimensionalidade e focar em termos semanticamente mais ricos.

Lematização (*Lemmatization*) é o processo de redução de uma palavra flexionada à sua forma base canônica, conhecida como lema, utilizando análise morfológica e dicionários (Ahmed et al., 2022; Alierio et al., 2023). Por exemplo, as palavras “correndo” e “correu” seriam ambas reduzidas ao lema “correr”. Embora geralmente preferível por gerar palavras válidas, a lematização pode ser computacionalmente mais intensiva que o *stemming*.

Stemming é um processo alternativo de redução morfológica que reduz uma palavra ao seu radical (*stem*) pela remoção de afixos (sufixos e prefixos), sem garantia de que o radical resultante seja uma palavra válida (Ahmed et al., 2022; Alierio et al., 2023). Por exemplo, “consultor”, “consultoria” e “consultando” poderiam ser reduzidos ao radical “consult”. É computacionalmente mais rápido que a lematização.

Tratamento de Ruído Específico compreende um conjunto de técnicas aplicadas para lidar com elementos comuns em textos informais ou de fontes específicas (Naseem et al., 2021b; Alierio et al., 2023). Exemplos incluem a remoção ou substituição de URLs (e.g., “visite https://site.com” → “visite”), a limpeza de hashtags (e.g., “#imperdível” → “imperdível”), a expansão de abreviações (e.g., “vc” → “você”) ou a normalização de emojis. Este tratamento é

particularmente relevante para dados oriundos de mídias sociais ou conteúdo gerado por usuários (UGC).

Reitera-se que a ordem e a seleção das técnicas de pré-processamento aplicadas são fatores que influenciam o desempenho final do classificador, sendo a experimentação e a adaptação ao problema específico etapas importantes no desenvolvimento do modelo (Naseem et al., 2021b).

2.6.4 Vetorização e Representação de Texto Curto

Após o pré-processamento, os textos necessitam ser convertidos em representações numéricas (vetores) para serem processados por algoritmos de aprendizado de máquina. A escolha da técnica de vetorização impacta diretamente a capacidade do modelo em capturar a semântica subjacente, especialmente em textos curtos.

2.6.4.1 Métodos Clássicos (Representações Esparsas)

As representações esparsas — *one-hot*, *bag-of-words* nas variantes binária, por frequência (TF) e ponderada por raridade (TF-IDF) (Salton e Buckley, 1988) — projetam cada texto num vetor de dimensão igual ao vocabulário, com extensão por n -gramas para capturar contexto local. Suas propriedades, variantes e o comportamento específico em descrições curtas de produtos em português foram investigados em profundidade na dissertação de mestrado do autor (Darú, 2024), que este trabalho toma como ponto de partida: a configuração vencedora lá identificada (representação binária com uni e bigramas, sem normalização L2) é justamente a adotada pelo classificador leve PVBIn (Capítulo 3). Em texto curto, a frequência de termos satura (quase todo termo ocorre uma única vez por descrição), o que explica a vantagem empírica da variante binária sobre TF e TF-IDF nesse regime (Darú, 2024); para o panorama geral de ponderação e representação, ver Salton e Buckley (1988) e Naseem et al. (2021a).

2.6.4.2 Embeddings (Representações Densas)

Estes métodos mapeiam itens (palavras, textos) para vetores em um espaço contínuo de baixa dimensionalidade (k), onde relações geométricas refletem propriedades semânticas ou sintáticas (Goldberg, 2017).

Um modelo de *embedding* aprende uma função $E : \mathcal{X} \rightarrow \mathbb{R}^k$, onde $\mathcal{X}$ é o espaço de entrada (e.g., vocabulário V) e k é a dimensão do *embedding* (Goldberg, 2017).

Embeddings Estáticos (Word Embeddings) atribuem um único vetor $E(w) \in \mathbb{R}^k$ a cada palavra $w \in V$, independentemente do contexto.

- **Word2Vec** (Mikolov et al., 2013): Aprende vetores treinando uma rede neural rasa para prever contexto a partir de palavras (Skip-gram) ou palavras a partir do contexto (CBOW).

- **GloVe** (Pennington et al., 2014): Aprende vetores fatorizando a matriz de coocorrência global de palavras.
- **FastText** (Bojanowski et al., 2017): Estende Word2Vec considerando n-grams de caracteres, útil para morfologia e palavras OOV.

A principal limitação é a incapacidade de lidar com polissemia, o que é relevante em textos curtos com contexto limitado (Selva e Titus, 2021; Goldberg, 2017).

Embeddings Contextuais Diferentemente dos embeddings estáticos, os embeddings contextuais geram representações vetoriais para um token que dependem do contexto específico (a sequência inteira) em que ele aparece (Peters et al., 2018; Devlin et al., 2019b). Isso permite que a mesma palavra tenha representações diferentes conforme seu sentido na frase, resolvendo o problema da polissemia.

Definição 2.4 (Embedding Contextual) A representação h_i do i -ésimo token t_i em uma sequência $S = (t_1, \dots, t_l)$ é uma função de toda a sequência: $h_i = f(t_i, S) \in \mathbb{R}^k$.

Dessa forma, a mesma palavra w terá vetores diferentes h_i e h_j se aparecer em contextos S_1 e S_2 distintos. Várias arquiteturas notáveis implementam este conceito.

ELMo (Embeddings from Language Models) utiliza as representações internas de um modelo de linguagem baseado em LSTMs bidirecionais (biLM) treinados em um grande corpus (Peters et al., 2018). O embedding final para uma palavra em um contexto é uma combinação ponderada das representações de diferentes camadas do biLM.

GPT (Generative Pre-trained Transformer) e suas variantes (e.g., GPT-2 (Radford et al., 2019), GPT-3) são baseados na arquitetura Transformer (especificamente, seu decodificador) (Radford et al., 2018). Estes modelos são pré-treinados em tarefas de modelagem de linguagem auto-regressiva (prever a próxima palavra). Embora primariamente geradores, suas representações internas também são contextuais, capturando informações da sequência anterior (contexto à esquerda), e podem ser ajustados para tarefas de classificação.

BERT (Bidirectional Encoder Representations from Transformers) utiliza o codificador da arquitetura Transformer e é pré-treinado em tarefas de automodelagem (previsão de palavras mascaradas e previsão da próxima sentença) usando contexto bidirecional profundo (considerando palavras à esquerda e à direita simultaneamente) (Devlin et al., 2019b). BERT e suas variantes (e.g., RoBERTa, ALBERT, DistilBERT) ajustados (*fine-tuned*) para STC frequentemente alcançam o estado da arte, sendo particularmente vantajosos pela capacidade de entender o contexto complexo mesmo em textos curtos e esparsos (Ahmed et al., 2022; Li et al., 2020; Karl e Scherp, 2023).

2.6.4.3 Métricas de Similaridade

Após a vetorização, métricas quantificam a proximidade ou dissimilaridade entre as representações vetoriais dos textos. A escolha da métrica adequada é importante e depende das características dos vetores (esparsos vs. densos) e do objetivo da comparação.

A **Similaridade do Cosseno** é uma métrica que avalia o quão similares são dois vetores em termos de sua orientação no espaço vetorial, independentemente de suas magnitudes. Ela mede o cosseno do ângulo entre eles (Baeza-Yates e Ribeiro-Neto, 2013).

É definida pela seguinte equação para vetores não-nulos a e b :

$$\text{sim}_{\cos}(a, b) = \cos(\theta) = \frac{a \cdot b}{\|a\| \|b\|} = \frac{\sum_{i=1}^n a_i b_i}{\sqrt{\sum_{i=1}^n a_i^2} \sqrt{\sum_{i=1}^n b_i^2}} \quad (2.12)$$

Onde $a \cdot b$ é o produto escalar dos vetores e $\|a\|$, $\|b\|$ são suas normas euclidianas (magnitude). O valor da Similaridade do Cosseno varia de -1 a 1, onde 1 indica vetores com a mesma orientação (alta similaridade) e -1 indica vetores com orientação oposta. É uma métrica **amplamente utilizada e recomendada para comparar documentos textuais representados por vetores de alta dimensionalidade e esparsos**, como os gerados por TF-IDF (Salton e Buckley, 1988; Ahmed et al., 2023; Baeza-Yates e Ribeiro-Neto, 2013). Sua insensibilidade à magnitude dos vetores (e, portanto, ao comprimento do documento, especialmente após normalização) a torna eficaz para medir a semelhança de conteúdo ou tópico com base nas proporções relativas dos termos.

O **Coefficiente de Jaccard / Tanimoto** mede a sobreposição entre conjuntos. Sua generalização para vetores com componentes não negativos, conhecida como Coeficiente de Tanimoto, pode ser usada para quantificar a similaridade entre representações textuais baseadas em contagens ou pesos (Ahmed et al., 2023).

Para vetores a e b com componentes não negativos, o Coeficiente de Tanimoto é calculado por:

$$J(a, b) = \frac{a \cdot b}{\|a\|^2 + \|b\|^2 - a \cdot b} \quad (2.13)$$

O valor varia de 0 a 1, onde 0 indica nenhuma sobreposição de termos ponderados e 1 indica vetores idênticos. É útil quando a ênfase está na proporção de características compartilhadas em relação ao total de características presentes em ambos os textos (Ahmed et al., 2023). Pode ser uma alternativa à Similaridade do Cosseno em certos cenários.

A **Distância Euclidiana** mede a distância geométrica linear ("em linha reta") entre as extremidades de dois vetores no espaço n -dimensional (Baeza-Yates e Ribeiro-Neto, 2013).

A distância entre dois vetores a e b é dada por:

$$d_{\text{euc}}(a, b) = \|a - b\| = \sqrt{\sum_{i=1}^n (a_i - b_i)^2} \quad (2.14)$$

É uma métrica de *distância* (dissimilaridade), onde valores menores indicam maior proximidade (similaridade). Seu uso em dados textuais esparsos de alta dimensão é frequentemente desencorajado (Baeza-Yates e Ribeiro-Neto, 2013). Isso ocorre porque ela é sensível à magnitude dos vetores (comprimento do documento) e pode ser menos significativa em espaços muito esparsos devido ao fenômeno da “maldição da dimensionalidade”. Pode ser mais apropriada para vetores densos de baixa dimensionalidade (*embeddings*) se a magnitude for considerada relevante.

Em resumo, a escolha da métrica depende da representação vetorial e dos objetivos da análise, sendo a Similaridade do Cosseno geralmente preferida para representações esparsas como TF-IDF. Estas métricas de similaridade ou distância são fundamentais não apenas para análise exploratória, mas também como componentes internos de certos algoritmos de classificação baseados em vizinhança ou para avaliar a qualidade das representações vetoriais que servirão de entrada para os modelos discutidos na próxima seção. A seção seguinte detalhará os algoritmos de aprendizado de máquina comumente aplicados à classificação de texto curto.

2.6.5 Algoritmos de Classificação para Texto Curto

A classificação de textos curtos pode ser abordada por uma variedade de algoritmos de aprendizado de máquina. A seleção do algoritmo mais apropriado depende das características específicas dos dados (volume, dimensionalidade, esparsidade), da representação vetorial utilizada (esparsa vs. densa) e dos requisitos da aplicação em termos de desempenho, interpretabilidade e recursos computacionais.

Algoritmos de aprendizado de máquina **tradicionais** são frequentemente empregados como linhas de base (*baselines*) ou em cenários com restrições computacionais. Entre eles, destacam-se as Máquinas de Vetores de Suporte (SVM) (Cortes e Vapnik, 1995), classificadores Naive Bayes (NB) (Murphy, 2012), K-Vizinhos Mais Próximos (KNN) (Cover e Hart, 1967), modelos lineares como Regressão Logística (LR) (Murphy, 2012), e métodos baseados em árvores como Árvores de Decisão (DT) (Quinlan, 1993) e seus *ensembles*, como Florestas Aleatórias (*Random Forests*) (Breiman, 2001) ou *Gradient Boosting* (e.g., XGBoost). Algoritmos como SVM podem apresentar bom desempenho em espaços de alta dimensão característicos de representações como TF-IDF, especialmente quando combinados com técnicas adequadas de seleção de características (Kowsari et al., 2019; Aliero et al., 2023). A descrição detalhada destes algoritmos pode ser encontrada na Seção 2.2.

O **Aprendizado Profundo** (*Deep Learning*) introduziu arquiteturas capazes de aprender representações hierárquicas diretamente dos dados, o que pode ser vantajoso para capturar padrões complexos em texto (Goodfellow et al., 2016). As Redes Neurais Convolucionais (CNNs) demonstraram eficácia na captura de padrões locais, como n-grams, em textos, sendo aplicadas com sucesso em tarefas de classificação (Xu et al., 2017). Redes Neurais Recorrentes (RNNs), incluindo suas variantes mais sofisticadas como *Long Short-Term Memory* (LSTM) e LSTMs Bidirecionais (BiLSTMs), são projetadas para modelar sequências e capturar dependências de

longo alcance (Goodfellow et al., 2016). Contudo, sua eficácia pode ser limitada em textos excessivamente curtos onde as dependências sequenciais são menos pronunciadas.

Atualmente, modelos baseados na arquitetura **Transformer**, em particular o **BERT** (*Bidirectional Encoder Representations from Transformers*) e suas variantes (e.g., RoBERTa, ALBERT, DistilBERT), representam o **estado da arte para muitas tarefas de Processamento de Linguagem Natural, incluindo a classificação de texto curto** (Devlin et al., 2019b; Li et al., 2020; Karl e Scherp, 2023). A força desses modelos reside no pré-treinamento em vastos corpora textuais, que lhes permite aprender representações contextuais ricas e profundas. A capacidade de modelar o contexto de forma bidirecional (considerando informações anteriores e posteriores a um token) é particularmente benéfica para desambiguação e compreensão semântica, mesmo em textos com poucas palavras (Devlin et al., 2019b). O processo de **ajuste fino** (*fine-tuning*), onde um modelo pré-treinado é adaptado para a tarefa específica de STC com dados rotulados do domínio, geralmente resulta em desempenho superior ao de algoritmos tradicionais e outras arquiteturas de aprendizado profundo, desde que recursos computacionais para treinamento e armazenamento do modelo estejam disponíveis (Devlin et al., 2019b; Karl e Scherp, 2023).

Adicionalmente, **Modelos Híbridos e Ensembles** podem ser explorados. Abordagens híbridas combinam diferentes arquiteturas (e.g., CNNs para extração de características locais e LSTMs para contexto sequencial), enquanto *ensembles* agregam previsões de múltiplos classificadores (sejam eles tradicionais ou profundos) para potencialmente melhorar a robustez e a precisão geral (Li et al., 2020; Dietterich, 2000).

Em termos de recomendação, para obter o desempenho mais elevado na classificação de textos curtos, o uso de modelos baseados em Transformer pré-treinados e ajustados (*fine-tuned*) é geralmente a abordagem preferencial (Karl e Scherp, 2023; Li et al., 2020). No entanto, algoritmos tradicionais como SVM ou Naive Bayes, combinados com representações como TF-IDF e n-grams, podem oferecer uma alternativa computacionalmente menos custosa e mais interpretável, servindo como *baselines* importantes ou sendo adequados para cenários com dados ou recursos limitados.

A seleção e o treinamento eficazes de qualquer um desses algoritmos, desde os tradicionais até os modelos Transformer de última geração, exigem uma avaliação criteriosa de seu desempenho. Compreender como medir a qualidade das classificações e como validar os modelos de forma robusta é, portanto, essencial. A próxima seção detalhará as métricas de avaliação e as técnicas de validação apropriadas para a tarefa de classificação de texto curto.

2.6.6 Avaliação e Validação

A avaliação e a validação de modelos são etapas necessárias para estimar a capacidade de generalização de classificadores de texto curto (STC) e para a seleção de hiperparâmetros.

2.6.6.1 Métricas de Avaliação

A avaliação do desempenho em tarefas de classificação multiclasse, comum em STC, utiliza métricas específicas, particularmente em cenários com desbalanceamento de classes. Conforme discutido na Seção 2.2.3, a Acurácia (Eq. 2.2), embora forneça uma visão geral, pode apresentar limitações quando as classes possuem frequências distintas, pois um modelo pode alcançar alta acurácia ao prever majoritariamente a classe mais frequente (Grandini et al., 2020; Barros et al., 2014; Riyanto et al., 2023).

Métricas que consideram o desempenho por classe ou são robustas ao desbalanceamento fornecem informações adicionais nesses cenários. O **F1-Score** (Eq. 2.4), média harmônica entre Precisão e Revocação (Eq. 2.3), é frequentemente utilizado. A agregação **Macro-average** (Macro-F1) calcula a média aritmética dos F1-Scores de cada classe, atribuindo peso igual a todas elas. Esta abordagem reflete o desempenho em classes minoritárias (Grandini et al., 2020; Riyanto et al., 2023).

A **Acurácia Balanceada** (*Balanced Accuracy*) é definida como a média aritmética dos *recalls* de cada classe (equivalente ao Macro-Recall, vide Seção 2.2.3). Esta métrica não é afetada pelo tamanho relativo das classes (Grandini et al., 2020).

Adicionalmente, o **Coefficiente de Correlação de Matthews (MCC)** é uma métrica considerada robusta para classificação binária e multiclasse, inclusive sob desbalanceamento. O MCC utiliza as quatro entradas da matriz de confusão (TP, FP, TN, FN) para todas as classes, resultando em uma medida de correlação entre as previsões e os rótulos verdadeiros (Grandini et al., 2020; Riyanto et al., 2023).

Outras formas de agregação, como a média **Weighted-average** do F1-Score (que pondera pelo suporte de cada classe) ou a média **Micro-average** (equivalente à acurácia global em multiclasse), podem complementar a análise, mas tendem a dar mais peso às classes majoritárias (Grandini et al., 2020). O **Kappa de Cohen** também pode ser empregado para medir a concordância entre as previsões e os rótulos reais, ajustada pela probabilidade de concordância ao acaso (Grandini et al., 2020).

A Tabela 2.3 (adaptada de (Grandini et al., 2020)) resume as características destas métricas no contexto de dados desbalanceados. A literatura sugere, para avaliação de STC em cenários desbalanceados, o uso das métricas Macro-F1, Acurácia Balanceada e/ou MCC, utilizando a Acurácia global como um indicador complementar (Grandini et al., 2020; Riyanto et al., 2023). A escolha final entre estas métricas pode, contudo, depender dos objetivos específicos da aplicação.

2.6.6.2 Técnicas de Validação

Conforme detalhado na Seção 2.2.4, estratégias de validação são aplicadas para obter estimativas do desempenho do modelo em dados não vistos e para o ajuste de hiperparâmetros.

Tabela 2.3: Métricas Comuns para Classificação Multiclasse e sua Sensibilidade ao Desbalanceamento (Adaptado de (Grandini et al., 2020)).

Métrica	Descrição (vide Seção 2.2.3)	Característica Principal (em dados desbalanceados)
Acurácia	Percentual global de acertos	Sensível ao desbalanceamento, favorece classes majoritárias
Macro-F1	Média aritmética dos F1-Scores por classe	Peso igual para todas as classes
Micro-F1	F1-Score calculado globalmente (equivale à Acurácia)	Favorece classes majoritárias
Acurácia Balanceada	Média aritmética dos <i>Recalls</i> por classe	Insensível ao desbalanceamento
MCC	Coeficiente de correlação entre predições e rótulos	Robusta a desbalanceamento
Kappa de Cohen	Medida de concordância ajustada pela chance	Avalia concordância além do acaso

A **Validação Cruzada K-Fold (*K-Fold Cross-Validation*)** é uma técnica padrão para este fim (Kohavi, 1995). O procedimento divide o conjunto de dados em k subconjuntos (*folds*) e realiza k iterações de treino e teste, utilizando a cada vez um *fold* diferente para teste e os $k - 1$ restantes para treino. O número de *folds* (k) usualmente adotado é 5 ou 10, valores que oferecem um equilíbrio entre o viés/variância da estimativa de erro e o custo computacional (Kohavi, 1995; Nti et al., 2021; Forman e Scholz, 2010; Reusens et al., 2024). Valores maiores de k , como em *Leave-One-Out Cross-Validation* (LOOCV), aumentam o custo computacional e podem introduzir maior variância na estimativa, sendo menos utilizados exceto para conjuntos de dados muito pequenos (James et al., 2013; Kohavi, 1995). Para a tarefa de STC, o uso de $k = 5$ ou $k = 10$ *folds* é uma prática comum.

Em problemas de classificação com dados desbalanceados, utiliza-se a **Validação Cruzada K-Fold Estratificada (*Stratified K-Fold*)**. A estratificação assegura que a proporção original das classes seja mantida em cada *fold* de treino e teste (Forman e Scholz, 2010; Widodo et al., 2022; James et al., 2013). Esta abordagem objetiva prevenir distorções na avaliação decorrentes de representações não proporcionais das classes nos *folds*, resultando em uma estimativa mais consistente do desempenho do modelo.

Outra técnica, particularmente utilizada no treinamento de modelos de aprendizado profundo (como CNNs, LSTMs ou Transformers), é a **Parada Antecipada (*Early Stopping*)**. Este método funciona como uma forma de regularização para prevenir sobreajuste (Prechelt, 2012; Goodfellow et al., 2016). Ele monitora o desempenho do modelo (e.g., a função de perda ou uma métrica de interesse como Macro-F1) em um conjunto de validação durante o treinamento. O processo é interrompido quando o desempenho no conjunto de validação cessa de melhorar ou

começa a degradar, selecionando-se o modelo correspondente ao ponto de melhor desempenho observado na validação.

Em suma, a aplicação de métricas de avaliação adequadas ao problema e técnicas de validação como as discutidas permite aferir a qualidade dos classificadores de texto curto. O estabelecimento de estimativas de desempenho para os modelos base (discutidos na Seção 2.6.5) fornece a referência necessária para investigar metodologias que visam otimizar a aquisição de dados rotulados. Considerando os custos associados à rotulagem manual e as características dos textos curtos, o Aprendizado Ativo (AL), introduzido na Seção 2.2.1, constitui uma área de investigação pertinente. Para analisar o estado da arte e identificar tendências e lacunas na aplicação desta técnica ao domínio específico de interesse, a próxima seção apresentará uma revisão sistemática da literatura focada na combinação de estratégias de Aprendizado Ativo com a Classificação de Texto Curto.

2.6.7 Revisão Sistemática: Avanços Recentes em Aprendizado Ativo para Classificação de Texto Curto (2020-2026)

Com base nos fundamentos de Aprendizado Ativo (AL) discutidos nas Seções 2.3 a 2.5 e nos desafios específicos da Classificação de Texto Curto detalhados na Seção 2.6, esta seção apresenta uma revisão sistemática focada nos avanços da literatura entre 2020 e o primeiro semestre de 2026. O objetivo é investigar como a pesquisa recente tem abordado os desafios persistentes, particularmente o problema de *cold start*, e como tem explorado o potencial dos Modelos de Linguagem Grandes (LLMs), especialmente no papel de oráculos, para otimizar o ciclo de aprendizado ativo no contexto específico da classificação de texto curto.

2.6.7.1 Escopo e Metodologia desta Revisão

Esta revisão concentrou-se em publicações revisadas por pares e pré-prints significativos (como os encontrados na ACL Anthology e arXiv) do período de 2020 até o primeiro semestre de 2026, com uma atualização dedicada cobrindo o último ano (meados de 2025 a meados de 2026) para captar a produção mais recente sobre AL com oráculos LLM. A busca utilizou combinações de termos como "active learning", "text classification", "short text", "LLM", "large language model", "cold start", "few-shot learning", e "oracle", priorizando trabalhos que explicitamente conectassem essas áreas. A análise focou em identificar tendências na aplicação de LLMs em AL, abordagens para mitigar o *cold start* e as lacunas remanescentes, especialmente relevantes para a classificação de texto curto.

2.6.7.2 Desafios Persistentes e a Emergência dos LLMs

Conforme introduzido na Seção 2.6.2, a classificação de texto curto apresenta desafios intrínsecos devido à esparsidade de características e falta de contexto. No âmbito do Aprendizado Ativo, esses desafios exacerbam problemas clássicos:

- **Problema de Partida a Frio (Cold Start):** Como destacado por Bayer & Reuter (Bayer e Reuter, 2024), muitas estratégias de AL (detalhadas em 2.5.3) dependem de um modelo inicial razoavelmente treinado para fazer seleções informativas. Com texto curto e poucos exemplos iniciais, o modelo frequentemente não consegue fazer escolhas significativas, tornando o início do processo de rotulagem ineficiente.
- **Custo Computacional e de Anotação:** Embora o objetivo do AL seja reduzir a anotação, algumas estratégias, especialmente as que envolvem múltiplos modelos ou re-treinamentos frequentes com modelos profundos como Transformers, podem ser computacionalmente caras (Fromme et al., 2022). O custo da anotação humana continua sendo um gargalo.
- **Incerteza e Diversidade em Espaços Esparsos:** Estimar a incerteza do modelo ou garantir a diversidade das amostras selecionadas pode ser mais complexo com representações esparsas típicas de texto curto.

É neste cenário que os LLMs, com seu vasto conhecimento pré-treinado e capacidades de compreensão de linguagem em contextos *few-shot* ou *zero-shot*, emergiram como uma alternativa promissora a partir de 2023. Sua capacidade de inferir significado mesmo com pouco contexto textual direto oferece um potencial disruptivo para as abordagens tradicionais de AL, especialmente para mitigar o *cold start*.

2.6.7.3 Integração de LLMs no Ciclo de Aprendizado Ativo

A revisão da literatura recente (2020-2025) revela uma mudança paradigmática na forma como os LLMs estão sendo integrados ao AL para classificação de texto, indo além do uso de modelos baseados em Transformers (como BERT (Ein-Dor et al., 2020; Grieshaber et al., 2020; Yuan et al., 2020)) para incorporar diretamente as capacidades generativas e de inferência dos LLMs:

LLMs como Oráculos Ativos: Uma das aplicações mais diretas e impactantes é o uso de LLMs como substitutos ou complementos aos oráculos humanos.

- Bayer & Reuter (Bayer e Reuter, 2024) introduziram o **ActiveLLM**, demonstrando que LLMs como GPT-4 podem selecionar instâncias informativas para classificação de texto em cenários *few-shot*, superando significativamente estratégias tradicionais de AL que sofrem com o *cold start*. O ActiveLLM mostra que o conhecimento pré-treinado do LLM permite fazer seleções úteis mesmo sem um modelo classificador inicial robusto.
- Zhang & Takada (Zhang e Takada, 2025b) levaram adiante a ideia de usar LLMs (GPT) como oráculos para *rotular* as instâncias selecionadas por estratégias de AL (como incerteza e diversidade), alcançando alta performance em classificação de texto

cross-task com um custo computacional e monetário significativamente menor do que usar o LLM para classificar todo o dataset. A engenharia de prompt torna-se crucial neste cenário.

- Rouzegar & Makrehchi (Rouzegar e Makrehchi, 2024) propuseram uma abordagem híbrida, combinando a rotulação por LLM com a validação/correção por anotadores humanos, sugerindo que a sinergia pode ser mais eficaz do que depender exclusivamente de um ou outro.

Essa abordagem de "oráculo LLM" ataca diretamente o problema do custo de anotação e, crucialmente, o problema de *cold start*, pois o LLM pode fornecer rótulos ou selecionar amostras informativas desde o início, sem depender de um modelo treinado especificamente para a tarefa alvo.

LLMs para Seleção e Geração de Dados Ativos: Além de atuarem como oráculos, os LLMs também estão sendo usados para refinar a própria seleção de amostras ou gerar dados sintéticos de forma ativa.

- A capacidade dos LLMs de avaliar a "surpresa" ou a incerteza semântica de um texto, como explorado conceitualmente em abordagens como ALPS (Yuan et al., 2020) para BERT, pode ser potencializada com LLMs maiores, permitindo estratégias de seleção baseadas em quão "inesperado" ou "informativo" um texto curto é para o conhecimento geral do LLM.
- Xia et al. (Xia et al., 2025), em sua survey sobre AL baseado em LLM, discutem a transição "da seleção para a geração", onde LLMs podem ser usados não apenas para selecionar, mas também para *gerar* exemplos sintéticos em regiões de baixa densidade ou alta incerteza do espaço de características, auxiliando no preenchimento de lacunas de conhecimento do modelo, especialmente útil no *cold start*.

Prompting Ativo e Adaptativo: Em vez de um ciclo de AL tradicional focado no treinamento do modelo, o foco pode mudar para a otimização do prompt fornecido ao LLM. Técnicas de "active prompting" podem selecionar exemplos *few-shot* ou refinar as instruções dadas ao LLM de forma iterativa, guiadas por princípios de AL para maximizar o desempenho do LLM na tarefa de classificação de texto curto com o mínimo de exemplos de demonstração.

Apesar desses avanços, a integração de LLMs também traz novos desafios, como a calibração da confiança do LLM (eles tendem a ser excessivamente confiantes), o custo computacional das chamadas à API (para modelos proprietários) e o risco de vieses inerentes ao LLM serem propagados para o modelo final (Bayer e Reuter, 2024; Zhang e Takada, 2025b).

2.6.7.4 Atualização (2025-2026): *Cold Start com Diversidade Dupla e Oráculos em Conjunto*

Uma atualização desta revisão, cobrindo o período de meados de 2025 a meados de 2026, identifica três desenvolvimentos que reforçam a relevância e, ao mesmo tempo, delimitam com mais precisão a contribuição do FALCO frente ao estado da arte mais recente.

Diversidade Dupla no Cold Start: Guo et al. (Guo et al., 2025) propuseram o **DEUCE** (*Dual-diversity Enhancement and Uncertainty-awareness for Cold-start Active Learning*), que combina representações de um modelo de linguagem pré-treinado com um grafo de duplo-vizinho (textual e de classe) e agrupamento baseado em densidade para selecionar simultaneamente instâncias diversas e representativas de classes difíceis logo na fase de *cold start*. A proposta converge conceitualmente com a Fase 1 do FALCO (clusterização semântica combinada à diversidade sintática via BoW/TF-IDF), mas o DEUCE não incorpora um oráculo LLM: a rotulagem permanece assumida como disponível ou humana, e o framework não é avaliado em português nem em texto curto de e-commerce. O FALCO se diferencia, portanto, ao integrar a seleção diversificada de *cold start* com um oráculo LLM progressivo, tratando simultaneamente o problema de seleção e o de rotulagem.

Oráculos LLM em Conjunto (*Mixture-of-LLMs*): Qi et al. (Qi et al., 2026) propuseram um framework de rotulagem baseado em *mixture-of-LLMs*, no qual múltiplos modelos leves rotulam simultaneamente e um mecanismo de discrepância entre anotações, combinado a aprendizado negativo, mitiga o ruído de rótulos individuais, aproximando a qualidade da anotação humana com modelos executáveis localmente. Essa abordagem é complementar à estratégia do FALCO: enquanto o *mixture-of-LLMs* busca robustez ao ruído combinando vários oráculos *em paralelo* no mesmo estágio, o FALCO busca eficiência de custo fazendo o oráculo evoluir *sequencialmente* (LLM mais simples nas fases iniciais, mais capaz nas fases finais). A combinação das duas ideias — oráculos em conjunto que também evoluem em capacidade ao longo das fases — é apontada na discussão desta tese (Capítulo 6) como direção de trabalho futuro.

Barreiras Práticas à Adoção do AL com LLMs: A pesquisa de comunidade conduzida por Romberg et al. (Romberg et al., 2025) constatou que, apesar do entusiasmo em torno de LLMs no ciclo de AL, três barreiras identificadas há mais de 15 anos permanecem: complexidade de implantação, incerteza quanto à real redução de custo e ferramental inadequado. Esse achado reforça a pertinência da Seção 2.6.7.5 a seguir e da discussão de custo financeiro do oráculo LLM retomada no Capítulo 6, uma vez que a viabilidade prática — e não apenas o ganho de acurácia — é apontada pela comunidade como o principal obstáculo à adoção de frameworks como o FALCO fora de ambientes de pesquisa.

Classificação de Produtos em Português em Escala: Machado & Veloso (Machado e Veloso, 2026) publicaram, também em 2026, um estudo aplicado que reforça a relevância prática do

domínio investigado nesta tese: a classificação de cerca de 100 mil títulos de produtos de supermercados portugueses nas categorias ECOICOP, usada para fins de estatística oficial. O BERTimbau *fine-tuned* atingiu a melhor performance entre os modelos testados (97,04% de acurácia, 94,00% de Macro F1-Score), superando modelos multilíngues e clássicos, o que corrobora a escolha do BERTimbau como classificador θ do FALCO (Seção 3.3). Entretanto, o processo de rotulagem do estudo depende de um fluxo humano-no-loop ad-hoc, iniciado com aproximadamente 12 mil produtos rotulados manualmente e expandido retailer a retailer sem uma estratégia formal de aprendizado ativo ou oráculo automatizado – exatamente a lacuna que o FALCO busca preencher ao formalizar a seleção e a rotulagem inicial com um oráculo LLM.

Em conjunto, esses quatro trabalhos confirmam que a lacuna identificada na revisão original (Seção 2.6.7.5) — a ausência de um framework que combine explicitamente diversidade no *cold start*, oráculo LLM progressivo e avaliação em texto curto de baixo recurso como o português — permanece aberta mesmo após a publicação de propostas próximas em cada uma dessas dimensões isoladamente.

2.6.7.5 Lacunas de Pesquisa: A Necessidade de Frameworks Integrados

A análise da literatura recente, embora mostre um progresso rápido e promissor na aplicação de LLMs ao AL, revela lacunas significativas, particularmente na interseção de AL, LLMs, *cold start* e classificação de *texto curto*:

Falta de Frameworks Sistemáticos para LLM-Oráculo em Cold Start: Apesar do potencial demonstrado por abordagens como ActiveLLM (Bayer e Reuter, 2024) e o uso de LLMs para rotulação (Zhang e Takada, 2025b), carecem na literatura frameworks de aprendizado ativo que explorem **sistematicamente** a sinergia entre LLMs como oráculos (ou seletores iniciais) e a resolução do problema de *cold start* especificamente para texto curto. As estratégias de seleção tradicionais (Seção 2.5.3) frequentemente falham no início, enquanto depender apenas do LLM para classificação direta pode ser caro ou subótimo. Falta, portanto, uma metodologia integrada que:

- Utilize o conhecimento pré-treinado do LLM para informar as seleções iniciais ou fornecer rótulos no estágio de *cold start*.
- Adapte as estratégias de seleção (e.g., baseadas em incerteza ou diversidade) para considerar não apenas o modelo classificador sendo treinado, mas também a confiança e o custo do LLM-oráculo.
- Seja otimizada para as características do texto curto (esparsidade, falta de contexto), talvez priorizando amostras que sejam semanticamente ambíguas ou representativas de clusters pouco explorados, conforme avaliado pelo LLM.

- Balanceie explicitamente o custo computacional/financeiro das consultas ao LLM com o ganho de informação esperado para o modelo final.

Estratégias de Seleção Adaptadas para LLMs e Texto Curto: Como apontado por Ein-Dor et al. (Ein-Dor et al., 2020) já no contexto do BERT, e ainda mais relevante para LLMs, há uma necessidade de desenvolver novas estratégias de seleção que sejam intrinsecamente projetadas para as representações e capacidades desses modelos, em vez de apenas adaptar métodos antigos. Isso é especialmente crítico para texto curto, onde a capacidade do LLM de inferir contexto pode ser explorada ativamente.

Calibração e Confiabilidade do Oráculo LLM: A tendência dos LLMs à excessiva confiança (*overconfidence*) é um problema sério ao usá-los como oráculos. São necessárias pesquisas sobre como calibrar melhor as previsões dos LLMs ou desenvolver estratégias de AL robustas à incerteza do próprio oráculo.

Avaliação Custo-Benefício Rigorosa: Embora alguns trabalhos como (Zhang e Takada, 2025b) comecem a analisar o custo, falta uma avaliação mais sistemática e comparativa do trade-off entre o desempenho do modelo, o número de amostras rotuladas (seja por humanos ou LLMs) e o custo computacional/financeiro total, especialmente em cenários de *cold start* para texto curto.

2.6.7.6 Conclusão da Revisão Sistemática

Esta revisão focada da literatura de 2020 até meados de 2026 evidencia que o campo do Aprendizado Ativo para classificação de texto curto está passando por uma transformação significativa impulsionada pelos LLMs. Essas tecnologias oferecem soluções promissoras para desafios persistentes como o *cold start* e o alto custo de anotação, particularmente ao atuarem como oráculos ou seletores informados. No entanto, a integração dessas capacidades ainda é incipiente. Permanece uma clara lacuna na pesquisa pela falta de frameworks sistemáticos e otimizados que combinem as forças do AL tradicional com o poder dos LLMs para enfrentar eficazmente o problema de *cold start* no domínio desafiador da classificação de texto curto. Esta lacuna motiva diretamente a necessidade de desenvolver novas abordagens, como a proposta neste trabalho.

3 METODOLOGIA

Este capítulo descreve a metodologia empregada para desenvolver e avaliar o **FALCO** (*Framework de Aprendizado Ativo com LLM para texto CurtO*). A investigação está organizada em quatro pilares empíricos, cada qual associado a um experimento identificado e reproduzível: (P1) o impacto da composição do conjunto inicial de rotulagem L_0 ; (P2) a construção de um L_0 informativo sem acesso a rótulos, via o algoritmo DRI-SL; (P3) a viabilidade, o custo e o perfil de erro de modelos de linguagem de grande porte (LLMs) como oráculos de rotulagem; e (P4) a avaliação integrada do FALCO contra métodos de referência sob o mesmo orçamento de rotulagem. Uma métrica transversal, a *Learning Curve Efficiency* (LCE), sumariza a eficiência das curvas de aprendizado em todos os pilares.

Todos os experimentos são implementados na biblioteca `activelearning` (Apêndice D), desenvolvida nesta pesquisa sob arquitetura hexagonal com domínio isolado, e cada número reportado nos capítulos de resultados é rastreável a um artefato de execução versionado (configuração, sementes, revisão do código e registros por iteração), conforme a Seção 3.10.

3.1 DESENHO DA PESQUISA

A pesquisa adota um desenho experimental quantitativo, no modo *pool-based* de aprendizado ativo (Lewis e Gale, 1994; Settles, 2012): há um acervo finito de instâncias não rotuladas U , um classificador da tarefa θ , uma estratégia de seleção S que escolhe lotes de consulta $Q_t \subset U_t$, um oráculo O que fornece rótulos e um orçamento B de consultas. Como os rótulos verdadeiros de todo o conjunto de dados estão disponíveis, o processo é simulado com fidelidade: o oráculo LLM pode ser avaliado contra o padrão-ouro, e um modelo treinado com supervisão completa fornece o limite superior de desempenho.

A Tabela 3.1 resume o programa experimental. Os experimentos E0 a E3 respondem, respectivamente, aos pilares P3, P1/P2 (reanálise) e P4; E4 é condicional ao resultado de E0, conforme o critério de decisão da Seção 3.7.3.

Tabela 3.1: Programa experimental da tese.

Id	Objetivo	Pilar	Recursos
E0	Avaliação fatorial de LLMs como oráculo	P3	APIs de LLM
E1	Estratégias de seleção $\times$ tamanho de lote (oráculo simulado)	apoio a P4	CPU
E2	Épocas de ajuste fino do BERTimbau por iteração	apoio a P4	GPU
E3	FALCO <i>versus</i> RS e US sob mesmo orçamento	P4	GPU + APIs
E4	Robustez do aprendizado a ruído controlado do oráculo	P4 (condicional)	GPU
P1 (sensibilidade de L_0) e P2 (DRI-SL) reutilizam execuções já realizadas e auditadas.			

3.2 CONJUNTO DE DADOS

3.2.1 Fonte e características

O conjunto de dados é o *Retail Product Description-Ptbr* (Darú et al., 2022; Darú, 2024), com $N = 250.365$ descrições de produtos de varejo na versão original — 250.221 na versão corrigida utilizada (Seção 3.2.2) — em português brasileiro, coletadas de 18 grandes varejistas, cada qual associada a uma categoria de produto. As descrições são curtas (4 a 50 caracteres; mediana de 32), tipicamente em caixa alta e com abreviações características de cupons fiscais (*e.g.*, CERV BRAHMA LT 350ML), configurando os desafios de esparsidade lexical e baixo contexto discutidos no Capítulo 2. A distribuição de classes é fortemente desbalanceada: a classe mais frequente (*biscoito*) concentra 14.292 instâncias (5,7%), enquanto centenas de classes têm poucas dezenas de exemplos.

3.2.2 Auditoria de qualidade dos rótulos

Antes dos experimentos, o conjunto foi auditado quanto à qualidade do padrão-ouro — etapa relevante porque os rótulos servem simultaneamente de gabarito para o oráculo LLM (P3) e de supervisão para o classificador (P4). Três achados condicionam o desenho experimental e a interpretação dos resultados:

1. **Conflitos de rótulo:** 719 descrições distintas (1.807 linhas; 0,7% do total) aparecem associadas a duas ou mais categorias diferentes (*e.g.*, MILHARINA QUAKER 500G ocorre com os rótulos *farinha de milho*, *floco de milho*, *fubá* e *polenta*). Esse ruído impõe um teto de aproximadamente 99,3% à acurácia mensurável de qualquer classificador ou oráculo na distribuição de produção. As instâncias foram mantidas por representarem o ruído real do domínio; o teto é considerado na interpretação (Capítulo 5). Uma análise de sensibilidade quantifica o efeito dessa decisão: reavaliando as anotações dos oráculos do E0 (i) com as instâncias conflitantes excluídas e (ii) sob pontuação *multi-gold* (acerto quando o rótulo predito coincide com *qualquer* dos rótulos observados para a mesma descrição na base), a acurácia de todos os oráculos varia no máximo +0,7 ponto percentual, sem alteração de nenhum ordenamento ou decisão. O ruído de gabarito, portanto, limita a medição, mas não a contamina de forma relevante — o que justifica manter as instâncias.
2. **Rótulo operacional:** a categoria *inativo* (144 linhas) registra um status de cadastro, não um tipo de produto (*e.g.*, UVA PASSA ESCURA 150G → *inativo*). As linhas foram removidas na versão corrigida da base (250.221 instâncias); a versão original e o registro exato das linhas removidas são preservados no repositório de código, garantindo a rastreabilidade da correção.

3. **Duplicatas exatas:** 19.356 linhas (7,7%) repetem o par (descrição, rótulo). Isso é inócuo para a avaliação do oráculo, mas exige **deduplicação por descrição normalizada antes do particionamento** nos experimentos com treinamento (E2/E3), sob pena de vazamento entre treino e teste.

3.2.3 Pré-processamento e espaço de rótulos

O pré-processamento textual é mínimo — conversão para minúsculas e remoção de acentos — delegando ao tokenizador de subpalavras do classificador o tratamento de variações lexicais. Rótulos passam pela mesma normalização. Classes com menos de cinco instâncias são agrupadas na categoria sentinela `_rare_` (0,13% das linhas), resultando em um espaço fechado de **621 categorias** (620 classes frequentes + `_rare_`). Esse espaço fechado, denominado *CategorySchema*, é um objeto de primeira classe na implementação: é a fonte única da restrição de saída imposta aos oráculos LLM (Seção 3.7.1).

3.2.4 Particionamento

Para os experimentos com treinamento do classificador (E2/E3), o conjunto — após deduplicação — é particionado de forma estratificada em: conjunto de teste T (20%), reservado exclusivamente à avaliação final; conjunto de validação V (10%), para monitoramento do ajuste fino; e o *pool* de aprendizado ativo U_0 (70%). Para o E3, um subconjunto estratificado de aproximadamente 50 mil instâncias do *pool* é utilizado — amostragem estratificada por classe com semente fixa e registrada, preservando as proporções de U_0 —, dimensionado para viabilizar múltiplas repetições do ciclo completo com BERTimbau no hardware disponível; o orçamento de rotulagem é fixado em $B = 30\%$ de $|U_0|$. A generalização das conclusões do subconjunto para o *pool* completo é discutida nas limitações (Seção 3.9).

3.3 CLASSIFICADORES DA TAREFA

Dois classificadores θ são empregados, com papéis distintos e explícitos:

- **BERTimbau Base** (`neuralmind/bert-base-portuguese-cased`) (Souza et al., 2020): classificador principal, usado na validação do FALCO e dos métodos de referência (E2/E3). O ajuste fino usa a biblioteca `transformers` (Wolf et al., 2020) com otimizador AdamW (Loshchilov e Hutter, 2019), taxa de aprendizado 3×10^{-5} , lote de treinamento 32 e decaimento de peso 0,01. O número de épocas por iteração do ciclo ativo é determinado empiricamente no E2 (curvas de perda em validação para $|L| \in \{10^3, 10^4, 5 \times 10^4\}$), em vez de fixado por convenção.
- **Classificador vetorial binário (PVBIn):** representação *bag-of-words* binária com uni e bigramas, protótipos de classe por concatenação de documentos e predição por

similaridade de cosseno com *softmax* sobre os escores (Darú, 2024). Por seu custo de treinamento desprezível, viabiliza os estudos que exigem milhares de reexecuções: a sensibilidade de L_0 , a otimização por algoritmo genético (P1) e a varredura de estratégias do E1.

Essa separação isola a contribuição metodológica: o FALCO é validado com o classificador forte, enquanto as análises exploratórias massivas usam o classificador leve.

3.4 MÉTRICAS DE AVALIAÇÃO E ANÁLISE ESTATÍSTICA

Desempenho do classificador. A métrica primária é o **Macro F1-Score** — média aritmética dos F1 por classe, que pondera igualmente classes majoritárias e minoritárias, adequada ao forte desbalanceamento do conjunto (Sokolova e Lapalme, 2009). A **acurácia global** é reportada como métrica secundária. Ambas são calculadas no conjunto de teste T ao longo das iterações, compondo curvas de aprendizado (métrica *versus* $|L_t|$).

Eficiência da curva de aprendizado (LCE). Para comparar estratégias de aprendizado ativo por um único escalar, emprega-se a métrica LCE, proposta nesta tese e formalizada no Apêndice A:

$$LCE = \frac{AUC_{\text{real}}}{AUC_{\text{ideal}}}, \quad AUC_{\text{ideal}} = \text{Perf}_{\text{baseline}} \times (L_{\text{final}} - L_{\text{ideal},0}), \quad (3.1)$$

em que AUC_{real} é a área sob a curva de aprendizado medida, integrada numericamente pela regra de Simpson sobre os pontos observados, $\text{Perf}_{\text{baseline}}$ é o desempenho do classificador com supervisão completa e $L_{\text{ideal},0}$ é a abscissa inicial da curva ideal (o menor tamanho de conjunto rotulado observado, de modo que curvas reais e ideal integrem o mesmo intervalo). Valores próximos de 1 indicam que a estratégia se aproxima rapidamente do desempenho de referência com poucos rótulos. A LCE tem precedente direto na **ALC** (*Area under the Learning Curve*) do *Active Learning Challenge* (Guyon et al., 2011); difere dela em dois pontos: a normalização usa o desempenho de supervisão completa do próprio par (classificador, conjunto) — e não o máximo teórico da métrica — tornando o valor comparável entre classificadores de tetos distintos; e a integração usa Simpson sobre a grade observada, em vez de interpolação em escala logarítmica.

Análise estatística. Três testes acompanham as comparações, conforme a natureza dos dados: (i) toda acurácia de oráculo é reportada com **intervalo de confiança de Wilson** a 95% (Wilson, 1927), apropriado para proporções em qualquer faixa; (ii) comparações entre oráculos que rotularam *as mesmas instâncias* usam o **teste de McNemar** (McNemar, 1947) sobre os pares discordantes (com teste binomial exato quando as discordâncias somam menos de 25); e (iii) comparações entre estratégias de aprendizado ativo executadas com múltiplas sementes usam o **teste de postos sinalizados de Wilcoxon** (Wilcoxon, 1945) sobre as métricas finais e a LCE.

3.5 PILAR P1: COMPOSIÇÃO DO CONJUNTO INICIAL L_0

3.5.1 Sensibilidade à amostragem aleatória

Para quantificar o impacto da composição de L_0 , o classificador PVBin foi treinado com conjuntos iniciais amostrados aleatoriamente em **47 tamanhos** entre 10 e 200.000 instâncias, com **30 repetições independentes** por tamanho (sementes distintas), avaliando Acurácia e Macro F1 no conjunto de teste. As estatísticas descritivas completas constam do Apêndice F.

3.5.2 Otimização por algoritmo genético

Para estimar os *limites* de desempenho alcançáveis pela escolha da composição de L_0 — inatingíveis por busca exaustiva no espaço combinatório — empregou-se um algoritmo genético (Holland, 1975; Goldberg, 1989) sobre indivíduos que representam conjuntos de I índices únicos do *pool*. A configuração, idêntica em todas as execuções, foi: população $N_{pop} = 50$; 100 gerações; seleção por torneio de tamanho $k_t = 3$; cruzamento de um ponto com probabilidade $p_c = 0,8$ e reparo de unicidade; mutação com probabilidade $p_m = 0,1$ substituindo $m_s = \max(1, \lceil 0,01 \cdot I \rceil)$ genes; elitismo de 10% ($N_{elite} = 5$). Quatro cenários foram otimizados (maximização e minimização de Acurácia e de Macro F1) para dez tamanhos de L_0 entre 10 e 30.000. A função de aptidão é avaliada em uma **partição de aferição disjunta do conjunto de teste**: otimizar e reportar na mesma partição superajustaria o envelope ao conjunto de avaliação (circularidade); por isso, os indivíduos finais de cada cenário são *reavaliados* no conjunto de teste intocado, e é esse valor — tipicamente inferior ao de aptidão — que os capítulos de resultados reportam como envelope. O fluxo completo e os operadores são formalizados no Apêndice B.

3.6 PILAR P2: *COLD START* SEM RÓTULOS — ALGORITMO DRI-SL

O DRI-SL (*Diversidade Representativa Inicial via densidade Semântica e variedade Lexical*) constrói um L_0 de tamanho alvo I a partir de U_0 sem acesso a rótulos, combinando dois espaços de representação: (i) **densidade semântica** — as instâncias são projetadas por um codificador de sentenças (Reimers e Gurevych, 2019) e agrupadas por k -médias em N_c grupos, com alocação de amostras proporcional ao tamanho de cada grupo; e (ii) **variedade lexical intragrupo** — dentro de cada grupo, as amostras são escolhidas iterativamente maximizando a introdução de termos relevantes ainda não cobertos (escore de novidade ponderado pelo perfil TF-IDF do grupo). A formalização, o pseudocódigo e as decisões de implementação constam do Apêndice C. O DRI-SL é a estratégia da Fase 1 do FALCO e é avaliado (P2) contra a amostragem aleatória e contra o envelope de desempenho estimado pelo algoritmo genético (P1), que atua como limite empírico de referência.

3.7 PILAR P3: LLMS COMO ORÁCULO DE ROTULAGEM (EXPERIMENTO E0)

3.7.1 Instrumentação da medição

Medir a acurácia de um LLM como rotulador exige restringir a saída ao espaço de rótulos: em experimento preliminar da própria pesquisa, um esquema de saída sem restrição produziu variações de fraseado (*e.g.*, “ovos de páscoa” quando o padrão-ouro registra “ovo de páscoa”) contabilizadas como erro, deflacionando a acurácia medida. Três modos de instrumentação são definidos — e o modo utilizado fica registrado em cada anotação:

- **enum** (modo de produção): saída estruturada com o rótulo restrito, na decodificação, ao *CategorySchema* de 621 valores, com validação estrita imposta pelo provedor (*structured outputs*);
- **json-prompt**: para provedores sem suporte a saída estruturada, a lista de categorias e o formato JSON são instruídos no *prompt*, com validação posterior exata e contabilização explícita de rótulos inválidos;
- **free**: saída estruturada *sem* restrição de rótulo — réplica controlada do instrumento defeituoso, usada exclusivamente para quantificar o efeito do instrumento (RQ4 abaixo).

O *prompt* (Apêndice E) contextualiza o domínio (cupons fiscais, abreviações), instrui a classificação do *tipo* de produto ignorando marca e embalagem, e desestimula o uso indevido da categoria sentinela `_rare_`. A parte estática do *prompt* e o esquema precedem o item variável, explorando o *cache* de prefixo dos provedores que o oferecem — com efeito direto no custo por rótulo. A rotulagem é feita **em lote** (itens numerados em uma única chamada; resposta como vetor indexado), com o tamanho do lote calibrado em etapa prévia (lotes de 1, 10 e 25 itens, pareados nas mesmas instâncias) e adotando-se o maior lote que não degrade a acurácia (teste de McNemar) — decisão registrada junto aos resultados.

3.7.2 Desenho fatorial do E0

O E0 responde a quatro perguntas: (RQ1) a acurácia e o Macro F1 de cada LLM candidato, com intervalos de confiança e comparações pareadas; (RQ2) o custo por mil rótulos e a latência; (RQ3) o perfil de erro por classe (matriz de confusão, taxa de rótulos inválidos); e (RQ4) o efeito do instrumento de medição (*enum versus free*, mesmas instâncias). Os modelos candidatos abrangem três regimes de custo: APIs comerciais (gpt-4o-mini e gpt-4o), modelos servidos por plataforma *MaaS* (DeepSeek-V4-Flash, DeepSeek-V4-Pro e GLM-5.2) e o regime de custo zero via agregador (representado pela variante *free* do Nemotron-3-Ultra; a redução de escopo deste braço, imposta pela vazão do plano gratuito, é registrada na decisão D-005 e discutida nos resultados).

Duas amostras pareadas — todos os modelos rotulam *as mesmas* instâncias — são usadas: **S-rand** ($n = 1.000$, amostragem aleatória simples), que preserva a distribuição de

produção e serve a RQ1/RQ2/RQ4; e **S-strat** (3 por classe, $n \approx 1.863$), que dá suporte por classe ao Macro F1 e à matriz de confusão (RQ3) — necessária porque, com 621 classes, a amostra aleatória deixa a maioria das classes sem representação. A temperatura é fixada em 0 em todos os modelos.

3.7.3 Critério de decisão para o FALCO

Do E0 deriva a configuração de oráculos do FALCO: o **LLM Inicial** é o de melhor razão acurácia/custo sujeito a acurácia mínima de 85% na S-rand; o **LLM Avançado** é o de maior acurácia, *desde que* significativamente superior ao Inicial (McNemar, $\alpha = 0,05$) — caso contrário, a Fase 3 do framework é eliminada e o FALCO opera com oráculo único. Se nenhum modelo atingir o limiar, o E4 (robustez a ruído) torna-se obrigatório e a discussão da tese passa a tratar o aprendizado com oráculo ruidoso como cenário central.

3.8 PILAR P4: O FRAMEWORK FALCO E SUA AVALIAÇÃO (EXPERIMENTOS E1–E4)

3.8.1 Componentes e fases

O FALCO opera em três fases, adaptando estratégia de seleção e oráculo ao amadurecimento do classificador:

1. **Fase 1 — *cold start* informado:** o lote inicial ($b_0 = \lceil 0,01 \cdot B \rceil$) é selecionado pelo DRI-SL (Seção 3.6) e rotulado pelo LLM Inicial, formando L_0 ;
2. **Fase 2 — seleção por incerteza com LLM Inicial:** a cada iteração, as b instâncias de maior entropia preditiva de θ (Settles, 2012) são consultadas ao LLM Inicial; a transição ocorre quando o Macro F1 no conjunto de *validação* V estagna por $p = 5$ iterações consecutivas (tolerância $\epsilon = 10^{-3}$). O conjunto de teste T jamais participa de decisões do processo — usá-lo aqui contaminaria a avaliação final (vazamento de teste);
3. **Fase 3 — refinamento com LLM Avançado:** mantida a seleção por incerteza, o oráculo passa ao LLM Avançado, concentrando o custo do modelo mais capaz nas instâncias mais difíceis. A fase existe apenas se o critério da Seção 3.7.3 a justificar.

O processo encerra ao exaurir B ou U . As constantes de projeto têm o seguinte racional, registrado como decisão de engenharia (não de otimização): $b_0 = \lceil 0,01 \cdot B \rceil$ dá à Fase 1 um custo máximo de 1% do orçamento — suficiente para o DRI-SL cobrir os agrupamentos semânticos sem comprometer o orçamento das fases guiadas; a janela de estagnação $p = 5$ com tolerância $\epsilon = 10^{-3}$ corresponde a cinco iterações sem ganho acima do ruído típico de reamostragem observado nas curvas do E1, evitando transições por flutuação; e o limiar de 85% do gate de oráculo (Seção 3.7.3) fica um desvio acima do melhor baseline supervisionado leve conhecido do conjunto de dados (acurácia de 89,56% com *todos* os rótulos (Darú, 2024)), exigindo do oráculo

zero-shot qualidade próxima à do teto supervisionado antes de dispensar tratamento de ruído; a sensibilidade a essas escolhas é discutida com os resultados. O tamanho de lote b e a estratégia de incerteza da Fase 2 são fixados com base no E1, que varre as estratégias de entropia, menor confiança, menor margem, híbrida e aleatória sob oráculo simulado perfeito com o classificador PVBin — barato o suficiente para varredura ampla — e justifica a escolha por LCE.

3.8.2 Métodos de referência e desenho do E3

O E3 compara, sob idênticos L_0 , orçamento $B = 30\%$, classificador BERTimbau e oráculos LLM: (i) **FALCO** completo; (ii) **RS** — amostragem aleatória por iteração; (iii) **US** — seleção por entropia desde o início; e (iv) **supervisão completa** — limite superior, treinado com todos os rótulos verdadeiros, que também fornece $\text{Perf}_{\text{baseline}}$ para a LCE; e (v) **oráculo-total** — classificador treinado com *todo* o pool rotulado pelo mesmo oráculo LLM do FALCO. Este quinto braço separa as duas fontes de perda que a comparação (i)–(iv) confunde: a diferença entre (iv) e (v) mede o custo do *ruído do oráculo*; a diferença entre (v) e o FALCO mede o custo da *parcimônia de rótulos* — sem ele, um resultado negativo seria ambíguo entre estratégia ruim e oráculo ruim. RS e US usam o mesmo cronograma de oráculos do FALCO, isolando o efeito da estratégia de seleção. Para atribuir o ganho a cada componente do framework — e não ao conjunto indissociável — o desenho inclui ainda duas **ablações**: (a) FALCO com L_0 aleatório no lugar do DRI-SL (isola a contribuição do *cold start* informado) e (b) FALCO sem troca de oráculo, usando apenas o LLM Inicial em todas as fases (isola a contribuição da progressão de oráculos). Cada configuração é repetida com **8 sementes** — mínimo necessário para que o teste de postos sinalizados de Wilcoxon possa atingir $p < 0,05$ bicaudal (o menor p-valor com n pares é $2/2^n$; com $n < 6$ a significância é inalcançável por construção). As comparações finais reportam Wilcoxon pareado sobre Macro F1 final e LCE, complementado por intervalo de confiança *bootstrap* (percentil, 10^4 reamostragens) sobre a diferença média de LCE, que permanece informativo mesmo sob poucas sementes. O E4 — executado se o critério do oráculo indicar ruído relevante — repete o desenho do E3 com oráculo simulado de ruído paramétrico $\varepsilon \in \{0; 0,1; 0,2; 0,4\}$, quantificando a degradação do aprendizado em função da qualidade do oráculo.

3.9 AMEAÇAS À VALIDADE

Validade externa. Todo o programa empírico usa um único conjunto de dados, construído pelo próprio autor (Darú et al., 2022). Isso maximiza o realismo (dados de produção de 18 varejistas) e a comparabilidade com o trabalho anterior, mas limita a generalização: as conclusões valem, a rigor, para descrições curtas de produtos de varejo em português. Três mitigações são adotadas: as decisões do framework não usam nenhuma propriedade específica do conjunto além das características públicas do gênero (texto curto, desbalanceamento, abreviações); os achados de instrumentação (P3) são mecanismos do par LLM-API, não do dado; e o protocolo

completo é reproduzível em qualquer conjunto rotulado com a mesma estrutura, ficando a réplica em benchmark público (*e.g.*, STOPS (Karl e Scherp, 2023)) registrada como trabalho futuro.

Validade interna. O conjunto de teste é isolado de todas as decisões do processo (particionamento com deduplicação prévia; transição de fase por V ; envelope do AG reavaliado em partição intocada). O viés distribucional que a amostragem ativa induz no conjunto rotulado (Santos, 2016) não afeta a medição, feita sempre em T fixo e aleatório.

Validade de constructo. A acurácia do oráculo é medida contra um padrão-ouro com ruído conhecido (teto $\approx 99,3\%$; análise de sensibilidade na Seção 3.2.2), e o efeito do instrumento de medição é ele próprio quantificado (RQ4). O custo por rótulo depende de preços de API vigentes na execução — os valores absolutos datam; as razões entre modelos são mais estáveis.

3.10 REPRODUTIBILIDADE E AMBIENTE

Toda a instrumentação é implementada na biblioteca `activelearning` (Apêndice D), sob arquitetura hexagonal: o núcleo de domínio (instâncias, esquema de categorias, estratégias, métricas, políticas de fase) é puro e testado isoladamente; LLMs, classificadores e armazenamento são adaptadores intercambiáveis. Cada experimento tem um ponto de entrada único parametrizado por arquivo de configuração versionado; execuções registram sementes, revisão do código e anotações linha a linha (JSONL), e são retomáveis após interrupção. Chamadas a oráculos registram tokens, tokens em *cache*, latência e custo estimado — insumos da análise de custo do Capítulo 5. O ambiente de treinamento é uma estação com GPU NVIDIA RTX 3090 (24 GB), 64 GB de RAM e Linux; as versões das dependências são fixadas pelo gerenciador de pacotes do repositório.

4 RESULTADOS: COMPOSIÇÃO E CONSTRUÇÃO DO CONJUNTO INICIAL

Este capítulo apresenta os resultados dos pilares P1 e P2: a sensibilidade da generalização à composição do conjunto inicial L_0 (Seção 4.1), os limites estimados por otimização evolutiva (Seção 4.2) e a avaliação do DRI-SL como estratégia de *cold start* (Seção 4.3). Todos os experimentos usam o classificador leve PVBin (Capítulo 3); os resultados originais foram obtidos no programa experimental da pesquisa e, como verificação de robustez, o estudo de sensibilidade e o mecanismo do AG foram **reexecutados de forma independente** na biblioteca *activelearning*, com protocolo mais rigoroso (deduplicação antes do particionamento e reavaliação em teste intocado); as duas séries são apresentadas lado a lado (Seção 4.4).

4.1 SENSIBILIDADE À COMPOSIÇÃO E AO TAMANHO DE L_0

O experimento avaliou 47 tamanhos de L_0 (10 a 200.000), com 30 repetições aleatórias por tamanho, medindo Acurácia Global e Macro F1 no conjunto de teste T . As estatísticas completas constam do Apêndice F; a Figura 4.1 resume a tendência.




Figura 4.1: Tendência da performance média (Acurácia e Macro F1) e intervalo mín-máx por tamanho de L_0 no teste T , escala logarítmica. Classificador PVBin.

Três padrões estruturam a leitura:

1. **Crescimento com saturação:** a acurácia média sobe de 6,7% ($I = 10$) para 24,7% ($I = 100$), 55,9% ($I = 1.000$), 76,9% ($I = 10.000$) e satura em torno de 89,1% ($I = 200.000$); o Macro F1 acompanha com atraso (0,4% $\rightarrow$ 3,4% $\rightarrow$ 17,8% $\rightarrow$ 43,3% $\rightarrow$ 70,4%), refletindo o custo de cobrir classes minoritárias.

2. **Variabilidade decrescente:** o desvio-padrão da acurácia cai de 0,024 ($I = 10$) para menos de 0,001 ($I = 200.000$); para $I = 100$, a acurácia entre repetições variou de 21,7% a 28,1% — uma amplitude de 6,4 pontos percentuais causada exclusivamente pela composição do sorteio. É a evidência direta da hipótese de variabilidade: *existem* L_0 bons e ruins de mesmo tamanho.
3. **Cobertura de classes como mecanismo:** em $I = 10$ o L_0 típico cobre 9 das 621 classes; em $I = 1.000$, cerca de 255; a curva de Macro F1 segue de perto a curva de cobertura, indicando que, no regime pequeno, o fator dominante é *quais classes* entram no sorteio.

Esses resultados fundamentam o P2: se a composição importa tanto no regime pequeno — exatamente o regime do *cold start* do aprendizado ativo —, então construir L_0 deliberadamente (em vez de sorteá-lo) é a alavanca disponível antes de existir qualquer rótulo.

4.2 LIMITES POR OTIMIZAÇÃO EVOLUTIVA

Para estimar o quanto a composição pode render além do sorteio, um algoritmo genético (Seção 3.5.2) otimizou a composição de L_0 em quatro cenários (maximização e minimização de Acurácia e Macro F1) para dez tamanhos. A Tabela 4.1 resume a evolução do melhor (pior) indivíduo entre a 1ª e a 100ª geração nos cenários de acurácia.

Tabela 4.1: Evolução do AG (1ª vs. 100ª geração) — cenários de Acurácia. Envelope entre minimização e maximização.

$ L_0 $	Maximização			Minimização		
	1ª	100ª	Δ	1ª	100ª	Δ
10	13,06%	18,82%	+5,76	—	—	—
50	22,12%	33,83%	+11,71	16,17%	7,13%	−9,04
100	26,65%	36,71%	+10,06	22,17%	10,86%	−11,31
500	48,55%	56,00%	+7,46	45,23%	36,17%	−9,06
1.000	57,76%	62,20%	+4,44	55,76%	49,33%	−6,43
5.000	73,48%	74,13%	+0,64	72,00%	70,82%	−1,18
20.000	82,10%	83,23%	+1,13	81,58%	79,55%	−2,03
30.000	85,07%	85,88%	+0,81	84,39%	83,03%	−1,36

Duas leituras: o envelope é **largo no regime pequeno** (em $I = 100$, a distância entre pior e melhor indivíduo da última geração chega a 25,9 pontos percentuais de acurácia) e **estreita com o tamanho** — coerente com a Seção 4.1: quanto maior o L_0 , menos a composição importa. O ganho evolutivo sobre a 1ª geração (coluna Δ) confirma que o AG explora estrutura real, não flutuação.

4.3 DRI-SL VERSUS ALEATÓRIO E ENVELOPE DO AG

A Tabela 4.2 compara o DRI-SL (heurística determinística sem rótulos, Seção 3.6) com o envelope do AG.

Tabela 4.2: *Cold start*: DRI-SL vs. envelope do AG (última geração), até $|L_0| = 5.000$. Classificador PVBin.

$ L_0 $	DRI-SL		AG (melhor)		AG (pior)	
	Acc	Macro F1	Acc	Macro F1	Acc	Macro F1
100	41,23%	6,85%	38,76%	6,51%	5,75%	1,81%
500	59,22%	18,45%	56,00%	18,01%	36,17%	6,52%
1.000	67,39%	25,83%	62,20%	24,69%	49,33%	12,60%
2.500	73,36%	36,53%	69,28%	32,58%	63,92%	24,11%
5.000	76,87%	44,09%	74,13%	40,07%	70,82%	31,87%

O resultado central do P2: **o DRI-SL supera não só a amostragem aleatória média, mas o próprio melhor indivíduo encontrado pelo AG** em todos os tamanhos de 100 a 5.000 (ex.: $I = 1.000$: 67,4% vs. 62,2% de acurácia). Uma heurística construtiva de custo linear e sem acesso a rótulos supera um otimizador evolutivo com 5.000 avaliações supervisionadas — forte indício de que densidade semântica + variedade lexical capturam exatamente a estrutura que torna um L_0 informativo. Há uma ressalva metodológica: os valores do AG aqui reportados herdam o protocolo original (aptidão e relato na mesma partição), inflacionado por construção — a quantificação está na seção seguinte, e reforça a conclusão.

4.4 REEXECUÇÃO INDEPENDENTE E EFEITO DA CIRCULARIDADE

A reexecução na biblioteca `activelearning` (grade reduzida com racional registrado: 15 tamanhos $\times$ 10 repetições; artefatos em `experiments/pl/results/`) reproduz a estrutura completa do estudo original, com protocolo mais rigoroso — deduplicação por texto normalizado *antes* do particionamento e teste fixo de 20.000 instâncias.

Tabela 4.3: Estudo de sensibilidade: original (30 rep.) vs. reexecução independente (10 rep., protocolo com deduplicação). Acurácia média.

$ L_0 $	Original	Reexecução	Diferença
10	6,7%	6,6%	-0,1
100	24,7%	24,0%	-0,7
1.000	55,9%	55,5%	-0,4
10.000	76,9%	76,4%	-0,5
100.000	87,1%	86,7%	-0,4
200.000	89,1%	88,8%	-0,3

A concordância (diferença $\leq 0,7$ p.p. em todos os tamanhos, sempre no sentido esperado — o protocolo com deduplicação é ligeiramente mais difícil) valida de forma independente tanto o estudo original quanto o porte do classificador para a biblioteca nova, cuja fidelidade foi adicionalmente verificada por igualdade exata das matrizes de escore entre implementações.

A reexecução do AG (2 tamanhos $\times$ 2 cenários, $N_{pop} = 30, 40$ gerações) aplicou o protocolo anticircularidade da Seção 3.5.2: aptidão medida em partição de aferição, indivíduo final *reavaliado* no teste intocado. O mecanismo se reproduz (melhor indivíduo evolui +5,2 p.p. de acurácia em $I = 50$; envelope acima da média aleatória em todos os casos), mas a reavaliação

honestas revela a inflação da circularidade: para maximização de Macro F1 com $I = 500$, a aptidão final é 19,4%, mas o mesmo indivíduo mede 13,1% no teste intocado — 6,3 pontos percentuais de superajuste ao conjunto de aferição. Para acurácia a inflação é menor (≈ 1 p.p.). Conclusão metodológica incorporada à tese: **envelopes evolutivos devem ser reportados exclusivamente em partição não usada como aptidão**; os valores de AG das Tabelas 4.1 e 4.2 devem ser lidos como limites otimistas, e a superioridade do DRI-SL sobre eles é, portanto, conservadora.

4.5 SÍNTESE DO CAPÍTULO

(i) A composição de L_0 tem efeito grande e mensurável no regime pequeno (amplitude de 6,4 p.p. em $I = 100$ só por sorteio), decaindo com o tamanho; (ii) o envelope evolutivo confirma espaço explorável de dezenas de pontos percentuais entre composições boas e ruins; (iii) o DRI-SL captura esse espaço sem usar rótulos, superando o melhor indivíduo do AG até $I = 5.000$ — e é por isso a estratégia da Fase 1 do FALCO; (iv) a reexecução independente reproduz os três achados e quantifica o viés de circularidade do protocolo original de AG, corrigido nesta tese.

5 RESULTADOS: ORÁCULOS LLM E O FRAMEWORK FALCO

Este capítulo apresenta os resultados do pilar P3 — a avaliação instrumentada de LLMs como oráculos de rotulagem (E0, Seção 5.1), a ablação de prompt no modelo de menor custo (E0-P, Seção 5.2) — e a parte do pilar P4 executável sem GPU: a varredura de estratégias com oráculo simulado (E1, Seção 5.3) e a robustez do aprendizado a ruído controlado de oráculo (E4, Seção 5.4). A avaliação integrada do FALCO com BERTimbau (E3) requer a estação com GPU e está com o instrumental pronto para execução; seu desenho e critérios permanecem os do Capítulo 3, e os resultados serão incorporados na versão final deste capítulo. Todos os números reportados são rastreáveis a artefatos versionados no repositório `activelearning(experiments/e0,e0p,e1e4)`.

5.1 E0: AVALIAÇÃO FATORIAL DE ORÁCULOS LLM

5.1.1 RQ1 — assertividade

A Tabela 5.1 apresenta acurácia (com IC de Wilson a 95%), Macro F1 e taxa de rótulos inválidos dos oráculos avaliados nas duas amostras pareadas oficiais (S-rand $n = 1.000$; S-strat $n = 1.863$), com temperatura 0 e rotulagem em lote calibrada.

Tabela 5.1: E0 — desempenho dos oráculos LLM. Modo enum para OpenAI; json-prompt para MaaS/agregador (sem suporte a saída estruturada). IC = intervalo de Wilson 95%.

Oráculo	Amostra	Acurácia	IC 95%	Macro F1	Inválidos
deepseek-v4-pro	S-rand	82,1%	[79,6; 84,4]	0,785	0,1%
gpt-4o	S-rand	80,9%	[78,4; 83,2]	0,788	0,0%
deepseek-v4-flash	S-rand	78,3%	[75,6; 80,8]	0,750	0,7%
glm-5.2	S-rand	77,3%	[74,6; 79,8]	0,742	0,0%
gpt-4o-mini	S-rand	61,3%	[58,2; 64,3]	0,518	0,0%
deepseek-v4-pro	S-strat	82,6%	[80,8; 84,2]	0,793	0,0%
gpt-4o	S-strat	82,1%	[80,3; 83,8]	0,797	0,0%
deepseek-v4-flash	S-strat	81,6%	[79,7; 83,3]	0,781	0,9%
glm-5.2	S-strat	80,9%	[79,1; 82,6]	0,782	0,0%
gpt-4o-mini	S-strat	45,7%	[43,4; 48,0]	0,427	0,0%

Quatro leituras principais. **(i)** Os quatro melhores oráculos formam um platô entre 77% e 83% nas duas amostras — as diferenças internas ao platô são pequenas; o teste pareado (RQ1, McNemar) na S-strat mostra deepseek-v4-pro significativamente superior ao v4-flash ($b = 43$, $c = 16$, $p < 0,001$) e estatisticamente empatado com o gpt-4o ($p = 0,061$). **(ii)** O gpt-4o-mini colapsa na amostra estratificada (45,7%): o modelo pequeno erra sistematicamente nas classes raras, que a S-strat expõe por construção. **(iii)** Nenhum oráculo atinge o limiar de 85% do gate (Seção 3.7.3) na S-rand — o melhor zero-shot fica a ≈ 7 p.p. do teto supervisionado com 250 mil rótulos (89,6%, Darú, 2024). A consequência de desenho está na Seção 5.5. **(iv)** Em compensação, o Macro F1 zero-shot dos oráculos do platô ($\approx 0,78$ – $0,80$ na S-strat) *supera*

o Macro F1 do PVBin treinado com supervisão completa (0,70): o conhecimento de mundo do LLM compensa exatamente onde o supervisionado leve sofre — classes com pouquíssimos exemplos.

5.1.2 RQ2 — custo e o efeito do *cache*

Tabela 5.2: E0 — custo por mil rótulos (US\$) e taxa de acerto de *cache* de prefixo (S-rand; preços vigentes na execução, jul/2026).

Oráculo	US\$/1k rótulos	Cache	Acurácia
deepseek-v4-flash	0,035	—	78,3%
gpt-4o-mini	0,051	91%	61,3%
glm-5.2	0,249	—	77,3%
deepseek-v4-pro	0,410	—	82,1%
gpt-4o	0,923	88%	80,9%

O intervalo de custo entre oráculos do mesmo platô de acurácia é de mais de uma ordem de grandeza: o deepseek-v4-flash entrega 78–82% por US\$ 0,035/1k — **26 vezes mais barato** que o gpt-4o (80–82%). O *cache* de prefixo (prefixo estático do *prompt* + schema precedendo o item variável, Seção 3.7.1) atinge 88–95% de acerto nos provedores que o suportam, reduzindo pela metade o custo efetivo do tokens de entrada. Para referência externa, o custo fica duas a três ordens de grandeza abaixo do custo típico de anotação humana por item relatado na literatura (Gilardi et al., 2023). Custo, porém, não é a única restrição operacional: os limites de vazão dos provedores (3 requisições/min no MaaS, 18/min no plano gratuito do OpenRouter, nos artefatos de latência do E0) moldaram o próprio desenho experimental e, em produção, definem o tempo de parede de um ciclo de rotulagem tanto quanto o preço — um oráculo barato e lento pode ser dominado por um caro e paralelo quando o gargalo é o prazo.

5.1.3 RQ3 — perfil de erro

A anatomia dos 324 erros do melhor oráculo (v4-pro, S-strat) revela estrutura, não ruído difuso: **31%** são confusões entre *categorias-irmãs* que compartilham palavra (*antiséptico bucal* → *enxaguante bucal*; *ervilha* → *ervilha em conserva*); **17%** têm como gabarito uma classe guarda-chuva *outro* . . . (o modelo escolhe a específica; o catálogo arquiva na agregadora) e 7% o inverso; $\approx$ 2% envolvem `_rare_` ou rótulo inválido; o restante são erros semânticos genuínos. Ou seja: quase metade do erro do oráculo não é ignorância sobre o produto, e sim desconhecimento das *convenções deste catálogo* — fronteiras entre classes vizinhas e política de agregação que só se aprendem com exemplos rotulados. Esse diagnóstico tem duas consequências: motiva a ablação de prompt do E0-P (regras de fronteira explícitas) e prevê que o ruído do oráculo é *estruturado* (concentrado em pares vizinhos), cenário menos danoso ao classificador treinado que ruído uniforme (Frénay e Verleysen, 2014; Song et al., 2023) — hipótese testada no E4.

5.1.4 RQ4 — efeito do instrumento de medição

Com o mesmo modelo (gpt-4o-mini), as mesmas 1.000 instâncias da S-rand e o mesmo *prompt*, a troca do instrumento — saída estruturada com `enum` *versus* saída livre (réplica do instrumento do legado) — produz: acurácia 61,3% (enum) contra 60,5% (free), mas taxa de rótulos inválidos de **0,0% contra 6,8%**. O efeito do instrumento aparece menos na acurácia pontual e mais na *contabilidade do erro*: sem restrição de saída, quase 7% das respostas são variações de fraseado fora do espaço de rótulos, que um protocolo ingênuo computa como erro do modelo — deflacionando a medição e contaminando qualquer comparação entre modelos com propensões diferentes a parafrasear. A restrição por `enum` com validação estrita elimina essa classe de artefato por construção, e é por isso o modo de produção do FALCO (Princípio III da constituição do projeto).

5.1.5 Sensibilidade ao ruído do gabarito e calibração do lote

Duas verificações de instrumentação completam o E0. **Gabarito**: reavaliando todos os oráculos (a) sem as instâncias de rótulo conflitante e (b) sob pontuação *multi-gold*, a acurácia varia no máximo +0,7 p.p., sem alterar nenhum ordenamento — o ruído conhecido do gabarito limita o teto de medição ($\approx 99,3\%$), mas não contamina as comparações (Seção 3.2.2). **Lote**: na calibração pareada (lotes de 1, 10 e 25 itens nas mesmas instâncias), o McNemar não detecta degradação ($b = 1$ vs. $b = 10$: $p = 0,58$), e o lote reduz o custo por rótulo em até 10 vezes ao amortizar o prefixo — adotou-se $b = 10$ (OpenAI) e $b = 25$ (MaaS), registrado por anotação.

5.2 E0-P: O PROMPT COMO VARIÁVEL DO INSTRUMENTO

A anatomia de erros (RQ3) indica que $\approx 48\%$ dos erros do oráculo são de convenção de catálogo — atacáveis por *prompt*. O E0-P mede esse potencial no modelo de MENOR custo com cache (gpt-4o-mini): variantes **v4a** (dez regras de fronteira explícitas derivadas do perfil de erro da S-strat) e **v4b** (v4a + dez exemplos *inventados* de fronteiras difíceis — nunca instâncias das amostras, desenho anti-vazamento D-004), pareadas com o v3 oficial nos mesmos 500 primeiros itens de cada amostra. A Tabela 5.3 resume o resultado (artefato: `experiments/e0p/results/analysis.json`).

O resultado é uma faca de dois gumes — e por isso mesmo informativo. Na S-rand, que espelha a distribuição de produção, as regras de fronteira recuperam parte do erro de convenção: +3,8 p.p. com v4a ($p = 0,045$) e +4,6 p.p. com v4b ($p = 0,012$), confirmando que uma fração do déficit do modelo fraco é atacável por *prompt* sem nenhum rótulo adicional. Na S-strat, porém, as mesmas regras *destroem* desempenho: $-7,0$ e $-10,8$ p.p. ($p < 0,001$), com os exemplos inventados piorando significativamente sobre as regras puras ($p = 0,0013$). A leitura é direta: regras derivadas do perfil de erro agregado empurram o modelo para as convenções das classes *frequentes*, exatamente o comportamento que penaliza a amostra estratificada, dominada por

Tabela 5.3: E0-P — ablação de *prompt* no gpt-4o-mini (enum, $b = 10$, $n = 500$ pareado por amostra). p : McNemar exato contra o v3.

Amostra	Variante	Acurácia	Discordantes (+/-)	p vs. v3
S-rand	v3 (base)	60,4%	—	—
S-rand	v4a (regras)	64,2%	50/31	0,045
S-rand	v4b (regras+ex.)	65,0%	50/27	0,012
S-strat	v3 (base)	51,8%	—	—
S-strat	v4a (regras)	44,8%	20/55	< 0,001
S-strat	v4b (regras+ex.)	41,0%	14/68	< 0,001

classes raras. Duas implicações para o FALCO: (i) otimização de *prompt* deve ser validada nas *duas* distribuições antes de adoção, pois um ganho medido só na amostra natural pode mascarar regressão severa nas caudas; e (ii) o ganho barato na distribuição de produção existe e justifica a direção de trabalho futuro de gerar regras automaticamente a partir da matriz de confusão (Seção 6.5) — desde que com salvaguarda estratificada.

5.3 E1: ESTRATÉGIAS DE SELEÇÃO COM ORÁCULO PERFEITO

O E1 varre as cinco estratégias de seleção (entropia, menor confiança, menor margem, híbrida, aleatória) com o PVBin e oráculo simulado sem ruído, em pool deduplicado de 20.000 instâncias, orçamento de 3.000 rótulos, lote 100 e 8 sementes por célula; a ablação de lote repete a entropia — a estratégia pré-registrada da Fase 2 do FALCO e do E4 — com $b \in \{50, 200\}$. O teto supervisionado do *pool* completo (20.000 rótulos) é Macro F1 = 0,540. A Tabela 5.4 apresenta as células (artefato: `experiments/ele4/results/analysis.json`).

Tabela 5.4: E1 — estratégias com oráculo perfeito (média $\pm$ dp sobre 8 sementes; orçamento 3.000, lote 100). p : Wilcoxon pareado por semente contra a aleatória; com $n = 8$, o menor p atingível é 0,0078.

Estratégia	LCE	Macro F1 final	p vs. aleatória
Menor margem	0,528 $\pm$ 0,013	0,418 $\pm$ 0,013	0,0078
Menor confiança	0,518 $\pm$ 0,010	0,421 $\pm$ 0,009	0,0078
Entropia	0,493 $\pm$ 0,006	0,398 $\pm$ 0,008	0,0078
Híbrida	0,476 $\pm$ 0,014	0,379 $\pm$ 0,008	0,0078
Aleatória	0,444 $\pm$ 0,011	0,339 $\pm$ 0,006	—

Três leituras. **(i) Toda estratégia de incerteza supera a aleatória**, e o faz no máximo de significância que 8 sementes permitem ($p = 0,0078$ em LCE e em F1 final, todas as comparações): com 15% do orçamento de rótulos, a melhor célula recupera 78% do Macro F1 do teto supervisionado. **(ii) As margens vencem a entropia** no regime de 621 classes: menor margem lidera em LCE (0,528) e menor confiança em F1 final (0,421), enquanto a entropia — diluída pela cauda longa de probabilidades em espaços de classe muito grandes — fica ≈ 2 –3 p.p. atrás; a híbrida herda o pior dos dois mundos. **(iii) O lote é barato até certo ponto**: na ablação

com entropia, $b = 50$ (LCE $0,492 \pm 0,009$) e $b = 100$ ($0,493 \pm 0,006$) são indistinguíveis, mas $b = 200$ degrada para $0,481 \pm 0,012$ — com lotes grandes a seleção repete redundância dentro do próprio lote antes de o modelo se atualizar. Para o FALCO, isso fixa o lote operacional em $b \leq 100$ e recomenda menor margem/menor confiança como estratégias da Fase 2.

5.4 E4: ROBUSTEZ DO APRENDIZADO AO RUÍDO DO ORÁCULO

O E4 injeta ruído uniforme $\varepsilon \in \{0,1; 0,2; 0,4\}$ no oráculo simulado e repete o desenho do E1 para entropia e aleatória — a pergunta é quanto do valor do aprendizado ativo sobrevive quando o oráculo erra na taxa observada nos LLMs reais ($\varepsilon \approx 0,17\text{--}0,23$ no platô do E0). A Tabela 5.5 apresenta o resultado (mesmo artefato do E1).

Tabela 5.5: E4 — robustez ao ruído uniforme do oráculo (média $\pm$ dp, 8 sementes). Retenção: fração do Macro F1 final da mesma estratégia em $\varepsilon = 0$. p : Wilcoxon pareado entropia vs. aleatória no mesmo ε .

ε	Estratégia	Macro F1 final	Retenção	p
0,1	Entropia	$0,347 \pm 0,008$	87,2%	0,0078
	Aleatória	$0,294 \pm 0,006$	86,7%	
0,2	Entropia	$0,294 \pm 0,006$	74,0%	0,0078
	Aleatória	$0,252 \pm 0,006$	74,4%	
0,4	Entropia	$0,215 \pm 0,010$	54,1%	0,0078
	Aleatória	$0,186 \pm 0,006$	54,8%	

Dois achados. **Primeiro, o ruído custa caro, mas não destrói o aprendizado ativo:** a vantagem da entropia sobre a aleatória sobrevive *intacta e no teto de significância* em todos os níveis de ruído ($p = 0,0078$ em LCE e F1 final para todo ε), e a retenção relativa das duas estratégias é praticamente idêntica (87%, 74% e 54% em $\varepsilon = 0,1, 0,2$ e $0,4$) — ou seja, o ruído uniforme deprime a curva inteira sem corroer o *valor da seleção*. Não há, neste regime, o colapso descrito na literatura em que a incerteza persegue os rótulos errados. **Segundo, a taxa de erro dos oráculos reais está na faixa tolerável:** os LLMs do E0 erram $\varepsilon \approx 0,17\text{--}0,23$ no espaço fechado, região em que o E4 mede retenção de $\approx 74\text{--}87\%$ do F1 final. E o E4 é deliberadamente pessimista: injeta ruído *uniforme*, enquanto a anatomia do RQ3 mostrou que quase metade do erro real dos oráculos é estruturado (categorias-irmãs e guarda-chuva semanticamente próximas), cujo dano esperado ao classificador é menor que o do erro aleatório de mesma taxa (Frénay e Verleysen, 2014; Song et al., 2023). O resultado positivo aqui obtido é, portanto, um limite inferior do desempenho esperável com os oráculos reais do E0.

5.5 DECISÃO DO GATE E CONFIGURAÇÃO DO FALCO

Aplicando o critério pré-registrado da Seção 3.7.3 aos resultados do E0: nenhum oráculo atinge acurácia $\geq 85\%$ na S-rand; portanto, (i) o **E4 torna-se obrigatório** — executado

nesta tese com o classificador leve (Seção 5.4) e pronto para reexecução com BERTimbau —, e (ii) a discussão passa a tratar o aprendizado com oráculo ruidoso como cenário central, não excepcional. Para a configuração de oráculos do FALCO derivada do E0: **LLM Inicial** = deepseek-v4-flash (melhor razão acurácia/custo: 78–82% a US\$ 0,035/1k); **LLM Avançado** = deepseek-v4-pro (maior acurácia; significativamente superior ao flash na S-strat, $p < 0,001$ — o critério de superioridade significativa é atendido e a Fase 3 do FALCO se justifica). O gpt-4o não se qualifica em nenhum papel: empata com o v4-pro em acurácia e custa o dobro; o gpt-4o-mini é eliminado ($p \approx 0$ contra todos na S-strat).

6 DISCUSSÃO E CONCLUSÃO

6.1 SÍNTESE DOS ACHADOS

Esta tese perguntou como reduzir o custo de rotulagem na classificação de textos curtos em português sem perda relevante de desempenho, usando modelos de linguagem nas fases em que o aprendizado ativo tradicional é mais frágil. Os quatro pilares produziram um quadro coerente:

P1 — a composição do conjunto inicial importa, e importa mais quanto menor o orçamento. A sensibilidade medida (47 tamanhos $\times$ 30 repetições, reproduzida de forma independente com divergência $\leq 0,7$ p.p.) mostra amplitude de 6,4 p.p. de acurácia em $|L_0| = 100$ causada só pelo sorteio, decaindo até a irrelevância em $|L_0| \geq 10^5$. O envelope evolutivo confirma dezenas de pontos percentuais entre composições boas e ruins no regime pequeno — o regime do *cold start*.

P2 — é possível capturar esse espaço sem nenhum rótulo. O DRI-SL, heurística determinística de densidade semântica + variedade lexical, superou o *melhor indivíduo* encontrado pelo algoritmo genético supervisionado em todos os tamanhos de 100 a 5.000 — e a reexecução com protocolo anticircularidade mostrou que essa comparação é conservadora, pois o envelope do AG estava inflacionado em até 6,3 p.p. pela avaliação na própria partição de aptidão.

P3 — oráculos LLM são viáveis, baratos e erram de forma estruturada. No espaço fechado de 621 categorias, os melhores oráculos zero-shot atingem 77–83% de acurácia (v4-pro: 82,6% na S-strat) — a ≈ 7 p.p. do teto supervisionado com 250 mil rótulos — a custos entre US\$ 0,035 e US\$ 0,92 por mil rótulos, ordens de grandeza abaixo da anotação humana (Gilardi et al., 2023). O Macro F1 zero-shot ($\approx 0,79$) supera o do baseline supervisionado leve (0,70): o LLM é *melhor nas classes raras* e pior nas convenções do catálogo — quase metade dos seus erros são fronteiras entre categorias-irmãs e política de classes guarda-chuva, aprendíveis apenas com exemplos. O efeito do instrumento de medição (RQ4) confirmou-se: sem restrição de saída, 6,8% das respostas viram falsos erros de fraseado.

P4 — parcial nesta versão. O gate pré-registrado decidiu: sem oráculo $\geq 85\%$, o aprendizado com oráculo ruidoso é o cenário central (E4), e a configuração derivada do FALCO é deepseek-v4-flash (Inicial) + deepseek-v4-pro (Avançado, superioridade significativa comprovada). A validação integrada com BERTimbau (E3) tem instrumental completo e testado — laço de AL, runner de fases com transição por validação, cinco braços incluindo o oráculo-total — e aguarda execução na estação com GPU.

6.2 DISCUSSÃO

O que muda quando o oráculo é um LLM. A literatura clássica de AL minimiza *contagem de rótulos* assumindo oráculo correto (Settles, 2012; Olsson, 2009); a com custos reais mostra que contagem não é custo (Settles et al., 2008). Com oráculo LLM, a moeda muda duas vezes: o custo vira função de tokens (e do *cache*, e do lote — nossa instrumentação mede os três) e a qualidade vira parâmetro escolhível num cardápio com uma ordem de grandeza de variação de preço. A decisão “qual oráculo em qual fase” — o coração do FALCO — só faz sentido nesse regime novo, e os dados do E0 mostram que ela não é trivial: o modelo mais caro (gpt-4o) não é o mais acurado, e o segundo mais barato entrega 96% da acurácia do melhor por 8,5% do custo.

Erro estruturado é menos grave que erro uniforme — e é o que temos. O perfil de erro do RQ3 (confusões concentradas em pares vizinhos e classes guarda-chuva) é o cenário benigno da literatura de rótulos ruidosos (Frénay e Verleysen, 2014; Natarajan et al., 2013; Song et al., 2023): parte do “erro” do oráculo é inclusive defensável semanticamente (a análise multi-gold mostrou que o gabarito também erra). Isso sugere que o E4 com ruído *uniforme* — nosso desenho — é um teste *mais duro* que a realidade, o que fortalece qualquer resultado positivo obtido nele.

A medição é parte do método. Três achados desta tese são sobre instrumentos, não sobre modelos: o efeito do enum (RQ4), a inflação de circularidade no envelope evolutivo (−6,3 p.p. ao reavaliar em teste intocado) e o teto imposto pelo ruído do gabarito (limitado a +0,7 p.p. nas comparações). Em conjunto, eles justificam a posição metodológica central do trabalho: nenhum número sem artefato rastreável, e nenhum instrumento sem quantificação do seu próprio erro.

6.3 CONTRIBUIÇÕES

(i) O framework FALCO — fases com oráculo LLM progressivo e *cold start* informado — com implementação aberta, testada e reproduzível; (ii) o algoritmo DRI-SL e a evidência de que supera o envelope evolutivo supervisionado no regime de interesse; (iii) a avaliação instrumentada de oráculos LLM para português com 621 classes — granularidade muito acima da usual na literatura de LLM-como-anotador — incluindo custo real com *cache* e lote; (iv) a métrica LCE (com posicionamento explícito frente à ALC); (v) o conjunto de dados público auditado, com censo de conflitos e análise de sensibilidade; e (vi) a biblioteca *activelearning* e o FlowBuilder (ingestão com saneamento, execução parametrizada e curvas), que tornam o protocolo reutilizável fora desta tese.

6.4 LIMITAÇÕES

As ameaças à validade estão detalhadas na Seção 3.9; as principais: um único conjunto de dados, criado pelo autor (mitigado por protocolo replicável e achados de mecanismo);

resultados de P4 com classificador leve nesta versão (BERTimbau pendente de GPU); custos de API datados (as *razões* entre modelos são mais estáveis que os valores); e regras de fronteira do E0-P derivadas do perfil de erro do próprio domínio — generalizam o método, não as regras.

6.5 TRABALHOS FUTUROS

Quatro direções saem diretamente dos dados: **(i)** composição de oráculos — comparar a progressão sequencial do FALCO com *mixture-of-LLMs* paralelo (Qi et al., 2026) e com roteamento por confiança (Rouzegar e Makrehchi, 2024), idealmente formulando a escolha de oráculo por fase como problema de *bandit* com custo (Blum e Mansour, 2007; Baykal et al., 2021); **(ii)** *prompt* como componente otimizável — o E0-P abre a porta; a versão natural seguinte é gerar regras de fronteira automaticamente a partir da matriz de confusão de uma rodada anterior; **(iii)** usar os racionais do oráculo (*expanded_description*) como atributo auxiliar do classificador (Sharma et al., 2015); **(iv)** réplica em benchmark público de produtos (STOPS, Karl e Scherp, 2023) e extensão a taxonomias hierárquicas (Sun et al., 2003; Tan et al., 2020).

6.6 CONCLUSÃO

No estado atual da evidência: o custo de rotulagem em classificação de textos curtos em português pode ser atacado nas três frentes que o FALCO integra — começar bem (DRI-SL supera até o envelope evolutivo), perguntar bem (estratégias de incerteza sobre classificador barato) e pagar bem (oráculos LLM com 78–83% de acurácia por centavos de dólar o milhar, com erro majoritariamente estruturado). A hipótese quantitativa central — $\geq 95\%$ do Macro F1 de supervisão completa com $\leq 30\%$ dos rótulos via oráculo LLM — permanece formalmente aberta até o E3 com BERTimbau, cujo instrumental esta tese deixa pronto, testado e com critérios de decisão pré-registrados; os resultados dos experimentos executados (E0, E0-P, E1, E4 e os replays de P1/P2) delimitam com precisão as condições em que ela pode se sustentar.

REFERÊNCIAS

- Abe, N. e Mamitsuka, H. (1998). Query learning strategies using boosting and bagging. Em Shavlik, J. W., editor, *Proceedings of the Fifteenth International Conference on Machine Learning (ICML '98)*, páginas 1–9. Morgan Kaufmann.
- Aggarwal, C. C. e Zhai, C. (2012). A survey of text classification algorithms. Em Aggarwal, C. C. e Zhai, C., editores, *Mining Text Data*, páginas 163–222. Springer.
- Ahmed, M. H., Tiun, S. e Omar, N. (2023). Topic modelling for short texts: A survey. *Information*, 14(4):215.
- Ahmed, M. H., Tiun, S., Omar, N. e Sani, N. S. (2022). Short text clustering algorithms, application and challenges: A survey. *Applied Sciences*, 13(1):342.
- Aliero, A. A., Adebayo, B. S., Aliyu, H. O., Tafida, A. G., Kangiwa, B. U. e Dankolo, N. M. (2023). Systematic review on text normalization techniques and its approach to non-standard words. *International Journal of Computer Applications*, 185(33):1–10.
- Alsmadi, I. e Gan, K. H. (2019a). Review of short-text classification. *International Journal of Web Information Systems*, 15(2):155–182.
- Alsmadi, I. e Gan, K. H. (2019b). Review of short-text classification. *International Journal of Web Information Systems*, 15(2):155–182.
- Angluin, D. (1988). Queries and concept learning. Em *Machine Learning*, volume 2, páginas 319–342.
- Attenberg, J. e Provost, F. (2010). Why label when you can search?: Alternatives to active learning for applying human resources to build classification models under extreme class imbalance. *Proceedings of the 16th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, páginas 423–432.
- Baeza-Yates, R. e Ribeiro-Neto, B. (2013). *Recuperação de Informação: conceitos e tecnologia das máquinas de busca*. Bookman Editora, Porto Alegre, 2 edition.
- Barros, R. C., Garcia, L. e Cavalcanti, G. (2014). Aprendizado supervisionado com conjuntos de dados desbalanceados. *Revista de Sistemas de Informação da FSMA*, (13):4–19.
- Baum, E. B. e Lang, K. (1992). Query learning can work poorly when a human oracle is used. Em *Proceedings of the IEEE International Joint Conference on Neural Networks*, páginas 1386–1391.

- Bayer, M. e Reuter, C. (2024). Activellm: Large language model-based active learning for textual few-shot scenarios. arXiv preprint arXiv:2405.10808.
- Bayer, M. e Reuter, C. (2026). ActiveLLM: large language model-based active learning for textual few-shot scenarios. *Transactions of the Association for Computational Linguistics*.
- Baykal, C., Liebenwein, L., Gal, O., Feldman, D. e Rus, D. (2021). Low-regret active learning.
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer, New York, NY.
- Blum, A. e Mansour, Y. (2007). Learning, regret minimization, and equilibria. Em Nisan, N., Roughgarden, T., Tardos, É. e Vazirani, V. V., editores, *Algorithmic Game Theory*. Cambridge University Press.
- Blum, A. e Mitchell, T. (1998). Combining labeled and unlabeled data with co-training. Em *Proceedings of the Eleventh Annual Conference on Computational Learning Theory (COLT '98)*, páginas 92–100. ACM.
- Bojanowski, P., Grave, E., Joulin, A. e Mikolov, T. (2017). Enriching word vectors with subword information. Em *Transactions of the Association for Computational Linguistics*, volume 5, páginas 135–146.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.
- Chapelle, O., Schölkopf, B. e Zien, A., editores (2006). *Semi-Supervised Learning*. The MIT Press, Cambridge, MA.
- Cohn, D., Atlas, L. e Ladner, R. (1994). Improving generalization with active learning. *Machine learning*, 15(2):201–221.
- Cohn, D. A., Ghahramani, Z. e Jordan, M. I. (1996). Active learning with statistical models. *Journal of Artificial Intelligence Research*, 4:129–145.
- Cortes, C. e Vapnik, V. N. (1995). Support-vector networks. *Machine Learning*, 20(3):273–297.
- Cover, T. e Hart, P. (1967). Nearest neighbor pattern classification. *IEEE transactions on information theory*, 13(1):21–27.
- Dagan, I. e Engelson, S. (1995). Committee-based sampling for training probabilistic classifiers. Em *12th International Conference on Machine Learning*, páginas 150–157.
- Darú, G. H. (2024). Categorização de produtos em e-commerce: avaliação do método argmax para classificação de descrições curtas em português. Dissertação de Mestrado, Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos.

- Darú, G. H., Motta, F. D. d., Castelo, A. e Loch, G. V. (2022). Short text classification applied to item description: Some methods evaluation. *Semina: Ciências Exatas e Tecnológicas*, 43(2):189–198.
- Dasgupta, S. e Hsu, D. (2008). Hierarchical sampling for active learning. Em *Proceedings of the 25th International Conference on Machine Learning (ICML '08)*, páginas 208–215. ACM.
- Deng, Z., Yang, Y. e Suzuki, K. (2023). Federated active learning framework for efficient annotation strategy in skin-lesion classification. *arXiv preprint arXiv:2303.09753*.
- Devlin, J., Chang, M.-W., Lee, K. e Toutanova, K. (2019a). Bert: Pre-training of deep bidirectional transformers for language understanding. Em *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, volume 1, páginas 4171–4186.
- Devlin, J., Chang, M.-W., Lee, K. e Toutanova, K. (2019b). Bert: Pre-training of deep bidirectional transformers for language understanding. Em *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, volume 1, páginas 4171–4186.
- Diao, S., Wang, P., Lin, Y. e Zhang, Y. (2023). Active prompting with chain-of-thought for large language models. *arXiv preprint arXiv:2302.12246*.
- Dietterich, T. G. (2000). Ensemble methods in machine learning. *Multiple Classifier Systems*, 1857:1–15.
- Duda, R. O., Hart, P. E. e Stork, D. G. (2001). *Pattern Classification*. Wiley-Interscience, New York, NY, 2nd edition.
- Ein-Dor, L., Halfon, A., Gera, A., Shnarch, E., Dankin, L. E., Choshen, L., Danilevsky, M., Aharonov, R., Katz, Y. e Slonim, N. (2020). Active learning for bert: An empirical study. Em *EMNLP 2020*, páginas 7949–7962.
- Forman, G. e Scholz, M. (2010). Apples-to-apples in cross-validation studies: pitfalls in classifier performance measurement. *ACM SIGKDD explorations newsletter*, 12(1):49–57.
- Frénay, B. e Verleysen, M. (2014). Classification in the presence of label noise: A survey. *IEEE Transactions on Neural Networks and Learning Systems*, 25(5):845–869.
- Freund, Y., Seung, H. S., Shamir, E. e Tishby, N. (1997). Selective sampling using the query by committee algorithm. *Machine Learning*, 28(2-3):133–168.
- Fromme, L., Mirylenka, K., Kuhn, J. e Bogojeska, J. (2022). Investigating active learning sampling strategies for extreme multi label text classification. Em *Proceedings of the 13th Conference*

- on Language Resources and Evaluation (LREC 2022)*, páginas 4597–4605, Marseille, France. European Language Resources Association.
- Gal, Y., Islam, R. e Ghahramani, Z. (2017). Deep bayesian active learning with image data. 70:1183–1192.
- Gilardi, F., Alizadeh, M. e Kubli, M. (2023). Chatgpt outperforms crowd workers for text-annotation tasks. *Proceedings of the National Academy of Sciences*, 120(30):e2305016120.
- Goldberg, D. E. (1989). *Genetic Algorithms in Search, Optimization, and Machine Learning*. Addison-Wesley.
- Goldberg, Y. (2017). Neural network methods for natural language processing. *Synthesis Lectures on Human Language Technologies*, 10(1):1–309.
- Golovin, D. e Krause, A. (2011). Adaptive submodularity: Theory and applications in active learning and stochastic optimization. *Journal of Artificial Intelligence Research*, 42:427–486.
- Goodfellow, I., Bengio, Y. e Courville, A. (2016). *Deep Learning*. The MIT Press, Cambridge, MA.
- Goudjil, M., Koudil, M., Bedda, M. e Ghoggali, N. (2018). A novel active learning method using SVM for text classification. *International Journal of Automation and Computing*, 15(3):290–298.
- Grandini, M., Bagli, E. e Visani, G. (2020). Metrics for multi-class classification: an overview. *arXiv preprint arXiv:2008.05756*.
- Grießhaber, D., Maucher, J. e Vu, N. T. (2020). Fine-tuning bert for low-resource natural language understanding via active learning. Em *COLING 2020*, páginas 1158–1171.
- Guestrin, C., Krause, A. e Singh, A. P. (2005). Near-optimal sensor placements in gaussian processes. Em *Proceedings of the 22nd International Conference on Machine Learning (ICML '05)*, páginas 265–272. ACM.
- Guo, J., Chen, C. L. P., Li, S. e Zhang, T. (2025). DEUCE: Dual-diversity enhancement and uncertainty-awareness for cold-start active learning.
- Guyon, I., Cawley, G., Dror, G. e Lemaire, V. (2011). Results of the active learning challenge. Em *JMLR Workshop and Conference Proceedings (AISTATS 2011 Workshop)*, volume 16, páginas 19–45.
- Han, J., Kamber, M. e Pei, J. (2012). *Data Mining: Concepts and Techniques*. Morgan Kaufmann Publishers Inc., San Francisco, CA, USA, 3rd edition.

- Hanneke, S. (2015). Theory of disagreement-based active learning. *Foundations and Trends in Machine Learning*, 7(2–3):131–309.
- Hoi, S. C. H., Jin, R. e Lyu, M. R. (2006). Large-scale text categorization by batch mode active learning. Em *15th International Conference on World Wide Web*, páginas 633–642.
- Holland, J. H. (1975). *Adaptation in Natural and Artificial Systems*. University of Michigan Press.
- James, G., Witten, D., Hastie, T. e Tibshirani, R. (2013). *An introduction to statistical learning*, volume 112. Springer.
- Karl, F. e Scherp, A. (2023). Transformers are short-text classifiers: A study of inductive short text classifiers on benchmarks and real-world datasets. *Lecture Notes in Computer Science*, 14065:103–122.
- Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI)*, 2:1137–1143.
- Kowsari, K., Jafari Meimandi, K., Heidarysafa, M., Mendu, S., Barnes, L. e Brown, D. (2019). Text classification algorithms: A survey. *Information*, 10(4):150.
- Krause, A. e Golovin, D. (2014). Submodular function maximization. Em Nowozin, S., Poupart, P., Kohli, P. e Tu, Z., editores, *Tracts in Machine Learning*, volume 5. Cambridge University Press. Chapter in "Modern Convex Optimization and Its Applications".
- Lewis, D. D. e Catlett, J. (1994). Heterogeneous uncertainty sampling for supervised learning. Em Cohen, W. W. e Hirsh, H., editores, *Machine Learning: Proceedings of the Eleventh International Conference (ICML 1994)*, páginas 148–156. Morgan Kaufmann.
- Lewis, D. D. e Gale, W. A. (1994). A sequential algorithm for training text classifiers. *Proceedings of the 17th ACM SIGIR Conference*, páginas 3–12.
- Li, Q., Peng, H., Li, J., Xia, C., Yang, R., Sun, L., Yu, P. S. e He, L. (2020). A survey on text classification: From shallow to deep learning. *arXiv preprint arXiv:2008.00364*.
- Loshchilov, I. e Hutter, F. (2019). Decoupled weight decay regularization. Em *International Conference on Learning Representations (ICLR)*.
- Machado, J. d. F. U. e Veloso, B. (2026). Turning web data into official statistics: Classifying Portuguese retail products with NLP models. *Statistical Journal of the IAOS*, 42(1).
- MacKay, D. J. C. (1992). Information-based objective functions for active data selection. *Neural Computation*, 4(4):590–604.

- Margatina, K., Vernikos, G., Mou, L. e Gunel, B. (2023). Active learning strategies for large language models: A survey. *arXiv preprint arXiv:2303.13561*.
- McCallum, A. K. e Nigam, K. (1998). Employing em in pool-based active learning for text classification. Em Shavlik, J. W., editor, *Proceedings of the Fifteenth International Conference on Machine Learning (ICML '98)*, páginas 350–358. Morgan Kaufmann.
- McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2):153–157.
- Melville, P. e Mooney, R. J. (2004). Diverse ensembles for active learning. Em *Proceedings of the 21st International Conference on Machine learning (ICML '04)*, página 74. ACM.
- Mikolov, T., Chen, K., Corrado, G. e Dean, J. (2013). Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781*.
- Mitchell, T. M. (1982). Generalization as search. *Artificial Intelligence*, 18(2):203–226.
- Mitchell, T. M. (1997). *Machine Learning*. McGraw Hill, Burr Ridge, IL.
- Murphy, K. P. (2012). *Machine Learning: A Probabilistic Perspective*. The MIT Press, Cambridge, MA.
- Muslea, I., Minton, S. e Knoblock, C. A. (2000). Selective sampling with redundant views. Em *Proceedings of the Seventeenth National Conference on Artificial Intelligence (AAAI'00)*, páginas 621–626.
- Naseem, U., Razzak, I., Khan, S. K. e Prasad, M. (2021a). A comprehensive survey on word representation models: From classical to state-of-the-art word representation language models. *ACM Transactions on Asian and Low-Resource Language Information Processing*, 20(5):1–35.
- Naseem, U., Razzak, I., Khushi, M., Eklund, P. W. e Kim, J. (2021b). A survey on text preprocessing techniques and their impact on text classification. *ACM Computing Surveys (CSUR)*, 54(8):1–39.
- Natarajan, N., Dhillon, I. S., Ravikumar, P. e Tewari, A. (2013). Learning with noisy labels. Em *Advances in Neural Information Processing Systems 26 (NIPS)*, páginas 1196–1204.
- Nguyen, H. T. e Smeulders, A. W. M. (2004). Active learning using pre-clustering. Em *Proceedings of the 21st International Conference on Machine learning (ICML '04)*, página 79. ACM.
- Nti, I. K., Nyarko-Boateng, O. e Aning, J. (2021). Performance of Machine Learning Algorithms with Different K Values in K-fold Cross-Validation. *International Journal of Information Technology and Computer Science*, 13(6):61–71.

- Olsson, F. (2009). A literature survey of active machine learning in the context of natural language processing. Relatório Técnico T2009:06, Swedish Institute of Computer Science, Kista.
- Pennington, J., Socher, R. e Manning, C. D. (2014). Glove: Global vectors for word representation. *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing*, 14:1532–1543.
- Peters, M. E., Neumann, M., Iyyer, M., Gardner, M., Clark, C., Lee, K. e Zettlemoyer, L. (2018). Deep contextualized word representations. Em *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, páginas 2227–2237.
- Prechelt, L. (2012). Early stopping – but when? Em Montavon, G., Orr, G. B. e Müller, K.-R., editores, *Neural Networks: Tricks of the Trade*, volume 7700 de *Lecture Notes in Computer Science*, páginas 53–67. Springer, second edition.
- Qi, Y., Yang, X., Lu, J., Guo, G., Enticott, J., Liu, G. e Du, L. (2026). Next generation active learning: Mixture of LLMs in the loop.
- Quinlan, J. R. (1993). *C4.5: Programs for Machine Learning*. Morgan Kaufmann Publishers Inc., San Francisco, CA, USA.
- Radford, A., Narasimhan, K., Salimans, T. e Sutskever, I. (2018). Improving language understanding by generative pre-training.
- Radford, A., Wu, J., Child, R., Luan, D., Amodei, D. e Sutskever, I. (2019). Language models are unsupervised multitask learners. *OpenAI blog*, 1(8):9.
- Reimers, N. e Gurevych, I. (2019). Sentence-BERT: sentence embeddings using Siamese BERT-networks. Em *Proceedings of EMNLP-IJCNLP*, páginas 3982–3992.
- Ren, P., Xiao, Y., Chang, X., Huang, P., Li, Z., Chen, X. e Wang, X. (2021). A survey of deep active learning. *ACM Computing Surveys*, 54(9):1–40.
- Reusens, M., Stevens, A., Tonglet, J. e De Smedt, J. (2024). Evaluating text classification: A benchmark study. *Expert Systems with Applications*, 252:124168.
- Rifkin, R. e Klautau, A. (2004). In defense of one-vs-all classification. *Journal of Machine Learning Research*, 5:101–141.
- Riyanto, S., Sitanggang, I. S., Djatna, T. e Atikah, T. D. (2023). Comparative Analysis using Various Performance Metrics in Imbalanced Data for Multi-class Text Classification. (*IJACSA International Journal of Advanced Computer Science and Applications*, 14(6):1082–1090.

- Romberg, J., Schröder, C., Gonsior, J., Tomanek, K. e Olsson, F. (2025). Reassessing active learning adoption in contemporary NLP: A community survey.
- Rouzegar, H. e Makrehchi, M. (2024). Enhancing text classification through llm-driven active learning and human annotation.
- Roy, N. e McCallum, A. (2001). Toward optimal active learning through sampling estimation of error reduction. Em *Proceedings of the 18th International Conference on Machine Learning*, páginas 441–448.
- Russell, S. J. e Norvig, P. (2010). *Artificial Intelligence: A Modern Approach*. Prentice Hall, Upper Saddle River, NJ, 3rd edition.
- Salton, G. e Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information processing & management*, 24(5):513–523.
- Santos, D. P. d. (2016). *Seleção e controle do viés de aprendizado ativo*. Tese de doutorado, Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos.
- Schick, T., Dwivedi-Yu, J., Dessì, R., Raileanu, R., Lomeli, M., Zettlemoyer, L., Cancedda, N. e Scialom, T. (2023). Toolformer: Language models can teach themselves to use tools. arXiv preprint arXiv:2302.04761.
- Schröder, C., Müller, L., Niekler, A. e Potthast, M. (2021). Small-text: Active learning for text classification in python.
- Selva, J. P. e Titus, T. S. (2021). Review on word embedding techniques and its applications. *International Journal of Engineering Research & Technology (IJERT)*, 10(01).
- Settles, B. (2009). Active learning literature survey. Computer Sciences Technical Report 1648, University of Wisconsin-Madison.
- Settles, B. (2012). *Active Learning*. Synthesis Lectures on Artificial Intelligence and Machine Learning. Morgan & Claypool.
- Settles, B. e Craven, M. (2008). An analysis of active learning strategies for sequence labeling tasks. Em *Proceedings of the 2008 Conference on Empirical Methods in Natural Language Processing (EMNLP '08)*, páginas 1070–1079. Association for Computational Linguistics.
- Settles, B., Craven, M. e Friedland, L. (2008). Active learning with real annotation costs. Em *Proceedings of the NIPS Workshop on Cost-Sensitive Learning*.
- Seung, H. S., Opper, M. e Sompolinsky, H. (1992). Query by committee. Em *Proceedings of the Fifth Annual Workshop on Computational Learning Theory (COLT '92)*, páginas 287–294. ACM.

- Shannon, C. E. (1948). A mathematical theory of communication. *The Bell System Technical Journal*, 27(3):379–423.
- Sharma, M., Zhuang, D. e Bilgic, M. (2015). Active learning with rationales for text classification. Em *Proceedings of NAACL-HLT 2015*, páginas 441–451.
- Sokolova, M. e Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4):427–437.
- Song, G., Ye, Y., Du, X., Huang, X. e Bie, R. (2014a). Short text classification: A survey. *Journal of Multimedia*, 9(5):635–643.
- Song, G., Ye, Y., Du, X., Huang, X. e Bie, S. (2014b). Short text classification: A survey. *Journal of Multimedia*, 9(5):635–643.
- Song, H., Kim, M., Park, D., Shin, Y. e Lee, J.-G. (2023). Learning from noisy labels with deep neural networks: A survey. *IEEE Transactions on Neural Networks and Learning Systems*, 34(11):8135–8153.
- Souza, F., Nogueira, R. e Lotufo, R. (2020). BERTimbau: pretrained BERT models for Brazilian Portuguese. Em *Brazilian Conference on Intelligent Systems (BRACIS)*, páginas 403–417. Springer.
- Su, B., Guo, J., Liu, Q. e Zhang, Y. (2023). Freeal: Towards human-free active learning in the era of large language models. Em *EMNLP 2023*, páginas 7982–7995.
- Sun, A., Lim, E.-P. e Ng, W.-K. (2003). Performance measurement framework for hierarchical text classification. *Journal of the American Society for Information Science and Technology*, 54(11):1014–1028.
- Tan, L., Li, M. Y. e Kok, S. (2020). E-commerce product categorization via machine translation. *ACM Transactions on Management Information Systems*, 11(3):1–14.
- Tian, Y., Lee, J., Fu, B., Das, R., Khashabi, C. e Ma, J. (2023). Artprompt: Ascii art-based jailbreak attacks against aligned llms. arXiv preprint arXiv:2402.11753.
- Tong, S. e Koller, D. (2000). Support vector machine active learning with applications to text classification. Em Langley, P., editor, *Proceedings of the Seventeenth International Conference on Machine Learning (ICML 2000)*, páginas 999–1006. Morgan Kaufmann.
- Wei, J., Wang, X., Schuurmans, D., Bosma, M., Chi, E. H., Le, Q. V. e Zhou, D. (2022). Chain-of-thought prompting elicits reasoning in large language models. Em *Advances in Neural Information Processing Systems*.

- Widodo, S., Brawijaya, H. e Samudi (2022). Stratified K-fold cross validation optimization on machine learning for prediction. *Sinkron : Jurnal dan Penelitian Teknik Informatika*, 7(4):2407–2413.
- Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83.
- Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158):209–212.
- Wolf, T. et al. (2020). Transformers: state-of-the-art natural language processing. Em *Proceedings of EMNLP: System Demonstrations*, páginas 38–45.
- Wu, L., Lei, T. e Pineau, J. (2022). Active learning for natural language processing: A survey. arXiv preprint arXiv:2212.06445.
- Xia, Y., Mukherjee, S., Xie, Z. L., Wu, J., Li, X. e Aponte, R. (2025). From selection to generation: A survey of LLM-based active learning. Year set to 2025 as per the citation, corresponds to arXiv submission date.
- Xu, J., Xu, B., Wang, P., Zheng, S., Tian, G. e Zhao, J. (2017). Self-taught convolutional neural networks for short text clustering. *Neural Networks*, 88:22–31.
- Yan, Y., Rosales, R., Fung, G. e Dy, J. (2011). Active learning from crowds. Em *28th International Conference on Machine Learning*, páginas 1161–1168.
- Yuan, M., Lin, H.-T. e Boyd-Graber, J. (2020). Cold-start active learning through self-supervised language modeling. Em *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, páginas 7935–7948, Online. Association for Computational Linguistics.
- Zhang, Y. e Takada, S. (2025a). Applying LLMs to active learning: towards cost-efficient cross-task text classification without manually labeled data. arXiv:2502.16892.
- Zhang, Y. e Takada, S. (2025b). Applying LLMs to active learning: Towards cost-efficient cross-task text classification without manually labeled data. Year set to 2025 as per the citation, corresponds to arXiv submission date.
- Zhang, Z., Strubell, E. e Hovy, E. (2022a). A survey of active learning for natural language processing. Em *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, páginas 6166–6190, Abu Dhabi, United Arab Emirates. Association for Computational Linguistics.

- Zhang, Z., Strubell, E. e Hovy, E. (2022b). A survey of active learning for natural language processing. Em Goldberg, Y., Kozareva, Z. e Zhang, Y., editores, *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, páginas 6166–6190, Abu Dhabi, United Arab Emirates. Association for Computational Linguistics.
- Zhu, X. e Goldberg, A. B. (2009). Introduction to semi-supervised learning. *Synthesis Lectures on Artificial Intelligence and Machine Learning*, 3(1):1–130.

APÊNDICE A – MÉTRICA LEARNING CURVE EFFICIENCY (LCE)

A.1 DEFINIÇÃO

Seja uma execução de aprendizado ativo que produz a curva $\{(n_k, m_k)\}_{k=1}^K$, em que n_k é o número de instâncias rotuladas na iteração k (estritamente crescente) e m_k a métrica de interesse (nesta tese, Macro F1 no conjunto de teste fixo T). Define-se:

$$\text{LCE} = \frac{\int_{n_1}^{n_K} m(n) dn}{\text{Perf}_{\text{baseline}} \cdot (n_K - n_1)}, \quad (\text{A.1})$$

em que a integral do numerador (AUC_{real}) é calculada numericamente pela regra composta de Simpson sobre os pontos observados (com recuo para a regra do trapézio quando $K = 2$) e $\text{Perf}_{\text{baseline}}$ é o desempenho do MESMO classificador treinado com supervisão completa do pool. O denominador é a área da curva ideal: desempenho de referência atingido instantaneamente no início do processo ($L_{\text{ideal},0} = n_1$).

A.2 PROPRIEDADES

(i) $\text{LCE} \in (0, 1]$ quando $m_k \leq \text{Perf}_{\text{baseline}}$ para todo k ; valores maiores indicam aproximação mais rápida do teto. (ii) É invariante a transformações afins do eixo n (mudança de unidade de orçamento). (iii) Ao normalizar pelo teto do próprio par (classificador, conjunto) — e não pelo máximo teórico da métrica — permite comparar estratégias entre classificadores de tetos distintos: um classificador fraco bem servido pela estratégia pode ter LCE maior que um classificador forte mal servido. (iv) Depende do intervalo $[n_1, n_K]$: comparações exigem execuções com o mesmo orçamento e o mesmo L_0 — condição imposta em todos os desenhos desta tese.

A.3 RELAÇÃO COM A ALC

A *Area under the Learning Curve* do *Active Learning Challenge* (Guyon et al., 2011) também sumariza a curva por área normalizada. As diferenças da LCE: normalização pelo baseline de supervisão completa do próprio par (a ALC normaliza pelo máximo global da métrica) e integração de Simpson na grade observada (a ALC interpola em escala logarítmica de consultas). A implementação de referência está em `src/activelearning/domain/metrics.py` (função `lce`), com testes unitários de propriedades.

APÊNDICE B – ALGORITMO GENÉTICO PARA OTIMIZAÇÃO DE L0

B.1 FORMULAÇÃO

Indivíduo: conjunto de I índices únicos do pool (L_0 candidato). Aptidão: desempenho (Acurácia ou Macro F1) do classificador PVBin treinado no indivíduo e avaliado em partição de **aferição** disjunta do conjunto de teste (protocolo anticircularidade; ver Seção 4.4 para a quantificação do viés do protocolo ingênuo). Quatro cenários: maximização e minimização de cada métrica — o par (max, min) delimita o envelope empírico de desempenho alcançável pela composição.

B.2 OPERADORES E PARÂMETROS

- **População** $N_{pop} = 50$; **gerações** 100 (reexecução reduzida: 30×40 ; decisão D-002 do registro de decisões);
- **seleção**: torneio de tamanho $k_t = 3$;
- **cruzamento**: um ponto sobre a lista de índices, com probabilidade $p_c = 0,8$, seguido de *reparo de unicidade* (índices repetidos são substituídos por sorteio até restaurar $|L_0| = I$);
- **mutação**: com probabilidade $p_m = 0,1$, substituição de $m_s = \max(1, \lceil 0,01 \cdot I \rceil)$ genes por índices inéditos;
- **elitismo**: 10% ($N_{elite} = 5$ na configuração original).

B.3 PSEUDOCÓDIGO

1. Inicializar N_{pop} indivíduos por amostragem uniforme sem reposição.
2. Avaliar aptidão de todos na partição de aferição.
3. Por geração: copiar elite; completar a população por torneio $\rightarrow$ cruzamento $\rightarrow$ reparo $\rightarrow$ mutação; reavaliar.
4. Ao final, **reavaliar o melhor indivíduo no conjunto de teste intocado** — o valor reportado como envelope é este, não a aptidão.

Implementação de referência da reexecução: `experiments/p1/replay_ga.py`; resultados em `experiments/p1/results/replay_ga.jsonl`.

APÊNDICE C – ALGORITMO DRI-SL

C.1 OBJETIVO E ENTRADAS

Construir L_0 de tamanho alvo I a partir do pool não rotulado U , sem acesso a rótulos. Entradas: textos de U ; codificador de sentenças ϕ (SBERT multilíngue (Reimers e Gurevych, 2019) na configuração da tese); número de grupos N_c (padrão $\max(2, \lfloor \sqrt{I} \rfloor)$); semente.

C.2 ETAPAS

1. **Densidade semântica:** projetar U por ϕ ; agrupar por k -médias em N_c grupos; alocar a cota q_c de cada grupo proporcionalmente ao seu tamanho (cota mínima de 1 para grupo não vazio; ajuste do resto pelas maiores frações).
2. **Variedade lexical intragrupo:** para cada grupo c , computar o perfil TF-IDF médio; selecionar iterativamente, entre os membros ainda não escolhidos, o texto que maximiza o *escore de novidade* — a soma dos pesos, no perfil do grupo, dos termos que o texto introduz e que ainda não estão cobertos pelos já selecionados; atualizar o conjunto de termos cobertos; repetir até preencher q_c .

A seleção é determinística dada a semente (inicialização do k -médias). O custo é dominado pela codificação ($O(|U|)$ passagens do codificador) e pelo k -médias; a etapa lexical é $O(q_c \cdot |c|)$ por grupo, com operações esparsas.

C.3 INTUIÇÃO

A etapa 1 garante *representatividade*: cada região semântica do pool contribui proporcionalmente — nenhum agrupamento relevante fica de fora do L_0 . A etapa 2 garante *não redundância*: dentro da região, evita quase-duplicatas (frequentes no domínio: 7,7% de duplicatas exatas) e força cobertura de vocabulário — que, para um classificador por protótipo como o PVBin, é exatamente o recurso que constrói fronteiras. A combinação explica o resultado do Capítulo 4: cobertura semântica dá o esqueleto de classes; cobertura lexical dá o poder discriminativo por classe.

Implementação de referência: `src/activelearning/adapters/strategies/drisl.py` (com codificador alternativo TF-IDF+SVD para ambientes leves), testes em `tests/unit/test_drisl.py`.

APÊNDICE D – A BIBLIOTECA ACTIVELEARNING

D.1 ARQUITETURA

A biblioteca segue arquitetura hexagonal com domínio isolado: o núcleo (`domain/`) contém instâncias, o espaço fechado de categorias (*CategorySchema*), anotações com contabilidade de uso (*OracleUsage*: tokens, tokens em cache, custo, latência), estratégias de incerteza e métricas (LCE, Wilson, McNemar) — puro, sem dependência de rede ou framework. Os **adapters** implementam as portas: oráculos (OpenAI, OpenAI-compatível/MaaS, OpenRouter, Gemini, Ollama, Simulado com ruído ε), classificadores (PVBIn; BERTimbau via `transformers`), estratégias com infraestrutura (DRI-SL com SBERT), dados (CSV do domínio) e persistência (SQLite/PostgreSQL). Os **casos de uso** (`application/`) orquestram: avaliação de oráculo (E0, retomável), laço de aprendizado ativo (E1/E4), runner do FALCO (fases com transição por validação) e saneamento de dados.

O diferencial frente a bibliotecas existentes de AL para texto — notadamente *small-text* (Schröder et al., 2021), que padroniza classificador $\times$ estratégia $\times$ critério de parada — é elevar o **oráculo** a porta de primeira classe: custo por consulta, modos de instrumentação (`enum/json-prompt/free`), variantes de prompt, lote por chamada e cache são medidos e registrados em cada anotação.

D.2 REPRODUÇÃO DOS EXPERIMENTOS

Cada experimento tem ponto de entrada único parametrizado por configuração versionada; execuções gravam sementes e registros por item/iteração (JSONL) e são retomáveis. Mapa: E0 $\rightarrow$ `experiments/e0/run_e0.py` (+ `analyze_e0.py`, `analyze_noise_impact.py`); E0-P $\rightarrow$ `experiments/e0p/`; P1/AG $\rightarrow$ `experiments/p1/`; E1/E4 $\rightarrow$ `experiments/e1e4/`; E2/E3 (GPU) $\rightarrow$ runner do FALCO em `application/run_falco.py` com os cinco braços do desenho. A suíte de testes unitários cobre domínio, adapters e casos de uso sem rede.

D.3 FLOWBUILDER

Interface web (FastAPI + React) sobre a biblioteca: envio de CSV com saneamento automático (remoção de rótulos operacionais; censo de conflitos e duplicatas; download da base saneada), execução parametrizada de fluxos (semente, orçamento, lote, L_0 , estratégia, oráculo — incluindo modelos de custo zero) e acompanhamento de curvas de aprendizado. O banco guarda o índice das execuções; os artefatos brutos permanecem em disco, versionáveis.

APÊNDICE E – PROMPTS E ESQUEMAS DO ORÁCULO LLM

E.1 PROMPT V3 (PRODUÇÃO)

Contexto de tarefa comum a todos os modos (o texto integral e versionado está em `src/activelearning/adapters/oracles/prompt.py`):

“Você é um especialista em catalogação de produtos do varejo brasileiro. As descrições vêm de cupons fiscais e cadastros de e-commerce: são curtas, geralmente em caixa alta e cheias de abreviações (ex.: CERV=cerveja, REFR=refrigerante, BISC=biscoito, CHOC=chocolate, RECH=recheado, PCT=pacote, LT=lata, CX=caixa, UN=unidade). Expanda mentalmente as abreviações e classifique o TIPO do produto, ignorando marca, tamanho e embalagem. Escolha sempre a categoria mais específica aplicável; na dúvida entre uma categoria plausível e ‘_rare_’, prefira a categoria plausível — use ‘_rare_’ SOMENTE se nenhuma categoria da lista descrever o tipo do produto. Exemplos: ‘CERV BRAHMA LT 350ML’ → cerveja; ‘BISC RECH CHOC 130G’ → biscoito; ‘REQUEIJAO LIGHT CP 200G’ → requeijao.”

O prefixo estático (contexto + esquema) precede o item variável, habilitando o *cache* de prefixo dos provedores (88–95% de acerto medido no E0).

E.2 MODOS DE INSTRUMENTAÇÃO

enum: saída estruturada com `strict:true`; o campo `predicted_category` é restrito por `enum` às 621 categorias do *CategorySchema*; campos `expanded_description` e `rationale` completam o objeto (todos obrigatórios — exigência do modo estrito). **json-prompt** (provedores sem saída estruturada): a lista de categorias e o formato JSON são instruídos no texto; a resposta passa por extração tolerante e validação exata contra o esquema, com rótulos fora do espaço contabilizados como inválidos. **free** (somente RQ4): saída estruturada sem `enum` — réplica controlada do instrumento defeituoso do trabalho anterior. Na rotulagem em lote, os itens são numerados e a resposta é um vetor indexado; o esquema do lote não fixa `minItems/maxItems` para preservar a cacheabilidade do prefixo; o uso (tokens/custo) é rateado igualmente entre os itens da chamada.

E.3 VARIANTES DO E0-P

v4a acrescenta dez regras de fronteira do catálogo derivadas da anatomia de erros (ex.: medicamentos → *outro farma*; produto bucal líquido → *antiséptico bucal*; pó para suco → *preparo para suco*; fones com fio → *acessorio de audio*); **v4b** soma dez exemplos *inventados* de

fronteiras difíceis (nunca instâncias das amostras de avaliação — decisão D-004). Texto integral das variantes no mesmo módulo versionado.

APÊNDICE F – TABELAS COMPLETAS

A Tabela F.1 apresenta as estatísticas descritivas completas do estudo de sensibilidade de L_0 (Seção 4.1): Acurácia Global e Macro F1 no teste T por tamanho I , com média, mediana, desvio-padrão, extremos, quartis e coeficiente de variação da mediana — 47 tamanhos, 30 repetições cada, classificador PVBin. A tabela reproduz o artefato original do programa experimental; a reexecução independente (15 tamanhos $\times$ 10 repetições) está em `experiments/p1/results/replay_l0.jsonl` no repositório de código.

Tabela F.1: Estatísticas Descritivas da Performance em Função do Tamanho de L_0 (Classificador: PVBin (1,2)-gram). 30 repetições por tamanho.

Métrica Base	Tam. L_0 (I)	Média	Mediana	DP	Mínimo	P25	P75	Máximo	IQR	CV (Med.)
Acurácia	10	0.067	0.069	0.024	0.026	0.046	0.088	0.102	0.042	0.345
Acurácia	20	0.105	0.110	0.023	0.049	0.089	0.122	0.138	0.033	0.211
Acurácia	30	0.140	0.139	0.023	0.095	0.125	0.155	0.181	0.030	0.165
Acurácia	40	0.160	0.159	0.023	0.100	0.145	0.178	0.191	0.034	0.141
Acurácia	50	0.178	0.180	0.022	0.124	0.164	0.199	0.208	0.034	0.121
Acurácia	60	0.193	0.194	0.019	0.145	0.179	0.207	0.230	0.027	0.100
Acurácia	70	0.207	0.207	0.014	0.177	0.196	0.219	0.229	0.023	0.067
Acurácia	80	0.224	0.224	0.015	0.203	0.212	0.235	0.252	0.023	0.066
Acurácia	90	0.235	0.234	0.019	0.205	0.221	0.250	0.278	0.029	0.082
Acurácia	100	0.247	0.247	0.016	0.217	0.237	0.257	0.281	0.020	0.064
Acurácia	200	0.333	0.333	0.016	0.306	0.321	0.345	0.370	0.024	0.048
Acurácia	300	0.391	0.392	0.010	0.365	0.388	0.397	0.409	0.010	0.027
Acurácia	400	0.435	0.434	0.010	0.417	0.429	0.439	0.465	0.009	0.023
Acurácia	500	0.468	0.467	0.008	0.452	0.463	0.475	0.483	0.012	0.018
Acurácia	600	0.491	0.492	0.008	0.471	0.486	0.496	0.509	0.010	0.016
Acurácia	700	0.513	0.513	0.007	0.497	0.508	0.516	0.530	0.008	0.014
Acurácia	800	0.529	0.532	0.009	0.508	0.524	0.537	0.544	0.013	0.018
Acurácia	900	0.546	0.547	0.005	0.534	0.544	0.550	0.557	0.006	0.010
Acurácia	1000	0.559	0.559	0.007	0.542	0.555	0.564	0.568	0.009	0.012
Acurácia	2000	0.640	0.641	0.004	0.633	0.637	0.643	0.648	0.006	0.006
Acurácia	3000	0.679	0.678	0.004	0.671	0.675	0.682	0.687	0.006	0.006
Acurácia	4000	0.705	0.705	0.003	0.698	0.703	0.707	0.714	0.003	0.004

Continua na próxima página

Tabela F.1 – continuação da página anterior

Métrica Base	Tam. L0 (I)	Média	Mediana	DP	Mínimo	P25	P75	Máximo	IQR	CV (Med.)
Acurácia	5000	0.721	0.721	0.003	0.713	0.719	0.723	0.726	0.005	0.004
Acurácia	6000	0.736	0.736	0.004	0.727	0.732	0.738	0.746	0.006	0.005
Acurácia	7000	0.747	0.747	0.003	0.741	0.744	0.748	0.751	0.004	0.003
Acurácia	8000	0.755	0.755	0.003	0.748	0.753	0.757	0.760	0.005	0.004
Acurácia	9000	0.763	0.762	0.003	0.758	0.761	0.765	0.769	0.004	0.004
Acurácia	10000	0.769	0.769	0.003	0.765	0.767	0.771	0.774	0.004	0.003
Acurácia	20000	0.806	0.807	0.002	0.802	0.805	0.808	0.812	0.003	0.003
Acurácia	30000	0.826	0.826	0.001	0.824	0.825	0.827	0.829	0.002	0.002
Acurácia	40000	0.838	0.838	0.001	0.835	0.837	0.839	0.842	0.002	0.002
Acurácia	50000	0.847	0.847	0.002	0.843	0.846	0.848	0.852	0.002	0.002
Acurácia	60000	0.853	0.854	0.001	0.851	0.853	0.854	0.856	0.001	0.001
Acurácia	70000	0.859	0.859	0.001	0.856	0.858	0.859	0.861	0.002	0.001
Acurácia	80000	0.864	0.863	0.001	0.861	0.863	0.864	0.867	0.002	0.001
Acurácia	90000	0.867	0.867	0.001	0.865	0.866	0.868	0.870	0.001	0.001
Acurácia	100000	0.871	0.871	0.001	0.869	0.870	0.872	0.873	0.001	0.001
Acurácia	110000	0.874	0.874	0.001	0.872	0.873	0.875	0.876	0.002	0.001
Acurácia	120000	0.876	0.877	0.001	0.875	0.876	0.877	0.878	0.001	0.001
Acurácia	130000	0.879	0.879	0.001	0.877	0.878	0.879	0.880	0.001	0.001
Acurácia	140000	0.881	0.881	0.001	0.880	0.881	0.882	0.883	0.001	0.001
Acurácia	150000	0.883	0.883	0.001	0.882	0.883	0.884	0.884	0.001	0.001
Acurácia	160000	0.885	0.885	0.001	0.884	0.885	0.885	0.886	0.001	0.001
Acurácia	170000	0.886	0.887	0.000	0.885	0.886	0.887	0.888	0.001	0.001
Acurácia	180000	0.888	0.888	0.000	0.887	0.888	0.888	0.889	0.000	0.000
Acurácia	190000	0.889	0.890	0.000	0.889	0.889	0.890	0.890	0.000	0.000
Acurácia	200000	0.891	0.891	0.000	0.891	0.891	0.891	0.891	0.000	0.000
F1-Macro	10	0.004	0.003	0.001	0.002	0.003	0.004	0.007	0.001	0.309
F1-Macro	20	0.008	0.008	0.001	0.005	0.007	0.009	0.010	0.002	0.175
F1-Macro	30	0.012	0.012	0.002	0.009	0.010	0.013	0.015	0.003	0.148
F1-Macro	40	0.015	0.015	0.002	0.011	0.014	0.016	0.018	0.002	0.099
F1-Macro	50	0.018	0.018	0.002	0.014	0.017	0.020	0.023	0.003	0.126
F1-Macro	60	0.021	0.022	0.002	0.017	0.020	0.023	0.026	0.003	0.105
F1-Macro	70	0.024	0.024	0.002	0.021	0.023	0.025	0.029	0.002	0.081
F1-Macro	80	0.028	0.027	0.003	0.023	0.026	0.029	0.036	0.003	0.097
F1-Macro	90	0.031	0.031	0.003	0.027	0.029	0.033	0.038	0.004	0.084

Continua na próxima página

Tabela F.1 – continuação da página anterior

Métrica Base	Tam. L0 (I)	Média	Mediana	DP	Mínimo	P25	P75	Máximo	IQR	CV (Med.)
F1-Macro	100	0.034	0.035	0.003	0.030	0.033	0.035	0.041	0.003	0.075
F1-Macro	200	0.062	0.063	0.004	0.054	0.058	0.064	0.068	0.006	0.064
F1-Macro	300	0.084	0.085	0.004	0.078	0.081	0.086	0.090	0.006	0.043
F1-Macro	400	0.103	0.104	0.005	0.095	0.098	0.108	0.113	0.010	0.053
F1-Macro	500	0.119	0.120	0.004	0.109	0.116	0.122	0.127	0.006	0.037
F1-Macro	600	0.135	0.134	0.004	0.128	0.131	0.138	0.141	0.007	0.029
F1-Macro	700	0.147	0.148	0.006	0.134	0.144	0.152	0.162	0.008	0.040
F1-Macro	800	0.158	0.158	0.006	0.149	0.154	0.162	0.169	0.008	0.036
F1-Macro	900	0.168	0.168	0.006	0.158	0.165	0.173	0.179	0.008	0.033
F1-Macro	1000	0.178	0.176	0.008	0.163	0.172	0.185	0.191	0.013	0.045
F1-Macro	2000	0.251	0.252	0.006	0.239	0.248	0.255	0.267	0.007	0.025
F1-Macro	3000	0.295	0.295	0.005	0.287	0.292	0.298	0.306	0.006	0.017
F1-Macro	4000	0.328	0.327	0.005	0.316	0.324	0.331	0.340	0.007	0.016
F1-Macro	5000	0.350	0.348	0.006	0.341	0.345	0.354	0.363	0.009	0.017
F1-Macro	6000	0.373	0.374	0.008	0.358	0.369	0.379	0.390	0.010	0.022
F1-Macro	7000	0.393	0.393	0.007	0.379	0.390	0.397	0.406	0.007	0.017
F1-Macro	8000	0.406	0.406	0.007	0.390	0.402	0.411	0.421	0.009	0.017
F1-Macro	9000	0.420	0.420	0.007	0.406	0.415	0.426	0.429	0.011	0.016
F1-Macro	10000	0.433	0.432	0.006	0.418	0.429	0.438	0.446	0.009	0.015
F1-Macro	20000	0.503	0.503	0.007	0.488	0.500	0.508	0.517	0.008	0.014
F1-Macro	30000	0.549	0.548	0.008	0.536	0.542	0.554	0.565	0.012	0.014
F1-Macro	40000	0.574	0.575	0.007	0.558	0.569	0.579	0.584	0.010	0.011
F1-Macro	50000	0.595	0.594	0.007	0.584	0.590	0.598	0.613	0.008	0.012
F1-Macro	60000	0.612	0.613	0.006	0.601	0.607	0.616	0.624	0.009	0.010
F1-Macro	70000	0.625	0.624	0.006	0.612	0.622	0.627	0.642	0.005	0.010
F1-Macro	80000	0.635	0.634	0.006	0.627	0.631	0.641	0.651	0.009	0.009
F1-Macro	90000	0.645	0.646	0.005	0.637	0.641	0.649	0.655	0.008	0.008
F1-Macro	100000	0.654	0.653	0.006	0.640	0.652	0.657	0.666	0.006	0.009
F1-Macro	110000	0.661	0.661	0.006	0.648	0.657	0.666	0.674	0.009	0.009
F1-Macro	120000	0.670	0.669	0.004	0.662	0.667	0.672	0.677	0.005	0.006
F1-Macro	130000	0.675	0.676	0.004	0.668	0.672	0.679	0.685	0.006	0.007
F1-Macro	140000	0.679	0.679	0.004	0.671	0.677	0.683	0.686	0.007	0.006
F1-Macro	150000	0.685	0.685	0.003	0.677	0.682	0.688	0.690	0.005	0.005
F1-Macro	160000	0.689	0.688	0.004	0.682	0.687	0.691	0.700	0.004	0.005

Continua na próxima página

Tabela F.1 – continuação da página anterior

Métrica Base	Tam. L0 (I)	Média	Mediana	DP	Mínimo	P25	P75	Máximo	IQR	CV (Med.)
F1-Macro	170000	0.693	0.693	0.003	0.688	0.690	0.695	0.699	0.005	0.004
F1-Macro	180000	0.698	0.699	0.003	0.692	0.696	0.700	0.704	0.004	0.004
F1-Macro	190000	0.701	0.701	0.002	0.695	0.700	0.702	0.706	0.002	0.003
F1-Macro	200000	0.704	0.704	0.000	0.704	0.704	0.704	0.705	0.000	0.000