

UNIVERSIDADE FEDERAL DO PARANÁ

GILSILEY HENRIQUE DARÚ

APRENDIZADO ATIVO COM MODELOS DE LINGUAGEM
PARA TEXTOS CURTOS EM PORTUGUÊS

CURITIBA PR

2026

GILSILEY HENRIQUE DARÚ

APRENDIZADO ATIVO COM MODELOS DE LINGUAGEM
PARA TEXTOS CURTOS EM PORTUGUÊS

(versão pré-defesa, compilada em 23 de agosto de 2026)

Tese apresentada como requisito parcial à obtenção do grau de Doutor em Métodos Numéricos em Engenharia no Programa de Pós-Graduação em Métodos Numéricos em Engenharia, Setores de Ciências Exatas e de Tecnologia, da Universidade Federal do Paraná.

Área de concentração: *Programação Matemática*.

Orientador: Prof. Dr. Gustavo Valentim Loch.

CURITIBA PR

2026

RESUMO

A classificação de textos curtos em português, como as descrições de produtos de notas fiscais eletrônicas, enfrenta vocabulário abreviado e ruidoso e centenas de categorias desbalanceadas, e depende de grandes volumes de rótulos cuja obtenção é o principal custo desses sistemas. Esta tese propõe e avalia o FALCO (*Framework de Aprendizado Ativo com LLM para texto CurtO*), que ataca esse custo em três frentes: composição informada do conjunto inicial de treinamento, seleção ativa de instâncias por incerteza e substituição parcial do anotador humano por oráculos baseados em modelos de linguagem de grande porte (LLMs), organizados em fases de custo crescente. A investigação usa um conjunto público auditado de 250.365 descrições de produtos em 621 categorias (250.221 na versão corrigida empregada nos experimentos) e segue protocolo pré-registrado com partições imutáveis, análise pareada (McNemar, Wilcoxon) e artefato rastreável para cada número reportado. Cinco resultados sustentam a tese. (i) A composição do conjunto inicial importa mais quanto menor o orçamento: só o sorteio produz amplitude de 6,4 pontos percentuais de acurácia com $|L_0| = 100$. A heurística determinística proposta, o DRI-SL, combina densidade semântica e diversidade lexical sem usar nenhum rótulo, e supera o melhor indivíduo de um algoritmo genético supervisionado em todos os tamanhos de 100 a 5.000. A comparação é conservadora: a correção de circularidade introduzida na tese reduziu o envelope evolutivo em até 6,3 pontos percentuais. (ii) Oráculos LLM *zero-shot* atingem 77–83% de acurácia no espaço fechado de 621 categorias, a custos de US\$ 0,035 a US\$ 0,92 por mil rótulos, com Macro F1 superior ao de um classificador supervisionado leve treinado com a base completa de 250 mil descrições rotuladas; quase metade dos seus erros concentra-se em convenções de catálogo (categorias-irmãs e classes guarda-chuva). (iii) O instrumento de medição é parte do resultado. Sem restrição de saída ao espaço de classes, 6,8% das respostas viram falsos erros. Regras de fronteira no *prompt* melhoram o modelo fraco na distribuição de produção (+4,6 p.p., $p = 0,012$), ao custo de degradação severa nas classes raras ($p < 0,001$). E o provedor de *serving* também é instrumento: o mesmo modelo gratuito diverge significativamente de si mesmo entre dois serviços ($p < 0,001$), embora, servido adequadamente, empate com oráculos pagos na amostra de produção. (iv) As estratégias de incerteza superam a seleção aleatória na significância máxima que 8 sementes permitem ($p = 0,0078$), e recuperam 78% do Macro F1 do teto supervisionado com 15% do *pool* daquele experimento. A vantagem sobrevive intacta a ruído uniforme de oráculo até $\varepsilon = 0,4$, faixa que cobre o erro observado nos LLMs reais. Nenhum oráculo alcançou o critério pré-registrado de 85% de acurácia: o gate metodológico definiu então a configuração final, com oráculo econômico na fase inicial e oráculo de maior acurácia na fase avançada, e tornou o aprendizado com rótulos ruidosos o cenário central. (v) O framework foi executado ponta a ponta com oráculo LLM gratuito, a custo monetário zero, e a validação com o classificador forte (BERTimbau, três sementes, avaliação na população

reservada de 177.490 instâncias) respondeu à hipótese central, a de obter pelo menos 95% da acurácia da supervisão completa do *pool* de referência, a métrica do pré-registro, com no máximo 34.724 rótulos (15% da população deduplicada). O veredito: **o critério é atingível dentro do teto, cruzado com 20 mil rótulos (8,6% da população) nas três sementes, em varredura *post hoc* com rótulos de gabarito, enquanto a configuração executada parou por estagnação aquém do piso, com 11.936 rótulos (5,2%)**; a decomposição pareada inocenta o ruído do oráculo, que, por ser estruturado, até beneficia as classes raras, inocenta a seleção, e atribui a perda ao critério de parada herdado do classificador leve. Em Macro F1, análise de robustez introduzida nesta tese, o critério é atingido com 30 mil rótulos (13,0% da população), também nas três sementes e dentro do teto; e, na média das três sementes, 35 mil rótulos ativamente selecionados superam a supervisão completa do *pool* nas duas métricas, com heterogeneidade declarada: duas sementes mantêm vantagem significativa, uma inverte em Macro F1 e empata em acurácia. Os experimentos em escala populacional mostram ainda que a autoavaliação em dados coletados ativamente é enviesada em direção que depende da métrica, pois a acurácia da autoavaliação subestima e o Macro F1 da autoavaliação superestima o desempenho real, o que fundamenta o conjunto reservado de avaliação e o critério de liberação que o framework adota. As limitações de primeira ordem são declaradas: os resultados provêm de uma única base, do próprio domínio de estudo; a superação da supervisão completa pelo braço de 35 mil rótulos vale na média das sementes, com uma semente divergente em Macro F1; e a análise de custo apoia-se em razões entre oráculos, como a diferença de 26 vezes sob empate estatístico de acurácia, e não em preços absolutos, que datam. A tese entrega ainda a métrica LCE (*Learning Curve Efficiency*) para comparação de curvas de aprendizado, a biblioteca aberta *activelearning* e a ferramenta FlowBuilder, com ingestão saneada de dados, execução parametrizada e curvas de aprendizado, que tornam o protocolo reutilizável em outros domínios.

Palavras-chave: Aprendizado Ativo. Classificação de Textos Curtos. Modelos de Linguagem de Grande Porte. FALCO. Rotulagem.

ABSTRACT

Short-text classification in Portuguese, such as product descriptions from electronic invoices, faces abbreviated, noisy vocabulary and hundreds of imbalanced categories, and depends on large volumes of labels whose acquisition is the dominant cost of these systems. This thesis proposes and evaluates FALCO (Active Learning Framework with LLMs for Short Text), which attacks that cost on three fronts: informed composition of the initial training set, uncertainty-based active selection of instances, and partial replacement of the human annotator by oracles based on large language models (LLMs), organized in phases of increasing cost. The investigation uses an audited public dataset of 250,365 product descriptions across 621 categories (250,221 in the corrected version used in the experiments) and follows a pre-registered protocol with immutable partitions, paired analysis (McNemar, Wilcoxon), and a traceable artifact for every reported number. Five results support the thesis. (i) The composition of the initial set matters more the smaller the budget: random draws alone produce a 6.4 percentage-point accuracy range at $|L_0| = 100$. The proposed deterministic heuristic, DRI-SL, combines semantic density and lexical diversity while using no labels at all, and outperforms the best individual found by a supervised genetic algorithm at every size from 100 to 5,000. The comparison is conservative: the circularity correction introduced in this thesis reduced the evolutionary envelope by up to 6.3 percentage points. (ii) Zero-shot LLM oracles reach 77–83% accuracy in the closed space of 621 categories, at costs of US\$ 0.035 to US\$ 0.92 per thousand labels, with Macro F1 above that of a light supervised classifier trained on the full base of 250 thousand labeled descriptions; nearly half of their errors concentrate on catalog conventions (sibling categories and umbrella classes). (iii) The measurement instrument is part of the result. Without output restriction to the class space, 6.8% of responses become spurious errors. Boundary rules in the prompt improve the weak model on the production distribution (+4.6 p.p., $p = 0.012$), at the cost of severe degradation on rare classes ($p < 0.001$). And the serving provider is an instrument too: the same free model diverges significantly from itself across two services ($p < 0.001$), although, properly served, it ties with paid oracles on the production sample. (iv) Uncertainty strategies outperform random selection at the maximum significance achievable with 8 seeds ($p = 0.0078$), and recover 78% of the supervised ceiling’s Macro F1 with 15% of that experiment’s pool. The advantage survives intact under uniform oracle noise up to $\varepsilon = 0.4$, a range that covers the error observed in the real LLMs. No oracle reached the pre-registered 85% accuracy criterion: the methodological gate therefore defined the final configuration, with an economical oracle in the initial phase and the most accurate oracle in the advanced phase, and made learning with noisy labels the central scenario. (v) The framework was executed end to end with a free LLM oracle at zero monetary cost, and validation with the strong classifier (BERTimbau, three seeds, evaluated on the reserved population of 177,490 instances) answered

the central hypothesis, that of obtaining at least 95% of the accuracy of full supervision on the reference pool, the pre-registered metric, with at most 34,724 labels (15% of the deduplicated population). The verdict: **the criterion is attainable within the ceiling, crossed at 20,000 labels (8.6% of the population) in all three seeds, in a *post hoc* gold-label sweep, while the executed configuration stopped by stagnation short of the floor, at 11,936 labels (5.2%)**; the paired decomposition exonerates oracle noise, which, being structured, even benefits rare classes, exonerates selection, and attributes the loss to the stopping criterion inherited from the light classifier. In Macro F1, the robustness analysis introduced in this thesis, the criterion is met at 30,000 labels (13.0% of the population), also in all three seeds and within the ceiling; and, on the average of the three seeds, 35,000 actively selected labels surpass full-pool supervision in both metrics, with heterogeneity declared: two seeds keep a significant advantage, one inverts in Macro F1 and ties in accuracy. Population-scale experiments further show that self-evaluation on actively collected data is biased in a metric-dependent direction, since self-evaluation accuracy underestimates and self-evaluation Macro F1 overestimates real performance, which grounds the reserved evaluation set and the release criterion the framework adopts. The first-order limitations are declared: the results come from a single dataset, from the author’s own study domain; the 35,000-label arm’s edge over full supervision holds on the seed average, with one divergent seed in Macro F1; and the cost analysis rests on ratios between oracles, such as the 26-fold difference under a statistical accuracy tie, rather than on absolute prices, which date quickly. The thesis also delivers the LCE (Learning Curve Efficiency) metric for learning-curve comparison, the open-source `activelearning` library, and the FlowBuilder tool, with sanitized data ingestion, parameterized execution, and learning curves, which make the protocol reusable in other domains.

Keywords: Active Learning. Short Text Classification. Large Language Models. FALCO. Labeling.

Declaração de autoria e de uso de ferramentas de inteligência artificial

Esta declaração explícita, em nome da transparência da pesquisa, a distinção entre o que foi concebido e decidido pelo autor — que retém integralmente a responsabilidade intelectual e científica por este trabalho — e o que foi produzido com auxílio de uma ferramenta de inteligência artificial (IA) sob sua direção e revisão.

De autoria e responsabilidade do autor. A pergunta de pesquisa, a hipótese e o *framework* FALCO; o algoritmo DRI-SL e o desenho do experimento E6; o conjunto de dados (coletado, rotulado e publicado pelo autor sob DOI próprio); os experimentos originais dos dois primeiros pilares e o piloto de oráculo; todas as decisões metodológicas, os critérios pré-registrados e a expertise de domínio; e a revisão crítica e a aprovação de cada etapa.

Produzido com auxílio de IA, sob direção do autor. Utilizou-se um assistente de IA baseado em modelo de linguagem de grande porte para: a refatoração do código experimental na biblioteca *activelearning*; a implementação e execução dos experimentos E0, E0-P, E4, E5, E6 e E3 com os desenhos e parâmetros definidos pelo autor; a instrumentação estatística e as rotinas de análise e figuras; a redação e reestruturação de texto sob direção e revisão do autor; a verificação dos resultados portados do repositório legado; e o *software* de apoio (interface de reprodução dos experimentos).

O autor leu, verificou e assume a responsabilidade por todo o conteúdo. Nenhum resultado numérico foi gerado sem artefato rastreável: todas as afirmações empíricas remetem a artefatos versionados e reexecutáveis.

LISTA DE FIGURAS

2.1	Arquitetura conceitual do ActiveLLM: o LLM atua como <i>seletor</i> de instâncias informativas, mitigando o <i>cold start</i> , enquanto a rotulagem permanece com um oráculo e o aprendizado com um modelo sucessor. Adaptado de Bayer et al. (2026).	31
3.1	Fluxo dos dados, da base original às três partições. A auditoria identifica conflitos de rótulo, rótulos operacionais e duplicatas exatas; a deduplicação por descrição normalizada produz a visão sobre a qual o particionamento é feito, por posição e com semente fixa. As três partições são disjuntas e têm papéis distintos, e apenas o <i>pool</i> é visível ao aprendizado ativo.	42
3.2	Arquitetura do FALCO e máquina de fases. Acima, o laço de aprendizado ativo: o classificador re-treinado a cada lote informa a estratégia de seleção, cujas instâncias vão ao oráculo LLM e retornam rotuladas. Abaixo, o que muda entre as fases, mantido o mesmo laço: a Fase 1 resolve a partida a frio sem rótulos, a Fase 2 passa a selecionar por incerteza e a Fase 3 troca apenas o oráculo. A transição da Fase 2 para a Fase 3 depende da estagnação do Macro F1 na validação, e a Fase 3 existe somente se o critério de aprovação do oráculo a justificar.	48
4.1	Tendência da performance média (Acurácia e Macro F1) e intervalo mín–máx por tamanho de L_0 no teste T , escala logarítmica. Classificador PVBIn.	52

LISTA DE TABELAS

2.1	Instrumentos de inferência estatística e seu emprego nesta tese.	24
2.2	Componentes do arcabouço de aprendizado ativo	25
2.3	Comparação de alto nível das famílias de estratégias de seleção.	28
2.4	Cobertura das dimensões da lacuna pelos trabalhos mais próximos (2020–2026). ✓ = tratado; ✗ = ausente; ~ = parcial.	36
3.1	Programa experimental e mapa de rastreabilidade: de cada experimento para a seção que discute o resultado e para os artefatos que o reproduzem.. . . .	39
4.1	Evolução do AG (1 ^a vs. 100 ^a geração): cenários de Acurácia. Envelope entre minimização e maximização.	54
4.2	Partida a frio: DRI-SL vs. envelope do AG (última geração), até $ L_0 = 5.000$. Classificador PVBIn.	54
4.3	Estudo de sensibilidade: original (30 rep.) vs. reexecução independente (10 rep., protocolo com deduplicação). Acurácia média.	56
5.1	Desempenho dos oráculos LLM. Modo enum para OpenAI; json-prompt para MaaS, agregador e NVIDIA NIM (<i>NVIDIA Inference Microservice</i>), que não suportam saída estruturada. IC = intervalo de confiança de Wilson a 95%.	58
5.2	Custo por mil rótulos (US\$) e taxa de acerto de <i>cache</i> de prefixo (S-rand; preços vigentes na execução, jul/2026).	59
5.3	Ablação de <i>prompt</i> no gpt-4o-mini (enum, $b = 10$, $n = 500$ pareado por amostra). p : McNemar exato contra o v3.. . . .	61
5.4	Estratégias com oráculo perfeito (média $\pm$ desvio-padrão, dp, sobre 8 sementes; orçamento 3.000, lote 100). p : Wilcoxon pareado por semente contra a aleatória; com $n = 8$, o menor p atingível é 0,0078.	62
5.5	Robustez ao ruído uniforme do oráculo (média $\pm$ dp, 8 sementes). Retenção: fração do Macro F1 final da mesma estratégia em $\varepsilon = 0$. p : Wilcoxon pareado entropia vs. aleatória no mesmo ε	63
5.6	Macro F1 na população por seletor e classificador. Saturação: menor $ L $ que atinge 95% do teto do próprio braço. As linhas usam denominadores de avaliação diferentes: as reavaliadas medem na população reservada de 177.490; as duas curvas de PVBIn Entropia e PVBIn Aleatório permanecem em 181.490 (execuções travadas com seletor congelado, não reavaliáveis); a diferença entre denominadores vale 0,02 p.p..	65

5.7	BERTimbau treinado por braço e avaliado na população reservada inteira (177.490 instâncias). Receita de agregação: regime homogêneo de treino (lote 16, artefatos <code>_bs16v2</code> em <code>experiments/e2e3</code>); braços A–D são média simples das sementes 7, 42 e 123; o braço E é média das sementes 7 e 42, pois a semente 123 não foi executada nesse regime; desvios-padrão nos artefatos.	66
5.8	Varredura de orçamento (média de três sementes; braço E: média de duas, ver Tabela 5.7; avaliação na população de 177.490; regime homogêneo). Critério $0,95 \times \text{régua } (D)$: acurácia $\geq 0,843$, Macro F1 $\geq 0,436$. As colunas de critério indicam em quantas sementes o braço cruza.	68
F.1	Estatísticas Descritivas da Performance em Função do Tamanho de L0 (Classificador: PVBIn (1,2)-gram). 30 repetições por tamanho.	95

LISTA DE ACRÔNIMOS

AA	Aprendizado Ativo (<i>active learning</i>)
AG	Algoritmo Genético
AL	<i>Active Learning</i> (Aprendizado Ativo)
ALC	<i>Area under the Learning Curve</i>
API	<i>Application Programming Interface</i>
AUC	<i>Area Under the Curve</i>
BERT	<i>Bidirectional Encoder Representations from Transformers</i>
CSV	<i>Comma-Separated Values</i> (formato de arquivo tabular)
DRI-SL	Diversidade Representativa Inicial via densidade Semântica e variedade Lexical
ECOICOP	<i>European Classification of Individual Consumption according to Purpose</i>
FALCO	Framework de Aprendizado Ativo com LLM para texto CurtO
GPT	<i>Generative Pre-trained Transformer</i>
GPU	<i>Graphics Processing Unit</i> (unidade de processamento gráfico)
IC	Intervalo de Confiança
KNN	<i>k-Nearest Neighbors</i> (<i>k</i> vizinhos mais próximos)
JSON	<i>JavaScript Object Notation</i> (formato de intercâmbio de dados)
LCE	<i>Learning Curve Efficiency</i> (Eficiência da Curva de Aprendizado)
LLM	<i>Large Language Model</i> (Modelo de Linguagem de Grande Porte)
MaaS	<i>Model-as-a-Service</i> (modelo servido como serviço)
NF-e	Nota Fiscal Eletrônica
NIM	<i>NVIDIA Inference Microservice</i> (serviço de inferência da NVIDIA)
PLN	Processamento de Linguagem Natural
PPGMNE	Programa de Pós-Graduação em Métodos Numéricos em Engenharia
PVBin	<i>Prototype Vector — Binary</i> (classificador por protótipos binários)
QBC	<i>Query-by-Committee</i> (consulta por comitê)
RQ	<i>Research Question</i> (Questão de Pesquisa)
SBERT	<i>Sentence-BERT</i>
SGD	<i>Stochastic Gradient Descent</i> (gradiente descendente estocástico)
SVD	<i>Singular Value Decomposition</i>
SVM	<i>Support Vector Machine</i> (máquina de vetores de suporte)
TF	<i>Term Frequency</i> (frequência de termos)
TF-IDF	<i>Term Frequency — Inverse Document Frequency</i>

UFPR

Universidade Federal do Paraná

LISTA DE SÍMBOLOS

L, L_t	conjunto de instâncias rotuladas (na iteração t)
L_0	conjunto inicial de instâncias rotuladas (<i>cold start</i>)
U	<i>pool</i> de instâncias não rotuladas
T	conjunto de teste, isolado de todas as decisões do processo
V	conjunto de validação, usado nas decisões de transição de fase
θ	estado do classificador da tarefa, treinado em L
S	regra de seleção, que escolhe o lote a consultar
O	oráculo, que fornece o rótulo de cada instância consultada
Q_t	lote de instâncias consultadas na iteração t
B	orçamento de rotulagem (número de consultas ao oráculo)
b	tamanho do lote (de seleção ou de rotulagem)
b_0	tamanho do lote inicial da Fase 1 do FALCO
I	tamanho alvo do conjunto inicial construído pelo DRI-SL
N_c	número de grupos semânticos formados pelo DRI-SL
ε	taxa de ruído injetada no oráculo simulado
$\varepsilon_{\max}$	limiar de estagnação da transição de fases do FALCO
p	paciência (rodadas sem melhora) na transição de fases
n_1, n_K	orçamentos inicial e final da curva de aprendizado

SUMÁRIO

	Declaração de uso de IA	vi
1	INTRODUÇÃO	16
1.1	PROBLEMA DE PESQUISA	17
1.2	LACUNA DE PESQUISA	17
1.3	QUESTÃO DE PESQUISA E HIPÓTESE	17
1.4	OBJETIVOS	18
1.5	DELIMITAÇÃO DA CONTRIBUIÇÃO	19
1.6	ORGANIZAÇÃO DO TRABALHO	19
2	FUNDAMENTAÇÃO TEÓRICA E REVISÃO DA LITERATURA	20
2.1	APRENDIZADO SUPERVISIONADO: CONCEITOS, MÉTRICAS E VALIDAÇÃO	20
2.1.1	Regimes de supervisão e a tarefa de classificação multiclasse	20
2.1.2	Métricas para classes desbalanceadas	21
2.1.3	Validação e particionamento	22
2.1.4	Inferência estatística para comparação de classificadores e oráculos	22
2.2	APRENDIZADO ATIVO	24
2.2.1	Formalização e cenários	25
2.2.2	Estratégias de seleção de instâncias	26
2.2.3	Limitações do laço clássico	29
2.3	MODELOS DE LINGUAGEM COMO ORÁCULOS DE ROTULAGEM	29
2.3.1	Capacidades e evidência empírica	30
2.3.2	Arquiteturas de integração no laço	30
2.3.3	Rótulos ruidosos e seu efeito no treinamento	32
2.3.4	Custo, instrumentação e reprodutibilidade da medição	32
2.4	CLASSIFICAÇÃO DE TEXTO CURTO	33
2.4.1	Definições e desafios	33
2.4.2	Representação e classificadores	33
2.4.3	Implicações para o aprendizado ativo no domínio	34
2.5	ESTADO DA ARTE NA INTERSEÇÃO E LACUNA DE PESQUISA	35
2.5.1	Escopo e método da revisão	35
2.5.2	Síntese por frente	35
2.5.3	Lacuna de pesquisa	36
2.5.4	Conclusão do capítulo	37

3	METODOLOGIA	38
3.1	DESENHO DA PESQUISA	38
3.2	CONJUNTO DE DADOS	39
3.2.1	Fonte e características.	40
3.2.2	Auditoria de qualidade dos rótulos	40
3.2.3	Pré-processamento e espaço de rótulos	41
3.2.4	Particionamento	41
3.3	CLASSIFICADORES DA TAREFA	43
3.4	MÉTRICAS DE AVALIAÇÃO E ANÁLISE ESTATÍSTICA	43
3.5	COMPOSIÇÃO DO CONJUNTO INICIAL L_0	44
3.5.1	Sensibilidade à amostragem aleatória.	44
3.5.2	Otimização por algoritmo genético	45
3.6	PARTIDA A FRIO SEM RÓTULOS: O ALGORITMO DRI-SL	45
3.7	LLMS COMO ORÁCULO DE ROTULAGEM	46
3.7.1	Instrumentação da medição	46
3.7.2	Desenho fatorial da avaliação de oráculos	47
3.7.3	Critério de decisão para o FALCO	47
3.8	O FRAMEWORK FALCO E SUA AVALIAÇÃO	47
3.8.1	Componentes e fases	48
3.8.2	Métodos de referência e desenho da comparação.	49
3.9	AMEAÇAS À VALIDADE	50
3.10	REPRODUTIBILIDADE E AMBIENTE	51
4	RESULTADOS: COMPOSIÇÃO E CONSTRUÇÃO DO CONJUNTO INICIAL	52
4.1	SENSIBILIDADE À COMPOSIÇÃO E AO TAMANHO DE L_0	52
4.2	LIMITES POR OTIMIZAÇÃO EVOLUTIVA	53
4.3	DRI-SL <i>VERSUS</i> ALEATÓRIO E ENVELOPE DO AG	54
4.4	REEXECUÇÃO INDEPENDENTE E EFEITO DA CIRCULARIDADE	55
4.5	SÍNTESE DO CAPÍTULO	56
5	RESULTADOS: ORÁCULOS LLM E O FRAMEWORK FALCO	58
5.1	AVALIAÇÃO FATORIAL DE ORÁCULOS LLM.	58
5.1.1	RQ1: assertividade	58
5.1.2	RQ2: custo e o efeito do <i>cache</i>	59
5.1.3	RQ3: perfil de erro	60
5.1.4	RQ4: efeito do instrumento de medição	60
5.1.5	Sensibilidade ao ruído do gabarito e calibração do lote	60
5.2	O <i>PROMPT</i> COMO VARIÁVEL DO INSTRUMENTO DE MEDIÇÃO	61
5.3	ESTRATÉGIAS DE SELEÇÃO COM ORÁCULO PERFEITO.	61
5.4	ROBUSTEZ DO APRENDIZADO AO RUÍDO DO ORÁCULO	62

5.5	SELETORES EM ESCALA POPULACIONAL E O VIÉS DA AUTOAVALIAÇÃO	63
5.6	AVALIAÇÃO DA HIPÓTESE CENTRAL COM O CLASSIFICADOR FORTE	66
5.6.1	Varredura de orçamento: o piso que sustenta a hipótese	67
5.7	DECISÃO DO GATE E CONFIGURAÇÃO DO FALCO	69
6	DISCUSSÃO E CONCLUSÃO	70
6.1	SÍNTESE DOS ACHADOS	70
6.2	DISCUSSÃO	71
6.3	CONTRIBUIÇÕES	72
6.4	LIMITAÇÕES	72
6.5	TRABALHOS FUTUROS	73
6.6	CONCLUSÃO	73
	REFERÊNCIAS	75
	APÊNDICE A – MÉTRICA LEARNING CURVE EFFICIENCY (LCE)	88
A.1	DEFINIÇÃO	88
A.2	PROPRIEDADES	88
A.3	RELAÇÃO COM A ALC	88
	APÊNDICE B – ALGORITMO GENÉTICO PARA OTIMIZAÇÃO DE L0	89
B.1	FORMULAÇÃO	89
B.2	OPERADORES E PARÂMETROS	89
B.3	PSEUDOCÓDIGO	89
	APÊNDICE C – ALGORITMO DRI-SL	91
C.1	OBJETIVO E ENTRADAS	91
C.2	ETAPAS	91
C.3	INTUIÇÃO	91
	APÊNDICE D – A BIBLIOTECA ACTIVELEARNING	92
D.1	ARQUITETURA	92
D.2	REPRODUÇÃO DOS EXPERIMENTOS	92
D.3	FLOWBUILDER	92
	APÊNDICE E – PROMPTS E ESQUEMAS DO ORÁCULO LLM	93
E.1	PROMPT V3 (PRODUÇÃO)	93
E.2	MODOS DE INSTRUMENTAÇÃO	93
E.3	VARIANTES DO E0-P	93
	APÊNDICE F – TABELAS COMPLETAS	95
	APÊNDICE G – CRITÉRIO DE PARADA, LIBERAÇÃO DO MODELO E MONITORAMENTO DE DERIVA	99
G.1	PARADA DO LAÇO DE APRENDIZADO ATIVO	99
G.2	CRITÉRIO DE LIBERAÇÃO DO MODELO	99
G.3	MONITORAMENTO DE DERIVA E POLÍTICA DE RETREINAMENTO	100

1 INTRODUÇÃO

A classificação de textos curtos é uma tarefa relevante em Processamento de Linguagem Natural (PLN), especialmente em contextos nos quais grandes volumes de registros textuais precisam ser organizados, filtrados ou categorizados automaticamente. Esse cenário aparece em aplicações como consultas, comentários, atendimento e descrições de produtos. A literatura mostra que textos curtos apresentam dificuldades específicas, como baixo contexto por instância, alta esparsidade, ruído e informalidade, o que torna sua classificação mais desafiadora do que a de documentos mais extensos (Alsmadi e Gan, 2019; Song et al., 2014).

No contexto da língua portuguesa, essas dificuldades se intensificam. Em aplicações como comércio eletrônico e cadastros operacionais, descrições curtas costumam apresentar abreviações, variações morfológicas, ruídos ortográficos e grande heterogeneidade lexical. Em trabalho anterior, voltado à classificação de descrições curtas de produtos em português, observou-se que métodos clássicos de recuperação da informação, como *bag-of-words*, a frequência de termos (TF) e sua ponderação TF-IDF (*term frequency-inverse document frequency*), podem alcançar desempenho relevante quando combinados com pré-processamento e parametrização adequados (Darú, 2024). Esse resultado ancora empiricamente o problema e é a base da qual esta tese parte.

Ao mesmo tempo, o avanço dos modelos de linguagem pré-treinados alterou significativamente o estado da arte em PLN. O BERT (*Bidirectional Encoder Representations from Transformers*) mostrou que representações bidirecionais profundas, obtidas por pré-treinamento em texto não rotulado e posterior ajuste fino em tarefas específicas, podem produzir resultados de ponta em diversas tarefas (Devlin et al., 2019). Para o português, o BERTimbau evidenciou que modelos monolíngues pré-treinados são particularmente relevantes em cenários com poucos dados anotados, superando o BERT multilíngue em tarefas importantes da língua (Souza et al., 2020). Por essa razão, esta tese adota um classificador baseado em BERTimbau na validação principal do framework proposto, reservando modelos mais leves para análises exploratórias específicas.

Apesar desses avanços, a limitação central permanece: dados não rotulados são abundantes, mas a obtenção de rótulos confiáveis continua custosa. O aprendizado ativo (*active learning*) enfrenta diretamente esse custo: seleciona iterativamente os exemplos potencialmente mais informativos para anotação. No entanto, revisões recentes mostram que sua aplicação prática envolve dificuldades adicionais, como custo de anotação, critérios de parada, viabilidade computacional e reaproveitamento dos exemplos obtidos (Zhang et al., 2022).

1.1 PROBLEMA DE PESQUISA

Embora o aprendizado ativo seja conceitualmente adequado para cenários com alto custo de rotulagem, sua aplicação em modelos modernos de PLN enfrenta limitações importantes. A principal delas é o problema de *cold start*: nas etapas iniciais, quando ainda há poucos exemplos anotados, o sistema não dispõe de informação suficiente para selecionar instâncias realmente informativas. Além disso, o treinamento iterativo do modelo ao longo do ciclo de seleção pode ser caro e pouco prático. Assim, o problema central desta tese não é apenas classificar textos curtos em português com boa acurácia, mas **como reduzir o custo de rotulagem nesse contexto sem comprometer o desempenho final**, superando as limitações do aprendizado ativo tradicional nas fases iniciais do processo (Zhang et al., 2022).

1.2 LACUNA DE PESQUISA

A literatura já consolidou os desafios da classificação de textos curtos e a força de modelos pré-treinados em cenários com poucos dados anotados (Alsmadi e Gan, 2019; Song et al., 2014; Devlin et al., 2019; Souza et al., 2020). Trabalhos recentes, como o ActiveLLM, indicaram que modelos de linguagem de grande porte (LLMs, de *large language models*) podem apoiar a seleção de instâncias em cenários com poucos exemplos, mitigando o *cold start* (Bayer et al., 2026), e que LLMs podem atuar como rotuladores de baixo custo em ciclos de aprendizado ativo (Zhang e Takada, 2025). Ainda assim, permanece uma lacuna específica: **falta uma formulação metodológica voltada ao português e ao problema de textos curtos que articule, de forma explícita e com validação empírica em cada componente, aprendizado ativo, classificação em baixo regime de supervisão e uso de modelos de linguagem para apoiar a fase inicial de seleção e rotulagem**. O confronto com os trabalhos mais próximos, dimensão a dimensão, está na Tabela 2.4; é nesse espaço que esta tese se posiciona.

1.3 QUESTÃO DE PESQUISA E HIPÓTESE

Diante dessa lacuna, esta tese é guiada pela seguinte questão de pesquisa:

Como estruturar um framework de aprendizado ativo para classificação de textos curtos em português que reduza o esforço de rotulagem, sem perda relevante de desempenho, utilizando modelos de linguagem para apoiar as fases iniciais do processo?

A hipótese central é que **um framework de aprendizado ativo apoiado por modelos de linguagem nas etapas iniciais pode reduzir a necessidade de rótulos sem perda relevante de desempenho final**.

Para torná-la falseável, adota-se um critério quantitativo de aceitação, fixado de antemão: treinado com no máximo **34.724 rótulos** (o equivalente a 15% da população deduplicada de

231.490 textos únicos), o framework deve alcançar pelo menos 95% da acurácia que o mesmo classificador obtém com o *pool* de referência inteiramente rotulado, superando com significância estatística a seleção aleatória e a seleção por incerteza sob o mesmo orçamento. A acurácia é a métrica do critério por ser a do pré-registro; o Macro F1 acompanha a avaliação como análise de robustez, para o espaço de centenas de classes desbalanceadas. O teto de 15% vem do pré-registro do estudo.¹

O Capítulo 3 formaliza cada elemento deste critério, incluindo os oráculos que fornecem os rótulos (Seções 3.7.3 e 3.8.2).

1.4 OBJETIVOS

O objetivo geral é propor e avaliar o **FALCO** (*Framework de Aprendizado Ativo com LLM para texto CurtO*): um framework de aprendizado ativo para classificação de textos curtos em português, com uso de modelos de linguagem como oráculo de rotulagem e apoio à fase inicial de seleção, visando reduzir o custo de anotação e manter desempenho competitivo. A investigação é organizada em quatro pilares empíricos, que estruturam também os capítulos de resultados:

1. **Composição do conjunto inicial:** quantificar o impacto da composição e do tamanho do conjunto inicial de rotulagem (L_0) na generalização do classificador, incluindo a estimativa de limites por otimização evolutiva;
2. **Partida a frio sem rótulos:** propor e avaliar o algoritmo DRI-SL (*Diversidade Representativa Inicial via densidade Semântica e variedade Lexical*), que constrói um L_0 informativo sem acesso a rótulos;
3. **LLM como oráculo:** medir, com instrumentação validada, a assertividade, o custo e o perfil de erro de LLMs como rotuladores para o domínio, derivando a configuração de oráculos do framework;
4. **O framework integrado:** avaliar o FALCO contra métodos de referência sob o mesmo orçamento, com testes de significância, verificando a hipótese central.

Transversalmente, propõe-se a métrica *Learning Curve Efficiency* (LCE) para sumarizar a eficiência de curvas de aprendizado, e disponibiliza-se a biblioteca *activelearning*, que implementa todo o instrumental com reprodutibilidade rastreável.

¹A ordem de grandeza é compatível com a literatura, que reporta desempenho equivalente ao da supervisão passiva rotulando frações comparáveis *do conjunto selecionável*: Settles (2009) estabelece o fenômeno e os *benchmarks* com transformers de Schröder et al. (2022, Tab. 3) o medem em até 15,45%; medido contra o mesmo tipo de conjunto, o teto desta tese corresponde a 69,4% do *pool* de referência. O denominador adotado aqui, a população deduplicada, é decisão declarada desta tese.

1.5 DELIMITAÇÃO DA CONTRIBUIÇÃO

Esta tese não propõe um novo modelo fundacional para o português nem um novo classificador de texto: sua contribuição está delimitada à **eficiência do processo de rotulagem**. Dois níveis de modelagem são usados de forma complementar: um classificador leve, derivado da linha investigada na dissertação de mestrado do autor (Darú, 2024), em análises exploratórias massivas, e um classificador baseado em BERTimbau na validação principal. Essa distinção isola a contribuição metodológica: a originalidade reside no processo de seleção e rotulagem, não no modelo de classificação. A tese também se distingue do trabalho anterior do autor, que investigou como classificar bem com dados já anotados; aqui a pergunta é **como obter, de forma eficiente, o conjunto anotado necessário**.

1.6 ORGANIZAÇÃO DO TRABALHO

Além desta introdução, o trabalho está organizado da seguinte forma. O Capítulo 2 apresenta os fundamentos de classificação de textos curtos, aprendizado ativo e modelos de linguagem, e a revisão narrativa focada da literatura recente. O Capítulo 3 descreve a metodologia: dados e sua auditoria, os quatro pilares, o programa experimental e o instrumental de reprodutibilidade. O Capítulo 4 apresenta os resultados sobre a composição e a construção do conjunto inicial. O Capítulo 5 apresenta a avaliação dos oráculos LLM e do framework FALCO. O Capítulo 6 discute os achados, limitações e trabalhos futuros. Os apêndices formalizam a métrica LCE, o algoritmo genético, o DRI-SL, a biblioteca *activelearning* e os *prompts* utilizados.

2 FUNDAMENTAÇÃO TEÓRICA E REVISÃO DA LITERATURA

Este capítulo estabelece a base teórica sobre a qual o framework FALCO, proposto no Capítulo 3, é construído, e o faz na ordem em que os conceitos se encadeiam no argumento da tese. A Seção 2.1 apresenta o instrumental de aprendizado supervisionado do qual todos os capítulos seguintes dependem: a tarefa multiclasse, as métricas sob desbalanceamento, as estratégias de validação e os testes estatísticos usados nas comparações. A Seção 2.2 formaliza o aprendizado ativo, o laço que compra rótulos seletivamente, e identifica as duas limitações do laço clássico que o FALCO enfrenta: a partida a frio e a suposição de oráculo perfeito. A Seção 2.3 examina o que muda quando o oráculo é um modelo de linguagem de grande porte: capacidades, arquiteturas de integração, ruído de rótulo e a estrutura de custo e medição que passa a existir. A Seção 2.4 caracteriza o domínio de aplicação, a classificação de texto curto em português, e mostra por que ele agrava, ao mesmo tempo, os desafios de métrica, de *cold start* e de oráculo. A Seção 2.5 fecha o capítulo com a revisão narrativa focada da interseção dessas frentes e a lacuna de pesquisa que o Capítulo 3 ocupa.

2.1 APRENDIZADO SUPERVISIONADO: CONCEITOS, MÉTRICAS E VALIDAÇÃO

O aprendizado de máquina desenvolve algoritmos que melhoram seu desempenho em uma tarefa T , segundo uma métrica P , por meio da experiência E adquirida dos dados (Mitchell, 1997). Esta seção limita-se ao que os capítulos seguintes usam diretamente: a tarefa de classificação multiclasse, as métricas adotadas, as estratégias de validação e a inferência estatística das comparações. Um panorama geral de algoritmos e representações para classificação de texto pode ser encontrado em Kowsari et al. (2019).

2.1.1 Regimes de supervisão e a tarefa de classificação multiclasse

No **aprendizado supervisionado**, o algoritmo recebe exemplos de entrada com os rótulos desejados e induz uma função que generalize para dados não vistos (Russell e Norvig, 2010; Mitchell, 1997). No **não supervisionado**, não há rótulos: o algoritmo identifica estruturas latentes, como agrupamentos ou direções de maior variância (Murphy, 2012). O **semi-supervisionado** combina uma pequena parcela rotulada com muitos exemplos não rotulados, explorando a estrutura destes para melhorar a generalização (Chapelle et al., 2006). O **aprendizado ativo**, objeto desta tese e formalizado na Seção 2.2, trata o mesmo gargalo do semi-supervisionado (o custo do rótulo) por via oposta: o próprio algoritmo escolhe, de forma interativa, quais instâncias submeter a um oráculo, priorizando as de maior benefício esperado (Settles, 2009). A distinção importa porque o desempenho passa a depender de duas políticas acopladas: a de seleção de instâncias e a de obtenção de rótulos, exatamente os dois eixos que o FALCO instrumenta.

A tarefa-alvo é a **classificação**: aprender $f : X \rightarrow Y$ com Y discreto (Duda et al., 2001), o que aqui significa atribuir a cada descrição de produto uma dentre centenas de categorias. Com $K > 2$ classes, classificadores binários podem ser combinados (um-contratodos, um-contrum) (Rifkin e Klautau, 2004), mas os modelos usados nesta tese são multiclasse diretos: produzem um vetor de escores $(z_1, \dots, z_K)$ convertido em distribuição de probabilidade pela função *softmax*,

$$p_i = \frac{\exp(z_i)}{\sum_{j=1}^K \exp(z_j)}, \quad i = 1, \dots, K, \quad (2.1)$$

treinados com perda de entropia cruzada (Bishop, 2006; Murphy, 2012). Essa distribuição p é duplamente essencial no aprendizado ativo: além de fornecer a predição ($\arg \max_i p_i$), é dela que as estratégias de seleção por incerteza (Seção 2.2.2) derivam seus escores. Os classificadores empregados nos experimentos são detalhados no Capítulo 3: dois modelos vetoriais leves (um baseado em protótipos de classe e uma regressão logística multinomial, ambos sobre representação *bag-of-words*) e o BERTimbau ajustado com uma camada de classificação (Souza et al., 2020).

2.1.2 Métricas para classes desbalanceadas

A **acurácia** é a proporção de predições corretas,

$$A = \frac{n_{\text{corretas}}}{N}, \quad (2.2)$$

mas é inadequada como métrica única sob desbalanceamento: um classificador que prediz sempre a classe majoritária obtém acurácia alta ignorando as minoritárias (Sokolova e Lapalme, 2009; Grandini et al., 2020; Barros et al., 2014). Por isso usam-se métricas por classe. Para uma classe tomada como positiva, com TP , FP e FN denotando verdadeiros positivos, falsos positivos e falsos negativos,

$$\text{Precisão} = \frac{TP}{TP + FP}, \quad \text{Revocação} = \frac{TP}{TP + FN}, \quad (2.3)$$

e o **F1-Score** é sua média harmônica,

$$F_1 = 2 \cdot \frac{\text{Precisão} \cdot \text{Revocação}}{\text{Precisão} + \text{Revocação}}. \quad (2.4)$$

No cenário multiclasse, a agregação **macro** calcula a métrica por classe e tira a média aritmética, dando peso igual a todas as classes; a agregação **micro** soma TP , FP e FN globais antes de aplicar a fórmula, refletindo sobretudo as classes majoritárias (Sokolova e Lapalme, 2009). Em bases com forte desbalanceamento (caso do conjunto de dados desta tese), o **Macro F1-Score** é a métrica principal, por expor o desempenho nas classes raras. Alternativas com propósito semelhante (acurácia balanceada, coeficiente de correlação de Matthews e Kappa de Cohen) são discutidas por Grandini et al. (2020) e Riyanto et al. (2023); esta tese as dispensa

porque o par Macro F1 + acurácia global já separa os dois fenômenos de interesse (desempenho nas caudas *versus* desempenho agregado) — separação que é operacional, não estética: nos experimentos desta tese as duas métricas chegam a divergir em sinal, e uma métrica única mascararia precisamente esse contraste (Capítulo 5). A **matriz de confusão** $K \times K$, cuja entrada $[i, j]$ conta exemplos da classe real i preditos como j , complementa as métricas agregadas ao revelar confusões sistemáticas entre pares de classes (Han et al., 2012); é o instrumento usado no Capítulo 3 para caracterizar o perfil de erro dos oráculos LLM.

2.1.3 Validação e particionamento

Avaliar um modelo nos mesmos dados de treino superestima seu desempenho (*overfitting*); a validação exige dados independentes (Kohavi, 1995). As práticas empregadas nesta tese são: (i) **hold-out**, separação treino/teste, adequada a bases grandes como a desta tese; (ii) **validação cruzada k -fold estratificada**, que particiona os dados em k dobras preservando as proporções de classe, o que é essencial sob desbalanceamento (Kohavi, 1995; Forman e Scholz, 2010; James et al., 2013; Widodo et al., 2022), com k tipicamente 5 ou 10, equilíbrio entre viés, variância e custo (Nti et al., 2021; Reusens et al., 2024); (iii) um conjunto de **validação** separado do teste para ajuste de hiperparâmetros, mantendo o teste intocado até a avaliação final (Bishop, 2006); e (iv) para modelos de aprendizado profundo, a **parada antecipada** (*early stopping*), que interrompe o treinamento quando o desempenho em validação cessa de melhorar (Prechelt, 2012; Goodfellow et al., 2016). Uma exigência adicional surge em bases textuais com instâncias repetidas: uma duplicata exata que atravesse a partição coloca a mesma instância no treino e no teste, e o que se mede deixa de ser generalização para ser memorização. Por isso, o particionamento desta tese deduplica por texto normalizado *antes* do sorteio; a extensão do fenômeno na base e o registro da decisão estão no Capítulo 3.

2.1.4 Inferência estatística para comparação de classificadores e oráculos

Toda comparação desta tese (entre oráculos, estratégias de seleção ou configurações) exige afirmar se a diferença observada excede a flutuação amostral. Quatro instrumentos cobrem as situações que aparecem nos Capítulos 4 e 5, cada qual com a referência original e a de uso em aprendizado de máquina.

Intervalo de confiança para proporções (Wilson). Toda acurácia é uma proporção estimada em n instâncias. Um intervalo de confiança de 95% deve conter o valor verdadeiro em 95% das repetições do experimento; a fração em que isso de fato ocorre é a *cobertura* do intervalo, e os 95% declarados são o seu *nível nominal*. O intervalo usual de Wald ($\hat{p} \pm z\sqrt{\hat{p}(1 - \hat{p})/n}$, com z o quantil da normal padrão associado ao nível: 1,96 para 95%) fica aquém do que declara: sua cobertura real cai abaixo do nível nominal e varia de forma imprevisível conforme n e p mudam, mesmo com amostras grandes. O intervalo de Wilson (1927) evita o defeito partindo da desigualdade do teste, $|\hat{p} - p| \leq z\sqrt{p(1 - p)/n}$, cuja variância usa o parâmetro desconhecido p

e não a estimativa $\hat{p}$, e resolvendo-a para p como equação de segundo grau. As raízes delimitam o intervalo

$$\frac{\hat{p} + \frac{z^2}{2n} \pm z \sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}}, \quad (2.5)$$

cujo centro desloca $\hat{p}$ levemente em direção a $1/2$ e cuja largura ganha o termo de correção $z^2/4n^2$; é isso que mantém a cobertura próxima do nível nominal em toda a faixa de p . A análise sistemática de [Brown et al. \(2001\)](#) o recomenda como escolha padrão. Por isso toda acurácia de oráculo desta tese é reportada com IC de Wilson a 95% (Capítulo 5).

Comparação pareada na mesma amostra (McNemar). Quando dois oráculos rotulam *as mesmas* instâncias, seus acertos não são independentes, e a comparação correta olha apenas os pares discordantes: as b instâncias em que só o primeiro acerta e as c em que só o segundo. Sob a hipótese nula de desempenhos iguais, cada discordância tem probabilidade $1/2$ de cair para cada lado, e o teste de [McNemar \(1947\)](#) verifica se a assimetria observada excede o que esse sorteio produziria, pela estatística

$$\chi^2 = \frac{(b - c)^2}{b + c}, \quad (2.6)$$

comparada à distribuição qui-quadrado com um grau de liberdade. Quando $b + c < 25$, a aproximação deixa de ser confiável e usa-se a versão binomial exata: sob a nula, $b \sim \text{Binomial}(b + c, 1/2)$, e o p -valor bicaudal é $2 P(X \leq \min(b, c))$. A escolha segue [Dietterich \(1998\)](#), que comparou empiricamente cinco testes e concluiu que o McNemar é o adequado quando cada modelo é avaliado uma única vez sobre um conjunto comum, o regime desta tese; nos experimentos daquele estudo, os demais testes apontaram diferença onde não existia com frequência maior do que o nível de significância prometia.

Comparação pareada por semente (Wilcoxon). Quando duas estratégias são executadas com as mesmas sementes de aleatorização (o valor que fixa o gerador pseudoaleatório e torna cada execução repetível), cada semente gera um par de resultados e uma diferença d_i . O teste de postos sinalizados de [Wilcoxon \(1945\)](#) ordena os valores absolutos $|d_i|$, atribui-lhes postos $1, \dots, n$ e soma os postos das diferenças positivas,

$$W^+ = \sum_{i: d_i > 0} \text{posto}(|d_i|). \quad (2.7)$$

Sob a hipótese nula, cada sinal é positivo ou negativo com probabilidade $1/2$, o que dá a W^+ distribuição conhecida sem supor normalidade, suposição difícil de sustentar para métricas limitadas ao intervalo $[0, 1]$, como o Macro F1; é a recomendação de [Demšar \(2006\)](#) para comparar dois algoritmos sobre múltiplas condições. Um limite aritmético importa ao desenho: o caso mais extremo, todos os n sinais para o mesmo lado, tem probabilidade $1/2^n$ por cauda, logo o menor p -valor bicaudal é $2/2^n$. Seis sementes são o mínimo que alcança significância a 5% ($p = 0,031$); esta tese adota oito, cujo piso de $p = 0,0078$ mantém a significância alcançável mesmo sob correção para comparações múltiplas sobre as mesmas sementes.

Intervalos por reamostragem (*bootstrap*). Para uma proporção existe fórmula fechada de intervalo; para estatísticas que resumem uma curva inteira em um único número, como a área sob uma curva de aprendizado (Guyon et al., 2011), a distribuição amostral não é conhecida e não há fórmula. O *bootstrap* (Efron e Tibshirani, 1993) contorna a ausência com um procedimento: dos n pares observados, sorteiam-se n com reposição; calcula-se a estatística de interesse na reamostra; repete-se o sorteio B vezes, obtendo as réplicas $\theta_1^*, \dots, \theta_B^*$; e o intervalo de confiança toma os percentis empíricos dessas réplicas,

$$\text{IC}_{95\%} = \left[\theta_{(2,5\%)}^*, \theta_{(97,5\%)}^* \right], \quad (2.8)$$

o chamado método do percentil. Sem conhecer a distribuição populacional, o procedimento usa a própria amostra como o melhor retrato disponível dela e mede quanto a estatística flutua ao repetir o experimento dentro desse retrato.

A Tabela 2.1 resume o mapeamento situação–teste–uso.

Tabela 2.1: Instrumentos de inferência estatística e seu emprego nesta tese.

Situação	Instrumento	Uso na tese
Precisão de uma proporção estimada	IC de Wilson 95% (Wilson, 1927; Brown et al., 2001)	toda acurácia de oráculo (Cap. 5)
Dois oráculos, mesmas instâncias	McNemar; binomial exato se $b+c < 25$ (McNemar, 1947; Dietterich, 1998)	pareamentos de oráculos e de variantes de <i>prompt</i> (Cap. 5)
Duas estratégias, mesmas sementes	Wilcoxon de postos sinalizados (Wilcoxon, 1945; Demšar, 2006)	duas estratégias sob as mesmas sementes (Cap. 5)
Estatística de resumo sem distribuição conhecida	IC <i>bootstrap</i> percentil (Efron e Tibshirani, 1993)	comparação de curvas de aprendizado (Cap. 3)

Com o instrumental de medição estabelecido, a próxima seção formaliza o processo cuja eficiência ele mede: o laço de aprendizado ativo.

2.2 APRENDIZADO ATIVO

O aprendizado ativo (AA) maximiza a eficiência de rotulagem ao permitir que o sistema selecione, de forma interativa, as amostras mais informativas para anotação (Settles, 2012), explorando o fato de que instâncias não rotuladas costumam estar disponíveis em abundância e a baixo custo (Zhu e Goldberg, 2009). Suas origens remontam aos trabalhos de Angluin (1988), sobre aprendizado via consultas, e de Cohn et al. (1994), sobre redução de incerteza; a consolidação teórica e a taxonomia de cenários e estratégias devem-se a Settles (2012). O paradigma é a resposta natural aos domínios em que a anotação é o gargalo (de imagens médicas que exigem radiologistas a transcrições cuja anotação custa um múltiplo da duração do áudio

(Settles, 2012)), e ganhou novas camadas com o aprendizado profundo (Ren et al., 2021) e, mais recentemente, com os LLMs no papel de oráculo ou de seletor (Bayer et al., 2026). Esta seção formaliza o laço, apresenta o catálogo de estratégias de seleção e encerra nas duas limitações estruturais que motivam o desenho do FALCO.

2.2.1 Formalização e cenários

No aprendizado supervisionado tradicional parte-se de um conjunto fixo de pares rotulados $L = \{(x_i, y_i)\}_{i=1}^n$. O aprendizado ativo acrescenta um componente interativo: além de L , dispõe-se de um conjunto não rotulado $U = \{x_j\}_{j=1}^m$ com $L \cap U = \emptyset$, e a cada iteração uma **regra de seleção** $S : (U_t, \theta_t, L_t) \mapsto Q_t \subseteq U_t$ escolhe um lote Q_t a ser consultado; o oráculo rotula Q_t , os pares entram em L_t , e o processo segue até esgotar o orçamento B ou satisfazer um critério de parada. Entre as formulações existentes (Settles, 2012; Roy e McCallum, 2001; Goudjil et al., 2018), adapta-se aqui o arcabouço de Cohn et al. (1996), ampliado por Hanneke (2014).

Definição 2.1 (Aprendizado Ativo) *Aprendizado ativo é representado, neste trabalho, pela sêxtupla*

$$\mathcal{A} = \langle L, U, \theta, S, O, B \rangle,$$

em que L é um conjunto de exemplos rotulados, U um conjunto de exemplos não rotulados, θ denota o estado do modelo supervisionado atualizado a partir de L , S é uma regra de seleção que indica os exemplos de U a serem consultados, O é o oráculo que fornece o rótulo correto para cada instância, e B corresponde ao orçamento, possivelmente infinito, de consultas possíveis ao oráculo.

A Tabela 2.2 resume os componentes; o Algoritmo 1 apresenta o laço (Settles, 2012; Goudjil et al., 2018). Essa notação é a mesma usada em todo o Capítulo 3: L_0 para o conjunto inicial, U para o *pool*, S para a estratégia, O para o oráculo, B para o orçamento.

Tabela 2.2: Componentes do arcabouço de aprendizado ativo

Símbolo	Definição formal	Descrição
L	$L = \{(x_i, y_i)\}_{i=1}^n \subseteq \mathcal{X} \times \mathcal{Y}$	Conjunto de exemplos rotulados
U	$U = \{x_j\}_{j=1}^m \subseteq \mathcal{X}$	Instâncias não rotuladas disponíveis
θ	$\theta \in \Theta$	Modelo treinado em L
S	$S : (U_t, \theta_t, L_t) \mapsto Q_t \subseteq U_t$	Regra que determina o lote Q_t a enviar ao oráculo
O	$O : \mathcal{X} \rightarrow \mathcal{Y}$	Oráculo que devolve o rótulo verdadeiro $y = O(x)$
B	$B \in \mathbb{N}$	Orçamento de consultas restantes

Algoritmo 1 Esquema geral de aprendizado ativo

- 1: **1. Inicialização:** definir os conjuntos iniciais e orçamento.
 - 2: $L_0 \leftarrow$ conjunto de exemplos rotulados iniciais
 - 3: $U_0 \leftarrow$ conjunto de exemplos não rotulados
 - 4: $B_0 \leftarrow$ orçamento inicial de consultas
 - 5: **2. Laço principal:** enquanto houver orçamento e instâncias não rotuladas, repetir:
 - 6: $\theta_t \leftarrow \text{Learn}(L_t)$
 - 7: $Q_t \leftarrow S(U_t, \theta_t, L_t)$
 - 8: $\forall x \in Q_t, y \leftarrow O(x)$
 - 9: $L_{t+1} \leftarrow L_t \cup \{(x, y) : x \in Q_t\}; U_{t+1} \leftarrow U_t \setminus Q_t; B_{t+1} \leftarrow B_t - |Q_t|$
 - 10: $t \leftarrow t + 1$
 - 11: **3. Finalização:** retornar θ_{final} treinado em L_T .
-

O laço admite três cenários clássicos, que diferem em como as instâncias chegam ao seletor (Settles, 2012): na **síntese de consultas**, o algoritmo gera instâncias artificiais, o que funciona quando o espaço de entrada tem estrutura conhecida, mas pode produzir exemplos ininteligíveis para anotadores humanos (Baum e Lang, 1992); na **amostragem seletiva em fluxo**, instâncias chegam uma a uma de uma distribuição natural e o algoritmo decide, por um limiar de utilidade, se consulta cada uma (Dagan e Engelson, 1995); e no **aprendizado ativo com acervo fixo** (*pool-based*), o cenário desta tese e o mais comum na prática (Settles, 2012), um conjunto finito U está disponível desde o início e o algoritmo seleciona dele as instâncias de maior utilidade (Lewis e Gale, 1994). Três extensões do cenário básico são relevantes aqui: o modo em **lote** (*batch-mode*), que seleciona múltiplas instâncias por iteração, necessário na prática quando cada re-treinamento é caro, ao custo de exigir diversidade dentro do lote (Hoi et al., 2006); o aprendizado ativo **federado**, que executa a seleção localmente em múltiplos clientes preservando privacidade (Deng et al., 2025); e o cenário com **múltiplos oráculos** de custos e competências distintos (Yan et al., 2011), formulado originalmente para anotadores humanos em *crowdsourcing* e que hoje se repete na oferta de LLMs com preços e acurácias distintos, que é o cenário do FALCO. Essa oferta e seus preços são instrumentados no Capítulo 3.

2.2.2 Estratégias de seleção de instâncias

A estratégia de seleção é o componente que define um algoritmo de aprendizado ativo: ela determina quais instâncias valem o custo do oráculo, buscando maximizar a informação obtida por consulta (Settles, 2012). As famílias de estratégias diferem no princípio heurístico e no custo computacional; as que esta tese emprega diretamente recebem tratamento completo, e as demais, uma síntese com as referências de aprofundamento.

Amostragem por incerteza (*uncertainty sampling*). A família mais usada na prática (Lewis e Catlett, 1994; Settles, 2012): seleciona as instâncias sobre as quais o modelo corrente está mais

incerto, requerendo apenas as probabilidades preditas. Reúne custo baixo, aplicabilidade geral e relação teórica com a bissecção do espaço de versão em classificadores de margem (Tong e Koller, 2000), e permanece linha de base forte em *deep learning* (Gal et al., 2017), com uma ressalva de regime que importa a esta tese: em classificação multirrótulo extrema (centenas de rótulos possíveis e vários rótulos por texto), nenhuma estratégia de seleção supera a aleatória de forma consistente (Wertz et al., 2022). O próprio estudo localiza o ganho de seleção nos conjuntos em que os rótulos pouco co-ocorrem, condição da qual a classificação de rótulo único, caso desta tese, é o extremo; e em tarefas de rótulo único com poucas classes a seleção supera a aleatória de forma consistente (Rouzegar e Makrehchi, 2024). As três medidas canônicas da amostragem por incerteza são usadas nos experimentos desta tese:

$$x_{LC}^* = \arg \max_x [1 - P_\theta(\hat{y}|x)] \quad (2.9)$$

seleciona pela **menor confiança** na classe mais provável;

$$x_M^* = \arg \min_x [P_\theta(\hat{y}_1|x) - P_\theta(\hat{y}_2|x)] \quad (2.10)$$

seleciona pela **menor margem** entre as duas classes mais prováveis; e

$$x_H^* = \arg \max_x \left[- \sum_y P_\theta(y|x) \log P_\theta(y|x) \right] \quad (2.11)$$

seleciona pela **entropia** da distribuição completa, a medida de incerteza de Shannon (1948). As limitações da família são conhecidas: é míope (confia num modelo possivelmente ruim, em especial no início), suscetível a *outliers*, e pode negligenciar classes raras ao concentrar-se na fronteira das majoritárias (Settles, 2012; Attenberg e Provost, 2010).

Comitês e espaço de versão. A segunda família seleciona pela divergência entre hipóteses plausíveis: o espaço de versão é o subconjunto de hipóteses consistentes com L (Mitchell, 1982), e consultas que maximizam o desacordo entre seus membros eliminam hipóteses mais rapidamente, com garantias teóricas de melhoria exponencial em certos regimes (Cohn et al., 1994; Hanneke, 2014). A implementação prática é a **consulta por comitê** (QBC, de *query-by-committee*): um *ensemble* construído por amostragem bayesiana, *bagging*, *boosting* ou múltiplas visões (Seung et al., 1992; Freund et al., 1997; McCallum e Nigam, 1998; Abe e Mamitsuka, 1998; Muslea et al., 2000; Blum e Mitchell, 1998) vota, e as instâncias de maior desacordo (medido por entropia de votos ou divergência de Kullback–Leibler) são consultadas; a diversidade do comitê é determinante (Melville e Mooney, 2004). O custo de manter múltiplos modelos torna a família menos adequada quando o classificador é re-treinado a cada lote.

Redução de erro ou variância esperados. A terceira família adota a perspectiva de teoria da decisão: escolher a consulta que, em expectativa, mais reduz o erro de generalização ou a variância preditiva do modelo resultante (Roy e McCallum, 2001; MacKay, 1992; Cohn et al., 1996), com tratamento natural de lotes via otimização submodular (Guestrin et al., 2005; Golovin e Krause, 2011; Krause e Golovin, 2014). É a família que se propõe explicitamente a otimizar o objetivo final, mas também a de custo computacional proibitivo no regime desta tese: re-treinamento por par candidato-rótulo ou álgebra matricial que escala mal com a dimensionalidade.

Exploração da estrutura dos dados. A quarta família incorpora a distribuição $P(X)$ das próprias instâncias: seleciona pontos que sejam, além de informativos, **representativos** (em regiões densas ou centrais a agrupamentos), mitigando a seleção de *outliers*. A ponderação por densidade multiplica a utilidade-base por um termo de representatividade,

$$x_{ID}^* = \arg \max_x \phi_A(x) \times (\text{Representatividade}(x))^\beta, \quad (2.12)$$

com β controlando o peso da densidade (Settles e Craven, 2008); as variantes por agrupamento consultam centróides ou amostram hierarquicamente com garantias de robustez (Nguyen e Smeulders, 2004; Dasgupta e Hsu, 2008). Dois desenvolvimentos recentes da família importam aqui. Sener e Savarese (2018) formalizam a seleção como a busca de um conjunto-núcleo (*core-set*), o subconjunto que melhor cobre o espaço das instâncias; sua garantia teórica, porém, degrada à medida que cresce o número de classes. E o algoritmo TypiClust, de Hacoheh et al. (2022), seleciona exemplos típicos, de alta densidade, dentro de agrupamentos; seus experimentos evidenciam uma transição de regime: exemplos representativos vencem quando o orçamento de rótulos é baixo, e exemplos incertos, quando é alto. Esta família é a base conceitual do DRI-SL (Capítulo 3): densidade semântica e variedade lexical como critérios de representatividade computáveis sem nenhum rótulo. Sua hipótese de trabalho (estrutura dos dados correlacionada com a distribuição dos rótulos) nem sempre vale, e o custo de computar a estrutura não é desprezível (Wertz et al., 2022).

A Tabela 2.3 resume o quadro comparativo.

Tabela 2.3: Comparação de alto nível das famílias de estratégias de seleção.

Estratégia	Vantagens principais	Desvantagens principais
Amostragem por incerteza	Simples, rápida, aplicabilidade geral.	Míope, suscetível a <i>outliers</i> , pode falhar com desbalanceamento.
Comitês / espaço de versão	Menos míope, garantias teóricas.	Custo do comitê; depende da sua qualidade e diversidade.
Redução de erro / variância	Otimiza o objetivo final; base teórica sólida.	Custo computacional proibitivo em escala.
Exploração da estrutura	Mitiga <i>outliers</i> ; funciona sem rótulos.	Depende da correlação estrutura-rótulo; custo de computar a estrutura.

2.2.3 Limitações do laço clássico

Duas suposições sustentam o laço da Seção 2.2.1, e ambas falham exatamente nos regimes que interessam a esta tese.

A primeira é a existência de um modelo inicial capaz de guiar a seleção. As estratégias de incerteza e desacordo pressupõem θ_0 treinado em algum L_0 ; com L_0 minúsculo ou inexistente, situação conhecida como **partida a frio** (*cold start*), o modelo não sustenta seleções melhores que o acaso (Bayer et al., 2026), e o problema se agrava em texto curto, onde cada instância carrega pouca informação (Seção 2.4), e com classificadores profundos, cujo re-treinamento frequente é caro (Wertz et al., 2022). As respostas da literatura passam pela exploração da estrutura dos dados antes de existir modelo (a família da Eq. (2.12); Hachohen et al., 2022) e, mais recentemente, por seletores externos com conhecimento pré-treinado (Bayer et al., 2026) (Seção 2.3).

A segunda é a suposição de **oráculo perfeito**: O devolve sempre o rótulo verdadeiro, a custo unitário constante. Anotadores reais erram, variam entre si e cansam; a resposta clássica inclui rotulagem repetida, modelagem da qualidade do anotador e roteamento entre anotadores de custos distintos (Sheng et al., 2008; Snow et al., 2008; Donmez et al., 2009; Yan et al., 2011). Quando o oráculo passa a ser um LLM, a violação da suposição muda de natureza: o erro torna-se sistemático e estruturado (Song et al., 2023), e o custo, uma função de tokens; o tratamento aprofundado está na Seção 2.3.

Duas consequências operacionais do laço merecem registro porque reaparecem nos experimentos. Primeiro, o **critério de parada**: o ganho marginal por lote decresce ao longo da curva de aprendizado (comportamento que a curva populacional de aprendizado desta tese exhibe, Capítulo 5), e critérios baseados na estagnação do desempenho em um conjunto de validação (como o adotado pelo FALCO e formalizado no Apêndice G) ou em razões de custo-benefício (Rouzegar, 2024) evitam gastar orçamento em rótulos que já não melhoram o modelo. Segundo, o **viés de amostragem ativa**: o conjunto rotulado resultante não é uma amostra i.i.d. da população (a seleção por incerteza sobre-representa casos difíceis e classes raras (Santos, 2016; Settles, 2012)), o que afeta tanto o treinamento (às vezes a favor: o conjunto fica mais balanceado que a distribuição natural) quanto, criticamente, a *avaliação*: métricas calculadas sobre os próprios dados coletados não estimam o desempenho populacional (Farquhar et al., 2021; Kossen et al., 2021), exigindo conjuntos reservados. O fenômeno é quantificado nesta tese (Capítulo 5).

2.3 MODELOS DE LINGUAGEM COMO ORÁCULOS DE ROTULAGEM

O surgimento dos *Large Language Models* (LLMs) altera os dois lados do laço de aprendizado ativo: eles podem selecionar instâncias e podem rotulá-las. Esta seção examina quatro aspectos dessa mudança: a evidência empírica dessas capacidades, as arquiteturas de integração propostas na literatura, o regime de treinamento com rótulos ruidosos que o oráculo

LLM inaugura e a estrutura de custo e de medição que passa a existir quando o oráculo é um serviço pago por token. Este último aspecto é o que esta tese toma como objeto de instrumentação.

2.3.1 Capacidades e evidência empírica

A anotação humana é cara, lenta e sujeita a inconsistências (Settles, 2012); LLMs surgem como pseudo-oráculos capazes de rotular em escala (Zhang et al., 2022). A evidência seminal é o estudo de Gilardi et al. (2023): o ChatGPT em modo *zero-shot* (sem nenhum exemplo rotulado da tarefa no *prompt*) superou anotadores de *crowdsourcing* em cerca de 25 pontos percentuais de acurácia média, com maior concordância intercodificador e custo por anotação aproximadamente 30 vezes menor. O estudo ilustra quatro vantagens estruturais: escalabilidade sem fadiga, consistência entre anotações, velocidade e custo (Gilardi et al., 2023).

Essas vantagens convivem com limitações documentadas. A validação sistemática de Pangakis et al. (2023) mostra que o desempenho varia fortemente de tarefa para tarefa: em um terço de 27 tarefas testadas, precisão ou revocação ficaram abaixo de 0,5. Daí a exigência de validar o oráculo por tarefa antes de usá-lo. Já os vieses herdados do pré-treinamento, a alucinação e o conhecimento datado entram nesta tese como parte do perfil de erro a medir, e não como pressuposto (Capítulo 5).

Cabe ainda a ressalva central para esta tese: os resultados positivos concentram-se em tarefas com poucas classes. Os estudos recentes de classificação de produtos operam com dezenas a algumas centenas de categorias: 248 no comparativo zero-shot de Roumeliotis et al. (2025) e 370 categorias terminais (as *folhas* da taxonomia) nos testes de robustez de Gholamian et al. (2024), que também mostram LLMs mais robustos que modelos supervisionados sob abreviação e truncamento de títulos. A transferência desse desempenho para espaços fechados com centenas de categorias em português não é automática e constitui uma das perguntas experimentais do Capítulo 3.

2.3.2 Arquiteturas de integração no laço

A literatura organiza-se em torno de papéis e composições distintas para o LLM no laço.

Como **anotador**, o LLM substitui o oráculo humano: Zhang e Takada (2025) rotulam com o GPT (*Generative Pre-trained Transformer*) as instâncias selecionadas por estratégias clássicas de incerteza e diversidade, treinando um único modelo compacto que atende várias tarefas (*cross-task*) a custo muito inferior ao de classificar todo o conjunto com o LLM; Rouzegar e Makrehchi (2024) introduzem roteamento por limiar de confiança, em que o LLM anota quando confia e os casos difíceis vão ao humano, aproximando o F1 da anotação inteiramente humana a custo reduzido. Em línguas de baixo recurso, Kholodna et al. (2024) acrescentam duas práticas operacionais que esta tese incorpora: a *seleção prévia do anotador* entre LLMs candidatos e a *anotação em lote*, que dilui entre várias instâncias o custo fixo da parte inicial do *prompt*

(instruções e exemplos da tarefa, idênticos em cada chamada), com economia estimada superior a 42 vezes frente à anotação humana.

Como **seletor**, o LLM mitiga a partida a frio: o ActiveLLM (Bayer et al., 2026) usa o conhecimento pré-treinado de modelos como o GPT-4 para escolher instâncias informativas em regime *few-shot* (com poucos exemplos da tarefa no *prompt*), sem depender de um classificador inicial, superando estratégias tradicionais e técnicas específicas de poucos exemplos; a arquitetura conceitual está na Figura 2.1. O desempenho do seletor depende da engenharia do *prompt*: instruções claras de papel, encadeamento de pensamento (Wei et al., 2022), controle do tamanho do lote e recapitulação das seleções anteriores (Bayer et al., 2026). A própria escolha de *prompts* pode ser ativa (Diao et al., 2024).




Figura 2.1: Arquitetura conceitual do ActiveLLM: o LLM atua como *seletor* de instâncias informativas, mitigando o *cold start*, enquanto a rotulagem permanece com um oráculo e o aprendizado com um modelo sucessor. Adaptado de Bayer et al. (2026).

Como **componente de sistemas compostos**, quatro desenhos recentes importam ao posicionamento desta tese. O pano de fundo é a capacidade, já demonstrada, de o próprio modelo decidir quando e como acionar recursos externos: no Toolformer, o LLM aprende por auto-supervisão quais interfaces chamar, em que momento e com quais argumentos (Schick et al., 2023).

O primeiro é a *destilação ativa de conhecimento*, em que o LLM-professor rotula para um estudante compacto (Xiao et al., 2023). Quando a aquisição é guiada por incerteza no laço ativo, o estudante treinado com poucas centenas de rótulos passa a superar o próprio LLM anotador (Zhang et al., 2023). Sua variante de *rótulos candidatos* (Xia et al., 2025a) faz o LLM emitir, quando incerto, um conjunto de hipóteses que o estudante destila, convertendo incerteza em informação.

O segundo são os *sistemas híbridos humano-LLM*, que roteiam casos difíceis ao humano (Margatina et al., 2023). O terceiro é a *mistura de LLMs* de Qi et al. (2026), que substitui o anotador único por um comitê de modelos leves locais com mecanismos de discrepância e de *aprendizado negativo*: treinar também com os rótulos que a instância provavelmente *não* tem, uma informação mais confiável sob ruído. O quarto é o paradigma *dual-expert* para taxonomias amplas de produtos (Cheng et al., 2024), em que um especialista de domínio contrai o espaço a K candidatos e o LLM generalista decide entre eles.

2.3.3 Rótulos ruidosos e seu efeito no treinamento

Quando o LLM assume o papel de oráculo, o classificador da tarefa passa a ser treinado com *rótulos ruidosos*, regime com literatura própria e madura: a revisão clássica de Frénay e Verleysen (2014) organiza taxonomias de ruído (aleatório, dependente de classe, dependente de instância) e seus efeitos; Natarajan et al. (2013) estabelecem garantias de aprendizado sob ruído com funções de perda corrigidas; e Song et al. (2023) revisam o estado da arte com redes profundas. Dois resultados dessa literatura importam diretamente (Frénay e Verleysen, 2014; Song et al., 2023): redes profundas toleram ruído moderado quando há dados suficientes, mas degradam de forma acentuada sob ruído dependente de classe que desloca fronteiras de decisão de modo sistemático. O perfil observado em oráculos LLM é um caso particular com estrutura própria: as confusões concentram-se em pares de classes semanticamente vizinhas. São erros parcialmente defensáveis, e o dano que causam ao classificador não se deduz da regra geral, sendo por isso examinado empiricamente nesta tese (Capítulo 5). A evidência mais recente acrescenta uma cautela metodológica: ruído *real* de anotação é substancialmente mais nocivo que as corrupções sintéticas usadas em avaliação. Isso foi demonstrado em reconhecimento de entidades pelo NoiseBench (Merdjanovska et al., 2024), que inclui um uma condição explícita de ruído gerado por LLM, e em classificação de produtos em larga escala pelo AlleNoise (Rączkowska et al., 2025), meio milhão de títulos em 5.692 categorias com 15% de ruído real de *marketplace*. Estratégias que combinam filtragem por modelos pequenos com consulta seletiva ao LLM apenas nos casos suspeitos (Yuan et al., 2024) apontam o caminho de integração. Esta tese quantifica a degradação sob ruído controlado no domínio de interesse (Capítulo 3).

2.3.4 Custo, instrumentação e reprodutibilidade da medição

O oráculo LLM introduz uma economia e uma metrologia próprias, que esta tese instrumenta de ponta a ponta (Capítulo 3). O **custo** deixa de ser por item e passa a ser por *token*, com três alavancas operacionais: o tamanho do lote de anotação, que dilui entre as instâncias do lote o custo fixo da parte inicial do *prompt* (Kholodna et al., 2024); o *cache* de prefixo oferecido por provedores, que reduz o preço da porção repetida; e os limites de vazão (requisições por minuto, cotas diárias), que definem o tempo total de execução (*wall-clock*) independentemente do preço. A **medição** também muda: parte do erro aparente de um LLM anotador é erro de *formato*, e não de semântica (Kholodna et al., 2024): resposta fora do espaço de classes ou inconsumível automaticamente. É o que torna a restrição da saída ao espaço fechado de rótulos parte do instrumento de medição: o conjunto de decisões que define como a resposta do LLM vira um rótulo e como o acerto é contado. Além disso, a confiança auto-reportada dos LLMs tende ao excesso (Diao et al., 2024), exigindo calibração (Tian et al., 2023); as janelas de contexto limitam o lote (Bayer et al., 2026); e a resposta do mesmo modelo pode variar entre versões e provedores de *serving*, fazendo com que cada medição valha para a tripla (modelo, provedor, data). A generalização natural desse cenário é estender a seleção ativa para além das instâncias:

à escolha dos exemplos que compõem o *prompt* de anotação (Diao et al., 2024; Margatina et al., 2023; Zhang et al., 2023) e à escolha do próprio oráculo e de sua configuração, passo que esta tese dá no Capítulo 5. O Capítulo 3 instrumenta cada um desses componentes.

Em síntese: com um oráculo LLM, qualidade, custo e instrumento de medição tornam-se três dimensões *escolhíveis* de projeto. É nesse espaço de decisão que o FALCO opera.

2.4 CLASSIFICAÇÃO DE TEXTO CURTO

O domínio de aplicação desta tese, descrições de produtos de varejo em português, pertence à classificação de texto curto (*short text classification*), subcampo com desafios próprios que afetam ao mesmo tempo as métricas da Seção 2.1 quanto o laço da Seção 2.2. Textos curtos são comuns em plataformas digitais (consultas de busca, mensagens, títulos) e sua classificação sustenta aplicações de análise de sentimento a categorização de catálogos (Ahmed et al., 2023; Song et al., 2014).

2.4.1 Definições e desafios

A classificação de texto aprende $f : X \rightarrow Y$ de documentos para um conjunto pré-definido de classes a partir de exemplos rotulados (Aggarwal e Zhai, 2012; Kowsari et al., 2019); o texto *curto* especializa a tarefa para sequências de comprimento limitado (Song et al., 2014), tipicamente até 200 caracteres (Alsmadi e Gan, 2019), como *tweets*, títulos de notícias, consultas e descrições de produtos (Darú, 2024). Quatro características tornam o regime difícil (Ahmed et al., 2023; Song et al., 2014): a **escassez de contexto**, que limita a desambiguação; a **esparsidade lexical** em alta dimensionalidade, que enfraquece métricas de similaridade e agrava a maldição da dimensionalidade; o **ruído e a informalidade** (erros, abreviações, gírias), que exigem normalização (Aliero et al., 2023); e a **ambiguidade** semântica acentuada pela falta de contexto. O pré-processamento usual (tokenização, minúsculas, remoção de pontuação e palavras funcionais de alta frequência (*stopwords*), lematização ou redução ao radical (*stemming*), tratamento de ruído específico) mitiga parte do problema, e sua escolha e ordem afetam o desempenho final (Naseem et al., 2021a; Aliero et al., 2023); nesta tese ele é deliberadamente mínimo (Capítulo 3), delegando a variação lexical ao classificador. No domínio específico (cupons fiscais de varejo), os textos têm 4 a 50 caracteres, caixa alta e abreviações extensas (CERV BRAHMA LT 350ML), combinando todos os quatro desafios de uma vez.

2.4.2 Representação e classificadores

As **representações esparsas** projetam cada texto num vetor de dimensão igual ao vocabulário: *one-hot*, *bag-of-words* nas variantes binária, por frequência e por frequência do termo ponderada pelo inverso da frequência nos documentos (TF-IDF) (Salton e Buckley, 1988), estendidas por *n*-gramas; a similaridade do cosseno é a métrica de comparação usual nesse regime (Baeza-Yates e Ribeiro-Neto, 2013). Suas propriedades em descrições curtas de produtos

em português foram investigadas na dissertação de mestrado do autor (Darú, 2024), que este trabalho toma como ponto de partida: em texto curto a frequência de termos satura (quase todo termo ocorre uma única vez por descrição), o que explica a vantagem empírica da variante binária sobre TF e TF-IDF; e a configuração vencedora lá identificada (binária, uni e bigramas, sem normalização) é a adotada pelo classificador leve desta tese, o PVBin (protótipos de classe sobre vetores binários; Capítulo 3); para o panorama de ponderação e representação, ver Salton e Buckley (1988) e Naseem et al. (2021b). As **representações densas** mapeiam palavras ou textos para espaços contínuos de baixa dimensão: os *embeddings* estáticos (Word2Vec (Mikolov et al., 2013), GloVe (Pennington et al., 2014), FastText (Bojanowski et al., 2017)) atribuem um vetor por palavra, sem tratar polissemia (Selva Birunda e Kanniga Devi, 2021; Goldberg, 2017); os **contextuais** condicionam a representação de cada token à sequência inteira (ELMo (Peters et al., 2018), a família GPT (Radford et al., 2018, 2019) e o BERT (Devlin et al., 2019)), resolvendo a polissemia e sustentando o estado da arte em texto curto (Ahmed et al., 2023; Li et al., 2020; Karl e Scherp, 2023). É dessa família o SBERT (Reimers e Gurevych, 2019), que produz representações de sentença comparáveis por cosseno, usado pelo DRI-SL, e o BERTimbau (Souza et al., 2020) usado como classificador forte.

Quanto aos **classificadores**, os algoritmos clássicos seguem relevantes como linhas de base eficientes sobre representações esparsas (Kowsari et al., 2019; Aliero et al., 2023): máquinas de vetores de suporte (SVM) (Cortes e Vapnik, 1995), Naive Bayes e regressão logística (Murphy, 2012), k vizinhos mais próximos (KNN) (Cover e Hart, 1967), árvores e *ensembles* (Quinlan, 1993; Breiman, 2001; Dietterich, 2000). Arquiteturas profundas convolucionais e recorrentes capturam padrões locais e sequenciais (Goodfellow et al., 2016; Xu et al., 2017), com benefício limitado em textos muito curtos; e os **Transformers ajustados** (BERT e variantes), construídos exclusivamente sobre o mecanismo de atenção (Vaswani et al., 2017), representam o estado da arte da tarefa (Devlin et al., 2019; Li et al., 2020; Karl e Scherp, 2023), ao custo de treinamento e inferência substancialmente maiores. Essa gradação de custo-capacidade é a razão de esta tese operar com um par de classificadores: um leve, barato o suficiente para re-treinos a cada lote, e um forte, para a validação final.

2.4.3 Implicações para o aprendizado ativo no domínio

Três consequências do regime de texto curto estruturam os experimentos desta tese. Primeiro, a cauda longa de classes torna o Macro F1 sensível a classes não cobertas: com centenas de categorias e poucas instâncias nas raras, cada classe descoberta tarde reduz o Macro F1 de forma desproporcional; o quanto a cobertura de classes do conjunto inicial pesa nesse regime é examinado no Capítulo 4. Segundo, a partida a frio é mais severa: com pouca informação por instância, o modelo inicial precisa de mais exemplos para sustentar seleções informadas, elevando o valor de heurísticas de representatividade que operam sem rótulos. Terceiro, o desbalanceamento interage com a seleção por incerteza, que tende a concentrar-se nas fronteiras das classes majoritárias (Attenberg e Provost, 2010), e com a própria avaliação, como discutido

na Seção 2.2.3. O domínio de descrições de varejo em português (Darú et al., 2022) reúne essas três condições em escala, o que o torna um caso de teste adequado para o framework proposto.

2.5 ESTADO DA ARTE NA INTERSEÇÃO E LACUNA DE PESQUISA

As três seções anteriores revisaram as frentes isoladamente; esta seção examina sua interseção (aprendizado ativo com oráculos LLM para classificação de texto curto) na literatura de 2020 ao primeiro semestre de 2026, e delimita a lacuna que o restante da tese ocupa.

2.5.1 Escopo e método da revisão

Esta é uma *revisão narrativa focada* na interseção das frentes, e não uma revisão sistemática completa com protocolo registrado e fluxo de seleção documentado (Kitchenham, 2004): o papel do capítulo é fundamentar a lacuna, não inventariar um campo, e a contrapartida do formato é a tabela de lacunas (Tabela 2.4) explicitar os critérios pelos quais os trabalhos mais próximos são confrontados. A revisão concentrou-se em publicações revisadas por pares e em pré-prints (ACL Anthology, arXiv e periódicos da área) de 2020 até o primeiro semestre de 2026, com uma atualização dedicada ao último ano (meados de 2025 a meados de 2026). A busca utilizou combinações de termos como *active learning*, *text classification*, *short text*, *LLM*, *large language model*, *cold start*, *few-shot learning* e *oracle*, priorizando trabalhos que conectassem explicitamente essas áreas, e a análise buscou tendências na aplicação de LLMs em AA, abordagens para a partida a frio e as lacunas remanescentes.

2.5.2 Síntese por frente

Partida a frio informada. A linha que antecede os LLMs usa representações pré-treinadas para selecionar o conjunto inicial: ALPS (Yuan et al., 2020) seleciona pela surpresa (*surprisal*) que a instância causa ao modelo de linguagem, medida como a perda de modelagem mascarada do próprio BERT: quanto pior o modelo prevê os tokens escondidos da instância, maior a surpresa, sem exigir nenhum rótulo; o ALPS então agrupa as instâncias por essa assinatura e seleciona pelos centros, para não sacar várias frases surpreendentes pelo mesmo motivo. Na mesma linha, Ein-Dor et al. (2020) e Griebhaber et al. (2020) adaptam AA ao BERT. A linha culmina no DEUCE (Guo et al., 2024), que combina diversidade textual e de classe prevista num grafo duplo-vizinho para evitar o que seus autores chamam de efeito de agrupamento não coberto (*missed cluster effect*): classes inteiras que a amostra inicial deixa de representar. O DEUCE converge conceitualmente com a fase de partida a frio do FALCO (Capítulo 3), mas não incorpora oráculo LLM nem é avaliado em português ou texto de e-commerce.

LLM no laço. A transição do BERT ajustado para o LLM generativo redefiniu os papéis: seleção informada pelo conhecimento pré-treinado (ActiveLLM (Bayer et al., 2026)), rotulagem das instâncias selecionadas (Zhang e Takada, 2025), roteamento híbrido humano-LLM (Rouzegar e Makrehchi, 2024), rótulos candidatos com destilação (Xia et al., 2025a) e misturas

de LLMs leves (Qi et al., 2026); a revisão de Xia et al. (2025b) organiza o campo na progressão "da seleção para a geração". Os desafios transversais são a calibração da confiança, o custo por consulta e a propagação de vieses (Bayer et al., 2026; Zhang e Takada, 2025). A pesquisa de comunidade de Romberg et al. (2026) acrescenta uma ressalva de ordem prática: complexidade de implantação, incerteza sobre a redução real de custo e ferramental inadequado seguem sendo as barreiras à adoção: a viabilidade operacional, não a acurácia, é o obstáculo apontado.

Robustez a ruído e produto/e-commerce. As duas frentes restantes foram detalhadas nas Seções 2.3.3 e 2.3.2; na interseção com o domínio, o estudo de Machado e Veloso (2026), que classifica ≈ 100 mil títulos de supermercados portugueses nas categorias da classificação europeia do consumo individual por finalidade (ECOICOP) para estatística oficial, corrobora a escolha do BERTimbau como classificador forte (97,0% de acurácia, 94,0% de Macro F1 após ajuste), mas depende de um fluxo de rotulagem humano sem protocolo definido iniciado com 12 mil rótulos manuais, sem estratégia formal de aprendizado ativo nem oráculo automatizado: exatamente o processo que o FALCO formaliza.

2.5.3 Lacuna de pesquisa

A análise revela que as peças existem separadas, mas sua integração sistemática não: falta um framework que (i) utilize o conhecimento pré-treinado de LLMs para informar a seleção inicial ou fornecer rótulos na partida a frio; (ii) adapte as estratégias de seleção para considerar, além do classificador em treinamento, a confiança e o custo do oráculo LLM; (iii) seja otimizado para as características do texto curto; e (iv) balanceie explicitamente o custo financeiro das consultas com o ganho de informação, com medição quantitativa desse compromisso (*trade-off*), ainda rara mesmo nos trabalhos que tocam o custo (Zhang e Takada, 2025; Ein-Dor et al., 2020). A Tabela 2.4 cruza os trabalhos mais próximos com as cinco dimensões cuja combinação define a lacuna.

Tabela 2.4: Cobertura das dimensões da lacuna pelos trabalhos mais próximos (2020–2026). ✓ = tratado; ✗ = ausente; ~ = parcial.

Trabalho	<i>Cold start</i> informado	Oráculo LLM	Custo instrum.	Texto curto em PT	AA formal
DEUCE (Guo et al., 2024)	✓	✗	✗	~	✓
ActiveLLM (Bayer et al., 2026)	✓	✗	✗	✗	✓
Zhang e Takada (2025)	✗	✓	~	✗	✓
Rouzegar e Makrehchi (2024)	✗	✓	~	✗	✓
Kholodna et al. (2024)	✗	✓	✓	✗	✓
CanDist (Xia et al., 2025a)	✗	✓	✗	~	~
MoLLIA (Qi et al., 2026)	✗	✓	~	✗	✓
Dual-expert (Cheng et al., 2024)	✗	✓	✗	~	✗
Machado e Veloso (2026)	✗	✗	✗	✓	✗
FALCO (esta tese)	✓	✓	✓	✓	✓

A leitura da tabela confirma que a lacuna permanece após a atualização 2025–2026: DEUCE cobre a partida a frio sem oráculo LLM; a mistura de LLMs cobre a robustez do anotador sem progressão de custo; os estudos de produto cobrem o domínio sem aprendizado ativo. A ausência combinada (partida a frio informada + oráculo LLM progressivo + texto curto em português + custo instrumentado) é a lacuna que o Capítulo 3 ocupa.

2.5.4 Conclusão do capítulo

O capítulo percorreu uma cadeia: as *métricas* sob desbalanceamento e a inferência que as compara (Seção 2.1); o *laço* que compra informação e suas duas limitações, partida a frio e oráculo imperfeito (Seção 2.2); o *oráculo LLM* que transforma qualidade, custo e instrumento em variáveis de projeto (Seção 2.3); o *domínio* de texto curto que agrava todos esses desafios ao mesmo tempo (Seção 2.4); e o *estado da arte* que resolve cada limitação isoladamente, mas não as três em conjunto (Seção 2.5). O Capítulo 3 apresenta o framework que ocupa essa interseção, e o programa experimental que o submete à prova.

3 METODOLOGIA

Este capítulo descreve a metodologia empregada para desenvolver e avaliar o **FALCO** (*Framework de Aprendizado Ativo com LLM para texto CurtO*). A investigação está organizada em quatro pilares empíricos, cada qual associado a um experimento identificado e reproduzível: o impacto da composição do conjunto inicial de rotulagem L_0 ; a construção de um L_0 informativo sem acesso a rótulos, via o algoritmo DRI-SL; a viabilidade, o custo e o perfil de erro de modelos de linguagem de grande porte (LLMs) como oráculos de rotulagem; e a avaliação integrada do FALCO contra métodos de referência sob o mesmo orçamento de rotulagem. Uma métrica transversal, a *Learning Curve Efficiency* (LCE), sumariza a eficiência das curvas de aprendizado em todos os pilares.

Todos os experimentos são implementados na biblioteca `activelearning` (Apêndice D), desenvolvida nesta pesquisa sob arquitetura hexagonal com domínio isolado, e cada número reportado nos capítulos de resultados é rastreável a um artefato de execução versionado (configuração, sementes, revisão do código e registros por iteração), conforme a Seção 3.10.

3.1 DESENHO DA PESQUISA

A pesquisa adota um desenho experimental quantitativo, no modo *pool-based* de aprendizado ativo (Lewis e Gale, 1994; Settles, 2012): há um acervo finito de instâncias não rotuladas U , um classificador da tarefa θ , uma estratégia de seleção S que escolhe lotes de consulta $Q_t \subset U_t$, um oráculo O que fornece rótulos e um orçamento B de consultas. Como os rótulos verdadeiros de todo o conjunto de dados estão disponíveis, o processo é simulado com fidelidade: o oráculo LLM pode ser avaliado contra o padrão-ouro, e um modelo treinado com supervisão completa fornece o limite superior de desempenho.

O desenho desta pesquisa tem proveniência documentada: o laço de aprendizado ativo com oráculo, a meta de redução do esforço de rotulagem e a avaliação da generalização contra um conjunto externo foram apresentados no exame de qualificação do autor (PPGMNE/UFPR, junho de 2023) e constam de material datado de maio de 2022, na versão de maio de 2023, preservado no repositório da tese (`docs/pre-registro/`). É a esse desenho que o termo *pré-registrado* se refere neste documento; números e partições fixados depois desse marco são decisões da tese, registradas como tal.

A Tabela 3.1 resume o programa experimental e serve de **mapa de rastreabilidade**: para cada experimento, o pilar que ele sustenta, a seção em que o resultado é discutido e o diretório de artefatos que permite reexecutá-lo. Os identificadores da primeira coluna são *controle interno*: servem para localizar código e dados, não para nomear achados, e por isso não reaparecem no texto corrido dos capítulos de resultados, que se organiza pelo que foi descoberto. Quem quiser ir do achado ao artefato usa esta tabela; quem quiser ler a tese não precisa dela. O E3 designa,

em toda a tese, a avaliação da hipótese central efetivamente executada; o que ficou fora dela está registrado como extensão na Seção 3.8.2.

Uma dependência entre experimentos não cabe na tabela e precisa ser dita: a avaliação de robustez ao ruído do oráculo é **condicional** ao desempenho medido na avaliação dos oráculos, e o critério que decide se ela ocorre foi fixado de antemão e está registrado na Seção 3.7.3.

Tabela 3.1: Programa experimental e mapa de rastreabilidade: de cada experimento para a seção que discute o resultado e para os artefatos que o reproduzem.

Id	Objetivo	Pilar	Resultado em
<i>Composição do conjunto inicial</i> — artefatos em <code>experiments/p1</code>			
—	Sensibilidade à composição e ao tamanho de L_0	conjunto inicial	Seção 4.1
—	Envelope por otimização evolutiva	conjunto inicial	Seção 4.2
—	DRI-SL <i>versus</i> sorteio aleatório	partida a frio	Seção 4.3
—	Reexecução independente e circularidade	conjunto inicial e partida a frio	Seção 4.4
<i>Oráculo e laço ativo</i>			
E0	Avaliação fatorial de LLMs como oráculo	oráculo LLM	Seção 5.1
E0-P	O <i>prompt</i> como variável do instrumento	oráculo LLM	Seção 5.2
E1	Estratégias de seleção sob oráculo perfeito	apoio ao framework	Seção 5.3
E2	Épocas de ajuste fino do BERTimbau por iteração	apoio ao framework	(interno)
E4	Robustez do aprendizado a ruído do oráculo	framework (condicional)	Seção 5.4
E5	Ciclo real de rotulagem com oráculo LLM e critério de parada	framework	(executado) [†]
E6	Seletores em escala populacional e viés de autoavaliação	framework	Seção 5.5
E3	Avaliação da hipótese central com o classificador forte	framework	Seção 5.6

Artefatos por experimento (todos sob a raiz de execução descrita na Seção 3.10): `experiments/e0` (E0) · `experiments/e0p` (E0-P) · `experiments/e1e4` (E1, E4) · `experiments/e5cycle` (E5) · `experiments/e6population` (E6) · `experiments/e2e3` (E2, E3) · `experiments/p1` (conjunto inicial e partida a frio).

[†] O E5 foi executado, mas nenhuma seção dos capítulos de resultados o reporta isoladamente; os artefatos estão em `experiments/e5cycle` e o gatilho de parada que ele exercitou é descrito no Apêndice G.1.

3.2 CONJUNTO DE DADOS

Esta seção documenta o material empírico da tese em quatro decisões encadeadas: de onde vêm os dados e o que os caracteriza, quanto se pode confiar nos rótulos de referência, como textos e espaço de classes foram normalizados e como o conjunto foi particionado para os experimentos.

3.2.1 Fonte e características

O conjunto de dados é o *Retail Product Description-Ptbr* (Darú et al., 2022; Darú, 2024), publicado pelo autor no Kaggle com identificador persistente (DOI 10.34740/kaggle/dsv/4265348; Darú, 2022), com $N = 250.365$ descrições de produtos de varejo na versão original (250.221 na versão corrigida utilizada, Seção 3.2.2), em português brasileiro, coletadas de 18 grandes varejistas, cada qual associada a uma categoria de produto. As descrições são curtas (4 a 50 caracteres; mediana de 32), tipicamente em caixa alta e com abreviações características de cupons fiscais (e.g., CERV BRAHMA LT 350ML), configurando os desafios de esparsidade lexical e baixo contexto discutidos no Capítulo 2. A distribuição de classes é fortemente desbalanceada: a classe mais frequente (*biscoito*) concentra 14.292 instâncias (5,7%), enquanto centenas de classes têm poucas dezenas de exemplos.

3.2.2 Auditoria de qualidade dos rótulos

Antes dos experimentos, o conjunto foi auditado quanto à qualidade do padrão-ouro, etapa relevante porque os rótulos servem simultaneamente de gabarito para o oráculo LLM e de supervisão para o classificador. Três achados condicionam o desenho experimental e a interpretação dos resultados:

1. **Conflitos de rótulo:** 719 descrições distintas (1.807 linhas; 0,7% do total) aparecem associadas a duas ou mais categorias diferentes (e.g., MILHARINA QUAKER 500G ocorre com os rótulos *farinha de milho*, *floco de milho*, *fubá* e *polenta*). Esse ruído impõe um teto de aproximadamente 99,3% à acurácia mensurável de qualquer classificador ou oráculo na distribuição de produção. As instâncias foram mantidas por representarem o ruído real do domínio; o teto é considerado na interpretação (Capítulo 5). Uma análise de sensibilidade quantifica o efeito dessa decisão: reavaliando as anotações dos oráculos (i) com as instâncias conflitantes excluídas e (ii) sob pontuação *multi-gold* (acerto quando o rótulo predito coincide com *qualquer* dos rótulos observados para a mesma descrição na base), a acurácia de todos os oráculos varia no máximo +0,7 ponto percentual, sem alteração de nenhum ordenamento ou decisão. O ruído de gabarito, portanto, limita a medição, mas não a contamina de forma relevante, o que justifica manter as instâncias.
2. **Rótulo operacional:** a categoria `inativo` (144 linhas) registra um status de cadastro, não um tipo de produto (e.g., UVA PASSA ESCURA 150G $\rightarrow$ `inativo`). As linhas foram removidas na versão corrigida da base (250.221 instâncias); a versão original e o registro exato das linhas removidas são preservados no repositório de código, garantindo a rastreabilidade da correção.
3. **Duplicatas exatas:** 19.356 linhas (7,7%) repetem o par (descrição, rótulo). Isso é inócuo para a avaliação do oráculo, mas exige **deduplicação por descrição normalizada antes**

do particionamento nos experimentos com treinamento, sob pena de vazamento entre treino e teste.

3.2.3 Pré-processamento e espaço de rótulos

O pré-processamento textual é mínimo: conversão para minúsculas e remoção de acentos, delegando ao tokenizador de subpalavras do classificador o tratamento de variações lexicais. Rótulos passam pela mesma normalização.

Duas observações de reprodutibilidade acompanham essa normalização, porque sem elas as contagens desta seção não se refazem. A primeira é que **duas chaves de texto distintas** convivem no processamento: o censo de conflitos e a contagem de duplicatas (Seção 3.2.2) comparam descrições com os espaços internos colapsados, ao passo que a deduplicação que precede o particionamento usa a descrição apenas aparada e convertida a minúsculas. Nesta base a remoção de acentos não altera contagem alguma (não há um único caractere acentuado nas descrições ou nos rótulos), de modo que a diferença entre as duas chaves está no tratamento de espaços, e não na acentuação. A segunda é que **o filtro brando de ≥ 2 instâncias conta linhas, e não textos já deduplicados**: são 715 as classes com pelo menos duas *linhas* na base corrigida, ao passo que a mesma contagem feita sobre os textos únicos devolveria 710. Dessas 715, uma (*pomada massagedora*) ainda desaparece na deduplicação, cuja regra é manter a primeira ocorrência de cada texto: os dois textos dessa classe já haviam aparecido sob outro rótulo. Daí as **714 classes presentes** na visão deduplicada. A receita completa é executável e reproduz todas as contagens desta seção (`scripts/check_dataset.py`, na biblioteca `activelearning`). Classes com menos de cinco instâncias são agrupadas na categoria sentinela `_rare_` (0,13% das linhas), resultando em um espaço fechado de **621 categorias** (620 classes frequentes + `_rare_`). Esse espaço fechado, denominado *CategorySchema*, é um objeto de primeira classe na implementação: é a fonte única da restrição de saída imposta aos oráculos LLM (Seção 3.7.1).

Dois espaços de rótulos convivem na tese, com papéis distintos e ambos rastreáveis ao mesmo arquivo de dados: o *CategorySchema* de 621 categorias, contado sobre as *linhas cruas* da versão corrigida (620 classes com ≥ 5 instâncias mais a sentinela), governa os experimentos de oráculo; já os experimentos em escala populacional (Capítulo 5) operam sobre a visão *deduplicada* com filtro brando (≥ 2 instâncias), na qual 231.490 textos únicos distribuem-se por **714 classes presentes**, sem o agrupamento `_rare_`, para não mascarar o comportamento da cauda longa justamente onde o aprendizado ativo é posto à prova.

3.2.4 Particionamento

O desenho *inicialmente planejado* previa particionamento estratificado em conjunto de teste T (20%), validação V (10%) e *pool* de aprendizado ativo U_0 (70%), com orçamento de rotulagem $B = 30\%$ de $|U_0|$. O protocolo *executado* nos experimentos em escala populacional integralmente registrado em código e artefatos, parte da base deduplicada (231.490 textos únicos,

714 classes presentes), embaralha-a com semente fixa e registrada (42) e particiona por posição (Figura 3.1): as primeiras 50.000 instâncias formam o *pool* de aprendizado ativo; as 4.000 seguintes, os conjuntos de validação e teste do ciclo real (2.000 + 2.000, usados apenas nas decisões de parada); e as 177.490 restantes, a **população reservada**, usada exclusivamente na avaliação final. O *pool* é, portanto, uma amostra *aleatória uniforme* da base, e não estratificada por classe. Sua representatividade foi medida e é verificável por artefato: a distribuição de classes do *pool* diverge da distribuição da base por divergência de Jensen–Shannon de 0,0022, com correlação de Spearman de 0,983 entre os ranks de frequência e desvio máximo de proporção de 0,20 ponto percentual em uma classe. O custo da amostragem aleatória concentra-se na cauda: 649 das 714 classes (90,9%) estão presentes no *pool*, 65 estão ausentes e 179 têm menos de cinco exemplos, limitação declarada e relevante para métricas macro (Seção 3.9). O tamanho de 50 mil resulta de viabilidade computacional: cada braço da avaliação com o classificador forte é um ajuste fino completo do BERTimbau, e o programa executa cinco braços mais a varredura de orçamento em uma única GPU, mantendo ainda uma média de 70 exemplos por classe no *pool*. Com a mudança da referência de comparação dessa avaliação (a régua contra a qual os braços são medidos, Seção 3.8.2), os orçamentos passam a ser medidos como fração do *pool* de 50 mil (30% = 15 mil rótulos), e não de $|U_0|$; essa re-baseação do denominador é declarada e suas consequências são discutidas nas limitações (Seção 3.9).




Figura 3.1: Fluxo dos dados, da base original às três partições. A auditoria identifica conflitos de rótulo, rótulos operacionais e duplicatas exatas; a deduplicação por descrição normalizada produz a visão sobre a qual o particionamento é feito, por posição e com semente fixa. As três partições são disjuntas e têm papéis distintos, e apenas o *pool* é visível ao aprendizado ativo.

3.3 CLASSIFICADORES DA TAREFA

Três classificadores θ são empregados, com papéis distintos e explícitos:

- **BERTimbau Base** (`neuralmind/bert-base-portuguese-cased`) (Souza et al., 2020): classificador principal, usado na validação do FALCO e dos métodos de referência. O ajuste fino usa a biblioteca `transformers` (Wolf et al., 2020) com otimizador AdamW (Loshchilov e Hutter, 2019), taxa de aprendizado 3×10^{-5} , lote de treinamento 32 e decaimento de peso 0,01. O número de épocas por iteração do ciclo ativo é determinado empiricamente (curvas de perda em validação para $|L| \in \{10^3, 10^4, 5 \times 10^4\}$), em vez de fixado por convenção; o valor daí resultante (três épocas) é o adotado, uniforme entre braços, na avaliação com o classificador forte (Seção 5.6).
- **Classificador vetorial binário (PVBIn)**: representação *bag-of-words* binária com uni e bigramas, protótipos de classe por concatenação de documentos e predição por similaridade de cosseno com *softmax* sobre os escores (Darú, 2024). Por seu custo de treinamento desprezível, viabiliza os estudos que exigem milhares de reexecuções: a sensibilidade de L_0 , a otimização por algoritmo genético e a varredura de estratégias de seleção (Seção 5.3).
- **Regressão logística** (referida como *SGD*, pelo otimizador que a treina): regressão logística multinomial (a mesma família *softmax*/entropia cruzada da Equação 2.1) sobre representação *bag-of-words* com uni e bigramas, treinada por descida de gradiente estocástica (Bishop, 2006). Também leve, atua como *segundo* classificador nas análises em escala populacional (Seção 5.5): serve para testar se os achados de seleção (saturação da entropia, “menos é mais”) se sustentam sob troca do classificador, e não são artefato do PVBIn.

Essa separação isola a contribuição metodológica: o FALCO é validado com o classificador forte, enquanto as análises exploratórias massivas usam os classificadores leves: são dois, PVBIn e SGD, para que os achados de seleção não dependam de um único modelo.

3.4 MÉTRICAS DE AVALIAÇÃO E ANÁLISE ESTATÍSTICA

Desempenho do classificador. A métrica primária é o **Macro F1-Score**, a média aritmética dos F1 por classe, que pondera igualmente classes majoritárias e minoritárias, adequada ao forte desbalanceamento do conjunto (Sokolova e Lapalme, 2009). A **acurácia global** é reportada como métrica secundária. Ambas são calculadas no conjunto de teste T ao longo das iterações, compondo curvas de aprendizado (métrica *versus* $|L_t|$).

Eficiência da curva de aprendizado (LCE). Para comparar estratégias de aprendizado ativo por um único escalar, emprega-se a métrica LCE, proposta nesta tese e formalizada no Apêndice A:

$$LCE = \frac{AUC_{\text{real}}}{AUC_{\text{ideal}}}, \quad AUC_{\text{ideal}} = \text{Perf}_{\text{baseline}} \times (L_{\text{final}} - L_{\text{ideal},0}), \quad (3.1)$$

em que AUC_{real} é a área sob a curva de aprendizado medida, integrada numericamente pela regra de Simpson sobre os pontos observados, $\text{Perf}_{\text{baseline}}$ é o desempenho do classificador com supervisão completa e $L_{\text{ideal},0}$ é a abscissa inicial da curva ideal (o menor tamanho de conjunto rotulado observado, de modo que curvas reais e ideal integrem o mesmo intervalo). Valores próximos de 1 indicam que a estratégia se aproxima rapidamente do desempenho de referência com poucos rótulos. A LCE tem precedente direto na **ALC** (*Area under the Learning Curve*) do *Active Learning Challenge* (Guyon et al., 2011); difere dela em dois pontos: a normalização usa o desempenho de supervisão completa do próprio par (classificador, conjunto), e não o máximo teórico da métrica, tornando o valor comparável entre classificadores de tetos distintos; e a integração usa Simpson sobre a grade observada, em vez de interpolação em escala logarítmica.

Análise estatística. Três testes acompanham as comparações, conforme a natureza dos dados: (i) toda acurácia de oráculo é reportada com **intervalo de confiança (IC) de Wilson** a 95% (Wilson, 1927), apropriado para proporções em qualquer faixa; (ii) comparações entre oráculos que rotularam *as mesmas instâncias* usam o **teste de McNemar** (McNemar, 1947) sobre os pares discordantes (com teste binomial exato quando as discordâncias somam menos de 25); e (iii) comparações entre estratégias de aprendizado ativo executadas com múltiplas sementes usam o **teste de postos sinalizados de Wilcoxon** (Wilcoxon, 1945) sobre as métricas finais e a LCE.

3.5 COMPOSIÇÃO DO CONJUNTO INICIAL L_0

O primeiro pilar responde a duas perguntas em sequência: quanto a composição do conjunto inicial importa (medição de sensibilidade) e qual o teto de desempenho que uma composição otimizada alcança (busca evolutiva). A segunda só faz sentido se a primeira acusar efeito relevante.

3.5.1 Sensibilidade à amostragem aleatória

Esta seção mede quanto o desempenho do classificador depende do conjunto inicial L_0 : tanto do seu tamanho quanto da amostra específica sorteada para um dado tamanho. A primeira dependência é a curva de aprendizado; a segunda, a dispersão entre sorteios distintos do mesmo tamanho, que mede o quanto o resultado fica refém do acaso da amostragem, e que mais pesa na partida a frio, onde poucos rótulos podem, por sorte, cobrir bem ou mal as classes.

Para quantificá-las, o classificador PVBIn foi treinado com conjuntos iniciais amostrados aleatoriamente em **47 tamanhos** entre 10 e 200.000 instâncias, com **30 repetições independentes**

por tamanho (sementes distintas), avaliando Acurácia e Macro F1 no conjunto de teste. As escolhas de grade acompanham o que se quer medir: 10 é a partida a frio extrema; 200.000 é o teto prático, próximo do total de textos únicos (231.490 após deduplicação), de modo que o maior L_0 representa treinar com quase todo o dado; os 47 tamanhos distribuem-se por décadas (passos de 10, 100, 1.000 e 10.000), densos onde a curva muda rápido e esparsos onde satura; e as 30 repetições estabilizam a média e medem a dispersão. As estatísticas descritivas completas constam do Apêndice F (Tabela F.1).

3.5.2 Otimização por algoritmo genético

Para estimar os *limites* de desempenho alcançáveis pela escolha da composição de L_0 (inatingíveis por busca exaustiva no espaço combinatório), empregou-se um algoritmo genético (AG) (Holland, 1975; Goldberg, 1989) sobre indivíduos que representam conjuntos de I índices únicos do *pool*. A configuração foi: população $N_{pop} = 20$ e 100 gerações por cenário (200 gerações no caso $|L_0| = 10$, o único que difere), valores confirmados contra os artefatos das corridas, sendo a população o único parâmetro sem fonte de configuração (o valor reportado é o do artefato, não o da configuração versionada); seleção por torneio de tamanho $k_t = 3$, cruzamento de um ponto com probabilidade $p_c = 0,8$ e reparo de unicidade, e mutação com probabilidade $p_m = 0,1$ substituindo $m_s = \max(1, \lceil 0,01 \cdot I \rceil)$ genes, parâmetros definidos no *notebook* que executou as corridas, que sempre os passa (o arquivo de configuração em JSON fixa apenas o tamanho de L_0 ; o valor padrão da classe para o cruzamento é 0,7, sempre sobrescrito pelo *notebook*); e elitismo de 10% ($N_{elite} = 2$), também definido no *notebook*. Quatro cenários foram otimizados (maximização e minimização de Acurácia e de Macro F1) para dez tamanhos de L_0 entre 10 e 30.000. A função de aptidão é avaliada em uma **partição de aferição disjunta do conjunto de teste**: otimizar e reportar na mesma partição superajustaria o envelope ao conjunto de avaliação (circularidade); por isso, os indivíduos finais de cada cenário são *reavaliados* no conjunto de teste intocado, e é esse valor, tipicamente inferior ao de aptidão, que os capítulos de resultados reportam como envelope. O fluxo completo e os operadores são formalizados no Apêndice B.

3.6 PARTIDA A FRIO SEM RÓTULOS: O ALGORITMO DRI-SL

O DRI-SL (*Diversidade Representativa Inicial via densidade Semântica e variedade Lexical*) constrói um L_0 de tamanho alvo I a partir de U_0 sem acesso a rótulos, combinando dois espaços de representação: (i) **densidade semântica**, em que as instâncias são projetadas por um codificador de sentenças (Reimers e Gurevych, 2019) e agrupadas por k -médias em N_c grupos, com alocação de amostras proporcional ao tamanho de cada grupo; e (ii) **variedade lexical intragrupo**, em que, dentro de cada grupo, as amostras são escolhidas iterativamente maximizando a introdução de termos relevantes ainda não cobertos (escore de novidade ponderado pelo perfil TF-IDF do grupo). A formalização, o pseudocódigo e as decisões de implementação

constam do Apêndice C. O DRI-SL é a estratégia da Fase 1 do FALCO (a máquina de fases é descrita na Seção 3.8.1) e é avaliado contra a amostragem aleatória e contra o envelope de desempenho estimado pelo algoritmo genético, que atua como limite empírico de referência.

3.7 LLMS COMO ORÁCULO DE ROTULAGEM

A avaliação de oráculos exige, antes de qualquer comparação, um instrumento de medição confiável. Por isso esta seção define primeiro a instrumentação (contrato de saída, custo e proveniência), depois o desenho fatorial da avaliação e, por fim, o critério fixado de antemão que converte as medições em decisão de arquitetura para o FALCO.

3.7.1 Instrumentação da medição

Medir a acurácia de um LLM como rotulador exige restringir a saída ao espaço de rótulos: em experimento preliminar da própria pesquisa, um esquema de saída sem restrição produziu variações de fraseado (*e.g.*, “ovos de páscoa” quando o padrão-ouro registra “ovo de páscoa”) contabilizadas como erro, deflacionando a acurácia medida. Três modos de instrumentação são definidos, e o modo utilizado fica registrado em cada anotação:

- **enum** (modo de produção): saída estruturada com o rótulo restrito, na decodificação, ao *CategorySchema* de 621 valores, com validação estrita imposta pelo provedor (*structured outputs*);
- **json-prompt**: para provedores sem suporte a saída estruturada, a lista de categorias e o formato JSON são instruídos no *prompt*, com validação posterior exata e contabilização explícita de rótulos inválidos;
- **free**: saída estruturada *sem* restrição de rótulo, réplica controlada do instrumento defeituoso, usada exclusivamente para quantificar o efeito do instrumento (RQ4 abaixo).

O *prompt* (Apêndice E) contextualiza o domínio (cupons fiscais, abreviações), instrui a classificação do *tipo* de produto ignorando marca e embalagem, e desestimula o uso indevido da categoria sentinela `_rare_`. A parte estática do *prompt* e o esquema precedem o item variável, explorando o *cache* de prefixo dos provedores que o oferecem, com efeito direto no custo por rótulo. A rotulagem é feita **em lote** (itens numerados em uma única chamada; resposta como vetor indexado), com o tamanho do lote calibrado em etapa prévia (lotes de 1, 10 e 25 itens, pareados nas mesmas instâncias) e adotando-se o maior lote que não degrade a acurácia (teste de McNemar), decisão registrada junto aos resultados e reproduzível pelo artefato de calibração (`experiments/e5cycle/calibrate_batch.py`).

3.7.2 Desenho fatorial da avaliação de oráculos

A avaliação responde a quatro perguntas: (RQ1) a acurácia e o Macro F1 de cada LLM candidato, com intervalos de confiança e comparações pareadas; (RQ2) o custo por mil rótulos e a latência; (RQ3) o perfil de erro por classe (matriz de confusão, taxa de rótulos inválidos); e (RQ4) o efeito do instrumento de medição (enum *versus* free, mesmas instâncias). Os modelos candidatos abrangem três regimes de custo: APIs comerciais (gpt-4o-mini e gpt-4o), modelos servidos por plataformas de modelo como serviço (*Model-as-a-Service*, MaaS: DeepSeek-V4-Flash, DeepSeek-V4-Pro e GLM-5.2) e o regime de custo zero via agregador (representado pela variante *free* do Nemotron-3-Ultra; a redução de escopo deste braço, imposta pela vazão do plano gratuito, é registrada na decisão D-005 e discutida nos resultados).

Duas amostras pareadas (todos os modelos rotulam *as mesmas* instâncias) são usadas: **S-rand** ($n = 1.000$, amostragem aleatória simples), que preserva a distribuição de produção e serve a RQ1/RQ2/RQ4; o tamanho é dimensionado pela precisão exigida da medição: com $n = 1.000$, a meia-largura do IC de Wilson é de no máximo ≈ 3 p.p. (pior caso $p = 0,5$; $\approx 2,5$ p.p. no platô observado), suficiente para separar os oráculos do limiar de 85% do critério de aprovação (Seção 3.7.3) e entre regimes de custo, com custo pareado de anotação linear no número de modelos; e **S-strat** (3 por classe, $n \approx 1.863$), que dá suporte por classe ao Macro F1 e à matriz de confusão (RQ3), necessária porque, com 621 classes, a amostra aleatória deixa a maioria das classes sem representação; três instâncias por classe é o mínimo que distingue erro sistemático de classe (0/3, 3/3) de erro esporádico (1/3, 2/3), e valores maiores dobrariam ou triplicariam o custo pareado de *todos* os oráculos sem alterar as decisões (a sensibilidade do gabarito, Seção 3.2.2, limita o ganho de precisão adicional). A temperatura é fixada em 0 em todos os modelos.

3.7.3 Critério de decisão para o FALCO

Dessa avaliação deriva a configuração de oráculos do FALCO, por um critério de aprovação fixado de antemão, antes de qualquer medição de oráculo, e registrado no repositório da tese, adiante referido também como *gate* do oráculo: o **LLM Inicial** é o de melhor razão acurácia/custo sujeito a acurácia mínima de 85% na S-rand; o **LLM Avançado** é o de maior acurácia, *desde que* significativamente superior ao Inicial (McNemar, $\alpha = 0,05$); caso contrário, a Fase 3 do framework é eliminada e o FALCO opera com oráculo único. Se nenhum modelo atingir o limiar, a avaliação de robustez a ruído do oráculo torna-se obrigatória e a discussão da tese passa a tratar o aprendizado com oráculo ruidoso como cenário central.

3.8 O FRAMEWORK FALCO E SUA AVALIAÇÃO

O quarto pilar integra os anteriores no framework proposto. A seção descreve primeiro os componentes e a máquina de fases do FALCO, o objeto em avaliação, e, em seguida, os métodos de referência e o desenho experimental que o colocam à prova.

3.8.1 Componentes e fases

O FALCO opera em três fases, adaptando estratégia de seleção e oráculo ao amadurecimento do classificador (Figura 3.2):

1. **Fase 1** (*cold start* informado): o lote inicial ($b_0 = \lceil 0,01 \cdot B \rceil$) é selecionado pelo DRI-SL (Seção 3.6) e rotulado pelo LLM Inicial, formando L_0 ;
2. **Fase 2** (seleção por incerteza com LLM Inicial): a cada iteração, as b instâncias de maior entropia preditiva de θ (Settles, 2012) são consultadas ao LLM Inicial; a transição ocorre quando o Macro F1 no conjunto de *validação* V estagna por $p = 5$ iterações consecutivas (tolerância $\epsilon = 10^{-3}$). O conjunto de teste T jamais participa de decisões do processo, porque usá-lo aqui contaminaria a avaliação final (vazamento de teste);
3. **Fase 3** (refinamento com LLM Avançado): mantida a seleção por incerteza, o oráculo passa ao LLM Avançado, concentrando o custo do modelo mais capaz nas instâncias mais difíceis. A fase existe apenas se o critério da Seção 3.7.3 a justificar.




Figura 3.2: Arquitetura do FALCO e máquina de fases. Acima, o laço de aprendizado ativo: o classificador re-treinado a cada lote informa a estratégia de seleção, cujas instâncias vão ao oráculo LLM e retornam rotuladas. Abaixo, o que muda entre as fases, mantido o mesmo laço: a Fase 1 resolve a partida a frio sem rótulos, a Fase 2 passa a selecionar por incerteza e a Fase 3 troca apenas o oráculo. A transição da Fase 2 para a Fase 3 depende da estagnação do Macro F1 na validação, e a Fase 3 existe somente se o critério de aprovação do oráculo a justificar.

O processo encerra ao exaurir B ou U . As constantes de projeto têm o seguinte racional, registrado como decisão de engenharia (não de otimização): $b_0 = \lceil 0,01 \cdot B \rceil$ dá à Fase 1 um custo máximo de 1% do orçamento, suficiente para o DRI-SL cobrir os agrupamentos semânticos sem comprometer o orçamento das fases guiadas; a janela de estagnação $p = 5$ com tolerância $\epsilon = 10^{-3}$ exige cinco iterações consecutivas sem qualquer ganho registrado no Macro F1 de

validação (a tolerância é deliberadamente menor que o ruído amostral da própria medição; a separação entre as duas grandezas está no Apêndice G), evitando transições por flutuação isolada; e o limiar de 85% do gate de oráculo (Seção 3.7.3) corresponde a exigir do oráculo *zero-shot* cerca de 95% da acurácia do melhor baseline supervisionado leve conhecido do conjunto de dados ($0,95 \times 89,56\% = 85,1\%$, com *todos* os rótulos (Darú, 2024)), a mesma razão de 0,95 que o critério da hipótese aplica à régua do classificador forte; essa referência foi medida nas 795 categorias de menor nível da hierarquia completa, espaço de rótulo maior que as 621 categorias presentes na amostra em que os oráculos são avaliados, de modo que a régua está, no máximo, subestimada; abaixo do limiar, o tratamento de ruído torna-se obrigatório; a sensibilidade a essas escolhas é discutida com os resultados. O tamanho de lote b é fixado com base na varredura de estratégias (Seção 5.3), que compara entropia, menor confiança, menor margem, híbrida e aleatória sob oráculo simulado perfeito com o classificador PVBIn (barato o suficiente para varredura ampla). A Fase 2 seleciona por entropia. A varredura mostra que, com o classificador leve, menor margem e menor confiança apresentam estimativas pontuais de LCE superiores à da entropia, sem que o desenho tenha testado essas estratégias entre si: a comparação medida ali é a de cada estratégia contra a aleatória, e a entropia a supera com a mesma significância que as demais. A troca da estratégia da Fase 2 fica registrada como extensão imediata.

3.8.2 Métodos de referência e desenho da comparação

A validação com o classificador forte segue o próprio desenho do FALCO: quem executa o laço é o classificador leve, re-treinado a cada lote; o BERTimbau é treinado *uma única vez por braço*, sobre o conjunto que o processo coletou. Essa decisão, a de manter o classificador forte *fora do laço*, reduz o custo computacional sem alterar o objeto medido: mantido o classificador forte fora do laço, cada braço custa *um* ajuste fino do BERTimbau, e não um ajuste por iteração do ciclo, e é exatamente assim que o framework opera em produção. Duas escolhas de régua completam o desenho, ambas registradas como decisão metodológica: **(a)** a “supervisão completa” de referência é o *pool* de 50.000 instâncias (o mesmo dos experimentos em escala populacional e do ciclo real, com semente e embaralhamento idênticos), e não a base inteira, porque o aprendizado ativo só enxerga o pool, e compará-lo com um braço treinado na base deduplicada inteira (231.490 textos, cerca de $4,6\times$ o pool) confundiria o valor da *seleção* com o valor de *ter mais dados*; **(b)** a avaliação de todos os braços ocorre na **população reservada** (≈ 177 mil instâncias fora do pool e fora dos conjuntos de validação/teste usados pelo ciclo real nas decisões de parada), com amostra estratificada fixa entre braços, acurácia com IC de Wilson e Macro F1, e predições persistidas por braço para os pareamentos de McNemar.

O experimento executado compara cinco braços, cada qual um ajuste fino do BERTimbau: **(A)** os itens selecionados e anotados pelo *pipeline real* (os ciclos ponta a ponta com oráculo LLM gratuito, Apêndice G.1, cujo cache de anotações define o conjunto), com os rótulos *do oráculo*; **(B)** os mesmos itens de (A) com rótulos do gabarito, de modo que a diferença $A-B$ isola o custo do *ruído do oráculo* no modelo forte; **(C)** igual cardinalidade de itens sorteados

uniformemente do pool, com gabarito, de modo que a diferença $B-C$ isola o valor da *seleção*; (D) o pool inteiro com gabarito, que é a régua; e (E) o prefixo de 15 mil da trajetória de entropia em escala populacional, que mede se orçamento adicional ajudaria. O critério de aceitação da hipótese central torna-se direto: $\text{acc}(A) \geq 0,95 \cdot \text{acc}(D)$ na métrica do pré-registro, com o Macro F1 acompanhando como análise de robustez, e com $|A|$ limitado ao teto de 34.724 rótulos (Seção 1.3). Os braços pareados A/B cumprem o papel do braço *oráculo-total* do desenho original, o de separar ruído de parcimônia, a custo de anotação zero, pois reutilizam as anotações reais já pagas. O desenho completo original (FALCO, seleção aleatória e seleção por incerteza com re-treino do BERTimbau no laço, ablações de L_0 e de progressão de oráculo, 8 sementes com Wilcoxon pareado e *bootstrap* sobre LCE) permanece registrado como extensão para hardware dedicado; a comparação executada tem semente única e estatuto descritivo, como os experimentos em escala populacional. A avaliação de robustez, executada se o critério do oráculo indicar ruído relevante, repete o desenho de comparação com oráculo simulado de ruído paramétrico $\varepsilon \in \{0; 0,1; 0,2; 0,4\}$, quantificando a degradação do aprendizado em função da qualidade do oráculo.

3.9 AMEAÇAS À VALIDADE

Validade externa. Todo o programa empírico usa um único conjunto de dados, construído pelo próprio autor (Darú et al., 2022). Isso maximiza o realismo (dados de produção de 18 varejistas) e a comparabilidade com o trabalho anterior, mas limita a generalização: as conclusões valem, a rigor, para descrições curtas de produtos de varejo em português. Três mitigações são adotadas: as decisões do framework não usam nenhuma propriedade específica do conjunto além das características públicas do gênero (texto curto, desbalanceamento, abreviações); os achados de instrumentação do oráculo são mecanismos do par LLM-API, não do dado; e o protocolo completo é reproduzível em qualquer conjunto rotulado com a mesma estrutura, ficando a réplica em benchmark público (e.g., STOPS (Karl e Scherp, 2023)) registrada como trabalho futuro.

Validade interna. O conjunto de teste é isolado de todas as decisões do processo (particionamento com deduplicação prévia; transição de fase por V ; envelope do AG reavaliado em partição intocada). O viés distribucional que a amostragem ativa induz no conjunto rotulado (Santos, 2016) não afeta a medição, feita sempre em T fixo e aleatório.

Desenho executado vs. planejado. Duas divergências entre o desenho inicialmente planejado e o executado são declaradas e têm consequências mensuráveis. Primeira: o *pool* de 50 mil é amostra aleatória uniforme (Seção 3.2.4), não estratificada; 65 das 714 classes não têm nenhum exemplo no *pool* e 179 têm menos de cinco, de modo que o teto de Macro F1 alcançável por *qualquer* braço treinado no *pool* é estruturalmente rebaixado nas classes de cauda; as comparações *entre* braços permanecem justas, pois todos compartilham o mesmo *pool*, mas os valores absolutos de Macro F1 subestimam o que uma amostra estratificada permitiria. Segunda:

o orçamento inicialmente planejado ($B = 30\%$ de $|U_0|$) foi re-baseado para fração do *pool* de 50 mil com a mudança de régua dessa comparação; os percentuais reportados no Capítulo 5 referem-se sempre ao denominador de 50 mil, e a primeira menção de cada resultado o explicita.

Validade de constructo. A acurácia do oráculo é medida contra um padrão-ouro com ruído conhecido (teto $\approx 99,3\%$; análise de sensibilidade na Seção 3.2.2), e o efeito do instrumento de medição é ele próprio quantificado (RQ4). O custo por rótulo depende de preços de API vigentes na execução, de modo que os valores absolutos datam, enquanto as razões entre modelos são mais estáveis. Mais amplamente, **toda medição de oráculo LLM nesta tese é uma fotografia da tripla (modelo, provedor, data)**: temperatura zero não garante determinismo entre versões de modelo nem entre serviços de *serving*, e a própria avaliação de oráculos demonstra o mesmo modelo divergindo significativamente de si mesmo entre dois provedores (Seção 5.1.2); por isso cada anotação é arquivada com proveniência completa, permitindo re-medição futura contra a mesma referência.

3.10 REPRODUTIBILIDADE E AMBIENTE

Toda a instrumentação é implementada na biblioteca *activelearning* (Apêndice D), sob arquitetura hexagonal: o núcleo de domínio (instâncias, esquema de categorias, estratégias, métricas, políticas de fase) é puro e testado isoladamente; LLMs, classificadores e armazenamento são adaptadores intercambiáveis. Cada experimento tem um ponto de entrada único parametrizado por arquivo de configuração versionado; execuções registram sementes, revisão do código e anotações linha a linha (JSONL), e são retomáveis após interrupção. Chamadas a oráculos registram tokens, tokens em *cache*, latência e custo estimado, insumos da análise de custo do Capítulo 5. O ambiente de treinamento é uma estação com GPU NVIDIA RTX 3090 (24 GB), 64 GB de RAM e Linux; as versões das dependências são fixadas pelo gerenciador de pacotes do repositório.

Proveniência dupla dos resultados. Por razões históricas, o programa experimental distribui-se em dois repositórios versionados, e a distinção é mantida explícita em toda a tese. Os resultados *originais* dos pilares do conjunto inicial e da partida a frio (estudo de sensibilidade de L_0 , envelope do algoritmo genético e DRI-SL na partida a frio) foram produzidos no repositório *activetextclassification*; os pilares do oráculo LLM e do framework (E0, E0-P, E1, E4, E5, E6 e E3), com as *reexecuções* de verificação dos dois primeiros, foram produzidos na biblioteca *activelearning*, reescrita sob a arquitetura acima. Onde a tese reporta um número originado no repositório legado, o porte para a biblioteca nova foi verificado: por igualdade de matrizes de score (PVBIn), por reexecução independente com protocolo mais rigoroso (sensibilidade de L_0 , divergência $\leq 0,7$ p.p.) ou por conferência direta contra o artefato de origem (DRI-SL); o registro dessa auditoria acompanha o código.

4 RESULTADOS: COMPOSIÇÃO E CONSTRUÇÃO DO CONJUNTO INICIAL

Este capítulo apresenta os resultados dos dois primeiros pilares: a sensibilidade da generalização à composição do conjunto inicial L_0 (Seção 4.1), os limites estimados por otimização evolutiva (Seção 4.2) e a avaliação do DRI-SL como estratégia de partida a frio (*cold start*) (Seção 4.3). Todos os experimentos usam o classificador leve PVBin (Capítulo 3); os resultados originais foram obtidos no programa experimental da pesquisa e, como verificação de robustez, o estudo de sensibilidade e o mecanismo do algoritmo genético (AG) foram **reexecutados de forma independente** na biblioteca *activelearning*, com protocolo mais rigoroso (deduplicação antes do particionamento e reavaliação em teste intocado); as duas séries são apresentadas lado a lado (Seção 4.4). Todos os resultados são medidos sobre a base real de varejo descrita no Capítulo 3, com centenas de classes desbalanceadas, cenário que os *benchmarks* usuais da área não cobrem; a dependência excessiva de *benchmarks* com características limitadas é uma restrição apontada pela própria literatura de classificação de texto curto (Karl e Scherp, 2023).

4.1 SENSIBILIDADE À COMPOSIÇÃO E AO TAMANHO DE L_0

O experimento avaliou 47 tamanhos de L_0 (10 a 200.000), com 30 repetições aleatórias por tamanho, medindo Acurácia Global e Macro F1 no conjunto de teste T . As estatísticas completas constam do Apêndice F; a Figura 4.1 resume a tendência.




Figura 4.1: Tendência da performance média (Acurácia e Macro F1) e intervalo mín-máx por tamanho de L_0 no teste T , escala logarítmica. Classificador PVBin.

Três padrões estruturam a leitura:

1. **Crescimento com saturação:** a acurácia média sobe de 6,7% ($I = 10$) para 24,7% ($I = 100$), 55,9% ($I = 1.000$), 76,9% ($I = 10.000$) e satura em torno de 89,1% ($I = 200.000$); o Macro F1 acompanha com atraso (0,4% $\rightarrow$ 3,4% $\rightarrow$ 17,8% $\rightarrow$ 43,3% $\rightarrow$ 70,4%), refletindo o custo de cobrir classes minoritárias.
2. **Variabilidade decrescente:** o desvio-padrão da acurácia cai de 0,024 ($I = 10$) para menos de 0,001 ($I = 200.000$); para $I = 100$, a acurácia entre repetições variou de 21,7% a 28,1%, uma amplitude de 6,4 pontos percentuais causada exclusivamente pela composição do sorteio. É a evidência direta da hipótese de variabilidade: *existem L_0 bons e ruins de mesmo tamanho*.
3. **Cobertura de classes como mecanismo:** em $I = 10$ o L_0 típico cobre 9 das 621 classes; em $I = 1.000$, cerca de 255; a curva de Macro F1 segue de perto a curva de cobertura, indicando que, no regime pequeno, o fator dominante é *quais classes* entram no sorteio.

Lidos contra a literatura, esses padrões ganham referência externa. O patamar de saturação coincide com o teto conhecido do classificador sobre esta base: a melhor configuração leve da dissertação que origina o PVBin mede 89,56% de acurácia e 70,09% de Macro F1 com supervisão completa (Darú, 2024), medidos nas 795 categorias da hierarquia completa (a relação com as 621 desta amostra está declarada no Capítulo 3), valores que a curva só alcança no extremo de $I = 200.000$; os métodos supervisionados clássicos avaliados sobre as mesmas descrições situam-se na mesma faixa (Darú et al., 2022). O estudo varre, portanto, o intervalo inteiro entre o quase-zero e o teto supervisionado do modelo. A variabilidade do regime pequeno também tem análogo publicado: em um *benchmark* inglês, o ajuste fino de um modelo pré-treinado com 32 rótulos varia até 10 pontos percentuais de acurácia conforme o subconjunto sorteado (Yu et al., 2023); a amplitude de 6,4 p.p. medida aqui em $I = 100$ é o mesmo fenômeno, num espaço com duas ordens de grandeza mais classes. A prática corrente, no entanto, trata essa escolha como detalhe de implementação: há estudos de aprendizado ativo com BERT que partem dos dez primeiros exemplos de um conjunto embaralhado (Grießhaber et al., 2020). O que esta seção mede é o custo dessa arbitrariedade.

Esses resultados fundamentam a partida a frio: se a composição importa tanto no regime pequeno (exatamente o regime da partida a frio do aprendizado ativo), então construir L_0 deliberadamente (em vez de sorteá-lo) é a alavanca disponível antes de existir qualquer rótulo.

4.2 LIMITES POR OTIMIZAÇÃO EVOLUTIVA

Para estimar o quanto a composição pode render além do sorteio, um algoritmo genético (Seção 3.5.2) otimizou a composição de L_0 em quatro cenários (maximização e minimização de Acurácia e Macro F1) para dez tamanhos, com população de 20 indivíduos e 100 gerações por cenário (200 gerações no caso $|L_0| = 10$), o que corresponde a 2.000 avaliações supervisionadas

por cenário (4.000 no caso $|L_0| = 10$, pelas 200 gerações). A Tabela 4.1 resume a evolução do melhor (pior) indivíduo entre a 1ª e a 100ª geração nos cenários de acurácia.

Tabela 4.1: Evolução do AG (1ª vs. 100ª geração): cenários de Acurácia. Envelope entre minimização e maximização.

$ L_0 $	Maximização			Minimização		
	1ª	100ª	Δ	1ª	100ª	Δ
10	13,06%	18,82%	+5,76	—	—	—
50	22,12%	33,83%	+11,71	16,17%	7,13%	−9,04
100	26,65%	36,71%	+10,06	22,17%	10,86%	−11,31
500	48,55%	56,00%	+7,46	45,23%	36,17%	−9,06
1.000	57,76%	62,20%	+4,44	55,76%	49,33%	−6,43
5.000	73,48%	74,13%	+0,64	72,00%	70,82%	−1,18
20.000	82,10%	83,23%	+1,13	81,58%	79,55%	−2,03
30.000	85,07%	85,88%	+0,81	84,39%	83,03%	−1,36

Duas leituras: o envelope é **largo no regime pequeno** (em $I = 100$, a distância entre pior e melhor indivíduo da última geração chega a 25,9 pontos percentuais de acurácia) e **estreita com o tamanho**, coerente com a Seção 4.1: quanto maior o L_0 , menos a composição importa. O ganho evolutivo sobre a 1ª geração (coluna Δ) indica que o AG explora estrutura real, não flutuação; separar por completo estrutura de deriva de busca exigiria um controle de busca aleatória de mesmo orçamento, que não foi executado.

4.3 DRI-SL VERSUS ALEATÓRIO E ENVELOPE DO AG

A Tabela 4.2 compara o DRI-SL (heurística determinística sem rótulos, Seção 3.6) com o envelope do AG.

Tabela 4.2: Partida a frio: DRI-SL vs. envelope do AG (última geração), até $|L_0| = 5.000$. Classificador PVBIn.

$ L_0 $	DRI-SL		AG (melhor)		AG (pior)	
	Acurácia	Macro F1	Acurácia	Macro F1	Acurácia	Macro F1
100	41,23%	6,85%	36,71%	5,39%	10,86%	1,19%
500	59,22%	18,45%	56,00%	18,01%	36,17%	6,52%
1.000	67,39%	25,83%	62,20%	24,69%	49,33%	12,60%
2.500	73,36%	36,53%	69,28%	32,58%	63,92%	24,11%
5.000	76,87%	44,09%	74,13%	40,07%	70,82%	31,87%

O resultado central da partida a frio: **o DRI-SL supera não só a amostragem aleatória média, mas o próprio melhor indivíduo encontrado pelo AG** em todos os tamanhos de 100 a 5.000 (ex.: $I = 1.000$: 67,4% vs. 62,2% de acurácia). Uma heurística construtiva de custo linear e sem acesso a rótulos supera um otimizador evolutivo com 2.000 avaliações supervisionadas por cenário, forte indício de que densidade semântica + variedade lexical capturam exatamente a estrutura que torna um L_0 informativo. Há uma ressalva metodológica: os valores do AG aqui

reportados herdam o protocolo original (aptidão e relato na mesma partição), inflacionado por construção; a quantificação está na seção seguinte, e reforça a conclusão.

Esse desfecho confirma a expectativa mais bem estabelecida da literatura de partida a frio: em orçamento baixo, representatividade supera incerteza. [Hacohen et al. \(2022\)](#) formalizam a transição de regime já apresentada no Capítulo 2 e mostram que, abaixo dela, as estratégias clássicas de consulta empatam com a seleção aleatória ou pioram; em texto, [Yu et al. \(2023\)](#) medem a incerteza estimada pelo modelo perdendo da aleatória, a seleção por conjunto-núcleo abaixo da aleatória e o k -médias simples superando alternativas mais elaboradas justamente nos conjuntos com mais classes. O DRI-SL combina representatividade (densidade semântica) e cobertura (variedade lexical), e vence no espaço de 621 classes: o resultado replica, em português e numa escala de classes maior do que a testada por esses trabalhos, o que essa literatura leva a esperar.

A surpresa está no adversário que a heurística supera. O AG não é um competidor fraco: otimiza a composição com acesso direto aos rótulos e à aptidão final, ao custo das 2.000 avaliações supervisionadas por cenário, e ainda assim perde para uma heurística que não consulta rótulo algum. A literatura sugere a explicação: mesmo a incerteza calculada por um modelo treinado no conjunto inteiro perde da aleatória no orçamento baixo ([Hacohen et al., 2022](#)), indício de que o gargalo da partida a frio não é falta de informação supervisionada, e sim a cobertura da estrutura do espaço de entrada, que densidade e variedade capturam sem rótulo. O contraste com [Zhang et al. \(2023\)](#) delimita o alcance: em tarefas de extração com poucos tipos de saída, a diversidade pura por k -médias só supera a aleatória em um de três conjuntos, e a incerteza domina; aqui, com centenas de classes desbalanceadas em texto curto, a relação se inverte. A divergência é coerente com a leitura de regime: o valor da representatividade cresce com o número de classes a cobrir e diminui quando poucas classes já são cobertas por qualquer amostra.

Há, por fim, um efeito de variância que as tabelas de média não mostram. A literatura reporta que a seleção estratégica reduz também a dispersão entre execuções, não só a média ([Grießhaber et al., 2020](#); [Yu et al., 2023](#)). O DRI-SL, determinístico, leva esse efeito ao limite: elimina por construção a amplitude de 6,4 p.p. que o sorteio introduz em $I = 100$ (Seção 4.1), o que importa na aplicação, em que o L_0 é construído uma única vez.

4.4 REEXECUÇÃO INDEPENDENTE E EFEITO DA CIRCULARIDADE

A reexecução na biblioteca `activelearning` usa grade reduzida de 15 tamanhos $\times$ 10 repetições (artefatos em `experiments/pl/results/`): os 15 tamanhos são log-espaçados cobrindo todo o intervalo original (10 a 2×10^5), pois a forma da curva, e não a sua densidade, é o objeto da validação, e 10 repetições estimam a média com erro-padrão inferior à divergência que se pretende detectar (a amplitude entre repetições do original), a um nono do custo computacional das 47×30 células originais. A reexecução reproduz a estrutura completa

do estudo original com protocolo mais rigoroso: deduplicação por texto normalizado *antes* do particionamento e teste fixo de 20.000 instâncias.

Tabela 4.3: Estudo de sensibilidade: original (30 rep.) vs. reexecução independente (10 rep., protocolo com deduplicação). Acurácia média.

$ L_0 $	Original	Reexecução	Diferença
10	6,7%	6,6%	-0,1
100	24,7%	24,0%	-0,7
1.000	55,9%	55,5%	-0,4
10.000	76,9%	76,4%	-0,5
100.000	87,1%	86,7%	-0,4
200.000	89,1%	88,8%	-0,3

A concordância entre as duas execuções (Tabela 4.3) valida de forma independente tanto o estudo original quanto o porte do classificador para a biblioteca nova: a diferença fica em $\leq 0,7$ p.p. em todos os tamanhos, sempre no sentido esperado, pois a deduplicação remove quase-duplicatas que inflavam a concordância entre treino e teste, e o protocolo com deduplicação é ligeiramente mais difícil. A fidelidade do porte foi adicionalmente verificada por igualdade exata das matrizes de escore entre implementações.

A reexecução do AG usou 2 tamanhos $\times$ 2 cenários com $N_{pop} = 30$ e 40 gerações, a menor configuração que reproduz o *mecanismo* (a aptidão estabiliza bem antes da 40ª geração em todas as células), pois o objetivo aqui é validar o fenômeno e quantificar a circularidade, não re-estimar o envelope completo, que permanece o do estudo original. Reduzir a malha por custo computacional, declarando o que se perde, tem precedente publicado: [Grießhaber et al. \(2020\)](#) restringem o *pool* de não rotulados a 20 mil elementos pela mesma razão, registrando o risco de excluir instâncias relevantes. A reexecução aplicou ainda o protocolo anticircularidade da Seção 3.5.2: aptidão medida em partição de aferição, indivíduo final *reavaliado* no teste intocado. O mecanismo se reproduz (melhor indivíduo evolui +5,2 p.p. de acurácia em $I = 50$; envelope acima da média aleatória em todos os casos), mas a reavaliação honesta revela a inflação da circularidade: para maximização de Macro F1 com $I = 500$, a aptidão final é 19,4%, mas o mesmo indivíduo mede 13,1% no teste intocado, isto é, 6,3 pontos percentuais de superajuste ao conjunto de aferição. Para acurácia a inflação é menor (≈ 1 p.p.). Conclusão metodológica incorporada à tese: **envelopes evolutivos devem ser reportados exclusivamente em partição não usada como aptidão**; os valores de AG das Tabelas 4.1 e 4.2 devem ser lidos como limites otimistas, e a superioridade do DRI-SL sobre eles é, portanto, conservadora.

4.5 SÍNTESE DO CAPÍTULO

(i) A composição de L_0 tem efeito grande e mensurável no regime pequeno (amplitude de 6,4 p.p. em $I = 100$ só por sorteio), decaindo com o tamanho; (ii) o envelope evolutivo confirma espaço explorável de dezenas de pontos percentuais entre composições boas e ruins

no regime pequeno; (iii) o DRI-SL captura esse espaço sem usar rótulos, superando o melhor indivíduo do AG até $I = 5.000$, e é por isso a estratégia da Fase 1 do FALCO; (iv) a reexecução independente reproduz os três achados e quantifica o viés de circularidade do protocolo original de AG, corrigido nesta tese. Lidos em conjunto contra a literatura, os achados confirmam que a representatividade domina o regime de orçamento baixo e a estendem em um ponto: nem um otimizador com acesso aos rótulos supera, nesse regime, uma heurística estrutural que não os consulta.

5 RESULTADOS: ORÁCULOS LLM E O FRAMEWORK FALCO

Este capítulo apresenta os resultados de dois pilares. O do oráculo LLM traz a avaliação instrumentada de modelos de linguagem de grande porte (LLMs) como oráculos de rotulagem (Seção 5.1) e a ablação de prompt no modelo de menor custo (Seção 5.2). O do framework traz: a varredura de estratégias com oráculo simulado (Seção 5.3), a robustez do aprendizado a ruído controlado de oráculo (Seção 5.4), os seletores em escala populacional (Seção 5.5) e a validação com o classificador forte fora do laço (Seção 5.6), que responde a hipótese central. Todos os números reportados são rastreáveis a artefatos versionados no repositório `activelearning` (`experiments/e0`, `e0p`, `e1e4`, `e6population`, `e2e3`).

5.1 AVALIAÇÃO FATORIAL DE ORÁCULOS LLM

5.1.1 RQ1: assertividade

A Tabela 5.1 apresenta acurácia (com intervalo de confiança, IC, de Wilson a 95%), Macro F1 e taxa de rótulos inválidos dos oráculos avaliados nas duas amostras pareadas oficiais (S-rand $n = 1.000$; S-strat $n = 1.863$), com temperatura 0 e rotulagem em lote calibrada.

Tabela 5.1: Desempenho dos oráculos LLM. Modo enum para OpenAI; json-prompt para MaaS, agregador e NVIDIA NIM (*NVIDIA Inference Microservice*), que não suportam saída estruturada. IC = intervalo de confiança de Wilson a 95%.

Oráculo	Amostra	Acurácia	IC 95%	Macro F1	Inválidos
deepseek-v4-pro	S-rand	82,1%	[79,6; 84,4]	0,785	0,1%
gpt-4o	S-rand	80,9%	[78,4; 83,2]	0,788	0,0%
deepseek-v4-flash	S-rand	78,3%	[75,6; 80,8]	0,750	0,7%
nemotron-3-ultra (grátis)	S-rand	77,9%	[75,2; 80,4]	0,752	1,2%
glm-5.2	S-rand	77,3%	[74,6; 79,8]	0,742	0,7%
gpt-4o-mini	S-rand	61,3%	[58,2; 64,3]	0,518	0,0%
deepseek-v4-pro	S-strat	82,6%	[80,8; 84,2]	0,793	0,2%
gpt-4o	S-strat	82,1%	[80,3; 83,8]	0,797	0,0%
deepseek-v4-flash	S-strat	81,6%	[79,7; 83,3]	0,781	0,9%
glm-5.2	S-strat	80,9%	[79,1; 82,6]	0,782	0,0%
nemotron-3-ultra (grátis)	S-strat	79,6%	[77,7; 81,4]	0,770	2,6%
gpt-4o-mini	S-strat	45,7%	[43,4; 48,0]	0,427	0,0%

Quatro leituras principais. **(i)** Os quatro melhores oráculos formam um platô entre 77% e 83% nas duas amostras, e as diferenças internas ao platô são pequenas; o teste pareado (RQ1, McNemar) na S-strat mostra deepseek-v4-pro significativamente superior ao v4-flash ($b = 43$, $c = 16$, $p < 0,001$) e estatisticamente empatado com o gpt-4o ($p = 0,061$). **(ii)** O gpt-4o-mini colapsa na amostra estratificada (45,7%): o modelo pequeno erra sistematicamente nas classes raras, que a S-strat expõe por construção. **(iii)** Nenhum oráculo atinge o limiar de 85% do gate (Seção 3.7.3) na S-rand: o melhor zero-shot fica a ≈ 7 p.p. do teto supervisionado

com 250 mil rótulos (89,6%, Darú, 2024). A consequência de desenho está na Seção 5.7. (iv) Em compensação, o Macro F1 zero-shot dos oráculos do platô ($\approx 0,78$ – $0,80$ na S-strat) *supera* o Macro F1 do PVBIn treinado com supervisão completa (0,70): o conhecimento de mundo do LLM compensa exatamente onde o supervisionado leve sofre, ou seja, nas classes com pouquíssimos exemplos.

5.1.2 RQ2: custo e o efeito do *cache*

Tabela 5.2: Custo por mil rótulos (US\$) e taxa de acerto de *cache* de prefixo (S-rand; preços vigentes na execução, jul/2026).

Oráculo	US\$/1k rótulos	Cache	Acurácia
nemotron-3-ultra (grátis)	0,000	—	77,9%
deepseek-v4-flash	0,035	—	78,3%
gpt-4o-mini	0,051	91%	61,3%
glm-5.2	0,249	—	77,3%
deepseek-v4-pro	0,410	—	82,1%
gpt-4o	0,923	88%	80,9%

A Tabela 5.2 consolida o custo por mil rótulos e a taxa de acerto do *cache* de prefixo por oráculo. O intervalo de custo entre oráculos do mesmo platô de acurácia é de mais de uma ordem de grandeza: o deepseek-v4-flash entrega 78–82% por US\$ 0,035/1k, **26 vezes mais barato** que o gpt-4o (80–82%). O *cache* de prefixo (prefixo estático do *prompt* + schema precedendo o item variável, Seção 3.7.1) atinge 88–95% de acerto nos provedores que o suportam, reduzindo pela metade o custo efetivo do tokens de entrada. Para referência externa, o custo fica duas a três ordens de grandeza abaixo do custo típico de anotação humana por item relatado na literatura (Gilardi et al., 2023). Custo, porém, não é a única restrição operacional: os limites de vazão dos provedores (3 requisições/min no MaaS, 18/min no plano gratuito do agregador OpenRouter, nos artefatos de latência de `experiments/e0`) moldaram o próprio desenho experimental e, em produção, definem o tempo de parede de um ciclo de rotulagem tanto quanto o preço: um oráculo barato e lento pode ser dominado por um caro e paralelo quando o gargalo é o prazo.

O **regime de custo monetário zero** confirmou-se competitivo: o nemotron-3-ultra servido pela API de avaliação da NVIDIA empata estatisticamente com o deepseek-v4-flash na S-rand (McNemar, $p = 0,76$) e com o glm-5.2 na S-strat ($p = 0,078$), ficando abaixo apenas do v4-pro ($p < 0,001$). Duas ressalvas operacionais, ambas achados: (i) *grátis não é custo operacional zero*, porque a primeira tentativa, via agregador com cota de 50 requisições/dia, projetava seis dias de execução (decisões D-005/D-006 do registro de decisões do repositório de experimentos); e (ii) *o provedor de serving é parte do instrumento*: o MESMO modelo servido pelo agregador diverge significativamente de si mesmo servido pela NVIDIA nas mesmas instâncias ($p < 0,001$ no subconjunto pareado de 850 itens). Medições de oráculo LLM devem registrar, portanto, não só o modelo, mas quem o serve e como.

5.1.3 RQ3: perfil de erro

A anatomia dos 324 erros do melhor oráculo (v4-pro, S-strat) revela estrutura, não ruído difuso: **31%** são confusões entre *categorias-irmãs* que compartilham palavra (*antiséptico bucal* → *enxaguante bucal*; *ervilha* → *ervilha em conserva*); **17%** têm como gabarito uma classe guarda-chuva *outro* . . . (o modelo escolhe a específica; o catálogo arquiva na agregadora) e 7% o inverso; $\approx 2\%$ envolvem `_rare_` ou rótulo inválido; o restante são erros semânticos genuínos. Ou seja: quase metade do erro do oráculo não é ignorância sobre o produto, e sim desconhecimento das *convenções deste catálogo*: fronteiras entre classes vizinhas e política de agregação que só se aprendem com exemplos rotulados. Esse diagnóstico tem duas consequências: motiva a ablação de *prompt* da Seção 5.2 (regras de fronteira explícitas) e prevê que o ruído do oráculo é *estruturado* (concentrado em pares vizinhos), cenário menos danoso ao classificador treinado que ruído uniforme (Frénay e Verleysen, 2014; Song et al., 2023); é a hipótese testada na Seção 5.4.

5.1.4 RQ4: efeito do instrumento de medição

Com o mesmo modelo (gpt-4o-mini), as mesmas 1.000 instâncias da S-rand e o mesmo *prompt*, a troca do instrumento produz o seguinte, comparando saída estruturada com `enum` e saída livre (réplica do instrumento do legado): acurácia 61,3% (`enum`) contra 60,5% (`free`), mas taxa de rótulos inválidos de **0,0% contra 6,8%**. O efeito do instrumento aparece menos na acurácia pontual e mais na *contabilidade do erro*: sem restrição de saída, quase 7% das respostas são variações de fraseado fora do espaço de rótulos, que um protocolo ingênuo computa como erro do modelo, o que deflaciona a medição e contamina qualquer comparação entre modelos com propensões diferentes a parafrasear. A restrição por `enum` com validação estrita elimina essa classe de artefato por construção, e é por isso o modo de produção do FALCO.

5.1.5 Sensibilidade ao ruído do gabarito e calibração do lote

Duas verificações de instrumentação completam a avaliação de oráculos. **Gabarito**: reavaliando todos os oráculos (a) sem as instâncias de rótulo conflitante e (b) sob pontuação *multi-gold*, a acurácia varia no máximo +0,7 p.p., sem alterar nenhum ordenamento: o ruído conhecido do gabarito limita o teto de medição ($\approx 99,3\%$), mas não contamina as comparações (Seção 3.2.2). **Lote**: na calibração pareada (lotes de 1, 10 e 25 itens nas mesmas instâncias), o McNemar não detecta degradação ($b = 1$ vs. $b = 10$: $p = 0,58$), e o lote reduz o custo por rótulo em até 10 vezes ao amortizar o prefixo, e por isso adotou-se $b = 10$ (OpenAI) e $b = 25$ (MaaS), registrado por anotação. O ganho é consistente com o precedente de anotação em lote em laços de aprendizado ativo com LLM (Kholodna et al., 2024), que reporta o mesmo mecanismo de amortização de *prompt* como componente central da economia frente à anotação humana.

5.2 O *PROMPT* COMO VARIÁVEL DO INSTRUMENTO DE MEDIÇÃO

A anatomia de erros (RQ3) indica que $\approx 48\%$ dos erros do oráculo são de convenção de catálogo, ou seja, atacáveis por *prompt*. Esta seção mede esse potencial no modelo de MENOR custo com cache (gpt-4o-mini): variantes **v4a** (dez regras de fronteira explícitas derivadas do perfil de erro da S-strat) e **v4b** (v4a + dez exemplos *inventados* de fronteiras difíceis, nunca instâncias das amostras, desenho anti-vazamento registrado na decisão D-004 do mesmo registro), pareadas com o v3 oficial nos mesmos 500 primeiros itens de cada amostra. Esse subconjunto-prefixo (aleatório por construção, pois as amostras já são embaralhadas) foi dimensionado para detectar, via McNemar, deslocamentos da ordem de 4–5 p.p. com o volume de discordâncias esperado (≈ 60 –80 pares), a um quinto do custo da amostra completa por variante. A Tabela 5.3 resume o resultado (artefato: `experiments/e0p/results/analysis.json`).

Tabela 5.3: Ablação de *prompt* no gpt-4o-mini (enum, $b = 10$, $n = 500$ pareado por amostra). p : McNemar exato contra o v3.

Amostra	Variante	Acurácia	Discordantes (+/–)	p vs. v3
S-rand	v3 (base)	60,4%	—	—
S-rand	v4a (regras)	64,2%	50/31	0,045
S-rand	v4b (regras+ex.)	65,0%	50/27	0,012
S-strat	v3 (base)	51,8%	—	—
S-strat	v4a (regras)	44,8%	20/55	$< 0,001$
S-strat	v4b (regras+ex.)	41,0%	14/68	$< 0,001$

O resultado é uma faca de dois gumes, e por isso mesmo informativo. Na S-rand, que espelha a distribuição de produção, as regras de fronteira recuperam parte do erro de convenção: +3,8 p.p. com v4a ($p = 0,045$) e +4,6 p.p. com v4b ($p = 0,012$), confirmando que uma fração do déficit do modelo fraco é atacável por *prompt* sem nenhum rótulo adicional. Na S-strat, porém, as mesmas regras *destroem* desempenho: $-7,0$ e $-10,8$ p.p. ($p < 0,001$), com os exemplos inventados piorando significativamente sobre as regras puras ($p = 0,0013$). A leitura é direta: regras derivadas do perfil de erro agregado empurram o modelo para as convenções das classes *frequentes*, exatamente o comportamento que penaliza a amostra estratificada, dominada por classes raras. Duas implicações para o FALCO: (i) otimização de *prompt* deve ser validada nas *duas* distribuições antes de adoção, pois um ganho medido só na amostra natural pode mascarar regressão severa nas caudas; e (ii) o ganho barato na distribuição de produção existe e justifica a direção de trabalho futuro de gerar regras automaticamente a partir da matriz de confusão (Seção 6.5), desde que com salvaguarda estratificada.

5.3 ESTRATÉGIAS DE SELEÇÃO COM ORÁCULO PERFEITO

Esta seção varre as cinco estratégias de seleção (entropia, menor confiança, menor margem, híbrida, aleatória) com o PVBin e oráculo simulado sem ruído, em pool deduplicado

de 20.000 instâncias, orçamento de 3.000 rótulos, lote 100 e 8 sementes por célula; a ablação de lote repete a entropia, estratégia adotada na Fase 2 do FALCO e na avaliação de robustez ao ruído (Seção 5.4), com $b \in \{50, 200\}$. O dimensionamento é deliberado: 20.000 é o maior pool que mantém as 104 células (5 estratégias + ablações + células de ruído, $\times 8$ sementes) computáveis em CPU preservando representação de todas as classes; o orçamento de 3.000 (15% do pool) cobre exatamente o regime de poucos rótulos em que as estratégias diferem, pois para além dele as curvas convergem e a comparação perde poder; o lote 100 é o valor operacional do FALCO, e a própria ablação testa sua vizinhança; e 8 sementes é o mínimo que permite $p < 0,05$ no Wilcoxon pareado (Seção 3.8.2). O teto supervisionado do *pool* completo (20.000 rótulos) é Macro F1 = 0,540. A Tabela 5.4 apresenta as células (artefato: `experiments/ele4/results/analysis.json`).

Tabela 5.4: Estratégias com oráculo perfeito (média $\pm$ desvio-padrão, dp, sobre 8 sementes; orçamento 3.000, lote 100). p : Wilcoxon pareado por semente contra a aleatória; com $n = 8$, o menor p atingível é 0,0078.

Estratégia	LCE	Macro F1 final	p vs. aleatória
Menor margem	0,528 $\pm$ 0,013	0,418 $\pm$ 0,013	0,0078
Menor confiança	0,518 $\pm$ 0,010	0,421 $\pm$ 0,009	0,0078
Entropia	0,493 $\pm$ 0,006	0,398 $\pm$ 0,008	0,0078
Híbrida	0,476 $\pm$ 0,014	0,379 $\pm$ 0,008	0,0078
Aleatória	0,444 $\pm$ 0,011	0,339 $\pm$ 0,006	—

A tabela comporta três leituras. **(i) Toda estratégia de incerteza supera a aleatória**, e o faz no máximo de significância que 8 sementes permitem ($p = 0,0078$ em LCE, a *Learning Curve Efficiency* do Capítulo 3, e em F1 final, todas as comparações): com 15% do orçamento de rótulos, a melhor célula recupera 78% do Macro F1 do teto supervisionado. **(ii) As margens vencem a entropia** no regime de 621 classes: menor margem lidera em LCE (0,528) e menor confiança em F1 final (0,421), enquanto a entropia, diluída pela cauda longa de probabilidades em espaços de classe muito grandes, fica $\approx 2\text{--}3$ p.p. atrás; a híbrida herda o pior dos dois mundos. **(iii) O lote é barato até certo ponto**: na ablação com entropia, $b = 50$ (LCE 0,492 $\pm$ 0,009) e $b = 100$ (0,493 $\pm$ 0,006) são indistinguíveis, mas $b = 200$ degrada para 0,481 $\pm$ 0,012; uma explicação compatível, não medida diretamente, é que com lotes grandes a seleção repete redundância dentro do próprio lote antes de o modelo se atualizar. Para o FALCO, isso fixa o lote operacional em $b \leq 100$ e recomenda menor margem/menor confiança como estratégias da Fase 2, com a ressalva explícita de que o ordenamento foi medido com o classificador leve e deve ser revalidado com BERTimbau (desenho na Seção 3.8.2): probabilidades mais calibradas do *transformer* podem reordenar entropia e margens.

5.4 ROBUSTEZ DO APRENDIZADO AO RUÍDO DO ORÁCULO

Esta seção injeta ruído uniforme $\varepsilon \in \{0,1; 0,2; 0,4\}$ no oráculo simulado e repete o desenho da Seção 5.3 para entropia e aleatória. A pergunta é quanto do valor do aprendizado

ativo sobrevive quando o oráculo erra na taxa observada nos LLMs reais ($\varepsilon \approx 0,17\text{--}0,23$ no platô de oráculos da Seção 5.1). Os três níveis são escolhidos para *cercar* essa faixa: 0,1 abaixo dela (oráculo melhor que os disponíveis), 0,2 dentro dela (cenário central) e 0,4 como teste de estresse, ou seja, o dobro do erro real, na região do gpt-4o-mini na S-strat. A Tabela 5.5 apresenta o resultado (mesmo artefato da Seção 5.3).

Tabela 5.5: Robustez ao ruído uniforme do oráculo (média $\pm$ dp, 8 sementes). Retenção: fração do Macro F1 final da mesma estratégia em $\varepsilon = 0$. p : Wilcoxon pareado entropia vs. aleatória no mesmo ε .

ε	Estratégia	Macro F1 final	Retenção	p
0,1	Entropia	0,347 $\pm$ 0,008	87,2%	0,0078
	Aleatória	0,294 $\pm$ 0,006	86,7%	
0,2	Entropia	0,294 $\pm$ 0,006	74,0%	0,0078
	Aleatória	0,252 $\pm$ 0,006	74,4%	
0,4	Entropia	0,215 $\pm$ 0,010	54,1%	0,0078
	Aleatória	0,186 $\pm$ 0,006	54,8%	

Os resultados trazem dois achados. **Primeiro, o ruído custa caro, mas não destrói o aprendizado ativo:** a vantagem da entropia sobre a aleatória sobrevive *intacta e no teto de significância* em todos os níveis de ruído ($p = 0,0078$ em LCE e F1 final para todo ε), e a retenção relativa das duas estratégias é praticamente idêntica (87%, 74% e 54% em $\varepsilon = 0,1, 0,2$ e $0,4$): o ruído uniforme deprime a curva inteira sem corroer o *valor da seleção*. Não se observa aqui o colapso em que a incerteza passa a selecionar preferencialmente instâncias mal rotuladas. **Segundo, a taxa de erro dos oráculos reais está na faixa tolerável:** os LLMs avaliados na Seção 5.1 erram $\varepsilon \approx 0,17\text{--}0,23$ no espaço fechado, região em que esta varredura mede retenção de $\approx 74\text{--}87\%$ do F1 final. E o desenho é deliberadamente pessimista: injeta ruído *uniforme*, enquanto a anatomia do RQ3 mostrou que quase metade do erro real dos oráculos é estruturado (categorias-irmãs e guarda-chuva semanticamente próximas), cujo dano esperado ao classificador é menor que o do erro aleatório de mesma taxa (Frénay e Verleysen, 2014; Song et al., 2023). Registre-se a nuance: essa leitura não é unânime, pois em reconhecimento de entidades o ruído *real* de anotação mostrou-se mais nocivo que corrupção artificial de mesma taxa (Merdjanovska et al., 2024); a extrapolação aqui é condicionada à anatomia específica medida no RQ3 (confusões semanticamente adjacentes e parcialmente defensáveis), não a uma superioridade geral do ruído estruturado. Sob essa condição, o resultado positivo desta seção é um limite inferior do desempenho esperável com os oráculos reais avaliados; e a extensão natural do desenho é a correção colaborativa de rótulos ruidosos com apoio de LLM (Yuan et al., 2024).

5.5 SELETORES EM ESCALA POPULACIONAL E O VIÉS DA AUTOAVALIAÇÃO

Esta seção estende a comparação de seletores (as estratégias de seleção, aqui aplicadas como política contínua ao longo de todo o orçamento) para a escala completa da base e

operacionaliza a distinção entre a *autoavaliação* (medir nos próprios dados que o processo coletou) e a avaliação *externa*. O viés estatístico de avaliar em dados coletados ativamente é conhecido da literatura (Farquhar et al., 2021; Kossen et al., 2021); a contribuição aqui é quantificá-lo em espaço de classes amplo, onde o sinal se revela dependente da métrica. A base deduplicada é dividida em um *pool* rotulável de 50.000 instâncias (oráculo perfeito, isto é, o próprio gabarito) e uma **população reservada** com todo o restante (181.490 instâncias), jamais tocada pela seleção. Registre-se a diferença de denominador em relação ao Capítulo 3, que declara 177.490: a avaliação em escala populacional desta seção não desconta as 4.000 instâncias do *conjunto retido* (2.000 de validação e 2.000 de teste, Seção 3.2.4), que existem para decidir a parada do ciclo real. O desconto é feito na avaliação com o classificador forte (Seção 5.6) por precaução, e não é necessário aqui porque esta varredura **não tem critério de parada**: ela percorre o orçamento inteiro e, portanto, nunca consulta aquelas instâncias para decidir coisa alguma. A diferença é de 2,2% da amostra de avaliação e, como o particionamento é feito por posição *depois* do embaralhamento, os dois recortes são intercambiáveis. A cada lote de 500, o conjunto rotulado acumulado sofre uma divisão convencional 80/20 e o modelo treinado é medido em dois lugares: no *teste de autoavaliação* (os 20% do que o processo rotulou, isto é, o que um praticante sem conjunto reservado conseguiria medir) e na *população* (o desempenho real de implantação). Cinco seletores são comparados com PVBin e SGD logístico: entropia, aleatório, DRI-SL como política contínua, a variante **DRI-SL-C** e um braço de **ablação** da própria DRI-SL-C. Na DRI-SL-C, após o *cold start*, os grupos do DRI-SL deixam de vir de *k*-means e passam a ser as *classes previstas pelo próprio classificador*, mantidas a alocação proporcional e a novidade lexical intra-grupo; a ablação remove o termo de novidade lexical e equivale, portanto, a *amostragem estratificada pelas classes previstas*. A ablação isola a origem do ganho da variante: agrupamento por predição ou seleção lexical dentro dos grupos. Execução com semente única e orçamento até o *pool* completo (artefatos em `experiments/e6population`); por ser braço único por célula, os números da Tabela 5.6 são descritivos. Os dois braços centrais (entropia e aleatório, ambos classificadores) foram, contudo, reexecutados em **oito sementes** que variam o sorteio inicial, os desempates e a divisão interna mantendo o *pool* fixo, permitindo inferência sobre a comparação principal (artefato `analysis_multiseed.json`). A robustez confirma o quadro: a saturação da entropia no SGD é $9,1k \pm 0,6k$ rótulos (faixa 8,5–10k) contra $15,5k \pm 1,1k$ do aleatório, e o teto da entropia supera o do aleatório em **8 das 8 sementes** (Wilcoxon pareado, $p = 0,0078$, a significância máxima alcançável com oito pares); no PVBin a vantagem de teto é pequena e não significativa (6/8), mas a saturação ($19,3k \pm 0,7k$) permanece menos da metade da do aleatório ($40,6k \pm 1,4k$). O viés de autoavaliação da acurácia é igualmente estável: em $|L| = 10k$ o teste de autoavaliação subestima a população em $17,1 \pm 1,0$ p.p. entre as sementes. O valor de saturação de 8.000 reportado na Tabela 5.6 (semente original) situa-se na borda otimista da faixa multi-semente, sem alterar nenhuma conclusão.

Cinco achados (Tabela 5.6). (i) **A entropia domina em escala**: satura a 95% do teto com 8.000 rótulos no SGD (19.000 no PVBin), cerca de metade do que a seleção aleatória

Tabela 5.6: Macro F1 na população por seletor e classificador. Saturação: menor $|L|$ que atinge 95% do teto do próprio braço. As linhas usam denominadores de avaliação diferentes: as reavaliadas medem na população reservada de 177.490; as duas curvas de PVBIn Entropia e PVBIn Aleatório permanecem em 181.490 (execuções travadas com seletor congelado, não reavaliáveis); a diferença entre denominadores vale 0,02 p.p.

Classif.	Seletor	Teto F1	Saturação	F1@10k	F1@20k
SGD	Entropia	0,590	8.000	0,565	0,573
SGD	Estratif. por predição	0,555	9.500	0,533	0,543
SGD	DRI-SL-C	0,491	15.500	0,412	0,486
SGD	Aleatório	0,458	15.500	0,391	0,448
SGD	DRI-SL	0,441	41.500	0,310	0,365
PVBIn	Entropia	0,529	19.000	0,438	0,509
PVBIn	Estratif. por predição	0,528	18.000	0,444	0,498
PVBIn	DRI-SL-C	0,525	39.500	0,349	0,452
PVBIn	Aleatório	0,530	40.000	0,348	0,423
PVBIn	DRI-SL	0,527	45.500	0,284	0,356

exige nos dois classificadores, o que confirma a varredura com oráculo perfeito (Seção 5.3) fora do regime de orçamento pequeno. **(ii) Rotular tudo pode piorar:** no SGD, o Macro F1 populacional atinge 0,59 com ≈ 15 mil rótulos selecionados por entropia e cai para 0,44 quando o *pool* inteiro é rotulado, porque a amostra ativa é mais balanceada por classe que a distribuição natural, que domina o treino do modelo de perda logística quando tudo entra. A composição foi medida a partir dos índices rotulados salvos por execução: em número efetivo de classes (o exponencial da entropia de Shannon da distribuição, isto é, quantas classes equiprováveis dariam a mesma dispersão), a amostra da entropia com 15 mil rótulos alcança 331,7 contra 172,6 do *pool* natural, e a classe majoritária cai de 5,97% para 1,87% da amostra; o braço aleatório, que serve de controle, fica em 167,6, indistinguível do natural, mostrando que o rebalanceamento vem da *seleção*, não do tamanho da amostra. O PVBIn, que constrói um protótipo por classe, é imune ao efeito na métrica, embora sua amostra ativa também seja rebalanceada (261,1). Para o custo de rotulagem, a implicação é forte: além do desperdício, o rótulo adicional pode ser *nocivo* à métrica macro. **(iii) O DRI-SL contínuo se corrige quando guiado pelo classificador:** a variante DRI-SL-C eleva o teto do SGD de 0,441 para 0,491, adianta a saturação em $2,7\times$ (de 41.500 para 15.500) e supera o aleatório em toda a região útil, enquanto o DRI-SL clássico, cego ao classificador, fica abaixo do aleatório como política contínua. **(iv) A ablação atribui o ganho ao agrupamento, não à novidade lexical:** o braço estratificado por predição, que é a DRI-SL-C sem o termo de novidade, supera a DRI-SL-C completa nos dois classificadores (SGD: teto 0,555 e saturação em 9.500 contra 0,491 e 15.500; PVBIn: saturação em 18.000 contra 39.500, empatando com a entropia) e em toda a região média da curva. A seleção lexical intra-grupo, valiosa na partida a frio sem nenhum rótulo, é *contraproducente* no regime contínuo: privilegia exemplares lexicalmente atípicos quando o que a métrica macro paga é cobertura balanceada de classes. A leitura consolidada da tese passa a ser: DRI-SL para o *cold start* (Fase 1, onde venceu o envelope evolutivo); na Fase 2, entropia como padrão, tendo a estratificação pelas

classes previstas, política trivial de implementar, como alternativa representativa que captura quase todo o ganho. (v) **A autoavaliação em dados coletados ativamente é enviesada, com sinal dependente da métrica:** no braço aleatório (controle), acurácia da autoavaliação e a externa coincidem ($\Delta \approx 0$), validando o instrumento; na entropia, a acurácia da autoavaliação *subestima* a real em até 14 p.p. (o teste de autoavaliação herda os casos difíceis, o mecanismo previsto por [Kossen et al., 2021](#)); e o Macro F1 da autoavaliação *superestima* o populacional em todos os seletores (até +34 p.p. no DRI-SL no início da curva), porque a amostra ativa sobre-representa classes raras: na mesma medição de composição, a massa das classes raras na amostra da entropia é de 2,347% contra 0,762% na distribuição natural (3,1 vezes), com 174 das 179 classes raras alcançadas, enquanto o braço aleatório fica em 0,807% e alcança 94 delas. Nenhuma das duas direções é utilizável como estimativa de implantação: é a justificativa empírica direta para o conjunto de validação reservado que o FALCO exige e para o critério de liberação do Apêndice [G.2](#).

5.6 AVALIAÇÃO DA HIPÓTESE CENTRAL COM O CLASSIFICADOR FORTE

O braço de validação com classificador forte (desenho na Seção [3.8.2](#)) treina o BERTimbau uma vez por braço, sobre conjuntos já coletados, e avalia todos os braços na população reservada inteira (177.490 instâncias, excluídos o pool e os conjuntos de decisão do ciclo real), com três sementes de treinamento e análise pareada por semente; cada número vem como média e desvio-padrão entre sementes, e as comparações usam McNemar e *bootstrap* pareados na mesma população (artefatos em `experiments/e2e3`). Configuração uniforme entre braços: 3 épocas, lote de treinamento 16 com limitação da norma do gradiente, comprimento máximo de 32 *tokens*. O tamanho do lote é ele próprio um achado metodológico, não um detalhe: a configuração inicial, com lote 128, sub-treinava todos os braços (no braço-régua D, a correção elevou o Macro F1 de 0,3684 para 0,459), e um teste de controle na mesma semente isolou o efeito, o que motivou reexecutar a varredura inteira no regime corrigido. A Tabela [5.7](#) consolida.

Tabela 5.7: BERTimbau treinado por braço e avaliado na população reservada inteira (177.490 instâncias). Receita de agregação: regime homogêneo de treino (lote 16, artefatos `_bs16v2` em `experiments/e2e3`); braços A–D são média simples das sementes 7, 42 e 123; o braço E é média das sementes 7 e 42, pois a semente 123 não foi executada nesse regime; desvios-padrão nos artefatos.

Braço	Conjunto de treino	<i>n</i>	Acurácia	Macro F1
A	pipeline real, rótulos do oráculo	11.936	0,705	0,297
B	mesmos itens, gabarito	11.936	0,777	0,299
C	aleatório, gabarito	11.936	0,788	0,246
E	15 mil por entropia, gabarito	15.000	0,822	0,351
D	<i>pool</i> inteiro, gabarito (régua)	50.000	0,887	0,459

O critério da hipótese é avaliado na métrica do pré-registro, a acurácia, operacionalizada como 0,95 da régua D; o Macro F1 acompanha como análise de robustez (Seção [1.3](#)).

Na configuração executada, a hipótese central não se confirma: o braço A alcança acurácia de 0,705 contra um critério de $0,95 \times 0,887 = 0,843$, e Macro F1 de 0,297 contra 0,436. O braço A usa 11.936 rótulos: 5,2% da população e 23,9% do *pool* de referência, aquém do teto de 34.724 que o critério admite. O valor do resultado está na decomposição, que o desenho pareado permite:

(i) O ruído do oráculo não é o gargalo. Nos mesmos 11.936 itens, os rótulos do oráculo custam 7,2 p.p. de acurácia frente ao gabarito (A vs. B), itens selecionados por incerteza e portanto mais difíceis que a média. Em Macro F1, os dois braços praticamente empatam (0,297 vs. 0,299, com B à frente em duas das três sementes): o erro estruturado do oráculo espalha rótulos por mais classes (o treino de A cobre 643 classes, contra 634 de B), mas a cobertura extra não se converte em Macro F1 superior. A leitura de que ruído estruturado é o regime benigno segue sustentada pela avaliação de robustez com ruído controlado (Seção 5.4); o que esta comparação mostra é que o custo do oráculo concentra-se na acurácia, sem perda correspondente em Macro F1: o gargalo do braço A é orçamento, não rótulo.

(ii) A seleção ativa compra Macro F1 e cobertura, não acurácia. Com o mesmo orçamento e gabarito, a diferença de acurácia entre o braço aleatório e o selecionado é pequena (C vs. B: 0,788 vs. 0,777, dentro da dispersão entre sementes), mas em Macro F1 a seleção vence com consistência (B – C é positivo e significativo nas três sementes, *bootstrap* pareado) e em cobertura: o treino selecionado alcança 634 classes, contra 525 do sorteio aleatório. É o mesmo padrão dos seletores em escala populacional (Seção 5.5), reproduzido no *transformer*.

(iii) O fator dominante é orçamento, e o critério de parada do laço leve subserve o modelo forte. O braço E, com 15 mil rótulos perfeitos selecionados por entropia (um quarto a mais do que o ciclo real coletou), sobe para 0,822 de acurácia (92,7% da régua) e 0,351 de Macro F1, ainda aquém do critério; este braço é média de duas sementes (7 e 42), pois a terceira semente não foi executada no regime homogêneo, divergência declarada na Tabela 5.7. A estagnação da validação do classificador *leve*, que encerrou o ciclo real em 11.936 rótulos, é, portanto, um *proxy* inadequado para o ponto de parada do classificador *forte*: o BERTimbau segue convertendo rótulos em desempenho muito além do ponto em que o PVBin/SGD saturam. Como os braços B e E usam gabarito (oráculo perfeito), essa conclusão independe da qualidade do oráculo: nenhum oráculo sustentaria o critério sob a política de parada executada.

Em síntese: na configuração executada (oráculo gratuito, parada por estagnação do classificador leve, 3 épocas), o critério não é atingido, e a decomposição pareada aponta a causa para a política de parada, não para o oráculo nem para a seleção. A varredura da subseção seguinte localiza o ponto em que o critério passa a valer e mostra que ele cabe no teto de rotulagem que a hipótese admite.

5.6.1 Varredura de orçamento: o piso que sustenta a hipótese

A varredura desta seção é um **achado post hoc**: foi desenhada e executada *depois* de observado o resultado da configuração executada, e não altera o critério, apenas localiza

empiricamente o orçamento em que ele passa a valer. Para isso, o BERTimbau foi treinado sobre prefixos crescentes da mesma trajetória de entropia (20, 25, 30 e 35 mil rótulos, com gabarito), avaliados na população reservada com as mesmas três sementes (Tabela 5.8). O quadro distingue duas exigências de robustez, e a distinção é deliberada: cruzar o critério *na média* das sementes e cruzá-lo *em todas* elas.

Tabela 5.8: Varredura de orçamento (média de três sementes; braço E: média de duas, ver Tabela 5.7; avaliação na população de 177.490; regime homogêneo). Critério 0,95× régua (D): acurácia $\geq 0,843$, Macro F1 $\geq 0,436$. As colunas de critério indicam em quantas sementes o braço cruza.

Braço	Rótulos	% <i>pool</i>	% base	Acurácia	Macro F1	acc	F1
A (pipeline real)	11.936	23,9%	5,2%	0,705	0,297	0/3	0/3
E	15.000	30%	6,5%	0,822	0,351	0/2	0/2
E20	20.000	40%	8,6%	0,858	0,407	✓ 3/3	0/3
E25	25.000	50%	10,8%	0,876	0,432	✓ 3/3	1/3
E30	30.000	60%	13,0%	0,884	0,455	✓ 3/3	✓ 3/3
E35	35.000	70%	15,1%	0,889	0,463	✓ 3/3	✓ 3/3
D (régua)	50.000	100%	21,6%	0,887	0,459	—	—

Três leituras fecham o pilar. **(i) A hipótese é atingível dentro do teto.** Na métrica do critério, a acurácia, o cruzamento ocorre em 20 mil rótulos (8,6% da população), nas três sementes e com folga (a menor semente do braço fica em 0,850, acima do critério de 0,843), bem abaixo do teto de 34.724 rótulos que a hipótese admite. **(ii) A robustez em Macro F1 acompanha, sem gradação:** com o regime homogêneo, o critério em F1 é atingido em 30 mil rótulos (13,0% da população), *na média e nas três sementes*, dentro do teto, com 4.724 rótulos de folga (Tabela 5.8); a bifurcação entre a leitura pela média e a leitura pela unanimidade, que a varredura anterior impunha, desapareceu com a homogeneização do regime de treino. **(iii) Menos é mais, como afirmação de média e com heterogeneidade declarada:** na média das três sementes, o braço de 35 mil rótulos ativamente selecionados fica à frente da régua de supervisão completa do *pool* nas duas métricas (0,889 contra 0,887 em acurácia; 0,463 contra 0,459 em Macro F1), mas o efeito não é unânime: duas sementes mantêm vantagem significativa (McNemar e *bootstrap* pareados), enquanto uma inverte em Macro F1 ($-0,0050$, IC 95% $[-0,0084; -0,0017]$) e empata em acurácia ($p = 0,67$). O sinal qualitativo (a fração final dos rótulos do *pool* não compra desempenho) reproduz no BERTimbau o efeito medido em escala populacional (Seção 5.5), e a tese o reporta como efeito de média com dispersão declarada, não como unanimidade. A conclusão consolidada: com uma política de parada ancorada no modelo forte, o critério é atingido dentro do teto de rotulagem da hipótese com rótulos de gabarito; a versão executada parou cedo demais, e a confirmação de ponta a ponta com rótulos de oráculo além do ponto de parada real é a extensão imediata.

5.7 DECISÃO DO GATE E CONFIGURAÇÃO DO FALCO

Aplicando o critério pré-registrado da Seção 3.7.3 aos resultados da avaliação de oráculos (Seção 5.1): nenhum oráculo atinge acurácia $\geq 85\%$ na S-rand; portanto, (i) a **avaliação de robustez ao ruído torna-se obrigatória**, executada nesta tese com o classificador leve (Seção 5.4) e pronta para reexecução com BERTimbau, e (ii) a discussão passa a tratar o aprendizado com oráculo ruidoso como cenário central, não excepcional. Uma divergência deve ser declarada aqui, na primeira menção do resultado afetado: o critério fixado de antemão, registrado na Seção 3.7.3, previa o ramo de falha (as consequências (i) e (ii), ambas executadas), mas definia o papel de LLM Inicial *sujeito* à acurácia mínima de 85% na S-rand, sem dizer como atribuí-lo se nenhum candidato a atingisse; a atribuição a seguir relaxa essa restrição e mantém o critério de melhor razão acurácia/custo, decisão desta tese registrada como tal. Registre-se também a regra de amostras das decisões: o limiar do gate e a equivalência do nemotron são medidos na S-rand, que preserva a distribuição de produção sob a qual o oráculo operará; a superioridade do LLM Avançado, cuja amostra o critério original não fixa, é medida na S-strat, que expõe as classes raras em que a Fase 3 deve agregar valor. Para a configuração de oráculos do FALCO derivada dessa avaliação: **LLM Inicial** = deepseek-v4-flash (melhor razão acurácia/custo: acurácia de 78,3% na S-rand, IC [75,6; 80,8], a US\$ 0,035/1k); **LLM Avançado** = deepseek-v4-pro (maior acurácia; significativamente superior ao flash na S-strat, $p < 0,001$: o critério de superioridade significativa é atendido e a Fase 3 do FALCO se justifica). O gpt-4o não se qualifica em nenhum papel: empata com o v4-pro em acurácia e custa o dobro; o gpt-4o-mini é eliminado ($p \approx 0$ contra todos na S-strat). O nemotron-3-ultra gratuito é a *alternativa de custo zero* para o papel de LLM Inicial, pois empata com o flash na S-rand ($p = 0,76$), condicionada a um provedor de *serving* com vazão e termos de produção; o flash permanece a escolha padrão pela confiabilidade operacional.

6 DISCUSSÃO E CONCLUSÃO

6.1 SÍNTESE DOS ACHADOS

Esta tese perguntou como reduzir o custo de rotulagem na classificação de textos curtos em português sem perda relevante de desempenho, usando modelos de linguagem nas fases em que o aprendizado ativo tradicional é mais frágil. Os quatro pilares produziram um quadro coerente:

A composição do conjunto inicial importa, e importa mais quanto menor o orçamento. A sensibilidade medida (47 tamanhos $\times$ 30 repetições, reproduzida de forma independente com divergência $\leq 0,7$ p.p.) mostra amplitude de 6,4 p.p. de acurácia em $|L_0| = 100$ causada só pelo sorteio, decaindo até a irrelevância em $|L_0| \geq 10^5$. O envelope evolutivo confirma dezenas de pontos percentuais entre composições boas e ruins no regime pequeno, que é o regime da partida a frio.

É possível capturar esse espaço sem nenhum rótulo. O DRI-SL, heurística determinística de densidade semântica + variedade lexical, superou o *melhor indivíduo* encontrado pelo algoritmo genético supervisionado em todos os tamanhos de 100 a 5.000, e a reexecução com protocolo anticircularidade mostrou que essa comparação é conservadora, pois o envelope do AG estava inflacionado em até 6,3 p.p. pela avaliação na própria partição de aptidão.

Oráculos LLM são viáveis, baratos e erram de forma estruturada. No espaço fechado de 621 categorias, os melhores oráculos *zero-shot* baseados em modelos de linguagem de grande porte (LLMs) atingem 77–83% de acurácia (v4-pro: 82,6% na S-strat), a ≈ 7 p.p. do teto supervisionado com 250 mil rótulos, a custos entre US\$ 0,035 e US\$ 0,92 por mil rótulos, ordens de grandeza abaixo da anotação humana (Gilardi et al., 2023). O Macro F1 zero-shot, medido na S-strat ($\approx 0,79$) nas 621 categorias desta amostra, supera o do baseline supervisionado leve com supervisão completa (0,70, no teste de distribuição natural e nas 795 categorias da hierarquia completa (Darú, 2024)); como a S-strat é balanceada por construção, o suporte por classe difere entre as duas medições. Como o Macro F1 é média por classe e o espaço de 795 rótulos é tarefa mais difícil que o de 621, no mesmo recorte de 621 o baseline subiria e a diferença encolheria: a margem aqui é um limite superior da vantagem do LLM. Com essa ressalva, o LLM é *melhor nas classes raras* e pior nas convenções do catálogo, pois quase metade dos seus erros são fronteiras entre categorias-irmãs e política de classes guarda-chuva, aprendíveis apenas com exemplos. O efeito do instrumento de medição (RQ4) confirmou-se: sem restrição de saída, 6,8% das respostas viram falsos erros de fraseado.

O framework integrado: respondido, com veredito refinado e diagnóstico. O gate de oráculo, fixado de antemão, decidiu: sem oráculo $\geq 85\%$, o aprendizado com oráculo ruidoso é o cenário central; a atribuição dos papéis manteve o critério de melhor razão acurácia/custo com a restrição de piso relaxada, divergência declarada onde o resultado é reportado (Seção 5.7),

e a configuração derivada do FALCO é deepseek-v4-flash (Inicial) + deepseek-v4-pro (Avançado, superioridade significativa comprovada). A validação com o classificador forte fora do laço julgou o pipeline completo, com três sementes e avaliação na população reservada inteira: na configuração executada a hipótese central *não* se atinge (acurácia de 0,705 contra critério de 0,843, com 11.936 rótulos, 5,2% da população), e a decomposição pareada atribui a perda ao *orçamento*: não ao ruído do oráculo, que em Macro F1 até ajuda as caudas (o braço com rótulos do oráculo supera o de gabarito nos mesmos itens, na média das sementes), nem à seleção, que compra Macro F1 e cobertura com consistência entre sementes, mas não acurácia. A parada por estagnação do classificador leve encerra o laço muito antes do ponto em que o BERTimbau para de converter rótulos em desempenho. A varredura de orçamento localiza a correção (achado *post hoc*, executado com rótulos de *gabarito*, não do oráculo da hipótese): o critério, na métrica pré-registrada, passa a ser atendido com 20 mil rótulos (8,6% da população), nas três sementes, dentro do teto de 34.724; em Macro F1, com 30 mil (13,0%), também nas três sementes e dentro do teto; e, na média das três sementes, 35 mil rótulos selecionados por entropia ficam à frente da supervisão completa do *pool* nas duas métricas, com heterogeneidade entre sementes declarada: a vantagem de cobertura do “menos é mais” medida em escala populacional reaparece no *transformer* como efeito de média. O veredito que os dados sustentam: **o critério é atingível dentro do teto da hipótese, com folga e robustez a sementes na métrica pré-registrada**; a configuração executada parou por estagnação aquém do piso, com orçamento e política identificados e medidos, restando a confirmação de ponta a ponta com rótulos de oráculo como trabalho futuro imediato.

6.2 DISCUSSÃO

O que muda quando o oráculo é um LLM. A literatura clássica de aprendizado ativo minimiza *contagem de rótulos* assumindo oráculo correto (Settles, 2012; Olsson, 2009); a com custos reais mostra que contagem não é custo (Settles et al., 2008). Com oráculo LLM, a moeda muda duas vezes: o custo vira função de tokens (e do *cache*, e do lote, os três medidos pela instrumentação desta tese) e a qualidade vira parâmetro escolhível num cardápio com uma ordem de grandeza de variação de preço. A decisão “qual oráculo em qual fase”, que é o coração do FALCO, só faz sentido nesse regime novo, e os dados da avaliação de oráculos mostram que ela não é trivial: o modelo mais caro (gpt-4o) não é o mais acurado, e o segundo mais barato entrega 95% da acurácia do melhor por 8,5% do custo.

Erro estruturado é menos grave que erro uniforme, e é o que temos. O perfil de erro do RQ3 (confusões concentradas em pares vizinhos e classes guarda-chuva) é o cenário benigno da literatura de rótulos ruidosos (Frénay e Verleysen, 2014; Natarajan et al., 2013; Song et al., 2023): parte do “erro” do oráculo é inclusive defensável semanticamente (a análise multi-gold mostrou que o gabarito também erra). Isso sugere que a avaliação de robustez com

ruído *uniforme*, o desenho adotado, é um teste *mais duro* que a realidade, o que fortalece qualquer resultado positivo obtido nele.

Mais rótulo não é sempre melhor, e a autoavaliação engana. A escala populacional acrescenta dois avisos operacionais ao quadro: treinar com o subconjunto ativamente selecionado pode superar o treino com *todos* os rótulos em métrica macro (a amostra ativa é mais balanceada que a distribuição natural), e a autoavaliação, isto é, a avaliação feita sobre os próprios dados coletados, é enviesada em direções opostas conforme a métrica: subestima a acurácia e superestima o Macro F1. Ambos reforçam o mesmo princípio de desenho do FALCO: parar cedo pelo critério de estagnação e medir sempre em conjunto reservado.

A medição é parte do método. Três achados desta tese são sobre instrumentos, não sobre modelos: o efeito do enum (RQ4), a inflação de circularidade no envelope evolutivo ($-6,3$ p.p. ao reavaliar em teste intocado) e o teto imposto pelo ruído do gabarito (limitado a $+0,7$ p.p. nas comparações). Em conjunto, eles justificam a posição metodológica central do trabalho: nenhum número sem artefato rastreável, e nenhum instrumento sem quantificação do seu próprio erro.

6.3 CONTRIBUIÇÕES

(i) O framework FALCO, com fases de oráculo LLM progressivo e partida a frio informada, em implementação aberta, testada e reproduzível; (ii) o algoritmo DRI-SL, com a evidência de que supera o envelope evolutivo supervisionado no regime de interesse, acompanhado da análise honesta do seu limite: no regime contínuo, a ablação da variante guiada pelo classificador (DRI-SL-C) mostrou que o ganho vem do agrupamento pelas classes previstas, não da novidade lexical, apontando a estratificação por predição como política representativa de referência; (iii) a avaliação instrumentada de oráculos LLM para português com 621 classes, granularidade muito acima da usual na literatura de LLM-como-anotador, cujos estudos zero-shot recentes de classificação de produtos operam com dezenas a ≈ 250 categorias (Roumeliotis et al., 2025), chegando a 370 folhas nos testes de robustez com catálogos públicos (Gholamian et al., 2024), incluindo custo real com *cache* e lote; (iv) a métrica LCE (*Learning Curve Efficiency*), com posicionamento explícito frente à ALC (*Area under the Learning Curve*); (v) o conjunto de dados público auditado, com censo de conflitos e análise de sensibilidade; e (vi) a biblioteca *activelearning* e o FlowBuilder (ingestão com saneamento, execução parametrizada e curvas), que tornam o protocolo reutilizável fora desta tese.

6.4 LIMITAÇÕES

As ameaças à validade estão detalhadas na Seção 3.9; as principais: um único conjunto de dados, criado pelo autor (mitigado por protocolo replicável e achados de mecanismo); a validação com o classificador forte executada em configuração uniforme mas econômica (3 épocas, contexto de 32 *tokens*, semente única, CPU), pois a régua absoluta do BERTimbau

pode subir com mais épocas e contexto, o que tornaria o critério *mais* exigente, não menos, preservando o sentido do veredito; custos de API datados (as *razões* entre modelos são mais estáveis que os valores); e regras de fronteira derivadas do perfil de erro do próprio domínio, que generalizam o método, não as regras.

6.5 TRABALHOS FUTUROS

A extensão prioritária, já parcialmente executada na varredura de orçamento (Seção 5.6.1), é consolidar a política de parada ancorada no modelo forte: substituir a estagnação do classificador leve por ajustes finos periódicos do BERTimbau em pontos de verificação da trajetória, ou por um piso de orçamento no ponto medido de cruzamento do critério (Seção 5.6.1), e formalizar a regra de liberação daí decorrente. Demais direções: (i) composição de oráculos, comparando a progressão sequencial do FALCO com *mixture-of-LLMs* paralelo (Qi et al., 2026) e com roteamento por confiança (Rouzegar e Makrehchi, 2024), idealmente formulando a escolha de oráculo por fase como problema de *bandit* com custo (Blum e Mansour, 2007; Baykal et al., 2021); (ii) *prompt* como componente otimizável, para o que a ablação de *prompt* abre a porta; as extensões naturais são gerar regras de fronteira automaticamente a partir da matriz de confusão de uma rodada anterior e permitir que o oráculo emita *rótulos candidatos* quando incerto, destilados pelo classificador leve (Xia et al., 2025a), o que também endereça os 2–4% de respostas inválidas observadas; a contração prévia do espaço de classes por top- K do classificador de domínio (Cheng et al., 2024) é o desenho complementar para as 621 categorias; (iii) usar os racionais do oráculo (`expanded_description`) como atributo auxiliar do classificador (Sharma et al., 2015); (iv) réplica em benchmark público de produtos (STOPS, Karl e Scherp, 2023; e AlleNoise, 500 mil títulos em 5.692 categorias com ruído *real* de marketplace, Rączkowska et al., 2025, o teste externo ideal para a avaliação de robustez) e extensão a taxonomias hierárquicas (Sun et al., 2003; Tan et al., 2020); e (v) o ciclo de vida pós-treinamento: o critério de parada do laço (estagnação em validação) já está implementado e formalizado, mas a decisão de *liberação* do modelo e o monitoramento de *drift* em produção merecem tratamento próprio: o oráculo barato da Fase 1 (o LLM Inicial) vira instrumento de auditoria contínua (verificação amostral periódica a custo desprezível), e sinais sem rótulo (taxa de vocabulário novo, deriva da confiança predita) antecipam o gatilho de retreino, com desenho detalhado na documentação operacional da biblioteca.

6.6 CONCLUSÃO

No estado atual da evidência: o custo de rotulagem em classificação de textos curtos em português pode ser atacado nas três frentes que o FALCO integra: começar bem (DRI-SL supera até o envelope evolutivo), perguntar bem (estratégias de incerteza sobre classificador barato) e pagar bem (oráculos LLM com 77–83% de acurácia por centavos de dólar o milhar, com erro majoritariamente estruturado). A hipótese quantitativa central ($\geq 95\%$ da acurácia da

supervisão completa do *pool* de referência, a métrica do pré-registro, com no máximo 34.724 rótulos, 15% da população deduplicada) foi submetida ao teste com três sementes e avaliação na população reservada: **o critério é atingível dentro do teto** (cruzamento em 20 mil rótulos, 8,6% da população, nas três sementes, em varredura *post hoc* com rótulos de gabarito), **enquanto a configuração executada parou por estagnação aquém do piso** (11.936 rótulos, 5,2%), com o diagnóstico identificando a causa: não o ruído do oráculo nem a seleção, e sim o critério de parada herdado do classificador leve, que subestima o apetite do classificador forte. Em Macro F1, a análise de robustez, o critério é atingido com 30 mil rótulos, nas três sementes, dentro do teto; e, na média das sementes, 35 mil rótulos ativamente selecionados ficam à frente da supervisão completa do *pool* nas duas métricas, com heterogeneidade declarada: para o desempenho final, a fração restante dos rótulos do *pool* não compra nada em média. Uma tese que termina com um número honesto, uma causa identificada e o piso corrigido medido vale mais que uma que termina com uma promessa: os resultados dos experimentos executados, com as reexecuções dos dois primeiros pilares, delimitam com precisão as condições em que a hipótese se sustenta.

REFERÊNCIAS

- Abe, N. e Mamitsuka, H. (1998). Query learning strategies using boosting and bagging. Em Shavlik, J. W., editor, *Proceedings of the Fifteenth International Conference on Machine Learning (ICML '98)*, páginas 1–9. Morgan Kaufmann.
- Aggarwal, C. C. e Zhai, C. (2012). A survey of text classification algorithms. Em Aggarwal, C. C. e Zhai, C., editores, *Mining Text Data*, páginas 163–222. Springer.
- Ahmed, M. H., Tiun, S., Omar, N. e Sani, N. S. (2023). Short text clustering algorithms, application and challenges: A survey. *Applied Sciences*, 13(1):342.
- Aliero, A. A., Adebayo, B. S., Aliyu, H. O., Tafida, A. G., Kangiwa, B. U. e Dankolo, N. M. (2023). Systematic review on text normalization techniques and its approach to non-standard words. *International Journal of Computer Applications*, 185(33):44–55.
- Alsmadi, I. e Gan, K. H. (2019). Review of short-text classification. *International Journal of Web Information Systems*, 15(2):155–182.
- Angluin, D. (1988). Queries and concept learning. Em *Machine Learning*, volume 2, páginas 319–342.
- Attenberg, J. e Provost, F. (2010). Why label when you can search?: Alternatives to active learning for applying human resources to build classification models under extreme class imbalance. Em *Proceedings of the 16th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, páginas 423–432.
- Baeza-Yates, R. e Ribeiro-Neto, B. (2013). *Recuperação de Informação: conceitos e tecnologia das máquinas de busca*. Bookman Editora, Porto Alegre, 2 edition.
- Barros, R. C., Garcia, L. e Cavalcanti, G. (2014). Aprendizado supervisionado com conjuntos de dados desbalanceados. *Revista de Sistemas de Informação da FSMA*, 13:4–19.
- Baum, E. B. e Lang, K. (1992). Query learning can work poorly when a human oracle is used. Em *Proceedings of the IEEE International Joint Conference on Neural Networks*, páginas 1386–1391.
- Bayer, M., Lutz, J. e Reuter, C. (2026). ActiveLLM: Large language model-based active learning for textual few-shot scenarios. *Transactions of the Association for Computational Linguistics*, 14:1–22.
- Baykal, C., Liebenwein, L., Feldman, D. e Rus, D. (2021). Low-regret active learning.

- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer, New York, NY.
- Blum, A. e Mansour, Y. (2007). Learning, regret minimization, and equilibria. Em Nisan, N., Roughgarden, T., Tardos, É. e Vazirani, V. V., editores, *Algorithmic Game Theory*. Cambridge University Press.
- Blum, A. e Mitchell, T. (1998). Combining labeled and unlabeled data with co-training. Em *Proceedings of the Eleventh Annual Conference on Computational Learning Theory (COLT '98)*, páginas 92–100. ACM.
- Bojanowski, P., Grave, E., Joulin, A. e Mikolov, T. (2017). Enriching word vectors with subword information. *Transactions of the Association for Computational Linguistics*, 5:135–146.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.
- Brown, L. D., Cai, T. T. e DasGupta, A. (2001). Interval estimation for a binomial proportion. *Statistical Science*, 16(2):101–133.
- Chapelle, O., Schölkopf, B. e Zien, A., editores (2006). *Semi-Supervised Learning*. The MIT Press, Cambridge, MA.
- Cheng, Z., Zhang, W., Chou, C.-C., Jau, Y.-Y., Pathak, A., Gao, P. e Batur, U. (2024). E-commerce product categorization with LLM-based dual-expert classification paradigm. Em *Proceedings of the 1st Workshop on Customizable NLP (CustomNLP4U), EMNLP 2024*.
- Cohn, D., Atlas, L. e Ladner, R. (1994). Improving generalization with active learning. *Machine learning*, 15(2):201–221.
- Cohn, D. A., Ghahramani, Z. e Jordan, M. I. (1996). Active learning with statistical models. *Journal of Artificial Intelligence Research*, 4:129–145.
- Cortes, C. e Vapnik, V. N. (1995). Support-vector networks. *Machine Learning*, 20(3):273–297.
- Cover, T. e Hart, P. (1967). Nearest neighbor pattern classification. *IEEE transactions on information theory*, 13(1):21–27.
- Dagan, I. e Engelson, S. (1995). Committee-based sampling for training probabilistic classifiers. Em *12th International Conference on Machine Learning*, páginas 150–157.
- Darú, G. H. (2022). Classificação produtos varejo CPG PTBR. Conjunto de dados. Disponível em: <https://www.kaggle.com/datasets/gilsileydaru/classificacao-produtos-varejo-cpg-prbr>.
- Darú, G. H. (2024). Categorização de produtos em e-commerce: avaliação do método argmax para classificação de descrições curtas em português. Dissertação de Mestrado, Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos.

- Darú, G. H., Motta, F. D. d., Castelo, A. e Loch, G. V. (2022). Short text classification applied to item description: Some methods evaluation. *Semina: Ciências Exatas e Tecnológicas*, 43(2):189–198.
- Dasgupta, S. e Hsu, D. (2008). Hierarchical sampling for active learning. Em *Proceedings of the 25th International Conference on Machine Learning (ICML '08)*, páginas 208–215. ACM.
- Demšar, J. (2006). Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, 7:1–30.
- Deng, Z., Yang, Y. e Suzuki, K. (2025). Federated active learning framework for efficient annotation strategy in skin-lesion classification. *Journal of Investigative Dermatology*, 145(2):303–311.
- Devlin, J., Chang, M.-W., Lee, K. e Toutanova, K. (2019). Bert: Pre-training of deep bidirectional transformers for language understanding. Em *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, volume 1, páginas 4171–4186.
- Diao, S., Wang, P., Lin, Y., Pan, R., Liu, X. e Zhang, T. (2024). Active prompting with chain-of-thought for large language models. Em *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, páginas 1330–1350, Bangkok, Thailand. Association for Computational Linguistics.
- Dietterich, T. G. (1998). Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation*, 10(7):1895–1923.
- Dietterich, T. G. (2000). Ensemble methods in machine learning. *Multiple Classifier Systems*, 1857:1–15.
- Donmez, P., Carbonell, J. G. e Schneider, J. (2009). Efficiently learning the accuracy of labeling sources for selective sampling. Em *Proceedings of the 15th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, páginas 259–268. ACM.
- Duda, R. O., Hart, P. E. e Stork, D. G. (2001). *Pattern Classification*. Wiley-Interscience, New York, NY, 2nd edition.
- Efron, B. e Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall/CRC.
- Ein-Dor, L., Halfon, A., Gera, A., Shnarch, E., Dankin, L., Choshen, L., Danilevsky, M., Aharonov, R., Katz, Y. e Slonim, N. (2020). Active learning for bert: An empirical study. Em *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, páginas 7949–7962.

- Farquhar, S., Gal, Y. e Rainforth, T. (2021). On statistical bias in active learning: How and when to fix it. Em *International Conference on Learning Representations (ICLR)*.
- Forman, G. e Scholz, M. (2010). Apples-to-apples in cross-validation studies: pitfalls in classifier performance measurement. *ACM SIGKDD explorations newsletter*, 12(1):49–57.
- Frénay, B. e Verleysen, M. (2014). Classification in the presence of label noise: A survey. *IEEE Transactions on Neural Networks and Learning Systems*, 25(5):845–869.
- Freund, Y., Seung, H. S., Shamir, E. e Tishby, N. (1997). Selective sampling using the query by committee algorithm. *Machine Learning*, 28(2-3):133–168.
- Gal, Y., Islam, R. e Ghahramani, Z. (2017). Deep bayesian active learning with image data. Em Precup, D. e Teh, Y. W., editores, *Proceedings of the 34th International Conference on Machine Learning (ICML)*, volume 70 de *Proceedings of Machine Learning Research*, páginas 1183–1192. PMLR.
- Gholamian, S., Romani, G., Rudnikowicz, B. e Skylaki, S. (2024). LLM-based robust product classification in commerce and compliance. Em *Proceedings of the 1st Workshop on Customizable NLP (CustomNLP4U), EMNLP 2024*, páginas 26–36.
- Gilardi, F., Alizadeh, M. e Kubli, M. (2023). Chatgpt outperforms crowd workers for text-annotation tasks. *Proceedings of the National Academy of Sciences*, 120(30):e2305016120.
- Goldberg, D. E. (1989). *Genetic Algorithms in Search, Optimization, and Machine Learning*. Addison-Wesley.
- Goldberg, Y. (2017). *Neural Network Methods for Natural Language Processing*. Synthesis Lectures on Human Language Technologies. Morgan & Claypool.
- Golovin, D. e Krause, A. (2011). Adaptive submodularity: Theory and applications in active learning and stochastic optimization. *Journal of Artificial Intelligence Research*, 42:427–486.
- Goodfellow, I., Bengio, Y. e Courville, A. (2016). *Deep Learning*. The MIT Press, Cambridge, MA.
- Goudjil, M., Koudil, M., Bedda, M. e Ghoggali, N. (2018). A novel active learning method using SVM for text classification. *International Journal of Automation and Computing*, 15(3):290–298.
- Grandini, M., Bagli, E. e Visani, G. (2020). Metrics for multi-class classification: an overview. *arXiv preprint arXiv:2008.05756*.
- Grießhaber, D., Maucher, J. e Vu, N. T. (2020). Fine-tuning bert for low-resource natural language understanding via active learning. Em *COLING 2020*, páginas 1158–1171.

- Guestrin, C., Krause, A. e Singh, A. P. (2005). Near-optimal sensor placements in gaussian processes. Em *Proceedings of the 22nd International Conference on Machine Learning (ICML '05)*, páginas 265–272. ACM.
- Guo, J., Chen, C. L. P., Li, S. e Zhang, T. (2024). DEUCE: Dual-diversity enhancement and uncertainty-awareness for cold-start active learning. *Transactions of the Association for Computational Linguistics*, 12:1736–1754.
- Guyon, I., Cawley, G., Dror, G. e Lemaire, V. (2011). Results of the active learning challenge. Em *Proceedings of the Active Learning and Experimental Design Workshop (in conjunction with AISTATS 2010)*, volume 16, páginas 19–45.
- Hacohen, G., Dekel, A. e Weinshall, D. (2022). Active learning on a budget: Opposite strategies suit high and low budgets. Em *Proceedings of the 39th International Conference on Machine Learning*, volume 162 de *Proceedings of Machine Learning Research*, páginas 8175–8195.
- Han, J., Kamber, M. e Pei, J. (2012). *Data Mining: Concepts and Techniques*. Morgan Kaufmann Publishers Inc., San Francisco, CA, USA, 3rd edition.
- Hanneke, S. (2014). Theory of disagreement-based active learning. *Foundations and Trends in Machine Learning*, 7(2–3):131–309.
- Hoi, S. C. H., Jin, R. e Lyu, M. R. (2006). Large-scale text categorization by batch mode active learning. Em *15th International Conference on World Wide Web*, páginas 633–642.
- Holland, J. H. (1975). *Adaptation in Natural and Artificial Systems*. University of Michigan Press.
- James, G., Witten, D., Hastie, T. e Tibshirani, R. (2013). *An introduction to statistical learning*, volume 112. Springer.
- Karl, F. e Scherp, A. (2023). Transformers are short-text classifiers: A study of inductive short text classifiers on benchmarks and real-world datasets. *Lecture Notes in Computer Science*, 14065:103–122.
- Kholodna, N., Julka, S., Khodadadi, M., Gumus, M. N. e Granitzer, M. (2024). LLMs in the loop: Leveraging large language model annotations for active learning in low-resource languages.
- Kitchenham, B. (2004). Procedures for performing systematic reviews. Relatório Técnico TR/SE-0401, Keele University and NICTA, Keele, UK.
- Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. Em *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI)*, volume 2, páginas 1137–1143.

- Kossen, J., Farquhar, S., Gal, Y. e Rainforth, T. (2021). Active testing: Sample-efficient model evaluation. Em *Proceedings of the 38th International Conference on Machine Learning (ICML)*, volume 139 de *Proceedings of Machine Learning Research*, páginas 5753–5763. PMLR.
- Kowsari, K., Jafari Meimandi, K., Heidarysafa, M., Mendu, S., Barnes, L. e Brown, D. (2019). Text classification algorithms: A survey. *Information*, 10(4):150.
- Krause, A. e Golovin, D. (2014). Submodular function maximization. Em Nowozin, S., Poupard, P., Kohli, P. e Tu, Z., editores, *Tracts in Machine Learning*, volume 5. Cambridge University Press. Chapter in "Modern Convex Optimization and Its Applications".
- Lewis, D. D. e Catlett, J. (1994). Heterogeneous uncertainty sampling for supervised learning. Em Cohen, W. W. e Hirsh, H., editores, *Machine Learning: Proceedings of the Eleventh International Conference (ICML 1994)*, páginas 148–156. Morgan Kaufmann.
- Lewis, D. D. e Gale, W. A. (1994). A sequential algorithm for training text classifiers. *Proceedings of the 17th ACM SIGIR Conference*, páginas 3–12.
- Li, Q., Peng, H., Li, J., Xia, C., Yang, R., Sun, L., Yu, P. S. e He, L. (2020). A survey on text classification: From shallow to deep learning. *arXiv preprint arXiv:2008.00364*.
- Loshchilov, I. e Hutter, F. (2019). Decoupled weight decay regularization. Em *International Conference on Learning Representations (ICLR)*.
- Machado, J. d. F. U. e Veloso, B. (2026). Turning web data into official statistics: Classifying Portuguese retail products with NLP models. *Statistical Journal of the IAOS*, 42(1).
- MacKay, D. J. C. (1992). Information-based objective functions for active data selection. *Neural Computation*, 4(4):590–604.
- Margatina, K., Schick, T., Aletras, N. e Dwivedi-Yu, J. (2023). Active learning principles for in-context learning with large language models. Em *Findings of the Association for Computational Linguistics: EMNLP 2023*, páginas 5011–5034, Singapore. Association for Computational Linguistics.
- McCallum, A. K. e Nigam, K. (1998). Employing em in pool-based active learning for text classification. Em Shavlik, J. W., editor, *Proceedings of the Fifteenth International Conference on Machine Learning (ICML '98)*, páginas 350–358. Morgan Kaufmann.
- McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2):153–157.
- Melville, P. e Mooney, R. J. (2004). Diverse ensembles for active learning. Em *Proceedings of the 21st International Conference on Machine learning (ICML '04)*, página 74. ACM.

- Merdjanovska, E., Aynetdinov, A. e Akbik, A. (2024). NoiseBench: Benchmarking the impact of real label noise on named entity recognition. Em *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, páginas 18182–18198.
- Mikolov, T., Chen, K., Corrado, G. e Dean, J. (2013). Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781*.
- Mitchell, T. M. (1982). Generalization as search. *Artificial Intelligence*, 18(2):203–226.
- Mitchell, T. M. (1997). *Machine Learning*. McGraw Hill, Burr Ridge, IL.
- Murphy, K. P. (2012). *Machine Learning: A Probabilistic Perspective*. The MIT Press, Cambridge, MA.
- Muslea, I., Minton, S. e Knoblock, C. A. (2000). Selective sampling with redundant views. Em *Proceedings of the Seventeenth National Conference on Artificial Intelligence (AAAI'00)*, páginas 621–626.
- Naseem, U., Razzak, I. e Eklund, P. W. (2021a). A survey of pre-processing techniques to improve short-text quality: a case study on hate speech detection on Twitter. *Multimedia Tools and Applications*, 80(28-29):35239–35266.
- Naseem, U., Razzak, I., Khan, S. K. e Prasad, M. (2021b). A comprehensive survey on word representation models: From classical to state-of-the-art word representation language models. *ACM Transactions on Asian and Low-Resource Language Information Processing*, 20(5):1–35.
- Natarajan, N., Dhillon, I. S., Ravikumar, P. e Tewari, A. (2013). Learning with noisy labels. Em *Advances in Neural Information Processing Systems 26 (NIPS)*, páginas 1196–1204.
- Nguyen, H. T. e Smeulders, A. W. M. (2004). Active learning using pre-clustering. Em *Proceedings of the 21st International Conference on Machine learning (ICML '04)*, página 79. ACM.
- Nti, I. K., Nyarko-Boateng, O. e Aning, J. (2021). Performance of Machine Learning Algorithms with Different K Values in K-fold Cross-Validation. *International Journal of Information Technology and Computer Science*, 13(6):61–71.
- Olsson, F. (2009). A literature survey of active machine learning in the context of natural language processing. Relatório Técnico T2009:06, Swedish Institute of Computer Science, Kista.
- Pangakis, N., Wolken, S. e Fasching, N. (2023). Automated annotation with generative AI requires validation. *arXiv preprint arXiv:2306.00176*.
- Pennington, J., Socher, R. e Manning, C. D. (2014). GloVe: Global vectors for word representation. Em *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, páginas 1532–1543.

- Peters, M. E., Neumann, M., Iyyer, M., Gardner, M., Clark, C., Lee, K. e Zettlemoyer, L. (2018). Deep contextualized word representations. Em *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, páginas 2227–2237.
- Prechelt, L. (2012). Early stopping – but when? Em Montavon, G., Orr, G. B. e Müller, K.-R., editores, *Neural Networks: Tricks of the Trade*, volume 7700 de *Lecture Notes in Computer Science*, páginas 53–67. Springer, second edition.
- Qi, Y., Yang, X., Lu, J., Guo, G., Enticott, J., Liu, G. e Du, L. (2026). Next generation active learning: Mixture of LLMs in the loop.
- Quinlan, J. R. (1993). *C4.5: Programs for Machine Learning*. Morgan Kaufmann Publishers Inc., San Francisco, CA, USA.
- Rączkowska, A., Osowska-Kurczab, A., Szczerbiński, J., Jasinska-Kobus, K. e Nazarko, K. (2025). AlleNoise: large-scale text classification benchmark dataset with real-world label noise.
- Radford, A., Narasimhan, K., Salimans, T. e Sutskever, I. (2018). Improving language understanding by generative pre-training. Relatório técnico, OpenAI.
- Radford, A., Wu, J., Child, R., Luan, D., Amodei, D. e Sutskever, I. (2019). Language models are unsupervised multitask learners. *OpenAI blog*, 1(8):9.
- Reimers, N. e Gurevych, I. (2019). Sentence-BERT: sentence embeddings using Siamese BERT-networks. Em *Proceedings of EMNLP-IJCNLP*, páginas 3982–3992.
- Ren, P., Xiao, Y., Chang, X., Huang, P.-Y., Li, Z., Gupta, B. B., Chen, X. e Wang, X. (2021). A survey of deep active learning. *ACM Computing Surveys*, 54(9):1–40.
- Reusens, M., Stevens, A., Tonglet, J., De Smedt, J., Verbeke, W., vanden Broucke, S. e Baesens, B. (2024). Evaluating text classification: A benchmark study. *Expert Systems with Applications*, 254:124302.
- Rifkin, R. e Klautau, A. (2004). In defense of one-vs-all classification. *Journal of Machine Learning Research*, 5:101–141.
- Riyanto, S., Sitanggang, I. S., Djatna, T. e Atikah, T. D. (2023). Comparative Analysis using Various Performance Metrics in Imbalanced Data for Multi-class Text Classification. (*IJACSA*) *International Journal of Advanced Computer Science and Applications*, 14(6):1082–1090.
- Romberg, J., Schröder, C., Gonsior, J., Tomanek, K. e Olsson, F. (2026). Reassessing active learning adoption in contemporary NLP: A community survey.

- Roumeliotis, K. I., Tselikas, N. D. e Nasiopoulos, D. K. (2025). LLMs for product classification in e-commerce: A zero-shot comparative study of GPT and Claude models. *Natural Language Processing Journal*, 11:100142.
- Rouzegar, H. (2024). LLM-powered active learning for cost-effective text classification. Master of applied science (masc) thesis, Ontario Tech University, Oshawa, Canada. Expande Rouzegar e Makrehchi (2024, arXiv:2406.12114).
- Rouzegar, H. e Makrehchi, M. (2024). Enhancing text classification through llm-driven active learning and human annotation.
- Roy, N. e McCallum, A. (2001). Toward optimal active learning through sampling estimation of error reduction. Em *Proceedings of the 18th International Conference on Machine Learning*, páginas 441–448.
- Russell, S. J. e Norvig, P. (2010). *Artificial Intelligence: A Modern Approach*. Prentice Hall, Upper Saddle River, NJ, 3rd edition.
- Salton, G. e Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information processing & management*, 24(5):513–523.
- Santos, D. P. d. (2016). *Seleção e controle do viés de aprendizado ativo*. Tese de doutorado, Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos.
- Schick, T., Dwivedi-Yu, J., Dessì, R., Raileanu, R., Lomeli, M., Zettlemoyer, L., Cancedda, N. e Scialom, T. (2023). Toolformer: Language models can teach themselves to use tools. arXiv preprint arXiv:2302.04761.
- Schröder, C., Müller, L., Niekler, A. e Potthast, M. (2023). Small-text: Active learning for text classification in python.
- Schröder, C., Niekler, A. e Potthast, M. (2022). Revisiting uncertainty-based query strategies for active learning with transformers. Em *Findings of the Association for Computational Linguistics: ACL 2022*, páginas 2194–2203, Dublin, Ireland. Association for Computational Linguistics.
- Selva Birunda, S. e Kanniga Devi, R. (2021). A review on word embedding techniques for text classification. Em *Innovative Data Communication Technologies and Application: Proceedings of ICIDCA 2020*, páginas 267–281. Springer.
- Sener, O. e Savarese, S. (2018). Active learning for convolutional neural networks: A core-set approach. Em *International Conference on Learning Representations*.
- Settles, B. (2009). Active learning literature survey. Computer Sciences Technical Report 1648, University of Wisconsin-Madison.

- Settles, B. (2012). *Active Learning*. Synthesis Lectures on Artificial Intelligence and Machine Learning. Morgan & Claypool.
- Settles, B. e Craven, M. (2008). An analysis of active learning strategies for sequence labeling tasks. Em *Proceedings of the 2008 Conference on Empirical Methods in Natural Language Processing (EMNLP '08)*, páginas 1070–1079. Association for Computational Linguistics.
- Settles, B., Craven, M. e Friedland, L. (2008). Active learning with real annotation costs. Em *Proceedings of the NIPS Workshop on Cost-Sensitive Learning*.
- Seung, H. S., Opper, M. e Sompolinsky, H. (1992). Query by committee. Em *Proceedings of the Fifth Annual Workshop on Computational Learning Theory (COLT '92)*, páginas 287–294. ACM.
- Shannon, C. E. (1948). A mathematical theory of communication. *The Bell System Technical Journal*, 27(3):379–423.
- Sharma, M., Zhuang, D. e Bilgic, M. (2015). Active learning with rationales for text classification. Em *Proceedings of NAACL-HLT 2015*, páginas 441–451.
- Sheng, V. S., Provost, F. e Ipeirotis, P. G. (2008). Get another label? Improving data quality and data mining using multiple, noisy labelers. Em *Proceedings of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, páginas 614–622. ACM.
- Snow, R., O'Connor, B., Jurafsky, D. e Ng, A. Y. (2008). Cheap and fast – but is it good? Evaluating non-expert annotations for natural language tasks. Em *Proceedings of the 2008 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, páginas 254–263, Honolulu, Hawaii. Association for Computational Linguistics.
- Sokolova, M. e Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4):427–437.
- Song, G., Ye, Y., Du, X., Huang, X. e Bie, S. (2014). Short text classification: A survey. *Journal of Multimedia*, 9(5):635–643.
- Song, H., Kim, M., Park, D., Shin, Y. e Lee, J.-G. (2023). Learning from noisy labels with deep neural networks: A survey. *IEEE Transactions on Neural Networks and Learning Systems*, 34(11):8135–8153.
- Souza, F., Nogueira, R. e Lotufo, R. (2020). BERTimbau: pretrained BERT models for Brazilian Portuguese. Em *Brazilian Conference on Intelligent Systems (BRACIS)*, páginas 403–417. Springer.

- Sun, A., Lim, E.-P. e Ng, W.-K. (2003). Performance measurement framework for hierarchical text classification. *Journal of the American Society for Information Science and Technology*, 54(11):1014–1028.
- Tan, L., Li, M. Y. e Kok, S. (2020). E-commerce product categorization via machine translation. *ACM Transactions on Management Information Systems*, 11(3):1–14.
- Tian, K., Mitchell, E., Zhou, A., Sharma, A., Rafailov, R., Yao, H., Finn, C. e Manning, C. (2023). Just ask for calibration: Strategies for eliciting calibrated confidence scores from language models fine-tuned with human feedback. Em *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, páginas 5433–5442, Singapore. Association for Computational Linguistics.
- Tong, S. e Koller, D. (2000). Support vector machine active learning with applications to text classification. Em Langley, P., editor, *Proceedings of the Seventeenth International Conference on Machine Learning (ICML 2000)*, páginas 999–1006. Morgan Kaufmann.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L. e Polosukhin, I. (2017). Attention is all you need. Em *Advances in Neural Information Processing Systems*, volume 30, páginas 5998–6008.
- Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E. H., Le, Q. V. e Zhou, D. (2022). Chain-of-thought prompting elicits reasoning in large language models. Em *Advances in Neural Information Processing Systems*, volume 35, páginas 24824–24837.
- Wertz, L., Mirylenka, K., Kuhn, J. e Bogojeska, J. (2022). Investigating active learning sampling strategies for extreme multi label text classification. Em *Proceedings of the Thirteenth Language Resources and Evaluation Conference*, páginas 4597–4605, Marseille, France. European Language Resources Association.
- Widodo, S., Brawijaya, H. e Samudi (2022). Stratified K-fold cross validation optimization on machine learning for prediction. *Sinkron : Jurnal dan Penelitian Teknik Informatika*, 7(4):2407–2414.
- Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83.
- Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158):209–212.
- Wolf, T. et al. (2020). Transformers: state-of-the-art natural language processing. Em *Proceedings of EMNLP: System Demonstrations*, páginas 38–45.

- Xia, M., Wang, H., Li, Y., Yu, Z., Wang, J., Zhao, J. e Wu, R. (2025a). Prompt candidates, then distill: A teacher-student framework for LLM-driven data annotation. Em *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (ACL)*, páginas 2750–2770.
- Xia, Y., Mukherjee, S., Xie, Z. et al. (2025b). From selection to generation: A survey of LLM-based active learning. Em *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, páginas 14552–14569, Vienna, Austria. Association for Computational Linguistics.
- Xiao, R., Dong, Y., Zhao, J., Wu, R., Lin, M., Chen, G. e Wang, H. (2023). FreeAL: Towards human-free active learning in the era of large language models. Em *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, páginas 14520–14535, Singapore. Association for Computational Linguistics.
- Xu, J., Xu, B., Wang, P., Zheng, S., Tian, G., Zhao, J. e Xu, B. (2017). Self-taught convolutional neural networks for short text clustering. *Neural Networks*, 88:22–31.
- Yan, Y., Rosales, R., Fung, G. e Dy, J. (2011). Active learning from crowds. Em *28th International Conference on Machine Learning*, páginas 1161–1168.
- Yu, Y., Zhang, R., Xu, R., Zhang, J., Shen, J. e Zhang, C. (2023). Cold-start data selection for better few-shot language model fine-tuning: A prompt-based uncertainty propagation approach. Em *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, páginas 2499–2521, Toronto, Canada. Association for Computational Linguistics.
- Yuan, B., Chen, Y., Zhang, Y. e Jiang, W. (2024). Hide and seek in noise labels: Noise-robust collaborative active learning with LLM-powered assistance. arXiv:2504.02901.
- Yuan, M., Lin, H.-T. e Boyd-Graber, J. (2020). Cold-start active learning through self-supervised language modeling. Em *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, páginas 7935–7948, Online. Association for Computational Linguistics.
- Zhang, R., Li, Y., Ma, Y., Zhou, M. e Zou, L. (2023). LLMaAA: Making large language models as active annotators. Em *Findings of the Association for Computational Linguistics: EMNLP 2023*, páginas 13088–13103, Singapore. Association for Computational Linguistics.
- Zhang, Y. e Takada, S. (2025). Applying LLMs to active learning: Toward cost-efficient cross-task text classification without manually labeled data. *International Journal of Intelligent Systems*, 2025(1):6472544.

- Zhang, Z., Strubell, E. e Hovy, E. (2022). A survey of active learning for natural language processing. Em Goldberg, Y., Kozareva, Z. e Zhang, Y., editores, *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, páginas 6166–6190, Abu Dhabi, United Arab Emirates. Association for Computational Linguistics.
- Zhu, X. e Goldberg, A. B. (2009). *Introduction to Semi-Supervised Learning*, volume 3 de *Synthesis Lectures on Artificial Intelligence and Machine Learning*. Morgan & Claypool.

APÊNDICE A – MÉTRICA LEARNING CURVE EFFICIENCY (LCE)

A.1 DEFINIÇÃO

Seja uma execução de aprendizado ativo que produz a curva $\{(n_k, m_k)\}_{k=1}^K$, em que n_k é o número de instâncias rotuladas na iteração k (estritamente crescente) e m_k a métrica de interesse (nesta tese, Macro F1 no conjunto de teste fixo T). Define-se:

$$\text{LCE} = \frac{\int_{n_1}^{n_K} m(n) dn}{\text{Perf}_{\text{baseline}} \cdot (n_K - n_1)}, \quad (\text{A.1})$$

em que a integral do numerador (AUC_{real}) é calculada numericamente pela regra composta de Simpson sobre os pontos observados (com recuo para a regra do trapézio quando $K = 2$) e $\text{Perf}_{\text{baseline}}$ é o desempenho do MESMO classificador treinado com supervisão completa do pool. O denominador é a área da curva ideal: desempenho de referência atingido instantaneamente no início do processo ($L_{\text{ideal},0} = n_1$).

A.2 PROPRIEDADES

(i) $\text{LCE} \in (0, 1]$ quando $m_k \leq \text{Perf}_{\text{baseline}}$ para todo k ; valores maiores indicam aproximação mais rápida do teto. (ii) É invariante a transformações afins do eixo n (mudança de unidade de orçamento). (iii) Ao normalizar pelo teto do próprio par (classificador, conjunto), e não pelo máximo teórico da métrica, permite comparar estratégias entre classificadores de tetos distintos: um classificador fraco bem servido pela estratégia pode ter LCE maior que um classificador forte mal servido. (iv) Depende do intervalo $[n_1, n_K]$: comparações exigem execuções com o mesmo orçamento e o mesmo L_0 , condição imposta em todos os desenhos desta tese.

A.3 RELAÇÃO COM A ALC

A *Area under the Learning Curve* do *Active Learning Challenge* (Guyon et al., 2011) também sumariza a curva por área normalizada. As diferenças da LCE: normalização pelo baseline de supervisão completa do próprio par (a ALC normaliza pelo máximo global da métrica) e integração de Simpson na grade observada (a ALC interpola em escala logarítmica de consultas). A implementação de referência está em `src/activelearning/domain/metrics.py` (função `lce`), com testes unitários de propriedades.

APÊNDICE B – ALGORITMO GENÉTICO PARA OTIMIZAÇÃO DE L_0

B.1 FORMULAÇÃO

Indivíduo: conjunto de I índices únicos do pool (L_0 candidato). Aptidão: desempenho (Acurácia ou Macro F1) do classificador PVBin treinado no indivíduo e avaliado em partição de **aferição** disjunta do conjunto de teste (protocolo anticircularidade; ver Seção 4.4 para a quantificação do viés do protocolo ingênuo). Quatro cenários: maximização e minimização de cada métrica: o par (max, min) delimita o envelope empírico de desempenho alcançável pela composição.

B.2 OPERADORES E PARÂMETROS

- **População** $N_{pop} = 20$; **gerações** 100 por cenário (200 no caso $|L_0| = 10$, o único que difere), o que dá 2.000 avaliações supervisionadas por cenário (4.000 no caso $|L_0| = 10$); valores confirmados contra o artefato da corrida canônica (`individual_id` 0..19). A população é o único parâmetro sem fonte de configuração: o valor reportado (20) é o do artefato da corrida, não o da configuração versionada. No caso $|L_0| = 10$, a tabela do Capítulo 4 reporta, como nas demais células, a 100ª geração (18,82%); a corrida desse caso segue até a 200ª, em que o melhor indivíduo alcança 19,20%. A reexecução independente usa configuração reduzida de $N_{pop} = 30$ por 40 gerações (decisão D-002 do registro de decisões);
- **seleção**: torneio de tamanho $k_t = 3$, definido no *notebook* que executou as corridas, que sempre o passa (o arquivo de configuração em JSON fixa apenas o tamanho de L_0);
- **cruzamento**: um ponto sobre a lista de índices, com probabilidade $p_c = 0,8$ definida no *notebook* da corrida (o valor padrão da classe é 0,7, sempre sobrescrito pelo *notebook*), seguido de *reparo de unicidade* (índices repetidos são substituídos por sorteio até restaurar $|L_0| = I$);
- **mutação**: com probabilidade $p_m = 0,1$, definida no *notebook* da corrida, substituição de $m_s = \max(1, \lceil 0,01 \cdot I \rceil)$ genes por índices inéditos (a fórmula de m_s é o ramo dinâmico do *notebook*);
- **elitismo**: 10%, definido no *notebook* ($N_{elite} = 2$, decorrente da população de 20).

B.3 PSEUDOCÓDIGO

1. Inicializar N_{pop} indivíduos por amostragem uniforme sem reposição.

2. Avaliar aptidão de todos na partição de aferição.
3. Por geração: copiar elite; completar a população por torneio → cruzamento → reparo → mutação; reavaliar.
4. Ao final, **reavaliar o melhor indivíduo no conjunto de teste intocado**; o valor reportado como envelope é este, não a aptidão.

Implementação de referência da reexecução: `experiments/p1/replay_ga.py`; resultados em `experiments/p1/results/replay_ga.jsonl`.

APÊNDICE C – ALGORITMO DRI-SL

C.1 OBJETIVO E ENTRADAS

Construir L_0 de tamanho alvo I a partir do pool não rotulado U , sem acesso a rótulos. Entradas: textos de U ; codificador de sentenças ϕ (SBERT multilíngue (Reimers e Gurevych, 2019) na configuração da tese); número de grupos N_c (padrão $\max(2, \lfloor \sqrt{I} \rfloor)$); semente.

C.2 ETAPAS

1. **Densidade semântica:** projetar U por ϕ ; agrupar por k -médias em N_c grupos; alocar a cota q_c de cada grupo proporcionalmente ao seu tamanho (cota mínima de 1 para grupo não vazio; ajuste do resto pelas maiores frações).
2. **Variedade lexical intragrupo:** para cada grupo c , computar o perfil TF-IDF médio; selecionar iterativamente, entre os membros ainda não escolhidos, o texto que maximiza o *escore de novidade* (a soma dos pesos, no perfil do grupo, dos termos que o texto introduz e que ainda não estão cobertos pelos já selecionados); atualizar o conjunto de termos cobertos; repetir até preencher q_c .

A seleção é determinística dada a semente (inicialização do k -médias). O custo é dominado pela codificação ($O(|U|)$ passagens do codificador) e pelo k -médias; a etapa lexical é $O(q_c \cdot |c|)$ por grupo, com operações esparsas.

C.3 INTUIÇÃO

A etapa 1 garante *representatividade*: como o número de grupos é $N_c = \max(2, \lfloor \sqrt{I} \rfloor)$ e cada grupo não vazio tem cota mínima de um, nenhum agrupamento fica de fora do L_0 . A etapa 2 *reduz* a redundância: dentro da região, evita quase-duplicatas (frequentes no domínio: 7,7% de duplicatas exatas) e força a cobertura de vocabulário, o recurso que, para um classificador por protótipo como o PVBin, constrói as fronteiras. A combinação explica o resultado do Capítulo 4: cobertura semântica dá o esqueleto de classes; cobertura lexical dá o poder discriminativo por classe.

Implementação de referência: `src/activelearning/adapters/strategies/drisl.py` (com codificador alternativo TF-IDF+SVD para ambientes leves), testes em `tests/unit/test_drisl.py`.

APÊNDICE D – A BIBLIOTECA ACTIVELEARNING

D.1 ARQUITETURA

A biblioteca segue arquitetura hexagonal com domínio isolado: o núcleo (`domain/`) contém instâncias, o espaço fechado de categorias (*CategorySchema*), anotações com contabilidade de uso (*OracleUsage*: tokens, tokens em cache, custo, latência), estratégias de incerteza e métricas (LCE, Wilson, McNemar). O núcleo é puro, sem dependência de rede ou framework. Os **adapters** implementam as portas: oráculos (OpenAI, OpenAI-compatível/MaaS, OpenRouter, Gemini, Ollama, Simulado com ruído ε), classificadores (PVBin; BERTimbau via `transformers`), estratégias com infraestrutura (DRI-SL com SBERT), dados (CSV do domínio) e persistência (SQLite/PostgreSQL). Os **casos de uso** (`application/`) orquestram: avaliação de oráculo (E0, retomável), laço de aprendizado ativo (E1/E4), runner do FALCO (fases com transição por validação) e saneamento de dados.

O diferencial frente a bibliotecas existentes de AL para texto, notadamente a *small-text* (Schröder et al., 2023), que padroniza classificador $\times$ estratégia $\times$ critério de parada, é elevar o **oráculo** a porta de primeira classe: custo por consulta, modos de instrumentação (enum/json-prompt/free), variantes de prompt, lote por chamada e cache são medidos e registrados em cada anotação.

D.2 REPRODUÇÃO DOS EXPERIMENTOS

Cada experimento tem ponto de entrada único parametrizado por configuração versionada; execuções gravam sementes e registros por item/iteração (JSONL) e são retomáveis. Mapa: E0 $\rightarrow$ `experiments/e0/run_e0.py` (+ `analyze_e0.py`, `analyze_noise_impact.py`); E0-P $\rightarrow$ `experiments/e0p/`; P1/AG $\rightarrow$ `experiments/p1/`; E1/E4 $\rightarrow$ `experiments/e1e4/`; E2/E3 (GPU) $\rightarrow$ runner do FALCO em `src/activelearning/application/run_falco.py` com os cinco braços do desenho. A suíte de testes unitários cobre domínio, adapters e casos de uso sem rede.

D.3 FLOWBUILDER

Interface web (FastAPI + React) sobre a biblioteca: envio de CSV com saneamento automático (remoção de rótulos operacionais; censo de conflitos e duplicatas; download da base saneada), execução parametrizada de fluxos (semente, orçamento, lote, L_0 , estratégia, oráculo, incluindo modelos de custo zero) e acompanhamento de curvas de aprendizado. O banco guarda o índice das execuções; os artefatos brutos permanecem em disco, versionáveis.

APÊNDICE E – PROMPTS E ESQUEMAS DO ORÁCULO LLM

E.1 PROMPT V3 (PRODUÇÃO)

Contexto de tarefa comum a todos os modos (o texto integral e versionado está em `src/activelearning/adapters/oracles/prompt.py`):

“Você é um especialista em catalogação de produtos do varejo brasileiro. As descrições vêm de cupons fiscais e cadastros de e-commerce: são curtas, geralmente em caixa alta e cheias de abreviações (ex.: CERV=cerveja, REFR=refrigerante, BISC=biscoito, CHOC=chocolate, RECH=recheado, PCT=pacote, LT=lata, CX=caixa, UN=unidade). Expanda mentalmente as abreviações e classifique o TIPO do produto, ignorando marca, tamanho e embalagem. Escolha sempre a categoria mais específica aplicável; na dúvida entre uma categoria plausível e ‘_rare_’, prefira a categoria plausível — use ‘_rare_’ SOMENTE se nenhuma categoria da lista descrever o tipo do produto. Exemplos: ‘CERV BRAHMA LT 350ML’ → cerveja; ‘BISC RECH CHOC 130G’ → biscoito; ‘REQUEIJAO LIGHT CP 200G’ → requeijao.”

O prefixo estático (contexto + esquema) precede o item variável, habilitando o *cache* de prefixo dos provedores (88–95% de acerto medido no E0).

E.2 MODOS DE INSTRUMENTAÇÃO

enum: saída estruturada com `strict:true`; o campo `predicted_category` é restrito por `enum` às 621 categorias do *CategorySchema*; campos `expanded_description` e `rationale` completam o objeto (todos obrigatórios — exigência do modo estrito). **json-prompt** (provedores sem saída estruturada): a lista de categorias e o formato JSON são instruídos no texto; a resposta passa por extração tolerante e validação exata contra o esquema, com rótulos fora do espaço contabilizados como inválidos. **free** (somente RQ4): saída estruturada sem `enum` — réplica controlada do instrumento defeituoso do trabalho anterior. Na rotulagem em lote, os itens são numerados e a resposta é um vetor indexado; o esquema do lote não fixa `minItems/maxItems` para preservar a cacheabilidade do prefixo; o uso (tokens/custo) é rateado igualmente entre os itens da chamada.

E.3 VARIANTES DO E0-P

v4a acrescenta dez regras de fronteira do catálogo derivadas da anatomia de erros (ex.: medicamentos → *outro farma*; produto bucal líquido → *antisseptico bucal*; pó para suco → *preparo para suco*; fones com fio → *acessorio de audio*); **v4b** soma dez exemplos *inventados* de

fronteiras difíceis (nunca instâncias das amostras de avaliação — decisão D-004). Texto integral das variantes no mesmo módulo versionado.

APÊNDICE F – TABELAS COMPLETAS

A Tabela F.1 apresenta as estatísticas descritivas completas do estudo de sensibilidade de L_0 (Seção 4.1): Acurácia Global e Macro F1 no teste T por tamanho I , com média, mediana, desvio-padrão, extremos, quartis e coeficiente de variação da mediana — 47 tamanhos, 30 repetições cada, classificador PVBin. A tabela reproduz o artefato original do programa experimental; a reexecução independente (15 tamanhos $\times$ 10 repetições) está em `experiments/p1/results/replay_l0.jsonl` no repositório de código.

Tabela F.1: Estatísticas Descritivas da Performance em Função do Tamanho de L_0 (Classificador: PVBin (1,2)-gram). 30 repetições por tamanho.

Métrica Base	Tam. L_0 (I)	Média	Mediana	DP	Mínimo	P25	P75	Máximo	IQR	CV (Med.)
Acurácia	10	0.067	0.069	0.024	0.026	0.046	0.088	0.102	0.042	0.345
Acurácia	20	0.105	0.110	0.023	0.049	0.089	0.122	0.138	0.033	0.211
Acurácia	30	0.140	0.139	0.023	0.095	0.125	0.155	0.181	0.030	0.165
Acurácia	40	0.160	0.159	0.023	0.100	0.145	0.178	0.191	0.034	0.141
Acurácia	50	0.178	0.180	0.022	0.124	0.164	0.199	0.208	0.034	0.121
Acurácia	60	0.193	0.194	0.019	0.145	0.179	0.207	0.230	0.027	0.100
Acurácia	70	0.207	0.207	0.014	0.177	0.196	0.219	0.229	0.023	0.067
Acurácia	80	0.224	0.224	0.015	0.203	0.212	0.235	0.252	0.023	0.066
Acurácia	90	0.235	0.234	0.019	0.205	0.221	0.250	0.278	0.029	0.082
Acurácia	100	0.247	0.247	0.016	0.217	0.237	0.257	0.281	0.020	0.064
Acurácia	200	0.333	0.333	0.016	0.306	0.321	0.345	0.370	0.024	0.048
Acurácia	300	0.391	0.392	0.010	0.365	0.388	0.397	0.409	0.010	0.027
Acurácia	400	0.435	0.434	0.010	0.417	0.429	0.439	0.465	0.009	0.023
Acurácia	500	0.468	0.467	0.008	0.452	0.463	0.475	0.483	0.012	0.018
Acurácia	600	0.491	0.492	0.008	0.471	0.486	0.496	0.509	0.010	0.016
Acurácia	700	0.513	0.513	0.007	0.497	0.508	0.516	0.530	0.008	0.014
Acurácia	800	0.529	0.532	0.009	0.508	0.524	0.537	0.544	0.013	0.018
Acurácia	900	0.546	0.547	0.005	0.534	0.544	0.550	0.557	0.006	0.010
Acurácia	1000	0.559	0.559	0.007	0.542	0.555	0.564	0.568	0.009	0.012
Acurácia	2000	0.640	0.641	0.004	0.633	0.637	0.643	0.648	0.006	0.006
Acurácia	3000	0.679	0.678	0.004	0.671	0.675	0.682	0.687	0.006	0.006
Acurácia	4000	0.705	0.705	0.003	0.698	0.703	0.707	0.714	0.003	0.004

Continua na próxima página

Tabela F.1 – continuação da página anterior

Métrica Base	Tam. L0 (I)	Média	Mediana	DP	Mínimo	P25	P75	Máximo	IQR	CV (Med.)
Acurácia	5000	0.721	0.721	0.003	0.713	0.719	0.723	0.726	0.005	0.004
Acurácia	6000	0.736	0.736	0.004	0.727	0.732	0.738	0.746	0.006	0.005
Acurácia	7000	0.747	0.747	0.003	0.741	0.744	0.748	0.751	0.004	0.003
Acurácia	8000	0.755	0.755	0.003	0.748	0.753	0.757	0.760	0.005	0.004
Acurácia	9000	0.763	0.762	0.003	0.758	0.761	0.765	0.769	0.004	0.004
Acurácia	10000	0.769	0.769	0.003	0.765	0.767	0.771	0.774	0.004	0.003
Acurácia	20000	0.806	0.807	0.002	0.802	0.805	0.808	0.812	0.003	0.003
Acurácia	30000	0.826	0.826	0.001	0.824	0.825	0.827	0.829	0.002	0.002
Acurácia	40000	0.838	0.838	0.001	0.835	0.837	0.839	0.842	0.002	0.002
Acurácia	50000	0.847	0.847	0.002	0.843	0.846	0.848	0.852	0.002	0.002
Acurácia	60000	0.853	0.854	0.001	0.851	0.853	0.854	0.856	0.001	0.001
Acurácia	70000	0.859	0.859	0.001	0.856	0.858	0.859	0.861	0.002	0.001
Acurácia	80000	0.864	0.863	0.001	0.861	0.863	0.864	0.867	0.002	0.001
Acurácia	90000	0.867	0.867	0.001	0.865	0.866	0.868	0.870	0.001	0.001
Acurácia	100000	0.871	0.871	0.001	0.869	0.870	0.872	0.873	0.001	0.001
Acurácia	110000	0.874	0.874	0.001	0.872	0.873	0.875	0.876	0.002	0.001
Acurácia	120000	0.876	0.877	0.001	0.875	0.876	0.877	0.878	0.001	0.001
Acurácia	130000	0.879	0.879	0.001	0.877	0.878	0.879	0.880	0.001	0.001
Acurácia	140000	0.881	0.881	0.001	0.880	0.881	0.882	0.883	0.001	0.001
Acurácia	150000	0.883	0.883	0.001	0.882	0.883	0.884	0.884	0.001	0.001
Acurácia	160000	0.885	0.885	0.001	0.884	0.885	0.885	0.886	0.001	0.001
Acurácia	170000	0.886	0.887	0.000	0.885	0.886	0.887	0.888	0.001	0.001
Acurácia	180000	0.888	0.888	0.000	0.887	0.888	0.888	0.889	0.000	0.000
Acurácia	190000	0.889	0.890	0.000	0.889	0.889	0.890	0.890	0.000	0.000
Acurácia	200000	0.891	0.891	0.000	0.891	0.891	0.891	0.891	0.000	0.000
F1-Macro	10	0.004	0.003	0.001	0.002	0.003	0.004	0.007	0.001	0.309
F1-Macro	20	0.008	0.008	0.001	0.005	0.007	0.009	0.010	0.002	0.175
F1-Macro	30	0.012	0.012	0.002	0.009	0.010	0.013	0.015	0.003	0.148
F1-Macro	40	0.015	0.015	0.002	0.011	0.014	0.016	0.018	0.002	0.099
F1-Macro	50	0.018	0.018	0.002	0.014	0.017	0.020	0.023	0.003	0.126
F1-Macro	60	0.021	0.022	0.002	0.017	0.020	0.023	0.026	0.003	0.105
F1-Macro	70	0.024	0.024	0.002	0.021	0.023	0.025	0.029	0.002	0.081
F1-Macro	80	0.028	0.027	0.003	0.023	0.026	0.029	0.036	0.003	0.097
F1-Macro	90	0.031	0.031	0.003	0.027	0.029	0.033	0.038	0.004	0.084

Continua na próxima página

Tabela F.1 – continuação da página anterior

Métrica Base	Tam. L0 (I)	Média	Mediana	DP	Mínimo	P25	P75	Máximo	IQR	CV (Med.)
F1-Macro	100	0.034	0.035	0.003	0.030	0.033	0.035	0.041	0.003	0.075
F1-Macro	200	0.062	0.063	0.004	0.054	0.058	0.064	0.068	0.006	0.064
F1-Macro	300	0.084	0.085	0.004	0.078	0.081	0.086	0.090	0.006	0.043
F1-Macro	400	0.103	0.104	0.005	0.095	0.098	0.108	0.113	0.010	0.053
F1-Macro	500	0.119	0.120	0.004	0.109	0.116	0.122	0.127	0.006	0.037
F1-Macro	600	0.135	0.134	0.004	0.128	0.131	0.138	0.141	0.007	0.029
F1-Macro	700	0.147	0.148	0.006	0.134	0.144	0.152	0.162	0.008	0.040
F1-Macro	800	0.158	0.158	0.006	0.149	0.154	0.162	0.169	0.008	0.036
F1-Macro	900	0.168	0.168	0.006	0.158	0.165	0.173	0.179	0.008	0.033
F1-Macro	1000	0.178	0.176	0.008	0.163	0.172	0.185	0.191	0.013	0.045
F1-Macro	2000	0.251	0.252	0.006	0.239	0.248	0.255	0.267	0.007	0.025
F1-Macro	3000	0.295	0.295	0.005	0.287	0.292	0.298	0.306	0.006	0.017
F1-Macro	4000	0.328	0.327	0.005	0.316	0.324	0.331	0.340	0.007	0.016
F1-Macro	5000	0.350	0.348	0.006	0.341	0.345	0.354	0.363	0.009	0.017
F1-Macro	6000	0.373	0.374	0.008	0.358	0.369	0.379	0.390	0.010	0.022
F1-Macro	7000	0.393	0.393	0.007	0.379	0.390	0.397	0.406	0.007	0.017
F1-Macro	8000	0.406	0.406	0.007	0.390	0.402	0.411	0.421	0.009	0.017
F1-Macro	9000	0.420	0.420	0.007	0.406	0.415	0.426	0.429	0.011	0.016
F1-Macro	10000	0.433	0.432	0.006	0.418	0.429	0.438	0.446	0.009	0.015
F1-Macro	20000	0.503	0.503	0.007	0.488	0.500	0.508	0.517	0.008	0.014
F1-Macro	30000	0.549	0.548	0.008	0.536	0.542	0.554	0.565	0.012	0.014
F1-Macro	40000	0.574	0.575	0.007	0.558	0.569	0.579	0.584	0.010	0.011
F1-Macro	50000	0.595	0.594	0.007	0.584	0.590	0.598	0.613	0.008	0.012
F1-Macro	60000	0.612	0.613	0.006	0.601	0.607	0.616	0.624	0.009	0.010
F1-Macro	70000	0.625	0.624	0.006	0.612	0.622	0.627	0.642	0.005	0.010
F1-Macro	80000	0.635	0.634	0.006	0.627	0.631	0.641	0.651	0.009	0.009
F1-Macro	90000	0.645	0.646	0.005	0.637	0.641	0.649	0.655	0.008	0.008
F1-Macro	100000	0.654	0.653	0.006	0.640	0.652	0.657	0.666	0.006	0.009
F1-Macro	110000	0.661	0.661	0.006	0.648	0.657	0.666	0.674	0.009	0.009
F1-Macro	120000	0.670	0.669	0.004	0.662	0.667	0.672	0.677	0.005	0.006
F1-Macro	130000	0.675	0.676	0.004	0.668	0.672	0.679	0.685	0.006	0.007
F1-Macro	140000	0.679	0.679	0.004	0.671	0.677	0.683	0.686	0.007	0.006
F1-Macro	150000	0.685	0.685	0.003	0.677	0.682	0.688	0.690	0.005	0.005
F1-Macro	160000	0.689	0.688	0.004	0.682	0.687	0.691	0.700	0.004	0.005

Continua na próxima página

Tabela F.1 – continuação da página anterior

Métrica	Tam. L0	Média	Mediana	DP	Mínimo	P25	P75	Máximo	IQR	CV (Med.)
Base	(I)									
F1-Macro	170000	0.693	0.693	0.003	0.688	0.690	0.695	0.699	0.005	0.004
F1-Macro	180000	0.698	0.699	0.003	0.692	0.696	0.700	0.704	0.004	0.004
F1-Macro	190000	0.701	0.701	0.002	0.695	0.700	0.702	0.706	0.002	0.003
F1-Macro	200000	0.704	0.704	0.000	0.704	0.704	0.704	0.705	0.000	0.000

APÊNDICE G – CRITÉRIO DE PARADA, LIBERAÇÃO DO MODELO E MONITORAMENTO DE DERIVA

Este apêndice consolida a política operacional do ciclo de vida do classificador treinado pelo FALCO, da decisão de parar de rotular à decisão de retreinar em produção. As duas primeiras seções descrevem mecanismos implementados na biblioteca `activelearning`; a terceira é o desenho recomendado para operação contínua (FlowBuilder), com gatilhos numéricos.

G.1 PARADA DO LAÇO DE APRENDIZADO ATIVO

O laço encerra a aquisição de rótulos pelo primeiro de três gatilhos: **(i) estagnação na validação**: o Macro F1 em V não melhora mais que $\varepsilon_{\max} = 10^{-3}$ por $p = 5$ iterações consecutivas (Capítulo 3 para o racional das constantes); o conjunto de teste jamais participa; **(ii) orçamento**: teto absoluto de rótulos B ; **(iii) exaustão do pool**. O racional do gatilho (i) é estatístico: o ganho marginal por lote decai ao longo da curva de aprendizado, enquanto o custo marginal do rótulo é constante; quando o ganho observável cai abaixo da resolução do próprio conjunto de validação ($\approx 1/\sqrt{n_V}$), rotular mais é pagar para medir ruído. A tolerância $\varepsilon_{\max} = 10^{-3}$ não deriva desse limite amostral: com $n_V = 2.000$, o limite vale $1/\sqrt{n_V} = 0,0224$, e a tolerância é deliberadamente cerca de vinte e duas vezes menor, de modo que a parada só ocorre após p iterações sem qualquer ganho registrado, e não por o ganho ser pequeno demais para se distinguir do ruído. A parada observada no ciclo real, portanto, não é efeito de uma tolerância estrita: o critério executado é o mais permissivo dos dois. O gatilho foi exercitado em duas execuções ponta a ponta da biblioteca, ambas com **oráculo LLM real e gratuito** (nemotron via NIM, acurácia $\approx 78\%$): com orçamento de 1.000, encerrou o ciclo em 991 rótulos (PVBin) e 982 (SGD); com orçamento de 15.000, encerrou em **6.009** rótulos (PVBin) e **4.742** (SGD), 32–40% do orçamento, com as curvas de validação e teste estagnadas em conjunto. Os artefatos estão no repositório (`experiments/e5cycle`).

G.2 CRITÉRIO DE LIBERAÇÃO DO MODELO

Recomenda-se liberar o modelo para produção quando três condições valem simultaneamente: **(a)** a estagnação foi atingida (o modelo parou de melhorar com o oráculo disponível); **(b)** o desempenho de validação alcança o alvo externo de negócio; na ausência de alvo, o teto empírico do braço *oráculo-total* (treinar com todo o pool rotulado pelo mesmo oráculo, ao custo de inferência apenas) indica o máximo que *este* oráculo permite: estagnar perto dele significa que mais rótulos não ajudam, apenas um oráculo melhor; **(c)** o intervalo de confiança de Wilson do desempenho de validação está inteiro acima do piso aceitável (com $n_V = 1.000$, a meia-largura é

de 2–3 pontos percentuais). Só então o modelo é avaliado *uma única vez* no conjunto de teste intocado, e esse é o número reportado.

G.3 MONITORAMENTO DE DERIVA E POLÍTICA DE RETREINAMENTO

Textos curtos de varejo derivam continuamente (novos produtos, marcas e grafias). Três camadas de monitoramento, em ordem de custo:

1. **Deriva de entrada** (sem rótulo, custo zero): fração de tokens fora do vocabulário de treino e divergência da distribuição de representações (PSI sobre projeções). Gatilho sugerido: taxa de vocabulário novo em dobro da taxa do treino, ou $PSI > 0,2$.
2. **Deriva de confiança** (sem rótulo, custo zero): queda da confiança média (ou aumento da entropia média) das previsões em produção. Gatilho: média móvel de 7 dias abaixo de $\mu - 2\sigma$ do período de referência.
3. **Verificação amostral com oráculo** (custo quase nulo): acurácia numa amostra pequena rotulada pelo LLM Inicial. Com os custos medidos no E0, 200 itens semanais custam da ordem de US\$ 0,01. Gatilho: acurácia amostral abaixo do limite inferior do IC de validação da liberação.

Política: camadas 1–2 disparando antecipam a camada 3; a camada 3 confirmando, retreina-se. O retreino reaproveita todos os rótulos históricos e roda um ciclo *incremental* de aprendizado ativo apenas sobre o fluxo recente (o classificador atual seleciona o que não entende; o oráculo LLM rotula; treina-se do zero com $L_{\text{antigo}} \cup L_{\text{novo}}$; retreinar do zero, e não continuar do modelo anterior, preserva comparabilidade e evita a degradação associada a *warm-starting*). Mesmo sem gatilho, recomenda-se a verificação amostral em cadência mensal: deriva de catálogo pode ser gradual demais para as camadas 1–2.