

UNIVERSIDADE DE SÃO PAULO

Instituto de Ciências Matemáticas e de Computação

Categorização de produtos em e-commerce: avaliação do método Argmax para classificação de descrições curtas em português

Gilsiley Henrique Darú

Dissertação de Mestrado do Programa de Mestrado Profissional em Matemática, Estatística e Computação Aplicadas à Indústria (MECAI)

SERVIÇO DE PÓS-GRADUAÇÃO DO ICMC-USP

Data de Depósito:

Assinatura: _____

Gilsiley Henrique Darú

Categorização de produtos em e-commerce: avaliação do método Argmax para classificação de descrições curtas em português

Dissertação apresentada ao Instituto de Ciências Matemáticas e de Computação – ICMC-USP, como parte dos requisitos para obtenção do título de Mestre – Mestrado Profissional em Matemática, Estatística e Computação Aplicadas à Indústria.
VERSÃO REVISADA

Área de Concentração: Matemática, Estatística e Computação

Orientador: Prof. Dr. Antonio Castelo Filho

USP – São Carlos
Novembro de 2024

Ficha catalográfica elaborada pela Biblioteca Prof. Achille Bassi
e Seção Técnica de Informática, ICMC/USP,
com os dados inseridos pelo(a) autor(a)

D228c	Darú, Gilsiley Henrique Categorização de produtos em e-commerce: avaliação do método Argmax para classificação de descrições curtas em português / Gilsiley Henrique Darú; orientador Antonio Castelo Filho. -- São Carlos, 2024. 106 p. Dissertação (Mestrado - Programa de Pós-Graduação em Mestrado Profissional em Matemática, Estatística e Computação Aplicadas à Indústria) -- Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, 2024. 1. Processamento de linguagem natural. 2. Classificação de texto. 3. Texto curto. 4. Aprendizado de máquina. 5. Descrição do produto. I. Filho, Antonio Castelo, orient. II. Título.
-------	---

Gilsiley Henrique Darú

**Product Categorization in E-commerce: Evaluation of the
Argmax Method for Classifying Short Descriptions in
Portuguese**

Dissertation submitted to the Instituto de Ciências Matemáticas e de Computação – ICMC-USP – in accordance with the requirements of the Professional Master's Program in Mathematics Statistics and Computing Applied to Industry, for the degree of Master in Science. *FINAL VERSION*

Concentration Area: Mathematics, Statistics and Computing

Advisor: Prof. Dr. Antonio Castelo Filho

**USP – São Carlos
November 2024**

Este trabalho é dedicado aos meus pais, por seu amor incondicional e apoio constante em todos os momentos da minha vida.

À minha companheira, por sua paciência, carinho e apoio durante essa jornada.

E a Deus, por me guiar e dar forças para superar os desafios ao longo desta jornada.

AGRADECIMENTOS

A realização deste trabalho só foi possível graças ao apoio e incentivo de várias pessoas e instituições, às quais sou profundamente grato.

Primeiramente, agradeço à Neogrid, por fornecer os recursos e o ambiente necessários para a realização desta pesquisa. Sua confiança e suporte foram fundamentais para que eu pudesse me dedicar a este projeto.

Ao meu orientador, Prof. Dr. Antonio Castelo Filho, meu sincero agradecimento pela orientação, paciência e ensinamentos ao longo deste processo.

Este percurso foi repleto de desafios e aprendizados, e cada obstáculo superado me fez crescer e aprimorar minhas habilidades. Que este trabalho seja uma fonte de inspiração e motivação para todos que buscam realizar seus sonhos acadêmicos. Lembre-se sempre de que a perseverança e a dedicação são chaves fundamentais para alcançar qualquer objetivo.

A todos que, de alguma forma, contribuíram para a concretização deste sonho, minha gratidão eterna.

“A verdadeira sabedoria está em reconhecer a própria ignorância e persistir na busca pelo conhecimento.

Assim como a categorização de produtos busca ordem em meio ao caos, o nosso propósito é encontrar clareza e precisão nas informações que moldam o mundo.”

(Sócrates, adaptado)

RESUMO

DARÚ, G. H. **Categorização de produtos em e-commerce: avaliação do método Argmax para classificação de descrições curtas em português**. 2024. 106 p. Dissertação (Mestrado – Mestrado Profissional em Matemática, Estatística e Computação Aplicadas à Indústria) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos – SP, 2024.

A crescente demanda por sistemas automatizados de classificação de produtos em plataformas de e-commerce impulsionou a busca por soluções eficientes para a categorização de produtos, especialmente em português. Este estudo investiga a adaptação de técnicas de recuperação da informação clássicas – sacola de palavras, TF, e TF-IDF – para a tarefa de classificar descrições curtas de produtos. A pesquisa avalia diferentes estratégias de pré-processamento e tokenização, incluindo a análise do impacto da normalização L2. Os resultados demonstraram que métodos simples de recuperação da informação, quando combinados com pré-processamento adequado e otimização de parâmetros, podem alcançar desempenho significativamente superior. Para avaliar abrangentemente o desempenho e a robustez dos modelos, foram propostas novas métricas – Índice de Eficiência Geral (IEG) e Índice de Eficiência Geral Estabilizado (IEGE). Essas métricas combinam a acurácia e o F1-score macro, oferecendo uma avaliação mais completa do desempenho, especialmente em cenários de desbalanceamento de classes. Este trabalho contribui com insights valiosos para o desenvolvimento de sistemas de categorização de produtos mais eficientes em plataformas de e-commerce em português.

Palavras-chave: Aprendizado de máquina, Processamento de linguagem natural, Classificação de texto, Descrição do produto, Texto curto, Sacola de palavras, Frequência de termos, Frequência inversa de documentos.

ABSTRACT

DARÚ, G. H. **Product Categorization in E-commerce: Evaluation of the Argmax Method for Classifying Short Descriptions in Portuguese**. 2024. 106 p. Dissertação (Mestrado – Mestrado Profissional em Matemática, Estatística e Computação Aplicadas à Indústria) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos – SP, 2024.

The increasing demand for automated product classification systems on e-commerce platforms has driven the search for efficient solutions for product categorization, especially in Portuguese. This study investigates the adaptation of classical information retrieval techniques – bag of words, TF, and TF-IDF – for the task of classifying short product descriptions. The research evaluates different preprocessing and tokenization strategies, including the analysis of the impact of L2 normalization. The results showed that simple information retrieval methods, when combined with appropriate preprocessing and parameter optimization, can achieve significantly superior performance. To comprehensively evaluate the performance and robustness of the models, new metrics were proposed – General Efficiency Index (IEG) and Stabilized General Efficiency Index (IEGE). These metrics combine accuracy and macro F1-score, offering a more complete assessment of performance, especially in class imbalance scenarios. This work provides valuable insights for the development of more efficient product categorization systems on e-commerce platforms in Portuguese.

Keywords: Machine learning, Natural language processing, Text classification, Product description, Short text, Bag of words, Term frequency, Inverse document frequency.

LISTA DE ILUSTRAÇÕES

Figura 1 – Camiseta com a palavra BISCOITO estampada	22
Figura 2 – Evolução Histórica dos artigos sobre classificação de texto nos últimos anos	26
Figura 3 – Evolução do número de publicações sobre classificação de texto na base ACL Anthology (1996-2024).	27
Figura 4 – Evolução do número de publicações sobre classificação de produtos na base ACL Anthology (2016-2024).	28
Figura 5 – Associação de produtos e suas categorias	30
Figura 6 – Modelo de recuperação de informação representando a interação entre consulta, documentos e a função de ranqueamento.	42
Figura 7 – Adaptação do modelo de RI para classificação de produtos, incorporando a etapa de mapeamento para classes.	42
Figura 8 – Árvore de decisão para jogar tênis.	53
Figura 9 – Fluxo de Trabalho.	64
Figura 10 – Hierarquia e quantidade de elementos distintos e descrições em cada segmento	66
Figura 11 – Distribuição das categorias de menor nível em escala logarítmica.	67
Figura 12 – Top 10 categorias de produtos com o maior número de rótulos.	67
Figura 13 – Distribuição de frequência da contagem de caracteres por descrição.	68
Figura 14 – Distribuição de frequência da contagem de palavras por descrição.	68
Figura 15 – Boxplot das acurácias das combinações Argmax.	74
Figura 16 – Boxplot dos F1 Scores Macro das combinações Argmax.	75
Figura 17 – Interpretação do gráfico de dispersão relacionando acurácia e F1 Score Macro das combinações Argmax.	76
Figura 18 – Gráfico de dispersão relacionando acurácia e F1 Score Macro das combinações Argmax.	77
Figura 19 – Boxplot dos F1 Scores Macro das combinações Argmax para o método Binary.	78
Figura 20 – Gráfico de dispersão relacionando acurácia e F1 Score Macro das combinações Argmax para o método Binary.	78
Figura 21 – Boxplot dos F1 Scores Macro das combinações Argmax para o método TFIDF.	79
Figura 22 – Gráfico de dispersão relacionando acurácia e F1 Score Macro das combinações Argmax para o método TFIDF.	80
Figura 23 – Boxplot dos F1 Scores Macro das combinações Argmax para o método TFIDF.	81
Figura 24 – Gráfico de dispersão relacionando acurácia e F1 Score Macro das combinações Argmax para o método TFIDF.	82

LISTA DE TABELAS

Tabela 1	– Principais fontes de publicações sobre classificação de textos, quantidade de artigos por fonte, total acumulado e porcentagem do total de publicações. . .	26
Tabela 2	– Artigos mais citados na área de classificação de textos, incluindo número de citações e ano de publicação.	27
Tabela 3	– Aplicação de técnicas de pré-processamento e tokenização sobre o texto <i>Arroz tio João 1.kg</i>	35
Tabela 4	– Vocabulário, representação de uma palavra como vetor em [1] e representação das demais descrições em [2],[3],[4] e [5] para "Arroz tio João 1 kg", "ARROZ FUMACENCE PARB 1KG", "FEIJAO CARIOCA 1KG AZULAO", "Feij 1 Kg Preto Caldão"respectivamente	36
Tabela 5	– Análise TF-IDF das descrições "Arroz tio João 1 kg", "ARROZ FUMACENCE PARB 1KG", "FEIJAO CARIOCA 1KG AZULAO", e "Feij 1 Kg Preto Caldão". A tabela mostra a frequência de termos (f_{ij}), o peso TF-IDF (w_{ij}) e o peso normalizado TF-IDF (w'_{ij}) para cada termo nas descrições. . .	38
Tabela 6	– Comparação de Modelos de Embedding Estático	40
Tabela 7	– Comparação de Modelos de Embedding Contextualizado	41
Tabela 8	– Matriz termo-documento com representações de frequência, TF-IDF e TF-IDF normalizado.	44
Tabela 9	– Resumo das principais técnicas de classificação de texto de algumas revisões de literatura [1] Aggarwal, Singh e Gupta (2018), [2] Bhavani e Kumar (2021), [3] Gasparetto <i>et al.</i> (2022), [4] Kowsari <i>et al.</i> (2019)	48
Tabela 10	– Matriz de confusão para um modelo de classificação binária	55
Tabela 11	– Exemplo de matriz de confusão	56
Tabela 12	– Resumo das métricas calculadas	56
Tabela 13	– Matriz de confusão para classificação multiclasse	57
Tabela 14	– Exemplo de matriz de confusão para classificação multiclasse	59
Tabela 15	– Métricas de Avaliação por Classe	60
Tabela 16	– Médias Macro e Micro das Métricas	60
Tabela 17	– Visão geral da estrutura hierárquica do conjunto de dados.	65
Tabela 18	– Combinações de Tokenização, Vetorização e Normalização	71
Tabela 19	– Resultados estatísticos dos testes para o método Argmax com Rankings . .	74
Tabela 20	– Resultados estatísticos dos testes para o método Argmax Binário	77
Tabela 21	– Resultados estatísticos dos testes para o método Argmax TF	79

Tabela 22 – Resultados estatísticos dos testes para o método TFIDF com diferentes configurações	81
Tabela 23 – Parâmetros sugeridos para os métodos Argmax baseados em Acurácia e F1 Score Macro (* parâmetro mais impactante)	82

SUMÁRIO

1	INTRODUÇÃO	21
1.1	Contextualização do Problema	21
1.2	Hipóteses	22
1.3	Objetivos	22
1.4	Justificativa e Relevância	23
1.5	Estrutura do Trabalho	23
1.6	CIMO - Contexto, Problema, Objetivo, Método e Contribuição . .	24
2	REVISÃO SISTEMÁTICA	25
2.1	Revisão Inicial da Literatura	25
2.2	Revisão Final da Literatura	27
3	FUNDAMENTOS	29
3.1	Classificação de Texto e Texto Curto - Definição	29
3.2	O Processo de Classificação	31
3.2.1	<i>Pré-processamento</i>	31
3.2.2	<i>Tokenização</i>	34
3.2.3	<i>Representação Numérica de Palavras</i>	34
3.2.4	<i>Modelos de Projeção - Redução de Dimensionalidade</i>	39
3.2.5	<i>Word Embeddings</i>	39
3.3	Técnicas para Classificação de Texto	40
3.3.1	<i>Matriz Termo-Documento</i>	43
3.4	Argmax da Similaridade de Vetores - Similaridade Lexical	47
3.5	Técnicas Supervisionadas Aplicadas a Classificação de Textos . . .	48
3.5.1	<i>Naive Bayes</i>	49
3.5.2	<i>K Vizinhos Mais Próximos (KNN)</i>	49
3.5.3	<i>Máquinas de Vetores de Suporte</i>	50
3.5.4	<i>Árvores de Decisão</i>	51
3.5.5	<i>Regressão Logística</i>	52
3.6	Métricas de Avaliação	54
3.6.1	<i>Matriz de Confusão</i>	54
3.6.2	<i>Matriz de Confusão para Classificação Multiclasse</i>	56
3.7	Técnicas para Divisão do Conjunto de Dados para Avaliação	60

4	METODOLOGIA	63
4.1	Introdução à Metodologia	63
4.2	Design da Pesquisa	63
4.3	Linguagem de Programação e Bibliotecas	64
4.4	Procedimento Experimental	64
4.4.1	<i>Conjunto de Dados</i>	64
4.4.2	<i>Pré-Processamento, Tokenização e Vetorização</i>	68
4.4.3	<i>Métricas de Avaliação</i>	69
4.4.4	<i>Configurações de Treinamento</i>	69
4.4.5	<i>Ajuste Fino dos Modelos</i>	70
5	RESULTADOS	73
6	CONCLUSÃO	101
	REFERÊNCIAS	103

INTRODUÇÃO

1.1 Contextualização do Problema

Na era atual de digitalização massiva, onde mais de 2.5 quintilhões de bytes (GAN-DOMI; HAIDER, 2015) são gerados diariamente, o crescimento acelerado de redes sociais e plataformas de e-commerce intensificou a demanda por métodos eficientes de classificação de textos. Esse vasto volume de dados exige sistemas automatizados que possam organizar e categorizar informações de maneira rápida e precisa, para otimizar a experiência do usuário e facilitar diversas aplicações, como filtragem de spam, análise de sentimento e personalização de publicidade (ALSMADI; GAN, 2019).

No contexto do idioma português, com suas particularidades, regionalismos e nuances entre variantes como o português do Brasil e de Portugal, a classificação textual apresenta desafios adicionais (BRANCO *et al.*, 2012). O objetivo deste trabalho é investigar a classificação de textos curtos, definida como um texto com até 200 caracteres, o que acrescenta uma camada de complexidade à tarefa, dado o conteúdo limitado disponível para análise (ALSMADI; GAN, 2019) e (SONG *et al.*, 2014).

Exemplo do Problema de Categorização de Texto em Português

Para ilustrar os desafios da categorização de textos curtos em português, considere a tarefa de identificar produtos da categoria "BISCOITO" em uma lista. A busca direta pela palavra "biscoito" retornaria resultados como "BISCOITO DUX SALGADO 648G" e "BISCOITO CRACKERS DUX 216G". No entanto, muitas descrições utilizam abreviações como "BISC LEITE MABEL 400G" e "BISC.PARATI MARIA PE 370GR", que seriam ignoradas pela busca simples.

Além disso, termos regionais ou estrangeiros como "BOLACHA", "COOKIE" e "CO-OKIES" também devem ser considerados, por exemplo, "BOLACHA PAPAGUARA MOTOR

400g" e "COOKIES GRAN CASTANH PARA KOBBER 150G". A complexidade aumenta quando produtos não relacionados são incluídos na busca, como "BISC PET CRACKER FORTAL 400G" (biscoitos para animais de estimação) e "CESTA SUPREME BISCOITO LÍMÃO 100G" (cesta de presentes), ou itens como camisetas com estampas que mencionam "BISCOITO".



Figura 1 – Camiseta com a palavra BISCOITO estampada

Fonte: Elaborada pelo autor em site de personalização de estampa.

Esses exemplos demonstram a necessidade de métodos mais avançados para garantir uma classificação precisa.

1.2 Hipóteses

Diversas pesquisas têm indicado a variabilidade no desempenho dos algoritmos de recuperação da informação dependendo da técnica e do dataset em questão (ALSMADI; GAN, 2019; AGGARWAL; SINGH; GUPTA, 2018). Técnicas de pré-processamento, como remoção de stopwords, stemming e lematização, podem ter um impacto significativo no desempenho dos modelos (NASEEM; RAZZAK; EKLUND, 2021). Outro ponto a se considerar são os parâmetros de cada modelo e sua otimização, que provocam significativas alterações nas medidas de avaliação de desempenho (BHAVANI; KUMAR, 2021).

Hipótese: Algoritmos simples de recuperação da informação, quando combinados com técnicas adequadas de pré-processamento e otimização de parâmetros, podem melhorar significativamente a precisão, acurácia, recall e F1-score na classificação de descrições curtas de produtos em português.

1.3 Objetivos

O objetivo central deste estudo é analisar o desempenho, medido em termos de acurácia e F1-score macro, de diferentes algoritmos de recuperação da informação adaptados para a classificação de descrições curtas de produtos em português, utilizando o dataset DARU como referência.

Objetivos Específicos

Dentro deste escopo, busca-se:

1. Adaptar métodos de recuperação da informação, como sacola de palavras, TF e TF-IDF, para servirem como classificadores de descrições curtas de produtos.
2. Avaliar o desempenho de algoritmos simples de recuperação da informação, como TF e TF-IDF com métricas de similaridade, na classificação de textos curtos em português.
3. Analisar o impacto de diferentes técnicas de pré-processamento, como normalização e diferentes abordagens de tokenização, na eficácia dos modelos de recuperação da informação.
4. Determinar e otimizar os parâmetros mais adequados para cada algoritmo, visando maximizar a acurácia e o F1-score macro.
5. Adaptar uma métrica que unifique a acurácia e o F1-score macro para a avaliação de desempenho.

1.4 Justificativa e Relevância

A classificação apropriada de descrições de produtos é relevante para a experiência do usuário, empresas e profissionais de e-commerce. Para os usuários, uma classificação eficiente facilita a busca por produtos, melhora a navegabilidade e personaliza as recomendações. Para as empresas, um sistema de classificação robusto otimiza a organização do catálogo de produtos, melhora a precisão das campanhas de marketing e aumenta a eficiência operacional.

1.5 Estrutura do Trabalho

O trabalho é dividido em seis capítulos. Iniciando com uma revisão sistemática da literatura sobre classificação de texto em português (Capítulo 2), com foco em descrições de produtos e algoritmos de recuperação da informação, o trabalho prossegue para os fundamentos teóricos (Capítulo 3), incluindo pré-processamento, vetorização e métricas de avaliação. A metodologia, com ênfase na adaptação de algoritmos, é detalhada no Capítulo 4. Os resultados são então apresentados e discutidos no Capítulo 5, finalizando na conclusão (Capítulo 6) que resume os achados, contribuições e sugestões para futuros trabalhos.

1.6 CIMO - Contexto, Problema, Objetivo, Método e Contribuição

- **Contexto:** Na era atual de digitalização massiva, a classificação textual tornou-se uma ferramenta essencial, especialmente no domínio do e-commerce e redes sociais. Com a crescente quantidade de dados gerados diariamente, métodos eficazes de categorização são necessários.
- **Problema:** Dada a complexidade do idioma português e a necessidade de classificar textos curtos, como descrições de produtos, existe uma demanda por algoritmos de recuperação da informação eficientes e precisos para esta tarefa.
- **Objetivo:** O estudo visa analisar e otimizar o desempenho de diferentes algoritmos de recuperação da informação na classificação de descrições curtas de produtos em português.
- **Método:** Serão utilizados diversos algoritmos de recuperação da informação, como sacola de palavras, TF e TF-IDF, avaliando o impacto de diferentes técnicas de pré-processamento e otimização de parâmetros.
- **Contribuição:** Esta pesquisa espera contribuir para a área de processamento de linguagem natural, fornecendo diretrizes e práticas recomendadas para a classificação de textos curtos em português, utilizando algoritmos simples de recuperação da informação, além de adaptar uma métrica unificada que combina acurácia e F1-score macro.

REVISÃO SISTEMÁTICA

Foi realizada duas revisões. A primeira descrita a seguir, foi no início deste trabalho e resultou em uma visão ampla do tema, ainda em elaboração. A segunda revisão foi realizada no final do trabalho, objetivando ampliar o tema, agora mais específico sobre o tema e na base aqlanthology, especializada em processamento natural de linguagem(PNL).


2.1 Revisão Inicial da Literatura

Esta revisão sistemática investigou estudos sobre técnicas de classificação de textos curtos, com foco em descrições de produtos em português. As bases de dados Scopus e Web of Science foram pesquisadas usando a seguinte estratégia de busca: os termos "*text* classification**", "*text* categori\$ation**", "*document* classification**", "*document* categori\$ation**" foram combinados com os termos "*machine learning*", "*machine* learn**", "*ML*", "*artificial intelligence*", "*AI*". A busca resultou em artigos em inglês e português, considerando títulos, resumos e palavras-chave, limitando-se a artigos de periódicos e conferências. Artigos duplicados, revisões e trabalhos sem acesso ao texto completo foram excluídos.

A análise quantitativa dos resultados revelou um conjunto de 7169 artigos. Observou-se um crescimento de 8,49% ao ano no número de publicações, com pico em 2021 e uma leve queda em 2022 ([Figura 2](#)). Esse crescimento rápido indica a crescente relevância da organização automática de informações. A distribuição das publicações entre diferentes periódicos e conferências demonstra a ampla disseminação do tema na literatura.

Com relação a jornais e conferências, a [Tabela 1](#) mostra que não há uma concentração significativa de publicações. As dez principais fontes representam 12,2% do total de publicações, o que demonstra uma ampla aplicabilidade do tema. É importante mencionar o primeiro jornal, que é um periódico de acesso aberto na Europa. Os próximos dois são repositórios tradicionais de artigos científicos nas áreas: ACM e IEEE. Outro jornal a se destacar é "Expert Systems With

Figura 2 – Evolução Histórica dos artigos sobre classificação de texto nos últimos anos



Origem:

Fonte: Elaborada pelo autor.

Applications". Além disso, vale mencionar que existem mais de 3600 fontes e mais de 14.000 autores envolvidos na amostra coletada.

Origem	Quant.	Total	%
CEUR Workshop Proceedings	228	228	3,2
ACM International Conference Proceeding Series	143	371	5,2
IEEE Access	133	504	7,0
Expert Systems with Applications	68	572	8,0
Journal of Biomedical Informatics	60	632	8,8
Applied Sciences-Basel	52	684	9,5
Journal of Physics: Conference Series	52	736	10,3
Neurocomputing	49	785	10,9
IJCAI International Joint Conference on Artificial Intelligence	48	833	11,6
International Journal of Advanced Computer Science and Applications	41	874	12,2

Tabela 1 – Principais fontes de publicações sobre classificação de textos, quantidade de artigos por fonte, total acumulado e porcentagem do total de publicações.

A Tabela 2 apresenta uma lista de artigos de referência na área de classificação de texto, ordenados por número de citações. Destacam-se os trabalhos que tratam de técnicas de pré-processamento e modelos de aprendizado de máquina relevantes para a classificação de descrições de produtos, como técnicas para evitar superajuste do aprendizado [Srivastava et al. \(2014\)](#), aprendizado de transferência [Pan e Yang \(2009\)](#), e métricas de desempenho [Sokolova e Lapalme \(2009\)](#).

Título	Citações	Ano
Srivastava <i>et al.</i> (2014)	19002	2014
Pan e Yang (2010)	9633	2010
Sebastiani (2002)	3854	2002
Sokolova e Lapalme (2009)	2472	2009
Zhang e Zhou (2007)	1852	2007
Forman (2003)	1843	2003
Le e Mikolov (2014b)	1772	2014
Le e Mikolov (2014a)	1663	2014
Dave, Lawrence e Pennock (2003)	1483	2003
Tong e Koller (2002)	1445	2002
Joachims (2006)	1417	2006
Lai <i>et al.</i> (2015)	1251	2015
Kusner <i>et al.</i> (2015)	1133	2015
Howard e Ruder (2018)	1116	2018
Raffel <i>et al.</i> (2020)	1056	2020
Raina <i>et al.</i> (2007)	998	2007
Botou, Curtis e Nocedal (2018)	876	2018
Tschantaridis <i>et al.</i> (2004)	841	2004
Natekin e Knoll (2013)	821	2013
Rennie <i>et al.</i> (2003)	760	2003

Tabela 2 – Artigos mais citados na área de classificação de textos, incluindo número de citações e ano de publicação.

2.2 Revisão Final da Literatura

Esta seção atualiza a revisão bibliográfica inicial, realizada no início de 2022, considerando os avanços recentes no campo da classificação de textos. A atualização, realizada em 2024, utilizando os mesmos termos de busca da revisão inicial, permitiu analisar a evolução do interesse pela temática. A Figura 3 apresenta dados da base ACL Anthology referentes ao tema de classificação de texto.



Figura 3 – Evolução do número de publicações sobre classificação de texto na base ACL Anthology (1996-2024).

Observa-se um crescimento contínuo a partir de 2016 e a partir de 2022 um patamar de um pouco mais de 500 artigos é mantido até 2024 (549 artigos), indicando uma estabilização do interesse na área.

Para refinar ainda mais a análise, focou-se em trabalhos especificamente sobre classificação de produtos. A Figura 4 ilustra a evolução temporal dessas publicações, totalizando 46 artigos no período analisado.

Figura 4 – Evolução do número de publicações sobre classificação de produtos na base ACL Anthology (2016-2024).



Origem:

Fonte: Elaborada pelo autor.

FUNDAMENTOS

Este capítulo apresenta os fundamentos teóricos para a classificação de textos curtos, focando nos conceitos e técnicas relevantes para este trabalho. Serão abordados: representações vetoriais de texto, métodos de classificação e métricas de avaliação.

3.1 Classificação de Texto e Texto Curto - Definição

Definição 1 (Classificação de Texto). A Classificação de texto consiste em atribuir uma classe ou categoria pré-definida a um conjunto de texto. É uma tarefa comum em processamento de linguagem natural e é utilizada para organizar, estruturar e categorizar grandes quantidades de dados [Kowsari *et al.* \(2019\)](#).

Os algoritmos de classificação de texto recebem como entrada um conjunto de texto e produzem uma classe. A classe é escolhida a partir de um conjunto pré-definido de categorias ou rótulos. Formalmente, de acordo com [Aggarwal e Zhai \(2012\)](#), um problema de classificação envolve um conjunto de instâncias $D = X_1, \dots, X_n$, onde cada instância pertence a uma das k classes indexadas por $1, 2, \dots, k$. Aqui, X_i é um exemplo, como uma descrição de produto, e n é o número de instâncias. Na [Figura 5](#), é apresentada a associação entre as descrições dos itens e suas respectivas categorias, onde se observa $n = 3$ itens distintos relacionados às suas classes ($k = 2$).




Figura 5 – Associação de produtos e suas categorias

Origem:

Fonte: Elaborada pelo autor.

Um conjunto de treinamento é usado para construir um modelo de classificação, que é utilizado para prever a classe de uma nova instância desconhecida. Este problema pode ser considerado difícil quando a classe é explicitamente determinada ou suave quando são atribuídas probabilidades. A classificação de texto requer a conversão de texto em dados numéricos, o que pode ser alcançado por meio de técnicas de processamento de linguagem natural, mostrados em seção posterior.

Definição 2 (Texto Curto). Texto curto é definido como um texto de até 200 caracteres.

A definição acima foi extraída de , extraído de [Alsmadi e Gan \(2019\)](#). Textos curtos acrescentam algumas dificuldades, conforme [Alsmadi e Gan \(2019\)](#) e [Song et al. \(2014\)](#), apresentados a seguir:

Contexto limitado: Textos curtos geralmente têm pouco contexto ou informações básicas, o que dificulta a compreensão detalhada e a classificação precisa.

Vocabulário limitado: Textos curtos podem apresentar um número restrito de palavras ou atributos, o que torna difícil extrair informações significativas para a classificação.

Ruído: Textos curtos frequentemente contêm erros ortográficos, abreviações e outras formas de ruído que complicam a análise.

Estilo informal ou não estruturado: Muitos textos curtos, como tweets ou resenhas de produtos, são escritos de forma informal ou não estruturada, dificultando a interpretação por modelos automatizados.

Alto grau de variabilidade: A extensão, o conteúdo e a linguagem dos textos curtos podem variar significativamente, o que desafia a construção de modelos que generalizem bem em diferentes contextos.

Esparsidade: Textos curtos frequentemente apresentam alta esparsidade, com muitos atributos de valor zero ou ausentes, o que prejudica a análise de dados e a criação de modelos eficazes.

Dados de treinamento limitados: A quantidade limitada de dados de treinamento disponível para textos curtos, especialmente em aplicações especializadas, dificulta a construção de modelos precisos.

Ambiguidade: Textos curtos são mais suscetíveis a conter informações ambíguas ou incompletas, dificultando a determinação correta da classe ou do significado pretendido.

Apesar das dificuldades anteriormente citadas, a inúmeras aplicações, conforme [Bhavani e Kumar \(2021\)](#), são apresentada a seguir:

Análise de mídia social: Textos curtos, como tweets ou postagens do Facebook, são comuns em plataformas de mídia social e podem ser classificados de acordo com várias categorias, como sentimento, tópico ou relevância.

Análise de feedback do cliente: Avaliações de clientes ou respostas a pesquisas podem ser analisadas e classificadas em categorias como satisfação, recursos do produto ou avaliação geral.

Recuperação de informações: Consultas de pesquisa ou títulos de documentos podem ser classificados de acordo com sua relevância em relação a um tópico ou conjunto de palavras-chave específicos.

Análise de sentimento: Avaliações online e postagens em redes sociais podem ser categorizadas com base no sentimento expresso, como positivo, negativo ou neutro.

Deteção de spam: Linhas de assunto de e-mails ou mensagens de texto podem ser analisadas para determinar se são spam ou não.

Modelagem de tópicos: Títulos de notícias ou artigos científicos podem ser classificados de acordo com os tópicos que abordam.

3.2 O Processo de Classificação

O processo de classificação de textos curtos envolve as mesmas etapas de uma classificação de texto normal, porém [Song et al. \(2014\)](#) sugere uma etapa de enriquecimento de atributos. As etapas são, adaptado de [Kowsari et al. \(2019\)](#), [Alsmadi e Gan \(2019\)](#) e [Aggarwal, Singh e Gupta \(2018\)](#): coleta de dados, pré-processamento, tokenização, representação numérica de palavras e documentos, seleção do modelo de classificação, avaliação do desempenho e implantação do modelo.

Nas seções subsequentes é detalhado as fases de pré-processamento, tokenização e extração de atributos.

3.2.1 Pré-processamento

Definição 3. O pré-processamento é a etapa de preparação dos dados brutos para torná-los adequados ao processamento por algoritmos de aprendizado de máquina e Processamento Natural de Linguagem. Ele visa transformar, limpar e normalizar os dados, eliminando ruídos e inconsistências para melhorar a precisão dos modelos.

A literatura sugere que as técnicas de pré-processamento têm um impacto significativo na classificação de textos, [Naseem, Razzak e Eklund \(2021\)](#). Podem influenciar significativamente o desempenho

dos classificadores. Imperfeições nos dados, tais como ruídos introduzidos por elementos não estruturados ou linguagem informal, podem degradar a eficácia dos modelos de classificação.

Naseem, Razzak e Eklund (2021) realizou uma análise detalhada de 12 técnicas distintas de pré-processamento e relatou que, enquanto algumas técnicas resultam em melhorias, outras podem impactar negativamente o desempenho. Mais ainda, foi identificado que a ordem na qual essas técnicas são aplicadas é um fator relevante, pois sequências inadequadas podem levar à perda de informações.

A sequência abaixo enumera as 12 técnicas do artigo Naseem, Razzak e Eklund (2021) e acrescenta uma técnica relevante para o contexto de descrição de produtos.

1. **Remoção de Ruído (URLs, Hashtags e Menções de Usuários):** Técnica que envolve a eliminação de elementos como URLs, hashtags e menções de usuários, considerados ruídos em dados de texto, especialmente em tweets.
 - **Exemplo (Antes):** "Confira em www.google.com #Tecnologia @usuario"
 - **Exemplo (Depois):** "Confira em ."
2. **Substituição de Emoticons e Emojis:** Esta técnica substitui emoticons e emojis por seus respectivos significados em palavras, ajudando na captura de sentimentos e opiniões expressos através desses símbolos.
 - **Exemplo (Antes):** Eu estou tão feliz :-)
 - **Exemplo (Depois):** Eu estou tão feliz smile
3. **Substituição de Abreviações e Gírias:** Envolve a conversão de abreviações e gírias em seus significados completos em palavras.
 - **Exemplo (Antes):** Refri Coca Cola **LT** 350ml
 - **Exemplo (Depois):** Refri Coca Cola **lata** 350ml
4. **Tratamento de Caracteres Alongados:** Lida com palavras em que caracteres são intencionalmente repetidos para ênfase (por exemplo, "loooovvveee"), convertendo-as para suas formas base para evitar que sejam tratadas como palavras diferentes ou fora do vocabulário.
 - **Exemplo (Antes):** Eu amoooooo muiiiiiito esse lugar!
 - **Exemplo (Depois):** Eu amo muito esse lugar!
5. **Correção de Ortografia e Gramática:** A correção de erros ortográficos e gramaticais ajuda a reduzir variações da mesma palavra escrita de maneira diferente, contribuindo para a normalização do texto.
 - **Exemplo (Texto Original):** "Eu vou commer piza hooje."
 - **Exemplo (Após Correção):** "Eu vou **comer** **pizza** **hoje**."
6. **Expansão de Contrações:** Contrações e palavras abreviadas são expandidas para suas formas completas, padronizando o texto para processamento mais fácil por máquinas.

- **Exemplo (Antes):** "I don't do this."
- **Exemplo (Depois):** "I do not do this."

Para o contexto de descrição de produtos, existe por exemplo o símbolo de polegadas ", que pode ser expandido para a palavra polegadas.

7. **Remoção de Pontuação:** Inclui a remoção de pontuações que, embora expressem sentimentos e emoções, podem não ser úteis para a classificação automática de textos curtos.

- **Exemplo (Antes):** "Eu estou tão feliz!!!"
- **Exemplo (Depois):** "Eu estou tão feliz"

Para o contexto de descrição de produtos, quando a pontuação representa abreviação é possível removê-lo sem perda de informação como por exemplo em "bisc.recheado".

8. **Remoção de Números:** Trata-se da eliminação de numerais presentes nos textos, embora se deva ter cuidado para não perder informações importantes nesse processo.

- **Exemplo (Antes):** "Havia 5 pássaros no jardim."
- **Exemplo (Depois):** "Havia pássaros no jardim."

Para o contexto de descrição de produtos, a remoção de número implica em retirada de informação relevante, pois as apresentações dos produtos são características de categorias, por exemplo, enquanto bebidas possuem padrões de volumetria como 350, 600 e 1, categorias como feijão possuem números como 500, 1, 2 e 5.

9. **Conversão para Minúsculas (Folding to Lower-casing):** Consiste em converter todas as letras maiúsculas para minúsculas para evitar variações da mesma palavra determinadas pelo uso de maiúsculas e minúsculas.

- **Exemplo (Antes):** "Este é um Exemplo."
- **Exemplo (Depois):** "este é um exemplo."

10. **Remoção de Palavras Comuns (Stop-words):** Envolve a eliminação de palavras de alta frequência que contribuem pouco para o significado semântico do texto. As palavras frequentes são palavras comuns que não têm muito significado, como "o", "e" ou "mas". Remover palavras frequentes reduz a dimensionalidade dos dados e melhora a eficiência do classificador.

- **Exemplo (Antes):** "O livro é muito bom."
- **Exemplo (Depois):** "livro bom."

11. **Lematização:** Processo que transforma palavras em suas formas base, utilizando conhecimento lexical em vez de simplesmente cortar as inflexões das palavras.

- **Exemplo (Antes):** Corri para a floresta e vi muitos cervos.
- **Exemplo (Depois):** Correr para a floresta e ver muitos cervo."

12. **Segmentação de Palavras:** A segmentação de palavras é o processo de separar as frases/conteúdos/palavras usadas em uma hashtag, ou seja, #algumtópico é segmentado em duas palavras: algum + tópico.

- **Exemplo (Antes):** "#TendênciasDeTecnologia estão em alta hoje!"
- **Exemplo (Depois):** "Tendências De Tecnologia estão em alta hoje!"

13. **Remoção de Acentuação:** Esta técnica não é incluída no artigo de [Naseem, Razzak e Eklund \(2021\)](#), mas para a língua portuguesa, tem-se uma quantidade significativa de palavras com acento. A remoção de acentuação objetiva normalizar as palavras retirando seus acentos e reduzindo a variabilidade de escrita. Por exemplo, a palavra feijão possui em muitas descrições apenas a escrita feijao que representa a mesma palavra acentuada.

- **Exemplo (Antes):** "Tendências de tecnologia **estão** em alta!"
- **Exemplo (Depois):** "Tendencias de tecnologia **estao** em alta!"

3.2.2 Tokenização

Definição 4 (Tokenização). Tokenização é o processo de dividir um texto em palavras ou tokens individuais. Isso é geralmente feito usando uma combinação de espaços em branco, pontuação e caracteres especiais como delimitadores.

Esta divisão pode ser de diversas formas, a seguir apresenta-se as principais conforme [Naseem, Razzak e Eklund \(2021\)](#).

- **n-grama:** Um n-grama é uma sequência contígua de n itens de um determinado conjunto de texto. O valor de n pode ser ajustado, como por exemplo os 1-grama (também conhecidos como unigramas) capturam palavras individuais, enquanto os 3-gramas (também conhecidos como trigramas) capturam grupos de três palavras consecutivas.
- **Skip-grama:** Um skip-grama é uma variante do modelo n-grama que é utilizada para capturar dependências de longo alcance. Assim como os n-gramas tradicionais, os skip-gramas são sequências de palavras contíguas de um determinado conjunto de texto. No entanto, ao contrário dos n-gramas tradicionais, os skip-gramas permitem "pular" algumas palavras no texto, em vez de exigir que todas as palavras da sequência sejam consecutivas.

A tabela [Tabela 3](#) demonstra uma sequência de aplicação para a descrição "Arroz tio João 1.kg".

3.2.3 Representação Numérica de Palavras

Definição 5 (Representação Numérica). Consiste na transformação de um documento, palavra ou token em um número ou vetor de números.

Técnica	Resultado
Descrição Original	Arroz tio joão 1.kg
Remoção de pontuação	Arroz tio joão 1 kg
Remoção de acentuação	Arroz tio joao 1 kg
Conversão para minúscula	arroz tio joao 1 kg
unigramas	{arroz, tio, joao, 1, kg}
bigramas	{(arroz, tio), (tio, joao), (joao,1),(1,kg)}
1-skip-2-grama	{(arroz, joao), (tio,1), (joao,kg) }

Tabela 3 – Aplicação de técnicas de pré-processamento e tokenização sobre o texto *Arroz tio joão 1.kg*

A forma mais utilizada pelos pesquisadores é a representação de cada palavra ou token como um vetor. A partir deste é possível gerar uma combinação de ponderação ou embutimentos. As próximas seções apresentam as técnicas Sacola de Palavras (Bag of Words - BoW), com sua diversas formas de ponderação: Binária, Frequência de Termos (Term Frequency - TF) e Frequência de Termos ponderada pela Frequência Inversa de Documentos (Term Frequency Inverse Document Frequency-TFIDF).

Modelo Sacola de Palavras (Bag of Words-BoW): Frequência de Termos e Modelo Booleano(Binário)

Uma técnica amplamente adotada para a representação numérica de documentos é o modelo de sacola de palavras ou *textbfBag of Words (BoW)*. Conforme descrito por [Deng et al. \(2019\)](#), neste modelo, um documento é representado por uma lista de pares (s_j, f_j) , onde s_j representa um termo e f_j denota a frequência desse termo no documento d_i . Este modelo simplifica a representação textual ao abstrair a ordem e a estrutura gramatical das palavras, focando apenas na presença e na frequência dos termos. Já para [Zhang, Jin e Zhou \(2010\)](#), envolve atribuir um valor numérico a cada palavra em uma descrição e representar a descrição como um vetor que indica a presença ou ausência de cada palavra, com um valor de 1 indicando a presença da palavra e 0 indicando sua ausência. Este último é conhecido como modelo booleano ou binário.

Exemplo de Sacola de Palavras com Ponderação Binária

Este exemplo demonstra a aplicação dessa técnica nas descrições: "Arroz tio joão 1 kg", "ARROZ FUMACENCE PARB 1KG", "FEIJAO CARIOCA 1KG AZULAO", "Feij 1 Kg Preto Caldão".

As etapas envolvidas são:

1. Remoção de acentos e conversão para minúsculas:

- "Arroz tio joão 1 kg" → "arroz tio joao 1 kg"
- "ARROZ FUMACENCE PARB 1KG" → "arroz fumacence parb 1kg"
- "FEIJAO CARIOCA 1KG AZULAO" → "feijao carioca 1kg azulao"
- "Feij 1 Kg Preto Caldão" → "feij 1 kg preto caldao"

2. Divisão das descrições em tokens (palavras) no formato unigrama:

Número do Type	Type	[1]	[2]	[3]	[4]	[5]
1	1	0	1	0	0	1
2	1kg	0	0	1	1	0
3	arroz	1	1	1	0	0
4	azulao	0	0	0	1	0
5	caldao	0	0	0	0	1
6	carioca	0	0	0	1	0
7	feij	0	0	0	0	1
8	feijao	0	0	0	1	0
9	fumacence	0	0	1	0	0
10	joao	0	1	0	0	0
11	kg	0	1	0	0	1
12	parb	0	0	1	0	0
13	preto	0	0	0	0	1
14	tio	0	1	0	0	0

Tabela 4 – Vocabulário, representação de uma palavra como vetor em [1] e representação das demais descrições em [2],[3],[4] e [5] para "Arroz tio joão 1 kg", "ARROZ FUMACENCE PARB 1KG", "FEIJAO CARIOCA 1KG AZULAO", "Feij 1 Kg Preto Caldão"respectivamente

- Descrição 1: ["arroz", "tio", "joao", "1", "kg"]
- Descrição 2: ["arroz", "fumacence", "parb", "1kg"]
- Descrição 3: ["feijao", "carioca", "1kg", "azulao"]
- Descrição 4: ["feij", "1", "kg", "preto", "caldao"]

3. Criação de um vocabulário com tokens únicos:

- Tokens Distintos: ["arroz", "tio", "joao", "1", "kg", "fumacence", "parb", "1kg", "feijao", "carioca", "azulao", "feij", "preto", "caldao"]

4. Contagem da frequência de cada token nas descrições, tabela [Tabela 4](#).

A representação de cada palavra é um vetor com um 1 na posição correspondente à posição da palavra no vocabulário e 0s em todas as outras posições. Por exemplo, "arroz" seria representado por {1,0,0,0,0,0,0,0,0,0,0,0,0,0}, conforme exemplo na tabela [Tabela 4](#). Para representar uma descrição, esta é pré-processada e tokenizada e, em seguida, cada token é convertido em sua representação vetorial. Finalmente, esses vetores são somados, o que equivale a uma contagem de palavras. Por exemplo, a descrição 'Feijao Preto Caldão Preto 1kg' é representado por {0,0,0,0,0,0,0,0,1,1,0,0,2,1}.

A tabela [Tabela 4](#) pode ser visualizada de maneira transposta, com cada documento ou descrição nas linhas e o vocabulário nas colunas. Esta representação é chamada de matriz termo-documento D , com d_{ij} representando a frequência do termo j no documento i . As dimensões da matriz $|D| \times |V|$ são definidas pelo número de documentos $|D|$ e o número de termos no vocabulário $|V|$.

Devido a alta dimensionalidade do vocabulário uma seleção de atributos é sugerida, [Mironczuk e Protasiewicz \(2018\)](#). [Deng et al. \(2019\)](#) em seu artigo descreve os processos de filtragem e extração de características com o objetivo de identificar atributos que sejam representativos e informativos para as

categorias em foco. Esta abordagem garante que o modelo de classificação minimize a redundância e a esparsidade dos dados, e também melhore sua capacidade de generalização e precisão preditiva.

Para efetuar essa seleção, [Deng et al. \(2019\)](#), técnicas como ganho de informação, TF-IDF (Term Frequency-Inverse Document Frequency) e teste χ^2 são utilizadas para identificar os atributos mais significativos, também chamadas de modelos de filtro. Além da seleção de atributos, técnicas de projeção como Análise Semântica Latente (LSA) e Análise de Componentes Principais (PCA) são empregadas para reduzir a dimensionalidade. Estas técnicas não são objetos de estudo deste trabalho.

Ponderação TF-IDF

O Term Frequency-Inverse Document Frequency (TF-IDF) é uma técnica de ponderação de termos amplamente utilizada em sistemas de recuperação de informações e classificação de texto [Yates e Neto \(2013\)](#). O modelo equilibra a necessidade de identificar termos relevantes em documentos individuais (frequência do termo - TF) e a raridade desses termos em uma coleção de documentos (frequência inversa do documento - IDF).

A frequência do termo (TF) indica quantas vezes um termo aparece em um documento específico, proporcionando uma medida da importância do termo nesse documento. No entanto, para evitar que termos comuns em muitos documentos sejam considerados excessivamente importantes, o modelo TF-IDF utiliza o componente IDF. A frequência inversa do documento (IDF) é calculada como o logaritmo do número total de documentos na coleção dividido pela frequência do documento do termo, ou seja, o número de documentos em que o termo aparece. Matematicamente, o peso TF-IDF de um termo em um documento é expresso como:

$$w_{ij} = tf_{ij} \times \log \left(\frac{|D|}{df_i} \right) \quad (3.1)$$

onde w_{ij} é o peso do termo i no documento j , tf_{ij} é a frequência do termo i no documento j , $|D|$ é o número total de documentos na coleção, e df_i é a frequência do documento do termo i .

Além disso, [Salton e Buckley \(1988\)](#) enfatiza a importância da normalização desses pesos para evitar distorções. A normalização é realizada dividindo o peso TF-IDF de um termo em um documento pela raiz quadrada da soma dos pesos TF-IDF desse documento em todos os termos. A fórmula de normalização é dada por:

$$w'_{ij} = \frac{w_{ij}}{|w_{.j}|} \quad (3.2)$$

onde

$$|w_{.j}| = \sqrt{\sum_i w_{ij}^2} \quad (3.3)$$

representa a norma dos pesos w_{ij} para o documento j , calculada como a raiz quadrada da soma dos quadrados dos pesos TF-IDF de todos os termos i no documento j .

Esta normalização assegura que os termos são ponderados não apenas pela sua frequência e raridade, mas também pela sua importância relativa em toda a coleção de documentos, proporcionando uma avaliação mais precisa e equilibrada da relevância de cada termo.

Exemplo de Aplicação do TF-IDF

Este exemplo aplica a técnica TF-IDF nas descrições anteriormente tratadas na seção "Sacola de Palavras" (veja a Seção 3.2.3). O TF-IDF é calculado com base na frequência do termo em cada descrição e na frequência inversa do documento para cada termo.

As etapas envolvidas são:

1. Utilização das descrições e do vocabulário já processados conforme descrito na Seção 3.2.3.
2. Cálculo dos pesos IDF, w_{ij} e w'_{ij} para cada token nas descrições.

A Tabela 5 exemplifica a implementação do método TF-IDF, partindo das descrições abordadas na seção "Sacola de Palavras". Nesta tabela, observa-se a interação entre a frequência de um termo em uma descrição específica (f_{ij}) e sua frequência inversa em todo o conjunto de documentos (IDF), resultando no peso TF-IDF (w_{ij}) de cada termo. É possível observar que palavras como "arroz", "1", "kg" e "1kg", que aparecem em mais de uma descrição, têm sua importância diminuída pelo componente IDF, refletindo a perda de força destes termos comuns. A normalização aplicada, resultando no valor w'_{ij} , ajusta o peso TF-IDF baseado na norma dos pesos dos termos do documento. No contexto deste trabalho, onde as descrições de produtos são tipicamente curtas, esta normalização não influencia significativamente a análise individual de cada descrição. Portanto, embora a normalização seja um passo relevante, seu impacto é menos pronunciado em análises de descrições curtas, mantendo a eficácia do modelo TF-IDF em contextos de processamento de linguagem natural aplicado a descrições de produtos.

Código	Type	IDF	[1]	[2]	[3]	[4]
			$f_{ij} w_{ij} w'_{ij}$	$f_{ij} w_{ij} w'_{ij}$	$f_{ij} w_{ij} w'_{ij}$	$f_{ij} w_{ij} w'_{ij}$
0	1	0.69	1 0.69 0.30	0 0.00 0.00	0 0.00 0.00	1 0.69 0.27
1	1kg	0.69	0 0.00 0.00	1 0.69 0.32	1 0.69 0.28	0 0.00 0.00
2	arroz	0.69	1 0.69 0.30	1 0.69 0.32	0 0.00 0.00	0 0.00 0.00
3	azulao	1.39	0 0.00 0.00	0 0.00 0.00	1 1.39 0.55	0 0.00 0.00
4	caldao	1.39	0 0.00 0.00	0 0.00 0.00	0 0.00 0.00	1 1.39 0.53
5	carioca	1.39	0 0.00 0.00	0 0.00 0.00	1 1.39 0.55	0 0.00 0.00
6	feij	1.39	0 0.00 0.00	0 0.00 0.00	0 0.00 0.00	1 1.39 0.53
7	feijao	1.39	0 0.00 0.00	0 0.00 0.00	1 1.39 0.55	0 0.00 0.00
8	fumacence	1.39	0 0.00 0.00	1 1.39 0.63	0 0.00 0.00	0 0.00 0.00
9	joao	1.39	1 1.39 0.60	0 0.00 0.00	0 0.00 0.00	0 0.00 0.00
10	kg	0.69	1 0.69 0.30	0 0.00 0.00	0 0.00 0.00	1 0.69 0.27
11	parb	1.39	0 0.00 0.00	1 1.39 0.63	0 0.00 0.00	0 0.00 0.00
12	preto	1.39	0 0.00 0.00	0 0.00 0.00	0 0.00 0.00	1 1.39 0.53
13	tio	1.39	1 1.39 0.60	0 0.00 0.00	0 0.00 0.00	0 0.00 0.00
$ w_{.j} $			2.30	2.19	2.50	2.59

Tabela 5 – Análise TF-IDF das descrições "Arroz tio joão 1 kg", "ARROZ FUMACENCE PARB 1KG", "FEIJAO CARIOCA 1KG AZULAO", e "Feij 1 Kg Preto Caldão". A tabela mostra a frequência de termos (f_{ij}), o peso TF-IDF (w_{ij}) e o peso normalizado TF-IDF (w'_{ij}) para cada termo nas descrições.

3.2.4 Modelos de Projeção - Redução de Dimensionalidade

A projeção de características é uma parte opcional na classificação de texto, onde algoritmos como Análise de Componentes Principais (PCA), Decomposição de Valor Singular (SVD) e Alocação Latente de Dirichlet (LDA) são frequentemente utilizados. Esses métodos são empregados para reduzir a dimensionalidade dos dados, mantendo ao mesmo tempo as características mais relevantes para a classificação. A PCA é uma técnica estatística que transforma os dados originais em um conjunto de valores de componentes principais linearmente descorrelacionados. A SVD, por outro lado, decompõe uma matriz em três outras matrizes, capturando a essência dos dados. A LDA é um modelo generativo que permite explicar conjuntos de observações por meio de grupos não observados que explicam por que algumas partes dos dados são semelhantes. A utilização dessas técnicas de projeção ajuda a melhorar a eficiência e a precisão dos modelos de classificação de texto, permitindo que eles lidem melhor com a alta dimensionalidade e a complexidade dos dados textuais [Mirończuk e Protasiewicz \(2018\)](#). Detalha-se a seguir a técnica de Análise Semântica Latente (LSA) devido a sua significativa relevância na literatura. [Pu e Yang \(2006\)](#).

Análise Semântica Latente (LSA)

A Análise Semântica Latente (LSA) é uma técnica para a geração automática de conceitos e análise da coocorrência de termos, útil para a classificação de texto e recuperação de informações [Pu e Yang \(2006\)](#). Baseando-se na decomposição em valores singulares (SVD), a LSA permite a construção de uma matriz de documento reduzida, A , que mantém apenas as informações mais cruciais da matriz de documento original. A representação matemática da LSA é dada por:

$$A = TSD^T \quad (3.4)$$

Nesta fórmula, T e D são compostos por vetores ortogonais, enquanto S é uma matriz diagonal de valores singulares. Os autovetores com os maiores valores singulares capturam os eixos de maior variação nos dados, permitindo a projeção de cada documento em um espaço de dimensionalidade inferior. Este processo de redução de dimensionalidade permite diminuir o ruído nos dados e evitar o sobreajuste.

A utilização da LSA na classificação de textos (TC) facilita a identificação de padrões e temas subjacentes, que podem não ser diretos em análises textuais diretas. Ao focar nas características mais significativas dos documentos através da redução da dimensionalidade, a LSA melhora a eficácia dos algoritmos de classificação e recuperação de informações.

3.2.5 Word Embeddings

Word embeddings (a tradução é incorporação ou embutimento, para fins subsequentes é mantido o original em inglês), é uma abordagem que transforma palavras em vetores de números reais, permitindo que palavras com contextos semelhantes sejam correlacionadas. Embora os primeiros métodos, como one-hot encoding, oferecessem representações básicas, a evolução para técnicas mais avançadas permitiu a captura de relações semânticas e das semelhanças entre as palavras. É seguido aqui a abordagem de

[Birunda e Devi \(2021\)](#). Os embeddings são categorizados em três tipos principais: Tradicional, Estático e Contextualizado.

Os embeddings tradicionais foram apresentados nas seções anteriores. Cita-se aqui apenas as vantagens e desvantagens. Essas abordagens têm limitações, como a falta de representação das relações semânticas entre palavras e a necessidade de grande capacidade de memória.

Word Embedding Estática

Os Embeddings Estáticos, como Word2Vec, GloVe e Fast Text, oferecem representações fixas que não variam com o contexto. Eles representam uma evolução em relação a métodos anteriores, fornecendo probabilidades às palavras e mapeando-as em vetores densos. Esses métodos são estáticos no sentido de que mantêm a mesma representação independentemente do contexto. A tabela [Tabela 6](#), adaptada de [Birunda e Devi \(2021\)](#), apresenta para Word2Vec, GloVe e Fast Text uma breve descrição, vantagens e desvantagens.

Modelo	Descrição	Vantagens	Desvantagens
Word2Vec	Gera embedding de palavras usando representação densa.	Transforma um corpus não rotulado em dados rotulados mapeando a palavra para um contexto.	Não utiliza informações globais;
GloVe	Modelo baseado em contagem e não supervisionado para gerar vetores de palavras.	Baseia-se em informações de contexto local e estatísticas globais (co-ocorrência de palavras); pode derivar relações semânticas.	Dependente da matriz de co-ocorrência; requer mais memória para armazenamento.
Fast Text	Extensão do Word2Vec que identifica palavras como n-gramas de caracteres.	Fornece representação vetorial eficiente de palavras raras e fragmentos de palavras.	Não adiciona informações contextuais.

Tabela 6 – Comparação de Modelos de Embedding Estático

Embedding Contextualizado

Os Embeddings Contextualizados, como ELMo, GPT-2 e BERT, oferecem representações dinâmicas que variam com base no contexto. Eles são capazes de capturar nuances contextuais e semânticas, oferecendo múltiplos embeddings para uma única palavra. Tais modelos têm demonstrado um bom desempenho em uma variedade de tarefas de NLP. A tabela [Tabela 7](#), retirado de [Birunda e Devi \(2021\)](#) apresenta para ELMo, GPT-2 e BERT uma breve descrição, vantagens e desvantagens.

3.3 Técnicas para Classificação de Texto

Na parte um é apresentada uma adaptação da teoria de recuperação da informação para a classificação de produtos. Na seção dois é apresentada as principais técnicas de Machine Learning. Na seção três as técnicas de redes neurais.

Modelo	Descrição	Vantagens	Desvantagens
ELMo	Embedding context-dependent e baseado em caracteres.	Fornecer múltiplos embeddings de palavras para uma única palavra.	Bidirecional superficial, não pode aproveitar contextos à esquerda e à direita simultaneamente.
GPT-2	Transformer que prediz a próxima palavra observando partes de uma frase.	Pode prever a próxima palavra e oferecer várias possíveis previsões com pontuação de probabilidade.	Requer grande capacidade de computação; pode criar informações falsas, pois é treinado em milhões de sites.
BERT	Sistema bidirecional não supervisionado com um codificador Transformer multicamada.	Aprende as relações contextuais entre palavras ou subpalavras; contém significados sintáticos e semânticos; pode fazer suposições para a palavra em branco.	Limitado a lidar com frases de comprimento mínimo.

Tabela 7 – Comparação de Modelos de Embedding Contextualizado

Classificação de Texto a partir da Função de Ordenação da Recuperação da Informação

A recuperação da informação (RI) concentra-se em localizar e prover informações pertinentes em resposta a consultas específicas. Sua aplicação tem sido aplicada em sistemas de busca, como os encontrados na web, e no gerenciamento de grandes repositórios de documentos.

Uma formulação formal da RI foi proposta por [Yates e Neto \(2013\)](#), definindo um modelo de RI como uma quádrupla $[D, Q, \mathcal{F}, R(q_i, d_j)]$, onde:

1. D representa um conjunto de documentos de uma coleção.
2. Q compreende as representações das necessidades de informação dos usuários, denominadas consultas.
3. $\mathcal{F}$ fornece a estrutura para modelar tanto os documentos quanto as consultas e suas inter-relações, utilizando-se de conjuntos, relações booleanas, vetores e operações de álgebra linear, bem como espaços amostrais e distribuições de probabilidade.
4. $R(q_i, d_j)$ é uma função de ranqueamento que atribui um valor real a cada par formado por uma consulta q_i e um documento d_j , estabelecendo uma ordenação dos documentos em face da consulta q_i .

Como ilustrado na Figura 6, o modelo de recuperação de informação recebe um consulta, converte para uma representação numérica e para cada documento aplica uma função de ordenação.

Adaptação da Recuperação da Informação para Classificação

Neste estudo realizou-se uma adaptação da definição tradicional de RI ao contexto de classificação de produtos. O elemento essencial é o conjunto de descrições (ainda não rotulada). Na sequência define-se um conjunto de classes. Aplica-se uma função de mapeamento, tornando um conjunto de descrições de




Figura 6 – Modelo de recuperação de informação representando a interação entre consulta, documentos e a função de ranqueamento.

produtos em classes (documentos), comumente executada por intervenção humana. De forma a retornar para a definição do modelo tradicional de RI.

A RI, no domínio da classificação de produtos, foi reformulada como uma sêxtupla $(X, Y, \mathcal{M}, Q, R, \mathcal{C})$, na qual:

- X é um conjunto de representações das descrições dos produtos.
- Y abrange um conjunto de classes previamente definidas.
- $\mathcal{M} : X \rightarrow Y$ descreve a função de mapeamento que associa descrições de produtos a suas respectivas classes a priori.
- Q compreende as descrições de produto a classificar.
- $\mathcal{C} : X \rightarrow Y$ descreve a função de mapeamento que associa descrições de produtos a suas respectivas classes a posteriori, ou classificador.

Conforme mostrado na Figura 7, a adaptação do modelo de recuperação de informação para a classificação de produtos é ilustrada. Este modelo expande a interação tradicional entre consultas e documentos para incluir uma etapa adicional de mapeamento para classes de produtos.




Figura 7 – Adaptação do modelo de RI para classificação de produtos, incorporando a etapa de mapeamento para classes.

No modelo tradicional de Recuperação da Informação (RI), o foco principal é na busca e ordenação de documentos em resposta a consultas específicas. Essa abordagem é bem representada pela função $R(q_i, d_j)$, que avalia a relevância de um documento d_j em relação a uma consulta q_i . Este modelo é amplamente utilizado em motores de busca e sistemas de gerenciamento de informações, onde a prioridade é encontrar a melhor correspondência possível para as consultas dos usuários dentro de um vasto conjunto de documentos.

Em contraste, a adaptação do modelo de RI para a classificação de produtos se concentra na categorização de descrições de produtos em classes predefinidas. Esta adaptação introduz a função $\mathcal{C} : X \rightarrow Y$, onde $\mathcal{C}$ é responsável pelo mapeamento da ordenação em sua classe correspondentes.

Diferenças entre os dois modelos incluem:

- No modelo tradicional de RI, a ordenação dos documentos é a principal operação, enquanto na adaptação para classificação de produtos, o foco é na posterior categorização das descrições.
- A função $\mathcal{M}$ no modelo adaptado serve como uma etapa de treinamento para um classificador, onde descrições de produtos são mapeadas em categorias conhecidas, diferentemente do modelo de RI que não possui uma etapa equivalente. Esta função tem o objetivo de agrupar as descrições com classes similares e gera os "documentos".
- A função $\mathcal{C}$, é utilizada para classificação ao invés de recuperação de documentos..

Na RI, tem-se alguns conceitos que serão necessários introduzir. O primeiro é a matriz termo-documento. O segundo refere-se a ao conceito de similaridade de documentos.

3.3.1 Matriz Termo-Documento

A matriz termo-documento é um conceito da teoria da Recuperação da Informação (RI). Ela representa uma forma de modelar as informações contidas em uma coleção de documentos de forma a facilitar a recuperação de informações relevantes.

Definição 6. A matriz termo-documento é uma matriz que relaciona os termos (palavras, frases, etc.) com os documentos em uma coleção. Cada linha da matriz representa um termo, e cada coluna representa um documento. Os elementos da matriz, a_{ij} , pode ser uma indicação binária (presença/ausência do termo), uma contagem de frequência (quantas vezes o termo aparece no documento), ou outras medidas como TF-IDF (Term Frequency-Inverse Document Frequency), dependendo do modelo de RI adotado em relação a combinação do termo t_i no documento d_j .

A representação genérica de uma matriz termo-documento é dada por:

$$A_{|V| \times |D|} = \begin{matrix} & \begin{matrix} d_1 & d_2 & \cdots & d_j \end{matrix} \\ \begin{matrix} t_1 \\ t_2 \\ \vdots \\ t_i \end{matrix} & \begin{bmatrix} t_{11} & t_{12} & \cdots & t_{1j} \\ t_{21} & t_{22} & \cdots & t_{2j} \\ \vdots & \vdots & \ddots & \vdots \\ t_{i1} & t_{i2} & \cdots & t_{ij} \end{bmatrix} \end{matrix} \quad (3.5)$$

A matriz termo-documento A , tem suas dimensões definidas pelo tamanho do vocabulário e pela quantidade de documentos na coleção. Se $|V|$ representa o número total de termos únicos no vocabulário e $|D|$ denota o número de documentos ou classes na coleção, então a matriz A é dimensionada como $|V| \times |D|$. Nesta matriz, cada linha representa um vetor no espaço de documentos, correspondendo a uma

palavra específica do vocabulário. Cada elemento dessa linha indica a presença ou a frequência dessa palavra em um documento específico. Analogamente, cada coluna de A pode ser interpretada como um vetor no espaço de palavras, representando um documento ou classe específico.

Exemplo de Matriz Termo-Documento com Múltiplas Representações

Este exemplo ilustra a aplicação da técnica de "sacola de palavras" nas descrições das classes ARROZ e FEIJÃO, empregando três diferentes representações textuais: frequência de termos, TF-IDF e TF-IDF normalizado. As etapas envolvidas são:

1. Junção das descrições por classe, remoção de acentos e conversão para minúsculas:
 - Classe ARROZ: "Arroz tio João 1 kg" e "ARROZ FUMACENCE PARB 1KG" → "arroz tio João 1 kg arroz fumacence parb 1kg"
 - Classe FEIJÃO: "FEIJAO CARIOCA 1KG AZULAO" e "Feij 1 Kg Preto Caldão" → "feijao carioca 1kg azulao feij 1 kg preto caldao"
2. Divisão das descrições em tokens e criação de um vocabulário único.
3. Utilização de técnicas de vetorização para gerar representações baseadas em frequência, TF-IDF e TF-IDF normalizado.

A matriz termo-documento A é representada na tabela [Tabela 8](#). Nesta matriz, as primeiras duas colunas mostram a frequência dos termos nas classes ARROZ e FEIJÃO, as próximas duas colunas exibem os valores TF-IDF, e as últimas duas colunas apresentam os valores TF-IDF normalizados.

Tabela 8 – Matriz termo-documento com representações de frequência, TF-IDF e TF-IDF normalizado.

Método Termo	Frequência		TF-IDF		TF-IDF Normalizado	
	ARROZ	FEIJÃO	ARROZ	FEIJÃO	ARROZ	FEIJÃO
1	1	1	0.23	0.26	0.09	0.09
1kg	1	1	0.23	0.26	0.09	0.09
arroz	2	0	0.65	0.00	0.25	0.00
azulao	0	1	0.00	0.36	0.00	0.12
caldao	0	1	0.00	0.36	0.00	0.12
carioca	0	1	0.00	0.36	0.00	0.12
feij	0	1	0.00	0.36	0.00	0.12
feijao	0	1	0.00	0.36	0.00	0.12
fumacence	1	0	0.32	0.00	0.12	0.00
joao	1	0	0.32	0.00	0.12	0.00
kg	1	1	0.23	0.26	0.09	0.09
parb	1	0	0.32	0.00	0.12	0.00
preto	0	1	0.00	0.36	0.00	0.12
tio	1	0	0.32	0.00	0.12	0.00

(3.6)

Dentro da matriz termo-documento A , as descrições das classes ARROZ e FEIJÃO são representadas como vetores coluna. Cada vetor coluna encapsula a frequência dos termos do vocabulário dentro de uma classe específica. Por exemplo, o vetor coluna para a classe ARROZ é representado por $\{1, 1, 2, 0, 0, 0, 0, 0, 1, 1, 1, 1, 0, 1\}$, onde cada elemento corresponde à frequência de um termo específico do vocabulário na descrição de ARROZ. De maneira similar, o vetor para a classe FEIJÃO é $\{1, 1, 0, 1, 1, 1, 1, 1, 0, 0, 1, 0, 1, 0\}$.

O próximo passo é representar uma nova descrição como vetor.

Representação de Uma Descrição como Vetor

Nesta seção, é descrito o processo pelo qual uma descrição de produto é transformada em um vetor para análise e processamento. As etapas realizadas são as seguintes:

- **Preparação da Descrição:** É realizada a normalização da descrição, que inclui a remoção de acentos e a conversão do texto para minúsculas.
- **Tokenização:** A descrição normalizada é então tokenizada, dividindo-a em palavras individuais. Palavras que não têm representação no vocabulário pré-definido, conhecidas como "out of vocabulary", são descartadas.
- **Conversão para Vetor de Frequência:** A descrição tokenizada é convertida em um vetor de frequência. Este vetor indica a presença e a frequência de cada termo do vocabulário na descrição.
- **Exemplo de Conversão:** Para a descrição "Arroz tio joão 1 kg Tipo II", após a normalização e tokenização, obtêm-se os tokens: ["arroz", "tio", "joao", "1", "kg", "tipo", "ii"]. Tokens que são considerados "out of vocabulary", como "tipo" e "ii", são excluídos. O vetor resultante, dada a presença dos termos no vocabulário, pode ser expresso como $\{1, 0, 1, 0, 0, 0, 0, 0, 1, 1, 0, 0, 1\}$, representando a frequência de cada termo do vocabulário na descrição.

A transformação de descrições textuais em vetores numéricos facilita a aplicação de técnicas de processamento de linguagem natural e aprendizado de máquina em dados textuais.

As descrições, as classes e o mapeamento a priori são entradas do modelo. As conversões para representação numérica, função de ranqueamento e classificadores são definições.

A representação numérica foi definida na 3.2.3. Aqui é definido a matriz termo-documento.

Agora se faz necessário, a partir da consulta e da matriz termo documento definir a função ordenação e por conseguinte o conceito de similaridade. Este define como encontrar um documento que mais se aproxima da consulta do usuário. Para o caso da classificação é como encontrar a categoria que contém a maior similaridade com a descrição.

Similaridade

O conceito de similaridade se refere ao grau de semelhança ou sobreposição entre dois ou mais documentos. Existem várias medidas de similaridade propostas na literatura, incluindo distância

euclidiana, coeficiente de Jaccard, correlação de Pearson, Similaridade Cosseno, distância de Hamming, coeficiente de Dice, IT-Sim, SMTP, distância do movimento da terra, divergência de Kullback-Leibler e BM25, Deng *et al.* (2019). A seguir apresenta-se as duas mais relevantes para este trabalho, similaridade de cosseno e distância euclidiana.

Similaridade de Cosseno

A similaridade de Cosseno mede o cosseno do ângulo entre dois vetores no espaço vetorial. É definida como:

$$\text{Similaridade de Cosseno}(u, v) = \frac{\sum_{i=1}^n u_i \cdot v_i}{\sqrt{\sum_{i=1}^n u_i^2} \cdot \sqrt{\sum_{i=1}^n v_i^2}} \quad (3.7)$$

onde u e v são dois vetores.

Exemplo de Aplicação da Similaridade de Cosseno para a Tarefa de Classificação

Ilustra-se a seguir um exemplo da aplicação da similaridade de cosseno na tarefa de classificação de textos utilizando-se os dados das seções anteriores. Especificamente, analisa-se a descrição de produto, “Arroz tio João 1 kg”, representada pelo vetor de frequência $v = [1, 0, 1, 0, 0, 0, 0, 0, 1, 1, 0, 0, 1]$. As categorias ARROZ e FEIJÃO são representadas pelos vetores de frequência (aqui pode-se utilizar qualquer representação tanto para a descrição quanto para as categorias):

$$ARROZ = [1, 1, 2, 0, 0, 0, 0, 0, 1, 1, 1, 0, 1]$$

$$FEIJAO = [1, 1, 0, 1, 1, 1, 1, 1, 0, 0, 1, 0, 1, 0]$$

.

A similaridade de cosseno entre o vetor v e cada vetor de categoria é calculada da seguinte forma:

- **Para ARROZ:** A similaridade é dada por $\frac{u \cdot ARROZ}{\|u\| \|ARROZ\|}$, resultando em:

$$\frac{6}{\sqrt{5} \cdot \sqrt{12}} \approx 0.775$$

- **Para FEIJÃO:** A similaridade é dada por $\frac{u \cdot FEIJAO}{\|u\| \|FEIJAO\|}$, resultando em:

$$\frac{3}{\sqrt{5} \cdot \sqrt{7}} \approx 0.507$$

Os cálculos revelam uma similaridade de aproximadamente 0.775 com a categoria ARROZ e 0.507 com a categoria FEIJÃO. Esses resultados indicam uma maior afinidade do rótulo “Arroz tio João 1 kg” com a categoria ARROZ, demonstrando a utilidade da similaridade de cosseno na classificação de descrições de produtos em categorias relevantes.

Distância Euclidiana

A distância Euclidiana é a "distância ordinária" entre dois pontos no espaço Euclidiano. Para dois pontos A e B , é calculada como:

$$\text{Distância Euclidiana}(A, B) = \sqrt{\sum_{i=1}^n (a_i - b_i)^2} \quad (3.8)$$

onde a_i e b_i são as coordenadas dos pontos A e B .

De acordo com Strehl et al., apud [Deng et al. \(2019\)](#), foi conduzida uma comparação experimental entre várias medidas de similaridade para categorização de texto. Eles mostraram que a distância euclidiana (métrica L2) tem o pior desempenho, enquanto Cosseno e Jaccard são os melhores na tarefa de categorização.

Isso sugere que a escolha da medida de similaridade depende da aplicação específica e das características dos dados analisados. Para este trabalho é utilizado a similaridade cosseno, devido a sua recomendação por simplicidade e eficiência.

3.4 Argmax da Similaridade de Vetores - Similaridade Lexical

Os métodos baseados em argmax para classificação de texto envolvem calcular a similaridade entre um vetor de consulta, representando o texto a ser classificado, e um conjunto de vetores de documento, representando as categorias ou classes. A classe atribuída é aquela cujo vetor de documento tem a maior similaridade (conforme calculado por uma métrica específica, como o produto interno) com o vetor de consulta.

Argmax Ax

Este modelo agrupa descrições de uma categoria e as vetoriza utilizando alguma técnica de ponderação, gerando a matriz termo documento A , sendo as consideradas neste trabalho, binária (B), frequência de termos (TF) e TFIDF.. Isso gera a matriz A com dimensão $|V| \times |D|$, onde $|V|$ é o tamanho do vocabulário e $|D|$ é o número de documentos ou categorias. O vetor x é a sacola de palavras da descrição x e tem dimensão $(V, 1)$. Assim, a multiplicação abaixo tem a dimensão $(D, V) \times (V, 1)$, que fornece um vetor de dimensão D , ou seja, o número de termos similares na descrição com a categoria. Esta multiplicação pode ser visualizada como a similaridade a partir dos cosseno sem a normalização. A entrada do vetor com o maior valor corresponde a categoria mais similar a descrição, vetor x fornecido, [3.9](#).

$$\text{Categoria} = \text{argmax}(A^T x) \quad (3.9)$$

Argmax Ax Normalizada

Os mesmos comentários são válidos para este modelo com a diferença que o vetor " A " é normalizado por coluna. Onde o elemento A representa um vetor de linha com as normas das colunas de

"A" sendo o divisor de cada coluna de "A", 3.10. Neste caso o vetor x também é normalizado e o resultado passa a ser a similaridade cosseno do vetor x com a categoria.

$$Categoria = \operatorname{argmax}_i \left(\frac{A_i^T}{A_i} x \right) \quad (3.10)$$

3.5 Técnicas Supervisionadas Aplicadas a Classificação de Textos

A classificação supervisionada de textos é uma tarefa de aprendizado de máquina que envolve treinar um classificador em um conjunto de dados rotulados de textos, onde o rótulo indica a classe ou categoria a qual cada texto pertence. O objetivo é usar o classificador treinado para prever o rótulo de classe de novos textos não vistos.

A seguir apresenta-se alguns artigos com suas técnicas avaliadas fornecido pela tabela [Tabela 9](#).

Tabela 9 – Resumo das principais técnicas de classificação de texto de algumas revisões de literatura
[1] [Aggarwal, Singh e Gupta \(2018\)](#), [2] [Bhavani e Kumar \(2021\)](#), [3] [Gasparetto et al. \(2022\)](#), [4] [Kowsari et al. \(2019\)](#)

Ref.	Técnicas e Conteúdo Resumido
[1]	Revisa técnicas de classificação de texto, incluindo árvores de decisão (DT), Naive Bayes (NB), k vizinhos mais próximos (KNN), e máquinas de vetores de suporte (SVM), abordando seleção de características e classificadores para grandes volumes de texto. Sugere métodos semi-supervisionados e baseados em ontologia.
[2]	Revisa os algoritmos de classificação de texto, destacando pré-processamento, extração de características, classificação e avaliação. Enfatiza a eficácia do SVM e modelos de aprendizado profundo, como CNN e RNN.
[3]	Revisa a evolução dos algoritmos de classificação de texto, destacando a transição do aprendizado raso para técnicas avançadas de deep learning, focando na transformação de texto para melhorar as previsões e na importância de conjuntos de dados e pré-processamento adequados. Destaca modelos gráficos probabilísticos (PGMs), que inclui NB, KNN, SVM, DT, Regressão Logística (LR), Florestas aleatórias (RF) e Modelos Ensembles, apresentando vantagens e desvantagens.
[4]	Destaca a necessidade de métodos avançados de aprendizado de máquina para a classificação de texto em diversas aplicações, abordando extração de características, redução de dimensionalidade, algoritmos de classificação e métodos de avaliação. Oferece uma visão abrangente de técnicas, incluindo aprendizado profundo, destacando a importância de conjuntos de dados e pré-processamento adequados. Apresenta modelos como Rocchio, Boosting, Bagging, LR, NB, KNN, SVM, DT, RF e aprendizado profundo.

Com base nestes trabalhos e sua avaliação de inúmeros artigos, é definido como escopo os mais utilizados, a saber Naive Bayes, Regressão Logística, Máquinas de Vetores de Suporte, Árvore de Decisão e K Vizinhos Mais Próximos.

3.5.1 Naive Bayes

O Naive Bayes é reconhecido por sua eficácia na classificação de textos, aproveitando-se de sua simplicidade e rapidez. Este classificador probabilístico baseia-se no Teorema de Bayes, operando com a suposição de independência entre as características dos documentos. Apesar de suas suposições simplistas, demonstra eficiência em uma variedade de aplicações de classificação de texto, sendo aplicável em cenários que vão desde a filtragem de spam até a categorização de documentos. A fórmula fundamental do Naive Bayes é dada por:

$$P(C|X) = \frac{P(X|C)P(C)}{P(X)} \quad (3.11)$$

onde $P(C|X)$ representa a probabilidade posterior de uma classe C dado um vetor de características X , enfatizando a capacidade do método em atribuir probabilidades condicionais de forma eficiente a documentos não previamente vistos.

Diferentes variantes do Naive Bayes são adequadas para diversos tipos de distribuição de dados, incluindo Gaussiano para dados com distribuição normal, Multinomial para dados discretos, Bernoulli para características binárias e a estimação de parâmetros semissupervisionada, que utiliza dados rotulados e não rotulados. Essas variantes expandem a aplicabilidade do Naive Bayes em uma ampla gama de tarefas de classificação de textos.

As vantagens do Naive Bayes incluem não apenas sua eficiência e simplicidade de implementação, mas também sua adequação para lidar com grandes volumes de dados. Contudo, é importante reconhecer suas limitações, como a forte presunção sobre a distribuição dos dados e a dependência da disponibilidade de dados para a estimação de valores de probabilidade. Apesar dessas limitações, o Naive Bayes mantém-se como uma opção para a classificação de textos, como evidenciado por sua ampla utilização e discussão em literaturas relevantes [Gasparetto et al. \(2022\)](#), [Aggarwal e Zhai \(2012\)](#), [Kowsari et al. \(2019\)](#).

3.5.2 K Vizinhos Mais Próximos (KNN)

K Vizinhos mais próximos, em inglês K-Nearest Neighbors (KNN), é um método não paramétrico amplamente utilizado em aprendizado de máquina para classificação e regressão [Kowsari et al. \(2019\)](#). Este algoritmo baseia-se no princípio de que instâncias similares estão próximas no espaço de características, permitindo a classificação ou previsão de novas instâncias a partir da análise da proximidade com instâncias previamente conhecidas, [Cover e Hart \(1967\)](#). O KNN determina o rótulo de uma nova instância por meio da agregação dos rótulos de seus k vizinhos mais próximos, utilizando uma medida de distância para calcular essa proximidade.

Uma fórmula generalizada para calcular a distância é dada pela distância de Minkowski, que é versátil o suficiente para abranger várias outras métricas através da variação de seu parâmetro p :

$$d(x, y) = \left(\sum_{i=1}^n |x_i - y_i|^p \right)^{1/p} \quad (3.12)$$

Dependendo do valor de p , a distância de Minkowski pode representar:

- $p = 1$: Distância de Manhattan, que soma as diferenças absolutas das coordenadas.
- $p = 2$: Distância Euclidiana, oferecendo a distância mais direta entre dois pontos no espaço.
- $p \neq 1, 2$: Distância de Minkowski Geral, permitindo uma gama de cálculos de distância que podem ser adaptados às especificidades dos dados.
- Distância de Hamming: Embora não seja um caso específico da distância de Minkowski, a distância de Hamming vale a pena mencionar, pois mede o número de posições nas quais os elementos correspondentes são diferentes, particularmente útil para dados categóricos.

A seleção apropriada de p e, conseqüentemente, da métrica de distância impacta diretamente o desempenho da classificação ou regressão do KNN pelo fato de modificar como a similaridade entre instâncias é calculada [Deza e Deza \(2009\)](#).

A eficácia do KNN é influenciada pela escolha do número de vizinhos k , com um valor muito baixo podendo levar a classificações altamente sensíveis ao ruído e classes desbalanceadas, enquanto um valor muito alto pode suavizar demais as fronteiras de decisão entre as classes. [Bhavani e Kumar \(2021\)](#) destacam a importância da seleção cuidadosa de k , assim como a necessidade de ponderar a contribuição dos vizinhos com base na distância, para melhorar a precisão da classificação. Uma forma sugerida é atribuir pesos inversamente proporcionais à distância.

O KNN é particularmente valorizado pela sua simplicidade e pela eficácia em uma ampla gama de tarefas de classificação e regressão, embora o seu desempenho possa ser comprometido em conjuntos de dados com alta dimensionalidade ou quando a distribuição das classes é desbalanceada. [Kowsari et al. \(2019\)](#) destaca como aspecto negativo a alto custo computacional, dificuldade em encontrar um bom valor para k e o problema da maldição da dimensionalidade. Isto pode ser explicado pela necessidade do KNN de computar distâncias para todas as instâncias de treinamento antes de fazer uma previsão, sendo um problema para grandes conjuntos de dados e sua eficácia diminui em espaços de alta dimensão, pois o conceito de proximidade se torna menos significativo, complicando a tarefa de identificar os verdadeiros vizinhos mais próximos, [Hastie, Tibshirani e Friedman \(2009\)](#).

3.5.3 Máquinas de Vetores de Suporte

Máquinas de Vetores de Suporte, em inglês Support Vector Machine (SVMs), tem sua origem no trabalho de Vladimir Vapnik e Alexey Chervonenkis no início dos anos 1960, culminando no artigo seminal de Cortes e Vapnik (1995), [Cortes e Vapnik \(1995\)](#), que introduziu formalmente as máquinas de vetores de suporte. A ideia central por trás da SVM é identificar um hiperplano que maximize a margem entre diferentes classes, onde a margem é definida como a distância entre o hiperplano e o ponto mais próximo de cada classe.

Na sua forma mais simples, uma SVM linear busca um hiperplano definido pela equação:

$$f(x) = \mathbf{w} \cdot \mathbf{x} + b = 0$$

onde $\mathbf{w}$ é o vetor de peso, $\mathbf{x}$ é o vetor de características de entrada, e b é o termo de viés. A função de decisão que classifica os dados de entrada é então dada por:

$$\text{senal}(f(x)) = \text{senal}(\mathbf{w} \cdot \mathbf{x} + b)$$

O problema de otimização para encontrar $\mathbf{w}$ e b envolve minimizar $\frac{1}{2}\|\mathbf{w}\|^2$ sujeito à restrição de que todos os pontos de dados sejam corretamente classificados, ajustados por variáveis de folga ξ_i para casos não linearmente separáveis, levando à introdução do parâmetro de penalidade C na função objetivo.

Truque do Kernel:

O truque do kernel, um conceito popularizado por Boser, Guyon e Vapnik (1992), [Boser, Guyon e Vapnik \(1992\)](#), permite que as SVMs construam fronteiras não-lineares mapeando implicitamente características de entrada em espaços de alta dimensão. Em vez de calcular o produto escalar $\mathbf{x}_i \cdot \mathbf{x}_j$ diretamente neste espaço de alta dimensão, uma função de kernel $K(\mathbf{x}_i, \mathbf{x}_j)$ é usada, onde as escolhas comuns incluem:

- **Kernel Linear:** $K(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i \cdot \mathbf{x}_j$
- **Kernel Polinomial:** $K(\mathbf{x}_i, \mathbf{x}_j) = (\gamma \mathbf{x}_i \cdot \mathbf{x}_j + r)^d$
- **Função de Base Radial (RBF):** $K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$

Regularização e Complexidade do Modelo:

O equilíbrio entre a maximização da margem e a minimização do erro de treinamento é controlado pelo parâmetro de penalidade C , introduzido no objetivo de otimização como:

$$\min_{\mathbf{w}, b} \left\{ \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \right\}$$

Valores mais altos de C concentram-se em reduzir os erros de classificação, potencialmente levando ao sobreajuste, enquanto um C menor promove uma margem maior e possivelmente um erro de generalização mais elevado.

As Máquinas de Vetores de Suporte (SVM), conforme [Kowsari et al. \(2019\)](#) são capazes de modelar fronteiras de decisão não lineares e se destacam na separação linear, sendo robustas contra o overfitting em espaços de alta dimensão. No entanto, enfrentam desafios como a falta de transparência nos resultados, a dificuldade na escolha de funções de kernel eficientes e a complexidade de memória. [Bhavani e Kumar \(2021\)](#) destacam o SVM como um dos algoritmos de aprendizado de máquina supervisionado mais efetivos para classificação, ressaltando sua precisão em espaços de alta dimensão e a eficácia na separação de diferentes classes.

3.5.4 Árvore de Decisão

Árvores de decisão são uma técnica em aprendizado de máquina que modela decisões como uma estrutura em forma de árvore. Esta estrutura consiste de um nó raiz, nós de decisão e nós folha, onde cada

nó interno representa um teste em um atributo, os ramos representam o resultado do teste, e cada nó folha representa um rótulo de classe ou resultado de decisão. Este método simplifica o processo de tomada de decisão ao quebrar visualmente decisões complexas em partes mais simples e gerenciáveis [Quinlan \(1986\)](#), [Breiman et al. \(1984a\)](#).

O processo de construir uma árvore de decisão envolve a seleção de atributos que melhor dividem o conjunto de dados em subconjuntos baseados em resultado. Esta decisão é guiada por métricas como Ganho de Informação e Impureza de Gini. O Ganho de Informação, derivado do conceito de entropia introduzido por Shannon, é usado para medir a eficácia de um atributo na classificação do conjunto de dados. O Ganho de Informação é calculado como a diferença na entropia antes e depois que o conjunto de dados é dividido com base em um atributo [Shannon \(1948\)](#), [Quinlan \(1986\)](#):

$$IG(D, f) = Entropia(D) - \sum_{v \in \text{Valores}(f)} \frac{|D_v|}{|D|} Entropia(D_v) \quad (3.13)$$

onde D é o conjunto de dados, f é o recurso para dividir, v são os valores que f pode assumir, e D_v é o subconjunto de D para o qual $f = v$.

Impureza de Gini é outra métrica usada para determinar o melhor atributo para dividir o conjunto de dados, especialmente no algoritmo CART. Ela mede a frequência com que um elemento escolhido aleatoriamente do conjunto seria incorretamente rotulado se fosse rotulado aleatoriamente de acordo com a distribuição de rótulos no subconjunto [Breiman et al. \(1984a\)](#):

$$Gini(D) = 1 - \sum_{i=1}^n p_i^2 \quad (3.14)$$

onde p_i é a proporção de itens rotulados com a classe i no conjunto de dados.

Árvores de Decisão apresentam vantagens significativas, como facilidade em tratar características tanto contínuas quanto categóricas, [Bhavani e Kumar \(2021\)](#), trabalham com fronteiras de decisão paralelas ao eixo de características e são rápidas tanto para aprendizado quanto para previsão e interpretabilidade. No entanto, possui dificuldades com fronteiras de decisão diagonais, propensão ao sobreajuste, sensibilidade a perturbações nos dados e problemas com previsões fora da amostra [Kowsari et al. \(2019\)](#).

A Figura 8 ilustra uma árvore de decisão simples para determinar se é um bom dia para jogar tênis, com base em condições meteorológicas como perspectiva (ensolarado, nublado, chuvoso), umidade e vento.

3.5.5 Regressão Logística

A Regressão Logística (RL), como introduzida por David Cox em 1958, é um método de classificação que utiliza a função logística para prever a probabilidade de um determinada entrada pertencer a uma classe específica. É um classificador linear que cria fronteiras de decisão na forma de probabilidades em vez de classes explícitas, tornando-se adequado para problemas de classificação binária. A RL opera sob a premissa básica de estimar a probabilidade de um resultado binário com base em uma ou mais variáveis preditoras, representada matematicamente como [Kowsari et al. \(2019\)](#):

$$P(Y = 1) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n)}}$$




Figura 8 – Árvore de decisão para jogar tênis.

onde $P(Y = 1)$ é a probabilidade da variável dependente Y estar na categoria 1, e é a base do logaritmo natural, $X_1, X_2, \dots, X_n$ são as variáveis independentes, e $\beta_0, \beta_1, \dots, \beta_n$ são os coeficientes a serem estimados. Este método é explorado na obra de [Hosmer, Lemeshow e Sturdivant \(2013\)](#).

A RL, com suas variantes regularizadas como Regressão Ridge (L2) e Lasso (L1), oferece uma solução para problemas de multicolinearidade e sobreajuste.

Regressão Ridge

A regressão Ridge aborda a multicolinearidade em modelos de regressão múltipla introduzindo um termo de penalidade à função de perda, proporcional ao quadrado da magnitude dos coeficientes. A fórmula da regressão Ridge é:

$$\hat{\beta}^{ridge} = \arg \min_{\beta} \left\{ \sum_{i=1}^n (y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij})^2 + \lambda \sum_{j=1}^p \beta_j^2 \right\}$$

Esta técnica, introduzida por [Hoerl e Kennard \(1970\)](#), ajuda a reduzir o tamanho dos coeficientes, mitigando o risco de sobreajuste.

Regressão Lasso

A regressão Lasso estende o conceito de regressão Ridge ao empregar um termo de penalidade proporcional ao valor absoluto dos coeficientes, permitindo a seleção de variáveis ao reduzir alguns coeficientes a zero. A fórmula da regressão Lasso é:

$$\hat{\beta}^{lasso} = \arg \min_{\beta} \left\{ \sum_{i=1}^n (y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij})^2 + \lambda \sum_{j=1}^p |\beta_j| \right\}$$

Esta abordagem foi proposta por Tibshirani [Tibshirani \(1996\)](#), oferecendo um método para simplificação do modelo e seleção de variáveis.

ElasticNet

O modelo Elastic Net combina as penalidades L1 e L2, oferecendo uma solução híbrida que captura as vantagens de ambos os métodos de regularização [Hastie, Tibshirani e Friedman \(2009\)](#) :

$$L_{elastic} = \sum (Y - \hat{Y})^2 + \lambda_1 \sum |\beta_j| + \lambda_2 \sum \beta_j^2 \quad (3.15)$$

Regressão Logística Multinomial

A Regressão Logística Multinomial estende a regressão logística para lidar com variáveis de resposta com mais de duas categorias, definida como:

$$P(Y = j) = \frac{e^{\beta_{0j} + \beta_{1j}X_1 + \dots + \beta_{nj}X_n}}{1 + \sum_{k=1}^{J-1} e^{\beta_{0k} + \beta_{1k}X_1 + \dots + \beta_{nk}X_n}}$$

para $j = 1, 2, \dots, J - 1$ categorias. Este modelo é eficiente em lidar com cenários de classificação complexos e foi desenvolvido por McFadden [McFadden \(1973\)](#).

A Regressão Logística destaca-se pela simplicidade de implementação e eficiência computacional, evitando a necessidade de ajustes e escalonamento prévio dos dados. Contudo, enfrenta limitações em cenários não-lineares e requer independência entre observações, o que implica considerações ao modelar com variáveis independentes para previsão [Kowsari et al. \(2019\)](#).

3.6 Métricas de Avaliação

Métricas de avaliação são medidas que permitem avaliar o desempenho de algoritmos de aprendizado. Na tarefa de classificação, conforme destacado por [Tharwat \(2018\)](#), as métricas como acurácia, precisão, revocação, F1-score e a área sob a curva ROC (AUC) servem como base para avaliar o desempenho em contextos de classificação binária. Avançando para o domínio das classificações multiclasse, a complexidade aumenta, e métricas adicionais, como a matriz de confusão multiclasse e medidas derivadas, tornam-se essenciais para capturar a performance do modelo de forma abrangente, [Grandini, Bagli e Visani \(2020\)](#).

O primeiro conceito importante é a matriz de confusão. A partir dela são derivados as demais métricas.

3.6.1 Matriz de Confusão

A matriz de confusão é uma ferramenta importante para avaliar o desempenho de modelos de classificação, especialmente em problemas de classificação binária, onde existem apenas duas classes possíveis para cada instância. Como apresentado na [Tabela 10](#), a matriz de confusão é composta por quatro células:

- Verdadeiros Positivos (TP) representam as instâncias positivas corretamente identificadas.

- Falsos Positivos (FP) são as instâncias negativas incorretamente identificadas como positivas.
- Falsos Negativos (FN) são as instâncias positivas incorretamente identificadas como negativas.
- Verdadeiros Negativos (TN) representam as instâncias negativas corretamente identificadas.

Tabela 10 – Matriz de confusão para um modelo de classificação binária

Classe Real	Classe Prevista	
	Positivo	Negativo
Positivo	TP	FN
Negativo	FP	TN

As principais medidas derivadas da matriz de confusão são acurácia, precisão, revocação e F1-Score.

Acurácia

A acurácia é a porcentagem de previsões corretas feitas pelo modelo, dada pela equação (3.16):

$$\text{Acurácia} = \frac{\text{Verdadeiros Positivos} + \text{Verdadeiros Negativos}}{\text{Total de Exemplos}} \quad (3.16)$$

Precisão

A precisão é a proporção de verdadeiros positivos em relação ao total de previsões positivas feitas pelo modelo, dada pela equação (3.17):

$$\text{Precisão} = \frac{\text{Verdadeiros Positivos}}{\text{Verdadeiros Positivos} + \text{Falsos Positivos}} \quad (3.17)$$

Revocação

A revocação é a proporção de verdadeiros positivos em relação ao total de exemplos positivos existentes, dada pela equação (3.18):

$$\text{Revocação} = \frac{\text{Verdadeiros Positivos}}{\text{Verdadeiros Positivos} + \text{Falsos Negativos}} \quad (3.18)$$

F1-Score

O F1-Score é uma métrica que combina precisão e revocação em uma única medida, dada pela fórmula (3.19):

$$\text{F1-Score} = 2 \times \frac{\text{Precisão} \times \text{Revocação}}{\text{Precisão} + \text{Revocação}} \quad (3.19)$$

Exemplo de Cálculos com a Matriz de Confusão

Nesta seção, exemplos de cálculo para as métricas descritas são apresentados usando uma matriz de confusão simplificada.

Para a matriz de confusão da [Tabela 11](#), os seguintes cálculos são feitos:

Tabela 11 – Exemplo de matriz de confusão

Classe Real	Classe Prevista	
	Positivo	Negativo
Positivo	50 (TP)	5 (FN)
Negativo	10 (FP)	135 (TN)

Acurácia:

$$\text{Acurácia} = \frac{\text{TP} + \text{TN}}{\text{Total de Exemplos}} = \frac{50 + 135}{200} = 0.925 = 92.5\%$$

Precisão:

$$\text{Precisão} = \frac{\text{TP}}{\text{TP} + \text{FP}} = \frac{50}{50 + 10} = \frac{50}{60} = 0.8333 = 83.33\%$$

Revocação:

$$\text{Revocação} = \frac{\text{TP}}{\text{TP} + \text{FN}} = \frac{50}{50 + 5} = \frac{50}{55} = 0.9091 = 90.91\%$$

F1-Score:

$$\text{F1-Score} = 2 \times \frac{\text{Precisão} \times \text{Revocação}}{\text{Precisão} + \text{Revocação}} = 2 \times \frac{0.8333 \times 0.9091}{0.8333 + 0.9091} = 0.8671 = 86.71\%$$

Tabela 12 – Resumo das métricas calculadas

Métrica	Valor
Acurácia	92.5%
Precisão	83.33%
Revocação	90.91%
F1-Score	86.71%

As métricas calculadas são resumidas na [Tabela 12](#). Esta tabela resumo fornece uma visão geral dos valores de desempenho obtidos, facilitando a análise comparativa e a interpretação dos resultados.

3.6.2 Matriz de Confusão para Classificação Multiclasse

Na classificação multiclasse, a matriz de confusão é estendida para acomodar múltiplas classes. Ela fornece uma representação tabular das classes previstas em relação às classes reais, ajudando a identificar o desempenho do modelo em diferentes classes. Denotando C como o número de classes, a matriz de confusão para classificação multiclasse é composta por $C \times C$ células, onde cada linha corresponde às instâncias em uma classe real e cada coluna corresponde às instâncias em uma classe prevista.

Nesta matriz:

- TP_{ii} (*Verdadeiros Positivos*) representa as instâncias corretamente previstas como classe i .

Tabela 13 – Matriz de confusão para classificação multiclasse

	Classe Prevista			
	Classe 1	Classe 2	...	Classe C
Classe 1	TP_{11}	FP_{12}	...	FP_{1C}
Classe 2	FP_{21}	TP_{22}	...	FP_{2C}
...	...	...	...	...
Classe C	FP_{C1}	FP_{C2}	...	TP_{CC}

- FP_{ij} (*Falsos Positivos*) representa as instâncias previstas incorretamente como classe j quando a classe real é i .

Cada elemento C_{ij} da matriz representa a contagem de instâncias conhecidas como pertencentes à classe i , mas previstas como classe j .

Métricas de Desempenho para Classificação Multiclasse

Acurácia

A acurácia na classificação multiclasse é medida pela proporção de instâncias corretamente previstas em relação ao total de instâncias em todas as classes. Ela é calculada da seguinte forma:

$$\text{Acurácia} = \frac{\sum_{i=1}^C TP_{ii}}{\sum_{i=1}^C \sum_{j=1}^C C_{ij}}$$

Precisão

A precisão para a classe i (P_i) é a proporção de verdadeiros positivos para a soma de verdadeiros positivos e falsos positivos para a classe i :

$$P_i = \frac{TP_{ii}}{TP_{i1} + TP_{i2} + \dots + TP_{iC}}$$

Revocação

A revocação para a classe i (R_i) é a proporção de verdadeiros positivos para a soma de verdadeiros positivos e falsos negativos para a classe i :

$$R_i = \frac{TP_{ii}}{TP_{i1} + TP_{i2} + \dots + TP_{iC}}$$

F1-Score

O F1-Score para a classe i ($F1_i$) é a média harmônica da precisão e da revocação para a classe i :

$$F1_i = 2 \times \frac{P_i \times R_i}{P_i + R_i}$$

Essas métricas fornecem métricas sobre o desempenho do modelo para cada classe e são particularmente úteis quando as classes estão desbalanceadas.

Médias Macro e Micro para Classificação Multiclasse

As métricas macro e micro são usadas para fornecer diferentes perspectivas sobre o desempenho de um modelo de classificação, especialmente em cenários de classificação multiclasse e em situações onde há desequilíbrio entre as classes. A principal diferença entre essas métricas reside na forma como elas agregam os resultados das diferentes classes.

Macro Médias

As macro médias calculam a métrica de interesse para cada classe individualmente e, em seguida, tiram a média dessas métricas. Em termos teóricos:

- **Igualdade de Classes:** Cada classe recebe igual peso na média, independentemente do número de instâncias em cada classe.
- **Sensibilidade ao Desequilíbrio de Classes:** As macro médias são mais sensíveis a desequilíbrios entre classes. Se uma classe tiver um desempenho muito ruim ou muito bom, isso impactará significativamente a média, mesmo que a classe seja pequena.
- **Foco em Classes Individuais:** As macro métricas são úteis quando se quer avaliar o desempenho do modelo em cada classe individualmente e tratar todas as classes com igual importância.

Micro Médias

As micro médias, por outro lado, agregam todas as instâncias das diferentes classes antes de calcular a métrica de interesse. Em termos teóricos:

- **Proporcionalidade de Instâncias:** Cada instância individual tem igual peso, independentemente da classe a que pertence.
- **Menor Sensibilidade ao Desequilíbrio de Classes:** Como todas as instâncias são tratadas igualmente, as métricas micro são menos sensíveis ao desequilíbrio entre classes. Isso pode mascarar o desempenho ruim em classes menores se a maioria das instâncias pertencer a uma ou poucas classes maiores.
- **Foco no Desempenho Global:** As micro métricas são úteis para obter uma visão geral do desempenho do modelo em todo o conjunto de dados, destacando a capacidade do modelo de classificar corretamente a maior parte das instâncias.

Precisão Macro

A precisão macro é a média da precisão em todas as classes, tratando cada classe igualmente:

$$\text{Precisão Macro} = \frac{\sum_{i=1}^C P_i}{C} = \frac{\sum_{i=1}^C \frac{TP_i}{TP_i + FP_i}}{C}$$

Revocação Macro

A revocação macro é a média da revocação em todas as classes, tratando cada classe igualmente:

$$\text{Revocação Macro} = \frac{\sum_{i=1}^C R_i}{C} = \frac{\sum_{i=1}^C \frac{TP_{ii}}{TP_{ii} + FN_{ij}}}{C}$$

F1-Score Macro

O F1-Score macro é a média do F1-Score em todas as classes, tratando cada classe igualmente:

$$\text{F1-Score Macro} = \frac{\sum_{i=1}^C F1_i}{C} = \frac{\sum_{i=1}^C 2 \times \frac{P_i \times R_i}{P_i + R_i}}{C}$$

Precisão, Revocação e F1-Score Micro

A precisão, revocação e F1-Score possuem a mesma fórmula que a acurácia.

$$\text{Métricas Micro} = \frac{\sum_{i=1}^C TP_{ii}}{\sum_{i=1}^C \sum_{j=1}^C C_{ij}}$$

Exemplo de Cálculo de Métricas para Avaliação de Classificação Multiclasse

Para ilustrar o cálculo, a [Tabela 14](#) contém um conjunto de exemplo de dados.

Tabela 14 – Exemplo de matriz de confusão para classificação multiclasse

	Classe Prevista		
	Classe 1	Classe 2	Classe 3
Classe 1	60	25	15
Classe 2	10	35	5
Classe 3	1	1	8

A soma total das instâncias é $60 + 25 + 15 + 10 + 35 + 5 + 1 + 1 + 8 = 160$.

A acurácia (ACC) é calculada pela soma dos verdadeiros positivos dividida pela soma total de instâncias em todas as classes:

$$\text{Acurácia} = \frac{TP_{11} + TP_{22} + TP_{33}}{160} = \frac{60 + 35 + 8}{160} \approx 0.6438$$

Portanto, a acurácia deste modelo é aproximadamente 64.38%.

Métricas de Avaliação por Classe com Valores Calculados

Médias Macro e Micro das Métricas

Como pode ser observado, todas as métricas micro recaem sobre o mesmo valor e conforme explicitado em [Grandini, Bagli e Visani \(2020\)](#) todas representam a acurácia do modelo. Desta forma a

Tabela 15 – Métricas de Avaliação por Classe

Classe	Precisão	Revocação	F1-Score
Classe 1	$\frac{60}{60+25+15} = 0.60$	$\frac{60}{60+10+1} = 0.85$	$2 \times \frac{0.60 \times 0.85}{0.60+0.85} = 0.70$
Classe 2	$\frac{35}{35+10+5} = 0.70$	$\frac{35}{35+25+1} = 0.57$	$2 \times \frac{0.70 \times 0.57}{0.70+0.57} = 0.63$
Classe 3	$\frac{8}{8+1+1} = 0.80$	$\frac{8}{8+15+5} = 0.29$	$2 \times \frac{0.80 \times 0.29}{0.80+0.29} = 0.42$

Tabela 16 – Médias Macro e Micro das Métricas

Métrica	Macro	Micro
Precisão	$\frac{0.60+0.70+0.80}{3} = 0.70$	$\frac{60+35+8}{160} = 0.64$
Revocação	$\frac{0.85+0.57+0.29}{3} = 0.57$	$\frac{60+35+8}{160} = 0.64$
F1-Score	$\frac{0.70+0.63+0.42}{3} = 0.58$	$2 \times \frac{0.64 \times 0.64}{0.64+0.64} = 0.64$

indicação para avaliar modelos multiclasse é a combinação de uma medida mais geral como a acurácia e uma medida classe a classe. Como a medida F1-Score contempla tanto a precisão quanto a revocação, é a medida indicada para avaliar o desempenho do modelo levando em conta todas as classes.

3.7 Técnicas para Divisão do Conjunto de Dados para Avaliação

No aprendizado de máquina, a divisão dos conjuntos de dados em treinamento, validação e teste desempenha um papel importante na avaliação do desempenho dos modelos. Este processo, conforme demonstrado em trabalhos seminais como os de [Kohavi et al. \(1995\)](#), [Breiman et al. \(1984b\)](#), e [Hastie, Tibshirani e Friedman \(2009\)](#), ajuda a garantir que os modelos sejam precisos nos dados de treinamento e generalizem adequadamente para dados não vistos. A divisão apropriada do conjunto de dados permite identificar e mitigar problemas de overfitting e underfitting, o que contribui para aumentar a confiabilidade dos modelos de aprendizado de máquina.

As principais técnicas consistem em:

Validação Cruzada K-Fold ([Kohavi et al. \(1995\)](#)): Esta técnica envolve dividir o conjunto de dados em k partes de tamanho igual. O modelo é treinado em $k - 1$ partes e testado na parte restante. Este processo é repetido k vezes, com cada parte sendo utilizada exatamente uma vez como conjunto de teste. A validação cruzada fornece uma estimativa mais robusta do desempenho do modelo, utilizando todo o conjunto de dados tanto para treinamento quanto para teste. A escolha do valor de k pode variar, mas $k = 10$ é uma prática comum.

Divisão Aleatória: Este método envolve a partição aleatória do conjunto de dados em conjuntos de treinamento, validação e teste. Tipicamente, o conjunto de dados é dividido em 70% para treinamento, 15% para validação e 15% para teste, embora estas proporções possam variar conforme o tamanho do conjunto de dados e a complexidade do modelo. Este método pode não ser ideal para datasets desbalanceados, pois pode resultar em distribuições de classes não representativas nos subconjuntos.

Amostragem Estratificada: Esta técnica é particularmente útil para conjuntos de dados com classes desbalanceadas. A amostragem estratificada garante que cada divisão do conjunto de dados contenha

aproximadamente a mesma proporção de amostras de cada classe-alvo que o conjunto completo. Preservar a distribuição de classes é desejado para a avaliação justa e precisa do desempenho de modelos treinados em conjuntos de dados desbalanceados.

Na literatura de aprendizado de máquina, especialmente no contexto de avaliação de modelos por meio da validação cruzada k-fold, não há um consenso único sobre o número ideal de partições. No entanto, é prática comum usar 10 partes, conforme sugerido por [Kohavi *et al.* \(1995\)](#) em seu trabalho seminal sobre estimativa de precisão de validação cruzada e seleção de modelo, devido ao bom equilíbrio entre a precisão das estimativas de desempenho e a eficiência computacional. Esta recomendação é baseada em evidências empíricas que indicam que a validação cruzada com 10 partes atinge um bom equilíbrio entre a obtenção de estimativas confiáveis do desempenho do modelo e a eficiência computacional.

METODOLOGIA

4.1 Introdução à Metodologia

A escolha metodológica de uma pesquisa define o caminho pelo qual as questões de estudo serão abordadas e os objetivos alcançados. No contexto deste estudo, a abordagem quantitativa foi selecionada devido à sua capacidade de fornecer resultados mensuráveis e replicáveis, importantes para a avaliação do desempenho dos algoritmos de Aprendizado de Máquina (AM). Conforme destacado por (CRESWELL, 2014), a metodologia quantitativa permite uma investigação sistemática das propriedades e fenômenos quantificáveis, facilitando a comparação e a generalização dos resultados. Este estudo emprega uma metodologia quantitativa para explorar a eficácia dos algoritmos de classificação de texto em um conjunto de dados específico, buscando contribuições significativas para o campo do processamento de linguagem natural e Aprendizado de Máquina (AM). A seleção desta abordagem está alinhada com os objetivos de pesquisa, que visam quantificar o desempenho dos modelos em tarefas de classificação de descrições de produtos em português, utilizando para isso o dataset RETAILPRODUCTDESCRIPTION-PTBR (RETAILPRODUCTDESCRIPTION-PTBR), especialmente preparado e anotado para este fim.

4.2 Design da Pesquisa

O design desta pesquisa adota uma abordagem quantitativa, estruturada para investigar o impacto de diferentes algoritmos de Aprendizado de Máquina (AM) na classificação de textos em português. Seguindo as recomendações de (YIN, 2018), que enfatiza a importância de um design de pesquisa claramente definido para estudos quantitativos, este estudo utiliza um design experimental para comparar o desempenho de vários algoritmos. Yin sugere que tal abordagem estabelece uma relação causal e permite compreender o efeito das variáveis independentes nas dependentes dentro de contextos controlados. O experimento é estruturado em fases distintas, incluindo a seleção de dados, pré-processamento, treinamento de modelos, e avaliação, visando um entendimento dos mecanismos que influenciam a eficácia da classificação de texto. Este design é particularmente adequado para a pesquisa em processamento de linguagem natural (Processamento de Linguagem Natural (PLN)), permitindo análises detalhadas e replicáveis dos modelos computacionais em tarefas de classificação.

4.3 Linguagem de Programação e Bibliotecas

Para este trabalho, foi utilizada a Linguagem Python (ROSSUM; DRAKE, 2009) e a biblioteca scikit-learn (PEDREGOSA *et al.*, 2011). A seleção da linguagem de programação Python e da biblioteca scikit-learn para a realização deste estudo foi baseada em múltiplas considerações técnicas e práticas, fundamentadas nas vantagens que ambas oferecem para projetos de Aprendizado de Máquina (AM) e Processamento de Linguagem Natural (PLN). Estas vantagens, entre outras, são: rica biblioteca de Pacotes, comunidade ativa, interoperabilidade, documentação e tutoriais.

4.4 Procedimento Experimental

O procedimento experimental adotado neste estudo é delineado em duas fases principais, cada uma focada em aspectos distintos da modelagem para classificação de texto. Essas fases são visualmente representadas na Figura 9. Nas seções seguintes são descritas em mais detalhes cada item.




Figura 9 – Fluxo de Trabalho.

Fonte: Elaborada pelo autor.

Elaborada pelos autores

4.4.1 Conjunto de Dados

O conjunto de dados foi obtido em (DARÚ, 2022). Este conjunto de dados abrange descrições de produtos e suas respectivas categorias, coletadas dos dezoito maiores varejistas no Brasil, baseando-se na classificação da ABRAS do ano de 2020. Os itens selecionados representaram noventa e cinco por cento das vendas do ano de 2020 destes varejistas, representando os produtos mais vendidos das maiores redes varejistas do Brasil.

O dataset é composto por 250.365 entradas e 7 colunas, detalhando descrições de produtos e informações taxonômicas. Os campos incluem `nm_item`, `segmento`, `subsegmento`, `categoria`, `subcategoria`, `id_product`, e `nm_product`, todos categorizados como strings, exceto `id_product` que é do tipo numérico. O número de valores únicos por coluna varia, indicando a diversidade dos produtos e sua classificação. Não existem registros nulos no dataset.

A tabela a seguir apresenta uma visão geral da estrutura hierárquica do conjunto de dados, destacando a organização e a especificidade com que os produtos são catalogados:

Nível de Classificação	Quantidade
Segmentos	6
Subsegmentos	20
Categorias	70
Subcategorias	169
Categoria de Menor Nível	795
Descrições	250.365

Tabela 17 – Visão geral da estrutura hierárquica do conjunto de dados.

Para cada campo do conjunto de dados, é apresentado uma descrição a seguir:

- **Nome do Item (`nm_item`):** Este campo contém descrições dos produtos.
- **Segmento:** Funciona como uma classificação de nível superior, agrupando os produtos em categorias amplas. Com apenas seis categorias distintas, destaca uma divisão geral dos produtos.
- **Subsegmento:** Fornece uma subdivisão dos segmentos, oferecendo 20 categorias distintas para uma diferenciação mais detalhada entre os produtos.
- **Categoria:** Apresenta uma camada de classificação sob os subsegmentos com 70 categorias únicas.
- **Subcategoria:** Representa o quarto nível de classificação, com 169 subcategorias distintas.
- **Categoria de Nível Mais Baixo (`id_product`):** Um código único atribuído a cada categoria de nível mais baixo, com 797 identificadores distintos, representa a menor granularidade hierárquica.
- **Descrição da Categoria de Nível Mais Baixo(`nm_product`):** A descrição da categoria de menor granularidade hierárquica.

A estrutura hierárquica pode ser resumida na Figura ??.




Figura 10 – Hierarquia e quantidade de elementos distintos e descrições em cada segmento

Fonte: Dados da pesquisa.

Análise Exploratória de Dados (EDA)

A Análise Exploratória de Dados (EDA) é necessária para entender as características do conjunto de dados, permitindo a identificação de padrões, anomalias, e distribuições. As análises concentram-se em descrever características das descrições de produtos e a distribuição de rótulos pelas categorias de menor nível.

Inicia-se a análise pela distribuição das descrições pelas categorias utilizando a curva acumulada, figura 11. A análise mostra que 70% dos dados estão concentrados em 80 categorias de menor nível, indicando uma distribuição desigual. Este padrão ressalta a importância de algumas categorias no contexto dos varejistas.




Figura 11 – Distribuição das categorias de menor nível em escala logarítmica.

Fonte: Dados da pesquisa.

Categorias como "BISCOITO" e "IOGURTE" lideram em quantidade de itens, refletindo as tendências de consumo. A Figura 12 exibe as 10 categorias com a maior quantidade de itens classificados. Esta concentração denota o desbalanceamento e a dificuldade que se tem em tarefas de classificação.




Figura 12 – Top 10 categorias de produtos com o maior número de rótulos.

Fonte: Dados da pesquisa.

A próxima análise refere-se como as descrições de produto se comportam nos varejos em relação a dois atributos importantes. A quantidade de caracteres e quantidade de palavras. Para definir uma palavra, realiza-se a segmentação da descrição por espaço.

A Figura 13 demonstra que a maioria das descrições contém entre 20 a 35 caracteres, indicando uma preferência por descrições breves, mas informativas. Este padrão sugere que as descrições são

projetadas para se encaixar dentro de cupons fiscais. É interessante observar que não há nas descrições do dataset nenhum registro com mais de 50 caracteres, mostrando um padrão por descrições de até 50 caracteres.




Figura 13 – Distribuição de frequência da contagem de caracteres por descrição.

Fonte: Dados da pesquisa.

A Figura 14 apresenta a distribuição por palavra. Esta mostra uma predominância de descrições com 4 a 6 palavras, refletindo uma tendência à concisão nas descrições dos produtos. Este padrão é indicativo de um esforço para comunicar informações essenciais de forma eficiente, permitindo aos consumidores entender rapidamente as características dos produtos.




Figura 14 – Distribuição de frequência da contagem de palavras por descrição.

Fonte: Dados da pesquisa.

4.4.2 Pré-Processamento, Tokenização e Vetorização

Conforme discutido na seção 3.2.1, a normalização, incluindo a remoção de acentos e a conversão para letras minúsculas, é adotada para uniformizar as variações linguísticas. Esta abordagem facilita a

análise dos dados, alinhando-se com as práticas padrão em Processamento de Linguagem Natural (PLN). Diversas técnicas são apresentadas, mas as de maior impacto são a **normalização e conversão para minúsculas**. As demais, conforme (NASEEM; RAZZAK; EKLUND, 2021), acabam não impactando significativamente no resultado final. Cabe ressaltar que as descrições de produto não apresentam verbos e variantes com prefixo e sufixo.

A tokenização é realizada para decompor os textos em unidades menores, ou tokens. Neste trabalho, serão exploradas representações baseadas em unigramas e bigramas. Esta decisão é fundamentada pela necessidade de capturar tanto a frequência de palavras individuais (*unigramas*) quanto as relações entre palavras adjacentes (*bigramas*), conforme destacado na seção 3.2.2.

Utilizam-se as técnicas de Bag of Words (Bag of Words (BoW)), Term Frequency (Term Frequency (TF)), e Term Frequency-Inverse Document Frequency (Term Frequency-Inverse Document Frequency (TFIDF)) para transformar os textos tokenizados em representações vetoriais. Estas técnicas são aplicadas a unigramas e bigramas, tanto em formas normalizadas quanto não-normalizadas, para capturar a importância relativa das palavras e suas relações contextuais. Estas técnicas são descritas na seção 3.2.3 sobre representação numérica. A escolha se deve a ser os principais modelos utilizados pelas literaturas.

São avaliadas as representações vetoriais em suas formas normalizadas e não-normalizadas. A normalização dos vetores de características visa a padronização à uma escala comum, facilitando a integração de diferentes tipos de características e a aplicação de algoritmos de Aprendizado de Máquina (AM).

4.4.3 Métricas de Avaliação

O principal objetivo das métricas de avaliação é fornecer um quadro confiável para a análise do desempenho dos modelos. Procurou-se selecionar métricas que considerassem tanto a eficácia geral do modelo quanto sua capacidade de tratar classes de maneira equitativa, evitando viés em favor das classes mais representativas no conjunto de dados. Desta forma, pode-se resumir o objetivo em *abrangência e equidade*. Segundo Tharwat (2018) e Grandini et al. (2020), as métricas são fundamentais para compreender o desempenho dos modelos em contextos multiclasse, onde a complexidade e o desbalanceamento entre classes apresentam desafios significativos. Para satisfazer estes dois critérios foram escolhidas a **F1-Score Macro** e **Acurácia**. Elas juntas proporcionam uma visão equilibrada e abrangente do desempenho dos modelos. Quanto a **abrangência** a acurácia fornece uma visão geral do desempenho enquanto que para a **equidade** A F1-score macro, ao calcular a média dos F1-Scores de todas as classes, dá igual peso a cada uma delas, favorecendo uma avaliação justa independentemente do tamanho da classe.

4.4.4 Configurações de Treinamento

Para avaliar o desempenho dos modelos de Aprendizado de Máquina (AM) especificados neste estudo, o conjunto de dados foi submetido a um processo de randomização antes da aplicação das técnicas de treinamento. A técnica de validação cruzada k-fold com 10 partições foi adotada, baseando-se na recomendação de (KOHAVI *et al.*, 1995), que destaca a eficiência desta abordagem em proporcionar

estimativas confiáveis do desempenho dos modelos.

O procedimento foi realizado da seguinte forma: após a randomização do conjunto de dados, este foi dividido em 10 partições de tamanho igual. Utilizando a abordagem de validação cruzada, em cada ciclo, nove partições foram empregadas para o treinamento do modelo, enquanto a partição restante foi reservada para teste. Este processo foi repetido 10 vezes, com cada partição servindo exatamente uma vez como conjunto de teste. Essa metodologia assegura uma avaliação completa e equitativa do desempenho dos modelos avaliados no trabalho.

4.4.5 Ajuste Fino dos Modelos

O ajuste fino dos hiperparâmetros visa otimizar o desempenho dos modelos de Aprendizado de Máquina (AM). Nesta seção, é descrito os hiperparâmetros que serão avaliados para cada modelo utilizado neste estudo.

Para os métodos baseados em argmax, as combinações dos seguintes hiperparâmetros serão avaliadas:

- **Tokenização:** Serão exploradas três abordagens distintas para a tokenização: unigramas, bigramas e seqgramas. Essas abordagens permitem analisar a influência do tamanho dos tokens na performance do modelo.
- **Vetorização:** É avaliada três técnicas de vetorização: binária, frequência e Term Frequency-Inverse Document Frequency (TFIDF). Cada técnica fornece uma representação diferente dos textos, que será examinada em termos de impacto no desempenho do modelo.
- **Normalização:** Será considerada a aplicação ou não de normalização nos textos, incluindo a conversão para minúsculas e remoção de acentos, para verificar sua influência na eficácia do modelo.

A combinação desses hiperparâmetros visa explorar uma ampla gama de configurações para identificar aquela que proporciona o melhor desempenho para a classificação de texto baseada em argmax. A tabela 18 exibe as combinações avaliadas.

Tabela 18 – Combinações de Tokenização, Vetorização e Normalização

ID	Tokenização	Tipo	Normalização
ARGMAX1BI	unigram	Binário	
ARGMAX1BINORM	unigram	Binário	Normalizado
ARGMAX1TF	unigram	TF	
ARGMAX1TFNORM	unigram	TF	Normalizado
ARGMAX1TFIDF	unigram	TFIDF	
ARGMAX1TFIDFNORM	unigram	TFIDF	Normalizado
ARGMAX2BI	bigram	Binário	
ARGMAX2BINORM	bigram	Binário	Normalizado
ARGMAX2TF	bigram	TF	
ARGMAX2TFNORM	bigram	TF	Normalizado
ARGMAX2TFIDF	bigram	TFIDF	
ARGMAX2TFIDFNORM	bigram	TFIDF	Normalizado

RESULTADOS

Neste capítulo, os resultados obtidos a partir da aplicação dos métodos de classificação de texto analisados neste estudo são apresentados, incluindo tanto técnicas baseadas em Argmax. A avaliação do desempenho desses métodos é considerada referencial para compreender sua eficácia na classificação de descrições de produtos em português, utilizando o dataset RETAILPRODUCTDESCRIPTION-PTBR (RETAILPRODUCTDESCRIPTION-PTBR) especialmente preparado para este fim.

Inicialmente, uma análise detalhada dos resultados obtidos com o método Argmax é apresentada, explorando diferentes configurações de vetorização, tokenização e normalização, e como estas são vistas para afetar o desempenho do método em termos de acurácia e F1-Score Macro.

Finalmente, uma comparação geral dos resultados de todos os métodos analisados é realizada, oferecendo uma visão integrada do desempenho relativo de cada técnica. Esta seção de resultados gerais visa identificar os métodos mais promissores provenientes das técnicas e teorias da recuperação da informação para a classificação de textos curtos em português, considerando as particularidades do dataset em estudo. Discussões sobre as limitações dos resultados, considerações para a interpretação dos dados e sugestões para pesquisas futuras também são abordadas, fornecendo um panorama dos achados e sua implicação para o campo do processamento de linguagem natural e Aprendizado de Máquina (AM).

Foram realizadas simulações com todas as combinações utilizando para teste e treino o método K-Fold com 10 partições. Isto permite gerar estatísticas e avaliar a variância do método, aqui avaliada em porcentagem pelo coeficiente de variação. A tabela 19 apresenta estas estatísticas.

Tabela 19 – Resultados estatísticos dos testes para o método Argmax com Rankings

Método	NGram	Norm	Acurácia (%)			F1 Score Macro(%)		
			Média	CV	#	Média	CV	#
Binary	[1, 1]	None	75.31	0.44	6	58.77	3.15	3
Binary	[1, 1]	L2	19.07	2.40	12	25.39	2.04	11
Binary	[1, 2]	None	89.56	0.21	1	70.09	1.91	1
Binary	[1, 2]	L2	31.30	1.48	11	33.82	1.77	8
TermFrequency	[1, 1]	None	63.76	0.41	10	23.44	2.05	12
TermFrequency	[1, 1]	L2	77.05	0.24	4	52.31	2.46	5
TermFrequency	[1, 2]	None	66.68	0.28	9	27.08	1.69	10
TermFrequency	[1, 2]	L2	79.65	0.29	3	55.56	2.61	4
TFIDF	[1, 1]	None	70.64	0.28	8	32.10	2.25	9
TFIDF	[1, 1]	L2	78.37	0.32	5	55.20	2.47	6
TFIDF	[1, 2]	None	74.57	0.33	7	37.67	1.53	7
TFIDF	[1, 2]	L2	82.76	0.29	2	59.83	2.52	2

Os resultados de acurácia revelam que o método Binary com NGram [1, 2] e sem normalização obteve a maior média de acurácia (89.56%), seguido pelo método TFIDF com NGram [1, 2] e L2 (82.76%). Por outro lado, o método Binary com NGram [1, 1] e L2 apresentou a menor média de acurácia (19.07%). Observa-se que o método Binary com NGram [1, 1] e L2 apresentou o maior coeficiente de variação (CV) (2.40%), indicando uma maior variabilidade nos resultados.

Os boxplots das acurácias (Figura 15) demonstram uma variância relativamente baixa entre as combinações de parâmetros testadas. Observou-se a presença de poucos outliers, indicando que a maioria das configurações apresenta um desempenho consistente. As combinações que utilizam o método binário sem normalização destacaram-se por apresentar as melhores acurácias, enquanto aquelas com normalização L2 mostraram-se menos eficazes.




Figura 15 – Boxplot das acurácias das combinações Argmax.

Fonte: Dados da pesquisa.

Em relação ao F1 Score Macro, observa-se algumas diferenças em comparação com os resultados de acurácia. Por exemplo, o método Binary com NGram [1, 2] e sem normalização mantém sua posição de destaque, enquanto o método TFIDF com NGram [1, 1] e L2 apresenta um desempenho superior em

relação ao método TermFrequency com a mesma configuração. As diferenças nos rankings atribuídos para acurácia e F1 Score destacam a importância de considerar múltiplas métricas ao avaliar o desempenho de modelos de classificação de texto.

Similarmente, os boxplots dos F1 Scores Macro (Figura 16) revelam que as configurações com bom desempenho em acurácia tendem também a exibir resultados satisfatórios no F1 Score Macro. Este padrão sugere que as configurações selecionadas são capazes de manter um equilíbrio razoável na performance entre as diversas classes, mesmo considerando o desbalanceamento presente no conjunto de dados.




Figura 16 – Boxplot dos F1 Scores Macro das combinações Argmax.

Fonte: Dados da pesquisa.

A análise combinada dos resultados visa integrar as observações feitas individualmente para acurácia e F1 Score Macro, oferecendo uma visão geral do desempenho dos métodos de classificação utilizados. Esta seção enfoca a interpretação conjunta dessas métricas, utilizando o gráfico de dispersão para ilustrar a eficácia relativa de cada configuração de método de vetorização, n-gramas e normalização.

O gráfico de dispersão apresentado na Figura 17 permite uma análise visual das diferentes configurações de modelos de classificação, dividindo o espaço em quatro áreas distintas. Na área superior direita (++), encontram-se as configurações que alcançaram altos valores tanto de acurácia quanto de F1 Score Macro, indicando um desempenho superior em ambas as métricas. Por outro lado, na área inferior esquerda (-), situam-se as combinações que apresentaram os piores resultados em ambas as métricas. Na área superior esquerda (-+), estão as configurações que alcançaram baixa acurácia, mas alto F1 Score Macro, enquanto na área inferior direita (+-), encontram-se as combinações com alta acurácia e baixo F1 Score Macro. Isto fornece uma maneira de avaliar ambas as métricas ao mesmo tempo.

No gráfico 18 apresenta-se os métodos de maneira combinada. Isto permite separar os métodos em quatro grupos distintos de configurações, divididos conforme a mediana de cada métrica.

- **Quadrante Superior Direito (++):** Configurações com alto desempenho tanto em acurácia quanto em F1 Score Macro.




Figura 17 – Interpretação do gráfico de dispersão relacionando acurácia e F1 Score Macro das combinações Argmax.

- Binary [1, 2] & None: Acurácia = 89.56%, F1 Score Macro = 70.09%.
 - TermFrequency [1, 2] & L2: Acurácia = 79.65%, F1 Score Macro = 55.56%.
 - TFIDF [1, 2] & L2: Acurácia = 82.76%, F1 Score Macro = 59.83%.
 - Binary [1, 1] & None: Acurácia = 75.31%, F1 Score Macro = 58.77%.
 - TermFrequency [1, 1] & L2: Acurácia = 77.05%, F1 Score Macro = 52.31%.
 - TFIDF [1, 1] & L2: Acurácia = 78.37%, F1 Score Macro = 55.20%.
- **Quadrante Inferior Direito (+-):** Configurações com alta acurácia mas F1 Score Macro abaixo de 50%.
 - TFIDF [1, 1] & None: Acurácia = 70.64%, F1 Score Macro = 32.10%.
 - TFIDF [1, 2] & None: Acurácia = 74.57%, F1 Score Macro = 37.67%.
 - TermFrequency [1, 1] & None: Acurácia = 63.76%, F1 Score Macro = 23.44%.
 - TermFrequency [1, 2] & None: Acurácia = 66.68%, F1 Score Macro = 27.08%.
 - **Quadrante Inferior Esquerdo (-):** Configurações com desempenho abaixo de 50% em ambas as métricas.
 - Binary [1, 1] & L2: Acurácia = 19.07%, F1 Score Macro = 25.39%.
 - Binary [1, 2] & L2: Acurácia = 31.30%, F1 Score Macro = 33.82%.
 - **Quadrante Superior Esquerdo (-+):** Não aplicável, pois não há configurações com acurácia < 50% e F1 Score Macro $\geq$ 50%.

Concluída a classificação preliminar das configurações por meio do método Argmax, a investigação avança para uma avaliação detalhada de cada técnica de classificação textual individualmente. Esta

etapa visa avaliar o impacto dos parâmetros específicos — incluindo o método de vetorização, a aplicação de N-Gramas e a normalização — na acurácia e no F1 Score Macro associados a cada método.




Figura 18 – Gráfico de dispersão relacionando acurácia e F1 Score Macro das combinações Argmax.

Fonte: Dados da pesquisa.

Análise do Método Binário

É avaliado as variações em relação ao N-Grama e Normalização. Os resultados são apresentados na tabela 20. Observando-a, a configuração binária sem normalização e com N-Gramas [1, 2] (binary-[1, 2]-None) apresentou o melhor desempenho, alcançando a maior média de acurácia (89.56%) e F1 Score Macro (70.09%). Em contraste, a configuração com normalização L2 e unigramas (binary-[1, 1]-L2) registrou o pior desempenho, com as menores médias de acurácia (19.07%) e F1 Score Macro (25.39%).

Tabela 20 – Resultados estatísticos dos testes para o método Argmax Binário

Método	NGram	Norm	Acurácia (%)			F1 Score Macro(%)		
			Média	CV	#	Média	CV	#
Binary	[1, 1]	None	75.31	0.44	2	58.77	3.15	2
Binary	[1, 1]	L2	19.07	2.40	4	25.39	2.04	4
Binary	[1, 2]	None	89.56	0.21	1	70.09	1.91	1
Binary	[1, 2]	L2	31.30	1.48	3	33.82	1.77	3

Os boxplots, 19 indicam uma forte correlação entre a acurácia e o f1scoremacro, a dispersões são relativamente baixas.




Figura 19 – Boxplot dos F1 Scores Macro das combinações Argmax para o método Binary.

Fonte: Dados da pesquisa.

O gráfico de dispersão, 20, ilustra o impacto significativo dos parâmetros de normalização e range de N-Gramas no desempenho do modelo. Configurações sem normalização L2 tendem a agrupar-se no quadrante de desempenho superior, destacando a influência negativa da normalização L2 na classificação binária para este conjunto de dados. É observável que ao se aplicar o ngram (1,2), as métricas melhoram, indicando melhoria no método.




Figura 20 – Gráfico de dispersão relacionando acurácia e F1 Score Macro das combinações Argmax para o método Binary.

Fonte: Dados da pesquisa.

Em resumo, os resultados sugerem que a ausência de normalização L2, combinada com o uso de bigramas, otimiza significativamente o desempenho da classificação binária. Esse padrão pode ser atribuído à maior capacidade dos bigramas em capturar contextos relevantes sem a penalização da normalização. É explicável que ao se normalizar um vetor binário, classes com mais termos tendem a

possuir valores menores para o token, o que por sua vez perde relevância ao se realizar a avaliação da similaridade.

Análise do Método TermFrequency

A Tabela 21 apresenta os resultados para o método tf. Os resultados indicam que a configuração utilizando bigramas (NGram [1,2]) com aplicação de normalização L2 alcançou a melhor performance em ambos os indicadores. Especificamente, a configuração TermFrequency [1, 2] com L2 destacou-se, sugerindo que a inclusão de bigramas e a normalização são benéficas para a análise de textos curtos, ao capturar relações contextuais mais complexas e reduzir a influência de termos frequentes, respectivamente.

Tabela 21 – Resultados estatísticos dos testes para o método Argmax TF

Método	NGram	Norm	Acurácia (%)			F1 Score Macro(%)		
			Média	CV	#	Média	CV	#
TermFrequency	[1, 1]	None	63.76	0.41	4	23.44	2.05	4
TermFrequency	[1, 1]	L2	77.05	0.24	2	52.31	2.46	2
TermFrequency	[1, 2]	None	66.68	0.28	3	27.08	1.69	3
TermFrequency	[1, 2]	L2	79.65	0.29	1	55.56	2.61	1

Os boxplots, 21, associados a estas configurações ilustram uma variância reduzida nos resultados de acurácia e F1Score não normalizado. Quando ocorre normalização a um leve aumenta da dispersão em relação ao F1Score. Novamente, a correlação entre os rankings de acurácia e F1 Score Macro reforça a ideia de que as configurações que performam bem em uma métrica tendem a performar bem na outra, demonstrando uma correlação em performar bem em uma métrica implica em performar bem em outra, medida global e medida interna.




Figura 21 – Boxplot dos F1 Scores Macro das combinações Argmax para o método TFIDF.

Fonte: Dados da pesquisa.

O gráfico de dispersão, 22, permite observar o maior ganho, quando aplicado sobre a normalização. Por outro lado aumentar a quantidade de tokens não influencia de maneira significativa a performance do

modelo. A normalização incrementa significativamente a performance sobre a métrica F1Score, devido a tirar o efeito do desbalanceamento.




Figura 22 – Gráfico de dispersão relacionando acurácia e F1 Score Macro das combinações Argmax para o método TFIDF.

Fonte: Dados da pesquisa.

Em suma, a análise do método TF revela uma preferência clara pelas configurações que utilizam bigramas em conjunto com normalização L2. Sendo a normalização que apresenta o maior impacto.

Análise do Método TFIDF

A análise dos resultados obtidos pelo método TFIDF, conforme apresentado na Tabela 22, destaca que configuração TFIDF [1, 2] e L2 como a mais eficaz, alcançando a maior média tanto em acurácia (82.76%) quanto em F1 Score Macro (59.83%). Tal configuração sugere que a utilização de bigramas, ao adicionar uma camada de análise contextual, juntamente com a normalização L2, que penaliza termos excessivamente frequentes, cria um equilíbrio ideal para a captura de nuances linguísticas em textos curtos.

O impacto da normalização L2, em particular, merece destaque. Ao comparar as configurações com e sem normalização L2, observa-se uma melhoria consistente nos resultados quando a normalização é aplicada. Isso indica que a redução da influência de termos de alta frequência pode ser crucial para aumentar a eficácia da classificação, especialmente em conjuntos de dados onde a prevalência de certos termos pode distorcer a representação do texto.

Tabela 22 – Resultados estatísticos dos testes para o método TFIDF com diferentes configurações

Método	NGram	Norm	Acurácia (%)			F1 Score Macro(%)		
			Média	CV	#	Média	CV	#
TFIDF	[1, 1]	None	70.64	0.28	4	32.10	2.25	4
TFIDF	[1, 1]	L2	78.37	0.32	3	55.20	2.47	3
TFIDF	[1, 2]	None	74.57	0.33	2	37.67	1.53	2
TFIDF	[1, 2]	L2	82.76	0.29	1	59.83	2.52	1

Os boxplots, 23 permite novamente verificar a correlação entre acurácia e f1score. Além disto, percebe-se o impacto normalização sendo o mais impactante, promovendo tanto ganho em acurácia quando ganho em f1score. Novamente o F1Score apresenta um ligeiro aumento de variabilidade quando se aplica a normalização, e por fim, o impacto do aumento de termos, ngram (1,2), melhora o desempenho, mas não na mesma intensidade que a normalização..




Figura 23 – Boxplot dos F1 Scores Macro das combinações Argmax para o método TFIDF.

Fonte: Dados da pesquisa.

O gráfico de dispersão, 24, permite confirmar visualmente a análise acima de maneira combinada.




Figura 24 – Gráfico de dispersão relacionando acurácia e F1 Score Macro das combinações Argmax para o método TFIDF.

Fonte: Dados da pesquisa.

Em conclusão, a normalização L2 provoca a maior alteração nos resultados, seguido de uma melhora não tão significativa dada pela tokenização.

Considerações Finais sobre Configurações Testadas

Ao finalizar a avaliação das diversas configurações testadas para os métodos de classificação Argmax, emerge um panorama claro sobre a influência dos parâmetros de normalização e n-gram na eficácia da classificação de textos curtos. Esta seção visa sintetizar as conclusões extraídas das análises anteriores e discutir as implicações práticas destes achados.

A Tabela 23 apresenta os parâmetros sugeridos para cada modelo bem como o parâmetro que promove o maior impacto.

Tabela 23 – Parâmetros sugeridos para os métodos Argmax baseados em Acurácia e F1 Score Macro (* parâmetro mais impactante)

Método	Normalização	N-Gram
Binary	None*	[1, 2]
TermFrequency	L2*	[1, 2]
TFIDF	L2	[1, 2]*

Neste segmento, são resumidos os principais achados decorrentes da avaliação das configurações testadas nos métodos de classificação Argmax, com ênfase na influência exercida pelos parâmetros de normalização e n-gram sobre a eficácia da classificação de textos curtos. Os padrões identificados nas preferências de configuração para cada método de classificação são delineados a seguir em forma de pontos-chave:

- Para o método Binary:
 - A ausência de normalização L2 foi determinante para alcançar melhores resultados, sugerindo que, no contexto binário, a normalização pode penalizar classes com uma diversidade maior de termos.
 - A utilização de bigramas [1, 2] contribuiu para uma melhoria secundária, evidenciando que a presença ou ausência de termos constitui um fator impactante na classificação.
- Para os métodos TermFrequency e TFIDF:
 - A aplicação da normalização L2, em combinação com bigramas [1, 2], foi identificada como a configuração mais eficaz, sublinhando a importância da normalização para contrabalançar a influência de termos frequentes e da expansão contextual para enriquecer a representação textual.
 - A normalização L2 assume um papel primordial no método TermFrequency, enquanto sua relevância é secundária no método TFIDF, o qual intrinsecamente ajusta a influência de termos frequentes através de sua formulação.
 - A inclusão de bigramas [1, 2] melhorou o desempenho dos modelos, indicando que a captura de contexto adicional beneficia a classificação.

CONCLUSÃO

Neste estudo, investigou-se a eficácia de algoritmos simples de recuperação da informação, combinados com técnicas de pré-processamento e otimização de parâmetros, na classificação de descrições curtas de produtos em português. A análise fundamentou-se na hipótese de que tais algoritmos, quando devidamente ajustados, poderiam melhorar significativamente métricas de desempenho como precisão, acurácia, recall e F1-score.

Os resultados apresentados no capítulo de resultados demonstraram que a combinação de métodos de vetorização (como Term Frequency (TF) e Term Frequency-Inverse Document Frequency (TFIDF)), aplicação de N-gramas e normalização L2 teve um impacto considerável no desempenho dos modelos. Em particular, o método Binary com N-Gram [1, 2] e sem normalização destacou-se, alcançando a maior acurácia (89.56%) e F1 Score Macro (70.09%). Da mesma forma, o método Term Frequency-Inverse Document Frequency (TFIDF) com N-Gram [1, 2] e normalização L2 também apresentou desempenho robusto, confirmando a hipótese de que a combinação de técnicas apropriadas de pré-processamento e otimização de parâmetros pode efetivamente melhorar os resultados.

Confirma-se a hipótese central do estudo, que postulava que algoritmos simples de recuperação da informação poderiam melhorar significativamente a precisão, acurácia, recall e F1-score na classificação de descrições curtas de produtos em português, pelos resultados obtidos. A análise detalhada dos métodos Argmax revelou que, ao aplicar técnicas de vetorização e normalização adequadas, foi possível alcançar melhorias substanciais nas métricas de desempenho.

Atenderam-se aos objetivos específicos delineados na introdução:

1. Adaptação de métodos de recuperação da informação: Adaptaram-se métodos como sacola de palavras, Term Frequency (TF) e Term Frequency-Inverse Document Frequency (TFIDF) para a classificação de descrições curtas de produtos.

2. Avaliação de desempenho: Demonstrou-se que algoritmos simples de recuperação da informação, como Term Frequency (TF) e Term Frequency-Inverse Document Frequency (TFIDF), combinados com métricas de similaridade, são eficazes na classificação de textos curtos em português.

3. Impacto das técnicas de pré-processamento: Revelou-se que a normalização L2 e a aplicação

de N-gramas (particularmente bigramas) têm um impacto significativo na eficácia dos modelos.

4. Otimização de parâmetros: Identificaram-se, através da validação cruzada e outras técnicas de ajuste, os parâmetros mais adequados para maximizar a acurácia e o F1-score macro dos algoritmos avaliados.

5. Métrica unificada: Propôs-se e aplicou-se uma métrica unificada que combina acurácia e F1-score macro, permitindo uma comparação mais integrada e holística dos resultados.

As principais contribuições deste estudo incluem uma análise aprofundada do desempenho de diferentes algoritmos de recuperação da informação na classificação de textos curtos em português e a apresentação de diretrizes sobre as técnicas de pré-processamento mais eficazes. Além disso, a adaptação de uma métrica unificada para avaliação de desempenho mostrou-se valiosa, proporcionando uma ferramenta adicional para futuras pesquisas na área.

Limitações e Trabalhos Futuros

Apesar dos resultados promissores, este estudo apresenta algumas limitações. A avaliação foi limitada a descrições curtas de produtos, o que pode não refletir a complexidade de outros tipos de textos em português. Além disso, a análise foi restrita a um conjunto específico de técnicas e parâmetros, sugerindo que futuros estudos poderiam explorar uma gama mais ampla de algoritmos e métodos de pré-processamento.

Além disso, a não utilização de algoritmos de Aprendizado de Máquina (AM) mais avançados é uma limitação significativa. Conforme apontado em um artigo publicado pelo próprio autor, a partir de uma base de desempenho de 90%, é possível aumentar significativamente a precisão utilizando técnicas mais sofisticadas de Aprendizado de Máquina (AM).

Pesquisas futuras podem expandir o escopo desta investigação, aplicando os métodos avaliados a diferentes tipos de textos e explorando novas técnicas de recuperação da informação e Aprendizado de Máquina (AM). Também seria valioso considerar a implementação de modelos mais avançados, como redes neurais profundas, e comparar seus desempenhos com os algoritmos mais simples analisados neste estudo.

REFERÊNCIAS

- AGGARWAL, A.; SINGH, J.; GUPTA, D. K. A review of different text categorization techniques. **International Journal of Engineering & Technology**, v. 7, n. 3.8, p. 11–15, 2018. Citado nas páginas 17, 22, 31 e 48.
- AGGARWAL, C. C.; ZHAI, C. A survey of text classification algorithms. In: **Mining text data**. [S.l.]: Springer, 2012. p. 163–222. Citado nas páginas 29 e 49.
- ALSMADI, I.; GAN, K. H. Review of short-text classification. **International Journal of Web Information Systems**, Emerald Publishing Limited, 2019. Citado nas páginas 21, 22, 30 e 31.
- BHAVANI, A.; KUMAR, B. S. A review of state art of text classification algorithms. In: IEEE. **2021 5th International Conference on Computing Methodologies and Communication (ICCMC)**. [S.l.], 2021. p. 1484–1490. Citado nas páginas 17, 22, 31, 48, 50, 51 e 52.
- BIRUNDA, S. S.; DEVI, R. K. A review on word embedding techniques for text classification. **Innovative Data Communication Technologies and Application: Proceedings of ICIDCA 2020**, Springer, p. 267–281, 2021. Citado na página 40.
- BOSER, B. E.; GUYON, I. M.; VAPNIK, V. N. A training algorithm for optimal margin classifiers. In: ACM. **Proceedings of the fifth annual workshop on Computational learning theory**. [S.l.], 1992. p. 144–152. Citado na página 51.
- BOTTOU, L.; CURTIS, F. E.; NOCEDAL, J. **Optimization methods for large-scale machine learning**. [S.l.]: Springer, 2018. v. 2. Citado na página 27.
- BRANCO, A.; MENDES, A.; PEREIRA, S.; HENRIQUES, P.; PELLEGRINI, T.; MEINEDO, H.; TRANCOSO, I.; QUARESMA, P.; LIMA, V.; BACELAR, F. **A língua portuguesa na era digital—The Portuguese Language in the Digital Age**. [S.l.]: Springer, 2012. Citado na página 21.
- BREIMAN, L.; FRIEDMAN, J.; OLSHEN, R.; STONE, C. **Classification and regression trees**. [S.l.]: Wadsworth & Brooks/Cole Advanced Books & Software, 1984. Citado na página 52.
- BREIMAN, L.; FRIEDMAN, J.; STONE, C. J.; OLSHEN, R. A. **Classification and regression trees**. [S.l.]: Wadsworth Brooks, 1984. Citado na página 60.
- CORTES, C.; VAPNIK, V. Support-vector networks. **Machine learning**, Springer, v. 20, n. 3, p. 273–297, 1995. Citado na página 50.
- COVER, T.; HART, P. Nearest neighbor pattern classification. **IEEE transactions on information theory**, IEEE, v. 13, n. 1, p. 21–27, 1967. Citado na página 49.
- CRESWELL, J. W. **Research Design: Qualitative, Quantitative, and Mixed Methods Approaches**. 4th. ed. Thousand Oaks, California: SAGE Publications, Inc, 2014. ISBN 978-1452226101. Citado na página 63.
- DARÚ, G. H. **Classificação Produtos Varejo CPG PTBR**. Kaggle, 2022. Disponível em: <<https://www.kaggle.com/dsv/4265348>>. Citado na página 64.

- DAVE, K.; LAWRENCE, S.; PENNOCK, D. Mining the peanut gallery: opinion extraction and semantic classification of product reviews. In: ACM. **Proceedings of the 12th international conference on World Wide Web**. [S.l.], 2003. p. 511–520. Citado na página 27.
- DENG, X.; LI, Y.; WENG, J.; ZHANG, J. Feature selection for text classification: A review. **Multimedia Tools and Applications**, Springer, v. 78, p. 3797–3816, 2019. Citado nas páginas 35, 36, 37, 46 e 47.
- DEZA, M. M.; DEZA, E. **Encyclopedia of Distances**. [S.l.]: Springer, 2009. Citado na página 50.
- FORMAN, G. An extensive empirical study of feature selection metrics for text classification. **The Journal of Machine Learning Research**, v. 3, p. 1289–1305, 2003. Citado na página 27.
- GANDOMI, A.; HAIDER, M. Beyond the hype: Big data concepts, methods, and analytics. **International Journal of Information Management**, v. 35, n. 2, p. 137–144, 2015. ISSN 0268-4012. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0268401214001066>>. Citado na página 21.
- GASPARETTO, A.; MARCUZZO, M.; ZANGARI, A.; ALBARELLI, A. A survey on text classification algorithms: From text to predictions. **Information**, MDPI, v. 13, n. 2, p. 83, 2022. Citado nas páginas 17, 48 e 49.
- GRANDINI, M.; BAGLI, E.; VISANI, G. Metrics for multi-class classification: an overview. **arXiv preprint arXiv:2008.05756**, 2020. Citado nas páginas 54 e 59.
- HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The Elements of Statistical Learning: Data Mining, Inference, and Prediction**. 2nd. ed. New York: Springer, 2009. ISBN 978-0387848570. Citado nas páginas 50, 54 e 60.
- HOERL, A. E.; KENNARD, R. W. Ridge regression: Biased estimation for nonorthogonal problems. **Technometrics**, Taylor & Francis, v. 12, n. 1, p. 55–67, 1970. Citado na página 53.
- HOSMER, D. W.; LEMESHOW, S.; STURDIVANT, R. X. **Applied Logistic Regression**. [S.l.]: Wiley, 2013. Citado na página 53.
- HOWARD, J.; RUDER, S. Universal language model fine-tuning for text classification. In: **Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)**. [S.l.: s.n.], 2018. v. 1, p. 328–339. Citado na página 27.
- JOACHIMS, T. Training linear svms in linear time. In: ACM. **Proceedings of the 12th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. [S.l.], 2006. p. 217–226. Citado na página 27.
- KOHAVI, R. *et al.* A study of cross-validation and bootstrap for accuracy estimation and model selection. In: MONTREAL, CANADA. **Ijcai**. [S.l.], 1995. v. 14, n. 2, p. 1137–1145. Citado nas páginas 60, 61 e 69.
- KOWSARI, K.; MEIMANDI, K. J.; HEIDARYSAFA, M.; MENDU, S.; BARNES, L.; BROWN, D. Text classification algorithms: A survey. **Information**, MDPI, v. 10, n. 4, p. 150, 2019. Citado nas páginas 17, 29, 31, 48, 49, 50, 51, 52 e 54.
- KUSNER, M.; SUN, Y.; KOLKIN, N.; WEINBERGER, K. From word embeddings to document distances. In: **International Conference on Machine Learning**. [S.l.: s.n.], 2015. p. 957–966. Citado na página 27.
- LAI, S.; XU, L.; LIU, K.; ZHAO, J. Recurrent convolutional neural networks for text classification. In: AAAI PRESS. **Proceedings of the 24th International Joint Conference on Artificial Intelligence**. [S.l.], 2015. p. 3133–3139. Citado na página 27.
- LE, L. Q.; MIKOLOV, T. Distributed representation of sentences and documents. **International Journal of Advanced Computer Science and Applications**, v. 5, n. 3, p. 2, 2014. Citado na página 27.

- LE, Q.; MIKOLOV, T. Distributed representations of sentences and documents. **International Journal of Artificial Intelligence and Data Mining**, v. 3, n. 2, p. 63–91, 2014. Citado na página 27.
- MCFADDEN, D. Conditional logit analysis of qualitative choice behavior. In: **Frontiers in Econometrics**. [S.l.]: Academic Press, 1973. p. 105–142. Citado na página 54.
- MIROŃCZUK, M. M.; PROTASIEWICZ, J. A recent overview of the state-of-the-art elements of text classification. **Expert Systems with Applications**, Elsevier, v. 106, p. 36–54, 2018. Citado nas páginas 36 e 39.
- NASEEM, U.; RAZZAK, I.; EKLUND, P. W. A survey of pre-processing techniques to improve short-text quality: a case study on hate speech detection on twitter. **Multimedia Tools and Applications**, Springer, v. 80, p. 35239–35266, 2021. Citado nas páginas 22, 31, 32, 34 e 69.
- NATEKIN, A.; KNOLL, A. Gradient boosting machines: A tutorial. **Frontiers in computational statistics**, v. 4, 2013. Citado na página 27.
- PAN, S. J.; YANG, Q. A survey on transfer learning. **IEEE Transactions on knowledge and data engineering**, IEEE, v. 22, n. 10, p. 1345–1359, 2009. Citado na página 26.
- _____. A survey on transfer learning. **IEEE Transactions on knowledge and data engineering**, IEEE, v. 22, n. 10, p. 1345–1359, 2010. Citado na página 27.
- PEDREGOSA, F.; VAROQUAUX, G.; GRAMFORT, A.; MICHEL, V.; THIRION, B.; GRISEL, O.; BLONDEL, M.; PRETTENHOFER, P.; WEISS, R.; DUBOURG, V.; VANDERPLAS, J.; PASSOS, A.; COURNAPEAU, D.; BRUCHER, M.; PERROT, M.; DUCHESNAY, E. Scikit-learn: Machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011. Citado na página 64.
- PU, Q.; YANG, G.-W. Short-text classification based on ica and lsa. In: SPRINGER. **International Symposium on Neural Networks**. [S.l.], 2006. p. 265–270. Citado na página 39.
- QUINLAN, J. Induction of decision trees. **Machine learning**, v. 1, n. 1, p. 81–106, 1986. Citado na página 52.
- RAFFEL, C.; SHAZEER, N.; ROBERTS, A.; LEE, K.; MATENA, G.; ZHOU, Y.; LI, W.; LIU, P. J. Exploring the limits of transfer learning with a unified text-to-text transformer. In: **International Conference on Learning Representations**. [S.l.: s.n.], 2020. Citado na página 27.
- RAINA, R.; BATTLE, A.; LEE, H.; PACKER, B.; NG, A. Self-taught learning: Transfer learning from unlabeled data. In: ACM. **Proceedings of the 24th international conference on Machine learning**. [S.l.], 2007. p. 759–766. Citado na página 27.
- RENNIE, J. D.; SHIH, L.; TEEVAN, J.; KARGER, D. Tackling the poor assumptions of naive bayes text classifiers. In: **ICML**. [S.l.: s.n.], 2003. v. 3, p. 616–623. Citado na página 27.
- ROSSUM, G. V.; DRAKE, F. L. **Python 3 Reference Manual**. Scotts Valley, CA: CreateSpace, 2009. ISBN 1441412697. Citado na página 64.
- SALTON, G.; BUCKLEY, C. Term-weighting approaches in automatic text retrieval. **Information processing & management**, Elsevier, v. 24, n. 5, p. 513–523, 1988. Citado na página 37.
- SEBASTIANI, F. Machine learning in automated text categorization. **ACM Computing Surveys (CSUR)**, ACM, v. 34, n. 1, p. 1–47, 2002. Citado na página 27.
- SHANNON, C. A mathematical theory of communication. **Bell System Technical Journal**, v. 27, n. 3, p. 379–423, 1948. Citado na página 52.

- SOKOLOVA, M.; LAPALME, G. A systematic analysis of performance measures for classification tasks. **Information Processing & Management**, v. 45, n. 4, p. 427–437, 2009. Citado nas páginas 26 e 27.
- SONG, G.; YE, Y.; DU, X.; HUANG, X.; BIE, S. Short text classification: a survey. **Journal of multimedia**, Citeseer, v. 9, n. 5, 2014. Citado nas páginas 21, 30 e 31.
- SRIVASTAVA, N.; HINTON, G.; KRIZHEVSKY, A.; SALAKHUTDINOV, R. Dropout: A simple way to prevent neural networks from overfitting. **The Journal of Machine Learning Research**, v. 15, p. 1929–1958, 2014. Citado nas páginas 26 e 27.
- THARWAT, A. Classification assessment methods. **Applied Computing and Informatics**, Elsevier, 2018. Citado na página 54.
- TIBSHIRANI, R. Regression shrinkage and selection via the lasso. **Journal of the Royal Statistical Society: Series B (Methodological)**, v. 58, n. 1, p. 267–288, 1996. Citado na página 53.
- TONG, S.; KOLLER, D. Support vector machine active learning for text classification. In: ACM. **Proceedings of the 19th international conference on Machine learning**. [S.l.], 2002. p. 45–52. Citado na página 27.
- TSCHANTARIDIS, I.; HOFMANN, T.; JOACHIMS, T.; ALTUN, Y. Support vector machine learning for interdependent and structured output spaces. In: **Proceedings of the International Conference on Machine Learning**. [S.l.: s.n.], 2004. p. 104–111. Citado na página 27.
- YATES, R. B.; NETO, B. R. **Recuperação de Informação-: Conceitos e Tecnologia das Máquinas de Busca**. [S.l.]: Bookman Editora, 2013. Citado nas páginas 37 e 41.
- YIN, R. K. **Case Study Research and Applications: Design and Methods**. 6th. ed. Thousand Oaks, California: SAGE Publications, Inc, 2018. ISBN 978-1506336169. Citado na página 63.
- ZHANG, M.-L.; ZHOU, Z.-H. Ml-knn: A lazy learning approach to multi-label learning. **Pattern Recognition**, Elsevier, v. 40, n. 7, p. 2038–2048, 2007. Citado na página 27.
- ZHANG, Y.; JIN, R.; ZHOU, Z.-H. Understanding bag-of-words model: a statistical framework. **International journal of machine learning and cybernetics**, Springer, v. 1, n. 1, p. 43–52, 2010. Citado na página 35.